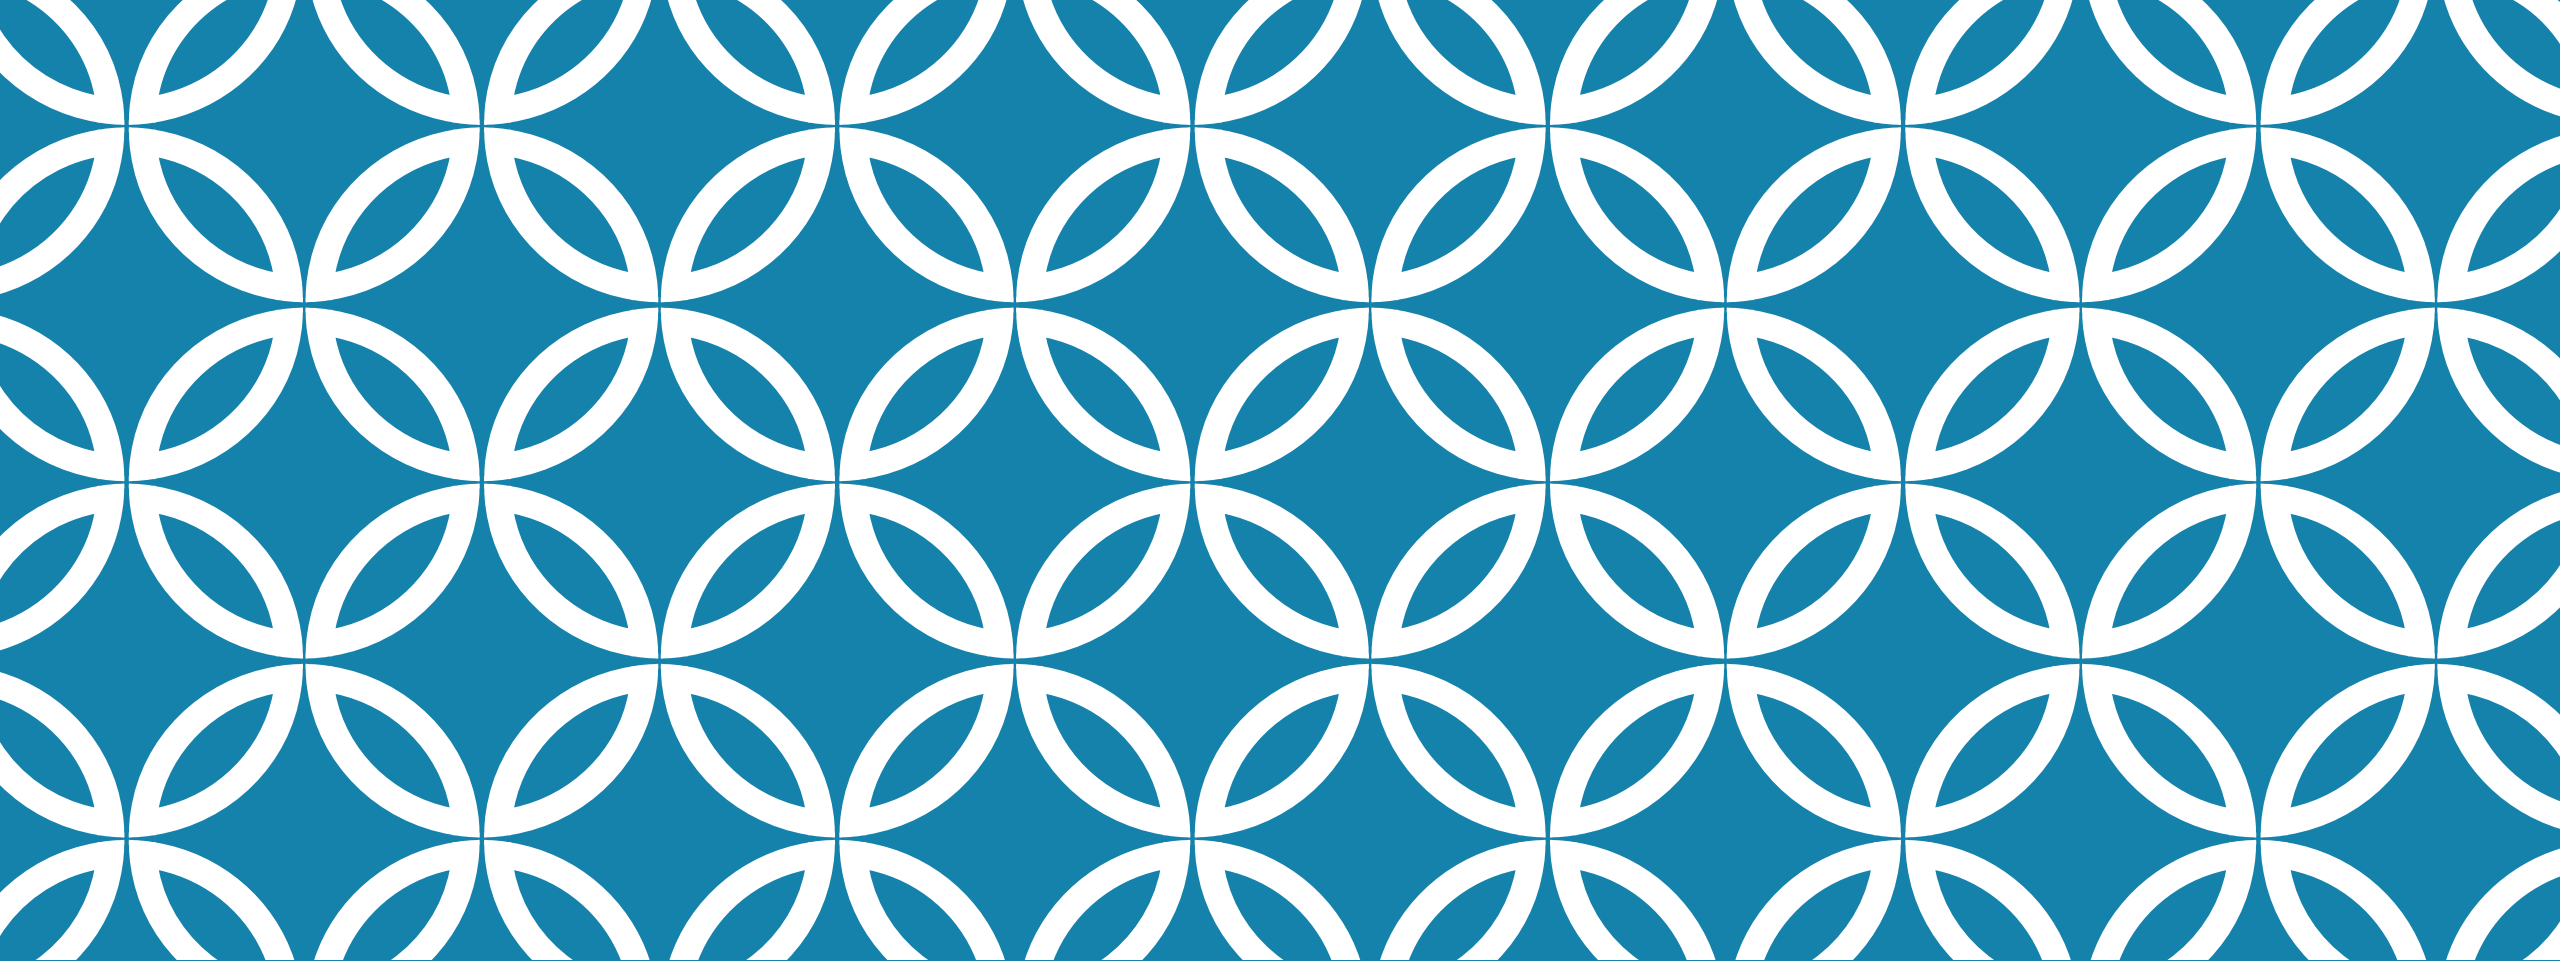


APLICAÇÕES EM APRENDIZADO DE MÁQUINA 2019/1

Johannes Von Lochter

TERCEIRO ENCONTRO

Objetivos:

- Seleção de atributos X Redução de dimensionalidade;

- Comitês de máquinas (ensemble) e diferentes estratégias de aprendizagem;

- Desafio sobre previsão de chuva na segunda parte.

SELEÇÃO DE ATRIBUTOS X REDUÇÃO

Uma confusão muito comum é com relação aos conceitos de seleção de atributos e redução de dimensionalidade.

Enquanto a seleção de atributos reduz o número de atributos selecionando os mais relevantes, a redução tenta encontrar uma representação menor que mantém as informações da representação original.

SELEÇÃO DE ATRIBUTOS X REDUÇÃO

As funções no Scikit-Learn para seleção de atributos e redução:

Seleção de atributos: SelectKBest()

Redução de dimensionalidade: PCA()

DIFERENTES MODELOS

Vamos utilizar o seguinte arquivo como roteiro para explorar as funções de seleção de atributos e redução de atributos:

03_01_Selecao.ipynb

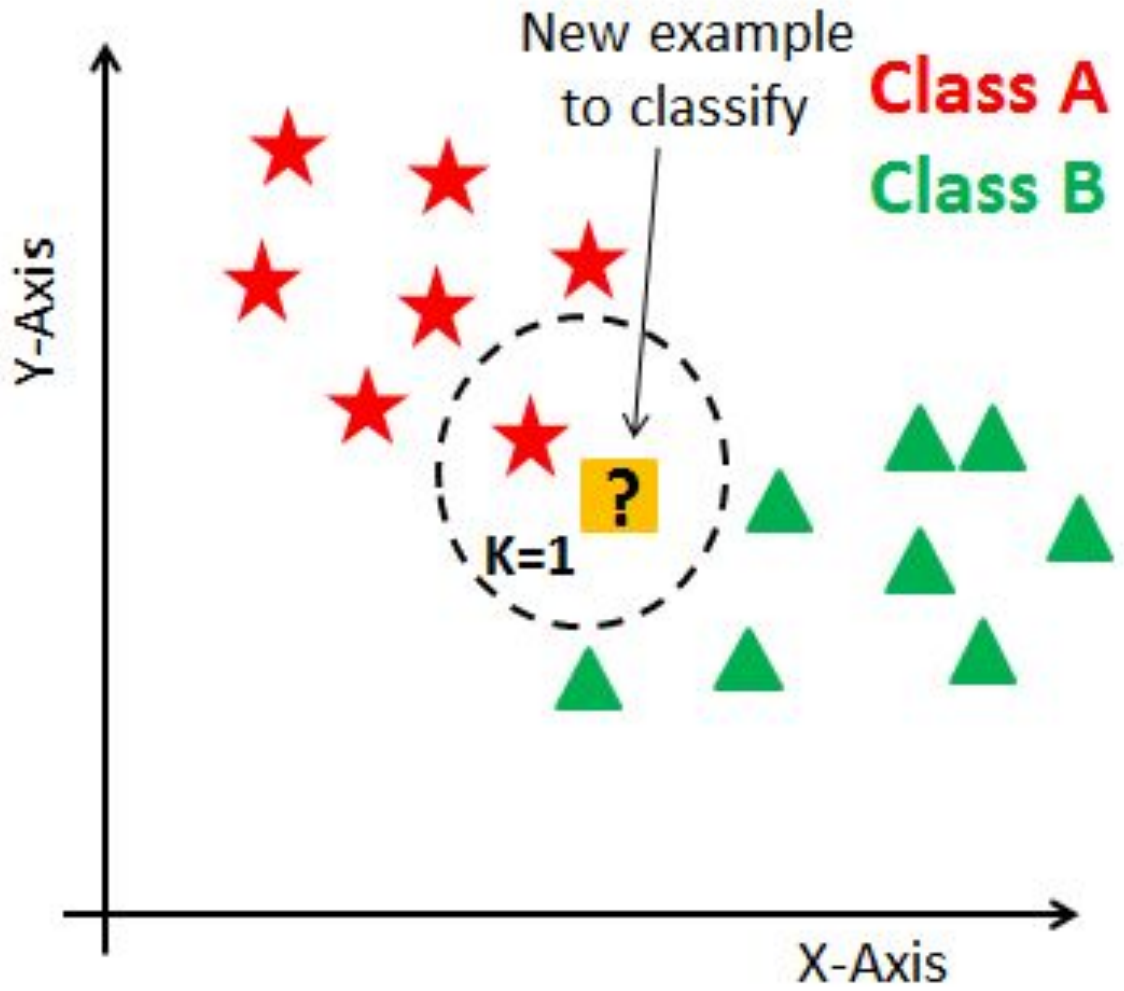
ESTRATÉGIAS DE APRENDIZAGEM

Os algoritmos de aprendizagem normalmente estão baseado em algum princípio para gerar a hipótese ou função acerca dos dados, o que pode ser entendido como modelo de aprendizado.

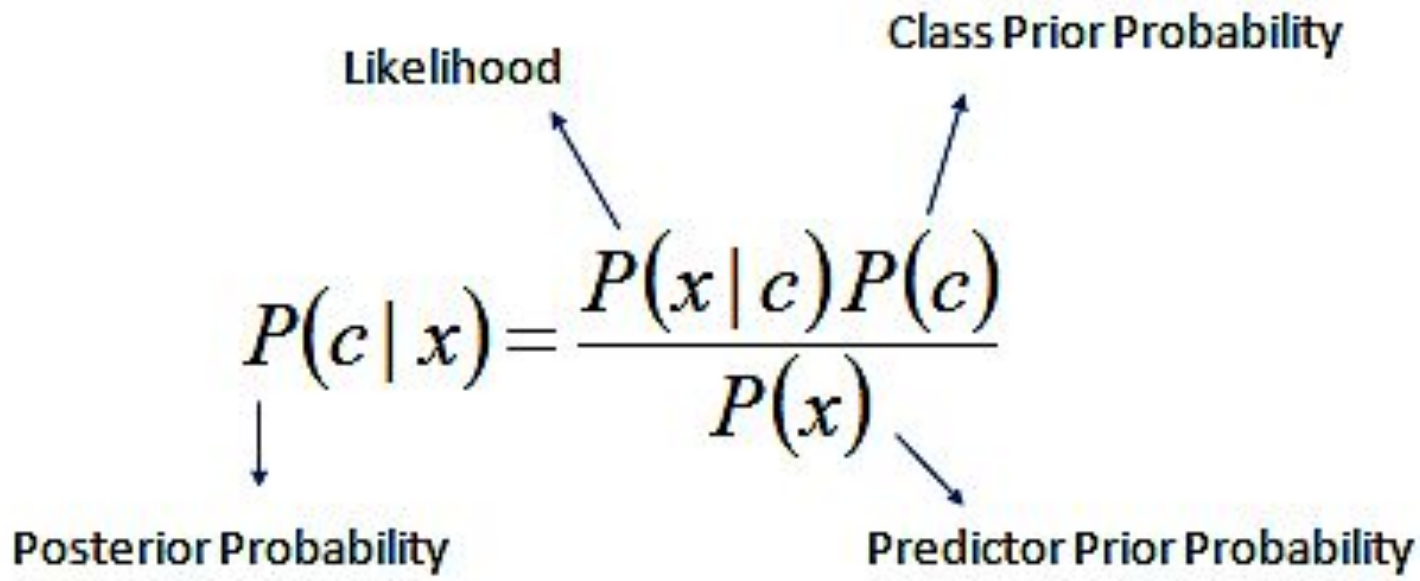
As estratégias mais comuns são:

- Distância;
- Probabilidade;
- Árvores de decisão; e
- Otimização.

DISTÂNCIA

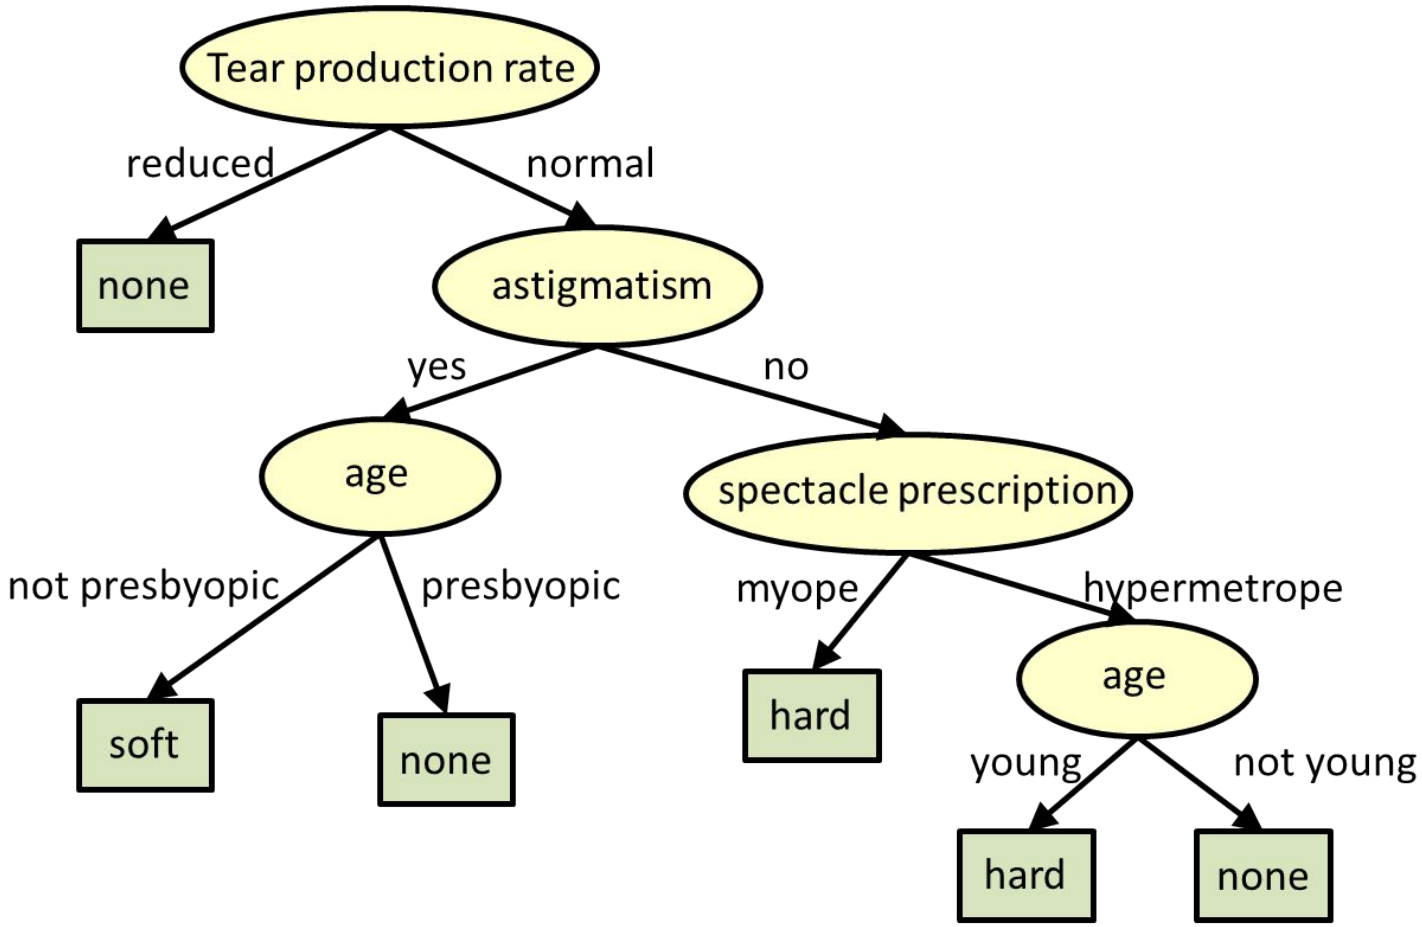


PROBABILIDADE

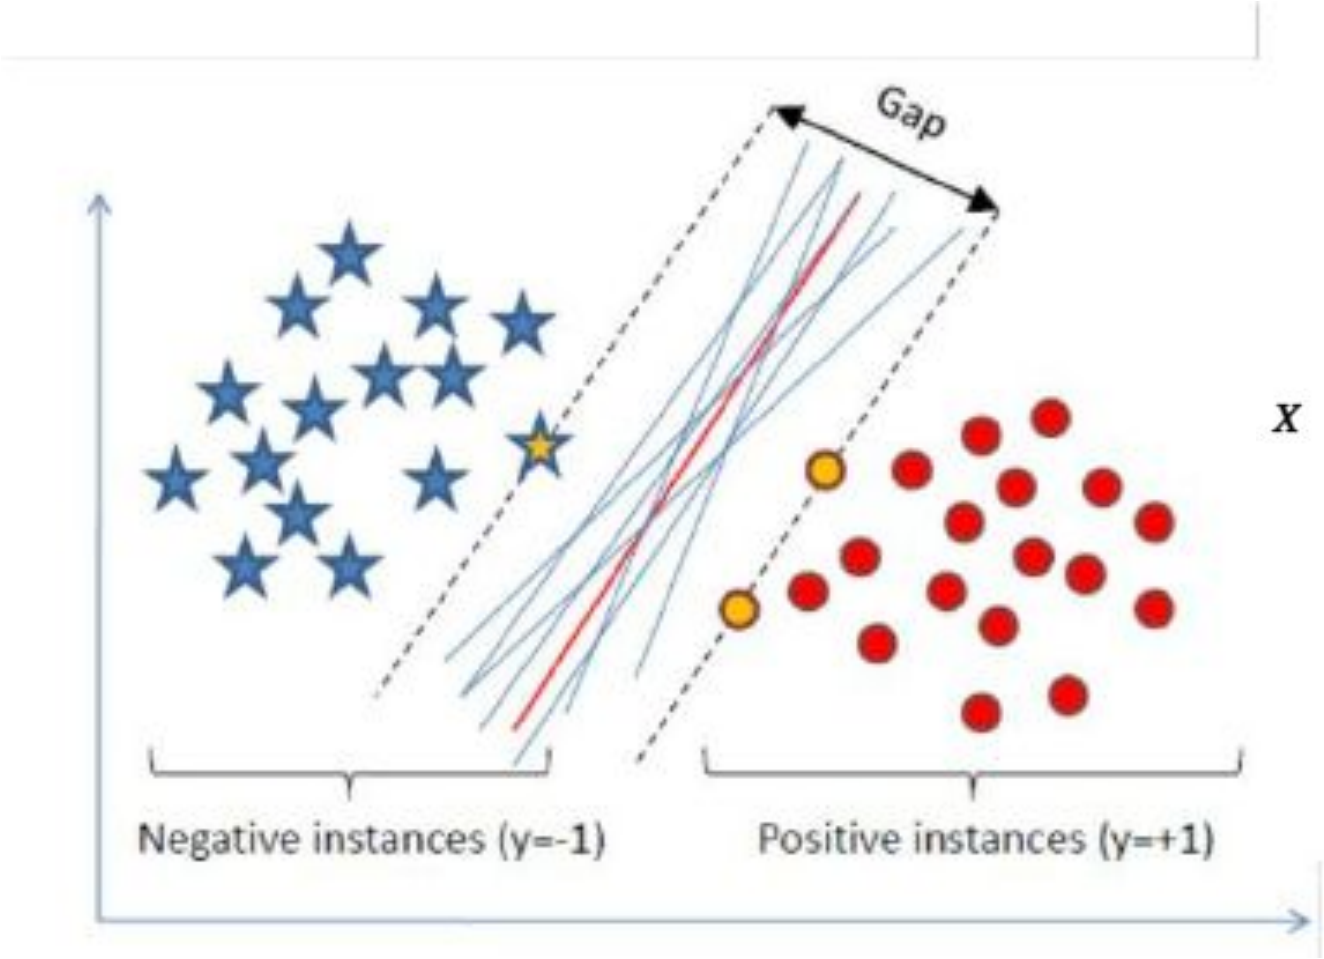


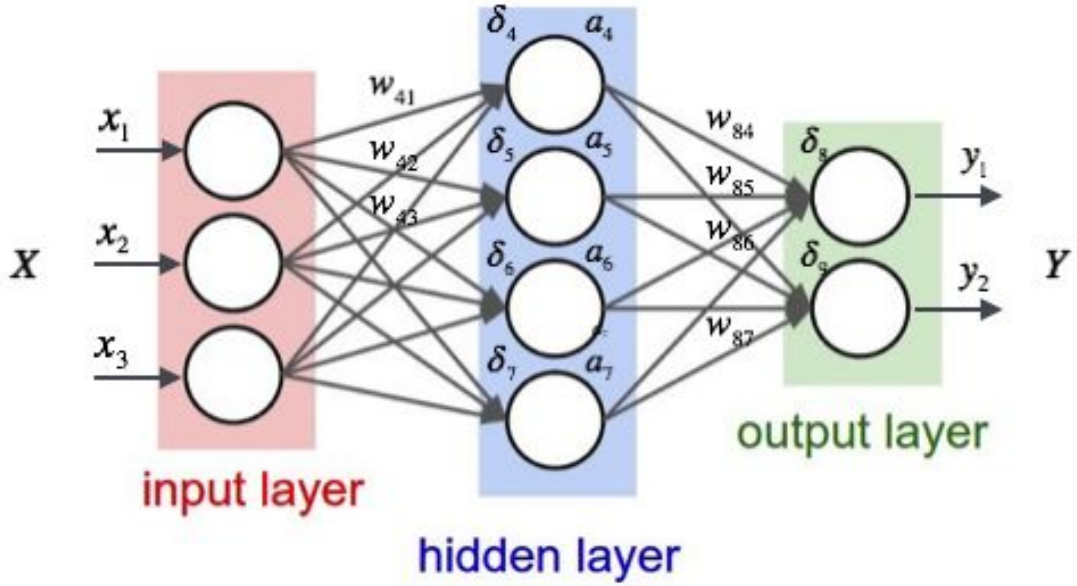
$$P(c \mid \mathbf{X}) = P(x_1 \mid c) \times P(x_2 \mid c) \times \cdots \times P(x_n \mid c) \times P(c)$$

ÁRVORES DE DECISÃO



OTIMIZAÇÃO


Gap
Negative instances (y=-1)
Positive instances (y=+1)


X
Y
input layer
hidden layer
output layer

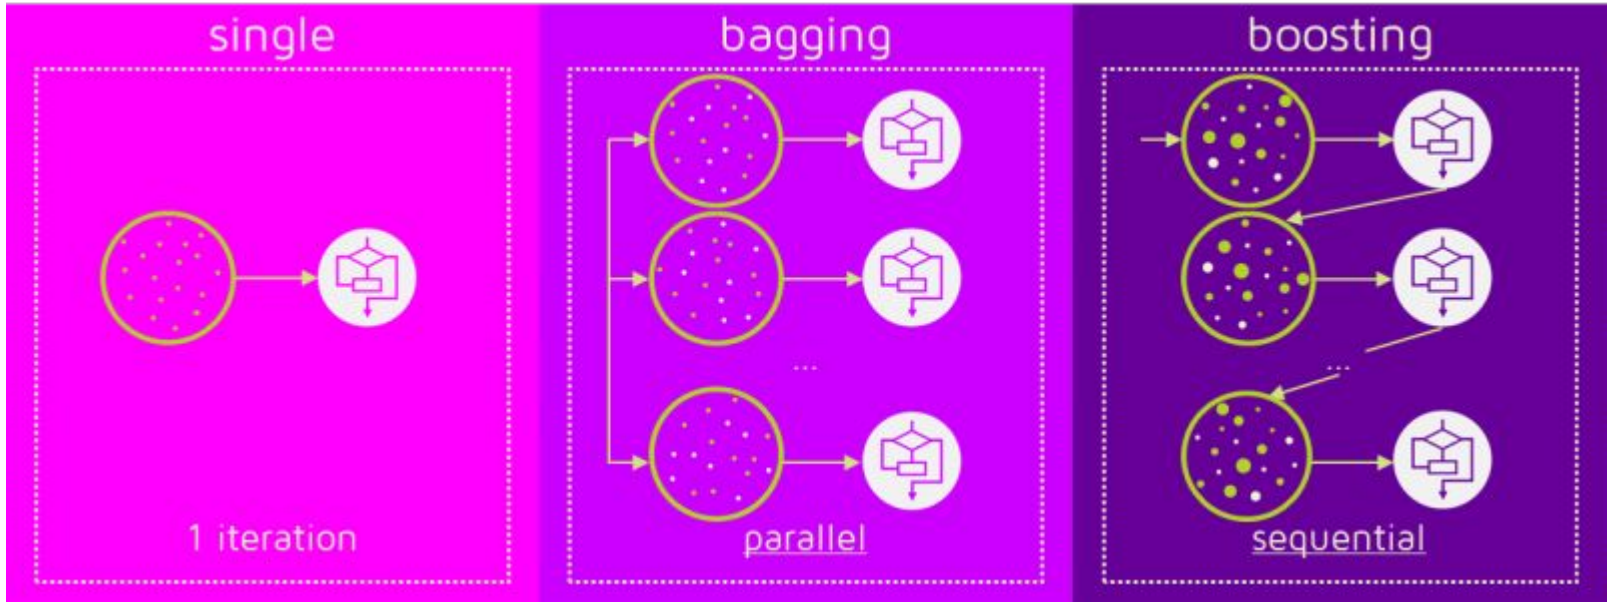
COMITÊ DE MÁQUINAS - ENSEMBLE

Um comitê de máquinas, ou ensemble, é a combinação de vários modelos para chegar a uma resposta final. Existe dois grupos de ensemble: bagging e boosting. Ambos criam subgrupos de amostras e atributos para gerar novos modelos e combiná-los ao final.

É como um grupo de diferentes especialistas opinando em um problema com característica em comum a todos.

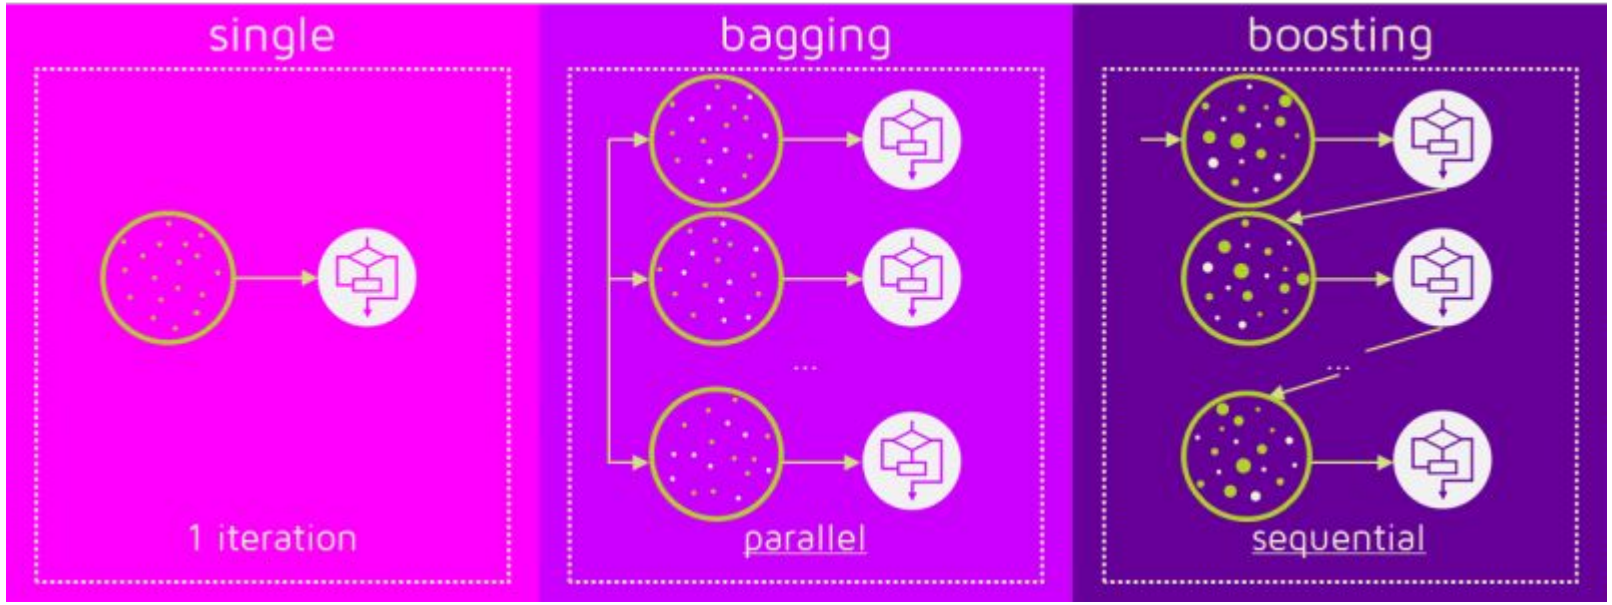
COMITÊ DE MÁQUINAS - ENSEMBLE

Bagging: cria-se vários modelos a partir de uma mesma redistribuição de dados, e combina-se os resultados desses modelos.



COMITÊ DE MÁQUINAS - ENSEMBLE

Boosting: cria-se vários modelos de forma sequencial, e há maior chance de aparecer os dados que os modelos anteriores erraram.



COMITÊ DE MÁQUINAS - ENSEMBLE

Não existe uma regra para qual método é melhor, mas normalmente as técnicas baseadas em bagging podem reduzir overfitting enquanto boosting podem piorar a situação.

DIFERENTES MODELOS E ENSEMBLES

Vamos utilizar o seguinte arquivo como roteiro para essa parte:

03_02_Modelos.ipynb

DESAFIO

Considere o arquivo weatherAUS.csv que contém informações sobre a previsão de chuva para o dia seguinte na Austrália.

A coluna Risk_MM deve ser descartada.

A coluna RainTomorrow deve ser utilizada com rótulo.