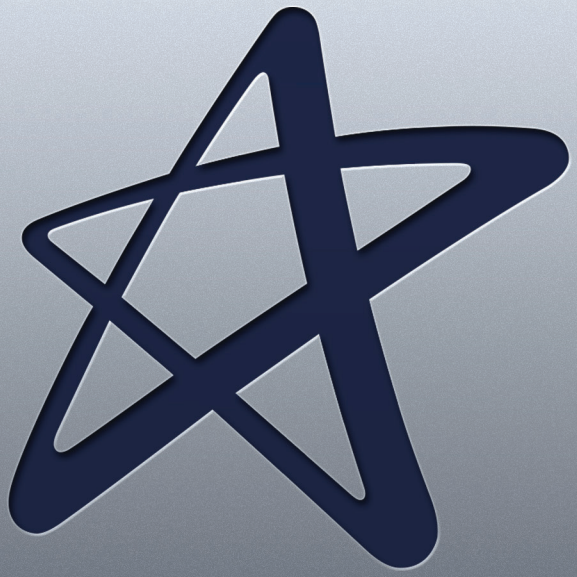
Pós-Graduação

Processos ETL



Cruzeiro do Sul Virtual
Educação a Distância

Business Intelligence e Introdução aos Processos ETL

Responsável pelo Conteúdo:
Profa. Ms. Lúcia Contente Mós

Revisão Textual:
Prof. Esp. Claudio Pereira do Nascimento

Unidade

Business Intelligence e Introdução aos Processos ETL

Nesta unidade, trabalharemos os seguintes tópicos:

- Introdução ao Tema
- *Business Intelligence*
- Orientações para Leitura Obrigatória



Fonte: iStock/Getty Images

Objetivos

- Entender a definição de BI e como os processos ETL estão inseridos na estratégia de montagem dos Sistemas de BI;
- Conhecer a definição e as características de um *Data Warehouse*;
- Conhecer e determinar diretrizes dos processos ETL
- Saber identificar os objetivos, requisitos dos processos ETL;
- Entender a importância e a utilização dos processos ETL para alimentar o DW.

Contextualização

Saber e entender a definição de BI e como os processos ETL estão inseridos na estratégia de montagem dos Sistemas de BI. Para conhecer a definição e as características de um *Data Warehouse* e determinar diretrizes dos processos ETL, além de identificar os objetivos, requisitos dos processos ETL, reconhecendo a importância e a utilização dos processos ETL para alimentar o DW. São alguns dos itens mais requisitados para profissionais que sejam Administradores, Analistas de BI. Daí a importância do material que consta nesta unidade.

Introdução ao Tema

Para entendermos a necessidade dos processos ETl, primeiro é necessário compreender onde esses processos estão inseridos e porque são necessários. Por esse motivo, antes de qualquer coisa, é importante falar sobre BI (*Business Intelligence*).

Tem-se a exigência de conhecer seus clientes e então, suas ações conseguirão atraí-los em novos negócios. Alguns detalhes como ferramentas de análise de dados, modelos estatísticos, dados históricos do mercado, pesquisas junto ao público, contribuem para tomadas de decisões com foco na eficiência dos resultados. Mas o cenário atual é ainda mais complexo. Diante da dificuldade em processar e assimilar a grande quantidade de dados gerados todos os dias em ações online, destaca-se a importância da BI - *Business Intelligence* - para compreender uma geração de consumidores que nasce conectada e que se comunica e consome múltiplas fontes de informação de forma dinâmica. O termo *Business Intelligence* (BI), inteligência de negócios, refere-se ao processo de coleta, organização, análise, compartilhamento e monitoramento de informações que oferecem suporte à gestão de negócios. É o conjunto de teorias, metodologias, processos, estruturas e tecnologias que transformam uma grande quantidade de dados brutos em informação útil para tomadas de decisões estratégicas. O conjunto do seu negócio, a gestão dos negócios, a tecnologia da informação, todos esses setores integrados formam a *Business Intelligence*.

As primeiras fontes de informações são coletadas dentro das próprias empresas. Posteriormente, as segundas fontes de informações incluem as necessidades do consumidor, o processo de decisão do cliente, as pressões competitivas, as condições industriais relevantes, os aspectos econômicos e tecnológicos e as tendências culturais. Cada sistema de BI determina uma meta específica, tendo por base o objetivo organizacional e a visão da empresa, existindo em ambos objetivos, sejam eles de longo ou curto prazo, as disputas nos negócios, a coleta de informação.

Tudo começa com a coleção de dados obtida através dos processos ETL, a integração de dados de uma ou mais fontes e assim, cria um repositório central de dados, um data *Warehouse*, os grandes bancos de dados. Com essa imensidão de dados, *Data Mining*, aplica-se a mineração desses dados, o processo de explorar grandes quantidades de dados à procura de padrões consistentes para detectar relacionamentos e novos subconjuntos de dados a serem mapeados e extrair informações privilegiadas. Análises, *Analytics*, de minerações geram relatórios, reporting, detalhados para fortalecer o esclarecimento do cenário. Reengenharia de processos de negócio (BPR) trata-se de uma estratégia de gestão de negócios para a análise e desenho dos fluxos de trabalho e dos processos de negócios visando a reestruturação organizacional, com foco no design de baixo para cima dos processos de negócios dentro de uma organização. E Benchmarking, a busca das melhores práticas com o propósito de maximizar o desempenho, em que uma empresa examina como realizar uma função específica a fim de melhorar, realizando a mesma ou uma função semelhante, ou seja, um processo de comparação do desempenho entre dois ou mais sistemas.

O profissional nesse universo de "*Business Intelligence*" deve se atentar a alguns detalhes importantes para uma boa atuação, buscar resultados da capacidade de detectar oportunidades de negócios e associar seus levantamentos numéricos a eventos de sucesso, focar nas análises das necessidades e desejos dos clientes. E então detectar as tendências e associá-las aos objetivos de seus clientes, promovendo seus produtos e serviços. Não há uma receita de bolo e nem uma garantia de que seus resultados serão satisfatórios, porém as boas práticas de BI reduzem os erros e possibilitam conhecer os padrões comportamentais dos clientes, o que é determinante na oferta de um produto.

A evolução da Internet mudou tudo, se até então a aplicação desse conceito era a de levar informação a poucos colaboradores selecionados de uma empresa, para que fizessem uso em suas decisões, hoje a rede permite disponibilizar soluções de BI para um número maior de pessoas e passou a ser tratado como uma aplicação estratégica integrada, estando disponível através de estações de trabalho e nos servidores da empresa. E também como a maior aliada para a capitação de dados sobre os clientes, conseguindo detalhes preciosos com o monitoramento de mídias e redes sociais e do desempenho de SEO e propaganda online. Após a gestão dessa informação, terá conclusões importantes para o desenvolvimento empresarial e para a elaboração de cenários, tendo participação direta em decisões que promovam a competitividade.

Com ações mais eficientes e resultados mais significativos da gestão de dados para tomadas de decisões, empresas passaram a investir em meios digitais e ações de BI para alcançar suas metas. Promover a compreensão do processo de captura e utilização de informações externas e internas à organização, para o desenvolvimento e monitoramento de estratégias coerentes ao momento competitivo.

Com o crescimento exponencial do uso das redes sociais, grandes corporações nas suas estratégias de negócios e BI também precisou se reinventar. Várias empresas estão desenvolvendo software para ter à disposição o seu histórico de interações e relacionamento na Internet.

Não somente as grandes empresas, mas também as corporações de pequeno e médio porte necessitam de BI para auxiliá-las nas mais diferentes situações para a tomada de decisão, otimizar o trabalho da organização, reduzir custos, eliminar a duplicação de tarefas, permitir previsões de crescimento da empresa como um todo e contribuir para a elaboração de estratégias. Na grande maioria das vezes, para estas empresas enquadradas como pequenas, não precisam necessariamente de sistemas de alto investimento, com milhares de relatórios, gráficos para identificar que existe um problema específico numa linha de produto que não está sendo comercializado conforme a sua potencialidade, basta o feeling da área comercial em se pensar numa outra estratégia de vendas para o mesmo.

No Brasil, soluções de *Business Intelligence* estão em instituições financeiras, empresas de telecomunicações, seguradoras e em toda instituição que perceba a tendência da economia globalizada em que a informação precisa chegar de forma rápida, precisa e abundante. O principal benefício do BI para a empresa é a sua capacidade de fornecer informações precisas quando necessárias, incluindo uma visão em tempo real do desempenho corporativo geral e de suas partes individuais.

A partir dos resultados de uma pesquisa entre 510 empresas, que os benefícios do BI são a economia de tempo, versão única da verdade, melhores estratégias e planos, melhores decisões táticas, processos mais eficientes e a economia de custos.

Business Intelligence

O termo *Business Intelligence* foi empregado em 1989 pelo *Gartner Group*, que defendeu a criação do termo para abrigar todas as iniciativas de inteligência.

Com a globalização, o mundo ficou mais competitivo, as empresas e clientes ficaram muito ágeis e exigentes, por isso, torna-se necessário o tratamento e o sincronismo das informações para apoio às decisões e manter as empresas competitivas.

As informações assumem um papel fundamental para obtenção de lucros nos negócios. Diante da enorme quantidade de informações que são produzidas atualmente, é necessário definir os critérios para seleção e organização dos dados que são considerados importantes.

Business Intelligence pode ser definido como um conjunto de técnicas utilizadas para extrair inteligência a partir de dados sobre um determinado negócio. Consiste no processo de transformar dados em informação e através da descoberta transformar informação em conhecimento.

O objetivo é converter o volume de dados em informações relativas ao negócio, através de relatórios analíticos.

O propósito é sempre de extrair Inteligência dos dados. Quanto maior o volume, menor é a capacidade analítica sobre uma massa de dados. Por exemplo: analisar todas as vendas classificadas por ruas dos seus clientes ou analisar as vendas por bairro da sua cidade.

O dado utilizado para a tomada de decisão sempre é uma visão resumida do total das informações disponíveis.

Estratégia para montagem de Sistemas BI

A melhor estratégia é a montagem de um *Data Warehouse* para a organização dos dados. As vantagens da montagem do DW é a criação de um ambiente para integração e tratamento dos dados, o ambiente com objetivo único, a separação dos sistemas legados (transacionais), a base de dados otimizada para consultas e o suporte de ferramentas específicas para esse fim.

Definição de *Data Warehouse*

Data Warehouse é um processo que extrai os dados de sistemas operacionais e transacionais, limpando, transformando em informações organizadas permitindo análises dessas informações. Seus principais idealizadores e autores são: Ralph Kimball e Bill Inmon.

Segundo William Inmon, considerado o pai da tecnologia, *Data Warehouse* é um conjunto de dados orientado por assuntos, não volátil, variável com o tempo e integrado, criados para dar suporte à decisão.

Orientação por assunto: é o direcionamento que se tem da visão que será disponibilizada, do negócio da empresa, por exemplo: numa empresa de telecomunicações o principal assunto é o cliente, e esses clientes podem ser residenciais, empresas, telefonia pública, etc. Então, quando um arquiteto de DW for desenhar o modelo do mesmo, deve levar em consideração essas premissas, e dividir as visões de acordo com o que o tomador de decisões quer ver. É importante ressaltar que tudo irá girar em torno dos assuntos, seja qual for a visão que se quer ter, ou seja, a visão financeira da empresa, também irá girar em torno disso, seja a inadimplência, o faturamento, a lucratividade, etc.

Volatilidade: refere-se ao DW não sofrer modificações como nos sistemas tradicionais, por exemplo: No sistema de faturamento de uma empresa, todos os dias ocorrem inclusões e alterações de novos clientes, novos produtos e consumo. Já no DW, acontecem somente cargas de dados e consultas, ou seja, há somente selects (consultas) e inserts (inserções), e não há updates (atualizações). Em resumo, num sistema de apoio à decisão existem basicamente duas operações, a carga e consulta.

Variável com o tempo: é uma característica do DW. Ele sempre retrata a situação analisada, num determinado ponto do tempo. Por exemplo, pegue uma fotografia sua, quando recém-nascido, depois, pegue outra quando você tinha 5 anos e compare. Com certeza muitas modificações ocorreram, mas ela retrata exatamente a sua situação naquele exato momento do tempo, e isso acontece da mesma forma com o DW. São guardadas "fotografias" dos assuntos em determinados pontos do tempo, e com isso é possível traçar uma análise histórica e comparativa entre os fatos.

Integração: é responsável por sincronizar os dados de todos os sistemas existentes na empresa, e colocá-los no mesmo padrão. O DW extrai dados de vários sistemas da empresa, e em alguns casos, dados externos. Porém, geralmente os dados não estão padronizados, então é necessário integrar antes de fazer a carga no DW.

Por que precisamos de processos de ETL?

Alguns dos passos para implementação de BI são:

- Definir onde os dados serão armazenados e analisados;
- Definir como buscar os dados nas fontes (ERP,CRM,etc);
- Montar os processos de carga, armazenamento e análise.
- Definir como os dados serão estruturados para o BI;
- Qual o nível de detalhamento será armazenado;
- Definir junto às padronizações necessárias para a estrutura de dados;
- Determinar qual banco de dados será utilizado para armazenamento de dados;
- Determinar qual será o período de atualização dos dados;

- Definir como os dados serão capturados dos sistemas;
- Definir como os dados, nos sistemas fontes, serão disponibilizados.

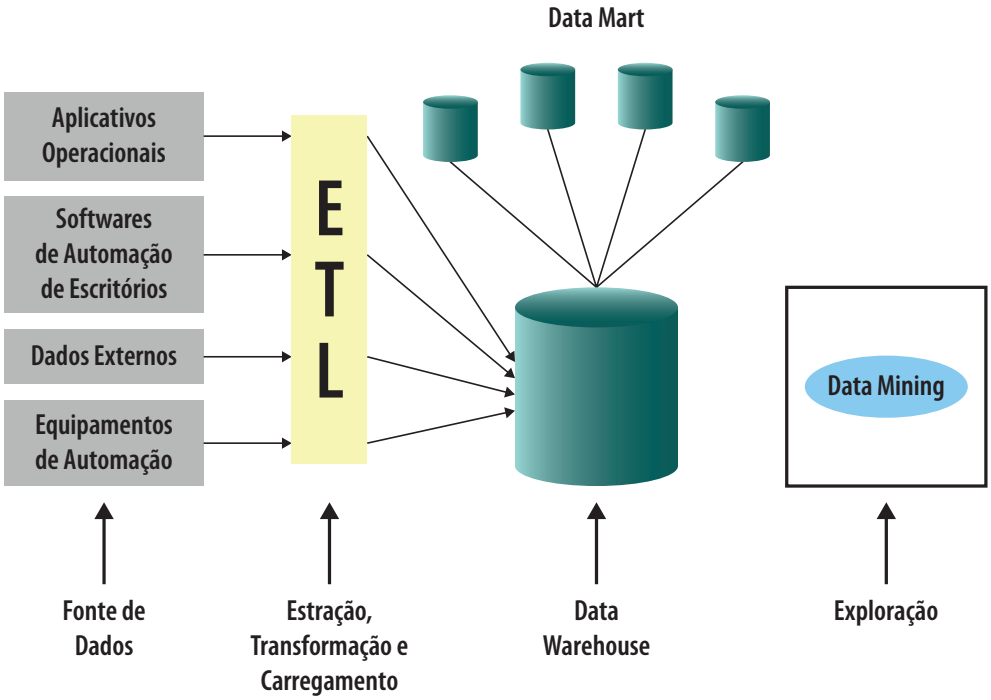


Figura 1

Definição de ETL ou ETC (Extração, Transformação e Carga)

E – Extração: extrair as informações de sistemas legados; muitas podem ser as fontes de dados como por exemplo: banco de dados relacionais, sistemas erp, redes sociais, vídeos, áudios, planilhas, documentos, etc. Essa extração leva os dados para uma área de trabalho chamada de área de staging. Essa área é dedicada para que se possa trabalhar e aplicar técnicas aos dados coletados.

T – Transformação: Transformar, limpar modificar a informação.

L/C – Load ou Carga dos dados: preparar e carregar os dados no DW e/ou DM para serem apresentados.

Objetivos do ETL

Extrair, limpar, padronizar e carregar os dados no *Data Warehouse*, ou seja, deixar os dados disponíveis para consulta.

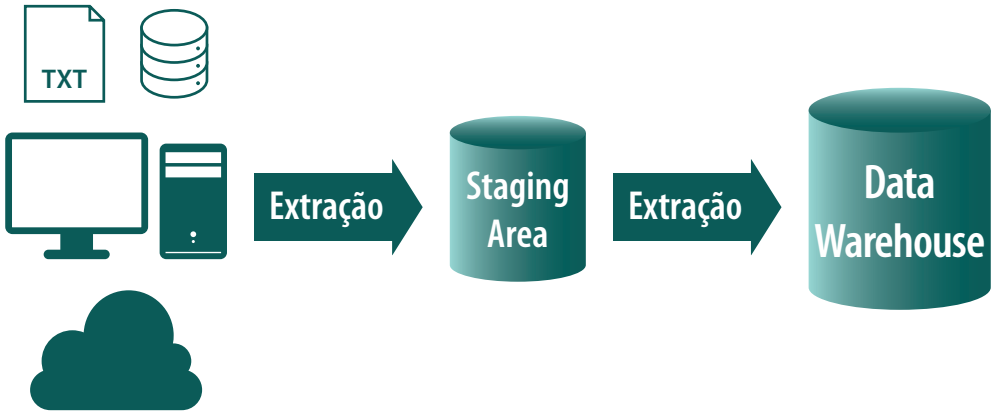


Figura 2

Os projetos de *Data Warehouse* consolidam dados de diferentes fontes. A maioria dessas fontes tendem a ser bancos de dados relacionais ou outros tipos de arquivos, mas podem existir outros tipos de fontes também. Um sistema ETL precisa ser capaz de se comunicar com bases de dados e ler diversos formatos de arquivos utilizados por toda a organização.

Requisitos para o ETL

Antes de iniciar um Projeto de ETL é necessário que os seguintes itens estejam bem alinhados:

- Requisitos de negócio: ter bem claro e documentado quais são os requisitos de negócio;
- Viabilidade dos Dados: realizar uma análise de viabilidade dos dados;
- Latência dos Dados: definir o tempo máximo permitido para disponibilização dos dados através do sistema de BI.
- Políticas de Compliance e Segurança: Definir quais são as políticas de *compliance* e segurança adotadas.

Importância do ETL

O processo de ETL, por exemplo, é essencial para a criação das estruturas de Dimensões e Fatos no ambiente do DW. É ele que faz a "ponte" de ligação entre o operacional e o DW. Deve-se escolher bem as ferramentas que darão suporte ao processo, pois são essenciais para a correta execução das atividades do ETL.

O ETL é fundamental para qualquer iniciativa de DW, porém deve ser planejado com cuidado para não comprometer os sistemas transacionais (OLTP) das empresas. Um bom ETL deve ter escalabilidade e ser manutenível.

Além disso, deve-se analisar a janela de operação do ETL. Não é em qualquer momento que ele poderá ser executado. Do mesmo modo, é necessário analisar a periodicidade de execução, como também definir qual será o alcance de dados que o ETL irá abranger.

Esses detalhes são críticos para o sucesso do processo.

O ETL une e possibilita a condução dos dados ao DW. O processo deve ser bem planejado para evitar transtornos futuros e até mesmo para que não ocasione, em casos extremos, a interrupção dos sistemas operacionais da empresa. Dessa forma, o DW terá informações tratadas, com qualidade e grande valor para apoiar as decisões organizacionais.

Principais Componentes do ETL

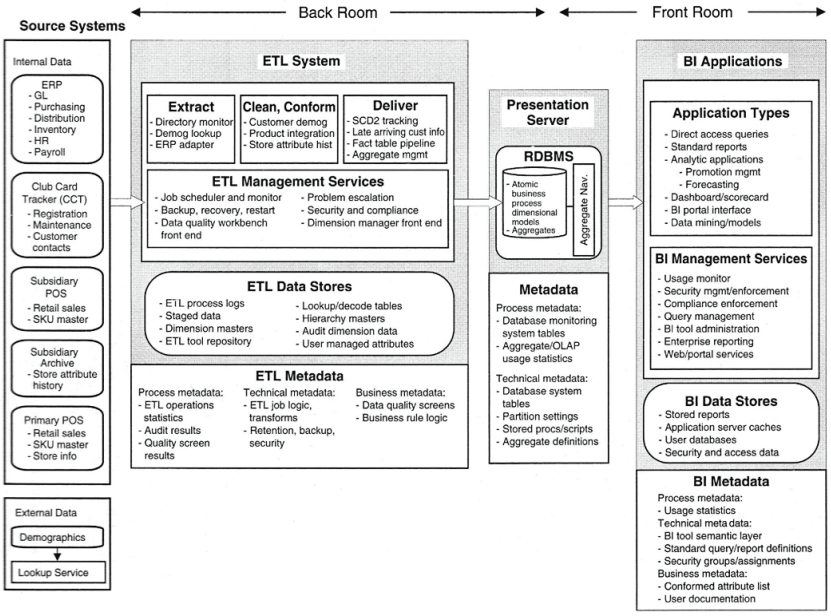


Figura 3

Nesta imagem é possível visualizar um exemplo de modelo de Arquitetura de uma solução de BI.

- **Extração:** É a coleta de dados dos sistemas de origem (também chamados *Data Sources* ou sistemas operacionais), extraindo-os e transferindo-os para o ambiente de DW, onde o sistema de ETL pode operar independente dos sistemas operacionais (ambiente OLTP).

A etapa de extração pode ser entendida como a fase em que os dados são extraídos dos OLTPs e conduzidos para a staging area (área de transição ou área temporária), onde são convertidos para um único formato. A conversão se faz necessária devido a heterogeneidade existente nas informações oriundas desses sistemas, sendo essencial a conformação prévia para o tratamento adequado.

Para realizar a extração dos dados, deve-se fazer a definição das fontes de dados e fazer a extração deles. As origens deles podem ser várias e também em diferentes formatos, onde pode-se encontrar desde os sistemas transacionais das empresas até planilhas, *flat files* (arquivos textos), dados do *Mainframe*, dados das redes sociais, etc.

- **Transformação:** É nesta etapa que se realizam os devidos ajustes, podendo assim melhorar a qualidade dos dados e consolidar dados de duas ou mais fontes. O estágio de transformação aplica uma série de regras ou funções aos dados extraídos

para ajustar os dados a serem carregados. Algumas fontes de dados necessitarão de pouca manipulação de dados. Em outros casos, podem ser necessários trabalhar algumas transformações, como por exemplo, junção de dados provenientes de diversas fontes, seleção de apenas determinadas colunas e tradução de valores codificados (se o sistema de origem armazena 1 para sexo masculino e 2 para feminino, mas o *Data Warehouse* armazena M para masculino e F para feminino, por exemplo).

Outro exemplo da necessidade de transformação dos dados, é muito comum, na obtenção dos dados que, no mais das vezes, são antigos e desconhecidos, encontrarmos muito 'lixo' e inconsistências. Por exemplo: quando um vendedor de linhas telefônicas for executar uma venda, ou inscrição, ele está preocupado em vender e não na qualidade dos dados que está inserindo na base, então, se por acaso o cliente não tiver o número do CPF, ele cadastra um número qualquer, desde que o sistema aceite, um dos mais utilizados é o 999999999-99. Agora imagine um diretor de uma companhia telefônica consultar o seu DW para ver quais são os seus maiores clientes, e aparecer em primeiro lugar o cliente que tem o CPF 999999999-99, ou seja, um dado inconsistente. Por isso, nessa fase do DW, são corrigidos, padronizados e tratados os desvios e inconsistências, transformando os dados de acordo com as regras do negócio.

- **Carga dos dados:** Consiste em fisicamente estruturar e carregar os dados para dentro da camada de apresentação seguindo o modelo dimensional. Dependendo das necessidades da organização, este processo varia amplamente. Alguns *Data Warehouses* podem substituir as informações existentes semanalmente, com dados cumulativos e atualizados, ao passo que outro DW (ou até mesmo outras partes do mesmo DW) podem adicionar dados a cada hora. A latência e o alcance de reposição ou acréscimo constituem opções de projetos estratégicos que dependem do tempo disponível e das necessidades de negócios. A etapa de carga ocorre em sequência com a de transformação. Assim que são efetuados os tratamentos necessários nos dados, a carga no DW é iniciada. Essa fase se resume a persistência dos dados na base consolidada.

A parte de **Gerenciamento** é composta por serviços para auxiliar no gerenciamento do *Data Warehouse*, tarefas específicas para gerenciamento de jobs, planos de *backup*, verificação de itens de segurança e compliance(regras e políticas).

Orientações para Leitura Obrigatória

Chuck Ballard, Daniel M. Farrell, Amit Gupta, Carlos Mazuela, Stanislav Vohnik; Dimensional Modeling: In a Business Intelligence Environment; An IBM Redbooks publication;2012

Chapter 1. Introduction

Chapter 2. Business Intelligence: The destination

Nesta publicação IBM *Redbooks*, descreve-se as técnicas de modelagem de dados dimensionais, especificamente focadas em *business intelligence* e *data warehousing*. É para ajudar o leitor a entender como projetar, manter e usar um modelo dimensional para *data warehousing* que pode fornecer acesso e desempenho de dados necessários para a inteligência de negócios.

A inteligência de negócios é composta por uma infra-estrutura de *data warehousing* e um ambiente de consulta, análise e relatórios. Aqui concentra-se na infraestrutura de *data warehousing*. Mas apenas um elemento específico disso, o modelo de dados - que é considerado o bloco básico de construção do *data warehouse*. Ou, mais precisamente, o tema da modelagem de dados e seu impacto nas aplicações comerciais e empresariais. O objetivo não é fornecer um tratado sobre técnicas de modelagem dimensional, mas focar em um nível mais prático.Existe conteúdo técnico para projetar e manter esse ambiente, mas também conteúdo comercial.

Por exemplo, são usados estudos de caso para demonstrar como a modelagem dimensional pode afetar os requisitos de *business intelligence* para suas iniciativas de negócios. Além disso, é fornecida uma discussão detalhada sobre os aspectos da consulta de BI e modelagem de dados. Por exemplo, é demonstrada a otimização de consulta e como se pode determinar o desempenho do modelo de dados antes da implementação.

POLI, Gabriel Antônio; BARROS, Guilherme Candiani. *Business intelligence* aplicado a um *data warehouse*. Franca, 2010. 65 p. Graduação - CIÊNCIA DA COMPUTAÇÃO.

A procura por uma melhora contínua nos negócios faz com que empresas invistam em soluções a fim de obterem informações sobre suas necessidades e capacidades operacionais. O uso de um banco de dados aliado a um *Data Warehouse* auxilia na tomada de decisões, possibilitando o crescimento significativo das empresas. Este trabalho foi elaborado com o intuito de demonstrar a viabilidade de um *Data Warehouse* de um banco de dados, associado à tecnologia OLAP (*Online Analytical Processing*) e integrado por meio da ferramenta *Microsoft Analisys Services*®. Deste modo torna-se possível gerar consultas em um período de tempo curto e hábil, de forma que o usuário final consiga visualizar as informações através da ferramenta *Microsoft Office Excel*®, oferecendo assim um suporte nas estratégias e tomadas de decisões.

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Sites

***Extract, Transformation and Load* (ETL) - Ferramentas BI**

https://goo.gl/expp58

O que é ETL?

https://goo.gl/7eXkil

Livros

Aspectos do ambiente gerencial e seus impactos no uso dos sistemas de inteligência competitiva para processos decisórios

JAMIL, George Leal. **Aspectos do ambiente gerencial e seus impactos no uso dos sistemas de inteligência competitiva para processos decisórios.** Perspectivas em Ciência da Informação .Belo Horizonte , v. 6, n. 2, p. 261-274, jul./dez. 2001

A essencia do business intelligence

SERRA, Laercio. **A essencia do business intelligence**. Sao Paulo: Berkeley, 2002. 288 p.

Bi: business intelligence: modelagem '&' tecnologia

BARBIERI, Carlos. **Bi: business intelligence:** modelagem '&' tecnologia. Rio de Janeiro Axcel books do Brasil 2001 424

Decisão nas organizações: introdução aos problemas de decisão encontrados nas organizações e nos sistemas de apoio à decisão

SHIMIZU, Tamio. **Decisão nas organizações:** introdução aos problemas de decisão encontrados nas organizações e nos sistemas de apoio à decisão. São Paulo: Atlas, 2001. 317 p. ISBN 8522427496.

Armazenamento e Gerenciamento de Informações

EMC; **Armazenamento e Gerenciamento de Informações**; Ed. EMC2

Arquitetura da Informação

CAMARGO, Liriane Soares de Araújo; VIDOTTI, Silvana Aparecida Borsetti Gregorio; Arquitetura da Informação; Ed. LTC

Administração de Sistemas de Informação

O´BRIEN, James A.; MARAKAS,George M.; Administração de Sistemas de Informação; Ed. Mc Graw Hill

Referências

BARBIERI, Carlos. **Bi: business intelligence:** modelagem '&' tecnologia. Rio de Janeiro Axcel books do Brasil 2001 424

ELIAS,Diego; **Entendendo o processo de ETL**; https://corporate.canaltech.com.br/noticia/business-intelligence/entendendo-o-processo-de-etl-22850/;2015

RIBEIRO, Viviane; **O que é ETL?**; https://vivianeribeiro1.wordpress.com/2011/06/28/o-que-e-etl-2/; 2011

ROSINI, Alessandro Marco; PALMISANO, Angelo. **Administração de sistemas de informação e a gestão do conhecimento.** São Paulo: Thomson, 2003. xiii, 219 p. ISBN 8522103127.

TURBAN, Efraim. **Business intelligence:** um enfoque gerencial para a inteligencia do negócio. Porto Alegre: Bookman, 2009. 256 p.

Cruzeiro do Sul Virtual
Educação a Distância

www.cruzeirodosulvirtual.com.br
Campus Liberdade
Rua Galvão Bueno, 868
CEP 01506-000
São Paulo - SP - Brasil
Tel: (55 11) 3385-3000



Cruzeiro do Sul
Educacional