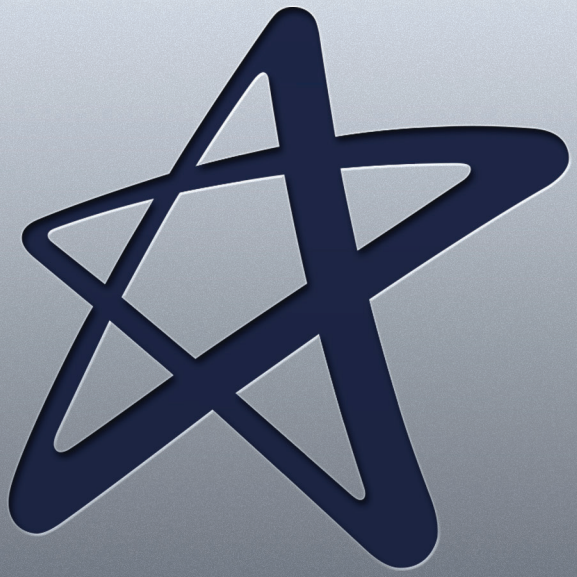
Pós-Graduação

Processos ETL



Cruzeiro do Sul Virtual
Educação a Distância

Implementação do ETL

Responsável pelo Conteúdo:
Profa. Ms. Lúcia Contente Mós

Revisão Textual:
Prof. Esp. Claudio Pereira do Nascimento

Unidade

Implementação do ETL

Nesta unidade, trabalharemos os seguintes tópicos:

- Introdução ao Tema
- Orientações para Leitura Obrigatória
- Material Complementar



Fonte: iStock/Getty Images

Objetivos

- Conhecer com detalhes as tarefas para o levantamento de dados específicos para etapa de extração;
- Conhecer, identificar e desenvolver a Bus Matrix;
- Identificação dos Processos, das Dimensões e das Relações;
- Conhecer todos os passos do plano para implementação do ETL;
- Definição, importância e geração da surrogate key;
- Definição, vantagens e desvantagens de ferramentas para implementação do ETL;
- Conhecer os principais fornecedores de ferramentas ETL;
- Definição, vantagens e desvantagens de implementação do ETL com programação manual.

Normalmente, com a correria do dia a dia, não nos organizamos e deixamos para o último momento o acesso ao estudo, o que implicará o não aprofundamento no material trabalhado ou, ainda, a perda dos prazos para o lançamento das atividades solicitadas.

Assim, organize seus estudos de maneira que entrem na sua rotina. Por exemplo, você poderá escolher um dia ao longo da semana ou um determinado horário todos ou alguns dias e determinar como o seu "momento do estudo".

No material de cada Unidade, há videoaulas e leituras indicadas, assim como sugestões de materiais complementares, elementos didáticos que ampliarão sua interpretação e auxiliarão o pleno entendimento dos temas abordados.

Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois estes ajudarão a verificar o quanto você absorveu do conteúdo, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e aprendizagem.

Introdução ao Tema

O Data Warehouse dificilmente existirá sem um processo de ETL (por mais simples que seja), mas processos de ETL existem para atender a muitas necessidades (não somente para abastecer um Data Warehouse).

Há milhares de ferramentas de ETL disponíveis no mercado como o **Oracle Warehouse Builder (OWB)**, **IBM Information Server (Data Stage)**, o **Integration Services (SSIS)**, o **Power Center (antigo Power Mart)**, etc, para citar algumas. Normalmente ferramentas de ETL custam caro e não raras às vezes as pessoas se perguntam se é mesmo necessário adquirir uma ferramenta de ETL

Algumas vantagens do uso de processo "Hard Code" – Programação Manual

- **Controle:** Se você desenvolve tudo do zero, tem controle completo sobre o processo. Esse controle evita qualquer tipo de "caixa preta" ou desconhecimento de como uma determinada parte da carga funciona. Todo o processo é conhecido e controlado de ponta a ponta e pode ser modificado da forma desejada quando necessário.
- **Customização:** As possibilidades de customização são infinitas, pois, todo o código do processo de carga estará disponível para eventuais mudanças. Isso inclui novas funcionalidades na carga, adaptabilidade em relação a algum framework interno da empresa, etc.
- **Convergência com a plataforma tecnológica:** Não será necessário adquirir hardware, software ou um sistema operacional a parte para adaptar a ferramenta de ETL ao direcionamento tecnológico da organização. A criação de um processo de ETL "hard code" permite a escolha da linguagem de programação que a organização jugar mais adequado.
- **Convivência com o legado:** O desenvolvimento interno sempre se adaptará aos sistemas legados e nunca será impositiva a mudança do legado para adaptar-se às cargas e (ou) construção de pequenos módulos para realizar essa integração.
- **Suporte:** A construção própria dispensa contratos de suporte e manutenção com o fabricante. Você também não será surpreendido pelo fato de um fabricante simplesmente descontinuar o produto e não comercializar mais suporte.
- **Descoberta de erros no código:** As atividades de DEBUG não vão se deparar com uma parte não "debugável" do código, pois, não haverá no processo partes cujo código fonte não esteja disponível

Algumas vantagens do uso de ferramentas de ETL

- **Desenvolvimento das cargas:** Desenvolver uma rotina de carga em uma ferramenta de ETL é muito mais fácil e rápido que codificá-la. Dependendo da facilidade da ferramenta é possível inclusive que usuários não técnicos a utilizem para cargas mais simples.

- **Manutenção das cargas:** As tarefas de manutenção de uma rotina de carga são mais fáceis de realizar em relação à manutenção de código.
- **Desempenho:** As ferramentas de ETL utilizam métodos mais performáticos para trabalhar com grandes volumes e normalmente conseguem extrair, transformar e carregar dados com mais velocidade e menos utilização de recursos. Isso inclui operações não auditadas, gravações em bloco, etc.
- **Execução em paralelo:** Ferramentas de ETL possuem recursos de paralelização nativos e facilmente implementáveis.
- **Escalabilidade:** Ferramentas de ETL podem ser transferidas de servidor mais facilmente e até eventualmente distribuir sua carga entre vários servidores.
- **Diversidade de conectores:** A conexão de uma ferramenta de ETL com múltiplas fontes de dados é transparente. Caso apareça alguma fonte não trivial como o SAP, Mainframe, VSAM, etc, é possível adquirir o conector sem a necessidade de codificar um.
- **Separação entre funcionalidade e manipulação de dados:** Uma ferramenta de ETL já possui suas funcionalidades disponíveis (Lookup, Merge, Split, Expressões calculadas, etc). Só é necessário concentrar-se em como fluir os dados dentro da carga e não codificar cada tarefa da carga.
- **Reusabilidade:** Uma carga normalmente pode ser reaproveitada dentro de outras cargas ou sobre a forma de um template.
- **Reinicialização:** Ferramentas de ETL possuem a capacidade de reiniciar a carga de onde pararam sem a necessidade de codificar essa inteligência
- **Manutenção de Metadados:** Os metadados são gerados e mantidos automaticamente com a ferramenta evitando que problemas de conversão gerem dados não íntegros ao final do processo. A manutenção de metadados também evita ou alerta para alterações de esquema que invalidem a carga.
- **Documentação:** As ferramentas de ETL possuem mecanismos de documentação (quando não são autoexplicativas). Isso pode ser um diferencial significativo principalmente para equipes de alta rotatividade.
- **Maior garantia da qualidade dos dados:** Ferramentas de ETL podem disponibilizar meios para trabalhar a qualidade dos dados através de algoritmos complexos (lógica fuzzy, IA, etc).
- **Auditoria e Rastreamento:** É possível implementar recursos de auditoria e tracking para conhecer de onde veio o registro, que transformações sofreu e como foi carregado.
- **Segurança:** É possível tornar a segurança mais modular dividindo-se os papéis (criação de cargas, execução de cargas, agendamento, etc)

Como é possível observar há vantagens e desvantagens associadas entre utilizar ou não uma ferramenta de ETL e muitos fatores podem influenciar nessa escolha (custo, tamanho do projeto, complexidade das cargas, etc). Com o declínio dos custos das ferramentas ETL e aumento constante de uso de ETL (principalmente para atender às crescentes demandas de BI), creio que optar por desenvolver todo o processo de ETL de forma "hard code" será algo cada vez mais sem sentido. Mesmo uma tarefa simples como retirar dados do SQL Server e colocar no Excel envolve um certo trabalho se for completamente codificada.

Um cenário comum bem relacionado a essa avaliação é a utilização de stored procedures para carregar dados. Já vi diversas implementações que utilizam stored procedures para carregar dados. Em minha opinião, utilizar stored procedures para carregar dados é algo que funciona bem para pequenos projetos e iniciativas, mas é algo inadequado para processos de cargas complexas e (ou) grandes volumes. Apresento abaixo algumas razões pela qual stored procedures não devem ser utilizadas em atividades de carga. Foque mais no SQL Server, mas provavelmente boa parte das razões (senão todas) são válidas para outros SGBDs.

- **Incapacidade de rodar em paralelo:** Por melhor codificada que uma stored procedure possa ser ela não é capaz de paralelizar comandos, ou seja, não há como uma stored procedure rodar duas instruções de INSERT em paralelo. Será necessário finalizar a primeira instrução para prosseguir para a segunda. Com grandes cargas e muitas bases, tal abordagem pode simplesmente ser proibitiva em virtude da janela de tempo
- **Incapacidade de se recuperar no caso de uma parada:** Se o processo que roda uma stored procedure for eliminado por qualquer razão (kill, deadlock victim, reinicialização do servidor, etc) não há como a carga se recuperar do ponto em que parou. É possível codificar essa inteligência na stored procedure, mas reinicializar a partir de uma parada não é uma característica nata.
- **Contexto transacional:** Stored Procedures rodam sobre um contexto transacional e vão impor bloqueios até que finalizem sua execução. Se uma stored procedure demorar para executar é possível que boa parte dos seus recursos sofra contenção até que ela finalize provocando bloqueios e lentidão para os outros processos. Se ela for eliminada, o custo de ROLLBACK pode ser considerável, gerando mais indisponibilidade no acesso a dados além de aumentar o log de transações. Tais características podem ser descartadas em um processo de ETL, retirando seu contexto transacional bem como implementar cargas não logadas.
- **Não isolamento:** Stored Procedures não podem ser isoladas do resto das atividades do SGBD. Elas sempre irão rodar no mesmo lugar que o SQL Server, impossibilitando movê-las para outro servidor para aliviar a carga das demais tarefas do SQL Server. Embora o Resource Governor possa ajudar com essa limitação, não haverá como retirar as stored procedures do servidor onde o SQL Server está.

- **Dificuldades para escalar:** Se as stored procedures estão provocando lentidão em um servidor SQL Server não há muita escolha senão aumentar as capacidades do servidor de banco de dados. Se uma ferramenta de ETL fosse utilizada, outros mecanismos de escalabilidade podem estar disponíveis como o balanceamento de carga por exemplo.
- **Manutenção e Complexidade:** Cargas complexas podem significar stored procedures bem longas com milhares de linhas (já vi SP com 20.000 linhas). Dar manutenção em um código desses é algo bem complicado já que não há nenhuma iteração visual. As atividades de testes e análise de impactos também são muito mais complicadas.

Nas palavras de Ralph Kimball no clássico "Data Warehouse ETL Toolkit", ele é enfático quando diz: "Um sistema de ETL pode fazer ou inviabilizar o Data Warehouse". Embora o processo de ETL seja uma atividade em background que o usuário não visualize, ele certamente consome a maior quantidade de tempo de um projeto de Data Warehouse e Business Intelligence (há percentuais variando de 70% a 90%). A escolha em optar ou não para uma ferramenta de ETL juntamente com a complexidade do projeto é crucial na determinação desse percentual.

Orientações para Leitura Obrigatória



Integration Services 2012: Implementando soluções de ETL - Parte 1

Renato Jose.

https://goo.gl/zA1eGh

Este artigo tem por finalidade apresentar o SQL Server Integration Services 2012 e de que maneira este serviço (que é parte integrante do SQL Server) pode ser útil na integração entre diferentes aplicações. Combinando recursos do .NET Framework a funcionalidades para a manipulação de bases relacionais, XML e outros formatos para a representação de informações, esta ferramenta permite a implementação dos mais variados tipos de soluções voltadas ao gerenciamento de dados. A implementação de projetos baseados no Integration Services acontece através do Visual Studio, sendo que demonstraremos isto através de dois exemplos (o primeiro envolvendo a exportação de informações, ao passo que um segundo exemplo descreve de que maneira as informações podem ser carregadas em uma base de dados).



Integration Services 2012: Implementando soluções de ETL – Parte 2

Renato Jose.

https://goo.gl/nhaPfF

O Integration Services é uma plataforma da Microsoft que possibilita a construção de soluções para a integração entre diferentes sistemas. Embora corresponda a mais um dos serviços que compõem o SQL Server, repositórios de dados dos mais variados tipos podem ser manipulados através de aplicações baseadas nesta tecnologia. Na edição anterior apresentamos as principais características desta ferramenta (enfatizando a versão 2012), alguns dos seus possíveis cenários de utilização, concluindo com a implementação de um projeto para a exportação de dados no formato .csv. Neste artigo encerraremos a série sobre o Integration Services com um novo exemplo, demonstrando a importação de informações de arquivos em diversos formatos (texto, CSV, planilhas do Excel) para uma base do SQL Server.



IBM InfoSphere DataStage Data Flow and Job Design

Nagraj Alur, Celso Takahashi, Sachiko Toratani, Denis Vasconcelos; **IBM InfoSphere DataStage Data Flow and Job Design**; An IBM Redbooks publication; 2008

Chapter 1. IBM InfoSphere DataStage overview; Chapter 2. IBM InfoSphere DataStage stages

O IBM Information Server é uma revolucionária plataforma de software que ajuda as organizações a obter mais valor a partir das informações heterogêneas complexas espalhadas por seus sistemas. Permite que as organizações integrem dados diferentes e forneçam informações confiáveis sempre que necessário, na linha e no contexto, para pessoas específicas, aplicativos e processos.

Aqui encontra-se a base para os componentes IBM InfoSphere QualityStage e IBM InfoSphere Information Analyzer. Esta publicação desenvolve cenários de uso que descrevem a implementação do fluxo de DataStage e design de trabalho, como o estágio de transação distribuída (DTS), estágio de dimensões que mudam lentamente.

Dimensional Modeling: In a Business Intelligence Environment

Chuck Ballard, Daniel M. Farrell, Amit Gupta, Carlos Mazuela, Stanislav Vohnik; **Dimensional Modeling:** In a Business Intelligence Environment; An IBM Redbooks publication; 2012

Chapter 1. Introduction; Chapter 2. Business Intelligence: The destination.

Nesta publicação IBM Redbooks descreve as técnicas de modelagem de dados dimensionais, especificamente focadas em business intelligence e data warehousing. É para ajudar o leitor a entender como projetar, manter e usar um modelo dimensional para data warehousing que pode fornecer acesso e desempenho de dados necessários para a inteligência de negócios.

A inteligência de negócios é composta por uma infraestrutura de data warehousing e um ambiente de consulta, análise e relatórios. Aqui concentra-se na infraestrutura de data warehousing. Mas apenas um elemento específico disso, o modelo de dados - que é considerado o bloco básico de construção do data warehouse, mais precisamente, o tema da modelagem de dados e seu impacto nas aplicações comerciais e empresariais. O objetivo não é fornecer um tratado sobre técnicas de modelagem dimensional, mas focar em um nível mais prático. Existe conteúdo técnico para projetar e manter esse ambiente, mas também conteúdo comercial.

Por exemplo, são usados estudos de caso para demonstrar como a modelagem dimensional pode afetar os requisitos de business intelligence para suas iniciativas de negócios. Além disso, é fornecida uma discussão detalhada sobre os aspectos da consulta de BI e modelagem de dados. Por exemplo, é demonstrada a otimização de consulta e como se pode determinar o desempenho do modelo de dados antes da implementação.

Business Intelligence Aplicado a um Data Warehouse

POLI, Gabriel Antônio; BARROS, Guilherme Candiani. **Business intelligence aplicado a um data warehouse**. Franca, 2010. 65 p. Graduação - CIÊNCIA DA COMPUTAÇÃO.

A procura por uma melhora contínua nos negócios faz com que empresas invistam em soluções a fim de obterem informações sobre suas necessidades e capacidades operacionais. O uso de um banco de dados aliado a um Data Warehouse auxilia na tomada de decisões, possibilitando o crescimento significativo das empresas. Este trabalho foi elaborado com o intuito de demonstrar a viabilidade de um Data Warehouse de um banco de dados, associado à tecnologia OLAP (Online Analytical Processing) e integrado por meio da ferramenta Microsoft Analisys Services®. Deste modo torna-se possível gerar consultas em um período de tempo curto e hábil, de forma que o usuário final consiga visualizar as informações através da ferramenta Microsoft Office Excel®, oferecendo assim um suporte nas estratégias e tomadas de decisões.

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Sites

O que é ETL?

RIBEIRO, Viviane; O que é ETL?

https://goo.gl/7eXkil

Extrair, Transformar e Carregar

CELESTINO, André L,; ETL – Extrair, Transformar e Carregar.

https://goo.gl/g8QmnG

Livros

Perspectivas em Ciência da Informação

JAMIL, George Leal. Aspectos do ambiente gerencial e seus impactos no uso dos sistemas de inteligência competitiva para processos decisórios. **Perspectivas em Ciência da Informação**. Belo Horizonte , v. 6, n. 2, p. 261-274, jul./dez. 2001.

A Essência do Business Intelligence

SERRA, Laercio. **A essência do business intelligence**. São Paulo: Berkeley, 2002. 288 p.

Bi – Business Intelligence: Modelagem '&' Tecnologia

BARBIERI, Carlos. **Bi: business intelligence:** modelagem '&' tecnologia. Rio de Janeiro: Axcel books do Brasil 2001 424.

Decisão nas Organizações: Introdução aos Problemas de Decisão encontrados nas Organizações e nos Sistemas de Apoio à Decisão

SHIMIZU, Tamio. **Decisão nas organizações:** introdução aos problemas de decisão encontrados nas organizações e nos sistemas de apoio à decisão. São Paulo: Atlas, 2001. 317 p. ISBN 8522427496.

Referências

ELIAS,Diego; **Entendendo o processo de ETL**; <https://corporate.canaltech.com.br/noticia/business-intelligence/entendendo-o-processo-de-etl-22850/>; 2015

PRIMAK , Fábio Vinicius ; **Extract, Transformation and Load (ETL) - Ferramentas BI**; <http://www.devmedia.com.br/extract-transformation-and-load-etl-ferramentas-bi/24408>; 2015

Cruzeiro do Sul Virtual
Educação a Distância

www.cruzeirodosulvirtual.com.br
Campus Liberdade
Rua Galvão Bueno, 868
CEP 01506-000
São Paulo - SP - Brasil
Tel: (55 11) 3385-3000



Cruzeiro do Sul
Educacional