# Almacenamiento y Recuperación de la Información

## Técnicas de Indexación

2do Semestre 2005

Wenceslao Palma M. <wpalma@inf.utfsm.cl>
www.inf.utfsm.cl/~wpalma/ari

Un índice es un archivo usado para agilizar la recuperación de los registros.

Es redundante puesto que la información que almacena se encuentra en el archivo al cual indexa.

La ventaja, sin duda, viene por la vía de recuperar los registros de manera más rápida.

## Tipos de índices

Existen diversos criterios para identificar los distintos tipos de índices, algunos de éstos son:

Campo de indexación: según el campo usado para construir el índice, éste se llamará primario, de grupos o secundario.

a) índice primario (principal) : se construye sobre el campo clave de ordenamiento de un archivo ordenado de registros.

b) índice agrupado (clusterizado): se construye sobre un campo de ordenamiento que abarca varios registros con el mismo valor, dentro de un archivo ordenado de registros.

c) índice secundario: se construye sobre un campo que no se utiliza para ordenar el archivo.

Número de referencias: si el índice tiene una entrada por cada registro del archivo se denomina denso, en caso contrario, dicho índice se llama no denso o disperso.

Tipo de referencias: si la entrada en el índice contiene un puntero físico al área de datos, es decir, un puntero que indica la dirección física de un registro en el disco, el índice se llama físico.

Estructura de las referencias: las referencias al área de datos se pueden estructurar como;

a) entrada de largo fijo, con un puntero al área de datos (bloque o registro).

b) registros de largo variable en el índice, con un campo repetitivo que permita almacenar un puntero a cada bloque de disco que contiene un registro. Este esquema se llama archivo o **lista invertida.**

c) mantener entradas en el índice de largo fijo y tener una única entrada por cada valor del campo de indexación, pero creando un nivel extra de indirección para manipular los múltiples punteros.

d) entradas en el índice de largo fijo y tener un bitmap asociado a cada una de ellas, el cual tenga un bit por cada bloque del archivo de datos; el bitmap guarda un valor 1 en los bits de los bloques que contiene un registro con el valor de la entrada, y un valor 0 en caso contrario.

## Indices ordenados

Indice primario: construido sobre un campo que a su vez se utiliza para ordenar el archivo de datos. Características:

- Archivo ordenado con registros de largo fijo.
- Cada entrada del índice tiene 2 campos:
  (1) Uno del mismo tipo del campo clave.
  (2) Un puntero a bloque de disco.
- El número de entradas en el índice es igual al número de bloques de disco.
- índice no denso.
- ocupa menos bloques que el área de datos, ya que por cada bloque de datos tiene sólo una entrada en el índice y además cada entrada es más pequeña que un registro.

Apellido
Rut
...
...
abarca
acuña
.....
adams
Bloque 1
abarca
amestica
wright
amestica
Bloque 2
.....
wright
Bloque n

## Operaciones

Búsqueda: binaria si se realiza sobre el campo de indexación. En otro caso, lineal.

Inserción: considera corrimientos en el archivo de datos y cambios en las entradas del índice.

Eliminación: marcas de borrado.

Suponer un disco con bloques físicos de 1KB y punteros a bloque de 6 bytes. Sobre aquél se desea almacenar un archivo de 80000 registros, cada uno de los cuales tiene un tamaño de 120 bytes.
Cuantos accesos a disco se necesitan para alcanzar un regsitro si se contruye un índice promario sobre la clave (9 bytes)de los registros.?

Solución:

archivo de datos

factor de bloqueo: 1024/120 = 8 [reg/bloque]

bloques en el archivo: 80000/8 = 10000 [bloques]

índice primario

entrada en el indice: 9+6 = 15 [bytes]

factor de bloqueo: 1024/15= 68 [entradas/bloque]

cantidad de bloques: 10000/68= 148 [bloques]

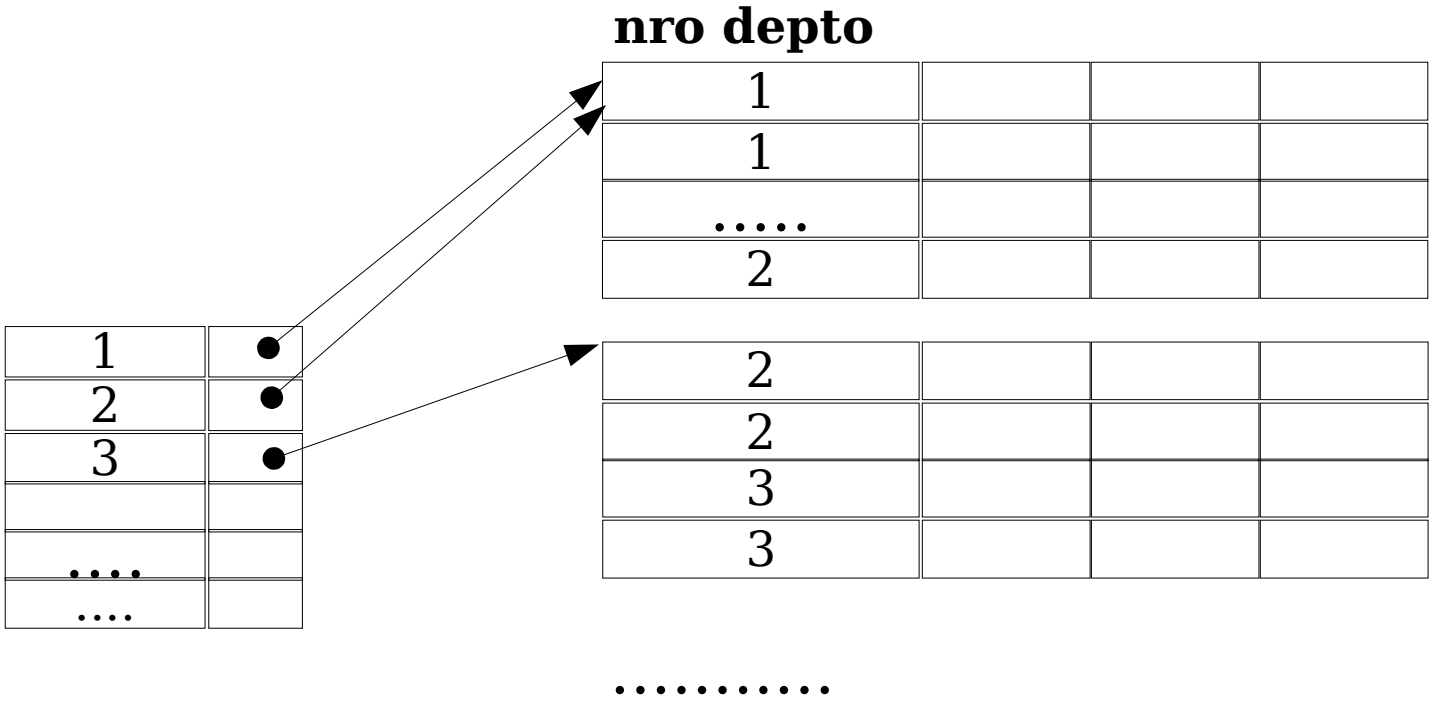
accesos

b. binaria en el índice + lineal en el bloque= $\log_2(148)+1=9$

Indice de grupos (clusterizado):

Características:

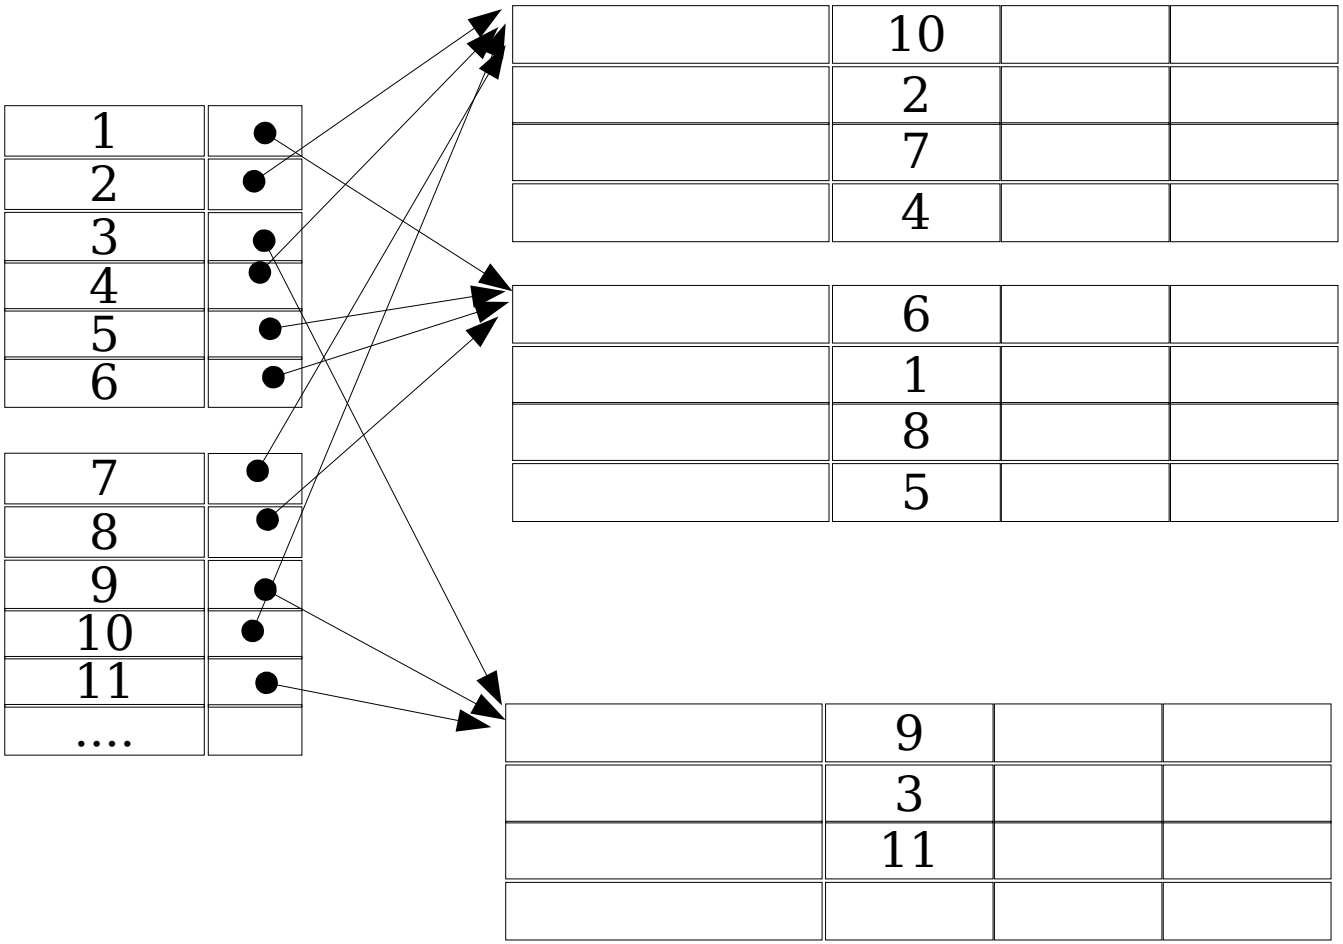
- archivo de datos ordenado, el campo de ordenamiento presenta repeticiones.
- cada entrada en el índice tiene dos campos:
  - un campo del mismo tipo del campo de ordenamiento.
  - puntero a bloque de disco.
- una entrada en el índice para cada valor distinto del campo de ordenamiento.



Indice Secundario:

Características:

- Cada entrada en el índice posee dos campos:
  - uno del mismo tipo de algún campo no ordenado del archivo de datos.
  - un puntero a bloque de disco.
- Si el campo de indexación es clave, entonces se dice que el índice es denso.



Se denomina archivo totalmente invertido a aquel que tiene un índice secundario sobre cada uno de sus campos. Debido a que todos los índices son secundario las inserciones se realizan al final ( el archivo es del tipo secuencial desordenado).

## Indices Multinivel

permiten reducir la parte del índice que se requiere acceder en un valor equivalente al factor de bloqueo del índice.
La principal desventaja es su naturaleza estática, es preferible usar un índice multinivel dinámico (árbol B/B+)

