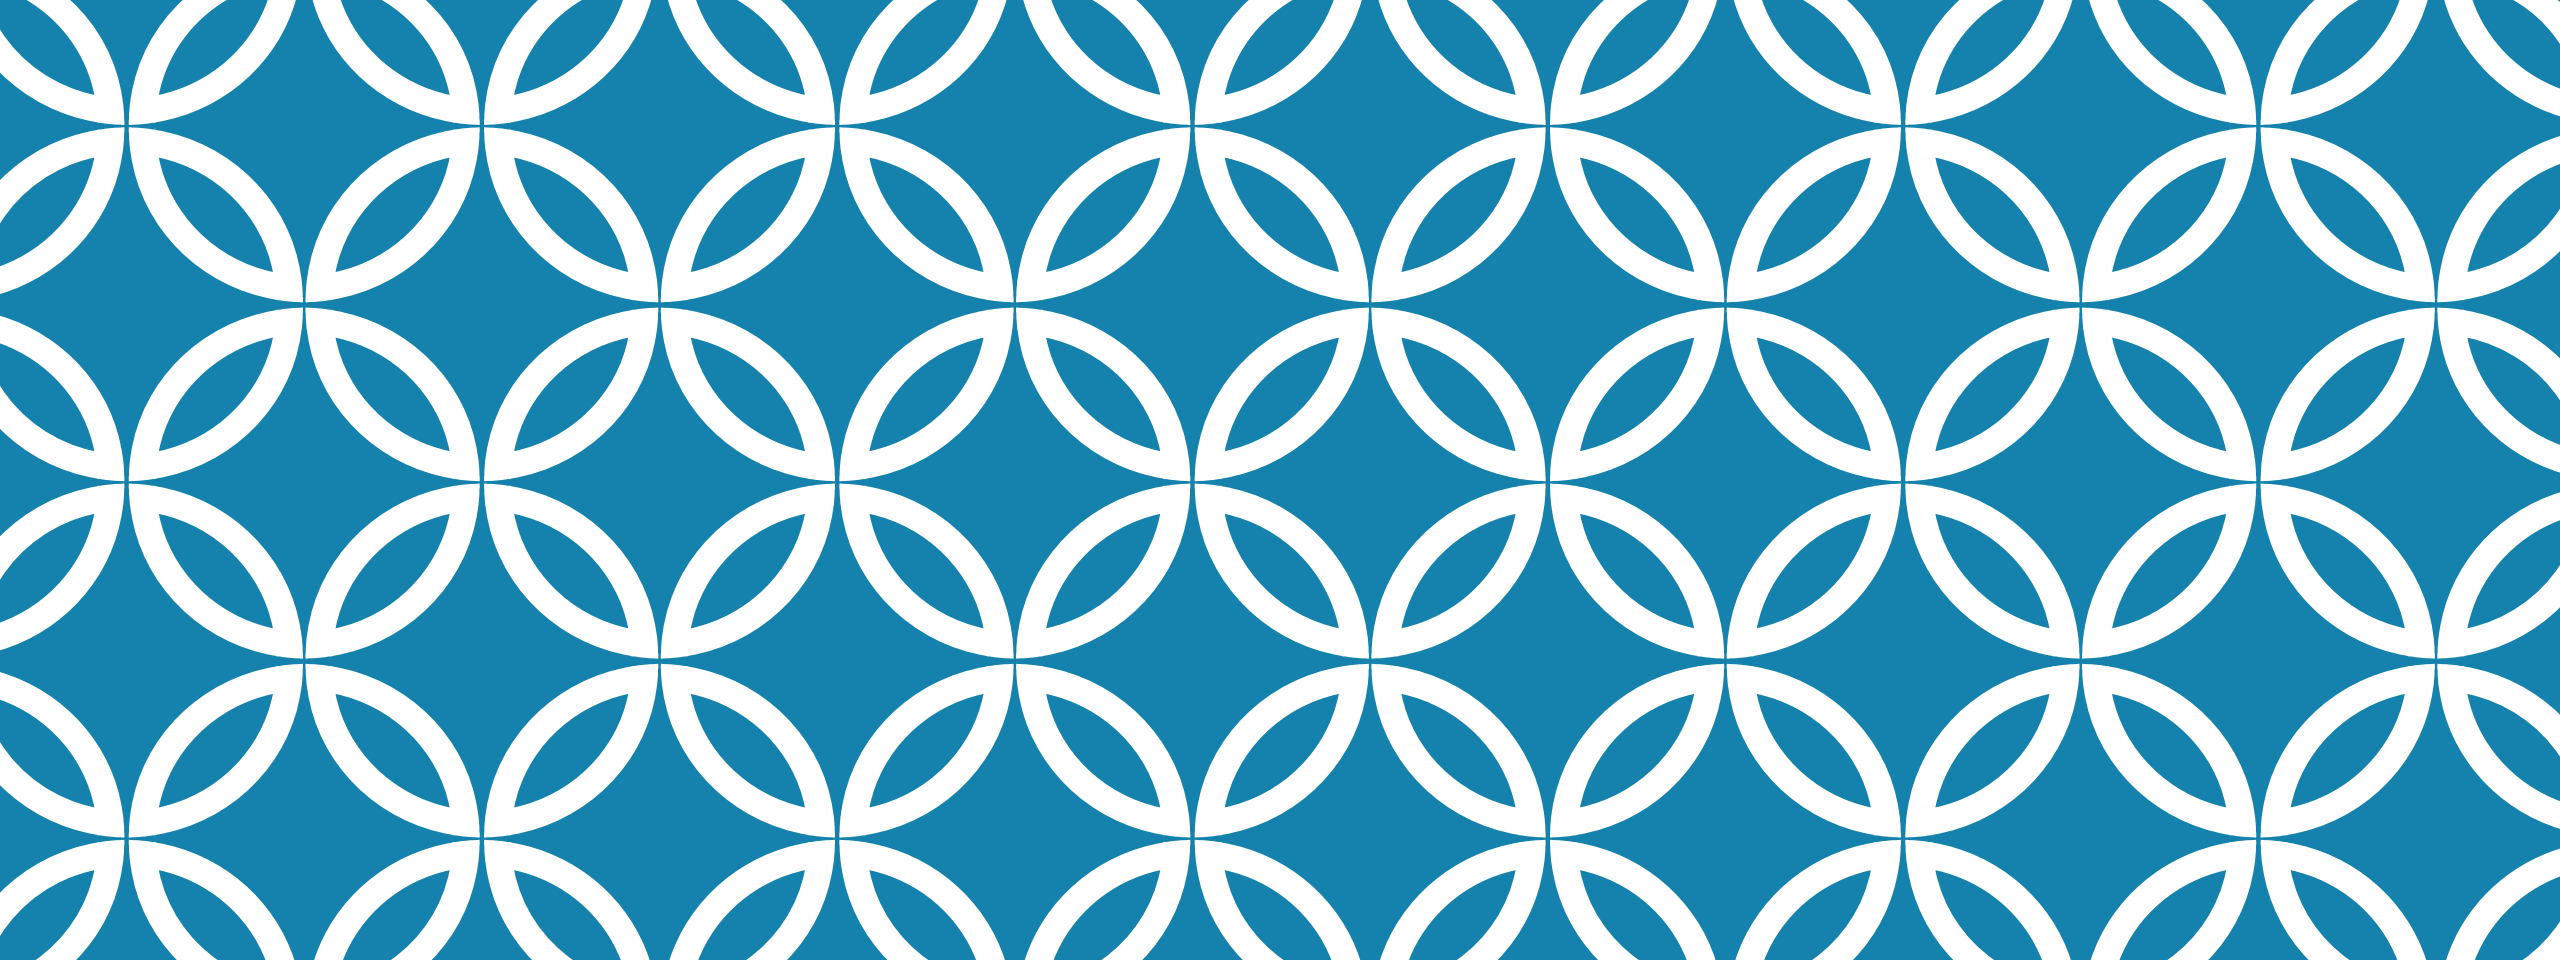


ANÁLISE EXPLORATÓRIA DOS DADOS

INTELIGÊNCIA COMPUTACIONAL 2019/1

JOHANNES VON LOCHTER
JOHANNES.LOCHTER@FACENS.BR

ANÁLISE EXPLORATÓRIA DOS DADOS

A análise exploratória dos dados permite utilizar algumas ferramentas estatísticas para visualizar informações descritivas do conjunto de dados. Normalmente são combinadas a ferramentas visuais, como gráficos, para facilitar o entendimento.

CONJUNTO DE DADOS

Retomando: os dados estão crescendo rapidamente e aprendizado de máquina tem sido empregado na automatização onde humanos seriam empregados para processar esse grande volume de informação.

CONJUNTO DE DADOS

Um exemplo de conjunto de dados.

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

CONJUNTO DE DADOS

Um exemplo de conjunto de dados.

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

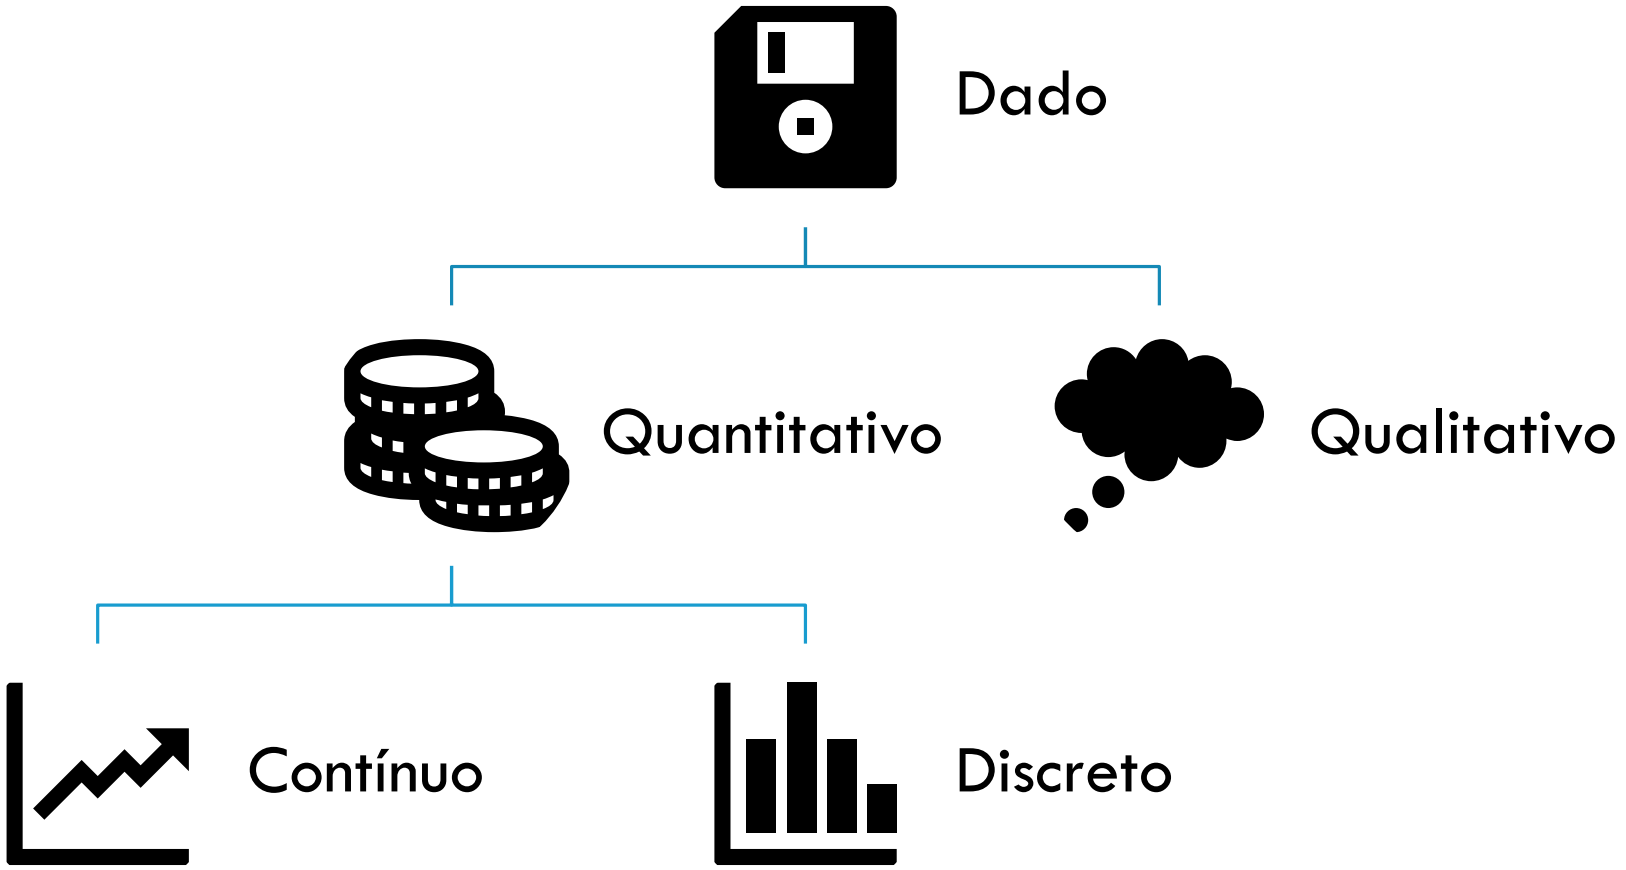
Atributos

Rótulo

TIPOS DE DADOS

Os valores que um atributo pode assumir são categorizados por dois aspectos: tipo e escala. O tipo diz respeito à quantização e a escala indica a significância relativa dos valores.

TIPOS DE DADOS

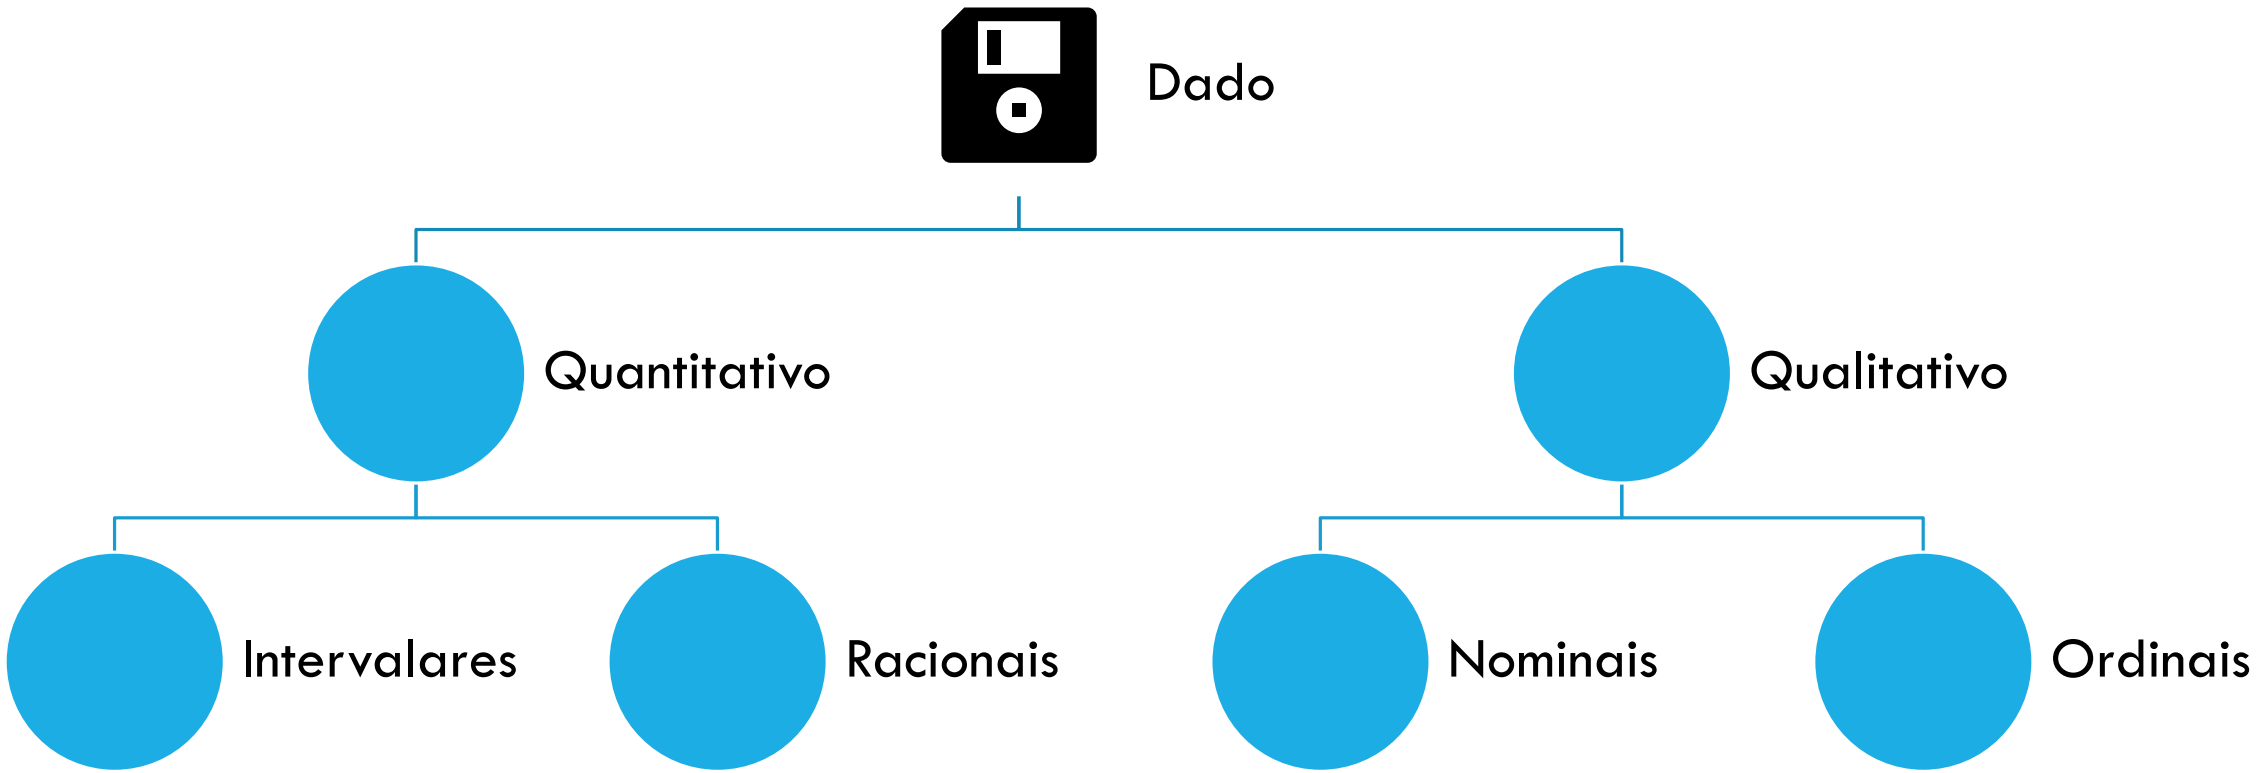


TIPOS DE DADOS

Qual a categorização dos tipos desse conjunto de dados médicos?

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

ESCALAS DE DADOS



ESCALA NOMINAL

Na escala nominal, os valores são apenas nomes diferentes, carregando pouca informação sem ordem entre seus valores. Operações: igualdade e desigualdade.

Exemplos: nome, RG, CPF.

ESCALA ORDINAL

Na escala ordinal, os valores refletem uma ordem e habilita, além dos operadores anteriores, os operadores de grandeza >, >=, < e <=.

Exemplos: hierarquia militar, avaliações qualitativas de temperatura, como quente, morno e frio.

ESCALA INTERVALAR

Na escala intervalar, os valores variam dentro de um intervalo, possibilitando definir tanto ordem quanto diferença de magnitude entre dois valores. A magnitude indica a distância que separa dois valores quaisquer do intervalo, mas não se pode usar razão e proporção, já que o zero nessa escala é definido de forma arbitrária.

Exemplo: temperatura.

ESCALA RACIONAL

A escala racional é a que carrega mais informações, pois seus números independem de um sistema (como Kelvin e Celsius). Exemplos desses atributos são tamanho, distância e valores financeiros como salário e saldo em conta corrente.

ESCALA

Qual a escala dos tipos desse conjunto de dados médicos?

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

EXPLORAÇÃO DE DADOS

Uma grande quantidade de informações úteis pode ser extraída de um conjunto de dados por meio de sua análise ou exploração.

Uma das formas mais simples de fazer isso é extraindo as medidas de estatística descritiva, a qual resume de forma quantitativa as principais características de um conjunto de dados.

EXPLORAÇÃO DE DADOS

As medidas da estatística descritiva assumem que os dados são gerados por um processo estatístico. Por exemplo, os dados podem ter sido gerados por uma distribuição normal com média 0 e variância 1. Essas medidas permitiriam capturar informações como:

- Frequência;
- Localização ou tendência central (média);
- Dispersão ou espalhamento (desvio padrão);

MEDIDAS DE LOCALIDADE

As medidas de localidade definem pontos de referência nos dados e variam entre dados numéricos e simbólicos. Para simbólicos, utiliza-se a moda, que é o valor com maior frequência para um atributo.

Para atributos numéricos, utiliza-se a média. No entanto, essa medida é muito sensível a outliers, portanto a mediana é uma opção com valores ordenados.

MEDIDAS DE LOCALIDADE

$$\bar{x}^j = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$\text{mediana}(\mathbf{x}^j) = \begin{cases} \frac{1}{2}(x_r + x_{r+1}) & \text{se } n \text{ for par } (n = 2r) \\ x_{r+1} & \text{se } n \text{ for ímpar } (n = 2r+1) \end{cases}$$

MEDIDAS DE LOCALIDADE

Moda, média ou mediana?

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

MEDIDAS DE LOCALIDADE

Quartil e percentil é outra forma de estatística descritiva. Na verdade, a mediana pode ser vista com um percentil de 50%, ou Q2 das quatro partes do Quartil.

MEDIDAS DE ESPALHAMENTO

As medidas de espalhamento medem a dispersão de um conjunto de valores, permitindo observar se os valores estão amplamente espalhados ou relativamente concentrados em torno de um valor. As mais comuns são:

- Intervalo
- Variância
- Intervalo Interquantil

(Contra outliers)

$$\text{intervalo}(\mathbf{x}^j) = \max_{i=1,\ldots,n}(x_i) - \min_{i=1,\ldots,n}(x_i)$$

$$\text{variância}(\mathbf{x}^j) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x}^j)^2$$

$$IQR(\mathbf{x}^j) = P_{75\%} - P_{25\%}$$

MEDIDAS DE DISTRIBUIÇÃO

As medidas que são definidas em torno da média de um conjunto de valores, como média e desvio padrão, são geralmente instanciação de uma medida chamada momento.

$$\text{momento}_k(\mathbf{x}^j) = \frac{\sum_{i=1}^{n} (x_i - \bar{x}^j)^k}{(n-1)}$$

MEDIDAS DE DISTRIBUIÇÃO

Para cada valor de k, uma medida diferente é definida:

- k = 1, obtém-se 0, que é o primeiro momento em torno da média;
- k = 2, tem-se a variância;
- k = 3, tem-se a obliquidade; e
- k = 4, tem-se a curtose.

$$\text{momento}_k(\mathbf{x}^j) = \frac{\sum_{i=1}^{n} (x_i - \bar{x}^j)^k}{(n-1)}$$

Os dois primeiros são medidas de localidade, enquanto os dois últimos mostram como os valores estão distribuídos.

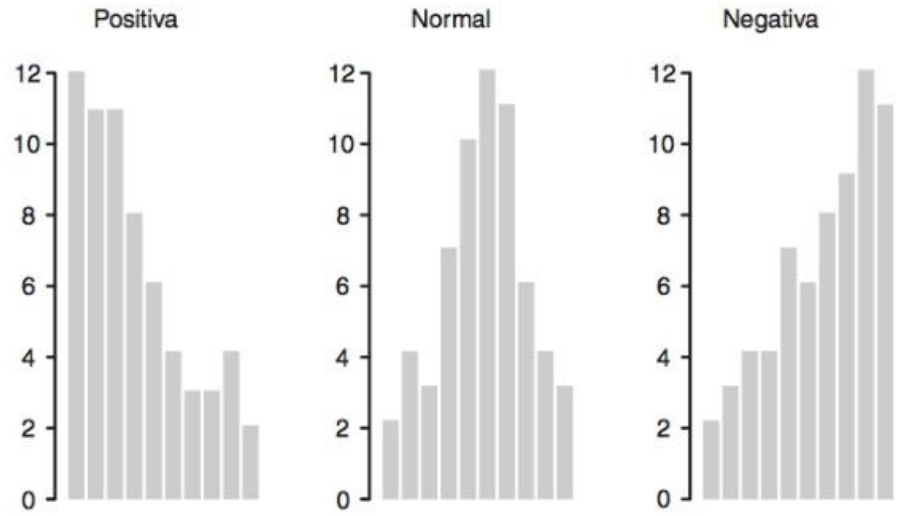
MEDIDAS DE DISTRIBUIÇÃO

A distribuição dos valores em um conjunto de dados está associada ao valor da obliquidade com relação a inclinação dos dados, onde s^3 é o desvio padrão ao cubo para ser invariante à escala.

$$\text{obliquidade}(\mathbf{x}^j) = \frac{\text{momento}_3(\mathbf{x}^j)}{s^3} = \frac{\sum_{i=1}^{n} (x_i^j - \bar{x}^j)^3}{(n-1)s^3}$$

MEDIDAS DE DISTRIBUIÇÃO

- obliquidade = 0, a distribuição é aproximadamente simétrica;
- obliquidade > 0, a distribuição concentra-se mais no lado esquerdo; e
- obliquidade < 0, a distribuição concentra-se mais no lado direito.



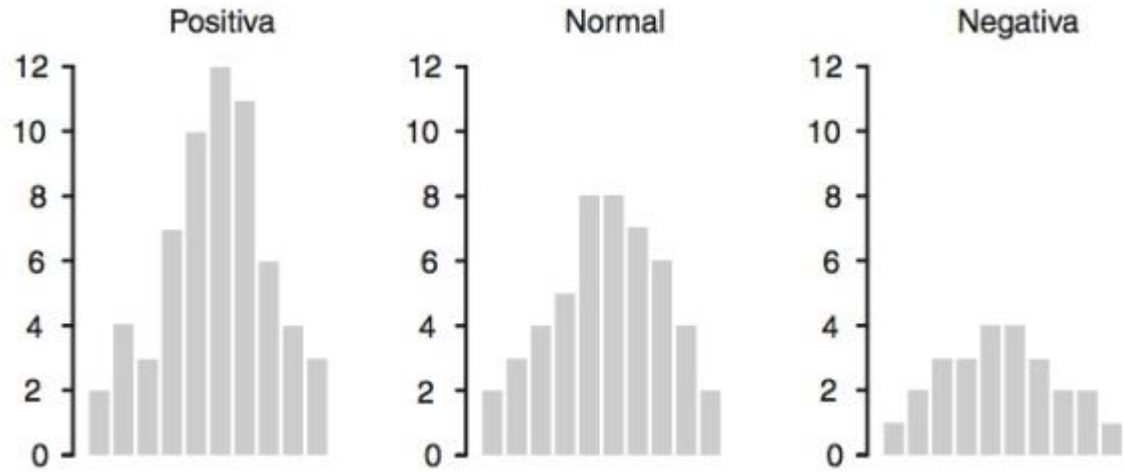
MEDIDAS DE DISTRIBUIÇÃO

A curtose é uma medida que captura o achatamento da função de distribuição, e com média 0 e variância 1 o valor se iguala a 3, assim faz-se a seguinte correção para que a curtose seja 0 nessa condição.

$$\text{curtose}(\mathbf{x}^j) = \frac{\text{momento}_4(\mathbf{x}^j)}{s^4} - 3 = \frac{\sum_{i=1}^{n} (x_i - \bar{x}^j)^4}{(n-1)s^4} - 3$$

MEDIDAS DE DISTRIBUIÇÃO

- curtose = 0, mesmo achatamento de distribuição normal;
- curtose > 0, distribuição mais alta e concentrada; e
- curtose < 0, distribuição mais achatada.



DADOS UNIVARIADOS E MULTIVARIADOS

Os conceitos passados até aqui se referem a análise univariada, quando interessa apenas um atributo isolado. No entanto, também é possível fazer a análise multivariada, que envolve mais de um atributo.

Exemplos são covariância e correlação.

COVARIÂNCIA

Para atributos quantitativos, o espalhamento de um conjunto de dados é mais bem capturado por uma matriz de covariância, onde cada elemento é a covariância entre dois atributos.

$$\text{covariância}(\mathbf{x}^i, \mathbf{x}^j) = \frac{1}{n-1} \sum_{k=1}^{n} (x_k^i - \bar{x}^i)(x_k^j - \bar{x}^j)$$

Próximo a 0 indica que não há relacionamento linear.

Valores positivos indicam relação, quando um aumenta o outro aumenta também;

Valores negativos indicam o contrário, quando um diminui o outro diminui também.

CORRELAÇÃO

A medida da covariância é afetada pela dimensão dos atributos avaliados. A medida de correlação elimina esse problema, indicando de forma mais clara a relação linear entre dois atributos.

$$\text{correlação}(\mathbf{x}^i, \mathbf{x}^j) = \frac{\text{covariância}(\mathbf{x}^i, \mathbf{x}^j)}{s_i s_j}$$

REFERÊNCIAS

FACELI, Katti; LORENA, Ana Carolina; GAMA, João; CARVALHO, André Carlos Ponce de Leon Ferreira de. Inteligência artificial: uma abordagem de aprendizado. (2011) Rio de Janeiro: LTC.