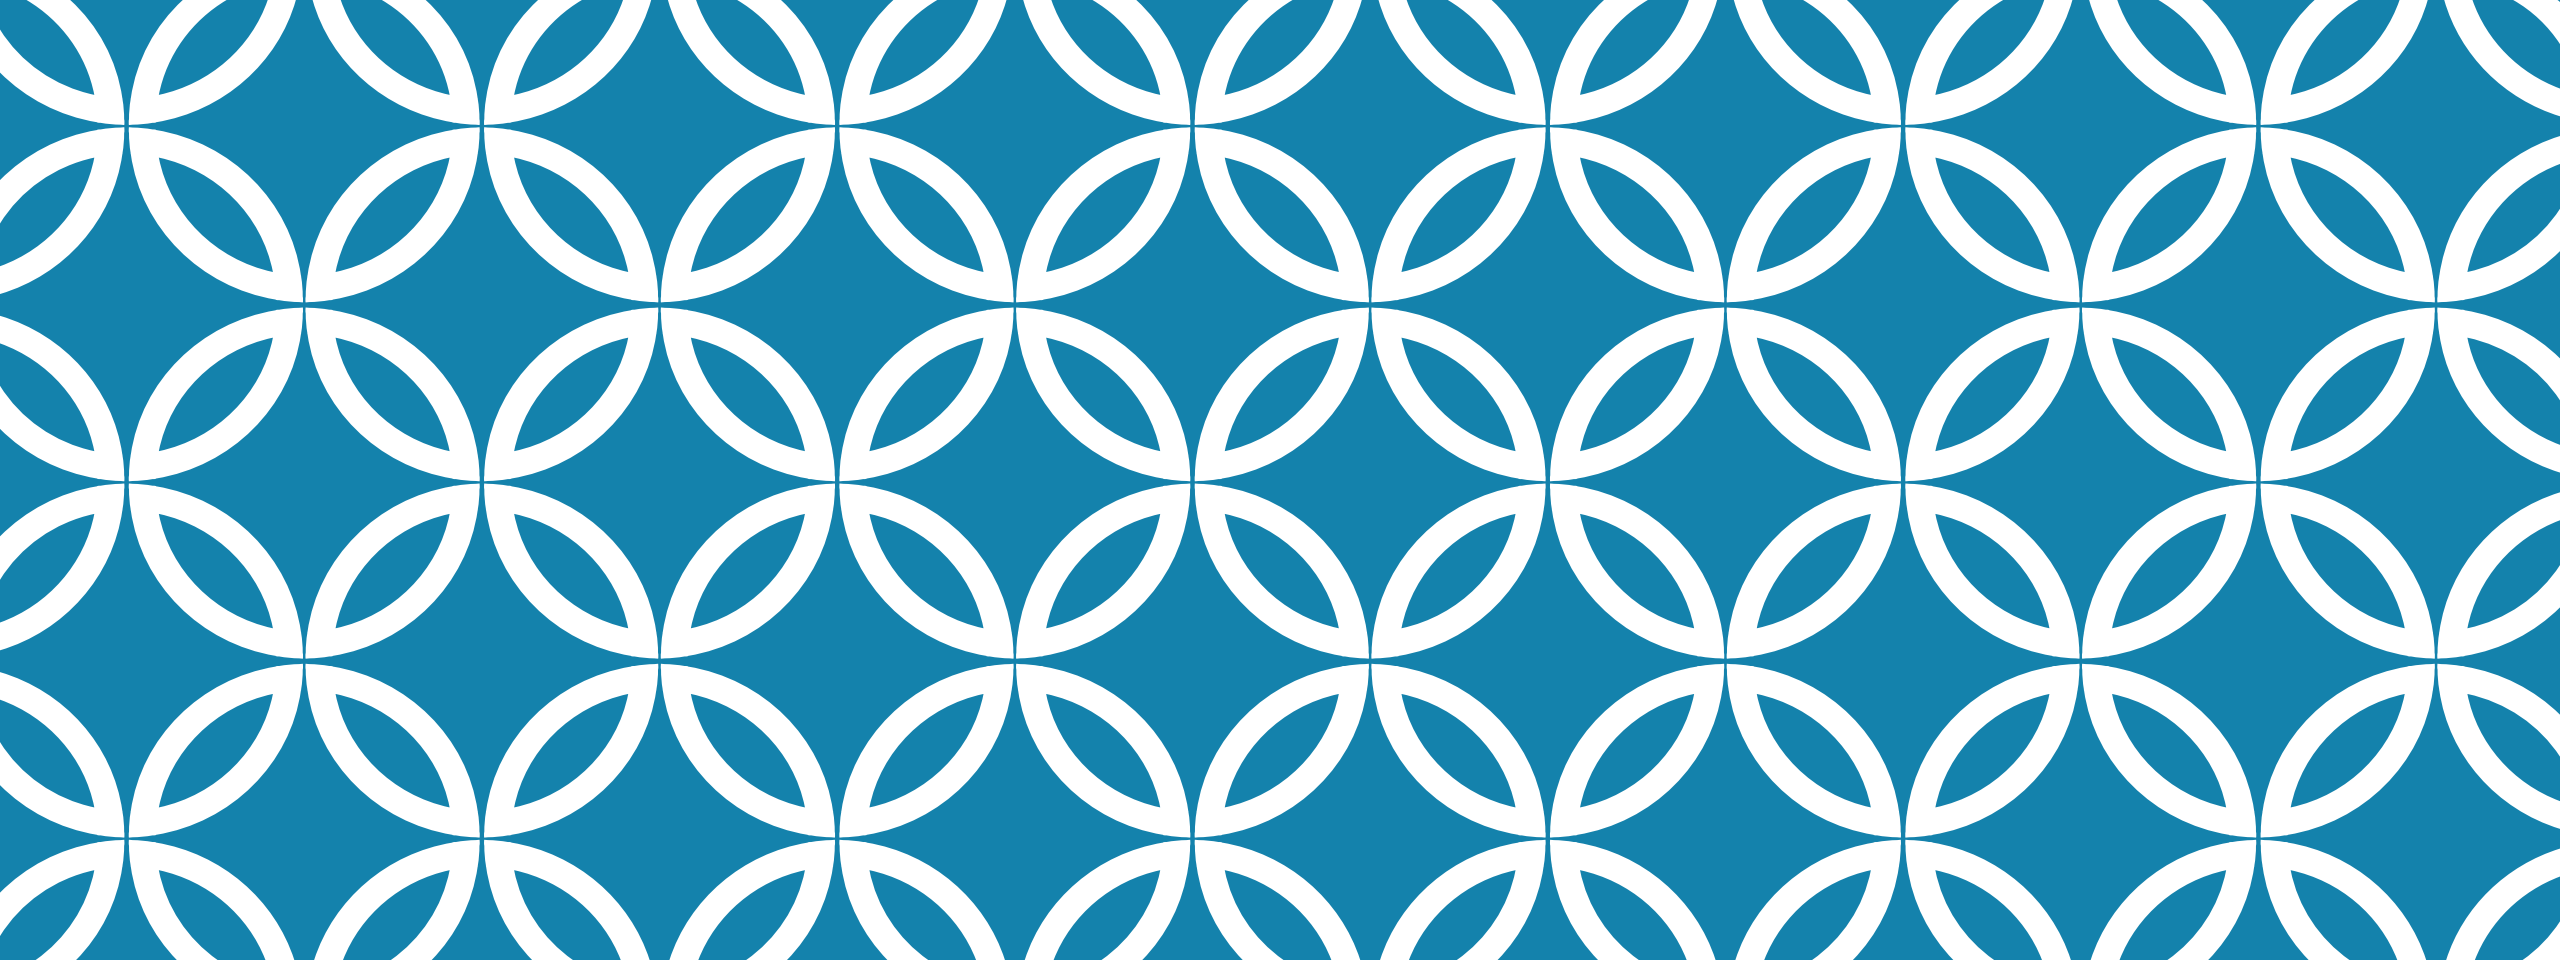


PRÉ-PROCESSAMENTO DE DADOS

INTELIGÊNCIA COMPUTACIONAL 2019/1

JOHANNES VON LOCHTER
JOHANNES.LOCHTER@FACENS.BR

PRÉ-PROCESSAMENTO

Os algoritmos de aprendizado de máquina são normalmente afetados pelo estado dos dados, os quais podem apresentar ruídos e imperfeições, como valores incorretos, inconsistentes, duplicados ou ausentes.

Técnicas de pré-processamento são empregadas para eliminar ou minimizar os problemas citados anteriormente.

PRÉ-PROCESSAMENTO

As técnicas de pré-processamento também podem ser empregadas inclusive em conjuntos de dados sem imperfeições, porque alguns métodos dependem que os dados estejam em algum formato específico.

Essas operações englobam o uso de amostragem, tratamento de dados desbalanceados, modificações para adequação de tipo, limpeza de dados, integração, transformação e redução de dimensionalidade.

ELIMINAÇÃO MANUAL DE ATRIBUTOS

A aplicação dessas técnicas não tem uma ordem fixa, e varia conforme o problema e a organização original dos dados.

A eliminação manual de atributos diz respeito a excluir as informações que não são pertinentes à tarefa a ser desempenhada.

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

INTEGRAÇÃO DE DADOS

Muitas vezes é necessário integrar dados provenientes de diferentes fontes. Nesse sentido, muito conhecimento de banco de dados e teoria de conjuntos é aplicado para estabelecer relações entre as partes.

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

AMOSTRAGEM DE DADOS

Os algoritmos de aprendizado de máquina são normalmente custosos computacionalmente e alguns inclusive dependem da base original para fazer uma predição nova.

Muitas vezes uma amostra leva ao mesmo desempenho que todo o conjunto de dados, então é preferível selecionar as amostras a serem empregadas nas outras etapas de aprendizado de máquina.

AMOSTRAGEM DE DADOS

A amostragem ela precisa ser representativa para que faça sentido selecionar um subconjunto. Basicamente são três as técnicas:

- Amostragem aleatória simples
- Amostragem estratificada
- Amostragem progressiva

DADOS DESBALANCEADOS

Dados desbalanceados é um problema específico de métodos de classificação. Ocorre quando uma classe tem muito mais amostras que as outras classes do problema.

Para ser aceitável, a acurácia preditiva de um classificador para um conjunto de dados desbalanceados deve ser maior que a acurácia obtida atribuindo todo novo objeto à classe majoritária.

DADOS DESBALANCEADOS

O grande problema dos dados desbalanceados é que podem favorecer uma classe em função de outra na maioria dos métodos de aprendizado. As principais técnicas para contornar isso na literatura são:

- Redefinir o tamanho do conjunto;
- Utilizar diferentes custos de classificação (ponderar); e
- Induzir um modelo para cada classe.

LIMPEZA DE DADOS

A qualidade dos dados pode ser comprometida por dados inconsistentes, redundantes (amostras iguais) ou incompletos. Enquanto os dados incompletos são fáceis de detectar, os outros não apresentam a mesma facilidade.

Algumas técnicas de aprendizado são capazes de minimizar o efeito da qualidade dos dados, mas é importante sempre produzir dados com a maior qualidade possível.

DADOS INCOMPLETOS

Causas:

- Um dado não era coletado no início;
- Não foi anotado ou medido;
- Distração no preenchimento;
- Problema de equipamento;
- Restrições de software.

Idade	Sexo	Peso	Manchas	Temp.	# Int.	Diagnóstico
—	M	79	—	38,0	—	Doente
18	F	67	Inexistentes	39,5	4	Doente
49	M	92	Espalhadas	38,0	2	Saudável
18	—	43	Inexistentes	38,5	8	Doente
21	F	52	Uniformes	37,6	1	Saudável
22	F	72	Inexistentes	38,0	3	Doente
—	F	87	Espalhadas	39,0	6	Doente
34	M	67	Uniformes	38,4	2	Saudável

DADOS INCOMPLETOS

Técnicas empregadas para resolver na literatura:

- Eliminar objetos com valores ausentes;
- Definir e preencher manualmente;
- Utilizar heurística para preencher;
- Utilizar aprendizado de máquina para definir os valores.

DADOS INCONSISTENTES

Inconsistências são identificadas quando relações conhecidas são violadas, por exemplo, numa base de adultos ter idade 3 ou peso 300. Unidades de medida trocadas podem causar inconsistência na escala também.

A solução é observar a distribuição dos dados e estabelecer regras para os atributos.

DADOS REDUNDANTES

Um objeto é redundante quando é muito semelhante a outros objetos do mesmo conjunto. Um atributo é redundante quando seu valor pode ser deduzido a partir de outro, por exemplo, com uma fórmula. Não remover esses dados pode induzir o método a entender que esse objeto tem mais importância que os outros.

Técnicas:

- Ordenação ajuda a identificar amostras semelhantes;
- Correlação ajuda a identificar atributos semelhantes.

TRANSFORMAÇÃO DE DADOS

Algumas técnicas de aprendizado dependem de entradas numéricas ou simbólicas exclusivamente. Quando os dados não estão no formato desejado, é necessário fazer a transformação apropriada.

Simbólico-Numérica

Quando o atributo é do tipo nominal e assume apenas dois valores, um dígito binário é suficiente. Para mais de dois valores, depende se o atributo é nominal ou ordinal. Os nominais não podem ser transformados com essa relação de dependência, enquanto que os ordinais obrigatoriamente devem mantê-la.

TRANSFORMAÇÃO DE DADOS

Numérico-Simbólico

Para os binários, basta associar um símbolo a cada. Para valores contínuos, é necessário empregar discretização.

Transformação de Atributos Numéricos

Também pode ser necessário mudar a escala de valores, normalmente obrigatório para tarefas que envolvam técnicas de otimização. Isso evita a predominância de atributos.

NORMALIZAÇÃO POR REESCALA

Também chamada de reescala por mínimo e máximo, esse tipo de normalização coloca todos os valores de um atributo dentro de um intervalo desejado, estabelecido em mínimo e máximo.

$$v_{Novo} = \min + \frac{v_{Atual} - \text{menor}}{\text{maior} - \text{menor}}(\max - \min)$$

NORMALIZAÇÃO POR PADRONIZAÇÃO

Na normalização por padronização, diferentes atributos podem ter limites inferiores e superiores diferentes, mas terão os mesmos valores de medidas de escala e espalhamento.

Comumente, emprega-se média e variância, mantendo os valores de cada atributo em média e variância 1.

$$v_{Novo} = \frac{v_{Atual} - \mu}{\sigma}$$

REDUÇÃO DE DIMENSIONALIDADE

A redução de dimensionalidade é empregada para condensar a informação de vários atributos em um conjunto menor utilizando alguns conceitos de álgebra linear, como autovetor e autovalor.

O benefício da redução é utilizar menos espaço em memória e reduzir o número de custo computacional para fazer o ajuste de modelo a partir dos dados com dimensionalidade reduzida.

REFERÊNCIAS

FACELI, Katti; LORENA, Ana Carolina; GAMA, João; CARVALHO, André Carlos Ponce de Leon Ferreira de. Inteligência artificial: uma abordagem de aprendizado. (2011) Rio de Janeiro: LTC.