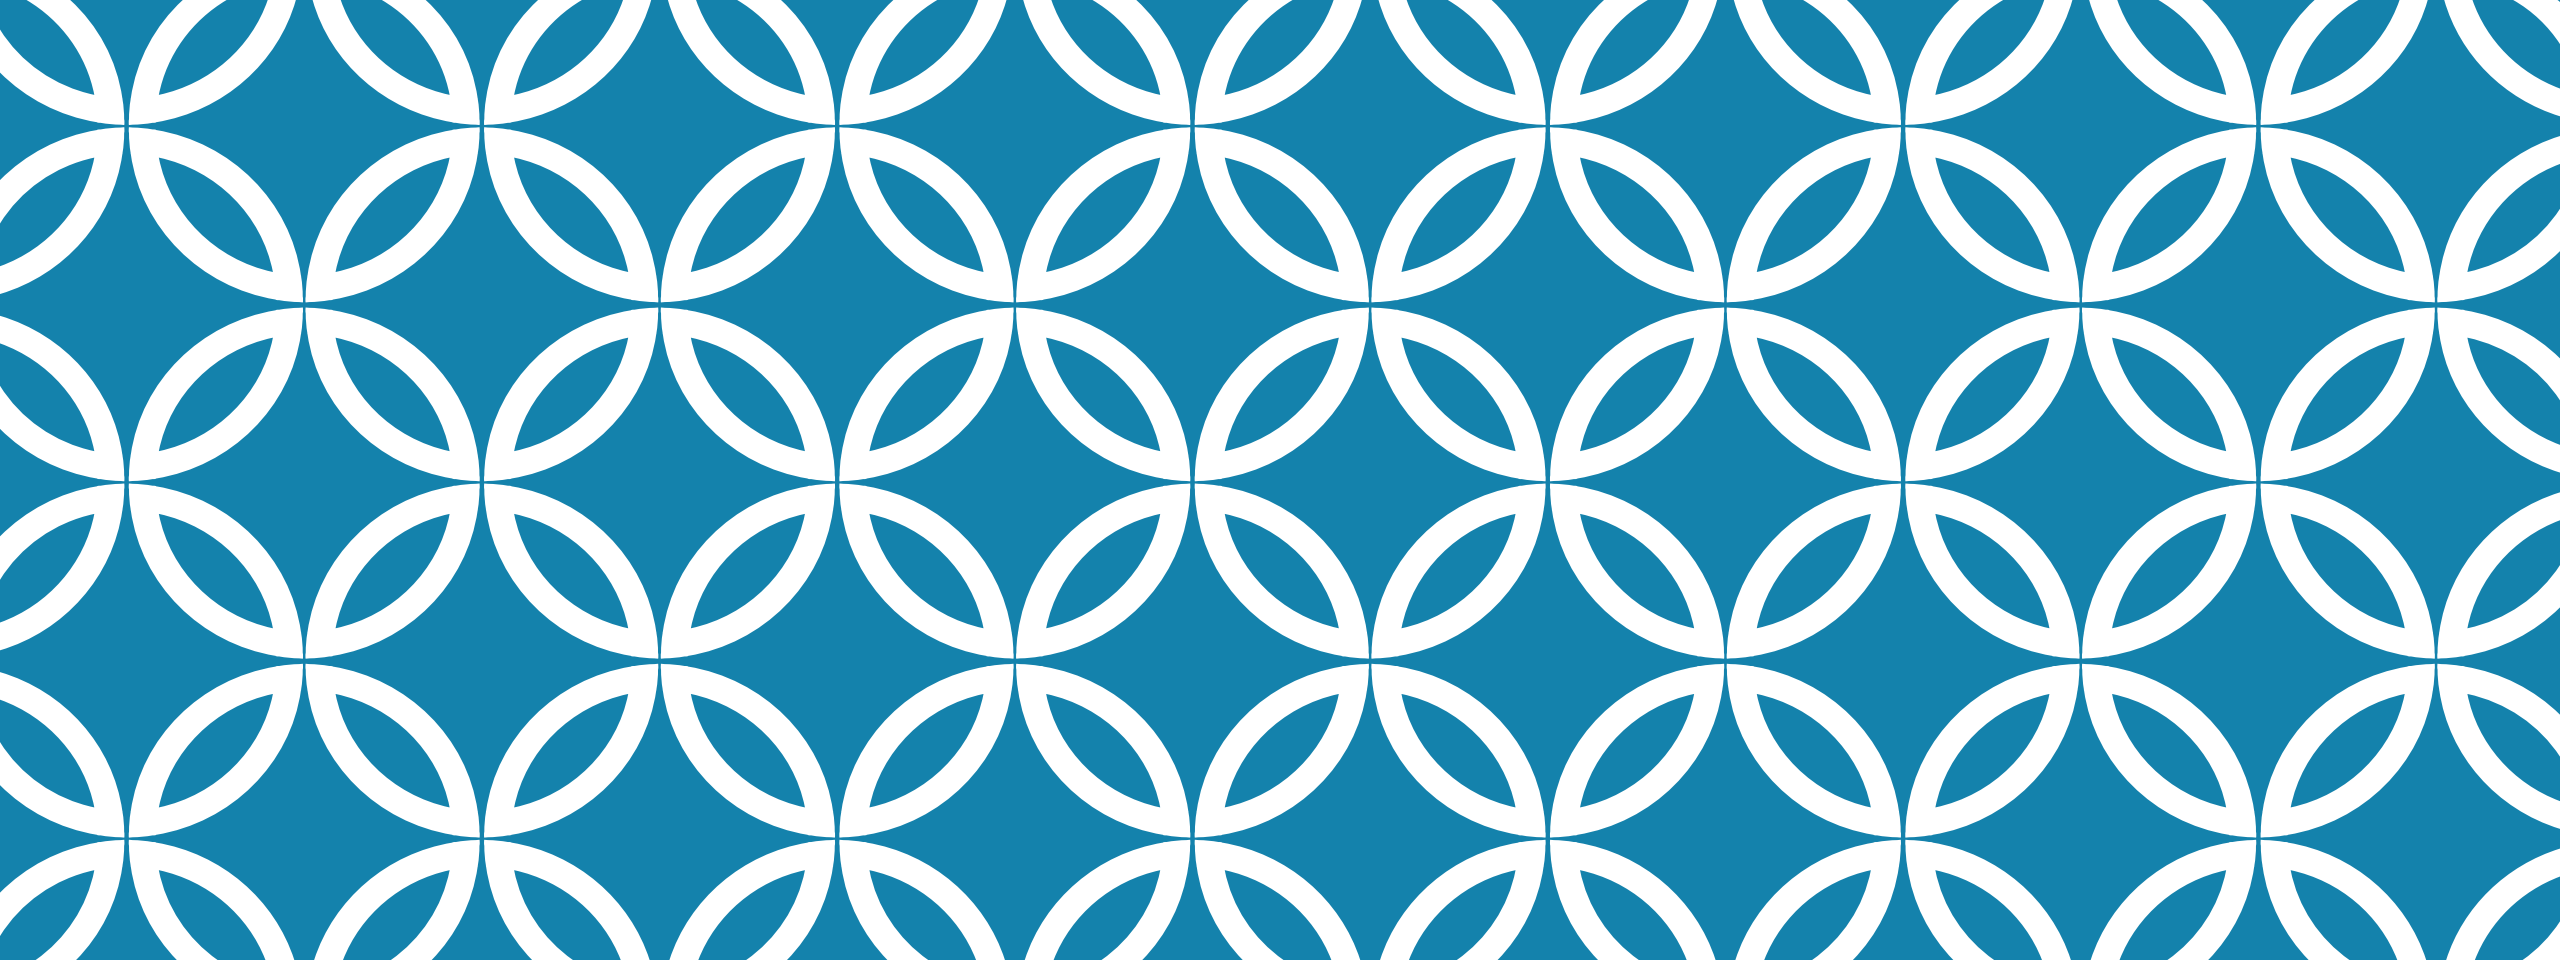


MODELOS PREDITIVOS

INTELIGÊNCIA COMPUTACIONAL 2019/1

JOHANNES VON LOCHTER
JOHANNES.LOCHTER@FACENS.BR

INTRODUÇÃO

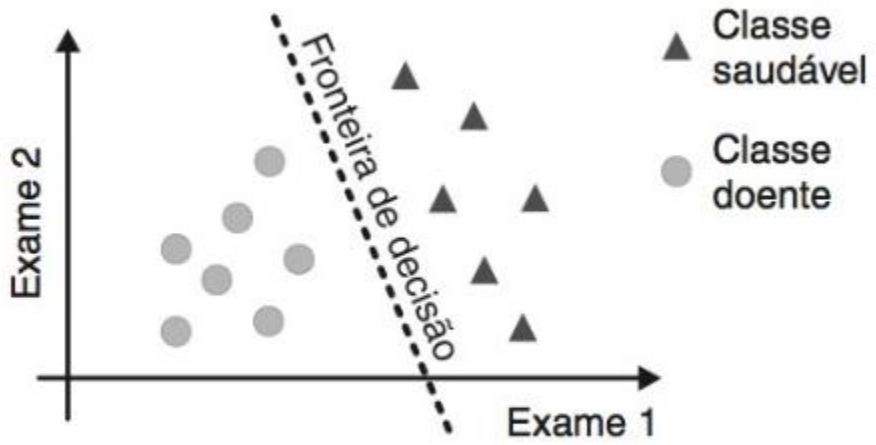
Um algoritmo preditivo é uma função que, dado um conjunto de exemplos rotulados, constrói um estimador. Nesse caso, o rótulo de cada amostra toma valores num domínio conhecido.

Domínio de valores nominais: classificação

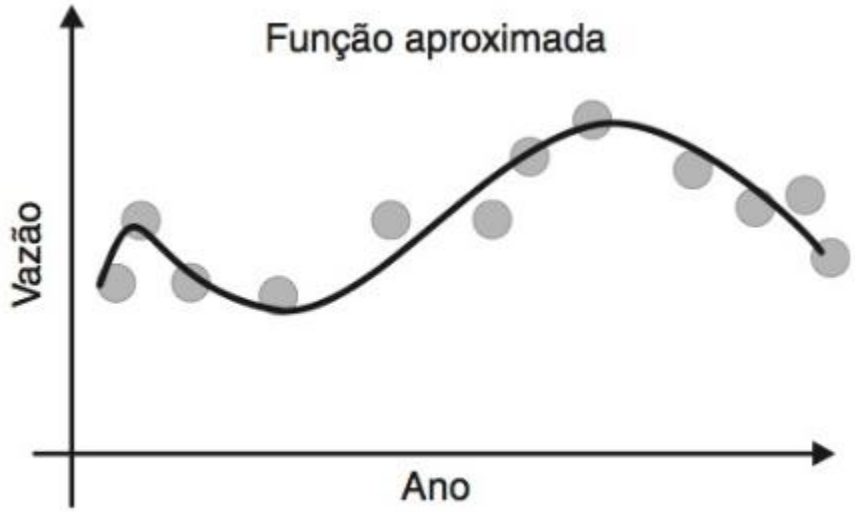
Domínio de valores infinitos e ordenados: regressão

INTRODUÇÃO

Um classificador (ou regressor) é uma função que, dado os dados de entrada, atribui o rótulo à amostra.



(a) Classificação



(b) Regressão

PROBLEMAS DE CLASSIFICAÇÃO

Os rótulos nesse problema são valores discretos e não ordenados.

Tamanho (P)	Largura (P)	Tamanho (S)	Largura (S)	Espécie
5,1	3,5	1,4	0,2	Setosa
4,9	3,0	1,4	0,2	Setosa
7,0	3,2	4,7	1,4	Versicolor
6,4	3,2	4,5	1,5	Versicolor
6,3	3,3	6,0	2,5	Virgínica
5,8	2,7	5,1	1,9	Virgínica

PROBLEMAS DE REGRESSÃO

Os rótulos nesse problema são valores contínuos e ordenados.

Fertilidade	Agricultura	Educação	Renda	Mortalidade
80,2	17,0	12	9,9	22,2
83,1	45,1	9	84,8	22,2
92,5	39,7	5	93,4	20,2
85,8	36,5	7	33,7	20,3
76,9	43,5	15	5,2	20,6

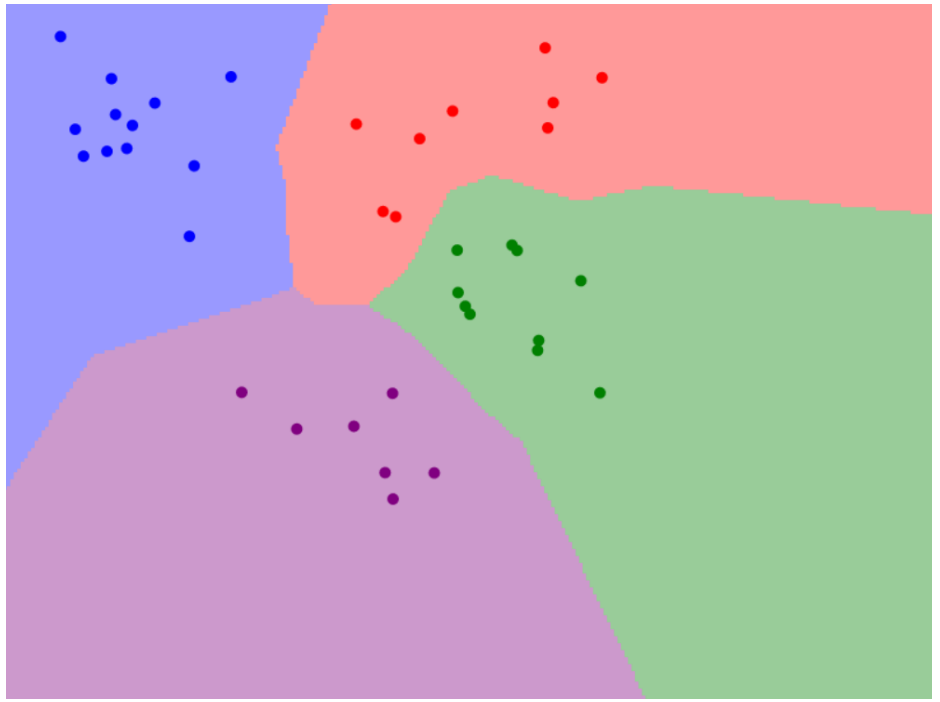
MODELO

A função que mapeia rótulos para as amostras também pode ser interpretada com um modelo, o qual é derivado de um algoritmo de aprendizagem após a etapa de treinamento.

Essa função pode assumir combinações lineares e não-lineares, por ramos, expressões lógicas, entre outras. Os métodos preditivos são organizados em métodos baseados em distâncias, probabilísticos, busca e otimização.

MÉTODOS BASEADOS EM DISTÂNCIA

A hipótese dos métodos baseados em distância é que dados similares tendem a estar concentrados em uma mesma região no espaço de entrada.



Um método comum baseado em distância são os n-vizinhos próximos.

N-VIZINHOS PRÓXIMOS

A intuição desse método é que objetos relacionados ao mesmo conceito são semelhantes (próximos) entre si. Assim, esse algoritmo classifica um novo objeto com base nos exemplos do conjunto de treinamento que são próximos a ele.

Esse algoritmo tem variações de acordo com o número de vizinhos observados para descrever o rótulo do novo objeto.

1-VIZINHO PRÓXIMO

Cada objeto representa um ponto em um espaço definido pelos atributos (espaço de entrada). Definida uma métrica nesse espaço, é possível calcular a distância entre dois pontos. A métrica mais comum é a distância euclidiana, e na equação a seguir, i e j indicam objetos distintos, l indica um atributo e d o total de atributos.

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{l=1}^{d} (x_i^l - x_j^l)^2}$$

1-VIZINHO PRÓXIMO

Na etapa de treinamento, esse algoritmo memoriza as amostras em vez de aprender com elas.

Para classificar um objeto não-rotulado, as etapas são:

(1) calcula-se a distância entre o objeto e todos objetos da base;

(2) ordena a lista de forma decrescente;

(3) armazena o rótulo do primeiro item (menor distância);

(4) atribui rótulo armazenado ao objeto não-rotulado.

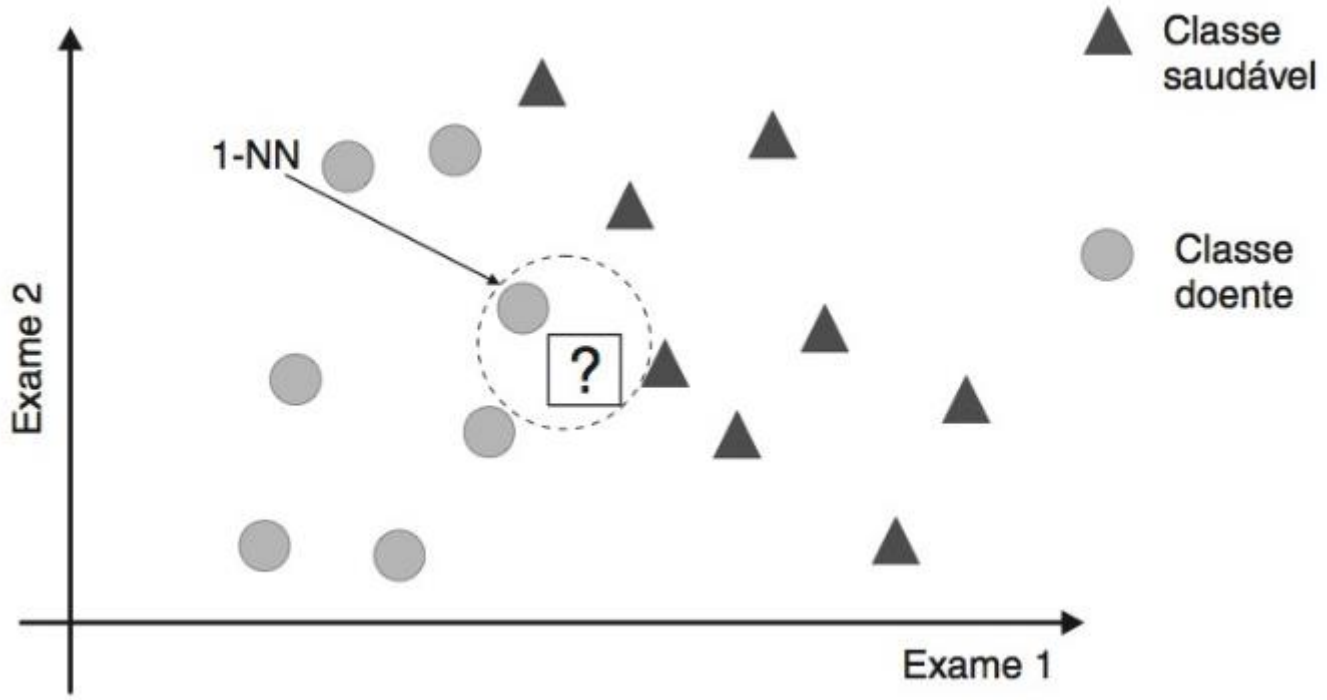
1-VIZINHO PRÓXIMO

Algoritmo 4.1 Versão básica do algoritmo 1-vizinho mais próximo

Entrada: Um conjunto de treinamento: $\mathbf{D} = \{(\mathbf{x}_i, y_i), i = 1, \ldots, n\}$
Um objeto de teste a ser classificado: $t = \{\mathbf{x}_t, y_t = ?\}$
A função de distância entre objetos: $d(\mathbf{x}_a, \mathbf{x}_b)$
Saída: y_t: Classe atribuída ao exemplo t

1 $d_{min} \leftarrow +\infty$
2 **para cada** $i \in 1, \ldots, n$ **faça**
3 **se** $d(\mathbf{x}_i, \mathbf{x}_t) < d_{min}$ **então**
4 $d_{min} \leftarrow d(\mathbf{x}_i, \mathbf{x}_t)$
5 $idx \leftarrow i$
6 **fim**
7 **fim**
8 $y_t = y_{idx}$
9 **Retorna:** y_t

1-VIZINHO PRÓXIMO



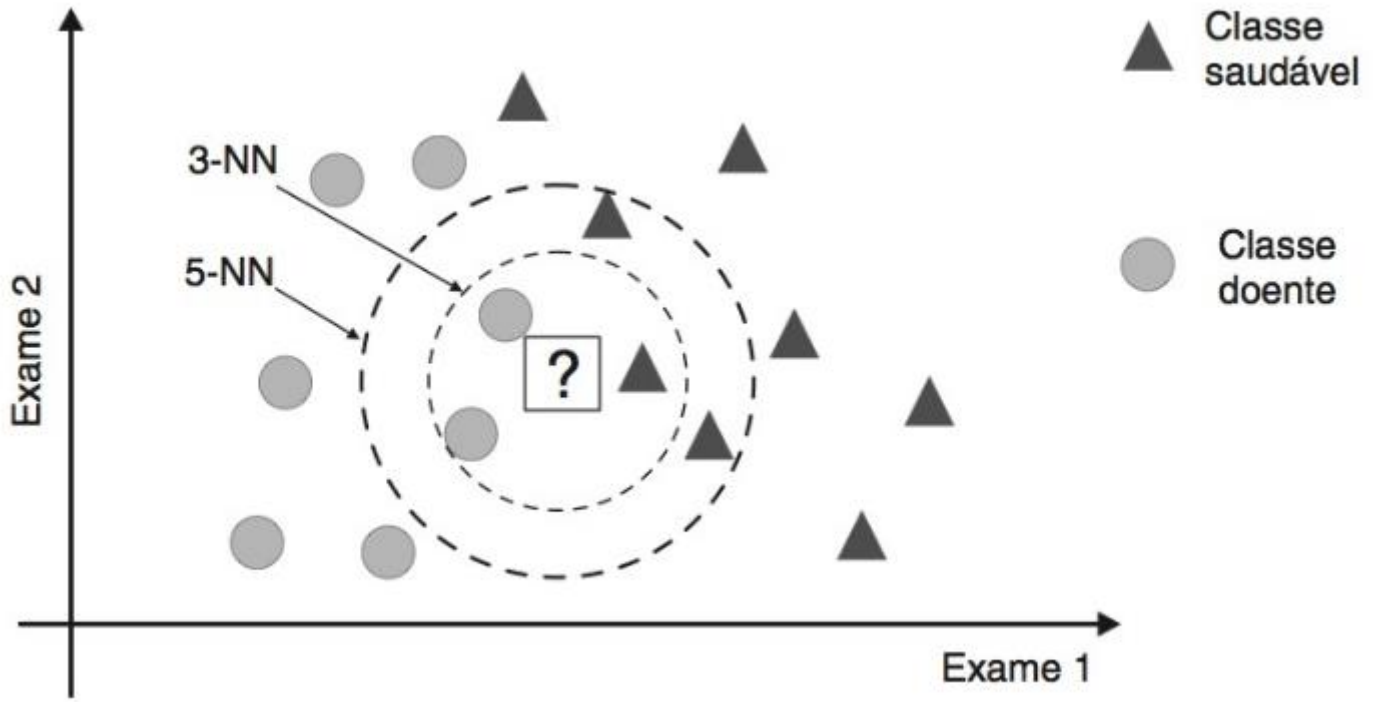
N-VIZINHOS PRÓXIMOS

Uma extensão muito óbvia do algoritmo dos vizinhos próximos é considerar um número n de vizinhos, em vez de apenas 1 vizinho.

Ou seja, após calcular a distância, não é considerado apenas o rótulo do vizinho no topo da lista (menor distância), mas n vizinhos do topo da lista.

Assim, o rótulo do objeto a ser classificado é determinado pela moda dos votos dos n vizinhos.

N-VIZINHOS PRÓXIMOS



A ESCOLHA DO VALOR N

A escolha da quantidade de vizinhos a ser utilizada é subjetiva. Depende do problema, da quantidade de classes e do volume de dados.

Para problemas com 2 classes não recomenda-se valores pares para n a fim de evitar empates.

A ESCOLHA DO VALOR N

Valores pequenos de n tornam o modelo muito específico, limita a uma região pequena; Valores grandes de n tornam o modelo mais genérico, englobando uma região maior;

Valores pequenos e valores grandes também são sujeitos ao tamanho da base. Valores pequenos em bases pequenas são proporcionalmente menores que valores pequenos em bases maiores.

ASPECTOS POSITIVOS

- O treinamento é simples (armazena objetos apenas);
- Aplicável mesmo em problemas complexos;
- Naturalmente incremental: basta armazená-los.

ASPECTOS NEGATIVOS

- Não tem representação compacta dos objetos;
- Esforço computacional na classificação: distância e ordenação de todos objetos memorizados;
- É afetado pela presença de atributos redundantes ou irrelevantes;
- A distribuição fica rarefeita conforme cresce o número de dimensões;

DESENVOLVIMENTO

Os estudos relacionados a esse algoritmo focam em tenta reduzir o espaço do problema, tal como reduzir o número de amostras: eliminando amostras redundantes e amostras cujos vizinhos sejam classes diferentes (ruído).

Também é possível aplicar algoritmos que encontram os protótipos (dados mais representativos) para representar a base apenas com essas amostras.

ELIMINAÇÃO SEQUENCIAL

Algoritmo 4.2 Algoritmo para *Edit* k-NN: eliminação sequencial

Entrada: Um conjunto de treinamento $\mathbf{D} = \{(\mathbf{x}_i, y_i), i = 1, \ldots, n\}$
Saída: Um conjunto de treinamento $\mathbf{D}' = \{(\mathbf{x}_i, y_i), i = 1, \ldots, m; m < n\}$

1 **para cada** *exemplo* $(\mathbf{x}_i, y_i) \in \mathbf{D}$ **faça**
2 **se** $(\mathbf{x}_i, y_i)$ *é corretamente classificado por* $\mathbf{D} \backslash \{(\mathbf{x}_i, y_i)\}$ **então**
3 **/* Remove** $(\mathbf{x}_i, y_i)$ **de D */** ;
4 $\mathbf{D} \leftarrow \mathbf{D} \backslash \{(\mathbf{x}_i, y_i)\}$;
5 **fim**
6 **fim**
7 **Retorna:** D;

INSERÇÃO SEQUENCIAL

Algoritmo 4.3 Algoritmo para *Edit* k-NN: inserção sequencial

Entrada: Um conjunto de treinamento $\mathbf{D} = \{(\mathbf{x}_i, y_i), i = 1, \ldots, n\}$
Saída: Um conjunto de treinamento $\mathbf{D}' = \{(\mathbf{x}_i, y_i), i = 1, \ldots, m; m < n\}$

1 $\mathbf{D}' \leftarrow \{\}$;
2 **para cada** *exemplo* $(\mathbf{x}_i, y_i) \in \mathbf{D}$ **faça**
3 **se** $(\mathbf{x}_i, y_i)$ *é incorretamente classificado por* $\mathbf{D}'$ **então**
4 /* **Acrescenta** $(\mathbf{x}_i, y_i)$ **a** $\mathbf{D}'$ /* ;
5 $\mathbf{D}' \leftarrow \mathbf{D}' \cup \{(\mathbf{x}_i, y_i)\}$;
6 **fim**
7 **fim**
8 **Retorna:** $\mathbf{D}'$

ATIVIDADE – UTILIZE 1-VIZINHO PRÓXIMO

Plote as amostras ímpares e verifique se a classificação é correta para as amostras pares considerando os atributos 2 a 2 num plano cartesiano. Qual apresenta a maior taxa de acurácia?

Tamanho (P)	Largura (P)	Tamanho (S)	Largura (S)	Espécie
5,1	3,5	1,4	0,2	Setosa
4,9	3,0	1,4	0,2	Setosa
7,0	3,2	4,7	1,4	Versicolor
6,4	3,2	4,5	1,5	Versicolor
6,3	3,3	6,0	2,5	Virgínica
5,8	2,7	5,1	1,9	Virgínica

REFERÊNCIAS

FACELI, Katti; LORENA, Ana Carolina; GAMA, João; CARVALHO, André Carlos Ponce de Leon Ferreira de. Inteligência artificial: uma abordagem de aprendizado. (2011) Rio de Janeiro: LTC.

KNN Demo: http://vision.stanford.edu/teaching/cs231n-demos/knn/