Redes Neurais e Deep Learning





Prof. Rodrigo Caropreso
Jun/2019
rcaropreso at gmail

Esta Foto de Autor Desconhecido está licenciado em CC BY-SA

Conteúdo Programático – Aulas 1 e 2

Introdução e Redes Multi-Camadas

- Conceitos Gerais em Aprendizado Profundo
- Perceptron Multi-Camadas;
- Backpropagation e Validação Cruzada.
- Redes Neurais com Retardos Temporais (TDNN);

Redes Neurais Recorrentes

- Redes de Jordan
- Redes de Elman
- Pytorch – Conceitos e Exercícios
- Redes Convolucionais: Conceitos e Exercícios

Conteúdo Programático – Aula 3

Redes Neurais Convolucionais

- TensorFlow: Conceitos e Exercícios
- Visão Computacional: Visão Geral
- Redes AlexNet: Conceitos e Exercícios
- Redes LSTM: Conceitos e Exercícios



Redes Neurais com Retardos Temporais (TDNN)

Fonte: http://cdn.jornalgrandebahia.com.br/2018/01/Intelig%C3%AAncia-Artificial-IA-106-500x333.jpg

TDNN: Problemas Variantes no Tempo



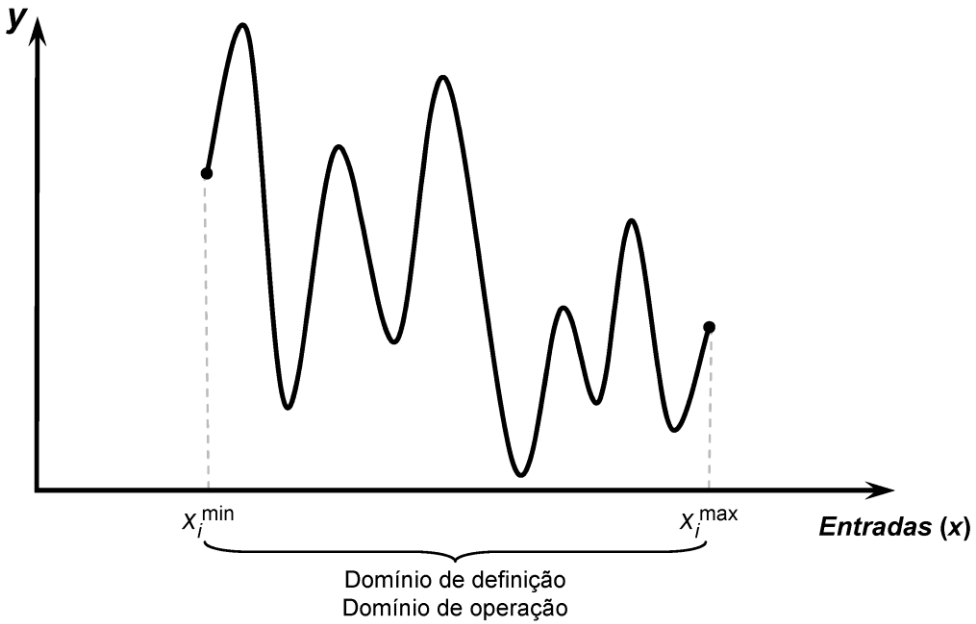
- Como o próprio nome sugere, sistemas dinâmicos ou sistemas variantes no tempo são aqueles cujos comportamentos são dependentes do tempo.
- A resposta atual depende dos valores das respostas anteriores.
- Como exemplos de aplicação, têm-se os seguintes:
  - Previsão de consumo de energia para os próximos meses.
  - Previsão de valores futuros para ações do mercado financeiro frente a um horizonte semanal.
  - Previsão de temperatura, precipitação atmosférica, etc.

TDNN: Problemas Variantes no Tempo



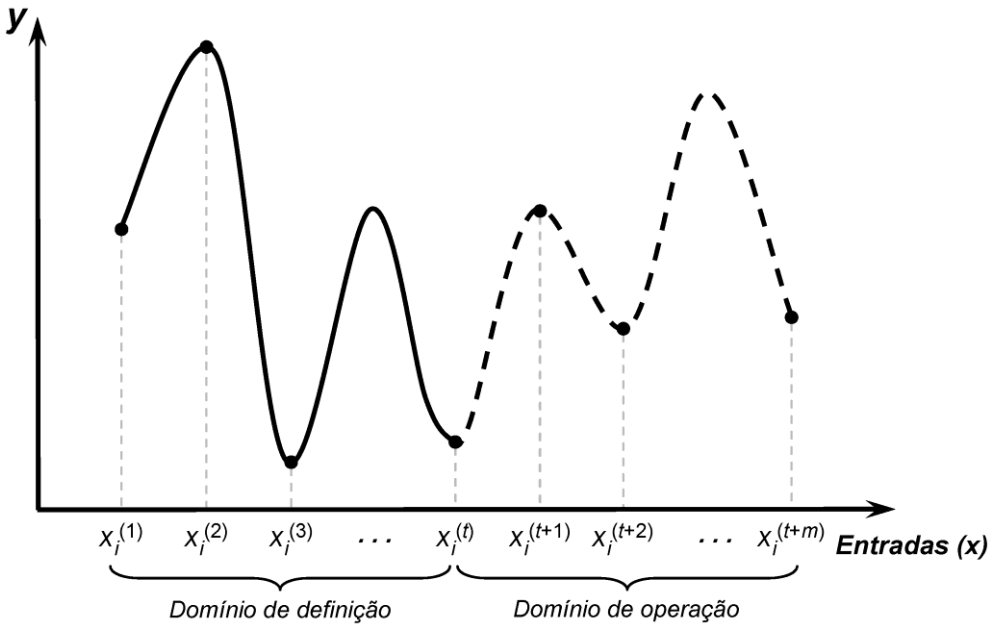
- Em contraste aos problemas de Aproximação de Funções ou Classificação de Padrões (considerados estáticos), tem-se que “As saídas dos sistemas denominados dinâmicos, assumindo um instante de tempo qualquer, dependem de seus valores anteriores de saída e de entrada”.

TDNN: Problemas Variantes no Tempo



- Para problemas de Aproximação de Funções:
- O domínio de definição referente aos dados de treinamento/teste são delimitados pelos valores mínimos e máximos associados a cada uma de suas variáveis de entrada.
- O domínio de operação em que a efetiva aplicação da rede PMC estará sujeita, após ter sido treinada, deve obrigatoriamente coincidir com o seu domínio de definição.

TDNN: Problemas Variantes no Tempo



- Para problemas de Sistemas Variantes no Tempo:
- Aqui, ambos os domínios são regidos pelo tempo, sendo que o domínio de operação se inicia após o seu domínio de definição.
- Como a saída atual depende das saídas/entradas anteriores, utiliza-se então dados de treinamento/teste para ajustar seus parâmetros internos.
- Em seguida, a rede estará apta para estimar valores futuros que estarão pertencendo ao seu domínio de operação.

TDNN: Problemas Variantes no Tempo



- Em se tratando de aplicação de redes PMC no mapeamento de problemas envolvendo sistemas variantes no tempo, duas configurações topológicas podem ser utilizadas:
- **Configuração TDNN**: rede PMC com entradas atrasadas no tempo (Time Delay Neural Network – TDNN).
- **Configuração RECORRENTE**: rede PMC com saídas recorrentes às entradas (Recurrent Perceptron).

TDNN: Conceitos



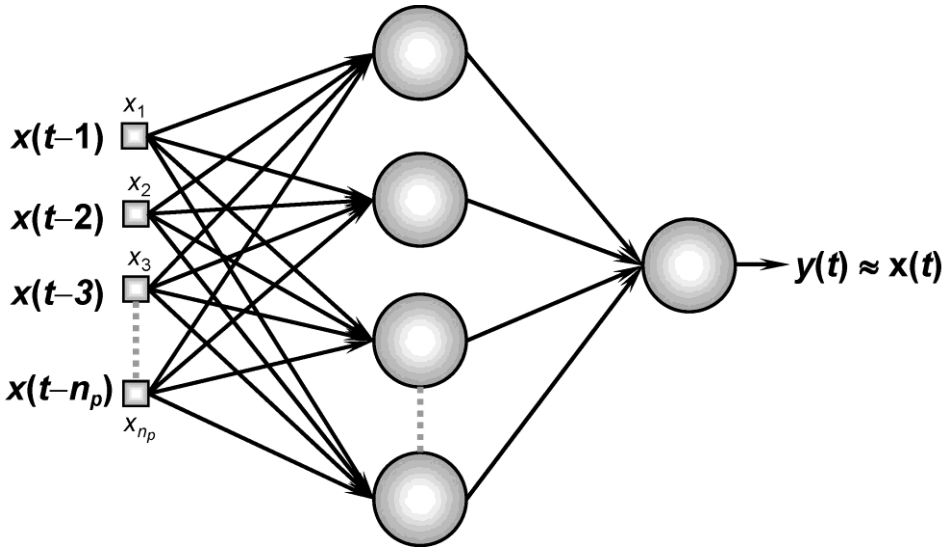
- Redes PMC em configuração TDNN (entradas atrasadas no tempo) são enquadradas dentro da arquitetura feedforward de camadas múltiplas.
- A previsão de valores futuros a partir do instante t, associados ao comportamento do processo, é computada em função do conhecimento de seus valores temporariamente anteriores:

$$x(t) = f\left(x(t-1), x(t-2), \ldots, x\left(t-n_p\right)\right)$$

np é a ordem do estimador, (a quantidade de medidas

(amostras) passadas que serão necessárias para a estimação do valor x(t))

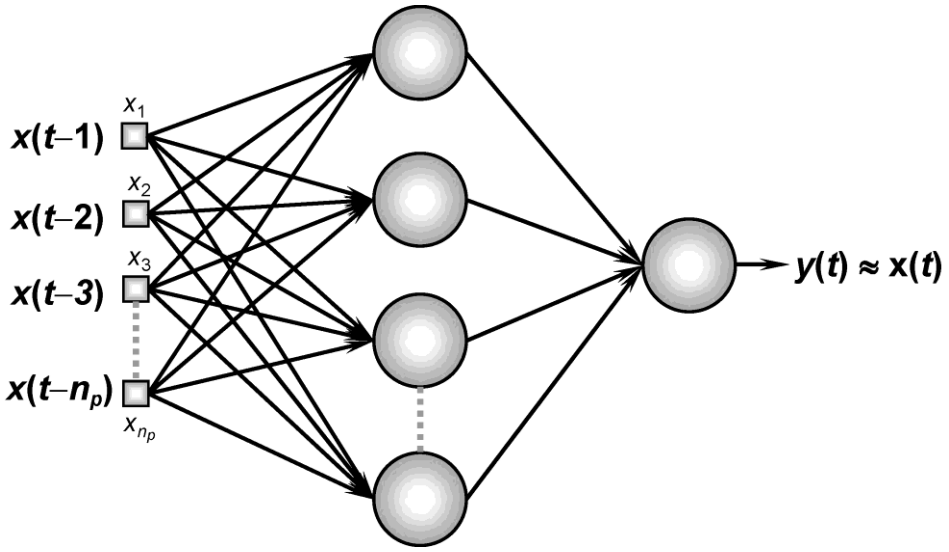
TDNN: Conceitos



$$E(t) = x(t) - y(t)$$

- De fato, a configuração TDNN estará aqui introduzindo linha de atrasos de tempo somente na camada de entrada.
- Esta linha funciona como uma memória, garantindo que amostras anteriores, que refletem o comportamento temporal do processo, sejam sempre inseridas dentro da rede.

TDNN: Conceitos



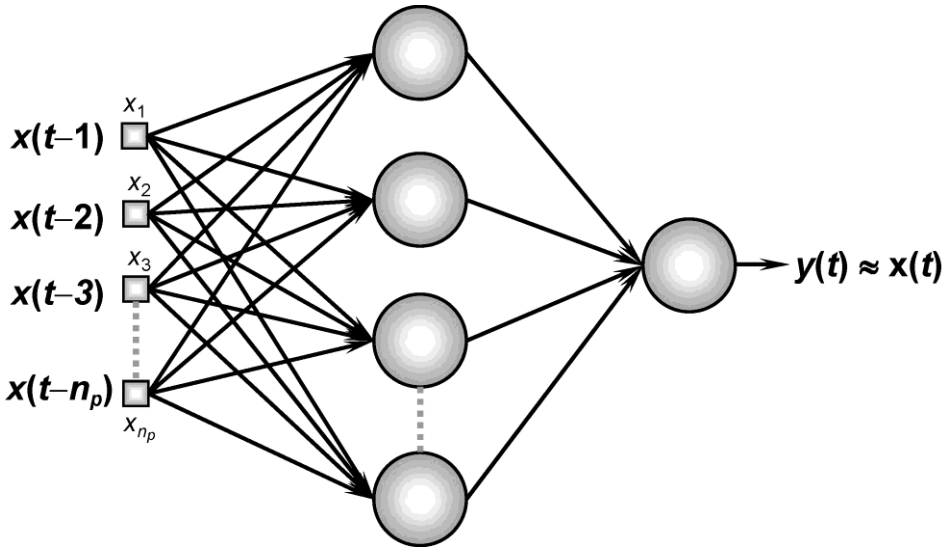
$$E(t) = x(t) - y(t)$$

- A rede recebe as n_p entradas

$$\{x(t-1),\ \ x(t-2), \dots ,\ \ x(t-n_p)\}$$

- A sua resposta prediz o respectivo valor esperado para x(t), cujo resultado é explicitado pelo valor y(t) fornecido pelo neurônio de saída.
- Assim, no treinamento, a rede tentará ajustar as suas matrizes de pesos visando minimizar o erro $E(t)$ produzido entre $x(t)$ e $y(t)$.

TDNN: Aspectos de Treinamento



$$E(t) = x(t) - y(t)$$

- O treinamento da rede PMC com configuração TDNN é similar ao PMC convencional, e o processo de aprendizado é também efetuado de maneira idêntica.
- Os cuidados que devem ser tomados estão associados com a montagem do conjunto de treinamento da rede.

$$x(t) = [0{,}11 \quad 0{,}32 \quad 0{,}53 \quad 0{,}17 \quad 0{,}98 \quad 0{,}67 \quad 0{,}83 \quad 0{,}79]^T$$

$$x(t) = [x(1) \quad x(2) \quad x(3) \quad x(4) \quad x(5) \quad x(6) \quad x(7) \quad x(8)]^T$$

- Como exemplo, assume-se que o processo possa ser mapeado com uma ordem de predição igual a três $\{n_p = 3\}$.

TDNN: Aspectos de Treinamento

relação entradas/saídas

	x_1	x_2	x_3	saída desejada
$t = 4$	$x(3)$	$x(2)$	$x(1)$	$x(4)$
$t = 5$	$x(4)$	$x(3)$	$x(2)$	$x(5)$
$t = 6$	$x(5)$	$x(4)$	$x(3)$	$x(6)$
$t = 7$	$x(6)$	$x(5)$	$x(4)$	$x(7)$
$t = 8$	$x(7)$	$x(6)$	$x(5)$	$x(8)$

$4 \leq t \leq 8$

(ordem 3)

$n_p = 3$

conjunto de treinamento

	x_1	x_2	x_3	d
$\boldsymbol{x}^{(1)}$	0,53	0,32	0,11	$\boldsymbol{d}^{(1)} = 0,17$
$\boldsymbol{x}^{(2)}$	0,17	0,53	0,32	$\boldsymbol{d}^{(2)} = 0,98$
$\boldsymbol{x}^{(3)}$	0,98	0,17	0,53	$\boldsymbol{d}^{(3)} = 0,67$
$\boldsymbol{x}^{(4)}$	0,67	0,98	0,17	$\boldsymbol{d}^{(4)} = 0,83$
$\boldsymbol{x}^{(5)}$	0,83	0,67	0,98	$\boldsymbol{d}^{(5)} = 0,79$

$$E(t) = x(t) - y(t), \text{ onde } \left(n_p + 1\right) \leq t \leq N$$

- Por intermédio da expressão acima, ter-se-á então um conjunto de treinamento composto por um total de 5 amostras, com parâmetro t variando de $4 \leq t \leq 8$. onde o valor $\{x_0 = -1\}$, associado ao limiar do neurônio, deverá serconsiderado em todos eles.

TDNN: Aspectos de Treinamento

- Na realidade, procede-se no vetor x(t), uma operação de janela deslizante de largura np, movimentando-a de uma unidade para a direita em cada iteração de tempo.
- Após o treinamento da rede, basta realizar a inserção de amostras anteriores da série a fim de se executar a predição de seus valores futuros (posteriores).

$$\boldsymbol{x}(t) = [\underbrace{0{,}11 \quad 0{,}32 \quad 0{,}53 \quad 0{,}17}_{\text{janela 1 } (t=4)} \quad 0{,}98 \quad 0{,}67 \quad 0{,}83 \quad 0{,}79\ ]^T$$

$$\boldsymbol{x}(t) = [\ 0{,}11 \quad \underbrace{0{,}32 \quad 0{,}53 \quad 0{,}17 \quad 0{,}98}_{\text{janela 2 } (t=5)} \quad 0{,}67 \quad 0{,}83 \quad 0{,}79\ ]^T$$

$$\boldsymbol{x}(t) = [\ 0{,}11 \quad 0{,}32 \quad \underbrace{0{,}53 \quad 0{,}17 \quad 0{,}98 \quad 0{,}67}_{\text{janela 3 } (t=6)} \quad 0{,}83 \quad 0{,}79\ ]^T$$

$$\boldsymbol{x}(t) = [\ 0{,}11 \quad 0{,}32 \quad 0{,}53 \quad \underbrace{0{,}17 \quad 0{,}98 \quad 0{,}67 \quad 0{,}83}_{\text{janela 4 } (t=7)} \quad 0{,}79\ ]^T$$

$$\boldsymbol{x}(t) = [\ 0{,}11 \quad 0{,}32 \quad 0{,}53 \quad 0{,}17 \quad \underbrace{0{,}98 \quad 0{,}67 \quad 0{,}83 \quad 0{,}79}_{\text{janela 5 } (t=8)}\ ]^T$$

TDNN: Aspectos de Treinamento



- Considerando-se agora o seu domínio de operação, a rede já treinada pode ser usada para estimação de valores futuros.
- Para o exemplo anterior, considerando agora {t ≥ 9}, tal procedimento é realizado da seguinte maneira:

predição de valores futuros

	x_1	x_2	x_3	saída estimada
$t = 9$	$x(8)$	$x(7)$	$x(6)$	$x(9) \approx y(9)$
$t = 10$	$x(9)$	$x(8)$	$x(7)$	$x(10) \approx y(10)$
$t = 11$	$x(10)$	$x(9)$	$x(8)$	$x(11) \approx y(11)$
(...)	(...)	(...)	(...)	(...)

TDNN: Aspectos de Treinamento



- Assim, para o exemplo anterior, conclui-se que a rede sempre realiza uma predição de um passo à frente, calculando seqüencialmente o seu valor atual ou futuro a partir de seus 3 últimos valores.

- Contudo, há situações em que a ordem de predição deve ser incrementada a fim de assegurar uma maior precisão na estimação do comportamento futuro do processo.



Redes Neurais Recorrentes

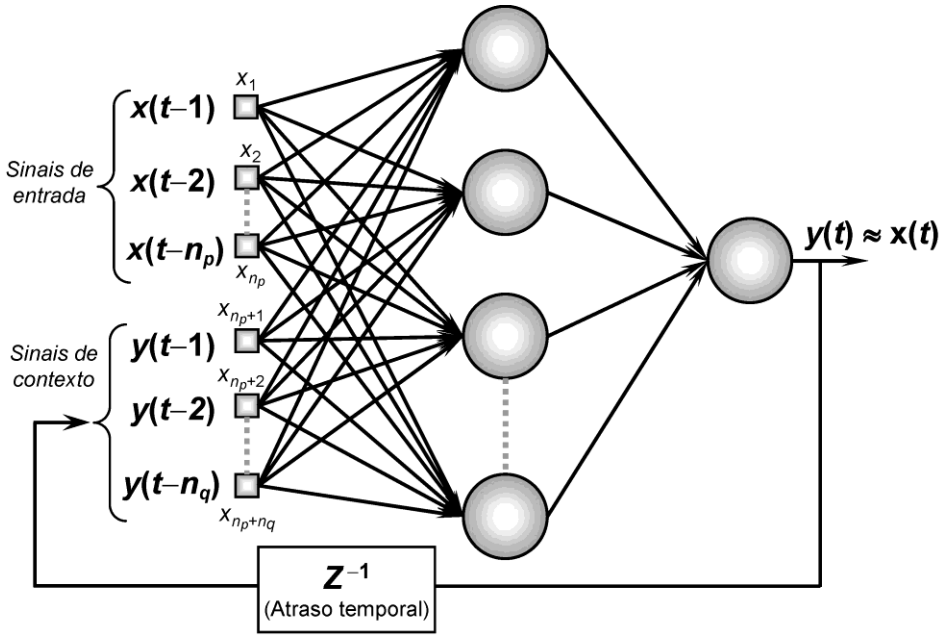
Fonte: http://cdn.jornalgrandebahia.com.br/2018/01/Intelig%C3%AAncia-Artificial-IA-106-500x333.jpg

Redes Neurais Recorrentes: Conceitos



- Diferentemente da TDNN, a arquitetura com saídas recorrentes às entradas possibilitam a recuperação de respostas passadas a partir da realimentação de sinais produzidos em instantes anteriores.
- Pode-se dizer que a configuração recorrente possui memória, sendo capazes de “relembrar” saídas passadas a fim de produzir a resposta atual ou futura.
- Tais redes pertencem à classe de arquiteturas recorrentes ou realimentadas.

Redes Neurais Recorrentes: Topologia

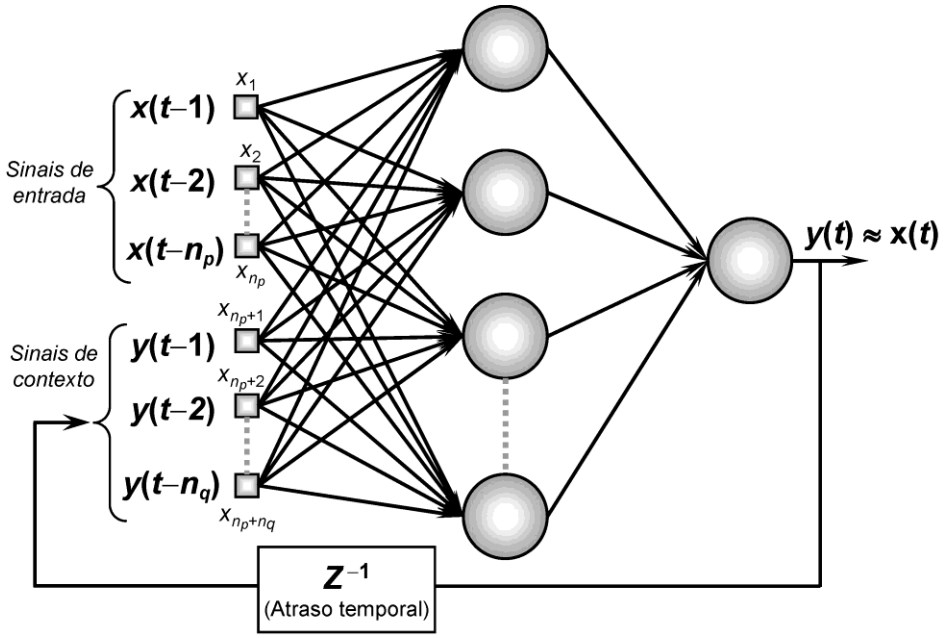


- A previsão de valores futuros a partir do instante t, associados ao comportamento do processo, é computada em função do conhecimento de seus valores temporariamente anteriores, assim como de valores anteriores produzidos por suas saídas:

$$x(t) = f\left(x(t-1), x(t-2), \ldots, x\left(t-n_p\right), y(t-1), y(t-2), \ldots, y\left(t-n_q\right)\right)$$

- onde n_p é a ordem do estimador, ou seja, a quantidade de medidas (amostras) passadas que serão necessárias para a estimação do valor $x(t)$.
- o valor n_q expressa a ordem de contexto, ou seja, a quantidade de saídas passadas que serão também utilizadas na estimação de x(t).

Redes Neurais Recorrentes: Topologia



- A rede recebe as n_p entradas:

$$\{x(t-1), x(t-2), \ldots, x(t-n_p)\}$$

e n_q saídas anteriores:

$$\{y(t-1), y(t-2), \ldots, y(t-n_q)\}$$

- A sua resposta prediz o valor esperado para $x(t)$, cujo resultado é explicitado pelo valor $y(t)$ fornecido pelo neurônio de saída.
- Assim, no treinamento, a rede tentará ajustar as suas matrizes de pesos visando minimizar o erro $E(t)$ produzido entre $x(t)$ e $y(t)$.

Redes Neurais Recorrentes: Aspectos de Treinamento



- O treinamento da rede PMC com configuração Recorrente é similar ao PMC convencional, e o processo de aprendizado é também efetuado de maneira idêntica.
- Os cuidados que devem ser tomados estão associados com a montagem do conjunto de treinamento da rede.

$$x(t) = [0{,}11 \quad 0{,}32 \quad 0{,}53 \quad 0{,}17 \quad 0{,}98 \quad 0{,}67 \quad 0{,}83 \quad 0{,}79]^T$$

$$x(t) = [x(1) \quad x(2) \quad x(3) \quad x(4) \quad x(5) \quad x(6) \quad x(7) \quad x(8)]^T$$

- Como exemplo, assume-se que o processo possa ser mapeado com ordem de predição igual a três $\{n_p = 3\}$ e ordem de contexto igual a dois $\{n_q = 2\}$

Redes Neurais Recorrentes: Aspectos de Treinamento

relação entradas/saídas

	x_1	x_2	x_3	x_4	x_5	saída desejada	saída da rede
$t = 4$	$x(3)$	$x(2)$	$x(1)$	0	0	$x(4)$	$y(4)$
$t = 5$	$x(4)$	$x(3)$	$x(2)$	$y(4)$	0	$x(5)$	$y(5)$
$t = 6$	$x(5)$	$x(4)$	$x(3)$	$y(5)$	$y(4)$	$x(6)$	$y(6)$
$t = 7$	$x(6)$	$x(5)$	$x(4)$	$y(6)$	$y(5)$	$x(7)$	$y(7)$
$t = 8$	$x(7)$	$x(6)$	$x(5)$	$y(7)$	$y(6)$	$x(8)$	$y(8)$

$4 \leq t \leq 8$

(ordem 3)

$n_p = 3$

$n_q = 2$

conjunto de treinamento

	x_1	x_2	x_3	x_4	x_5	d
$\boldsymbol{x}^{(1)}$	0,53	0,32	0,11	0	0	$d^{(1)} = 0,17$
$\boldsymbol{x}^{(2)}$	0,17	0,53	0,32	$y(4)$	0	$d^{(2)} = 0,98$
$\boldsymbol{x}^{(3)}$	0,98	0,17	0,53	$y(5)$	$y(4)$	$d^{(3)} = 0,67$
$\boldsymbol{x}^{(4)}$	0,67	0,98	0,17	$y(6)$	$y(5)$	$d^{(4)} = 0,83$
$\boldsymbol{x}^{(5)}$	0,83	0,67	0,98	$y(7)$	$y(6)$	$d^{(5)} = 0,79$

$$E(t) = x(t) - y(t), \text{ onde } (n_p + 1) \leq t \leq N$$

- Por intermédio da expressão acima, ter-se-á então um conjunto de treinamento composto por um total de 5 amostras, com parâmetro t variando de $4 \leq t \leq 8$. onde o valor $\{x_0 = -1\}$, associado ao limiar do neurônio, deverá ser considerado em todos eles.

Redes Neurais Recorrentes: Aspectos de Treinamento



- Considerando-se agora o seu domínio de operação, a rede já treinada pode ser usada para estimação de valores futuros.
- Para o exemplo anterior, considerando agora {t ≥ 9}, tal procedimento é realizado da seguinte maneira:

	x_1	x_2	x_3	x_4	x_5	saída estimada
$t = 9$	$x(8)$	$x(7)$	$x(6)$	$y(8)$	$y(7)$	$x(9) \approx y(9)$
$t = 10$	$x(9)$	$x(8)$	$x(7)$	$y(9)$	$y(8)$	$x(10) \approx y(10)$
$t = 11$	$x(10)$	$x(9)$	$x(8)$	$y(10)$	$y(9)$	$x(11) \approx y(11)$
(...)	(...)	(...)	(...)	(...)	(...)	(...)

Redes Neurais Recorrentes: Aspectos de Treinamento



- Assim, para o exemplo anterior, a predição de seus valores futuros sempre levará em conta tanto as 3 entradas atrasadas no tempo como as 2 últimas saídas produzidas pela rede.

- Contudo, há situações em que tanto a ordem de predição como a ordem de contexto $\{n_q\}$ deve ser incrementada a fim de assegurar maior precisão na estimação do comportamento futuro do processo.

- O número de sinais de entrada p/ a rede será a soma de n_p com n_q

Backpropagation: Aspectos de Treinamento



- Um dos problemas em aplicar o algoritmo backpropagation está justamente em se determinar o momento em que o mesmo já está generalizando de maneira satisfatória.
- Um procedimento eficaz a ser implementado na técnica crossvalidation é a parada antecipada ou prematura (early stopping).

Backpropagation: Aspectos de Treinamento



- Aqui, o processo de aprendizagem para uma topologia candidata é constantemente checado pela aplicação dos subconjuntos de teste, sendo finalizado quando começar haver elevação do erro quadrático (frente aos subconjuntos de teste) entre épocas sucessivas.

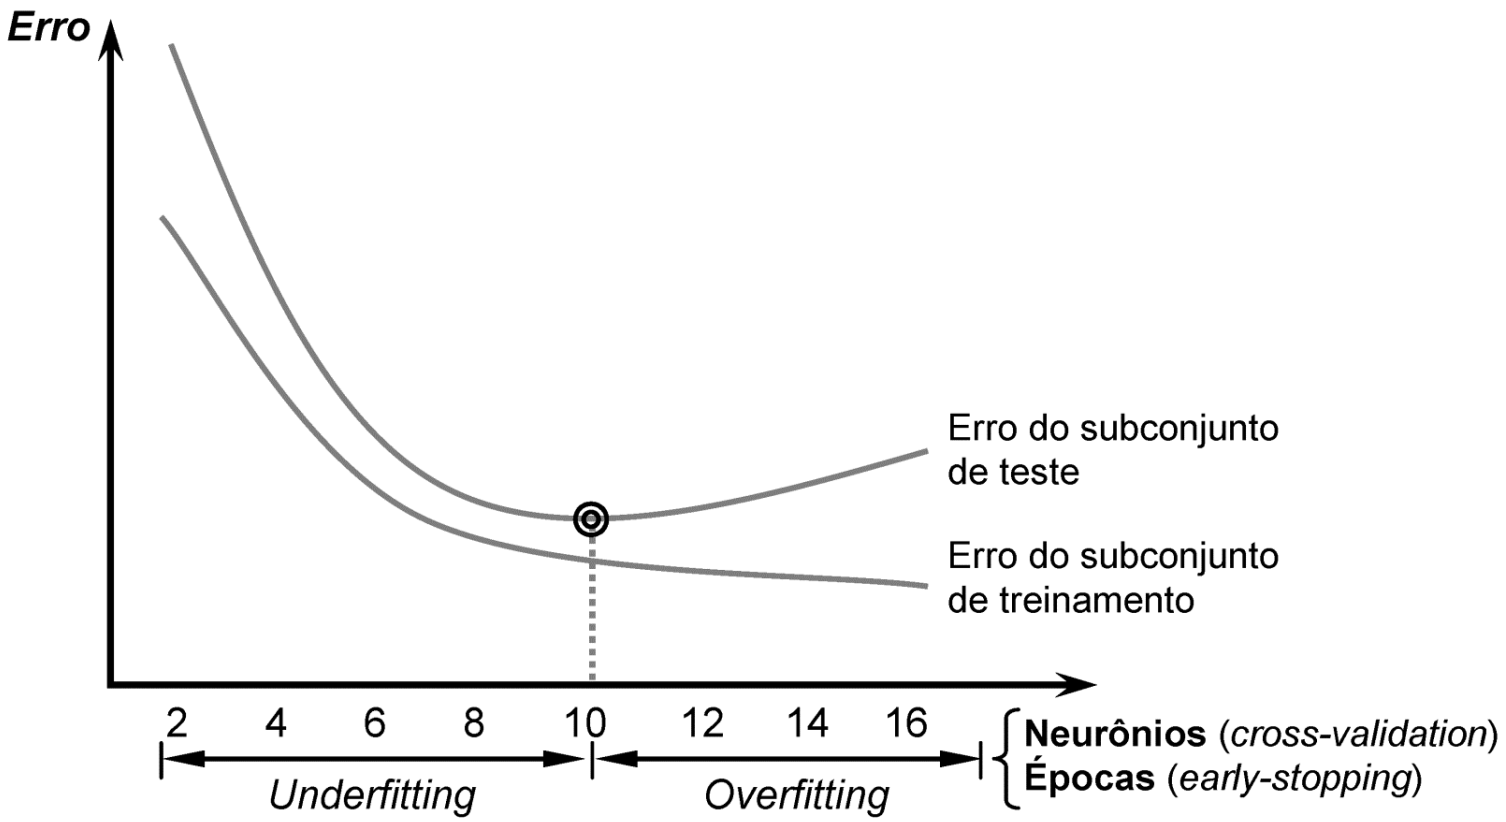
- De fato, esta variação repentina sinaliza a tentativa de extração excessiva de características dos subconjuntos de treinamento, como por exemplo, os ruídos de medição.

Backpropagation: Aspectos de Treinamento

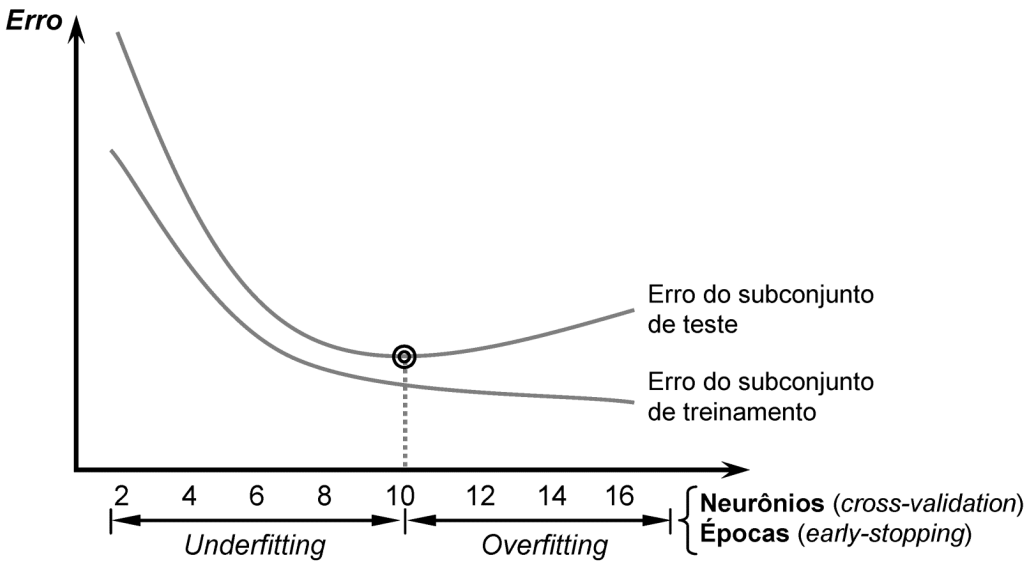


- Em suma, a seleção de uma topologia de RNA deve levar em conta o compromisso de superar o underfitting e de evitar o overfitting.
- Com exemplo, considerando um PMC com apenas uma camada escondida, ilustra-se na figura seguinte o processo early stopping, assim como as situações de underfitting e overfitting em função do número de neurônios de sua camada escondida.

Backpropagation: Aspectos de Treinamento



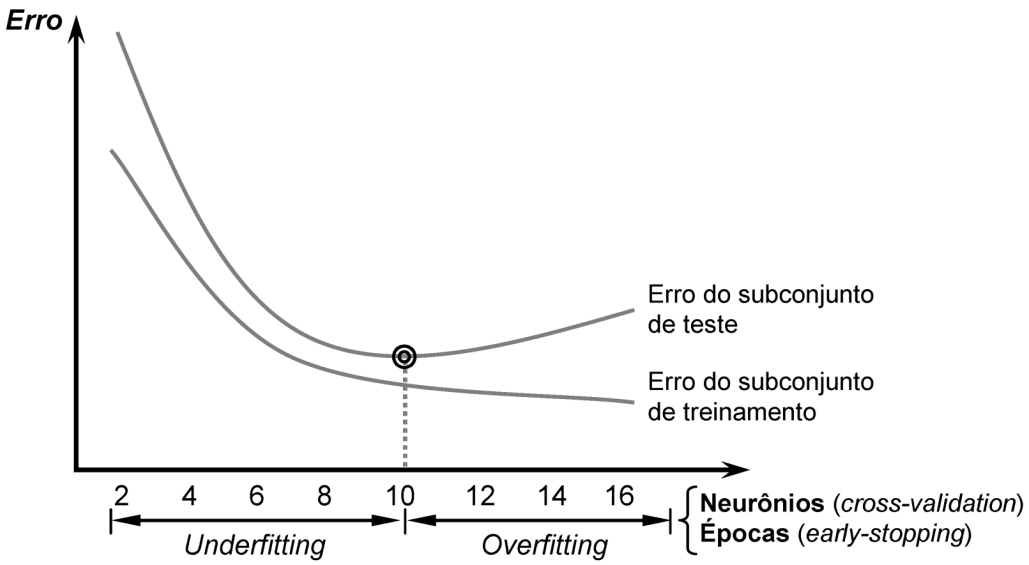
Backpropagation: Aspectos de Treinamento



- Tem-se aqui que uma RNA apropriada teria um total de 10 neurônios em sua camada escondida, pois um número menor acarretaria em erro grande nas amostras de testes em virtude da insuficiência de neurônios (underfitting).

- Em contraposição, para uma quantidade maior que 10, o PMC começaria também a produzir um erro considerável para as amostras dos subconjuntos de teste (overfitting).

Backpropagation: Aspectos de Treinamento



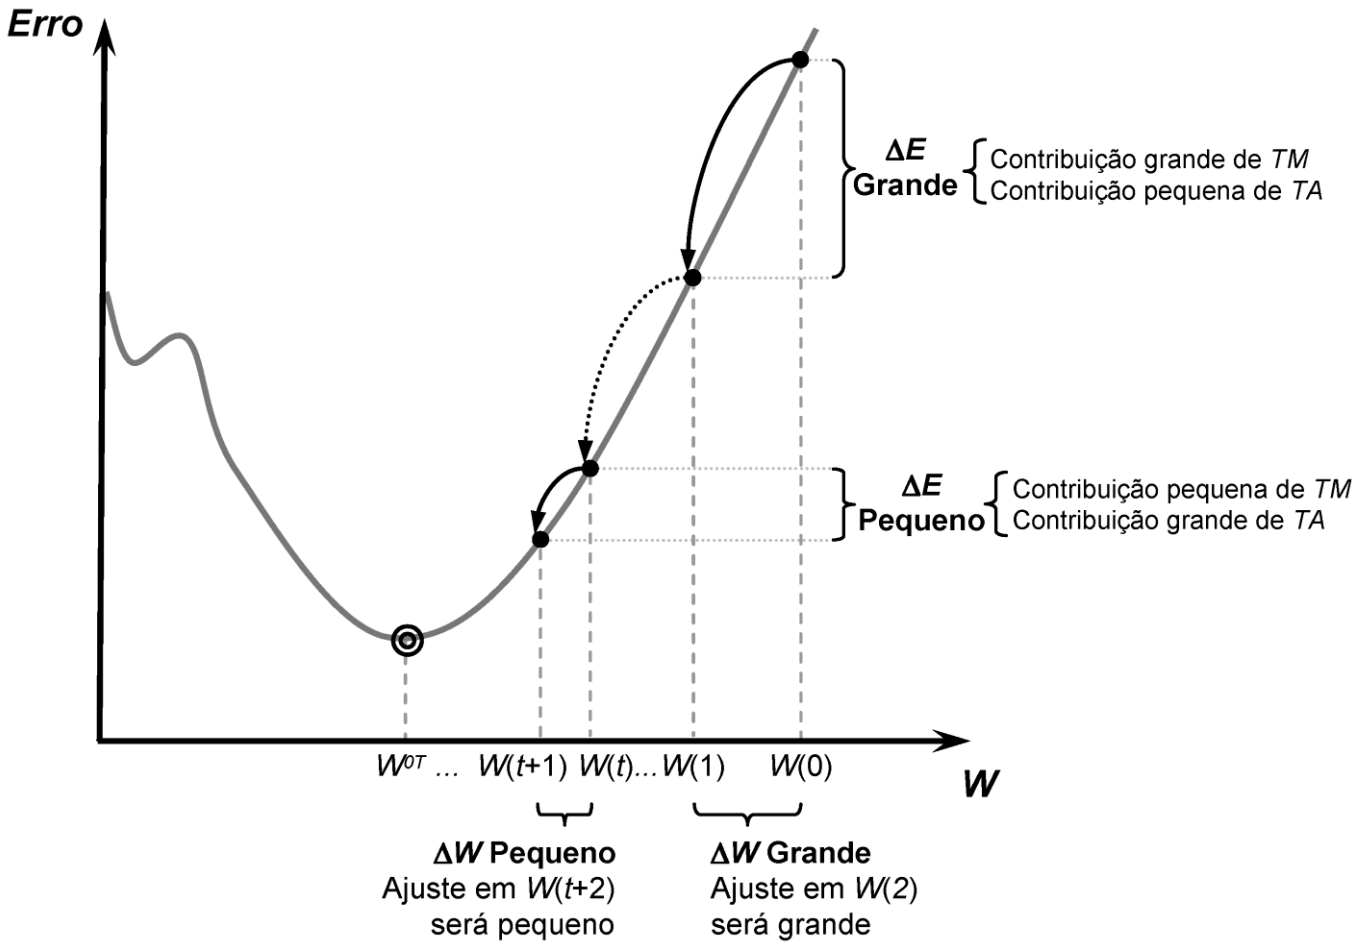
- A inserção do termo de momentum se configura como uma das variações mais interessantes de ser efetuada no algoritmo backpropagation, pois, basta-se inserir um único parâmetro visando ponderar o quão as matrizes sinápticas foram alteradas entre duas iterações anteriores e sucessivas.

- Formalmente, considerando os neurônios pertencentes à L-ésima camada, tem-se:

$$W_{ji}^{(L)}(t+1) = W_{ji}^{(L)}(t) + \alpha \cdot \left(W_{ji}^{(L)}(t) - W_{ji}^{(L)}(t-1) \right) + \eta \cdot \delta_j^{(L)} \cdot Y_i^{(L-1)}$$

Termo de momentum **Termo de aprendizagem**

Backpropagation: Aspectos de Treinamento



A figura ao lado ilustra a contribuição do termo de momentum (TM) e do termo de aprendizagem (TA) visando a convergência em direção ao mínimo WOT da função erro quadrático.

Referências



- RUSSELL, STUART J.. Inteligência Artificial. 2ª ed. São Paulo: Campus - Elsevier, 2004.
- FERNANDES, Anita M. R.. Inteligência Artificial: noções gerais. 1ª ed. Florianópolis: Visual Books, 2008. Capítulo 1.
- SILVA, I.N. – Sistemas Inteligentes – Notas de Aula da disciplina de Redes Neurais Artificiais – USP São Carlos, 2012.
- SILVA, I.N., SPATTI, D.H., FLAUZINO, R.A., Redes Neurais Artificiais para Engenharia e Ciências Aplicadas. 1ª ed. São Paulo: Editora Artiliber, 2010.
- NASCIMENTO JUNIOR, Cairo L., YONEYAMA, T. Inteligência Artificial em Controle e Automação. 1ª ed. São Paulo: Edgard Blücher, 2000.



Facens

AQUI TEM ENGENHARIA