UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Engenharia Química
Departamento de Engenharia de Sistemas Químicos

FLÁVIO MARCELO CORREIA

Métodos Estatísticos e Redes Neurais Aplicados a Modelos Preditivos em Digestor Contínuo de Celulose Kraft de Eucalipto

Campinas/SP
2016

FLÁVIO MARCELO CORREIA

Métodos Estatísticos e Redes Neurais Aplicados a Modelos Preditivos em Digestor Contínuo de Celulose Kraft de Eucalipto

Tese apresentada à Faculdade de Engenharia Química da Universidade Estadual de Campinas como parte dos requisitos exigidos para a obtenção do título de Doutor em Engenharia Química na Área de Engenharia Química

Orientador: Prof. Dr. José Vicente Hallak d'Angelo
Co-orientadora: Prof[a.] Dr[a.] Sueli Aparecida Mingoti

ESTE EXEMPLAR DIGITAL CORRESPONDE À VERSÃO FINAL DA TESE DEFENDIDA PELO ALUNO FLÁVIO MARCELO CORREIA E ORIENTADA PELO PROF. DR. JOSÉ VICENTE HALLAK D'ANGELO

CAMPINAS/SP
2016

Agência(s) de fomento e nº(s) de processo(s): Não se aplica.

Ficha catalográfica
Universidade Estadual de Campinas
Biblioteca da Área de Engenharia e Arquitetura
Luciana Pietrosanto Milla - CRB 8/8129

Correia, Flávio Marcelo, 1966-
C817m Métodos estatísticos e redes neurais aplicados a modelos preditivos em digestor contínuo de celulose kraft de eucalipto / Flávio Marcelo Correia. – Campinas, SP : [s.n.], 2016.

Orientador: José Vicente Hallak D'Angelo.
Coorientador: Sueli Aparecida Mingoti.
Tese (doutorado) – Universidade Estadual de Campinas, Faculdade de Engenharia Química.

1. Celulose. 2. Eucalipto. 3. Digestão. 4. Redes neurais (Computação). 5. Métodos estatísticos. I. D'Angelo, José Vicente Hallak,1967-. II. Mingoti, Sueli Aparecida,1956-. III. Universidade Estadual de Campinas. Faculdade de Engenharia Química. IV. Título.

Informações para Biblioteca Digital

Título em outro idioma: Statistical methods and neural networks applied to predictive models in a continuous digester of eucalyptus kraft pulp
Palavras-chave em inglês:
Cellulose
Eucalyptus
Digestion
Neural netowrks
Statistical methods
Área de concentração: Sistemas de Processos Químicos e Informática
Titulação: Doutor em Engenharia Química
Banca examinadora:
José Vicente Hallak D'Angelo [Orientador]
Ana Maria Frattini Fileti
Ademir José Petenate
Jorge Luiz Colodette
Francides Gomes da Silva Júnior
Data de defesa: 30-06-2016
Programa de Pós-Graduação: Engenharia Química

Tese de Doutorado defendida por Flávio Marcelo Correia e aprovada em 30 de junho de 2016 pela banca examinadora constituida pelos professores doutores:

Prof. Dr. José Vicente Hallak d'Angelo - Orientador
FEQ/UNICAMP

Prof. Dr. Jorge Luiz Colodette
UFV

Prof. Dr. Francides Gomes da Silva Júnior
ESALQ/USP

Prof. Dr. Ademir José Petenate
IMECC/UNICAMP

Profª Drª Ana Maria Frattini Fileti
FEQ/UNICAMP

A Ata da Defesa, assinada pelos membros da Comissão Examinadora, consta no processo de vida acadêmica do aluno.

Minha Mãe Querida,

Saudades Eternas...

ad Deum qui lætificat juventutem meam !

AGRADECIMENTOS

Que saibam estas linhas expressar minha gratidão às generosas pessoas que contribuíram no desenvolvimento deste trabalho. Na impossibilidade de mencionar a miríade dos envolvidos, ouso destacar:

O Prof. *Fernando Carazza* (*in memorian*) do DQ ICEx UFMG, que me propiciou despertar a pesquisa acadêmica, com a IC em carboquímica vegetal e síntese orgânica.

A Profª. *Ela Mercedes Teodoro* do DE ICEx UFMG, pela oportunidade concedida na disciplina de Séries Temporais no Curso de Pós Graduação em Estatística.

A Profª. *Lorena Guadalupe Barberia* da FFCL USP, pela arte de ensinar na disciplina Análise de Regressão.

O Prof. *Gustavo Matheus de Almeida* do Depto. de Engenharia Química UFMG, pelo apoio no desenvolvimento das redes neurais.

Os Professores da FEQ UNICAMP, pelas considerações e contribuições na etapa de qualificação *Ana Maria Fratini Fileti*, *Roger Josef Zemp* e *Flávio Vasconcelos Silva* (também pela paciência na disciplina Inteligência Artificial).

O Prof. *José Lívio Gomide* (*in memorian*) do LCP UFV, por ter compartilhado sua amizade e sabedoria ímpar da deslignificação Kraft.

A CENIBRA, na pessoa de seu Diretor Industrial *Robinson Félix* pelo incentivo.

Os Profs. da Banca *Ademir José Petenate, Ana Maria Fratini Fileti, Francides Gomes Silva Jr* e *Jorge Luis Colodette* pelas discussões, críticas e sugestões neste trabalho.

A co-orientadora *Sueli Aparecida Mingoti* do Depto. de Estatística UFMG, por sua mão estendida no esclarecimento de dúvidas, me permitindo trafegar no desenvolvimento das equações de uma forma mais segura e esclarecida.

O amigo, confidente e também orientador *José Vicente Hallak d'Angelo*. O meu reconhecimento da sua contribuição em todas as etapas desta tese, bem como às alegrias e tristezas divididas em décadas de nosso convívio.

Meus pais *José Cirilo Correia* e *Carmelita Correia,* pelo valor ao labor, à disciplina, à família e às belezas da vida dentre as muitas coisas que aprendi.

A minha esposa *Cláudia* e meus filhos *Vítor* e *Mariana*, pela valorosa compreensão dos momentos de ausência. Vocês são a razão do meu viver!

Aos acima nomeados e a todos que apoiaram em maior ou menor grau na elaboração desta tese, registro os meus sinceros agradecimentos.

RESUMO

Nas indústrias de celulose, o cozimento em digestor contínuo é um exemplo de processo complexo com longo tempo de retenção, envolvendo reações químicas e fenômenos de transferência de momento, energia e massa. Uma dificuldade adicional é o tempo necessário para execução de algumas análises *off line*, que resultam em ajustes tardios sobre as variáveis de controle. A fim de minimizar este impacto, apresentam-se neste trabalho duas abordagens para predições, usando dados industriais de um digestor contínuo de uma fábrica de celulose branqueada de eucalipto no Brasil. A primeira abordagem é desenvolvida com foco na matéria-prima, visando reduzir o erro da aplicação da densidade aparente de cavaco usada para calcular o fluxo mássico de licor branco de cozimento. Foram usados métodos univariados de predições como Média Móvel Simples (MMS), Alisamento Exponencial Simples (AES) e o método Box-Jenkins de séries temporais (ARIMA) em modelos dinâmicos para predição. Com um banco de dados de um período de aproximadamente 12 meses, após ajuste dos parâmetros, os modelos foram validados usando um novo conjunto de dados, levando a seleção do modelo ARIMA, que apresentou redução do erro percentual absoluto em torno de 25%. A segunda abordagem foi desenvolvida com foco no produto reagido, usando uma base de dados de aproximadamente um mês de operação do digestor. Foram aplicados os métodos AES, Regressão Linear Múltipla (RLM), ARIMA e Redes Neurais Artificiais (RNA) para predições do número kappa. Após ajuste dos parâmetros, os modelos foram validados usando um novo conjunto de dados em um período equivalente. A análise dos resíduos e índices estatísticos de previsão mostra que os quatro modelos testados apresentam bons resultados, sendo ARIMA o melhor deles, que apresentou ordem de 3% de erro absoluto percentual. Aplicações de modelos preditivos como estes, possibilitam tomar ações operacionais em avanço às análises, diminuindo desvios dos objetivos de processo. Estas metodologias podem ser replicadas em outros reatores contínuos que apresentam características semelhantes.

Palavras Chave: *Cozimento Kraft, Digestor Contínuo, Predições, Séries Temporais, Redes Neurais Artificiais.*

ABSTRACT

Complex processes with long retention time present significant delay between the input and output operations. In pulp mills, continuous cooking digester is a typical example of the process with this feature, involving chemical reactions and momentum, mass and energy transfer phenomena. In addition, another difficulty is the time needed to perform some off line analyses. Both problems result in late adjustments to the control variables. In order to minimize this impact, two approaches to perform variables predictions are presented in this work, using industrial data from a continuous digester of eucalyptus operating in a bleached pulp mill in Brazil. The first approach is developed with a focus on the raw material, to reduce the application error of the chip bulk density used to calculate white liquor mass flow. An approach using univariate methods like Simple Moving Average, Simple Exponential Smoothing and the Box-Jenkins time series (ARIMA) was proposed to develop dynamic models to predict chip bulk density on line. With a database for a period of 12 months after the adjustment of the parameter models, the models were validated using a new dataset, leading to selection of the ARIMA model which showed reduction in the absolute percentage error of around 25%. The second approach was developed with focus on reacted product, using a database for approximately one month digester operation. Single Exponential Smoothing, Multiple Linear Regression (MLR), Box-Jenkins methodology (ARIMA) and Artificial Neural Networks (ANN) were used for kappa number predictions. After parameters models adjustment, the models were validated using a new data set for the equivalent period. The analysis of residuals and statistical forecasting index indicate that the four models tested show good results, the best being the ARIMA model which presented around 3% of absolute percentage error. The application of predictive models like these enables one to take operational actions in advancing of the analysis, reducing deviations of process goals. These methods can be replicated in other continuous reactors that have similar characteristics.

Keywords: *Kraft Pulping, Continuous Digester, Predictions, Time Series, Artificial Neural Network.*

LISTA DE ILUSTRAÇÕES

Figura 3.1 - Representação do polímero da celulose 35

Figura 3.2 - Formação da fibra de celulose..... 36

Figura 3.3 - Modelo da estrutura química da lignina de eucaliptos 37

Figura 3.4 - Etapas do processo Kraft de uma planta de celulose de mercado 40

Figura 3.5 - Formação do ácido hexenurônico..... 44

Figura 3.6 - Unidades básicas estruturais da lignina 45

Figura 3.7 - Modelo de reações da lignina com licor Kraft 46

Figura 3.8 - Digestor contínuo Kamyr típico..... 47

Figura 4.1 - Ilustração Série Estacionária..... 52

Figura 4.2 - Ilustração Série Não Estacionária..... 53

Figura 4.3 - Distribuição dos termos de erros em regressão linear simples..... 57

Figura 4.4 - Fluxograma do ciclo iterativo de Box – Jenkins..... 64

Figura 4.5 - Informação de transferência da RNA *Feedforward*..... 65

Figura 4.6 - Modelo de um neurônio artificial..... 66

Figura 5.1 - Micro estruturas de madeira fibra curta..... 74

Figura 5.2 - Aparato para determinação da densidade a granel de cavacos..... 77

Figura 5.3 - Evolução serial densidade cavacos [DENS1]..... 79

Figura 5.4 - Histograma densidade cavacos [DENS1]..... 79

Figura 5.5 - Gráfico (a) comp. de média m x MAD x RMSE [DENS1]
(b) comp. de média m x MAD x MAPE [DENS1]..... 81

Figura 5.6 - Evolução comp. de média m x (MAD x MAPE x RMSE) [DENS1]..... 81

Figura 5.7 - Gráfico (a) comp. de média m x MAD x RMSE [DENS2]
(b) comp. de média m x MAD x MAPE [DENS2]..... 82

Figura 5.8 - Gráfico (comprimento de média m) x (MAD x RMSE) [DENS2]..... 82

Figura 5.9 - Evolução dos valores observados e preditos modelo MMS [DENS2]..... 83

Figura 5.10 - Evolução dos resíduos modelo MMS [DENS2]..... 84

Figura 5.11 - Histograma dos resíduos modelo MMS [DENS2]..... 84

Figura 5.12 - (a): índice de ponderação α x MAD x RMSE [DENS1]
(b): índice de ponderação α x RMSE x MAPE [DENS1]..... 85

Figura 5.13 - Gráfico α x (MAD x MAPE x RMSE) [DENS1]..... 86

Figura 5.14 - (a): índice de ponderação α x MAD x RMSE [DENS2]
(b): índice de ponderação α x RMSE x MAPE [DENS2]..... 86

Figura 5.15 - Gráfico α x (MAD x MAPE x RMSE) [DENS2]..... 87

Figura 5.16 - Evolução valores observados e preditos modelo AES [DENS2]..... 88

Figura 5.17 - Evolução dos resíduos modelo AES [DENS2]..... 89

Figura 5.18 - Histograma dos resíduos modelo AES [DENS2]..... 89

Figura 5.19 - Correlograma Densidade Cavacos [DENS1]..... 91

Figura 5.20 - Evolução de previsão do modelo ARMA (2,2) [DENS1]..... 92

Figura 5.21 - Curvas reais e teóricas das FAC e FACP do Modelo ARMA (2,2) [DENS1]..... 94

Figura 5.22 - Evolução Resíduos do Modelo ARMA (2,2) [DENS1]..... 95

Figura 5.23 - Correlograma dos Resíduos Modelo ARMA (2,2)..... 96

Figura 5.24 - Histograma dos Resíduos Modelo ARMA (2,2)..... 96

Figura 5.25 - Evolução dos valores observados e preditos modelo ARMA [DENS2]. 97

Figura 5.26 - Evolução dos resíduos do modelo ARMA [DENS2]..... 98

Figura 5.27 - Histograma dos resíduos modelo AES [DENS2]..... 99

Figura 5.28 - Posição do instrumento de análise do álcali da circulação superior..... 100

Figura 5.29 - CV antes e após a implantação do modelo ARMA..... 101

Figura 6.1 - Tempo de retenção das principais zonas do digestor contínuo..... 108

Figura 6.2 - Evolução cronológica número kappa [KAPPA1]..... 109

Figura 6.3 - Histograma número kappa [KAPPA1]..... 109

Figura 6.4 - Gráfico de Superfície: (a) Gráfico α x MAD x MAPE [KAPPA1]
(b) Gráfico α x MAPE x RMSE [KAPPA1].... 110

Figura 6.5 - Gráfico α x (MAD x MAPE x RMSE) [KAPPA1]..... 110

Figura 6.6 - Histograma dos resíduos modelo AES [KAPPA2]..... 111

Figura 6.7 - Correlação entre variáveis e número kappa..... 114

Figura 6.8 - Correlograma do número kappa..... 114

Figura 6.9 - Evolução predição do número kappa Modelo RLM [KAPPA1]..... 116

Figura 6.10 - Evolução dos resíduos modelo RLM [KAPPA1]..... 117

Figura 6.11 - Histograma dos resíduos RLM [KAPPA1]..... 118

Figura 6.12 - Histograma dos Resíduos Modelo RLM [KAPPA2] 119

Figura 6.13 - Ilustração evolução número de épocas x MSE..... 120

Figura 6.14 - Evolução número de neurônios x Coef. de Correlação de Pearson [KAPPA1]..... 122

Figura 6.15 - Evolução número de neurônios x RMSE [KAPPA1]..... 123

Figura 6.16 - Evolução número de neurônios x Coeficiente *a* [KAPPA1]..... 123

Figura 6.17 - Evolução número de neurônios x Intercepto *b* [KAPPA1]..... 124

Figura 6.18 - Ilustração do treinamento com 3 neurônios na camada oculta..... 125

Figura 6.19 - Arquitetura final da RNA..... 125

Figura 6.20 - Histograma dos Resíduos do Modelo RNA [KAPPA2]..... 126

Figura 6.21 - Evolução valores observados e modelados Mod. ARMA (1,2) [KAPPA1]..... 129

Figura 6.22 - Curvas reais e teóricas das FAC e FACP do Modelo ARMA (1,2) [KAPPA1]..... 130

Figura 6.23 - Correlograma Ruído branco das FAC e FACP Modelo ARMA (1,2) [KAPPA1]..... 131

Figura 6.24 - Histograma dos Resíduos Modelo ARMA (1,2) [KAPPA1]..... 131

Figura 6.25 - Histograma dos Resíduos Modelo ARMA (1,2) [KAPPA2]..... 132

Figura 6.26 - Dispersão entre os modelos analisados ‘modelados x observados’ [KAPPA2]..... 133

LISTA DE TABELAS

Tabela 3.1- Composição típica de folhosas e coníferas de uso industrial..... 38

Tabela 4.1 - Condições de estacionariedade / invertibilidade..... 61

Tabela 4.2 - Equivalência de terminologia RNA e estatística..... 70

Tabela 5.1 - Resultados dos índices estatísticos dos modelos ARMA [DENS1]..... 91

Tabela 5.2 - Coeficientes do Modelo ARMA (2,2) [DENS1]..... 92

Tabela 5.3 - Índices estatísticos modelo ARMA (2,2) [DENS1]..... 93

Tabela 5.4 - Índices Estatísticos de Validação dos Modelos ARMA [DENS2]..... 98

Tabela 5.5 - Índices dos Erros de Previsão dos Modelos [DENS1]..... 101

Tabela 5.6 - Índices dos Erros de Previsão dos Modelos [DENS2]..... 101

Tabela 6.1 - Índices de desempenho de previsão para o modelo AES [KAPPA2]..... 112

Tabela 6.2 - Variáveis de Cozimento Selecionadas na Análise Inicial RLM..... 113

Tabela 6.3 - Coeficientes do modelo RLM para estimativa do número kappa..... 115

Tabela 6.4 - Desempenho do Modelo RLM [KAPPA1]..... 117

Tabela 6.5 - Estatística descritiva dos resíduos RLM [KAPPA1]..... 118

Tabela 6.6 - Índices de desempenho de previsão para o modelo RLM [KAPPA2].... 119

Tabela 6.7 - Índices de desempenho de previsão para o modelo RNA [KAPPA2].... 126

Tabela 6.8 - Índices estatísticos modelos ARMA [KAPPA1]..... 127

Tabela 6.9 - Coeficiente de Desigualdade Theil Modelo ARMA (1,2) [KAPPA1].... 128

Tabela 6.10 - Parâmetros estimados para o modelo ARMA (1,2)..... 128

Tabela 6.11 - Índices de desempenho Modelos ARMA [KAPPA2]..... 133

Tabela 6.12 - Resumo dos índices dos modelos avaliados [KAPPA2]..... 134

NOMENCLATURA

a	coeficiente angular da reta de associação entre os valores estimados pelo modelo e o valor real modelo RNA
b	coeficiente linear da reta (intercepto) da reta de associação entre os valores estimados pelo modelo e o valor real modelo RNA
e_t	erro estimado ($Y_t - \hat{Y}_t$).
k	período de translação (intervalo)
j	componente de indexação
m	comprimento da média nos modelos MMS
Ne	número de neurônios de entrada
No	número de neurônios na camada oculta
N_{TR}	número de dados para treinamento de uma RNA
p	ordem do processo de um modelo AR
q	ordem do processo de um modelo MA
$r\ (k)$	autocorelação amostral
T	série temporal (T = $\mathbb{R}$)
$x_1, x_2 \ldots x_q$	variáveis regressoras
Y_t	valor da série temporal no tempo t
$\hat{Y}_t$	valor estimado no tempo t;
α	coeficiente de ponderação nos modelos AES
$\beta_0, \beta_1 \ldots \beta_q$	parâmetros da regressão
δ	constante a ser estimada dos modelos ARMA
ε_t	componente do erro aleatório
μ	media do processo
σ^2	variância do processo
$\phi_1, \ldots, \phi_p$	parâmetros estimados do modelo AR
$\theta_1, \ldots, \theta_q$	parâmetros estimados do modelo MA

AES	Alisamento Exponencial Simples
AIC	*Akaike Information Criterion* Critério de Informação de Akaike
AR (p)	*Autoregressive* Modelo Autorregressivo de ordem *p*
ARIMA	*Autoregressive Integrated Moving Average* Modelo Autorregressivo Integrado de Médias Móveis
ARMA	*Autoregressive Moving Average Model* Modelo de Médias Móveis Auto-regressivo
BKP	*Bleached Kraft Pulp* Polpa Kraft Branqueada
BP	*Bias Proportion* Proporção do Viés
BSC	*Bayesian Schwarz Criterion* Critério Bayesiano de Schwarz
BV	*Variance Proportion* Proporção da Variância
CV	*Covariance Proportion* Proporção da Covariância
DENS	Densidade (kg/m^3)
DW	Índice Durbin Watson
FAC	Função de Autocorrelação
FACP	Função de Autocorrelação Parcial
MA (q)	*Moving Average* Modelo Média Móvel de ordem q
MAD	*Mean Absolute Deviation* Desvio Absoluto Médio
MAPE	*Mean Absolute Percentual Error* Erro Absoluto Percentual Médio
MLP	*Multi Layer Perceptron* Multicamadas Perceptrons

MMS	Média Móvel Simples
MQO	Mínimos Quadrados Ordinários
PLS	*Partial Least Square* Mínimos Quadrados Parciais
RLM	Regressão Linear Múltipla
RMSE	*Rooted Mean Squared Error* Raiz do Erro quadrado médio
RNA	Redes Neurais Artificiais
SVM	*Suport Vector Machine* Máquinas de Vetores de Suporte
TAPPI	Technical Association of Pulp and Paper Industries Associação Técnica das Indústria de Celulose e Papel (EUA)
TIC	*Theil Inequality Coeficient* Coeficiente de Desigualdade de Theil
tSA	tonelada Seca ao Ar
UKP	*Unbleached Kraft Pulp* Polpa Kraft Não Branqueada

SUMÁRIO

1. INTRODUÇÃO..... 18
1.1. Motivação..... 20
1.2. Objetivos..... 21
1.3. Organização..... 22

2. REVISÃO DA LITERATURA..... 24
2.1. Modelos em Polpação Kraft..... 26
2.2. Conclusões..... 32

3. A DESLIGNIFICAÇÃO KRAFT..... 33
3.1. A Madeira..... 34
3.2. O Processo Kraft..... 38
3.3. O Digestor Contínuo..... 46

4. MÉTODOS ESTATÍSTICOS E REDES NEURAIS ARTIFICIAIS..... 48
4.1. Séries Temporais..... 49
4.2. Método Média Móvel Simples..... 53
4.3. Método Alisamento Exponencial Simples..... 54
4.4. Regressão Linear Múltipla..... 55
4.5. Método Box-Jenkins de Séries Temporais..... 58
4.6. Redes Neurais Artificiais..... 64
4.7. Relações entre Redes Neurais Artificiais e Métodos Estatísticos..... 69
4.8. Análise e Validação dos Modelos..... 70

5. PREDIÇÃO DA DENSIDADE DO CAVACO AO DIGESTOR..... 72
5.1. Introdução..... 73
5.2. Materiais e Métodos..... 76
5.3. Resultados e Discussão..... 78
5.4. Conclusões..... 102

6. PREDIÇÃO DO NÚMERO KAPPA..... 104
6.1 Introdução..... 105
6.2. Materiais e Métodos..... 107
6.3. Resultados e Discussão..... 108
6.4. Conclusões..... 135

7. CONSIDERAÇÕES FINAIS..... 137
7.1 Conclusões..... 138
7.2 Sugestões para Pesquisas Futuros..... 140
7.3 Contribuições Associadas à Tese..... 141

REFERÊNCIAS BIBLIOGRÁFICAS..... 143

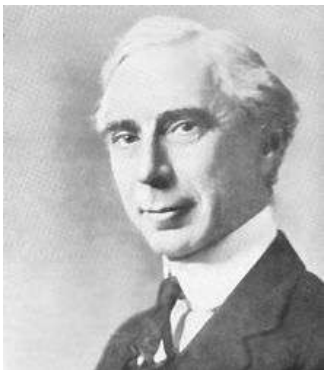
APÊNDICES..... 154
Apêndice 1 Complementos dos Modelos de Predição da Densidade de Cavaco..... 155
Apêndice 2 Complementos dos Modelos de Predição do Número Kappa..... 161

ANEXOS..... 169
Anexo 1 Patentes do Processo Kraft..... 170
Anexo 2 Terminologia do Processo Kraft..... 173
Anexo 3 Alguns Conceitos Estatísticos 177
Anexo 4 Publicações Associadas à Tese..... 183

Capítulo 1

Introdução

"When one admits that nothing is certain, one must, I think, also add that some things are more nearly certain than others."



Bertrand Arthur William Russell (1872 – 1970)
Matemático e Filósofo Britânico

Capítulo 1

Introdução

A celulose (*Anexo 2.6*) enquanto composto químico, é o polímero mais abundante na terra, presente em todos os vegetais. Industrialmente, a produção de polpa celulose possui relevância significativa na economia nacional, com fábricas de porte cada vez maior sendo construídas, tornando o Brasil referência mundial em instalações modernas.

Afora as adversidades enfrentadas nas diferentes dimensões da economia nacional, devido às suas condições edafoclimáticas, o Brasil é um país privilegiado no que se refere à produção de florestas plantadas. Em particular ao cultivo do eucalipto, que originário da Austrália tão bem se adaptou em nosso país, esta árvore necessita em torno de 6 a 7 anos para atingir a maturidade econômica. Inversamente, nas regiões de clima frio predominam espécies de crescimento lento, com ciclos de maturação superiores a 35 anos. Parafraseando Gonçalves Dias na *Canção do Exílio*[1], pode-se dizer que *as árvores que aqui crescem não crescem como lá*. No Brasil, a abundância de luz, calor, períodos de chuva distribuídos ao longo do ano, são fatores que propiciam o bom crescimento das plantas de crescimento rápido. Entretanto, as benesses naturais não são suficientes para alta produtividade. Nosso país possui forte tecnologia aplicada na floresta e indústria, permitindo atingir competitividade e qualidade em classe mundial no processamento da madeira para produção de polpa de celulose.

As vantagens competitivas são dinâmicas e exigem constante aprimoramento. A pequena presença de madeiras de fibra curta nos países nórdicos conduz ao inevitável direcionamento das pesquisas científicas destes países para as madeiras de fibra longa. Nações tradicionais na produção papeleira como Estados Unidos, Canadá, Suécia e Finlândia, direcionam suas investigações nas propriedades e processamento de madeiras coníferas, sendo que estas apresentam características diferentes das madeiras folhosas (PASCOAL *et al.* 2005). Outrossim, com a gradativa mudança do consumo de fibras longas para fibras curtas, tem ocorrido um incremento da produção desta segunda nos últimos anos.

---

[1] *Canção do Exílio in PRIMEIROS CANTOS, Gonçalves Dias, Coimbra, 1843.*

Neste sentido, o setor brasileiro de árvores plantadas de madeiras de fibra curta, está em equilíbrio para atendimento à demanda global por fibras, energia e bioprodutos. A adoção de tecnologias inovadoras e processos adequados são fundamentais para obtenção de resultados que possam manter uma evolução sustentável no Brasil, cabendo-nos a liderança nas investigações do processamento de fibras curtas visando melhorar o competitivo desempenho do setor.

1.1. Motivação

Nas modernas indústrias químicas, grandes quantidades de dados sobre as variáveis de processo estão disponíveis, os quais podem ser analisados para identificar e evitar as falhas ou propor melhorias do processo. Várias são as técnicas para análise de conjuntos de dados complexos com um grande número de variáveis medidas. Métodos estatísticos e redes neurais artificiais são algumas delas. O uso destas técnicas permite obter informações para melhor entendimento dos processos e subsidiam tomadas de decisão mais rápidas frente aos distúrbios naturais existentes. As situações anormais dos processos químicos ocorrem quando o sistema de controle não consegue manter os distúrbios naturais dentro de uma faixa de variabilidade aceitável (CHIANG *et al.* 2001). As causas dos distúrbios podem ser os fatores humanos, a matéria prima, os processos ou os equipamentos. A deficiência do controle pode impactar em danos materiais aos equipamentos, perdas de produção, qualidade do produto não suficiente, riscos de segurança, bem como alterações nas emissões ambientais.

O digestor é um dos equipamentos mais críticos de uma fábrica que usa o processo Kraft. As unidades industriais de grande porte contemplam o digestor contínuo na linha de produção, sendo o digestor em batelada (*batch*) presente em menor quantidade (PIKA e ANDRADE, 2015).

Ações no processo de cozimento podem levar a melhorias significativas do desempenho operacional, com impactos relevantes nos custos do processo fabril. Em um digestor contínuo, as características da madeira têm influência relevante nas reações de deslignificação. Entretanto, pelas dificuldades de medições, a única variável que é mensurada antes do cozimento é a densidade aparente (*Anexo 2.7*) do cavaco. Este item influencia na determinação do fluxo mássico de reagentes químicos aplicados ao cozimento, conforme a carga alcalina (*Anexo 2.5*) fixada. O cavaco para verificação da

densidade é normalmente amostrado na alimentação do digestor. A análise é realizada em laboratório por aparato específico, cujo tempo demanda aproximadamente 4 horas para execução dos procedimentos e compilação dos resultados. Isto é, após o resultado da análise estar disponível ao operador do digestor, o cavaco analisado já foi processado.

Quanto à qualidade da polpa resultante do cozimento, é normalmente determinada através da medição do número kappa, que é uma referência do teor de lignina (*Anexo 2.14)* residual. O número kappa é o índice mais importante para o controle e acompanhamento do cozimento e é determinante para as etapas subsequentes do processo, tendo impactos significativos para a produção, custos, meio ambiente e qualidade da celulose. Sua análise é realizada com amostras coletadas na descarga do digestor, sendo que as principais variáveis manipuladas no processo estão localizadas no topo do mesmo, como nível, temperatura e carga alcalina. Desta forma, existe uma defasagem do tempo de retenção do digestor (usualmente superior a quatro horas) para a variável de controle em relação à variável manipulada.

Modelos têm sido aplicados ao processo Kraft em diferentes níveis de complexidade. A cinética de reações químicas, a influência das características da madeira, impactos da temperatura, químicos do licor de cozimento, dentre outras variáveis, possuem vastas informações na literatura em relação aos processos de cozimento. Não obstante, em menor número são as referências que contemplam informações de fibra curta com dados industriais, que expressam seus resultados por índices estatísticos formais.

Neste intuito de melhoria tecnológica, o presente trabalho pretende contribuir com modelos preditivos de densidade de cavaco e do número kappa em um digestor contínuo de celulose Kraft de fibra curta, com possíveis aplicações em outros processos contínuos da indústria química.

1.2. Objetivos

1.2.1. Geral

O objetivo geral desta Tese de Doutorado é avaliar o uso de modelos preditivos usando métodos estatísticos e redes neurais artificiais em um digestor contínuo de celulose Kraft de eucalipto, para potencializar o desempenho produtivo de uma unidade industrial de cozimento de celulose.

1.2.2. Específicos

Para alcançar o objetivo geral proposto, foram traçados os seguintes objetivos específicos:

- Elaborar modelos de predição da densidade do cavaco alimentado ao digestor, visando reduzir o erro da aplicação desta variável usada no cálculo do fluxo de licor de cozimento ao digestor.

- Ajustar parâmetros de modelos de predição do número kappa, permitindo ações preventivas de controle do processo, em avanço aos seus resultados.

- Comparar os modelos utilizados para predição da densidade do cavaco e predição do número kappa, avaliando seu potencial de representação de dados industriais reais, visando identificar os que apresentaram melhores resultados e de mais fácil aplicabilidade em um digestor industrial.

1.3. Organização

O corpo desta tese está organizado em 07 Capítulos e Referências, além do Apêndice e Anexos. Inicia-se com as motivações da seleção do tema, a relevância da indústria de celulose no Brasil e da importância do digestor contínuo numa unidade fabril.

No Capítulo 2 são referenciados as pesquisas reportadas na literatura que abordam o tema de modelagem e predições em digestores por diferentes métodos e seus resultados.

Os fundamentos teóricos aplicados são apresentados nos Capítulos 3 e 4. O Capítulo 3 introduz os conceitos do processo Kraft, abordando a importância da densidade do cavaco e do número kappa para o processo do cozimento contínuo. No Capítulo 4, são descritos os métodos que foram aplicados como Média Móvel Simples (MMS), Alisamento Exponencial Simples (AES), Regressão Linear Múltipla (RLM), Box-Jenkins (ARMA) e Redes Neurais Artificiais (RNA), além de reportar algumas comparações entre os métodos estatísticos e redes neurais.

O Capítulo 5 apresenta os resultados de predição da densidade de cavacos aplicados ao controle do fluxo de licor branco (*Anexo 2.10*) ao digestor com os métodos MMS, AES e ARMA.

No Capítulo 6, são descritos os resultados da predição do número kappa em digestor contínuo com os métodos AES, RLM, ARMA e RNA e seus comparativos.

Concluindo os capítulos, são apresentadas no Capítulo 7 as considerações finais com conclusões, sugestões para investigações futuras, e as contribuições desta tese.

Em seguida são apresentadas as Referências Bibliográficas consultadas, Apêndices e Anexos. No *Apêndice 1* são indicados os complementos dos modelos para predição de densidade de cavaco, e no *Apêndice 2* complementos dos modelos estudados para predição do número kappa.

No A*nexo 1*, em um contexto histórico, são apresentadas as primeiras patentes do processo Kraft. Para possibilitar ao leitor menos familiarizado na diversidade dos tópicos aqui listados, são reportados no *Anexo 2* os principais conceitos do jargão técnico da indústria de celulose Kraft e no *Anexo 3* o detalhamento de alguns conceitos estatísticos aplicados no desenvolvimento desta tese. Finalizando, o Anexo 4 apresenta as publicações frutos do desenvolvimento desta tese.

A seguir, é apresentado no Capítulo 2 revisão da literatura reportando algumas comparações entre modelos estatísticos e redes neurais, e os principais trabalhos quanto a predição de número kappa. Não são abordados no Capítulo 2 aspectos de predição de densidade, pois não foram encontradas na literatura aberta referências que tratam de metodologias para predição da densidade do cavaco ou de outras propriedades do mesmo.

Capítulo 2

Revisão da Literatura

"…the applied like the theorist soon discovers from experience that a useful model is not one that is 'true' or 'realistic' but one that is parsimonious, plausible and informative"



Martin Feldstein (1939 -)
Professor Universidade Harvard

Capítulo 2

Revisão da Literatura

A modelagem tem grande importância na análise e resolução de problemas nos processos químicos. Ela está presente em todas as fases dos processos, desde a definição até a solução final.

Nas indústrias químicas integradas, não é somente o desempenho localizado de etapas individuais dos processos que é importante, mas também suas interações para determinar o desempenho global da planta. Não obstante, na prática é necessário dividir o problema em pequenas escalas para permitir uma análise de controle tradicional (HALMEVAARA 2009). Com o aumento da automação, a indústria química moderna gera grande volume de dados. Entretanto, em muitos casos a instrumentação fornece dados redundantes ou medições altamente correlacionadas. Isto é, o grande volume de dados por si só não gera resultados. A adequada análise dos dados e a transformação destes em informações produtivas são desafios permanentes do engenheiro de processos com maturidade.

A modelagem e simulação tornou-se uma ferramenta valiosa para as indústrias de papel e celulose, sejam em análises preditivas, alterações de configuração, melhoria de desempenho ou para a obtenção de melhor compreensão dos processos existentes (DAHLQUIST 2008).

Para o processo Kraft, existem referências de modelos em vários níveis de complexidade, permitindo ao usuário prever os resultados da alteração das variáveis, auxiliar nas tomadas de decisão, ou ainda identificar o ponto ótimo no equilíbrio nas situações *trade-off*.

O cozimento contínuo apresenta algumas dificuldades intrínsecas para tratamentos que buscam inferências. Os eventos físicos e químicos que ocorrem dentro do digestor são uma mistura de fenômenos de transporte e reações químicas complexas. O desenvolvimento de modelos fenomenológicos que representem o processo de cozimento da madeira é difícil devido aos seguintes fatores: natureza heterogênea do sistema no qual três fases (sólido/líquido/gás) estão presentes; medições difíceis (sistema pressurizado, sendo comum o uso de instrumentos radioativos); longo tempo de residência; complexidade da dinâmica no movimento da coluna de cavacos; não

linearidade e interação entre as variáveis de processo. Por estas razões, a modelagem e identificação das equações do processo de cozimento contínuo são desafios permanentes. Tais desafios são mais presentes com a expansão das tecnologias de cozimentos modificados[2] a partir da década de 1990.

2.1. Modelos em Polpação Kraft

Um dos primeiros modelos da cinética de deslignificação foi desenvolvido por Vroom em 1957. Em um esforço pioneiro, por meio da derivação da equação de *Arrhenius*, desenvolveu uma variável que combina a temperatura e tempo, transformando ambas variáveis em uma única, que denominou de "Fator H" aplicável para digestores descontínuos. Uma unidade do fator H, expressa o efeito de uma hora ao cozimento a 100 ºC, que é definido conforme indica a Equação 2.1:

$$H = \int_0^{t_\tau} e^{(43{,}2 - 16115/T)} dt \tag{2.1}$$

De uma forma geral, o Fator H permite boas previsões do grau de deslignificação, quando as demais variáveis de cozimento permanecem constantes. Esta variável foi de significativa importância e mesmo mais de 50 anos após sua publicação, várias fábricas ainda a utilizam como referência no controle operacional do número kappa.

Hatton (1973) sucedeu Vroom na correlação do número kappa em relações simples, propondo predições do número kappa baseados em medidas do Fator H e concentração do álcali efetivo (C_{EA}) (*Anexo 2.2*), conforme indica Equação 2.2:

$$K = \alpha - \beta . logH . C_{EA}^{w} \tag{2.2}$$

na qual α, β e w são parâmetros ajustáveis conforme as várias espécies de madeira. De uma forma geral, fibra longa apresentam valores similares, e madeiras de fibra curta apresentam maior sensibilidade quanto às variações de álcali. Porém, pela simplicidade, esta equação não contabiliza os efeitos de outras variáveis tornando a qualidade da previsão com restrições. Apesar disso, apresenta uma estimativa rápida e razoável para avaliar as relações entre carga de químicos e Fator H (Clayton *et al.* 1989).

[2] *Cozimentos Modificados : Aqueles que possuem alternativas de adição de álcali ao longo do corpo do digestor.*

Nas últimas décadas, muitos modelos teóricos e empíricos para o cozimento Kraft foram propostos. Ao leitor interessado na cronologia dos modelos em deslignificação Kraft, Gustavsson (2006), assim como Fernandes (2007) cobrem a evolução histórica no desenvolvimento de modelos ao longo das últimas décadas.

Muitos são os fatores que afetam a velocidade da reação de deslignificação em geral, tais como fatores térmicos, dinâmica de fluidos, características de difusão e penetração do licor nos cavacos, bem como as reações químicas dos carboidratos (*Anexo 2.4*) e de deslignificação (GULLICHSEN, 2000). Alguns autores dão ênfase nas abordagens da cinética das reações químicas (YANG e LIU 2005; SIXTA e RUTKOWSKA 2007; BOGREN *et al.*, 2009). Outros aos fenômenos físicos (MALKOV 2002, WALKUSH e GUSTAFSON 2002; RANTANEN 2006; GUSTAVSSON 2006, LAAKSO 2008). A maioria com propósitos de predição do número kappa, ou com objetivos específicos como melhoria da etapa de transição nos cozimentos entre madeiras de fibra longa e fibra curta (ARAUJO *et al.*, 2008).

Por outro lado, os avanços dos recursos de processamento de dados têm facilitado o desenvolvimento de modelos de previsão empíricos para o número kappa. Dentre outros, Kumar e Gustafson (1998) estudaram uma aplicação de modelos estatísticos para um digestor Kamyr e para o reator de deslignificação com oxigênio com base em análise multivariada. Os resultados de modelagem mostraram que cerca de metade da variabilidade observada no número kappa em ambos os pontos (digestor e o reator de oxigênio) pode ser explicada pela falta de controle das variáveis do processo.

Alexandridis *et al.* (2002) estudaram a eficiência da metodologia de Mínimos Quadrados utilizando dados reais para 20 variáveis de processo (incluindo o número kappa) com coleta de dados em frequência de 1 hora durante um funcionamento regular de dois meses de um digestor contínuo de fibra longa. Concluíram que o método Mínimos Quadrados Parciais - *Partial Least Square* (PLS) quando comparado com outras técnicas lineares regulares, apresentam resultados superiores, uma vez que não é afetada por correlações que existem entre as variáveis de entrada, reduzindo a dimensionalidade do sistema, rejeitando o efeito do ruído. Também ilustraram que pode ser combinada a predição em um sistema de controle. Pode ser usado tanto *on line* em controle de processo automático ou *off line* como uma ferramenta de controle consultivo. Registram ainda que cuidados especiais devem ser tomados frente às correlações entre as variáveis de entrada que são observadas nos dados de treinamento.

A metodologia de identificação apresentada pode ser estendida com a introdução de técnicas não lineares como redes neurais no algoritmo PLS, de modo que os parâmetros do modelo possam ser ajustados em linha, para a construção de modelos precisos de dados de entrada-saída.

Li e Zhu (2004) compararam a previsão de número kappa entre os métodos *Suport Vector Machine* (SVM), Regressão Linear Múltipla (RLM) e RNA *feed-forward* em cozimentos *batch*. Concluíram que o modelo SVM fornece uma alternativa exequível de predições, com vantagens sobre o RLM e RNA. Dentre as vantagens, reportam o menor número de parâmetros livres (considerando que os modelos RNA necessitam considerar os tipos da rede, o tamanho, parâmetros de treinamento e outros que podem afetar significativamente o desempenho da previsão). Além destas vantagens, reportam que o método SVM não apresenta as dificuldades típicas de RNA como "sobre-ajuste" (*overfitting*), formação de mínimos locais etc. Embora tenha alcançado bons resultados, registram que o algoritmo SVM pode ainda ser melhorado na melhor determinação de parâmetros para ser aplicado em dados de grande escala.

Dufour *et al.* (2005) pesquisaram o comportamento das variáveis: umidade e densidade de cavacos, carga de álcali, sulfidez (*Anexo 2.18*) do licor branco e seus efeitos na deslignificação em uma planta piloto contínua por redes neurais artificiais. Realizaram uma abordagem para a avaliação das variações da amplitude das propriedades da matéria-prima em relação à polpa produzida. Foi desenvolvida uma RNA *Multi Layer Perceptron* MLP em duas camadas ocultas, visando construir uma inferência de algumas variações não medidas, a partir das duas medições disponíveis nas extrações superiores do digestor. Tendo em vista as restrições das poucas medidas experimentais disponíveis, os próprios autores consideraram que a rede não teve um bom funcionamento, e a principal contribuição foi a seleção do conjunto de dados.

Ahvenlampi e Kortela (2005) desenvolveram uma previsão de número kappa e diagnóstico de falhas em digestores contínuos utilizando modelo híbrido com técnicas estatísticas de agrupamentos e lógica *fuzzy*, usando um conjunto de 30.000 observações em operação de um digestor contínuo industrial. As variáveis de entrada consideradas foram temperatura, álcali, taxa de produção e o número kappa. A variável de saída foi o número kappa e o modelo foi validado em um novo conjunto de dados. Um dos objetivos foi avaliar o diagnóstico de falhas, quanto à tendência do número kappa. Os desvios foram considerados em três grandezas, referenciados nas cores verde,

amarelo e vermelho. Os intervalos de medições do número kappa em analisador *on line* foi de aproximadamente 30 minutos. Os autores concluíram que o sistema proposto não era sensível a pequenos desvios das variáveis de entrada, que geravam desvios grandes na variável de saída.

Halmevaara e Hyotniemi (2005) desenvolveram um método utilizando regressão múltipla para capturar as dependências entre os parâmetros do sistema e medidas de qualidade, por eles denominado de *Iterative Regression Tuning*. Realizaram um estudo de caso de simulação interativa, de um digestor contínuo de vaso duplo para celulose de fibra longa. Consideraram as variáveis coeficiente de lavagem, nível de licor no digestor, nível de cavaco no digestor, nível de cavaco no vaso de impregnação e Fator H para predições do número kappa na descarga do digestor. Concluíram que as interdependências entre as variáveis é um fator complicador para capturar as variações no número kappa. O método proposto permite facilitar o entendimento da interação entre as variáveis podendo abrir possibilidades para encontrar parâmetros dos controladores.

Rantanen (2006) analisou dados em digestor contínuo convencional[3] e Lo-Solids™[4], com produção de celulose de coníferas e de folhosas. Desenvolveu modelos preditivos a partir de medições e de modelos fenomenológicos. Utilizou parâmetros em tempo real de temperatura, químicos de cozimento e grau de compactação da coluna de cavacos, visando predições do número kappa de ambos os processos de forma iterativa. Buscou ainda o desenvolvimento de uma nova estratégia de controle para o número kappa. Concluiu que os modelos podem dar novas informações sobre os processos, sendo seus resultados viáveis para apoiar a atividade dos operadores, em comparação com o controle baseado no então utilizado fator H.

Eriksson *et al.* (2006) compararam a previsão de número kappa entre os métodos RNA e PLS, usando dados históricos de um digestor Kamyr convencional de celulose de fibra curta. Usaram 14 variáveis de entrada a seguir nomeadas : Ritmo de produção (velocidade do dosador de cavaco), umidade de cavaco, fluxo mássico de cavaco, fluxo de vapor ao silo, fluxo de licor branco, concentração do licor branco, carga alcalina, nível de cavaco do digestor, concentração e temperatura da circulação

---

[3] *Cozimento convencional : Aquele em que toda a carga de álcali necessária é adicionada junto ao sistema de alimentação de cavacos.*

[4] *Lo-Solids™ : Cozimento que busca reduzir os sólidos dissolvidos ao longo do cozimento, reduzindo as concentrações de lignina dissolvida e íons de sódio.*

superior, concentração e temperatura da circulação inferior, temperatura da circulação de topo e sulfidez do licor branco. Concluíram que ambos modelos foram similares em termos de resultados, sendo que o modelo PLS é mais parcimonioso.

Ahvenlampi e Rantanen (2007) estudaram previsões e diagnósticos em digestor contínuo Lo-Solids^{TM}. O número kappa de descarga é previsto com o uso do *software Matlab*, aproximadamente na metade do tempo de retenção. Conforme seu resultado é realizado ajustes de temperatura. Os dados de modelagem (cerca de um mês de dados) foram coletados de um digestor contínuo industrial durante o seu funcionamento normal, com amostragens a cada 30 minutos. Usaram como variáveis de entradas a temperatura, carga alcalina, o número kappa e taxa de produção (tempo de residência). O sistema foi validado com os dados a partir do mesmo digestor em diferentes períodos. A temperatura de cozimento é alterada de forma iterativa com base na diferença entre os dados previstos e os observados, tendo obtido bons resultados.

Saavedra (2011) estudou modelos preditivos de número kappa de um digestor Lo-Solids^{TM} de fibra curta. Partindo inicialmente de um conjunto de 40 variáveis de cozimento, usando análise de regressão selecionou 9 como significativas (velocidade do dosador de cavacos, carga alcalina, percentual de cavacos com alto tempo de armazenagem, fluxo de licor branco ao vaso de impregnação, fluxo de licor branco à transferência ao digestor, temperatura de circulação de transferência, fluxo de circulação de transferência, fluxo de licor branco à circulação e temperatura de circulação). Buscou associar os efeitos destas no número kappa e também nas propriedades do branqueamento e propriedades físico-mecânicas da polpa. Testou os modelos RLM, RNA com regulação Bayesiana, RNA *back-propagation* com uma e duas camadas ocultas. Concluiu que o modelo preditivo usando RNA com regulação Bayesiana apresentou melhores resultados.

A modelagem do número kappa tem sido um tema amplamente estudado. No entanto, a maioria das pesquisas são direcionadas para espécies de coníferas, sendo poucos os estudos para madeiras folhosas (RANTANEN 2006). As propriedades das madeiras de fibra curta são diferentes das propriedades de fibra longa. Da mesma forma, o teor de lignina (e por consequência o número kappa) também é diferente, não somente em quantidade, mas também nas suas características químicas (LI e GELLERSTEDT 1997; JIANG *et al.* 2000), fazendo com que os modelos para madeiras desta origem tenham que ser estudados a par das pesquisas de fibra longa.

Além disso, nos vários estudos disponíveis na literatura, poucos autores reportam os desvios obtidos em seus modelos de forma clara para uma análise estatística comparativa através de índices formais. Como exemplo, das 18 referências indicadas neste capítulo, apenas 6 apresentam algum índice estatístico de desempenho, que estão sumarizados no Quadro 2.1.

Ademais, nenhum das referências pesquisadas apresenta análise estatística dos resíduos (ainda que pouco detalhada) de seus modelos.

Quadro 2.1 - Referências em predição de número kappa que apresentam índices

Autores	**Material**	**Técnicas**	**Resultados (*)**	**Digestor**
Kumar e Gustafson (1998)	*Softwood*	Análise Fatorial	R^2 ~ 0,70	Contínuo
Li e Zhu (2004)	*Softwood*	SVM	MAD <1 = 65 %	*Batch*
Saavedra (2011)	*Hardwood*	RLM	R^2 = 0,56 MAD = 7,39	Contínuo
		RNA	R^2 = 0,82 MAD = 5,18	Contínuo
Eriksson et al. (2006)	*Softwood*	PLS	R^2 = 0,60	Contínuo
Rantanem (2006)	*Hardwood*	Fenomenológicas	RMSE = 1,44 ~ 3,32	Contínuo
	Softwood	Fenomenológicas	RMSE = 2,20 ~ 4,40	Contínuo

(*****) Os índices R^2, MAD, RMSE estão descritos no *Anexo 3.2.*

Nesta tese, são formulados modelos de inferência para a densidade do cavaco e do número kappa de descarga de um digestor contínuo industrial de celulose fibra curta, orientados com base em dados históricos, tratados em métodos estatísticos e redes neurais artificiais.

São usados métodos de diferentes níveis de complexidade, como Alisamento Exponencial Simples (AES), Regressão Linear Múltipla (RLM), Análise Box-Jenkins de Séries Temporais (ARMA) e Redes Neurais Artificiais (RNA), cujos conceitos estão descritos no Capítulo 4.

2.2. Conclusões

Foram apresentados neste capítulo, a importância dos modelos nos processos industriais, bem como revisão da literatura no desenvolvimento dos diferentes modelos preditivos do número kappa em madeiras de folhosas e coníferas.

Quanto às referências relativas à deslignificação, poucos são as pesquisas que abordam predições em sistemas com fibra curta usando dados industriais. Além disso, é frequente que os resultados dos modelos estudados sejam reportados em forma de gráficos "previstos x realizados" em um determinado período de tempo. De uma forma geral os autores não reportam seus resultados por índices estatísticos formais, o que dificulta comparações efetivas entre os modelos pesquisados.

Não foram encontradas na literatura aberta, referências que tratam de metodologias para predição do número kappa com métodos univariados.

Da mesma forma, não foram encontrados referências quanto a modelos preditivos da densidade do cavaco ou de outras propriedades do mesmo para aplicações no digestor.

Neste contexto, reforça-se a contribuição deste estudo em caráter de inovação, no uso de métodos de domínio público em aplicações ainda não exploradas.

No Capítulo 3 são apresentadas as características da madeira nos aspectos físicos e químicos, os conceitos básicos do processo Kraft, as principais etapas das reações de deslignificação, contextualizando o digestor contínuo dentro de uma unidade fabril.

Capítulo 3

A Deslignificação Kraft

"As árvores estão sós. Mas não o só da solidão :

O só da solistência."

João Guimarães Rosa



João Guimarães Rosa (1908 – 1967)
Poeta e Escritor

Capítulo 3

A Deslignificação Kraft

Neste capítulo apresentam-se os fundamentos teóricos do trabalho, iniciando pelas características da madeira, os princípios do processo Kraft e os principais componentes das reações de deslignificação.

Os conceitos estruturais e anatômicos da madeira são importantes no contexto do entendimento da importância da densidade de cavaco no processo de absorção do álcali contido no licor por difusão e penetração. Os conceitos da química da madeira são importantes para o entendimento das reações de deslignificação, e do conceito do número kappa enquanto referencial do teor de lignina residual da polpa.

São estabelecidas as bases e pressupostos dos métodos que foram usados nos modelos tratados, com as descrições sumárias, mas suficientes, das informações necessárias ao entendimento.

3.1 A Madeira

A madeira é a principal fonte de fibras nas aplicações industriais. É normalmente classificada quanto ao comprimento da fibra, podendo ser de fibra longa (2,0 a 3,5 mm) ou fibra curta (0,5 a 2,0 mm), com relevantes implicações nas propriedades físicas do papel. São de fibra longa as originadas de madeiras coníferas (também chamadas de baixa densidade ou *softwood*), e fazem parte do grupo botânico *Gymnospermae*. A araucária, *spruce* e *pinus spp* são exemplos típicos como matéria prima industrial. Tem como principais produtores os Estados Unidos, Canadá, Suécia, Finlândia, Chile, Alemanha e Noruega. Na Escandinávia a produtividade é da ordem de 5 a 7 m^3/ha.ano, enquanto que nos Estados Unidos é de 5 a 15 m^3/ha.ano (SIXTA, 2006).

Analogamente, as madeiras de fibra curta são também chamadas de folhosas (densas ou *hardwood)* e fazem parte do grupo botânico *Angiospermae*. Exemplos típicos nas aplicações industriais de celulose são os eucaliptos (em maior volume), acácia, bétula e birtch. Os principais produtores mundiais são o Brasil, Indonésia, Chile,

Espanha, Portugal e mais recentemente o Uruguai. No Brasil destacam-se as madeiras de *Eucaliptus Grandis* e *Eucaliptus Urophylla* (bem como seus híbridos), e no Chile, Uruguai e Ibéria *Eucalyptus Globulus*. A produtividade do eucalipto no Brasil é da ordem de 40 a 50 m^3/ha.ano, sendo que em algumas regiões ultrapassa 75 m^3/ha.ano (COLODETTE e GOMES 2015).

3.1.1 Carboidratos

Holocelulose

É o termo usado para designar toda a fração de carboidrato do material celulósico depois de removido a lignina. A maior porção de carboidratos da madeira é composta por polímeros de celulose e hemicelulose. A combinação de celulose e hemicelulose é chamada de holocelulose.

Celulose

Na natureza está presente em todos os vegetais e é o polímero mais abundante na terra, sendo um dos principais constituintes das paredes celulares das plantas. É um biopolímero linear, de cadeia extensa, com um único tipo de unidade de açúcar como monômero (RYDHOLM, 1969). Classificado como polissacarídeo, cuja hidrólise completa resulta em glicose, indicado na Figura 3.1 (FENGEL e WEGENER, 1984). Com fórmula $(C_6H_{10}O_5)n$, sua massa molar pode variar de 160.000 a 2.400.000, conforme o grau de polimerização.

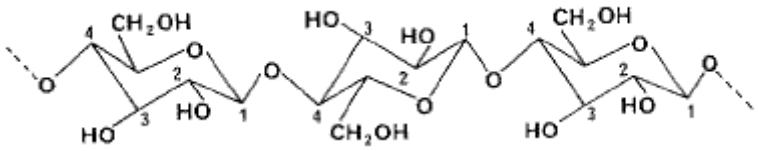


Figura 3.1 - Representação do polímero da celulose.

Os monômeros formam o conjunto de moléculas de celulose e estas agregadas formam as micelas. O conjunto de micelas formam as microfibrilas, em que regiões organizadas (cristalinas) se alternam com regiões desorganizadas (amorfas). As microfibrilas se agrupam formando as macrofibrilas e o conjunto destas constituem as fibras conforme indicado na Figura 3.2 (adaptado d'ALMEIDA 2013).

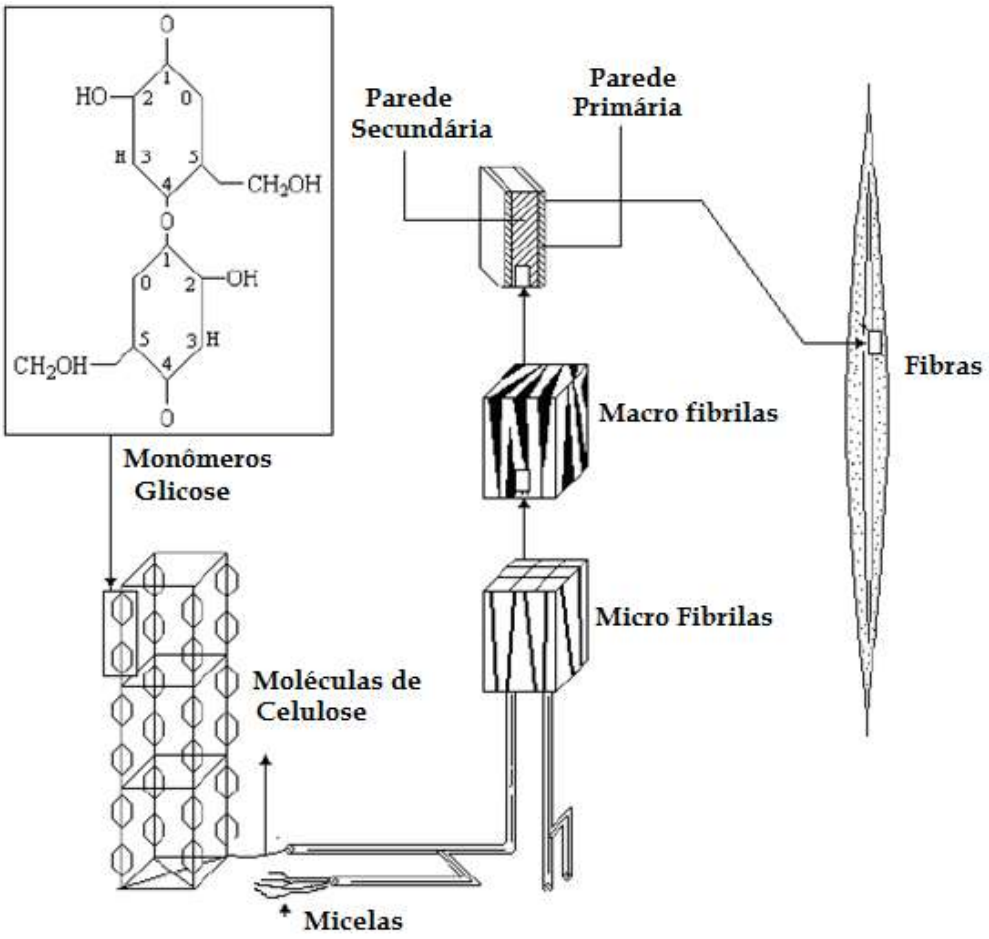


Figura 3.2 - Formação da fibra de celulose

As microfibrilas encontram-se combinadas, entre outros, com as hemiceluloses e com a lignina. Além da sua aplicabilidade nos diversos segmentos de papéis, a celulose é aplicada na indústria alimentícia, de tecidos, cosmética e farmacêutica. Em termos quantitativos, seu maior consumidor é a indústria papeleira, que além da escrita e impressão, possui grandes demandas para embalagem e para o segmento *tissue.*

Hemiceluloses

São polissacarídeos (com cadeias menores que da celulose), de estrutura linear ramificada. As hemiceluloses de folhosas e coníferas diferem em percentagem e em composição química (*Anexo 2.9*).

3.1.2 Lignina

A lignina é a substância que une as fibras e confere à madeira resistência aos esforços mecânicos. É um polímero fenólico polidisperso, composto por unidades de fenilpropano substituídas por grupos hidroxilas e metoxilas, formando uma rede tridimensional. São polímeros amorfos, de composição complexa. Sua finalidade é conferir firmeza à estrutura do vegetal, sendo o ligante que mantém as fibras unidas na estrutura da madeira. É resistente à hidrólise ácida e possui alta reatividade com agentes oxidantes (GOMIDE, 2010). Um modelo de sua estrutura é indicado na Figura 3.3.

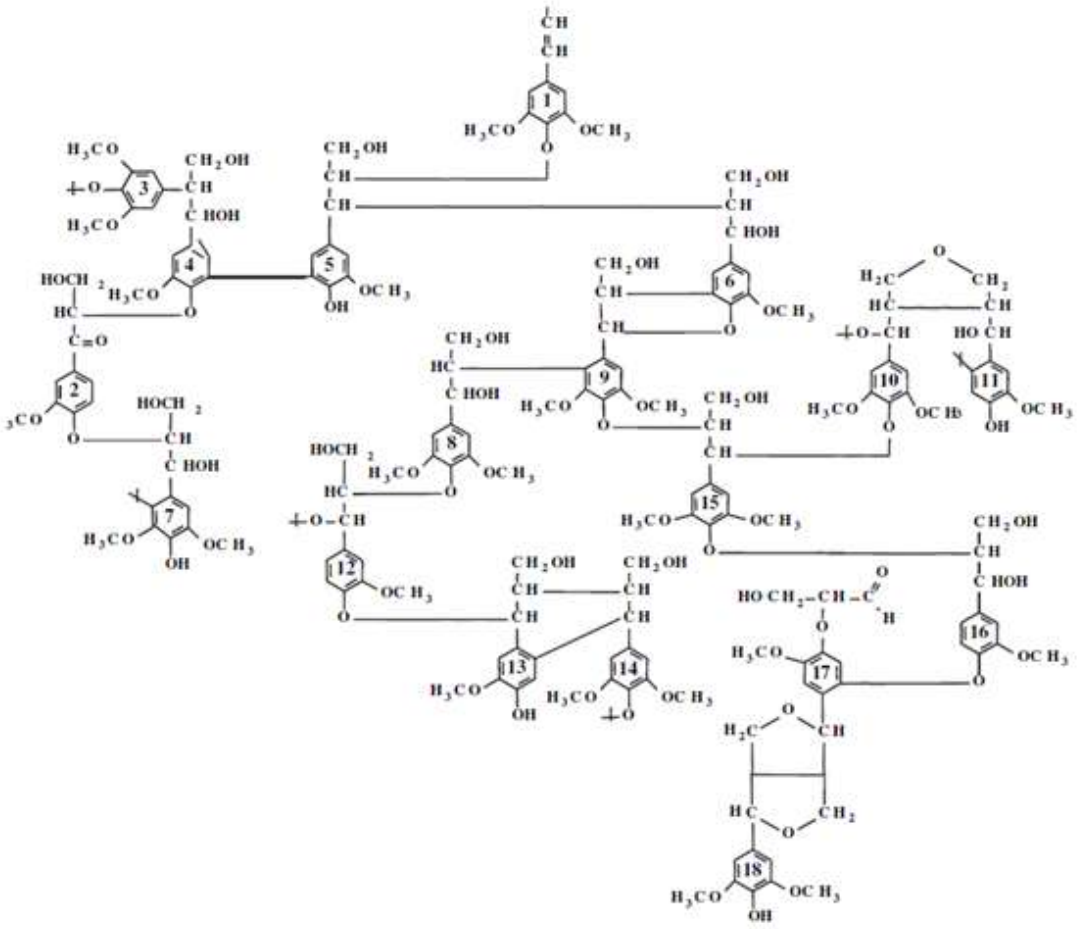


Figura 3.3 - Modelo da estrutura química da lignina de eucaliptos

Seus principais grupos funcionais são as metoxilas, hidroxilas e carbonilas. O teor quantitativo destes grupos varia de espécie para espécie, e possui relação significativa com as reações de polpação alcalina. A natureza aromática das unidades fenólicas dá a esses polímeros características hidrofóbicas, enquanto sua estrutura

tridimensional proporciona-lhes resistência e rigidez às forças de compressão. O teor de lignina das folhosas é menor do que nas coníferas conforme indicado na Tabela 3.1.

3.1.3 Substâncias de Baixa Massa Molar

Os componentes de baixa massa molar atribuem propriedades como cheiro, gosto, cor e em algumas espécies são responsáveis para proteção à degradação. Embora presentes em pequena quantidade na madeira, podem apresentar uma grande influência nas propriedades e no processamento das mesmas. São divididas em substâncias orgânicas e inorgânicas. O material orgânico é chamado de extrativos, e a parte inorgânica tem como principais compostos os sulfatos, fosfatos, oxalatos, carbonatos e silicatos de cálcio bem como o potássio e magnésio.

De uma forma geral, madeiras com alto teor de extrativos levam a rendimentos baixos. Estes reagem com o licor de cozimento, e inibem as reações com a lignina pelo aumento da impermeabilidade do cavaco, dificultando a penetração do licor. Certos extrativos podem tornar a polpa mais escura e mais difícil de branquear, gerando compostos saponificados (levando a formação de espuma). Na Tabela 3.1 é indicada a constituição química típica de madeiras de fibra curta e longa, reportada por GOMIDE (2010), indicada em percentual em massa:

Tabela 3.1: Composição típica de folhosas e coníferas de uso industrial

Componentes	***E. Grandis***	***E. Globulus***	***Pinus radiata***
Celulose	50,8	51,3	37,4
Mananas	1,2	1,4	20,4
Xilanas	15,5	20,2	8,5
Lignina	26,8	21,9	27,2
Extrativos	3,1	2,8	4,1

3.2 O Processo Kraft

A polpa de celulose pode ser obtida por meio de processos mecânicos, químicos, ou semi-químicos. O processo químico é o mais frequente, e destes, o processo Kraft (ou sulfato) é o dominante nas fábricas de grande porte.

O processo Kraft tem origens no final do século 19. As primeiras publicações que tratam da deslignificação de madeira com a presença de compostos de enxofre usando uma solução alcalina de "*oxysulfide of calcium*" foram realizadas por *Asahel K. Eaton* (*Anexo 1.1*) com as patentes *Improvement in the manufacture of paper pulp - US Patent 106 143* em 09 de agosto de 1870 e *Improvement in the manufacture of paper pulp - US Patent 119 224* de 26 de setembro de 1871. O objetivo das referidas patentes, era a substituição por um produto químico de menor custo, neste caso por óxidos de cálcio e enxofre.

Aproximadamente 15 anos depois, o químico alemão *Carl Ferdinand Dahl* efetivamente descobriu o uso do Na_2SO4 como fonte de reposição dos químicos de cozimento, com o método *Process of Manufacturing Cellulose from Wood - US Patent 296 935* em 15 de abril de 1884, e é creditado a ele o 'inventor do processo Kraft'(*Anexo 1.2*).

Suas principais vantagens estão ligadas à flexibilidade com relação às espécies de madeira, cozimentos mais curtos, obtenção de altos níveis de alvura da polpa e principalmente a recuperação do licor resultante do cozimento, tornando-se atrativo quanto à viabilidade econômica e ambiental. Suas desvantagens principais estão ligadas ao alto custo de investimentos, o odor característico e o baixo rendimento do processo (comparado aos demais). Extensa literatura é disponível sobre as características do processo Kraft (KOKUREK *et al*. 1989, CLAYTON *et al*. 1989).

De uma forma geral, uma moderna indústria de processo Kraft de celulose de mercado possui as etapas de descascamento, picagem de cavacos, cozimento, depuração, lavagem, branqueamento e secagem, a seguir indicadas na Figura 3.4.

As toras de madeira após descascadas são picadas em cavacos, que são classificados no peneiramento. Antes do cozimento propriamente dito, os cavacos são tratados rapidamente com vapor, visando o seu aquecimento uniforme e a eliminação do ar contido em seus poros. A presença do ar é um obstáculo à migração do licor para o interior do cavaco. A saturação dos poros permitirá a melhor difusão dos químicos de cozimento. Os cavacos impregnados são alimentados ao digestor, visando remover a lignina e transformação em polpa marrom (ou UKP – "*unbleached Kraft pulp*"). Em seguida ao cozimento, a polpa passa para as etapas de lavagem, depuração, branqueamento e deste para as máquinas de secagem (polpa de mercado) ou de papel.

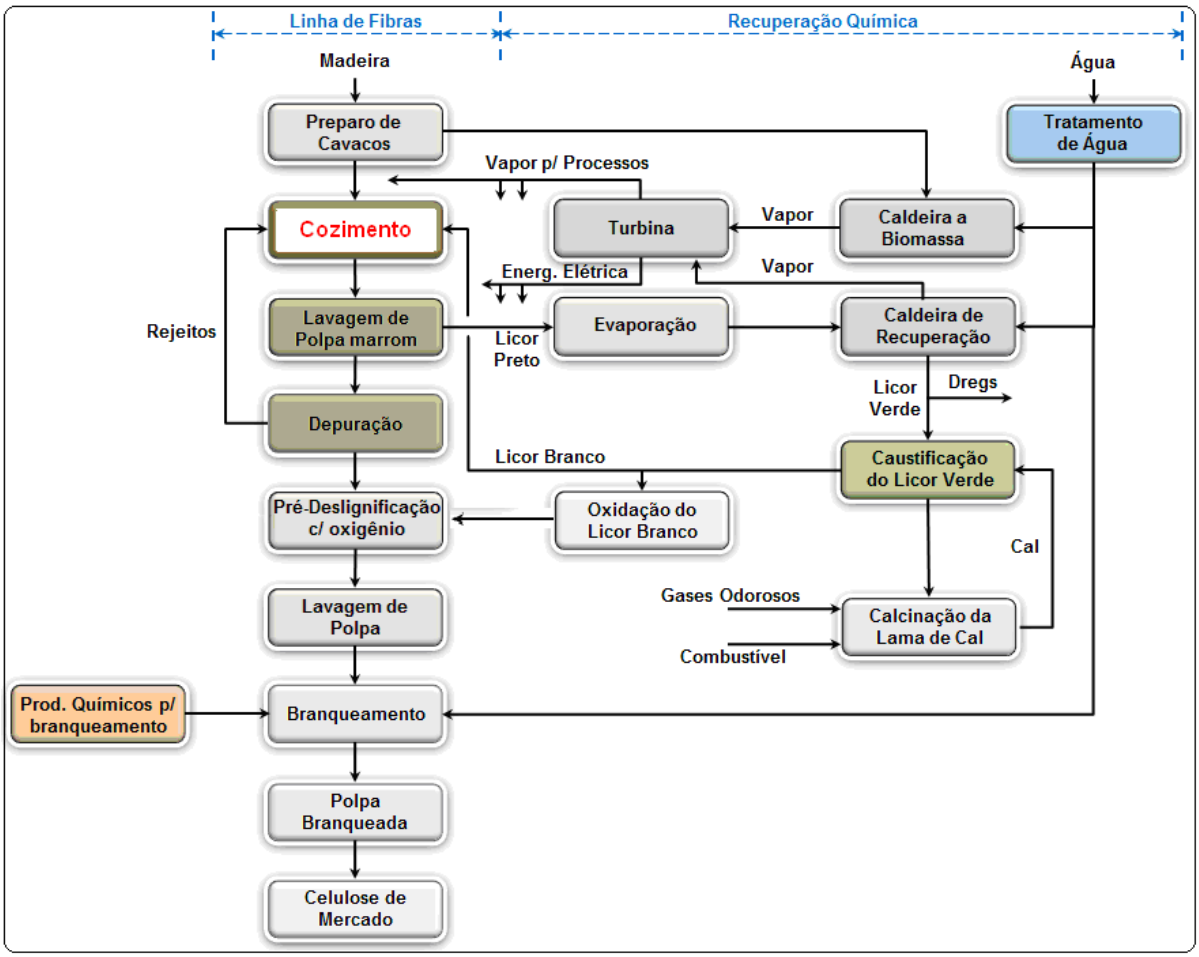


Figura 3.4 - Etapas do processo Kraft de uma planta de celulose de mercado

O objetivo da lavagem é recuperar a matéria orgânica ao sistema de recuperação química (minimizando impactos ao efluente e obtendo material combustível) e preparar a polpa para a etapa do branqueamento. A depuração tem como objetivo separar os cavacos não cozidos e as fibras aglomeradas (*shives*), que podem vir a contaminar a polpa branqueada. Já o branqueamento, tem como objetivo remover a lignina residual aumentando a alvura.

Quanto ao ciclo do licor, a fase líquida que é produzida no digestor (licor preto fraco) é rica em matéria orgânica dissolvida, (concentrações 10 ~ 18 % de sólidos). Após ser concentrado nos evaporadores (70 ~ 85 %), é chamado de licor negro concentrado (*Anexo 2.12*) Este licor alimenta a caldeira de recuperação química, que tem as funções simultâneas de produção de energia térmica e recuperação de químicos. Os produtos químicos inorgânicos fundidos *smelt (Anexo 2.17*) são dissolvidos em filtrados procedentes da caustificação, dando origem ao licor verde. Após clarificação, o *underflow* (*dregs*) é retirado, e a solução segue para o caustificador, onde é tratada com

uma suspensão aquosa de $Ca(OH)_2$ a fim de converter o Na_2CO_3 em NaOH. Simultaneamente, precipita-se o $CaCO_3$ que é retirado da solução no clarificador, sendo direcionado para um ciclo fechado no forno de cal a fim de gerar o CaO por reação de calcinação, regenerando o $Ca(OH)_2$. Este é direcionado para a bateria de caustificadores fechando-se então o ciclo de recuperação de produtos químicos.

Apesar da elevada eficiência da recuperação de espécies inorgânicas no processo Kraft, a reposição de perdas é realizada com sulfato de sódio. Por esta razão o processo Kraft é também chamado de "Processo ao Sulfato".

Detalhes da terminologia técnica do processo Kraft estão presentes no *Anexo 2.*

3.2.1 O número kappa

O número kappa é o índice mais utilizado para fornecer a referência do grau de deslignificação no processo de celulose. Quanto maior seu valor, maior o conteúdo de lignina e maior o consumo de químicos necessários ao branqueamento. É usado não somente no controle da operação do digestor, mas também na deslignificação com oxigênio, ou nos estágios do branqueamento.

No Brasil, seu método de análise está expresso na norma ABNT NBR ISO 302:2005, baseada na norma TAPPI T236-85. Sua definição é o número de mililitros da solução de $KMnO_4$, com concentração de 0,1 N consumido sob condições especificadas e corrigidas para 50 % da solução adicionada, por grama de pasta celulósica (seca em estufa). O ponto de consumo é definido conforme a descoloração da solução. Conforme expresso na referida norma, não existe uma relação geral e não ambígua entre o número kappa e o teor de lignina de pastas celulósicas. A relação varia de acordo com as espécies de madeira e o procedimento de deslignificação. Várias investigações têm sido feitas buscando uma correlação. D'Almeida (2013) reporta a proporcionalidade do número kappa com a concentração de lignina como "referência macro" em torno de 22% para coníferas e em torno de 15% para folhosas.

Quimicamente, a determinação do número kappa é realizada no conceito do ataque do permanganato aos anéis aromáticos da lignina, resultando na transformação do permanganato em MnO_2. As reações principais na especificação do método são:

1. Lignina + compostos oxidáveis + MnO_4^- + $4H^+$ → Lignina oxidada + compostos oxidados + MnO_4^- (excesso) + MnO_2 + H_2O

2. $2\ MnO_4^- + 10\ I^- + 16\ H^+ \rightarrow 2\ Mn^{2+} + 5\ I_2 + 8\ H_2O$

3. $MnO_2 + 4\ H^+ + 2\ I^- \rightarrow Mn^{2+} + 2\ H_2O + I_2$

4. $2\ S_2O_3^{2-} + I_2 \rightarrow S_4O_6^{2-} + 2\ I^-$

Todos os compostos oxidáveis pelo $KMnO_4$, fazem aumentar o consumo deste nas reações de oxidação. Além da lignina residual, provocam um aumento do número kappa outros componentes não cromóforos como ácidos hexenurônicos e outras estruturas de "não lignina" (GELLERSTEDT e SEVASTYANOVA, 2000). Este conceito é importante, pois a análise do número kappa como é realizada, expressa o conteúdo da lignina presente, mas também de outros compostos.

A análise do número kappa pode também ser realizada em um medidor *on line*, que coleta a amostra e faz a análise através de instrumentos. Seus principais componentes são o coletor de amostra, microcomputador e componentes da unidade óptica. A amostra é coletada e enviada para um tanque onde é lavada por chuveiros com água desmineralizada, e enviada para o medidor. A medição é realizada por luz ultravioleta. A absorção de luz pela polpa de celulose determina o número kappa que é automaticamente enviado para a estação de controle. Normalmente é feita uma distribuição dos diversos pontos de coleta de número kappa na linha de fibras, sendo feito uma análise por cada ponto em aproximadamente 10 a 15 minutos (isto é, se houver 4 pontos de análise, a análise é repetida naquele ponto a cada 40 a 60 min). A previsão do número kappa é tão importante, que o fabricante do instrumento medidor incluiu a possibilidade de analisar uma amostra antes da descarga (isto é, para antecipar informações da análise). Não obstante, tendo em vista a não formação de polpa na parte intermediária do digestor, não é raro o entupimento da linha de admissão e alta variabilidade das medidas.

Devido ao baixo ponto de separação de fibras do *Eucalyptus* (LINDSTROM 2007), ou seja, ao baixo teor de lignina no qual as fibras são quimicamente separadas, a principal falha de processo que pode ocorrer em um digestor contínuo é a produção de uma polpa com número kappa alto. A elevação do número kappa causa maior carga de orgânicos ao efluente, maior consumo de químicos do branqueamento, riscos de perda de alvura da polpa, e principalmente, a obstrução de equipamentos da depuração marrom, impedindo o fluxo normal de produção.

3.2.2 A Polpação Alcalina

O processo de polpação ocorre no digestor, onde se dá o cozimento da madeira para separação das fibras. Ela ocorre com a mistura de cavacos e licor branco (solução de NaOH + Na_2S). O licor e cavacos são alimentados ao digestor, passando por equipamentos auxiliares de alimentação ao sistema de alta pressão. Como a reação de deslignificação é exotérmica e também pela adição de vapor, a zona de cozimento atinge temperaturas da ordem de 160 ºC, ocorrendo as reações de solubilização da lignina, permitindo separá-las das fibras dos carboidratos. Dentre outros fatores, a duração do cozimento depende da taxa de deslignificação pretendida, da temperatura e da concentração das espécies inorgânicas. Os cavacos (então transformados em polpa), são descarregados do digestor sob pressão.

As reações químicas na polpação Kraft

A madeira é um material de natureza química extremamente complexa. Essa complexidade resulta da grande variabilidade entre diferentes espécies (e dentro da mesma espécie), da estrutura polimérica dos seus constituintes e da associação química entre eles. Durante as reações de deslignificação nos processos químicos alcalinos, ocorrem as reações de quebra da lignina, bem como as indesejáveis reações com os carboidratos.

A entrada dos reagentes na estrutura da madeira ocorre por penetração e difusão. Nas folhosas, a penetração ocorre rapidamente através dos vasos, sendo que a penetração na direção transversal é quase inexistente. Já nas coníferas (que não possuem vasos), são dotadas de membranas com pontuações porosas, ocorrendo a penetração através do lúmen destas células. Com a difusão do licor branco no interior dos cavacos, ocorre a ruptura das ligações de hidrogênio entre os carboidratos, inchando a madeira, fazendo que a difusão dos íons seja praticamente igual em todas as direções. No processo Kraft, o álcali é consumido pelas reações com a lignina, dissolução dos carboidratos, reações com os vários ácidos orgânicos (originários da madeira, ou produzidos pelas reações de hidrólise da polpação), reações com as resinas ou em menor quantidade na adsorção pelas fibras (GOMIDE e FANTUZZI, 2000).

Reações dos carboidratos

A degradação alcalina dos carboidratos é bem apresentada por Rydholm (1965). Tanto a celulose como as hemiceluloses ficam instáveis em soluções alcalinas, permitindo ocorrer as indesejáveis reações hidrolíticas das ligações glicosídicas, causando a quebra das cadeias dos carboidratos. Tais reações de degradação resultam no decréscimo do rendimento.

Ácidos Hexenurônicos

Em condições de tratamento alcalino em alta temperatura, como as encontradas no digestor, as estruturas das hemiceluloses podem ser modificadas, com a dissolução dos polímeros e a degradação parcial dos seus grupos laterais, propiciando a conversão dos ácidos urônicos presentes na madeira em ácidos hexenurônicos. Estes são formados pela modificação dos ácidos 4-O-metilglicurônicos, presentes nas xilanas, conforme mecanismo proposto na Figura 3.5 (VENTORIM *et. al.* 2009).

As condições de polpação que resultam em aumento do conteúdo de ácidos hexenurônicos na polpa são maior carga de álcali ativo (*Anexo 2.1*), maior sulfidez e menor temperatura.

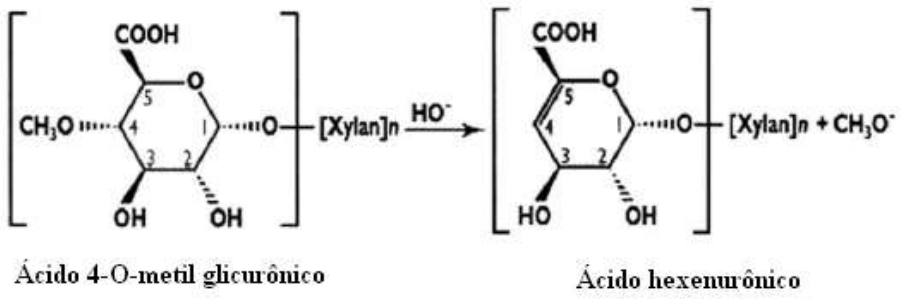


Figura 3.5 - Formação do ácido hexenurônico

A presença destes ácidos impede a despolimerização terminal das xilanas, aumentando o rendimento do cozimento Kraft como efeito benéfico (LI e GELLERSTEDT 1997). Por outro lado, tais ácidos consomem reagentes químicos de branqueamento. Quando não removidos, causam reversão de alvura e funcionam como quelantes, fixando os metais. Por reagirem com oxidantes, o teor de ácido hexenurônico é um reagente que "aumenta o número kappa" da polpa UKP, podendo representar de 20 a 30 % do número kappa total para polpas de eucaliptos. As polpas Kraft de fibra

curta possuem mais grupos dos ácidos hexenurônicos do que as de fibra longa produzidas pelo mesmo tipo de cozimento, uma vez que as madeiras folhosas contêm mais 4-O-metilglicuronoxilana, que são os precursores dos ácidos hexenurônicos (VUORINEN *et al.* 1996, COLODETTE *et al.* 2002).

Reações da lignina

A lignina é um constituinte da parede celular, de natureza polimérica complexa e tridimensional. Não deve ser considerada uma substância química única, mas uma classe de materiais correlatos, sendo o fenilpropano a sua unidade básica, conforme Figura 3.6 (SJÖSTRÖM, 1992).

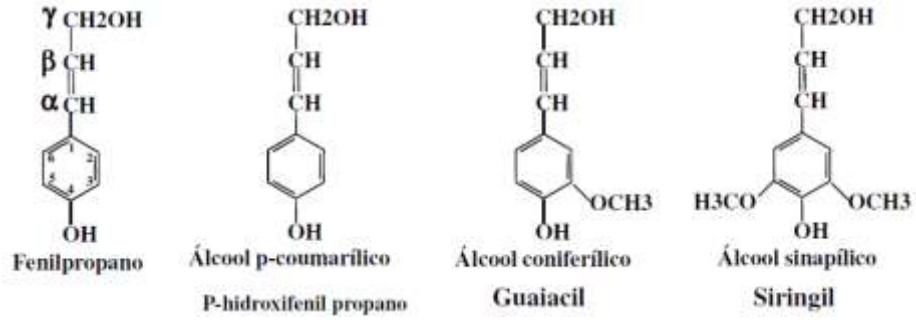


Figura 3.6 - Unidades básicas estruturais da lignina

A remoção da lignina é feita por meio da quebra das ligações no interior da macromolécula. O licor branco movimenta-se no interior das fibras, difunde-se através da parede celular e degrada a lignina. Ocorre a formação de fragmentos solúveis de lignina, que são removidos das fibras pelos processos de separação sólido/líquido posteriores. Embora a lignina apresente na sua estrutura vários tipos de ligações, apenas as do tipo carbono-oxigênio das ligações éter, são hidrolisadas durante o cozimento normal, conforme indicado na Figura 3.7 (KOKUREK *et al.* 1989). Além das reações de hidrólise, também ocorrem reações de condensação com átomos de carbono e com formaldeídos.

Podem ainda ocorrer no interior do digestor, reações de reprecipitação da lignina, quando se alteram as condições físico-químicas de solubilidade da mesma. Nestas situações, a remoção posterior da lignina da polpa é difícil e com impactos relevantes no branqueamento.

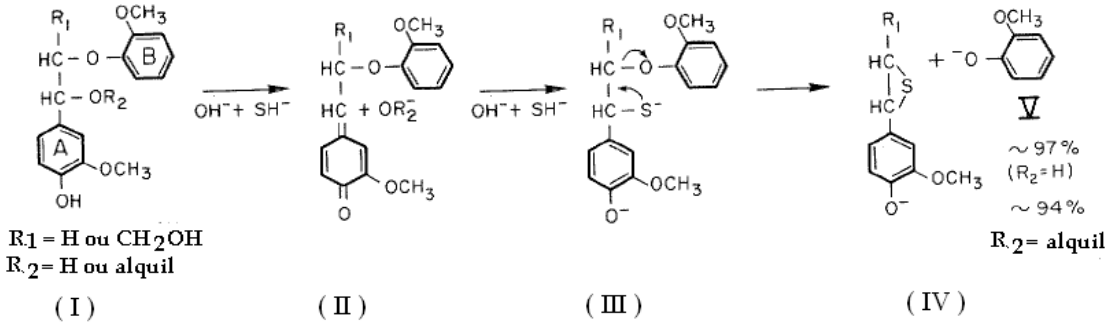


Figura 3.7 - Modelo de reações da lignina com licor Kraft

3.3. O Digestor Contínuo

O digestor contínuo é um reator tubular onde ocorre a deslignificação de cavacos de madeira em solução alcalina em altas temperaturas e pressão. Os cavacos e licor de cozimento são alimentados em taxas controladas em um vaso vertical pressurizado. Os cavacos se movem em fluxo descendente, sendo descarregados ao fundo em forma de polpa. Os fatores que favorecem os digestores contínuos frente aos de batelada são relevantes: menor consumo de vapor e de energia, menor espaço físico, melhor tratamento dos gases gerados e principalmente os menores custos de instalação. Apresenta simultaneamente as fases sólida, líquida e vapor, cujo comportamento é fortemente dependente dos fenômenos de transporte de calor e massa, bem como da evolução das reações químicas.

De uma forma geral é constituído de três regiões distintas: zona de impregnação, zona de cozimento (onde ocorrem as reações de deslignificação) e zona de lavagem (onde ocorrem as fases de lavagem, resfriamento e remoção da lignina residual) conforme Figura 3.8 (Adaptado SMOOK, 2002).

A zona de impregnação fornece o tempo de retenção suficiente para que o licor branco possa penetrar e se difundir através dos cavacos. Normalmente tem um tempo de retenção de 45 a 60 minutos, com temperaturas entre 100 e 125 ºC.

Na zona de cozimento os cavacos recebem o licor do sistema de circulação, atingindo uma temperatura em torno de 150 a 160 ºC. O licor extraído pelas peneiras passa por um sistema de circulação e aquecimento indireto, sendo reintroduzido ao digestor pelo tubo central. É a etapa em que ocorrem as principais reações de deslignificação. O tempo nesta zona varia conforme a produção e qualidade da polpa requerida.

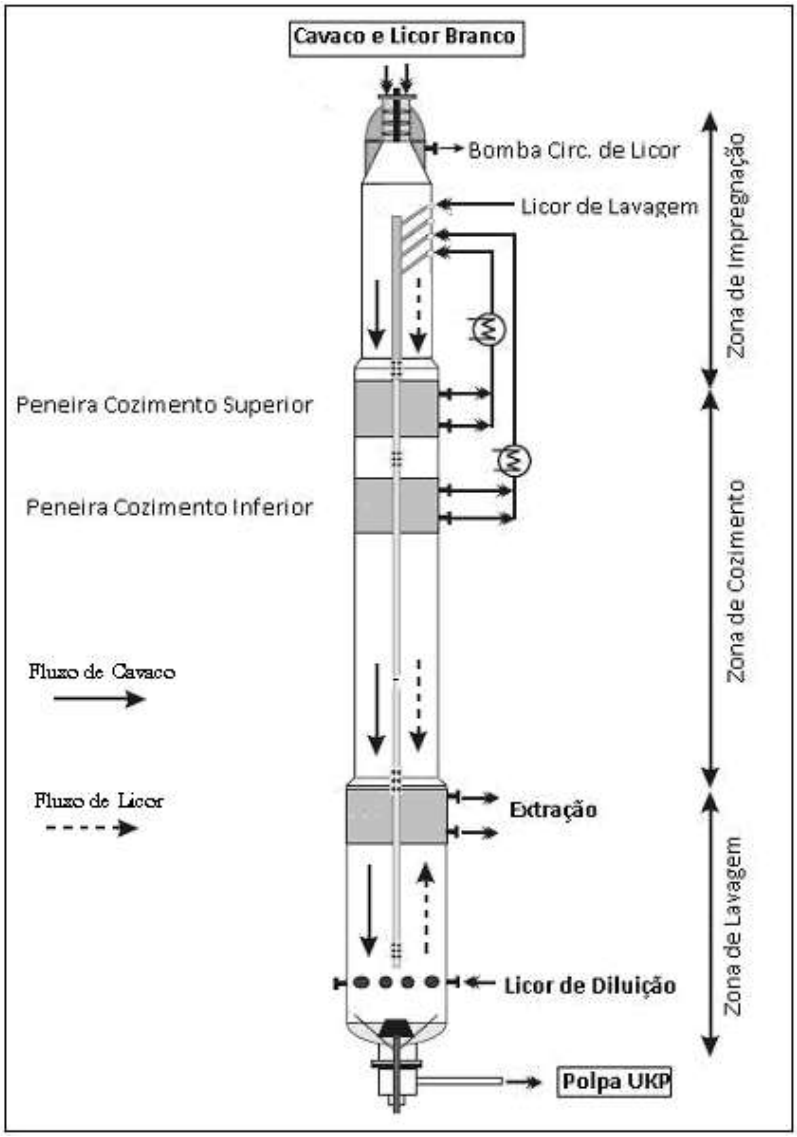


Figura 3.8 - Digestor contínuo Kamyr típico

Por último, na zona de lavagem (também chamada de lavagem *hi heat*) ocorre a interrupção das reações entre os cavacos e licor. O licor de diluição injetado ao fundo do digestor desloca o licor de cozimento em contracorrente resfriando o sistema, permitindo a descarga à pressão atmosférica, normalmente na faixa de temperatura de 90 a 95 ºC.

Os digestores contínuos são equipados com um raspador de fundo que promove a descarga do digestor, garantindo a saída ao longo de toda a seção reta do equipamento, facilitando a importante regularidade da descida da coluna de cavacos. Ao longo dos anos, tem ocorrido uma evolução nos projetos dos digestores visando atender a melhoria das propriedades da polpa, aumento do rendimento bem como ao aumento da produção por área do equipamento.

Capítulo 4

Métodos Estatísticos

e

Redes Neurais Artificiais

"Essentially, all models are wrong, but some are useful !"



George Edward Pelham Box (1919 – 2013)
Estatístico Britânico

Capítulo 4

Métodos Estatísticos e Redes Neurais Artificiais

As incertezas do futuro dificultam as decisões nos processos de escolha. No entanto, estas decisões são tomadas com as informações disponíveis (ainda que incompletas). Quando uma ação deve ser executada em ambientes ruidosos e variantes no tempo, implementar alternativas que possam prover um maior conjunto de informações tem contribuição relevante para mitigar riscos. Métodos Estatísticos e Redes Neurais Artificiais são ferramentas úteis para facilitar os processos de decisão, fornecendo subsídios para complementar as informações existentes.

No desenvolvimento deste trabalho, são aplicados modelos univariados Média Móvel Simples (MMS), Alisamento Exponencial Simples (AES) e Box-Jenkins de Séries Temporais (ARMA) na predição da densidade de cavaco. Já para a predição do número kappa são aplicados modelos de AES, ARMA, Regressão Linear Múltipla (RLM) e Redes Neurais Artificiais (RNA). A RLM foi também utilizada para determinar a relação entre a variável resposta (número kappa) e as variáveis explanatórias (variáveis de processo digestor), que serviu de base para as variáveis de entrada para o próprio modelo RLM e também para o modelo RNA.

A metodologia buscou o foco de facilitar decisões operacionais em um equipamento de operação complexa, com variáveis de processo não lineares, tempo de resposta longo e muitas vezes sem possibilidade de correções quanto ao produto obtido.

4.1. Séries Temporais

Série temporal é uma função Y aleatória ou não determinística de uma variável independente *t*. Na maioria das situações, a função Y(t) será uma função do tempo, mas em outras situações pode ser uma função de outro parâmetro físico, como por exemplo, do espaço. Uma característica das séries temporais é que seu comportamento futuro não pode ser previsto exatamente, como seria o caso de uma função ‘determinística’ do tempo. Embora não possuam funções determinísticas, podem ser estimadas considerando o conceito de processo estocástico. Outra característica

importante deste tipo de dados é que as observações vizinhas (t–k) são dependentes e, portanto, procura-se analisar e modelar esta dependência. Exemplos de séries temporais são registros de temperaturas diárias em uma cidade, vendas mensais de uma empresa, valores de fechamento diários da bolsa de valores, rendimento de um reator químico etc. (MORETTIN e TELOI, 2006).

A habilidade de prever adequadamente e entender as relações dinâmicas entre variáveis são de grande importância. Grande parte desta metodologia estatística é aplicada em modelos nos quais se assumem que as observações variam no tempo. No estudo de Séries Temporais pode-se ter o objetivo de fazer previsões de valores futuros, acompanhamento e controle de medições, entender a estrutura da série (padrões de tendência, sazonalidade, *outliers*, etc.) ou ainda entender a relação com outras séries.

Nos casos em que o objetivo é a previsão, os dados futuros são estimados com base nos dados históricos e atuais. A abordagem em modelos estatísticos industriais é dependente no tempo, uma vez que pode identificar quantitativamente a dinâmica ou as propriedades de um processo, usando dados obtidos durante as condições de produção real. Com a crescente variedade e complexidade dos problemas de previsão, muitas técnicas foram desenvolvidas nos últimos anos. Cada uma tem sua particularidade e aplicação mais adequada. A seleção de um método depende de muitos fatores, dentre eles as demandas da previsão, a relevância e a disponibilidade de dados históricos, o grau de precisão desejável, o período de tempo a ser previsto, o custo/benefício das previsões e o tempo disponível para fazer a análise (CHAMBERS *et al.* 1971).

Processos Estocásticos, Tendência, Sazonalidade e Estacionariedade, são alguns conceitos importantes no entendimento de séries temporais, que estão a seguir descritos (MORETTIN e TOLOI, 2006):

Processos Estocásticos

Seja T um conjunto arbitrário de indexação. Um processo estocástico é uma família $Y=\{Y(t), t \in T\}$, tal que para cada $t \in T$, $Y(t)$ é uma variável aleatório.

A realização de um processo estocástico, considerando $T = \mathbb{R}$, é uma série temporal, ou em outras palavras, a série temporal é uma realização de um processo estocástico.

Tendência

É o comportamento de longo prazo da série, que pode ser causada por qualquer aspecto que afete a variável de interesse no longo prazo. Há três objetivos básicos na sua identificação: avaliar o seu comportamento para utilizá-lo em previsões, removê-la da série para facilitar a visualização das outras componentes, ou ainda identificar o nível da série (o valor ou faixa típica de valores que a variável pode assumir se não for observado comportamento crescente ou decrescente no longo prazo).

Sazonalidade

Diz-se que uma série temporal é sazonal quando os fenômenos que ocorrem durante o tempo se repete a cada período idêntico de tempo, como flutuações periódicas. Ou seja, fenômenos que ocorrem diariamente em certa hora todos os dias, ou em certo mês em todos os anos. A sazonalidade pode ser *determinística* (quando se pressupõe um padrão sazonal regular e estável no tempo, podendo se prever o comportamento sazonal perfeitamente a partir de dados anteriores) ou *estocástica* (quando a componente sazonal da série varia com o tempo).

Estacionariedade

Estacionariedade Estrita:

Um processo estocástico $\{Y(t),\ t \in T\}$ é estritamente estacionário, se e somente se, as propriedades das variáveis Y(t) não se modificam por uma translação na origem do tempo ($T = \mathbb{R}$), isto é

$f(y_t, y_{t+1}, \ldots, y_{t+j}) = f(y_t, y_{t+k}, y_{t+k+1}, \ldots, y_{t+k+j})$, $\forall$ k , j (k e m valores inteiros).

k = período de translação (intervalo)
j = indexação

Dessa forma, a informação que temos sobre a relação da distribuição conjunta de y_{t+1} e $y_1, y_2, \ldots y_t$, faz com que seja possível prever o provável valor de yt+1.

Estacionariedade fraca :

Um processo estocástico $\{Y(t),\ t \in T\}$ é fracamente estacionário, se e somente se:

(i) $E[Y(t)] = j(t)$, é constante, para $\forall\ t \in T$;
(ii) $E[Y^2(t)] < \infty$, para $\forall\ t \in T$;
(iii) $Cov[Y_{(t1)}, Y_{(t2)}]$ é uma função de $(t_1\text{-}t_2)$.

Um processo fracamente estacionário também é chamado de processo de segunda ordem estacionário. Nesses processos, $Var[Y(t)] = \sigma^2 < \infty$, para $\forall$ t .

Informalmente, uma série temporal é dita (fracamente) estacionária quando ela se desenvolve no tempo aleatoriamente ao redor de uma média constante, refletindo alguma forma de equilíbrio estável. Isto é, suas características do comportamento do processo não são alteradas no tempo, sem apresentar tendência ou sazonalidade. Uma série pode ser estacionária por períodos curtos ou longos, o que implica uma mudança de nível e/ou inclinação. A classe dos modelos ARIMA será capaz de descrever de maneira satisfatória séries estacionárias e séries não estacionárias que não apresentem um comportamento explosivo. Este tipo de não estacionariedade é chamado homogêneo, quando a série pode ser estacionária, flutuando ao redor de um nível, por um certo tempo, depois mudar de nível e flutuar ao redor de um novo nível e assim por diante, ou então mudar de inclinação. A maioria dos procedimentos de análise estatística de séries temporais supõe que estas sejam estacionárias. Portanto, será necessário transformar os dados originais se estes não formam uma série estacionária. A transformação mais comum consiste em tomar diferenças sucessivas da série original, até se obter uma série estacionária.

Qualitativamente, uma série estacionária é aquela que está em equilíbrio estatístico sem tendência. Já uma série não estacionária é aquela cujas propriedades mudam com o decorrer do tempo. São ilustradas nas Figuras 4.1 e 4.2 gráficos de séries estacionárias e não estacionárias respectivamente (MORETTIN e TOLOI 2006):

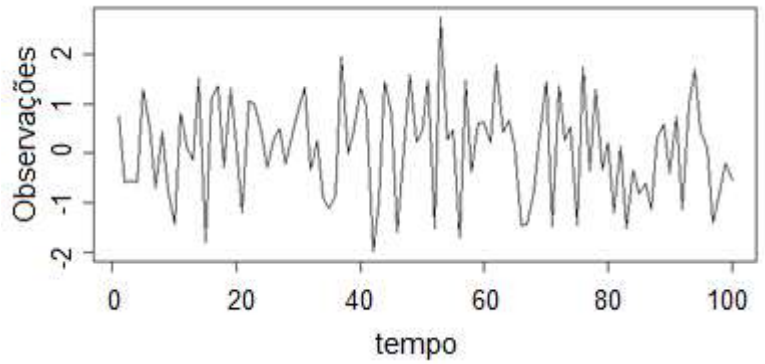


Figura 4.1 - Exemplo de Série Temporal Estacionária

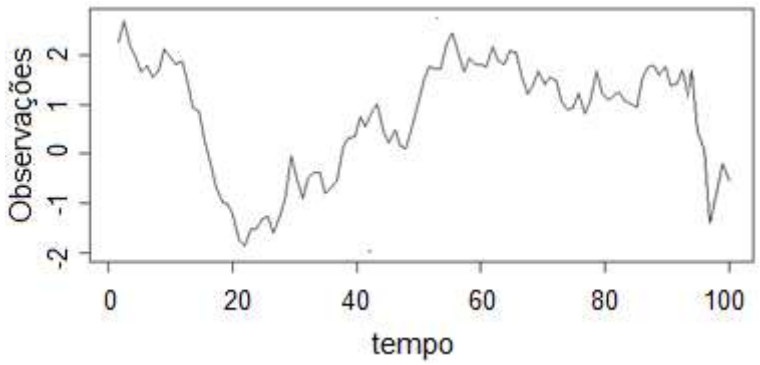


Figura 4.2 - Exemplo de Série Temporal Não Estacionária

Uma série pode ser estacionária por períodos curtos ou longos, o que implica uma mudança de nível e/ou inclinação.

São indicadas a seguir, 7 etapas na análise de séries temporais, sugeridos por Pankratz (2008):

(i) Coletar os dados das séries temporais, com máxima fidedignidade.
(ii) Representar graficamente a série, identificando qualitativamente a presença de tendências e variações cíclicas.
(iii) Construir a curva de tendência.
(iv) Se houver variações por ciclos, desazonalizar a série.
(v) Ajustar os dados desestacionalizados à tendência.
(vi) Representar graficamente as variações obtidas na etapa 5, identificando outras periodicidades eventuais.
(vii) Mediante as combinações das análises anteriores, fazer a previsão do modelo, avaliando as fontes de erro e sua grandeza.

Neste trabalho são avaliados três métodos univariados (Médias Móveis Simples, Alisamento Exponencial Simples e Método Box-Jenkins) e dois métodos multivariados (Regressão Linear Múltipla e Redes Neurais Artificiais), descritos a seguir.

4.2. Método Médias Móveis Simples (MMS)

A média móvel simples é uma das técnicas mais simples usada em tratamento de dados. O principal objetivo da média móvel simples é fornecer o valor médio da observação dentro de um determinado período *m*. Para cada valor incluído no cálculo da média, o valor mais antigo é excluído. Na MMS, cada dado utilizado no

cálculo da média terá o mesmo peso. O seu uso não possibilita uma antecipação das mudanças nas tendências. Com isso, as médias móveis apresentarão sinais de mudanças nas tendências só depois que o movimento já tiver começado, o que faz seu uso ser recomendado em pequenos espaços de tempo. O cálculo é efetuado com a média aritmética simples das *m* observações mais recentes, conforme Equação 4.1:

$$\hat{Y}_t = \frac{Y_{t-1} + Y_{t-2} + \ldots + Y_{t-m}}{m} \tag{4.1}$$

Denota-se por *m* o comprimento da média (também chamado de tamanho da janela da média móvel). A medida que os dados avançam no tempo, a janela também se desloca, daí o nome do método. Tem aplicações para a previsão de curto alcance.

4.3. Método de Alisamento Exponencial Simples (AES)

Uma técnica de previsão simples e comum em séries temporais é a técnica de Alisamento (ou Suavização) Exponencial Simples. O conceito é predizer algum valor futuro Y_{t+k} dada uma história passada $\{Y_1, Y_2, \ldots, Y_n\}$ de observações. É uma técnica simples usada para suavizar e prever uma série de tempo sem a necessidade de ajuste de um modelo paramétrico. É um método baseado em um esquema de algoritmo recursivo, onde as previsões são atualizadas a cada nova observação de entrada (GELPER *et al.* 2008). Apesar de não possuir justificação probabilística seu uso é simples e de bom desempenho em muitas aplicações (MAKRIDAKIS *et al.* 1998). Assim como MMS, suas aplicações são para pequeno alcance.

O modelo requer um grande número de observações, assume que os dados flutuem em torno de uma média razoavelmente estável, isto é, não é adequada para dados que possui um componente sazonal, tendência ou padrão consistente de crescimento (HOLT 2004). A fórmula para Alisamento exponencial simples é expressa pela Equação 4.2:

$$\hat{Y}_t = \alpha Y_{t-1} + (1-\alpha)\hat{Y}_{t-1} \tag{4.2}$$

Na qual:

$\hat{Y}_t$ = Valor estimado no tempo *t*;

α = Coeficiente de ponderação;

Y_{t-1} = Valor observado no tempo (t-1);

Quando aplicado de forma recursiva a cada observação sucessiva na série, cada novo valor suavizado (previsto) é calculado como a média ponderada da observação atual e a observação anterior suavizada. A observação anterior suavizada foi calculada por sua vez a partir do valor observado e o valor anterior suavizado antes da observação anterior e assim por diante. Cada valor suavizado é a média ponderada das observações anteriores, em que os pesos diminuem exponencialmente em função do valor do parâmetro (α). A velocidade com que as respostas anteriores são suavizadas é uma função do valor de (α). Quando α é próximo de 1, amortecimento é rápido e quando α é próximo de 0, amortecimento é lento.

Um método de alisamento mais geral é o de *Holt-Winters* (WINTERS, 1960), que usa médias móveis exponencialmente ponderadas para atualizar estimativas da

(i) média ajustada sazonalmente (nível);
(ii) tendência;
(iii) sazonalidade.

O método de Alisamento Exponencial de Holt-Winters é adequado para séries temporais que apresentam tendência e sazonalidade, que não é o caso das séries avaliadas nesta tese.

4.4. Regressão Linear Múltipla (RLM)

O termo "regressão" foi criado por Francis Galton[5] no final do século XIX. Em seu artigo publicado em 1886, verificou que embora existisse uma tendência de que pais altos tivessem filhos altos e pais baixos tivessem filhos baixos, a estatura média das crianças (agrupadas conforme a altura dos pais) possuía uma tendência a mover-se ou "regredir" à altura média da população como um todo.

Sua proposição foi confirmada por Karl Pearson[6], que analisou dados de mais de 1000 registros nos primeiros anos do século XX.

RLM é uma ferramenta que permite ao pesquisador melhor entender a relação entre os dados que estão sendo estudados. Tem sido utilizada em várias

[5] *FRANCIS GALTON Family likeness in stature , Proceedings of the Royal Society of London, Londres, 1886.*
[6] *KARL PEARSON; LEE, A. On the laws of inheritance, Biometrika, Nov 1903 v.2, p 357-462.*

disciplinas onde a modelagem linear preditiva é necessária (BERRY e FELDMAN 1985). Os modelos de regressão são construídos com os objetivos de:

(i) **Predição** (aplicação mais comum);
(ii) **Seleção de variáveis,** quando se busca identificar quais são as variáveis que afetam significativamente a variação de Y (eliminando aquelas cuja contribuição não seja importante);
(iii) **Estimação de parâmetros**, ou ajustar um modelo aos dados obtendo valores ou estimativas para os parâmetros, tendo por base o modelo proposto e os dados observados;
(iv) **Inferência**, quando busca realizar inferência sobre os parâmetros do modelo usando testes de hipóteses e intervalos de confiança.

Se houver um número de pontos de dados (Y_i, X_{1i}, X_{2i},..., X_{qi}; i = 1, n), com uma variável dependente Y, variáveis dependentes Xj (onde j = 1, 2, 3... q) que pode ser representada pela Equação 4.3:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \ ... + \beta_q x_{qi} + \ \varepsilon_i \qquad (4.3)$$

na qual:
Y_i = variável dependente (ou regressando);
$\beta_0, \beta_1 ... \beta_q$ = Parâmetros da regressão (ou coeficientes da regressão);
$x_1, x_2 ... x_q$ = variáveis independentes (ou regressoras);
ε_i = componente de erro aleatório, independentes, com média zero; variância σ^2 ;

O termo *linear* é usado, pois a Equação 4.3 é uma função linear de parâmetros desconhecidos $\beta_0, \beta_1 ... \beta_q$. O parâmetro β_0 corresponde ao intercepto da curva e os parâmetros $\beta_1 ... \beta_q$ indicam o valor correspondente a uma mudança na resposta média de Y a cada unidade de mudança em x_i, quando as demais variáveis são mantidas fixas.

Para fazer estimativas dos coeficientes do modelo de regressão, podem ser usados os métodos de máxima verossimilhança ou de mínimos quadrados (FOX 1997).

Além da adequada coleta dos dados, existem os pressupostos clássicos da regressão linear múltipla, que podem ser indicados sob várias formas. Alguns pressupostos são necessários para os modelos de RLM, que estão resumidamente indicados:

(i) As variáveis explicativas X_j e o termo de erro são independentes.
(ii) Os erros ε_i são variáveis aleatórias com média zero, variância constante (σ^2), isto é, hipótese de homocedasticidade do termo de erro.

(iii) As variáveis explicativas $X_1, X_2 \ldots X_j$ são independentes e fixas nos experimentos, ou seja, são assumidos como não estocásticos.
(iv) As variáveis explicativas $X_1, X_2 \ldots X_j$ são não correlacionadas, isto é, hipótese de ausência de multicolinearidade entre as variáveis explicativas.
(v) Os erros ε_i seguem uma distribuição normal: $\varepsilon_i \sim N(0, \sigma^2)$.
(vi) O número de observações n deve ser maior que o número de parâmetros.
(vii) Presença de variabilidade dos valores de X (medidos em níveis diferentes).

Se cumpridos estes pressupostos:

A variável Y tem distribuição normal com variância σ^2 e média

$$E\ (Y\ \mathrm{I}\ X\ ) = \beta_0\ + \beta_1 x_1 + \beta_2 x_2\ +\ \ldots + \beta_q x_q +\ \varepsilon_t$$

Os estimadores de Mínimos Quadrados Ordinários (MQO)[7] são considerados os Melhores Estimadores Lineares Não Viesados (BERRY, 1993).

A Figura 4.3 ilustra um modelo de regressão linear simples, mostrando a variância constante, homocedasticidade e distribuição condicional dos termos de erros (GUJARATI, 2004):

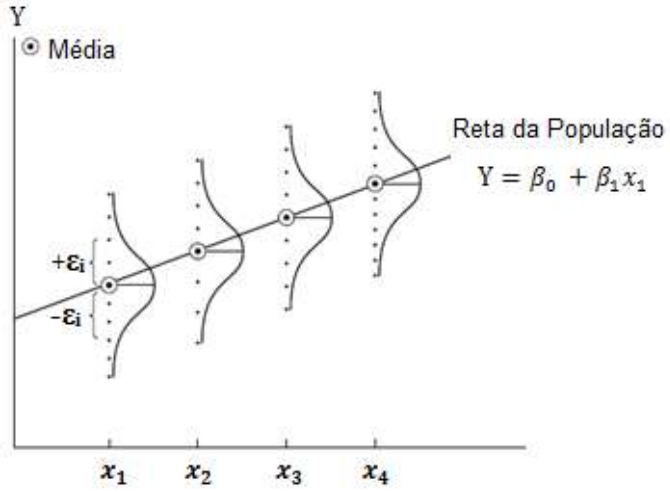


Figura 4.3: Distribuição dos termos de erros em regressão linear simples

Existem controvérsias em relação ao "atendimento absoluto" a todas as hipóteses. Alguns autores questionam a relevância das mesmas no cômputo dos modelos. Como exemplo, para Lewis-Beck (1980), violar a suposição da

[7] *MQO Mínimos Quadrados Ordinários: Técnica matemática que busca o melhor ajuste para um conjunto de dados, minimizando a soma dos quadrados das diferenças entre o valor estimado e os dados observados.*

homocedasticidade faz com que as estimativas dos mínimos quadrados continuem não-viesados, mas perdem a propriedade de melhores estimadores dos parâmetros populacionais.

Importante registrar que as unidades do regressando e regressor afetam a interpretação dos coeficientes. Isso pode ser evitado se expressarmos ambos com variáveis padronizadas. Diz-se que uma variável é padronizada se subtrairmos o valor médio da variável de seus valores individuais e dividirmos a diferença pelo desvio padrão dessa variável. Terá média zero e desvio padrão igual a 1.

4.5. Método Box-Jenkins de Séries Temporais (ARIMA)

Conforme reportam Makridakis (1976) e Espasa (1991), a era moderna em séries temporais iniciou com G. Yule[8] (1927), introduzindo conceitos de processos auto-regressivos até segunda ordem. Em seguida, A. Walker[9] (1931) estabeleceu um esquema geral de processos autorregressivos e E. Slutski[10] (1937) desenvolveu modelos gerais de médias móveis. A integração dos modelos propostos por Yule e Slutski se realiza com H. Wold[11] (1938), que estabelece uma formulação geral para processos mistos autoregressivos e médias móveis (ARMA). Séries temporais ARMA são baseadas somente sobre o passado da própria variável para fins de previsões, ou seja, não é baseado em teorias ou propriedades do objeto estudado.

Durante a década de 1960 os professores *George Edward Pelham Box* e *Gwilym Meirion Jenkins* desenvolveram vários pesquisas sobre a teoria de controle e análise de séries temporais. Em 1970 publicam o livro *Time Series Analysis, Forecasting and Control* apresentando uma metodologia para a análise de séries temporais, e em 1976 foi lançada a versão revisada deste, que é normalmente a mais mencionada. O grande mérito desse trabalho foi reunir as técnicas existentes numa metodologia para construir modelos que descrevem de forma parcimoniosa o processo

---

[8] *Yule, G. U. (1927). On the method of investigating periodicities in disturbed series, with special reference to Wôlfer's sunspot numbers. Philosophical Transactions, A, 226, 267-298.*
[9] *Walker, A. M. (1931). On the periodicity in series of related terms. Proceedings of the Royal Society of London, A, 131, 518-532.*
[10] *Slutsky, E. (1937). The summation of random causes as the source of cyclic processes. Econometrica, 5, 105-146.*
[11] *Wold, H. (1938). A Study in the Analysis of Stationary Time Series. Almqrist & Wiksell, Stockholm (1 ed. 1938).*

gerador da série temporal, proporcionando previsões acuradas de valores futuros com os modelos auto regressivos AR e de média móvel MA.

Embora estes modelos fossem já conhecidos, a contribuição de Box e Jenkins foi o desenvolvimento de um processo sistemático de identificação e estimação de modelos que incorporam simultaneamente ambas as características. Apesar de não terem sido os autores da metodologia e nem os pesquisadores mais importantes neste domínio, Box e Jenkins muito contribuíram para difundir o conceito e aplicações dos modelos ARMA. Por isto, os modelos ARMA são também chamados indistintamente de modelos Box-Jenkins, e são bem aplicados para previsões de curto prazo (PANKRATZ 2008).

Interessante registrar que tendo concluído seus estudos na Inglaterra, *George Box* iniciou sua carreira na *Imperial Chemical Industries* em Londres. Após sua mudança para os Estados Unidos na década de 1950, um das primeiras atividades na academia foi no Departamento de Engenharia Química da Universidade de Princeton na área de catálise e também no Departamento de Engenharia Química da Universidade de Wiscosin, com o professor Olaf Hougen em apoio ao desenvolvimento de modelos estatísticos aplicados (PENA 2001).

Da mesma forma, o escocês *Gwilym Jenkins* concluiu sua graduação em matemática em 1953 e o *Ph. D.* em 1956 na *University College London*. Serviu na força aérea britânica e em seguida iniciou sua carreira como pesquisador, tendo realizado suas primeiras atividades com modelos de domínios discretos com aplicações em Engenharia Química na Universidade de Lancaster, Reino Unido, em meados da década de 1960.

Modelos Autorregressivos (AR)

Num processo autorregressivo, o valor presente da série temporal Y_t é expresso linearmente em termos dos valores passados da série e da perturbação aleatória ocorrendo no instante t. A equação do modelo autorregressivo de ordem p, é dada pela Equação 4.4:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t \qquad (4.4)$$

em que ϕ_i são parâmetros desconhecidos a serem estimados; os erros ε_t são independentes, tem distribuição normal, com média zero e variância σ^2 para todo t de valores independentes; $\{\varepsilon_t\}$ é uma série ruído branco[12]; p é a ordem do processo. Um modelo autorregressivo é simplesmente uma regressão linear do valor corrente da série sobre um ou mais dos valores anteriores da série. Por isso, estes modelos podem ser criados usando a técnica dos mínimos quadrados, e têm uma fácil interpretação.

Modelos de média móvel (MA "*Moving Average*")

Num processo dito de média móvel, o se expressa em função dos valores presente e passada das perturbações aleatórias, que formam uma série de ruído branco. A ordem deste processo depende do valor mais antigo da série de ruído branco considerado. Para um processo de média móvel de ordem q, a série é descrita como Equação 4.5:

$$Y_t = \delta - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} + \varepsilon_t \qquad (4.5)$$

Em que δ é uma constante a ser estimada, e os vários θ_j são parâmetros desconhecidos a serem estimados dos modelos MA. Um modelo de média móvel constrói-se como uma regressão linear do valor presente da série sobre as perturbações aleatórias de um ou mais valores anteriores da série. Admite-se que estas perturbações são geradas por uma mesma distribuição, habitualmente normal, de média e desvio padrão constante. Este modelo difere do anterior na medida em que cada perturbação aleatória se propaga para os valores futuros da série.

Vale notar portanto, que o termo "média móvel" aqui utilizado se dá porque a série é uma função soma algébrica ponderada dos termos de erro que se movem no tempo. Mas o nome não se aplica ao comumente usado no conceito literal de médias móveis simples sucessivas. Para a língua portuguesa, talvez o nome mais apropriado ao conceito fosse de "erro móvel".

---

[12] *Ruído branco : Processo em que os dados da série não dependem do seu passado, isto é, apresentam todas autocorrelações nulas (Anexo 3.4).*

Modelos autorregressivos e de média móvel (ARMA)

O processo de Box-Jenkins dito de tipo ARMA combina os dois efeitos Autorregressovp e Média Móvel. Em um processo de ordem (p,q) o valor presente da série temporal Yt representa-se pela Equação 4.6:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (4.6)$$

em que :

$\delta = \mu\,(1 - \sum_{i=1}^{p} \phi_i)$; μ a media do processo;

$\phi_1, \ldots, \phi_p$ = parâmetros estimados do modelo AR;

$\theta_1, \ldots, \theta_q$ = parâmetros estimados do modelo MA;

ε_t = Componente do erro aleatório $\left(Y_t - \hat{Y}_t\right)$. Os erros são assumidos como tendo distribuição normal, média zero, variância constante e não correlacionados (ruído branco).

No processo ARMA a condição de invertibilidade significa que a parte MA do modelo pode ser invertida em modelo AR (puro). Um processo estacionário e invertível pode representar-se na forma autorregressiva ou na forma média móvel. As condições de invertibilidade e estacionariedade estabelecem restrições aos valores das estimativas dos parâmetros dos modelos. Para a estimação desses parâmetros são obtidas inicialmente suas estimativas preliminares.

As estimativas preliminares dos parâmetros dos modelos de séries temporais AR, MA ou ARMA nem sempre são estacionárias, precisando cumprir certos requisitos de estacionariedade e invertibilidade apresentados na Tabela 4.1:

Tabela 4.1 - Condições de estacionariedade / invertibilidade

Processo	**Condições necessárias**
AR	AR(1) : $-1 < \phi < 1$
	AR(2) : $\phi_1 + \phi_2 < 1$; $\phi_2 - \phi_1 < 1$; $-1 < \phi_2 < 1$
MA	MA(1) : $-1 < \Theta < 1$
	MA(2) : $\Theta_1 + \Theta_2 < 1$; $\Theta_2 - \Theta_1 < 1$; $-1 < \Theta_2 < 1$
ARMA	ARMA (1,1) : $-1 < \phi < 1$; $-1 < \Theta < 1$

Modelos autorregressivos integrados e de média móvel (ARIMA)

O modelo de Box-Jenkins assume que a série é estacionária (quando a média da série e as covariâncias entre as suas observações não variam com o tempo). Se o processo não for estacionário, deve-se proceder a sua desestacionarização, que pode ser obtida com operações de diferenciação (mesmo que aplicada sucessivas vezes) ou por aplicação de logaritmo à série. À série estacionarizada aplica-se então um modelo ARMA (p,q). O modelo ARIMA (p,d,q) corresponde então a um processo autorregressivo (*de ordem p*) integrado (*de ordem d*) com média móvel (*de ordem q*). A designação "integrado" explica-se pelo fato de se reconstruir a série original a partir da série diferenciada, por uma operação de integração ou soma recursiva. A metodologia de Box-Jenkins refere-se ao método sistemático de identificação, ajuste, checagem e uso de modelos autorregressivos integrados à média móvel ou, simplesmente, modelos ARIMA. Um dos processos fundamentais na metodologia de Box-Jenkins é transformar uma série não estacionária em uma estacionária, obtendo dessa maneira, a estabilidade dos parâmetros estimados.

Função de Autocorrelação (FAC) e Função de Autocorrelação Parcial (FACP) são duas ferramentas importantes nos procedimentos ARIMA, a seguir definidas:

Função de Autocorrelação (FAC)

A função de autocorrelação mede o grau de correlação de uma variável, em um dado instante, consigo mesma, em um instante de tempo posterior. Isto é, ela informa quanta interdependência há entre observações em uma série temporal, medindo a dependência linear entre uma função Yt e Yt+k. Graficamente a correlação existente é mostrada pelo correlograma[13] que desenha a FAC (função de autocorrelação). Em estatística, autocorrelação é uma medida que informa o quanto o valor de uma realização de uma variável aleatória é capaz de influenciar seus vizinhos. O valor da autocorrelação está entre 1 (correlação perfeita) e -1 (anti-correlação perfeita). O valor 'zero' significa total ausência de correlação. É definida como a razão entre a autocovariância e a variância para um conjunto de dados. Supondo-se uma variável

[13] *Correlograma : Gráfico que mostra a estrutura de dependência entre os dados FAC e FACP (Anexo 3.1).*

aleatória Y_t discreta estacionária, dependente do tempo, com média $\bar{y}$, sua autocorelação *r (k)* é definida como:

$$r(k) = \frac{\sum_{t=1}^{n-k}(y_t-\bar{y})(y_{t+k}-\bar{y})}{\sum_{t=1}^{n}(y_t-\bar{y})^2} \quad (4.7)$$

Autocorrelação Parcial (FACP)

As autocorrelações para intervalos sucessivos são formalmente dependentes. Considerando que o primeiro elemento da série está fortemente relacionado com o segundo, e o segundo com o terceiro, então o primeiro está de alguma forma também relacionado com o terceiro elemento. Para obter uma informação sobre autocorrelações na série sem esta influência em cascata, definiu-se o conceito de função de autocorrelação parcial. Na caracterização da série, além da autocorrelação, utiliza-se a função de autocorrelação parcial (FACP). Trata-se da correlação entre observações vizinhas em uma série temporal removendo a correlação dos outros vizinhos. A idéia da é mensurar o quanto Yt e Yt-k estão relacionados, mas sem os efeitos dos Ys intermediários, isto é a autocorrelação parcial na posição *k* é a autocorrelação entre $Y_{(t)}$ e $Y_{(t-k)}$ que não foi considerada nas posições *(1)* até *(k-1)*. O seu cálculo é mais elaborado do que a função de autocorrelação, sendo usadas as equações de Yule-Walker (descritas em BOX e JENKINS 1994, p.57). A FACP é útil para determinar a ordem de um processo AR ou da parte AR de um processo ARMA(p,q). Se o gráfico da FAC indicar que um modelo AR pode ser apropriado, então o gráfico de autocorrelação parcial amostral é examinado para ajudar identificar a ordem (*Anexo 3.1*).

A estratégia utilizada para a construção de modelos, pela metodologia Box-Jenkins, é baseada no ciclo iterativo conforme Figura 4.4, no qual a estrutura do modelo é formada pelos próprios elementos da série. A descrição de cada uma das dessas principais etapas é apresentada a seguir:

Identificação do modelo: certificar-se de que a série é estacionária, identificando sazonalidade na série (diferenciando se for o caso). Usar gráficos das funções FAC e FACP da série visando estimar a ordem dos componentes autorregressivos (AR) e média móvel (MA) a serem usados no modelo.

Estimação dos parâmetros: Usando métodos estatísticos implementados em algoritmos de cálculo para determinar os coeficientes que melhor se ajustam ao modelo ARMA

selecionado. Estes parâmetros podem ser estimados por métodos MQO ou por máxima verossimilhança.

Verificação: Testar se o modelo estimado está em conformidade com as especificações teóricas. Em particular, os resíduos devem ser independentes, média zero e variância constante ao longo do tempo. A distribuição normal também é necessária para realizar inferências estatísticas. Se a estimativa não estiver bem ajustada aos dados, faz-se necessário voltar para a primeira etapa para construir um modelo melhor.
Além destes três passos, é importante para validar o modelo obtido através de um novo conjunto de dados, a fim de confirmar a capacidade preditiva do modelo para observações futuras.

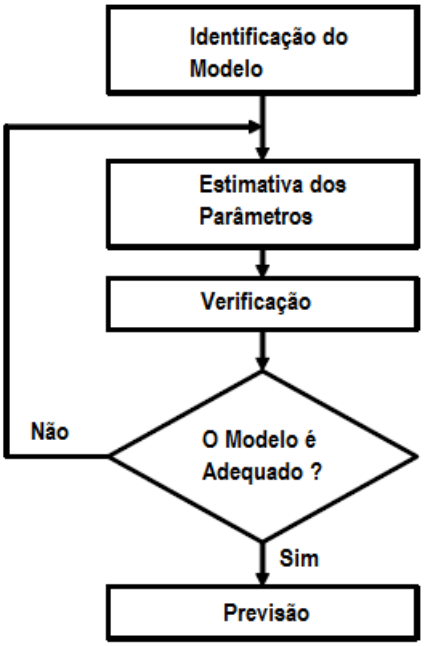


Figura 4.4 – Fluxograma do ciclo iterativo de Box – Jenkins

4.6. Redes Neurais Artificiais (RNA)

Redes Neurais Artificiais (RNA) são técnicas empíricas inspiradas na estrutura neural de organismos vivos, pois aprendem o comportamento de um sistema por meio de exemplos. As RNAs são sistemas computacionais estruturados, capazes de aprender os padrões existentes em um conjunto de dados e de generalizá-los (BRAGA *et al.* 2007). Sua aplicação tem sido as mais diversas, como em problemas de classificação, categorização de dados, aproximação, previsão e controle não linear dentro das diferentes áreas do conhecimento, quando modelos fenomenológicos não estão disponíveis. A literatura tem reportado várias aplicações no campo da engenharia química descrevendo o uso de RNA em detecção de falhas, processamento de sinais,

modelagem e controle (RUDD 1991; BULSARI 1995; SATO et. al 1999, HIMMELBLAU 2000). Podem ser usadas nos problemas de predição, de controle ou de classificação. Robustez, facilidade de uso (embora com sofisticadas técnicas de modelagem) em diferentes campos de aplicação são as principais razões de sucesso das RNA.

RNA são modelos formados por unidades de processo (chamados nós ou neurônios) que são ordenados em camadas interligadas. A principal propriedade é a sua capacidade de aproximar funções não lineares no espaço multidimensional. Das muitas topologias, a rede mais comum usada para modelagem de processos é a rede neural *Feedforward*, onde informações percorrem exclusivamente da entrada para os nós de saída. Para aproximações funcionais não lineares, rede *Feedforward* com funções de uma camada oculta e do tipo sigmoidal de ativação são as estruturas mais comuns (FAUSETT 1994). As ligações entre os nós de rede deste tipo são transmitidas para frente, a partir de cada neurônio na camada de um para todos os neurônios na camada seguinte, como mostrado na Figura 4.5.

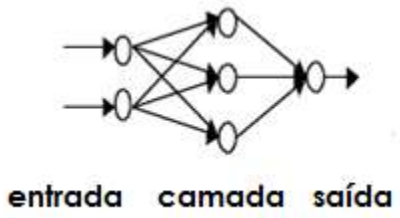


Figura 4.5- Informação de transferência da RNA *Feedforward*

A camada de entrada serve para introduzir os valores das variáveis de entrada. Os neurônios da camada são ocultos, sendo cada um ligado a todas as unidades da camada anterior. Cada unidade executa uma soma ponderada de suas entradas e passa este nível de ativação através de uma função de transferência para produzir sua saída. A partir de dados e algoritmos de treinamento representativos, a RNA pode aprender a estrutura dos dados, e então ser aplicável em situações que existe uma relação entre as entradas e as variáveis previstas, mesmo quando a relação for complexa para ser descrita por métodos explícitos. Um modelo de RNA recebe um número de entradas, cada uma com um peso ponderado. A soma ponderada de todas as entradas é formada para compor a ativação do neurônio. O sinal de ativação é transmitido através de uma função de transferência para produzir a saída. Os neurônios de entrada,

intermediários e de saída precisam ser conectados em conjunto (BISHOP, 1994). Uma ilustração de um neurônio artificial é mostrada na Figura 4.6, onde são identificados alguns elementos básicos do modelo neural (HAYKIN, 2001):

- Sinapses (ou camada de entrada), caracterizadas por seus pesos;
- Sinal xj na entrada da sinapse, conectada ao neurônio ***k*** é multiplicado pelo peso sináptico ***w*** ;
- Junção aditiva responsável pela soma ponderada dos sinais de entrada;
- Função de ativação que restringe a amplitude da saída do neurônio e limita o intervalo permissível de amplitude do sinal de saída. Podem ser do tipo linear e não linear.
- *Bias* aplicadas externamente, representado por bk, que tem o efeito de aumentar, ou diminuir a entrada líquida da função de ativação.

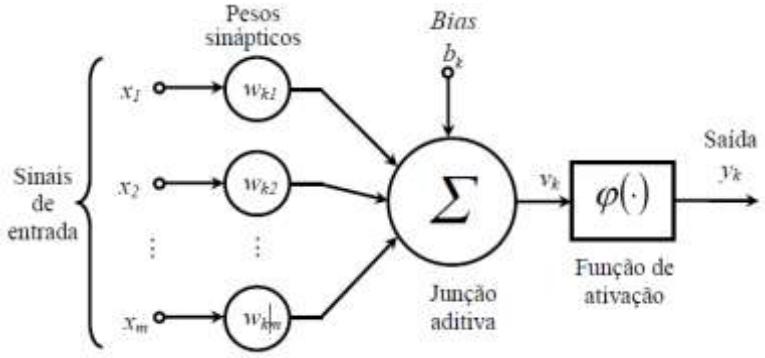


Figura 4.6 - Modelo de um neurônio artificial

Um requisito importante para o uso de uma RNA é que deve existir uma relação entre as entradas e saídas propostas. Outra característica fundamental é que aprendam a relação de entrada/saída por meio de treinamento (que normalmente é feito a partir de registros históricos). A quantidade e qualidade dos conjuntos de treinamento são essenciais para as simulações da rede. Esta fase é caracterizada pela extração de informações dos padrões de entrada apresentados à rede, em um processo iterativo de ajustes de parâmetros (pesos das conexões) da rede. Os algoritmos de treinamento podem ser classificados como supervisionados, que são aqueles em que padrões de entrada e as saídas calculadas são comparadas com a saída desejada (dados medidos). Tal algoritmo é usado para resolução de problemas de previsão e aproximação de funções. Quando redes utilizam algoritmos em que apenas padrões de entrada são

usados no seu treinamento, este é chamado de não supervisionado. Este tipo de aprendizado se aplica a problemas de identificação de agrupamentos, ou classes (BRAGA *et.al.* 2007). Multicamadas Perceptrons (MLP- *Multi Layer Perceptron*) é a arquitetura de rede mais comum em uso e discutida amplamente na maioria dos livros de redes neurais (HORNIK *et al.* 1989).

Número de Camadas e Neurônios

A estrutura de uma rede MLP é definida pelo número de camadas ocultas, número de neurônios em cada camada e a forma de conexão entre os neurônios (com ou sem recorrência).

Uma quantidade inadequada de neurônios numa rede pode comprometer sua capacidade de generalização. Se o número de parâmetros são insuficientes dificulta obter uma boa convergência durante o treinamento. Por outro lado, uma rede com número elevado de neurônios em relação à quantidade de dados disponíveis para treinamento, pode perder sua boa representação, tendo sua capacidade comprometida. Redes superdimensionadas geram uma boa representação apenas do conjunto de treinamento, ou seja, ela passa a ter sua capacidade de generalizar comprometida. Este comportamento é chamado de sobre-ajuste (*overfitting* ou *overtraining*), que se caracteriza por erros muito baixos para os dados de treinamento, mas erros elevados quando novos dados são compilados (TETKO *et al.* 1995).

O número de unidades de entrada e de saída é definido pelo problema. Especial atenção deve ser dada à escolha das variáveis de entrada/saída, de modo que a rede seja obtida e treinada adequadamente.

O número de camadas ocultas depende da complexidade da relação entre as entradas e saídas. Contudo, a maior parte dos problemas necessita de apenas uma camada oculta, e raros são os problemas práticos que demandam mais que duas camadas (FENG *et al.* 2005; BRAGA *et al.* 2007).

A determinação da quantidade adequada de neurônios é um dos desafios do processo de investigação. Hecht-Nielsen (1987), sugere a aplicação da Equação 4.8 para o limite máximo do número de neurônios, visando garantir que a RNA seja capaz de aproximar a uma função contínua:

$$N_o \leq (2N_e + 1) \tag{4.8}$$

Em que *No* é o número de neurônios na camada oculta, e *Ne* o número de entradas. Além disso, alguns autores sugerem que a relação entre o número de dados para treinamento e a quantidade de neurônios usados deve ser levada em consideração. Para garantir que a rede não apresente o problema de sobre ajuste, recomenda-se que o limite máximo de neurônios na camada oculta atenda ao critério da Equação 4.9 (ROGERS e DOWLA, 1994 *apud* MAIER e DANDY, 2001):

$$N_o \leq N_{TR}/(N_e + 1) \tag{4.9}$$

Em que N_{TR} é o número de dados para treinamento.

Maier e Dandy (2001) reportam que o número máximo de neurônios na camada oculta deve ser o menor dos obtidos entre as equações 4.8 e 4.9. Registram ainda que de uma forma geral, o uso de tentativas e erros é muito comum, sendo que em muitos casos se obtém bom desempenho da rede com número de neurônios muito menores que os limites indicados das equações 4.8 e 4.9.

Sheela e Deepa (2013) realizaram uma revisão dos diferentes métodos propostos nas últimas duas décadas para este desafio. Thomas *et al.* (2015) publicaram alternativas e métodos, citando desde regras gerais como "o número de neurônios na camada oculta é um valor entre o número de neurônios de entrada e de saída" até equações sofisticadas de aplicação.

Uma vez que o número de camadas e neurônios em cada camada for selecionado, os pesos da rede devem ser fixados de modo a minimizar o erro de predição. O erro de uma configuração particular da rede pode ser determinado através da execução de todos os casos de formação da rede, comparando os resultados reais gerados com os produtos desejados. Por conseguinte, o algoritmo progride de forma iterativa, através de um número de épocas. Em cada época, os passos de formação são submetidos à rede e saídas alvo, sendo comparados com o erro calculado. Este erro é usado para ajustar os pesos e, em seguida, o processo repete-se. A configuração de rede inicial é aleatória e a formação geralmente para quando um determinado número de épocas decorre ou quando o erro para de melhorar.

Segundo Haykin (2001) o projeto de uma RNA passa pelas etapas de seleção da arquitetura (definição da quantidade de neurônios de entrada, ocultos e de saída); treinamento da rede (a partir de um conjunto de dados iniciais); validação da rede treinada (a partir da avaliação das respostas da rede mediante a apresentação de

dados não utilizados durante o treinamento). A capacidade de reconhecer e reproduzir relações de causa e efeito através da formação, filtragem de dados de ruído ou irrelevantes, bem como a possibilidade de trabalhar com múltiplos vetores de entrada e saída, fazem as RNA serem eficientes na modelagem de processos complexos.

4.7. Relações entre RNA e Métodos Estatísticos

O uso de modelos de Redes Neurais Artificiais (RNA) tem sido adotados por diferentes profissionais em vários campos, e não raro com aplicações associadas às abordagens tradicionais estatísticas. Alguns autores reportam as relações entre os modelos RNA com uma perspectiva estatística (HILL *et al.* 1994; CHENG e TITTERINGTON 1994; RIPLEY 1993). Esses estudos indicam que certos modelos obtidos quando a arquitetura da RNA é alterada, são equivalentes ou muito próximos aos modelos estatísticos clássicos, tais como regressão linear, regressão não paramétrica, regressão logística, funções discriminantes, probabilidades Bayesianas, análise de componentes principais etc.

Outros autores sugerem que alguns modelos RNA são semelhantes aos modelos de séries temporais do tipo Box-Jenkins. Dentre eles, Faraway e Chatfield (1998) compararam a clássica série de Box e Jenkins (1976) do número de passageiros em aviões nos modelos ARMA e RNA. Concluíram da maior complexidade nas RNA, quanto a seleção das variáveis de entrada, arquitetura da rede e recursos computacionais quanto aos modelos ARMA. Connor *et al.* (1994) mostraram que as redes neurais *Feedforward* são casos especiais de modelos autorregressivos não lineares e que as redes neurais recorrentes são um caso especial de modelos média móvel autorregressivo não linear. Chon e Cohen (1997) demonstraram a equivalência de modelos ARMA e RNA *Feedforward* usando funções de transferência polinomiais. SARLE (1994) reporta ainda que ao contrário de alguns modelos estatísticos, modelos RNA podem ser facilmente estendidos a partir de modelos univariados para multivariados. Vários autores realizaram estudos buscando comparar as técnicas tradicionais de séries temporais com RNA, dentre eles Makridakis *et al.* (1982), Barron (1989), Hill *et al.* (1994).

Conforme reportam Maier e Dandi (2000), de uma forma geral, as redes neurais têm suas origens na inteligência artificial, tendo sido desenvolvidos por engenheiros e cientistas da computação, resultando em diferenças na terminologia entre os modelos estatísticos tradicionais. Por esta razão, um pequeno glossário da terminologia usada em RNA e seus equivalentes na terminologia estatística, foram propostos por Sarle (1994) e estão sumarizados na Tabela 4.2:

Tabela 4.2 - Equivalência de terminologia RNA e estatística

Terminologia RNA	***Terminologia Estatística***
Características	Variáveis
Entrada	Variável Independente
Saída	Valor Predito
Valores Treinamento	Variável Dependente
Erros	Resíduos
Treinamento	Estimação
Função Erro	Critério de Estimação
Pesos	Parâmetros de Estimação
Generalização	Interpolação / Extrapolação
Links Funcionais	Transformações
Treinamento supervisionado	Regressão / An. Discriminante
Aprendizagem competitiva	Análise Cluster

4.8. Análise e Validações dos Modelos

Existem vários índices estatísticos para análise e validação de modelos. A comparação dos valores estimados pelos modelos ($\hat{Y} = Y_{ESTIMADO}$) com os valores reais da série ($Y_{OBSERVADO}$) caracteriza a capacidade preditiva do método utilizado. Foram utilizados nos Capítulos 5 e Capítulo 6, os índices indicados a seguir:

MAD	*Mean Absolute Deviation*	Desvio Absoluto Médio
MAPE	*Mean Absolute Percentual Error*	Erro Absoluto Percentual Médio
MPE	*Mean Percentual Error*	Erro Percentual Médio
RMSE	*Rooted Mean Squared Error*	Raiz do Erro quadrado médio
AIC	*Akaike Information Criterion*	Critério de Informação de Akaike
BSC	*Bayesian Schwarz Criterion*	Critério Bayesiano de Schwarz
DW	*Durbin Watson*	Índice Durbin Watson
TIC	*Theil Inequality Coeficient*	Coeficiente de Desigualdade de Theil

Para a etapa de validação, os modelos foram analisados de acordo com os mesmos critérios estatísticos de decisão para a etapa de elaboração MAD, MAPE e RMSE. A confiabilidade é medida através do MAD e MAPE. A precisão[14] é medida através do RMSE. Um benefício do RMSE é que ele é medido nas mesmas unidades que os dados originais. Por outro lado, grandes erros influenciam significativamente seu resultado (MAKRIDAKIS e HIBON, 1995). Estes critérios e medidas para escolha entre modelos são discutidos em diferentes livros de estatísticas (MAKRIDAKIS 1998, BOWERMAN 2005).

Detalhes conceituais dos referidos índices, fórmulas de cálculo e sua interpretação estão descritas no *Anexo 3.2.*

Em todos os modelos, a validação foi realizada mantendo fixos os parâmetros estimados e fazendo previsão a um passo, atualizando os valores observados necessários para a implementação de cada previsão.

São apresentadas no Capítulo 5 as aplicações dos métodos univariados para predição da densidade de cavaco, a fim de melhorar a acurácia[15] do valor da mesma quando aplicada ao controle do fluxo de licor branco do digestor.

[14] *Precisão: Proximidade entre os valores obtidos pela repetição do processo de mensuração.*
[15] *Acurácia : proximidade da medida relativamente ao verdadeiro valor da variável*

Capítulo 5

Predição da Densidade do Cavaco ao Digestor

" c'est une vérité très certaine que, lorsqu'il n'est pas en notre pouvoir de discerner les plus vraies opinions, nous devons suivre les plus probables "

"é uma verdade muito certa que quando não está em nosso poder para determinar o que é verdadeiro, devemos seguir o mais provável"



Rene Descartes
(1596 – 1650)
Matemático e Filósofo Francês

Capítulo 5

Predição da Densidade do Cavaco ao Digestor

Neste capítulo, analisam-se alternativas para mitigar uma situação problema presente no sistema de alimentação dos digestores contínuos, que não possuem analisadores eficientes de densidade a granel de cavaco em linha. Esta variável é usada no cálculo do fluxo mássico de licor branco de cozimento. De uma forma geral a amostra de cavaco é coletada na alimentação do digestor e o tempo de análise demanda aproximadamente 4 horas. Isto é, após o resultado estar disponível ao operador do equipamento, o cavaco analisado já foi processado, tornando-se interessante o uso de alguma metodologia de predição do seu valor, em vez da aplicação direta do resultado da análise de um material coletado com 4 horas de retardo.

Pelas dificuldades de obtenção de dados da madeira após sua colheita na floresta, bem como dificuldades de controlar os respectivos tempos de armazenagem até alimentação do digestor, faz-se necessário trabalhar com uma metodologia de predição univariada, ou seja, com uma única variável dependente. São apresentadas a seguir três abordagens aplicadas para predição da densidade de cavacos alimentados ao digestor contínuo, visando redução do erro da mesma aplicada ao cálculo do fluxo de licor branco de cozimento. São avaliados os métodos de Média Móvel Simples (MMS), Alisamento Exponencial Simples (AES) e Método Box-Jenkins de séries temporais (ARMA).

5.1. Introdução

Na planta de cozimento, um dos problemas que dificulta o bom monitoramento é o controle de variáveis que não são medidas instantaneamente. Estas, de uma forma geral, são obtidas a partir de amostras periódicas e que demandam tempo de análise em laboratório. Em consequência, os ajustes no processo são feitos com um tempo de atraso. O controle do fluxo mássico do álcali presente no licor branco alimentado ao digestor é um exemplo desta característica de problema.

O álcali efetivo presente no licor branco é consumido nas reações químicas com a lignina, carboidratos, ácidos orgânicos e resinas ou é adsorvido por fibras de celulose (KOKUREK *et al.*, 1989). No digestor contínuo, variáveis de processo são medidas em diferentes frequências. Como exemplo, a densidade do cavaco não tem a mesma frequência do fluxo de licor branco, concentrações de álcali, etc. Quanto mais densa a madeira, maior é a quantidade de paredes celulares e menor a quantidade de espaços vazios. Madeiras densas possuem menores espaços para a entrada de líquidos, menores porosidade e capilaridade, dificultando a penetração e difusão do licor branco. Conforme reporta Foelkel (2015a), a porosidade natural da madeira é constituída pela capilaridade dos lúmens de suas células (vasos, fibras, células parenquimatosas, etc.). Além desses, existem os micro capilares nas paredes, tais como as pontuações e os pequenos canais entre fibrilas. São ainda comuns as microfissuras e micro fraturas nas paredes e entre as células da madeira. Esses tipos de fissuras são comuns nos cavacos e menos comuns na madeira em toras. É indicada na Figura 5.1 microfotografia indicando os espaços vazios das fibras e vasos (FOELKEL, 2015a).

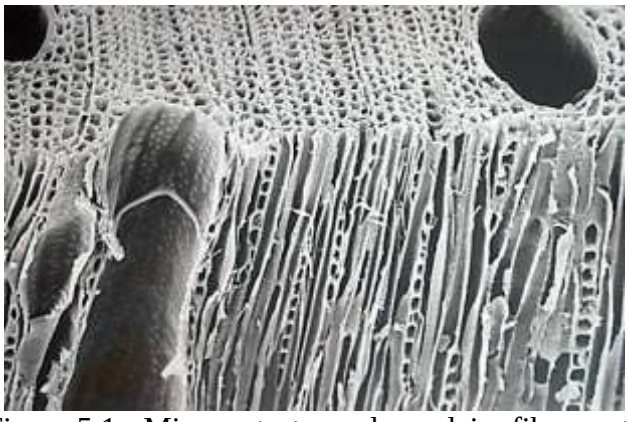


Figura 5.1 - Micro estruturas de madeira fibra curta

Variações da densidade da madeira de eucalipto ocorrem em níveis de estrutura anatômica, composição química e propriedades físicas (TOMAZELLO, 1994). Não há senso comum entre os efeitos desta variável da madeira no processo. Alguns autores reportam que esta propriedade é a que mais oferece informações sobre as demais características deste material (SHIMOYAMA e BARRICHELO, 1989). Dentre outros, Queiroz *et al.* (2004) analisaram a influência da densidade da madeira na qualidade da polpação Kraft e nas características da polpa, demanda de álcali para polpação, rendimento, características do licor residual, branqueabilidade e as

propriedades físico-mecânicas da polpa branqueada. Sabe-se que a densidade básica (*Anexo 2.8*), apesar de muito importante, não é a única propriedade a definir a qualidade de uma espécie ou tipo de madeira para fins industriais na produção de celulose (FOELKEL *et al.* 1990).

Já a densidade anidra a granel dos cavacos, é um dos principais indicadores de qualidade do cavaco em fábricas de celulose e papel. É calculada pela relação indicada na Equação 5.1 :

Densidade de cavacos = Massa absolutamente seca / Volume em condições padronizadas de ensaio (5.1)

É usada para determinar a massa em uma base livre de umidade por unidade de volume de cavacos. Como é realizada em laboratório, apresenta valores discretos conforme a frequência especificada pelo usuário. A análise necessita ser executada em condições bem determinadas, visto que é afetada pela dimensão e forma do recipiente de ensaio e pela compactação dos cavacos no mesmo. O arranjo dos cavacos depende das suas dimensões, da umidade, da altura de queda, da velocidade como caem, da compactação sobre eles etc. (FOELKEL 2015b).

O álcali é o principal reagente químico no processo do cozimento e sua quantidade é muito importante no digestor (MACLEOD 2007). O fluxo de licor branco alimentado em um digestor contínuo é calculado conforme Equação 5.2:

$$FLB = 60\,(CA)\,(RPM)\;(V)\;(DENS) / (AE) \quad (5.2)$$

Em que:
FLB = Fluxo de licor branco (m^3/h);
60 = Fator de conversão (minutos → horas);
CA = Carga Alcalina (%);
RPM = Rotação do medidor de cavacos (RPM);
V = Volume do medidor de cavacos (m^3);
DENS = Densidade a granel do cavaco (kg/m^3);
AE = Concentração de álcali efetivo do licor adicionado (kg/m^3)

Das variáveis presentes na Equação 5.2:

- A carga alcalina (CA) é um valor fixado pelo operador com base no histórico, no número kappa obtido e na concentração de álcali das circulações.
- O Volume do medidor de cavacos (V) é fixo conforme a capacidade do equipamento.

- As variáveis (RPM) e concentração do álcali (AE) são normalmente medidas "em linha". Isto é, os dados são atualizados automaticamente.
- Já a densidade do cavaco (DENS) é medida em laboratório, conforme a frequência estabelecida.

Usualmente nas fábricas, o tempo total desta análise (incluindo coleta de amostra, transporte, execução da análise, tabulação de dados e disponibilização ao operador) é muito próximo ou até mesmo superior que o tempo de residência do digestor. Isto leva ao aumento do erro do fluxo calculado, tendo em vista que no momento em que o operador do digestor toma posse do valor obtido, o cavaco analisado já foi processado e transformado em polpa.

Considerando-se a tendência das fábricas em concluir o cozimento com um número kappa mais elevado para aumentar rendimento (FORSSTROM *et al.* 2006; LINDSTROM 2007; WEDING 2012), a melhor acurácia nos valores da densidade de cavacos passa a ter maior importância. Ocorrendo altos valores não percebidos pelo ajuste de químicos do cozimento, a quantidade de álcali instantânea será insuficiente, podendo acarretar número kappa superiores ao estabelecido, com excesso de formação de rejeito e riscos de entupimentos na etapa de depuração, com consequente redução da produção (HART *et al.* 2011).

A defasagem do tempo entre a obtenção do resultado da densidade do cavaco e a aplicação no processo, foi o principal motivador no desenvolvimento do objetivo específico, que visa "antecipar" o resultado futuro da densidade, com melhor acurácia no cálculo do fluxo do licor branco.

Valores mais adequados desta variável terão como efeito uma melhor adequação na quantidade (que poderá ser maior ou menor) de licor branco adicionado.

5.2. Materiais e Métodos

Cavacos industriais peneirados de *Eucalyptus spp* foram coletados em intervalos de frequência de 04 horas. Um total de 2.306 observações tabuladas sequencialmente foi dividido em dois conjuntos de dados. O primeiro conjunto foi obtido em um período aproximado de 12 meses (com 1948 observações), usado para elaboração do modelo de densidade, doravante denominado [DENS1]. O segundo

conjunto de dados foi obtido em aproximadamente dois meses (com 358 observações), usado para validação do modelo, doravante denominado [DENS2]. Dados dúbios e *outliers* foram eliminados.

A ABNT (NBR 14984 / 2003), tendo como base a metodologia adaptada a partir do método escandinavo *SCAN Method CM 46-92* (1992), definiu o tipo de equipamento e as condições para a realização dos testes, exatamente para impedir variações não exclusivas aos cavacos em si. Todos os dados foram obtidos dentro das recomendações da referida norma, em aparato ilustrado pela Figura 5.2.



Figura 5.2 - Aparato para determinação da densidade a granel de cavacos.

Vale registrar que este método mede a "densidade a granel", isto é, mede a massa do cavaco em relação ao volume total ocupado (incluindo os espaços vazios), simulando o que ocorre dentro do equipamento de alimentação do digestor.

Usando métodos univariados de séries temporais, buscou-se identificar os melhores parâmetros dos estimadores dos modelos para predição desta propriedade.

Os dados da série temporal foram tabulados em sua evolução cronológica, histogramas e correlogramas.

Vários *softwares* podem ser usados para análise estatística e estimação dos parâmetros de modelos (R, MINITAB, STATA, SAS, Statistica, etc.). Para os cálculos dos modelos MMS e AES foram usados o *software* MINITAB, pela simplicidade na interface com o usuário. Já para a estimação dos parâmetros do modelo ARMA, foi usado o *software Eviews* 5 (*Econometric Views* HIS Global, Irvine, CA, USA), pela possibilidade de análises mais complexas e principalmente pela robustez com capacidade de processamento de grande volume de dados.

5.3. Resultados e Discussão

5.3.1 Análise Preliminar dos Dados

Os dados do primeiro conjunto [DENS1] foram tabulados em sua evolução cronológica, conforme Figura 5.3, onde se pode observar aspectos de linearidade e homocedasticidade[16]. Pela análise do gráfico, observa-se a estacionariedade da série, não sendo necessária a diferenciação da mesma. Por questões de confidencialidade, nas Figuras 5.3, 5.4 e 5.9 os valores reais dos dados coletados na indústria foram intencionalmente normalizados para "média 1".

Aspectos de normalidade podem ser confirmados pelo grande volume da amostra e análise visual do histograma apresentado na Figura 5.4.

Com o uso dos dados dos valores observados "sem a aplicação do modelo preditivo" para o cálculo do consumo de licor branco (isto é, usando o dado com o atraso relativo ao tempo de processamento da amostra), foram investigados os erros de desvios do conjunto de dados [DENS1].

---

16 *Homocedasticidade : Termo que indica homogeneidade da variância ao longo do tempo. O termo e o conceito foram dados por Karl Pearson em 1905.*

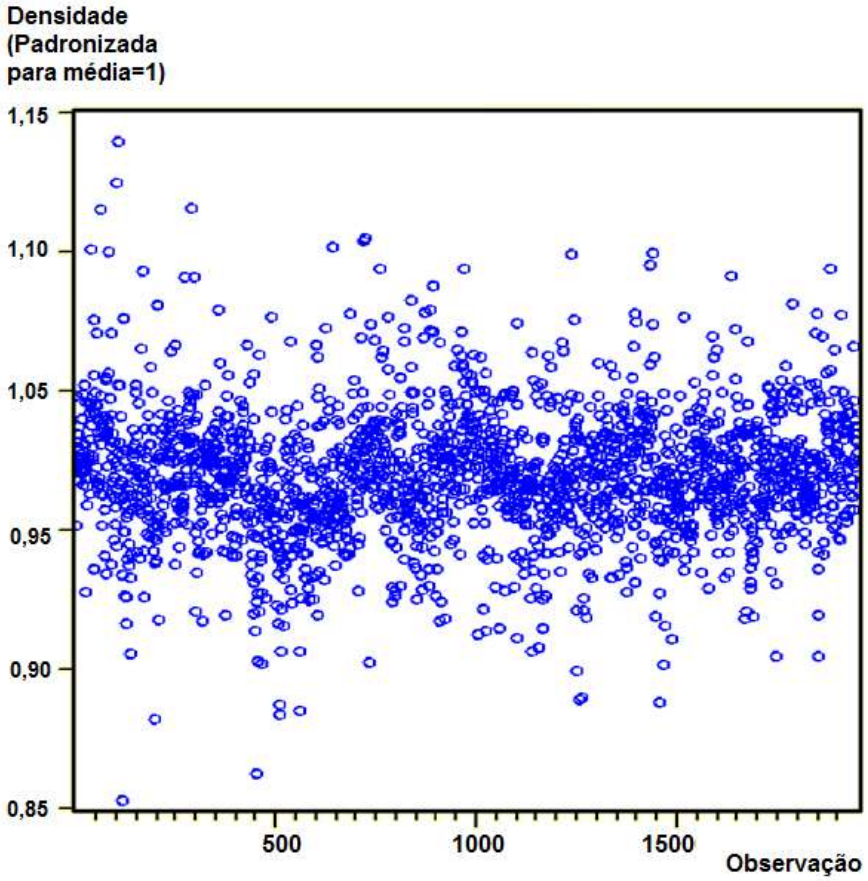


Figura 5.3 - Evolução serial densidade cavacos [DENS1].

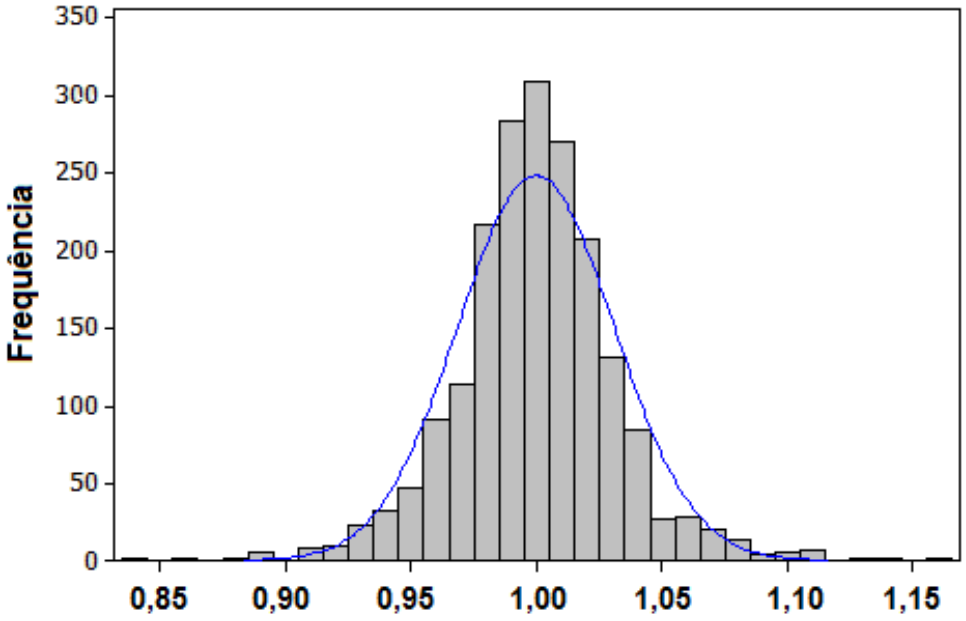


Figura 5.4 - Histograma Densidade Cavacos [DENS1].

Foram analisados os índices MAD (Desvio Absoluto Médio), MAPE **(**Erro Absoluto Percentual Médio) e RMSE (Raiz do Erro Quadrado Médio) calculados conforme Equações AN3.1, AN3.2 e AN3.4 respectivamente, indicadas no *Anexo 3.2*. Foram obtidos os resultados MAD = 4,00 kg/m^3, MAPE = 2,30 % e RMSE = 5,55 kg/m^3. Na Tabela A1.5 do *Apêndice 1.3*, encontram-se ilustrados valores sem o uso do modelo para melhor entendimento.

Para efeito comparativo com os demais métodos, tais índices estão compilados na Tabela 5.5.

5.3.2 Modelo Média Móvel Simples (MMS)

Um dos principais pontos na implementação de modelos MMS é a determinação do tamanho do comprimento da média (m). Valores próximos a 1 fazem com que os resultados se assemelhem à previsão ingênua (*naive forecaster*)[17], enquanto valores muito grandes podem criar uma suavização excessiva. Neste trabalho, usou-se a sugestão de BARROS (2006) em analisar inteiros de 1 a 10 no valor de comprimento de média, avaliando os erros de previsão MAD, MAPE e RMSE.

Aplicando a Equação 4.1 para estimativa dos dados com diferentes valores de M (inteiros de 1 a 10), foram obtidos os índices de desvios citados.

A Figura 5.5 (a) ilustra o gráfico de superfície entre tamanho da média (m), e valores de MAD, RMSE. Já a Figura 5.5 (b) ilustra o gráfico de superfície entre tamanho da média (m) e os valores de MAD e MAPE.

Em complemento, buscou-se identificar um índice que mostre a associação dos índices citados. A Figura 5.6 demonstra o comprimento de média m *versus* produto (MAD x MAPE x RMSE), onde foi selecionado m = 8 como o menor valor dos erros associados, sendo obtidos os valores de MAD = 3,41; MAPE = 1,96 e RMSE = 4,66. Para efeito comparativo com os demais métodos de elaboração [DENS1], tais índices estão compilados na Tabela 5.5.

---

[17] *Previsão ingênua (naive forecaster): Método em que considera que a previsão do próximo instante é igual ao último valor observado.*

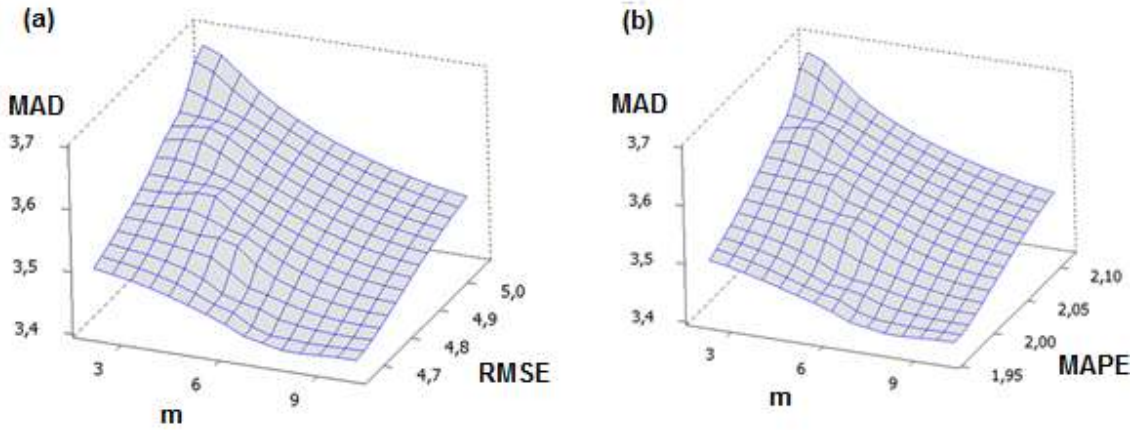


Figura 5.5 – (a): *comprimento de média m* x MAD x RMSE [DENS1];
(b): *comprimento de média m* x MAD x MAPE [DENS1].

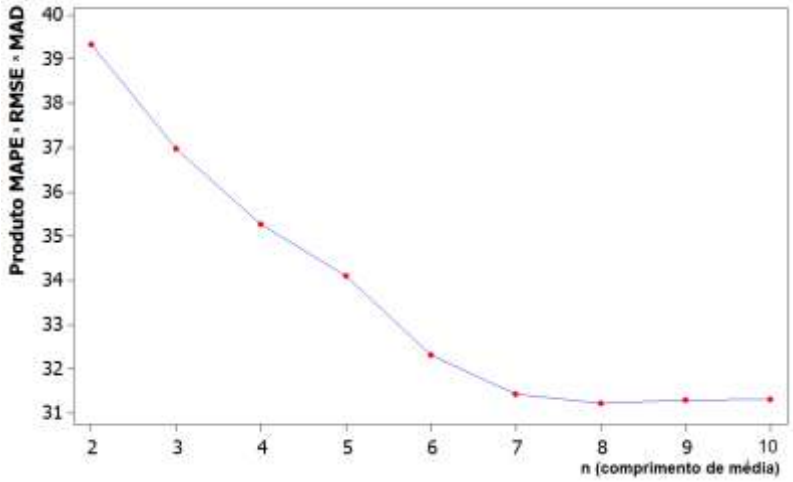


Figura 5.6 – Evolução *comprimento de média m* x (MAD x MAPE x RMSE) [DENS1].

Os dados que originaram os gráficos das Figuras 5.5 e 5.6 estão indicados na Tabela A1.1 (*Apêndice 1*).

Validação do Modelo MMS

Usando o segundo conjunto de dados para validação [DENS2], foi novamente avaliado o melhor valor de comprimento de média, indicando o valor de m = 8 como melhor resultado, conforme Figuras 5.7 que ilustra o gráfico de superfície entre tamanho da média (m), MAD, RMSE MAPE, cujos dados estão indicados na Tabela A1.2 (*Apêndice 1*).

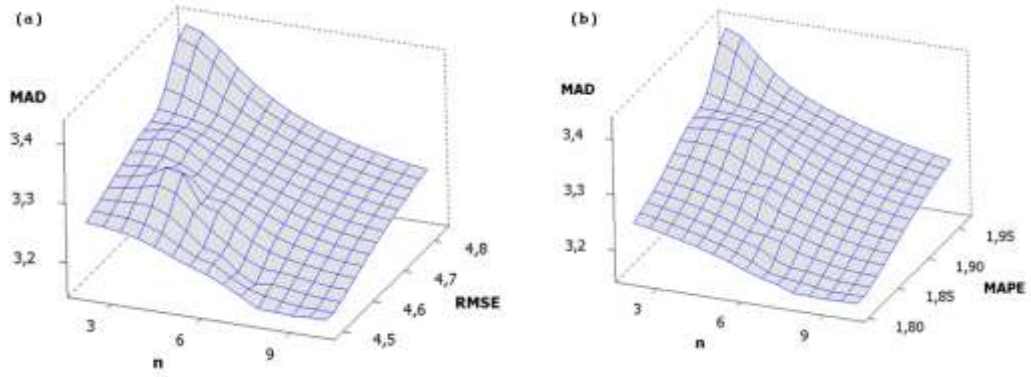


Figura 5.7 – (a) : *comprimento de média m* x MAD x RMSE [DENS2];
(b) : *comprimento de média m* x MAD x MAPE [DENS2].

Em complemento, a Figura 5.8 apresenta o 'comprimento de média m' *versus* produto (MAD x RMSE x MAPE), mostrando que o comprimento de média m=8 apresenta o menor valor dos erros associados, ao qual foi selecionado para estimação dos dados.

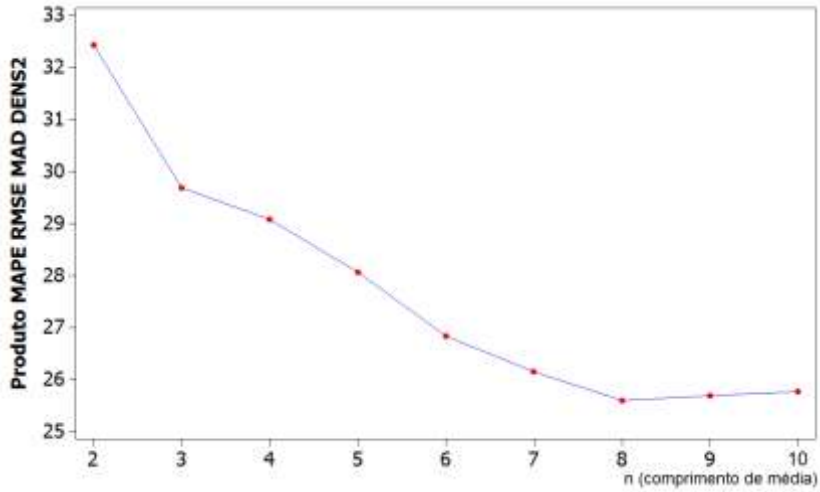


Figura 5.8 – Gráfico (*comprimento de média m*) x (MAD x RMSE) [DENS2].

Usando o comprimento de média m=8 na Equação 4.1, foi obtido a Equação 5.3, para obtenção dos valores estimados:

$$\hat{Y}_t = \frac{Y_{t-1}+Y_{t-2}+\cdots+Y_{t-8}}{8} \tag{5.3}$$

A Figura 5.9 mostra a evolução dos valores observados e estimados, em que se pode verificar que os valores estimados permeiam por uma tendência central com

um *delay* de acompanhamento. Se por um lado podem apresentar desvios altos em relação às observações distantes da média (acarretando maior RMSE), apresentam para o processo maior estabilidade quando as observações oscilam bruscamente entre valores altos e baixos. Por outro lado, este *delay* quando é acentuado, não acompanha adequadamente a tendência dos dados, como pode ser observado na seta indicada próximo à observação 75, em que o valor observado está em queda, e o valor estimado ainda em elevação.

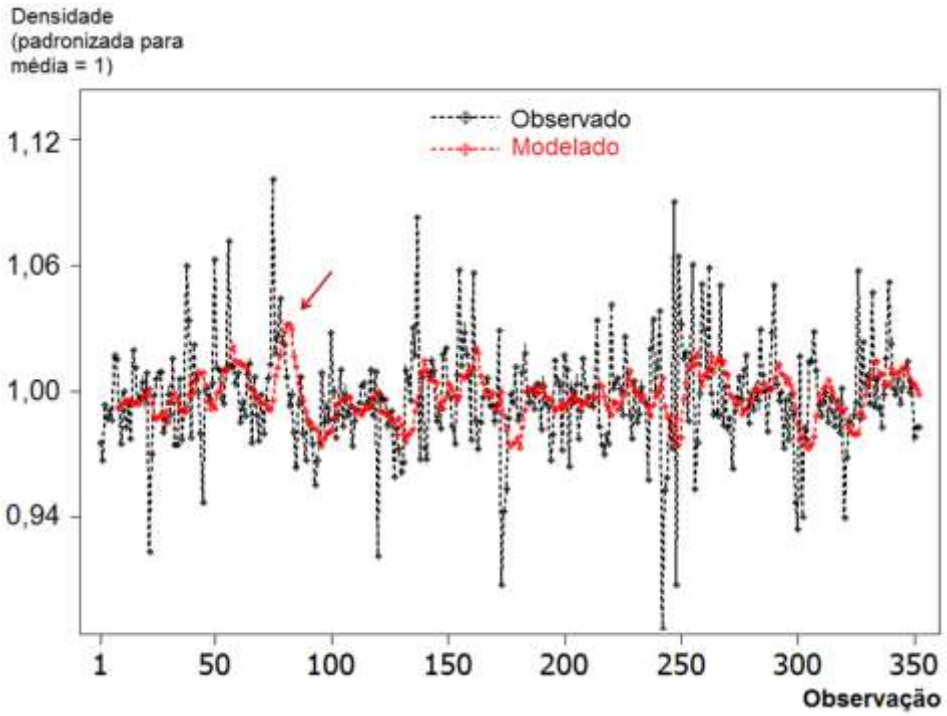


Figura 5.9 – Evolução dos valores observados e preditos modelo MMS [DENS2].

A avaliação dos resíduos ($Y_{Observado} - Y_{Estimado}$) é um item de importância na seleção de modelos. Se estes são essencialmente randômicos, indicam que o modelo é apropriado. A Figura 5.10 apresenta a evolução dos mesmos. Nela, pode-se observar a aleatoriedade em torno de zero, a variância constante, mostrando a homocedasticidade dos resíduos. Verifica-se alguns pontos com valores elevados nas observações próximas ao número 50, 75, 140 e 250. Considerando como um valor razoável de aceitabilidade um erro de 3% (para mais ou para menos), o modelo apresentou 82,1% dos valores estimados dentro do intervalo entre -3% e +3% do valor da média.

O índice Durbin Watson (calculado conforme Equação A3.7), apresentou valor 1,77 mostrando que não há evidência de autocorrelação entre os resíduos.

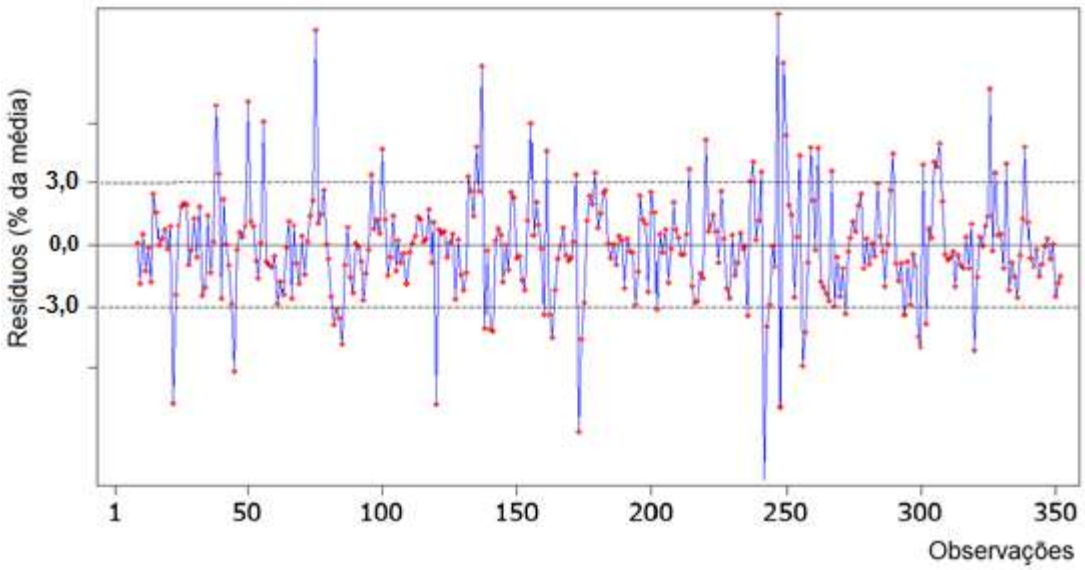


Figura 5.10 – Evolução dos resíduos modelo MMS [DENS2].

Ainda na análise dos resíduos, a Figura 5.11 apresenta o histograma dos mesmos, mostrando a boa assimetria[18], com média e mediana em torno de zero.

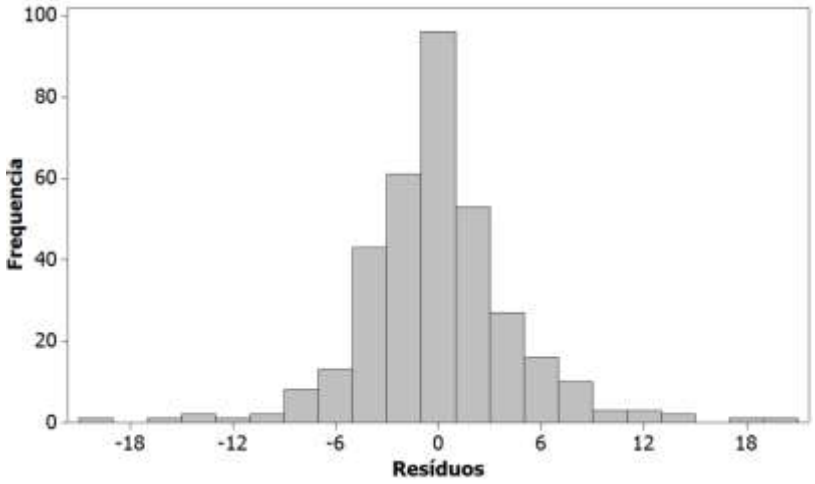


Figura 5.11 – Histograma dos resíduos modelo MMS [DENS2].

O modelo MMS selecionado apresentou os índices MAD = 3,16; MAPE = 1,80 e RMSE = 4,49. Estes índices foram muito próximos ou ligeiramente inferiores aos

[18] *Assimetria : nomenclatura referente ao grau de afastamento de uma distribuição da unidade de assimetria. Uma distribuição é simétrica quando seus valores de Média, Mediana e Moda coincidem ou são muito próximos.*

da etapa de elaboração do modelo [DENS1], e estão compilados para efeito comparativo junto aos resultados dos demais modelos de validação [DENS2] na Tabela 5.6 (página 86).

5.3.3 Modelo Alisamento Exponencial Simples (AES)

De acordo com a Figura 5.3, o conjunto de dados para construção do modelo é uma série temporal não sazonal, sem tendência, viabilizando a aplicação do modelo AES aos dados desta série.

Aplicando a Equação 4.2 para estimação dos dados com diferentes valores do *índice de ponderação* α, foram obtidos os índices de desvios MAD, RMSE e MAPE conforme as equações 5.1, 5.2 e 5.3 que estão ilustrados nas Figuras 5.12 (a) e 5.12 (b) com o gráfico de superfície entre o índice α e os desvios citados.

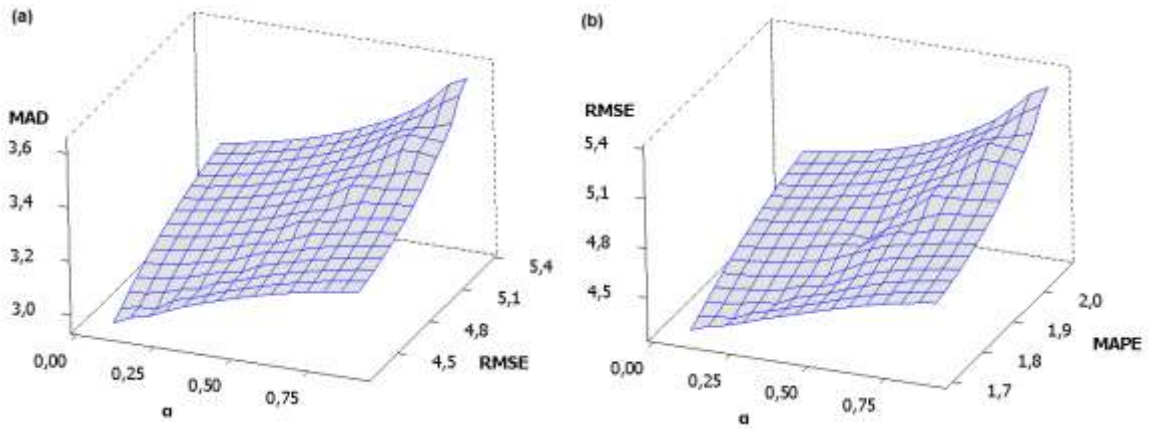


Figura 5.12 - (a): índice de ponderação α x MAD x RMSE [DENS1];
(b): índice de ponderação α x RMSE x MAPE [DENS1].

Em complemento, foi analisado o valor do índice de ponderação α *versus* produto (MAD x RMSE x MAPE). O objetivo desta avaliação, foi analisar o índice α em relação aos três índices de erro associados. A Figura 5.13 mostra que α = 0,1 apresentou o menor valor dos erros em conjunto, sendo então este o valor selecionado para ser usado na etapa de validação. O índice α = 0,1 apresentou os valores de MAD = 3,28; MAPE = 1,89 e RMSE = 4,52. Tais índices estão sumarizados para efeito comparativo na Tabela 5.5 (página 85). Os dados que geraram os gráficos das Figuras 5.12 e 5.13 estão apresentados no *Apêndice 2* - Tabela 2.4.

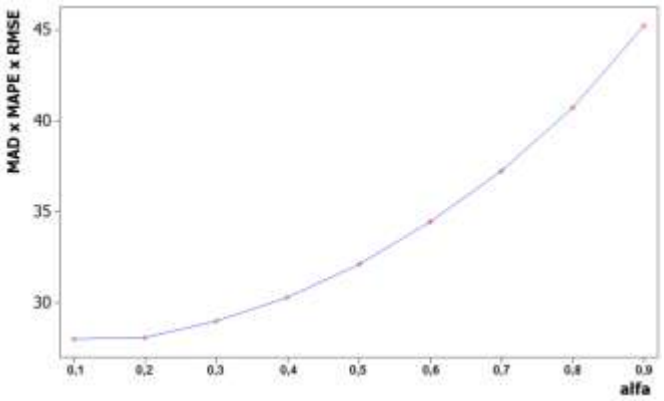


Figura 5.13 – Gráfico α x (MAD x MAPE x RMSE) [DENS1].

Validação do Modelo AES

Usando o segundo conjunto de dados para validação [DENS2], foi novamente avaliado o valor do coeficiente de ponderação, confirmando o valor α = 0,1 como melhor resultado, conforme Figuras 5.14 (a) e 5.14 (b) que ilustram os gráficos de superfície entre α , MAD, RMSE MAPE.

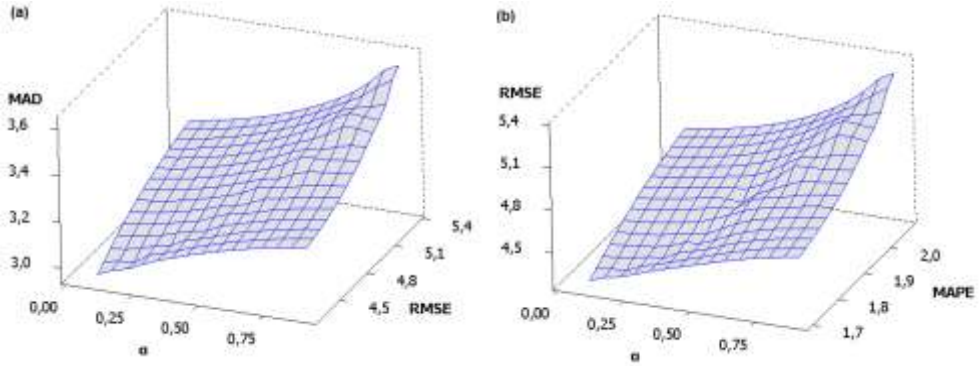


Figura 5.14 - (a): índice de ponderação α x MAD x RMSE [DENS2];
(b): índice de ponderação α x RMSE x MAPE [DENS2].

Em complemento a Figura 5.15 mostra o índice de ponderação α *versus* produto (MAD x RMSE x MAPE), confirmando que o índice α = 0,1 apresentou o menor valor dos erros associados também para os dados de validação. Os dados geradores dos gráficos das Figuras 5.14 e 5.14 estão apresentados no *Apêndice 2* - Tabela A2.5 .

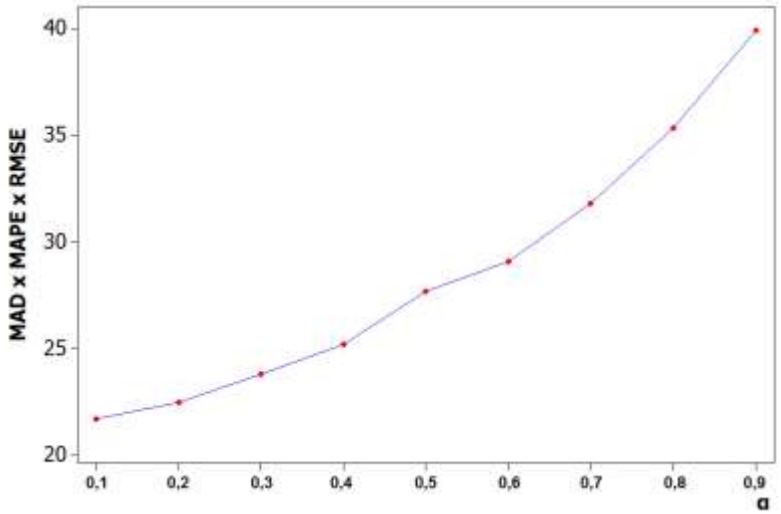


Figura 5.15 – Gráfico α x (MAD x MAPE x RMSE) [DENS2].

Usando o índice de ponderação α = 0,1 na Equação 4.2, foi obtida a Equação 5.4, para estimativa dos valores da série:

$$\hat{Y}_t = 0{,}1Y_{t-1} + 0{,}9\hat{Y}_{t-1} \tag{5.4}$$

Aplicando a Equação 5.4 à série de dados [DENS2], obteve-se o conjunto de dados de predição do modelo densidade de cavaco com o método AES. Tais dados foram comparados com os valores reais observados da série presentes na Figura 5.16, a qual apresenta a evolução dos valores observados e estimados. Pode-se verificar que os valores estimados permeiam por uma tendência central com um *delay* de acompanhamento, mas de menor intensidade do que o modelo MMS. Comparando a Figura 5.16 com a Figura 5.9 no ponto próximo à observação 75, verifica-se que houve o mesmo *delay* observado, porém mais atenuado. Isto é um indicativo do melhor desempenho deste método em relação ao anterior. Da mesma forma da análise do modelo MMS, os desvios acentuados contribuem para o incremento do RMSE, mas os valores estimados estão sempre próximos da média o que pode contribuir para maior estabilidade quando as observações oscilam bruscamente entre valores altos e baixos.

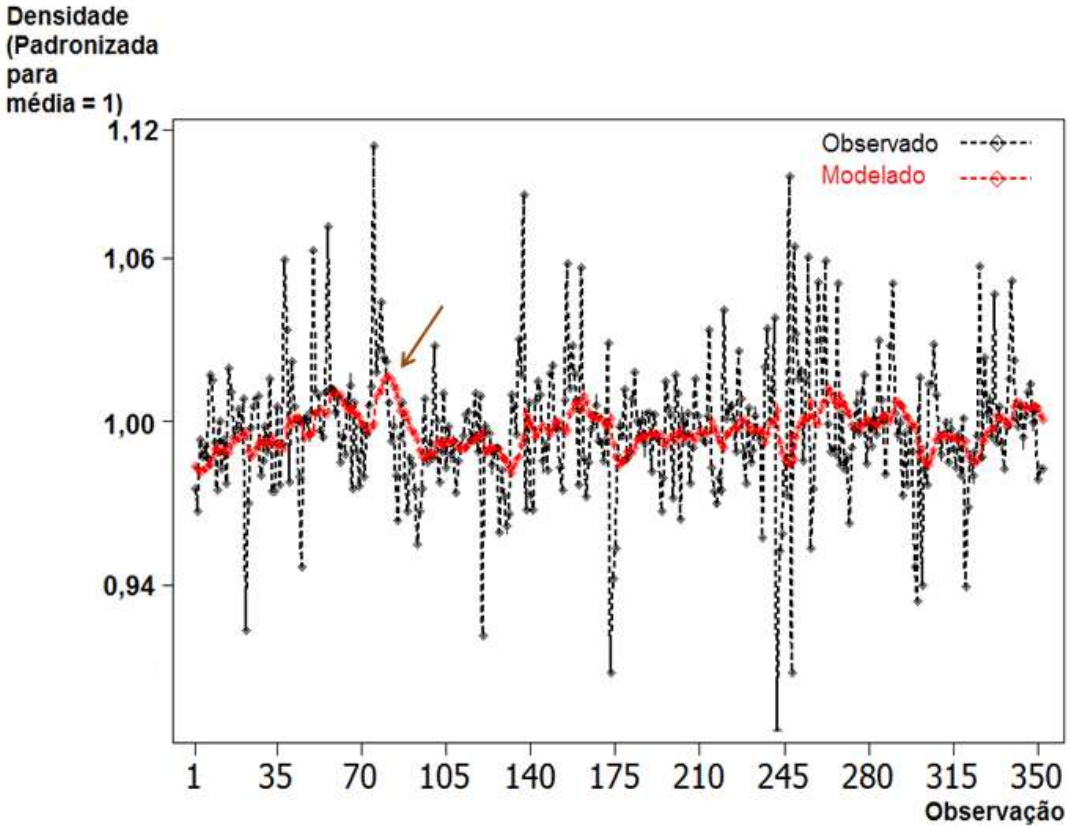


Figura 5.16 – Evolução dos valores observados e preditos modelo AES [DENS2].

A Figura 5.17 apresenta a evolução dos resíduos. Nela, pode-se observar a aleatoriedade em torno de zero e variância constante, mostrando a homocedasticidade dos resíduos.

Apesar de alguns pontos com valores elevados nas observações próximas ao número 50, 75, 140 e 250, o modelo apresentou 84,4% dos valores estimados dentro do intervalo entre -3% e +3% do valor da média.

O índice Durbin Watson, apresentou valor 1,85 mostrando que não há evidência de autocorrelação entre os resíduos.

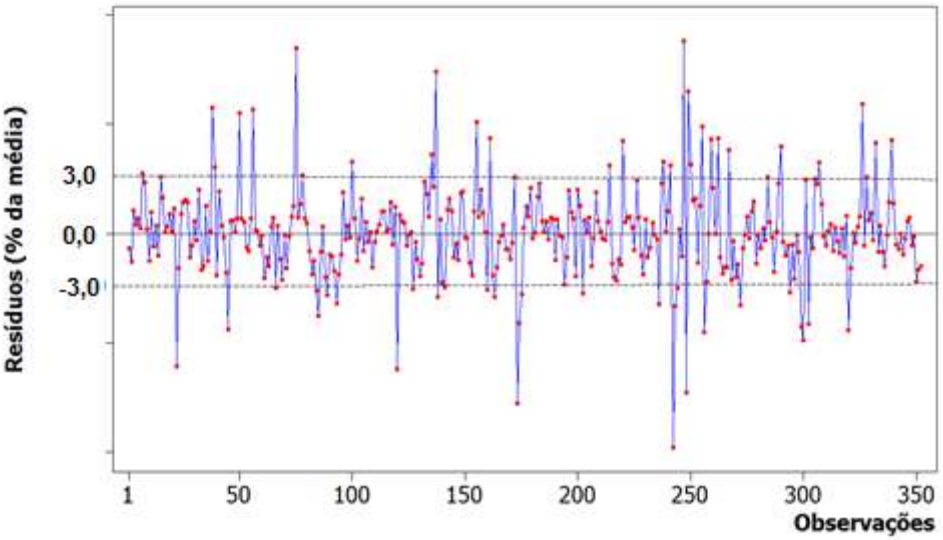


Figura 5.17 – Evolução dos resíduos modelo AES [DENS2].

No mesmo contexto, a Figura 5.18 apresenta o histograma dos resíduos, mostrando a assimetria, com média e mediana em torno de zero.

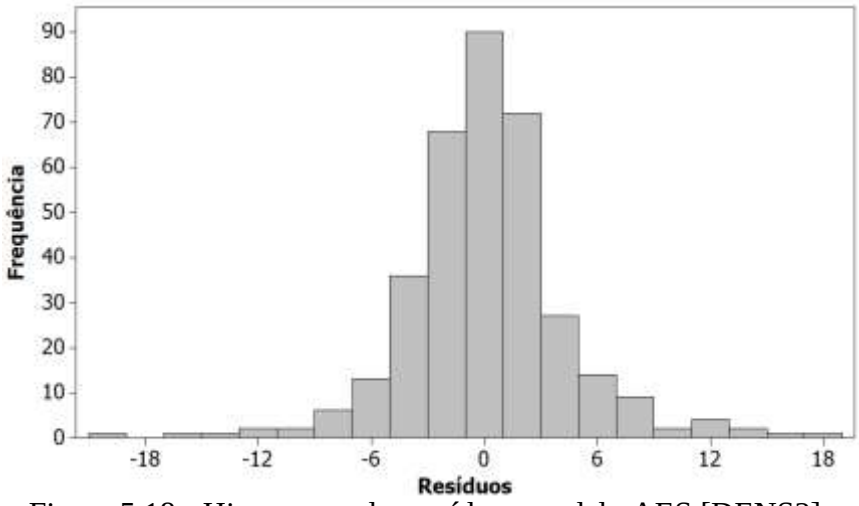


Figura 5.18 - Histograma dos resíduos modelo AES [DENS2].

O modelo AES selecionado apresentou os índices MAD = 2,97; MAPE = 1,70 e RMSE = 4,30. Estes valores foram muito próximos ou ligeiramente inferiores aos da etapa de elaboração do modelo [DENS1], e estão compilados para efeito comparativo na Tabela 5.6, junto aos demais métodos analisados na etapa de validação [DENS2].

5.3.4 Modelo Box-Jenkins (ARMA)

Identificação do Modelo

Para a seleção dos melhores parâmetros estimativos do modelo ARMA, foram considerados os critérios MAD, MAPE e RMSE, e também os índices AIC - Critério de Informação de Akaike, BSC - Critério Bayesiano de Schwarz, DW - Índice Durbin Watson, TIC - Coeficiente de Desigualdade de Theil. Menores valores são melhores em todos os critérios indicados, com exceção para DW, que deve ser o mais próximo do número dois. Detalhamento dos referidos índices estão sumarizados no *Anexo 3.2.* Além destes, foi considerado a avaliação dos resíduos através de seus histogramas e evolução dos mesmos.

Considerando as restrições de uso do coeficiente de determinação R^2 em comparações de modelos em séries temporais, (GRANGER e NEWBOLD 1976; ACHEN 1982; ANDERSON-SPRECHER 1994; WILLET e SINGER 1988) este índice não foi considerado na seleção.

Para estimação dos parâmetros do modelo, foi usado o primeiro conjunto de dados [DENS1] para elaboração do correlograma indicado na Figura 5.19. Nesta Figura, pela análise do decaimento e também pela relevância das colunas horizontais circuladas da FAC - *Função de Auto Correlação*[19] (equivalentes a 0,300 e 0,186) e FACP - *Função de Auto Correlação Parcial*[20] (equivalentes a 0,300 e 0,105) respectivamente, observa-se que existe uma significância para os componentes autorregressivos e de média móvel de primeira e segunda ordem, AR(1), AR(2), MA(1) e MA(2). Por esta razão, foram então avaliados estes componentes nos modelos testados.

Os modelos ARMA (2,2), ARMA (1,2) e ARMA (2,1) apresentaram ruído branco na série de resíduos estimados. Todos apresentaram bons resultados (na ordem indicada) nos critérios MAD, MAPE, RMSE, AIC, BSC, DW e TIC, cujos índices estão indicados na Tabela 5.1. Informações complementares deste modelo são apresentados no *Apêndice 2.4.*

---

[19] *FAC - Função de Auto Correlação : função que mede o grau de correlação de uma variável, em um dado instante, consigo mesma, em um instante de tempo posterior.*

[20] *FACP - Função de Auto Correlação Parcial : função que busca mensurar o quanto Yt e Yt+k estão relacionados, sem os efeitos dos Ys intermediários.*

A avaliação dos resultados nos permite concluir que todos os modelos ARMA indicados apresentam resultados satisfatórios.

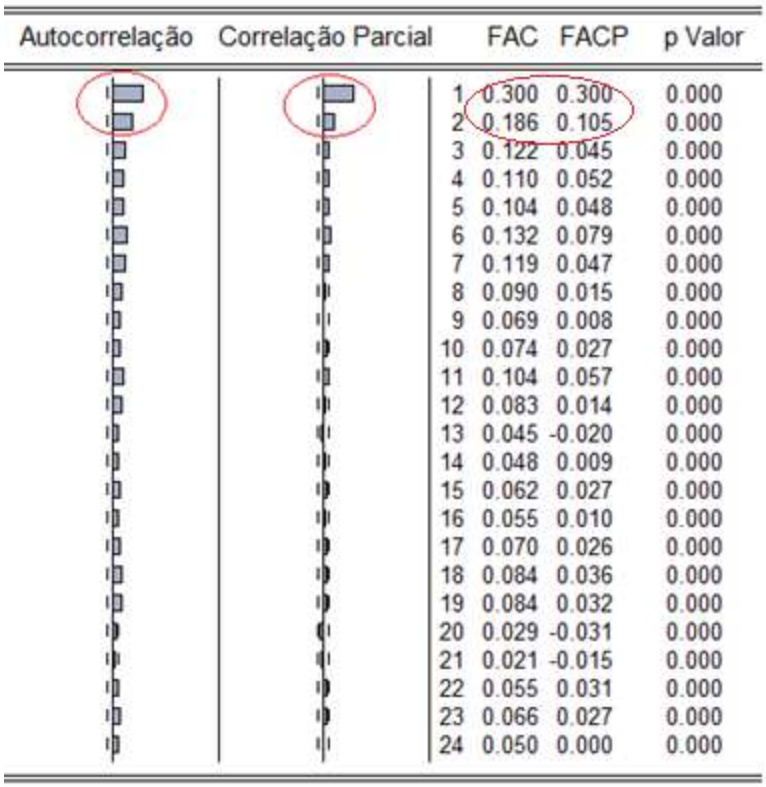


Figura 5.19 - Correlograma Densidade Cavacos [DENS1].

Tabela 5.1 - Resultados dos índices estatísticos dos modelos ARMA [DENS1].

Modelo	**AR (1)**	**MA (1)**	**ARMA (1,1)**	**ARMA (2,1)**	**ARMA (1,2)**	**ARMA (2,2)**
AIC	5,8360	5,8550	5,8190	5,8100	5,8110	5,8090
SBC	5,8410	5,8610	5,8280	5,8210	5,8230	5,8124
DW	2,0630	1,9250	1,9440	2,0110	1,9860	2,0010
RMSE	4,4720	4,5150	4,4340	4,4100	4,4140	4,4070
MAD	3,2090	3,2780	3,1610	3,1550	3,1640	3,1420
MAPE	1,8460	1,8860	1,8170	1,8150	1,8190	1,8070
TIC	0,0128	0,0128	0,0127	0,0127	0,0127	0,0127

Apesar da pequena diferença no cômputo geral dos índices, foi selecionado o modelo ARMA (2,2) para a etapa de validação por seu melhor desempenho (visível em alguns casos na segunda casa decimal). Para efeito comparativo com os demais métodos, os índices deste modelo estão compilados na Tabela 5.5.

Os parâmetros estimados do modelo ARMA (2,2) estão presentes na Tabela 5.2. Os parâmetros são significativos a 5% de significância estatística[21], e atendem aos requisitos de estacionariedade e invertibilidade indicados na Tabela 4.1.

Tabela 5.2 - Coeficientes do Modelo ARMA (2,2) [DENS1]

Variável	**Coeficiente**	**D. Padrão**	**p-valor**
δ	173,9198	0,344822	0,0000
$\boldsymbol{\phi_1}$	1,4043	0,0993	0,0000
$\boldsymbol{\phi_2}$	-0,4170	0,0954	0,0000
$\boldsymbol{\theta_1}$	-1,1576	0,1048	0,0000
$\boldsymbol{\theta_2}$	0,2012	0,0936	0,0317

Observa-se na Figura 5.20, o gráfico da evolução dos valores observados (em vermelho) e os estimados pelo modelo (em verde). Pode se observar que de uma forma geral os valores modelados tendem a não se distanciar da média oscilando a 3 pontos percentuais para cima e para baixo.

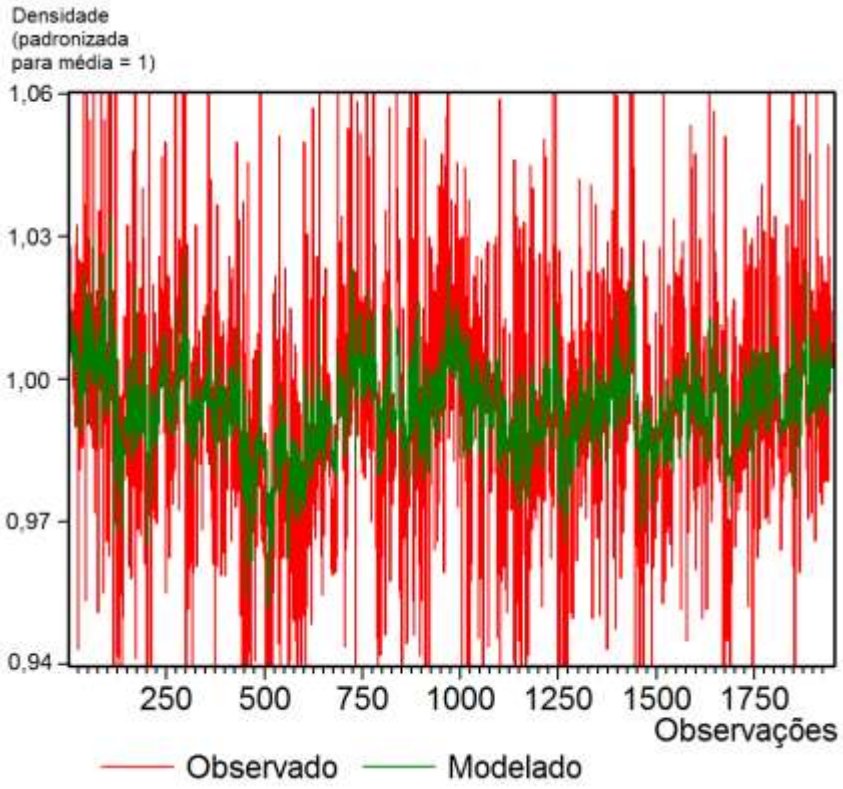


Figura 5.20 – Evolução de previsão do modelo ARMA (2,2) [DENS1].

[21] Significância (p-valor): Medida estimada do grau em que o resultado tenha ocorrido "por acaso".

São apresentados na Tabela 5.3 os índices estatísticos para a série [DENS1]. Observa-se que o índice RMSE (Raiz do erro quadrado médio) ficou próximo do MAD (Desvio Absoluto Médio), indicando que foi baixo o volume de desvios acentuados (lembrando que no cálculo do RMSE envolve o quadrado dos desvios). Verificam-se valores baixos de AIC e BSC, e o apropriado valor de DW próximo a dois, demonstrando um bom comportamento dos resíduos. Em complemento, o TIC *Coeficiente de Desigualdade de Theil* foi próximo de zero como desejável. Sua proporção BP Bias (do Viés) que informa o quão distante está a média da série estimada da média real foi zero. Já a VP proporção da variância (que deveria ser próximo de zero indicando boa capacidade do modelo de repetir a variabilidade da variável de interesse) foi próximo de 0,5. Em complemento, a CV proporção da covariância (que mede os erros de previsão não previstos no modelo) atingiu o desejável valor próximo de 0,5. Assim, o modelo proposto não atingiu a distribuição ideal das proporções BP ≈VP ≈ 0 e CV ≈ 1. Por outro lado os demais índices estatísticos foram satisfatórios. Detalhamento do conceito destes e demais índices estatísticos estão descritos no *Anexo 3.2*.

Tabela 5.3 – Índices estatísticos modelo ARMA (2,2) [DENS1].

Índice	**Valor**	
RMSE	4,407	
MAD	3,142	
MAPE	1,807	
AIC	5,809	
BSC	5,812	
DW	2,001	
TIC	0,013	
	BP Proporção Bias	*0,000*
	BV Proporção Variância	*0,489*
	CV Proporção Covariância	*0,511*

A Figura 5.21 apresenta as curvas reais e teóricas das FAC e FACP. O bom ajuste da curva contínua com as barras verticais evidencia o bom ajuste do modelo ARMA (2,2).

A Figura 5.22 apresenta a evolução dos resíduos $(Y_t - \hat{Y}_t)$. Nela, pode-se observar a aleatoriedade em torno de zero, e variância constante, mostrando a homocedasticidade dos resíduos.

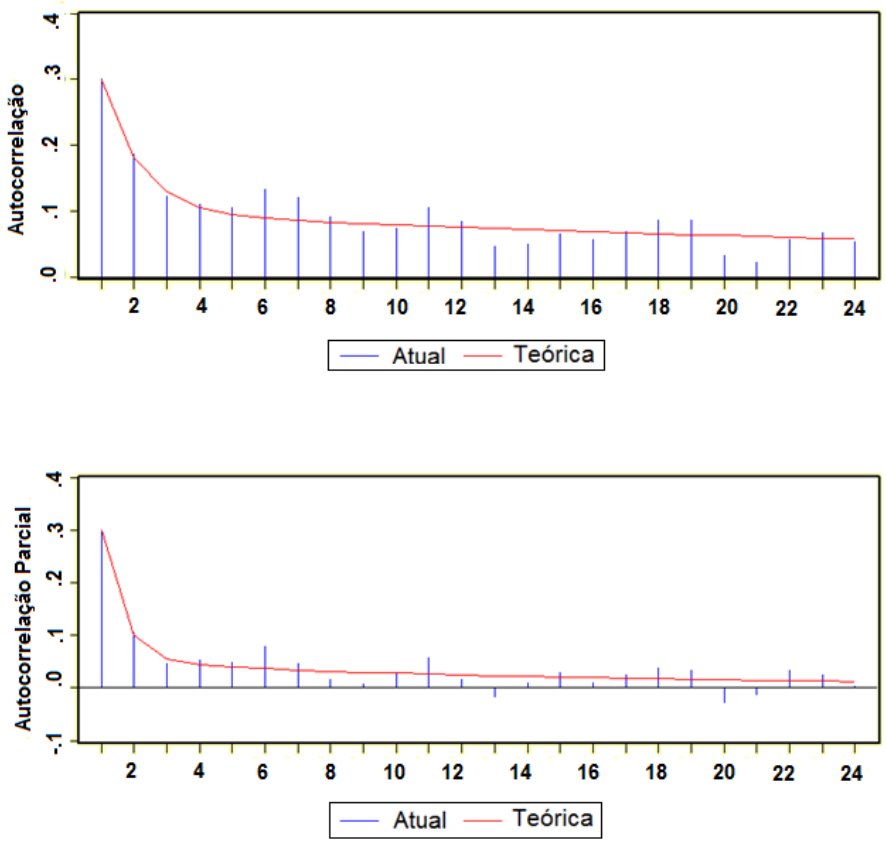


Figura 5.21 - Curvas reais e teóricas das FAC e FACP do Modelo ARMA (2,2) [DENS1].

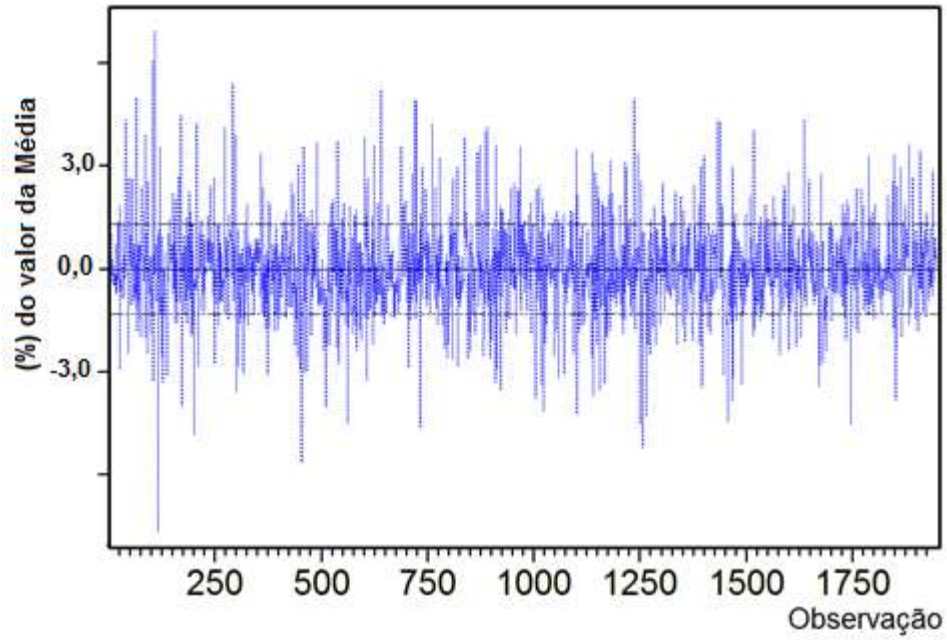
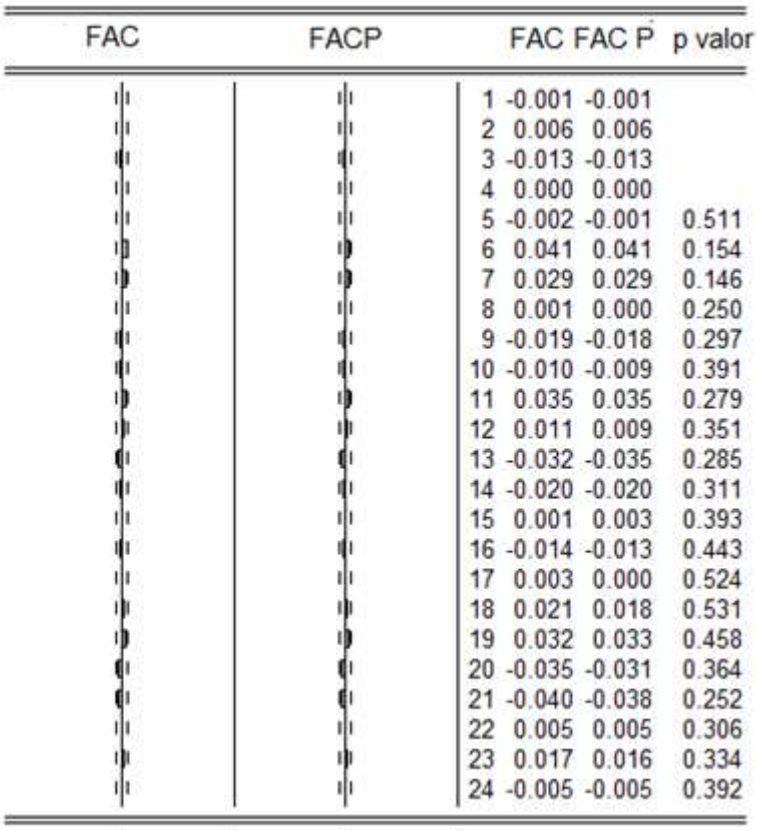


Figura 5.22 Evolução Resíduos do Modelo ARMA (2,2) [DENS1].

A Figura 5.23 mostra o correlograma dos resíduos para o modelo ARMA (2,2). Observando as funções FAC e FACP evidencia-se O ruído branco na série dos resíduos, indicando que os mesmos são não correlacionados.

A Figura 5.24 apresenta o histograma dos resíduos, indicando uma distribuição com média zero e assimetria próximo de zero.



FAC	FACP		FAC	FAC P	p valor
		1	-0.001	-0.001	
		2	0.006	0.006	
		3	-0.013	-0.013	
		4	0.000	0.000	
		5	-0.002	-0.001	0.511
		6	0.041	0.041	0.154
		7	0.029	0.029	0.146
		8	0.001	0.000	0.250
		9	-0.019	-0.018	0.297
		10	-0.010	-0.009	0.391
		11	0.035	0.035	0.279
		12	0.011	0.009	0.351
		13	-0.032	-0.035	0.285
		14	-0.020	-0.020	0.311
		15	0.001	0.003	0.393
		16	-0.014	-0.013	0.443
		17	0.003	0.000	0.524
		18	0.021	0.018	0.531
		19	0.032	0.033	0.458
		20	-0.035	-0.031	0.364
		21	-0.040	-0.038	0.252
		22	0.005	0.005	0.306
		23	0.017	0.016	0.334
		24	-0.005	-0.005	0.392

Figura 5.23 – Correlograma dos Resíduos Modelo ARMA (2,2).

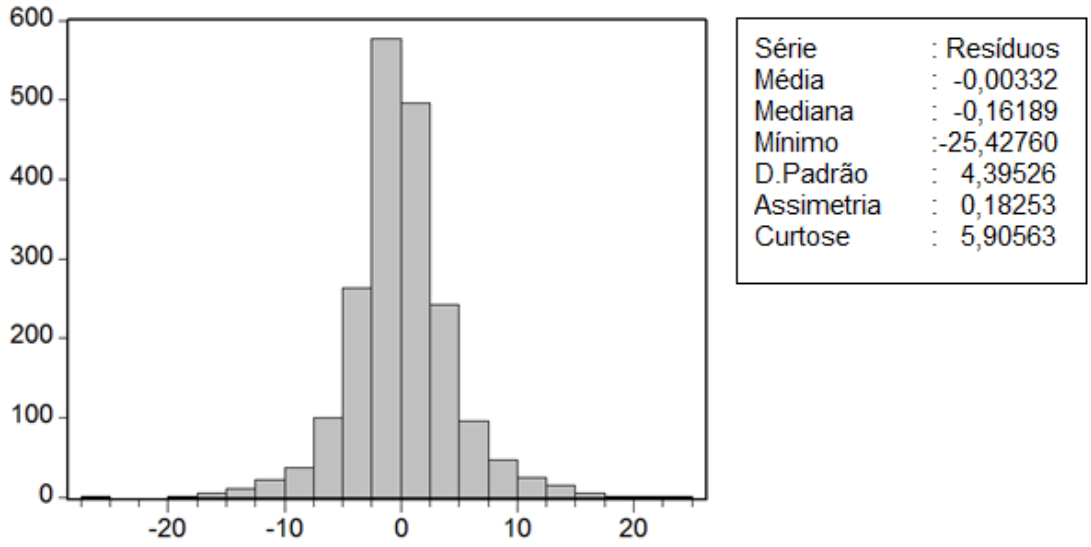


Figura 5.24 - Histograma dos Resíduos Modelo ARMA (2,2) [DENS1].

Validação do Modelo ARMA

Aplicando os coeficientes indicados na Tabela 5.2 na Equação 4.6, foi obtida a Equação 5.8 para validação do modelo usando o segundo conjunto de dados [DENS2]:

$$Y_t = 2.220086 + 1.404277\, Y_{t-1} - 0.417042\, Y_{t-2} - 1.157647 e_{t-1} + 0.201239\, e_{t-2} \quad (5.5)$$

na qual:

Y_t = Densidade a granel ao tempo t (kg/m^3)
e_t = Erro da densidade a granel ao tempo t ($Y_t - \hat{Y}_t$).

A Figura 5.25 apresenta a evolução dos valores observados e modelados. Pode-se verificar que os valores modelados permeiam por uma tendência central com um *delay* de acompanhamento. Nas mesmas circunstâncias dos métodos anteriores, os desvios acentuados contribuem para o incremento do RMSE, mas os valores estimados estão sempre próximos da média o que pode contribuir para maior estabilidade quando as observações oscilam bruscamente entre valores altos e baixos. Analisando os picos próximos à ocorrência 75, verifica-se que o tempo de resposta é mais rápido quanto á variação (subida x descida) quando comparado aos modelos MMS e AES.

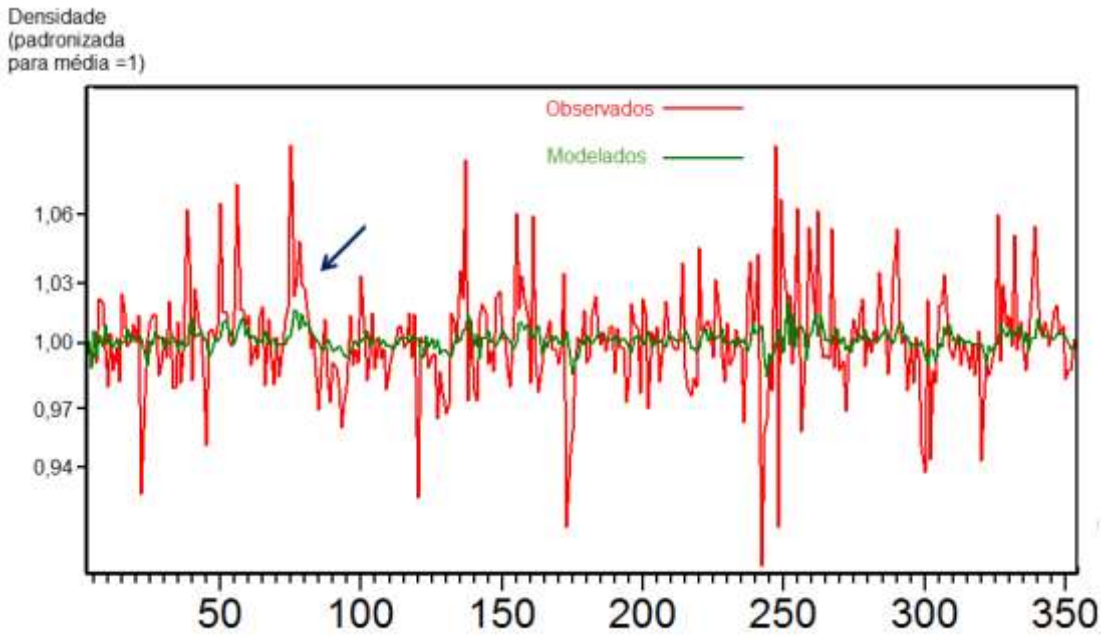


Figura 5.25 – Evolução dos valores observados e preditos modelo ARMA [DENS2].

Como ilustração são apresentados no *Apêndice 1.3* complementos dos resultados deste modelo, com ilustração dos dados numéricos reais com o uso da predição com a metodologia Box-Jenkins, e com os dados sem nenhuma predição, mostrando a redução nos índices de desvios.

Na Tabela 5.4 são indicados os índices de desvios dos quatro modelos analisados no conjunto usado para validação dos modelos [DENS2]. Pelos resultados apresentados observa-se que os modelos ARMA (1,2) e ARMA (2,2) apresentaram índices muito semelhantes, e ambos são melhores em relação aos modelos ARMA (1,1) e ARMA (2,1).

Tabela 5.4: Índices Estatísticos de Validação dos Modelos ARMA [DENS2]

Modelo	**ARMA(1,1)**	**ARMA(2,1)**	**ARMA(1,2)**	**ARMA (2,2)**
MAD	3,3082	3,2580	2,8589	2,8177
RMSE	4,9455	4,9457	4,2561	4,1472
MAPE	1,8968	1,8681	1,6370	1,6151

A Figura 5.26 apresenta a evolução dos resíduos. Nela, pode-se observar a aleatoriedade em torno de zero, a variância constante, mostrando a homocedasticidade dos resíduos. Na mesma tendência dos modelos MMS e AES, apresentam-se alguns pontos com valor'es elevados nas mesmas observações (próximas ao número 50, 75, 140 e 250).

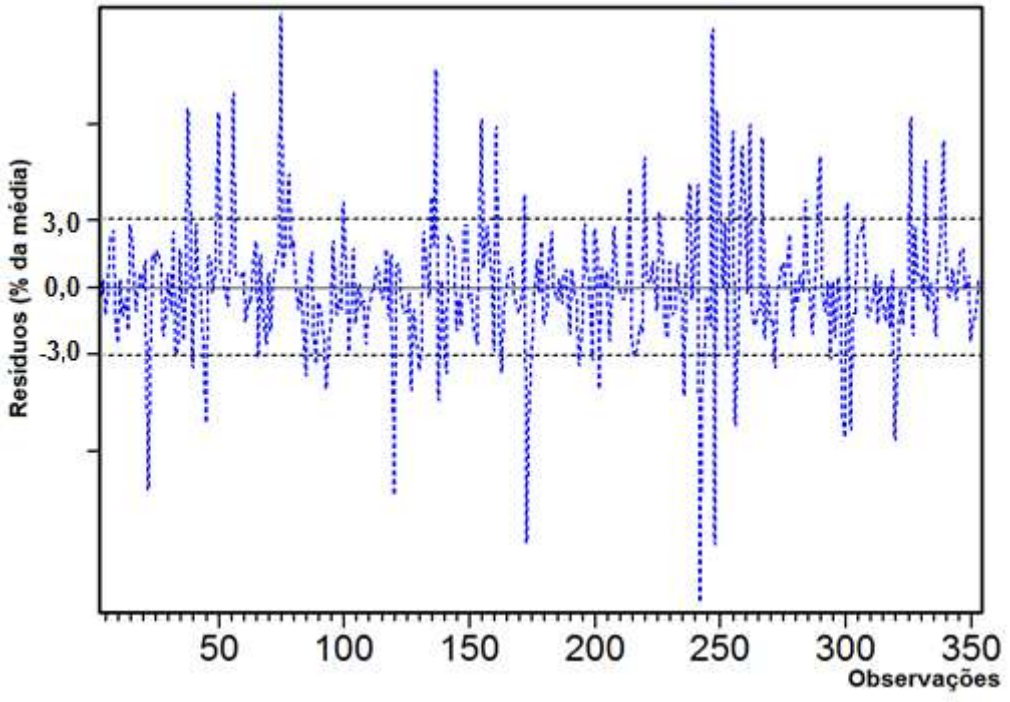


Figura 5.26 – Evolução dos resíduos do modelo ARMA [DENS2].

Verifica-se que 86,1% dos dados estão dentro do intervalo de 3% do valor da média (para mais ou para menos).

O índice Durbin Watson apresentou valor de 2,24 mostrando que não há evidência de autocorrelação entre os resíduos.

No mesmo contexto, a Figura 5.27 apresenta o histograma dos resíduos, mostrando a assimetria, com média e mediana em torno de zero.

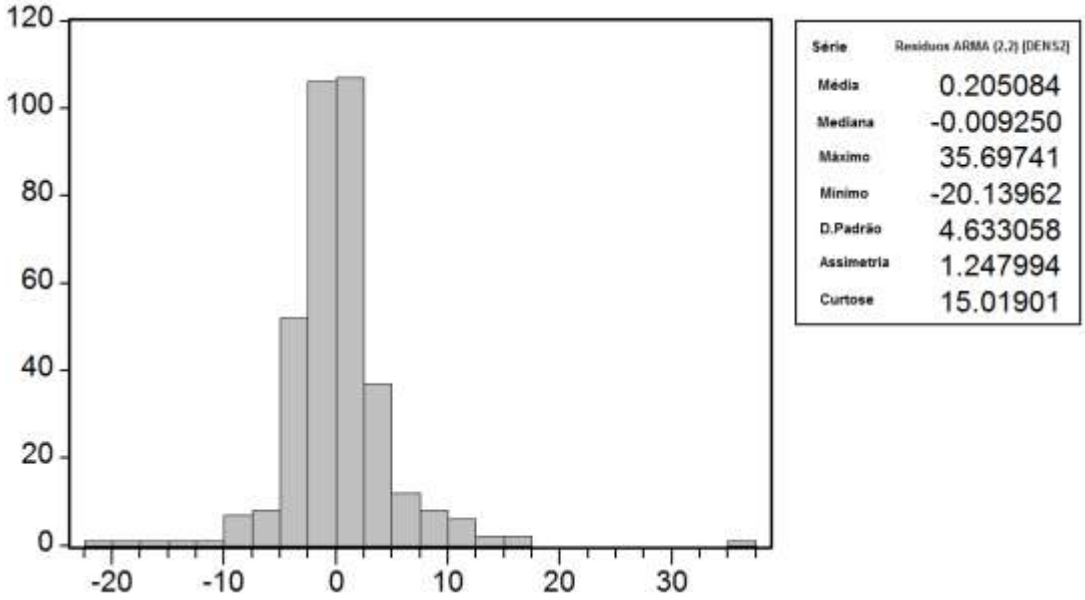


Figura 5.27 - Histograma dos resíduos modelo ARMA(2,2) [DENS2].

O modelo ARMA selecionado apresentou os índices MAD = 2,84; MAPE = 1,63 e RMSE = 4,24. Estes índices foram muito próximos ou ligeiramente inferiores aos da etapa de elaboração do modelo [DENS1], e estão compilados para efeito comparativo junto aos demais métodos na Tabela 5.6.

Este modelo foi implantado na planta industrial objeto deste estudo, sendo os parâmetros do modelo atualizados a cada três meses. A implantação da metodologia foi realizada em planilha eletrônica, com a entrada dos dados feita manualmente pelos operadores, conforme os resultados do laboratório são disponibilizados. A planilha gera como resposta a "densidade prevista" para ser usada no controle SDCD do digestor. A assimilação por parte dos operadores foi imediata, não sendo necessários treinamentos especiais ou tutoriais.

Uma melhor adição de álcali adequada ao cavaco alimentado tende a refletir em uma menor variabilidade do álcali na circulação do digestor. O licor da circulação superior possui analisador de álcali *on line* em posição indicada na Figura 5.28.

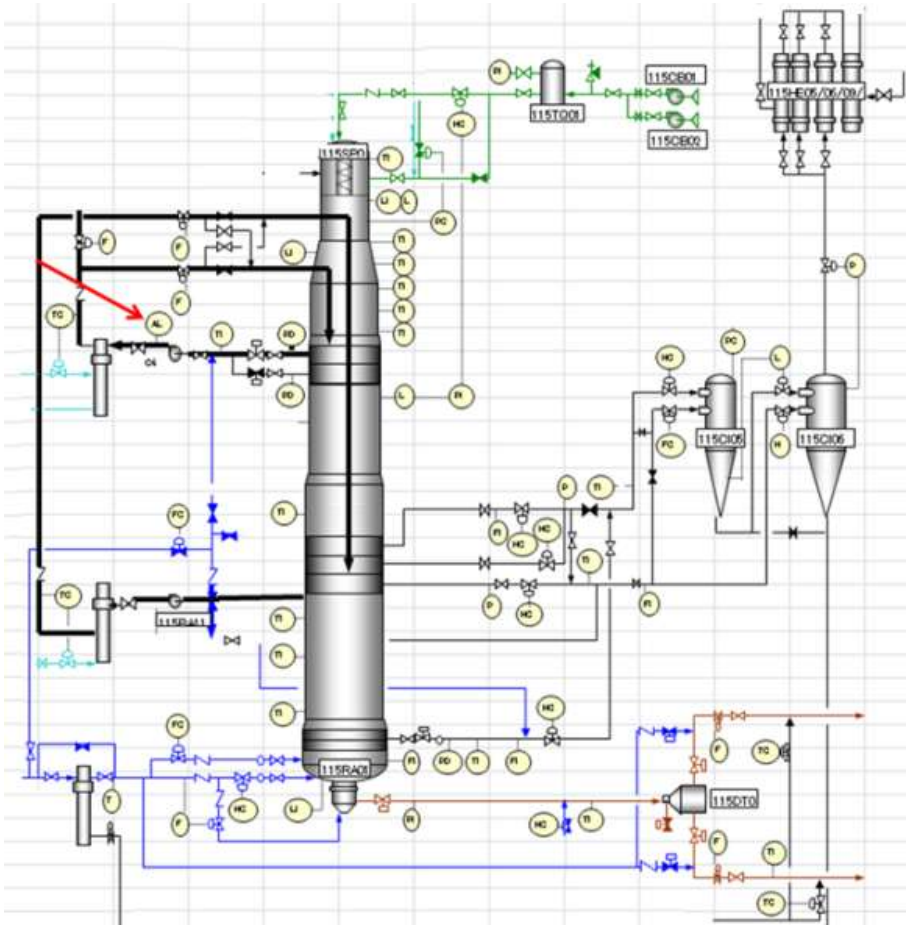


Figura 5.28 – Posição do instrumento de análise do álcali da circulação superior

Dados coletados de média horária foram tabulados para avaliação do no coeficiente de variação de Pearson[22] (CV) no álcali das circulações. O CV é uma das medidas de dispersão relativa, permitindo comparar a intensidade de variações em períodos diferentes. Ao contrário das demais empresas brasileiras, a indústria em referência não usava o "valor com *delay*" da amostra de densidade. Por conhecer as imperfeições do tempo de atraso, aplicava o valor da média móvel das últimas três análises. Para efeito informativo da verificação nas variáveis de processo do digestor, foram avaliadas amostras um ano antes da implantação da metodologia e dois anos após. A partir de janeiro de 2014, iniciou-se o uso do novo método. Ainda que não se possa afirmar que a redução do coeficiente de variação tenha sido causada exclusivamente por este fator, a Figura 5.29 é um indicativo de melhor aplicação da quantidade de álcali ao digestor com a nova metodologia.

[22] Coeficiente de variação de Pearson (CV) : Medida de dispersão relativa, obtida pela razão entre o desvio-padrão e a média (σ/μ).

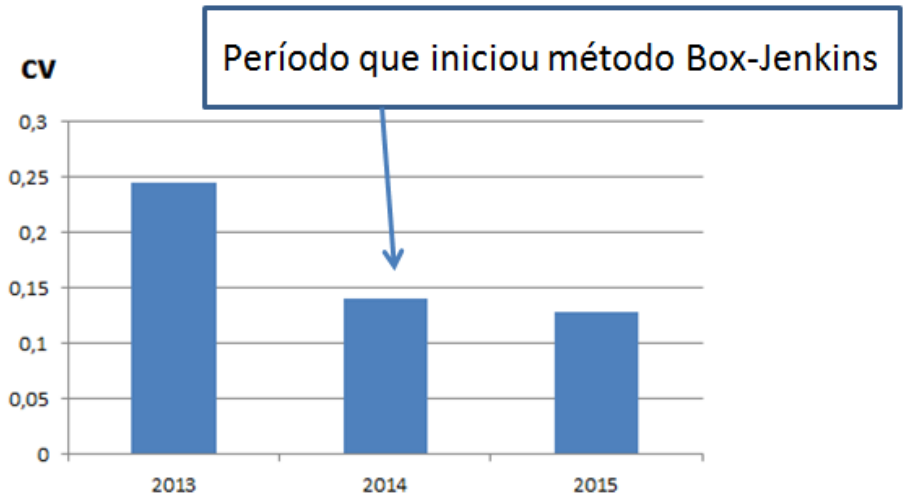


Figura 5.29 – CV antes e após a implantação do modelo ARMA

5.3.5 Comparativo entre os Métodos

A Tabela 5.5 resume os índices de previsão dos três métodos avaliados em relação à análise dos dados para elaboração do modelo [DENS1]. Foram também incluídos os dados do laboratório "sem predição" (isto é, com o indesejável tempo de atraso entre coleta e resultado da análise da densidade) na série. De uma maneira geral, os métodos preditivos apresentaram redução em todos os índices de desvios quando comparados a aplicação direta (sem estimação). O método ARMA foi superior que os demais em todos os índices de previsão, seguido por AES e MMS.

Tabela 5.5: Índices dos Erros de Previsão dos Modelos [DENS1]

Modelo	**Sem Predição**	**MMS**	**AES**	**ARMA**
MAD (kg/m^3)	4,00	3,41	3,28	3,14
MAPE (%)	2,30	1,96	1,89	1,81
RMSE (kg/m^3)	5,55	4,66	4,52	4,41

A Tabela 5.6 apresenta os índices estatísticos dos métodos avaliados, em relação aos dados para validação do modelo [DENS2], comparando-os com os dados sem predição.

Tabela 5.6: Índices dos Erros de Previsão dos Modelos [DENS2]

Modelo	**Sem Predição (*)**	**MMS**	**AES**	**ARMA**
MAD (kg/m^3)	3,78	3,16	2,97	2,84
MAPE (%)	2,17	1,80	1,70	1,63
RMSE (kg/m^3)	5,58	4,49	4,30	4,24
DW	--	1,77	1,85	2,23

(*) Sem predição : Dados aplicados com o tempo de atraso de execução da análise.

Confirmando a tendência do primeiro conjunto de dados [DENS1], todos os métodos apresentaram redução nos índices de desvios quando comparados a aplicação direta (sem predição). O método ARMA foi superior que os demais métodos em todos os índices de previsão, seguido por AES e MMS, atingindo uma redução de aproximadamente 25% no erro médio absoluto percentual quando se usa o valor sem nenhuma estimativa (2,17%→1,63%). O índice Durbin Watson mostrou que os resíduos são não correlacionados para todos os modelos. Interessante notar que todos os modelos apresentaram a mesma tendência de minimização de erros em ambas as séries [DENS1] e [DENS2], mesmo se tratando de séries de dados absolutamente distintos, com as observações coletados em períodos diferentes.

Comparando os resultados das Tabelas 5.5 e 5.6, observa-se que os índices calculados na validação foram ligeiramente menores que os índices da elaboração do modelo. Observa-se na coluna "Sem Predição" de ambas as tabelas, que os índices de erros na validação são também menores, indicando que o segundo conjunto de dados tem uma menor variabilidade em relação ao primeiro. O conceito inicial em elaborar uma série com 12 meses de observações [DENS1], foi buscar um período que envolvesse as quatro estações do ano, considerando que a variável "densidade de cavaco" pudesse estar associada às condições climáticas. A região de plantio da floresta possui clara sazonalidade nos índices pluviométricos, temperatura, umidade relativa do ar etc. Ao incluir o ciclo anual no conjunto de dados, esperava-se que a influência das variáveis climáticas fosse eliminada. No entanto, verifica-se que em um menor número de observações ([DENS2] ~ 2 meses) , obtêm-se índices de desvios melhores.

5.4. Conclusões

Foi apresentada neste capítulo a aplicação de métodos univariados de séries temporais (Média Móvel Simples MMS, Alisamento Exponencial Simples AES e Método Box-Jenkins de Séries Temporais ARMA) na predição da densidade a granel de cavacos de E*ucalyptus spp*. Os resultados foram analisados baseados em índices de erros de previsão e na análise dos resíduos. O método ARMA apresentou melhor desempenho nos critérios indicados, resultando em uma redução no erro do valor da densidade aplicada ao cálculo do fluxo de licor branco de um digestor contínuo industrial, quando comparado à aplicação do valor da análise laboratorial sem

estimativa de predição. Para a série analisada, aquela com menor conjunto de dados [DENS2] apresentou melhor desempenho em relação à de maior conjunto de dados [DENS1].

Um menor erro de aplicação da densidade no cálculo do fluxo de licor branco resulta numa melhor adequação da taxa do fluxo de licor branco à densidade do cavaco que está sendo alimentado. A melhor adequação da taxa do fluxo de licor possibilita menores variações da qualidade do processo do digestor. Considerando o impacto significativo das oscilações da matéria prima e demais dificuldades do processo apresentados nos itens 2.2 e 2.3, as técnicas aqui apresentadas são um "ajuste fino" visando melhor estabilizar a adição de álcali ao digestor. Esta técnica é uma ferramenta útil para melhoria da planta de cozimento e pode ser implementada em uma planilha eletrônica, permitindo inserção dos dados correntes pelo operador, recebendo como resposta o valor predito da densidade. Em um primeiro momento, pode-se imaginar que a redução do erro tenha sido muito pequena. Entretanto, pela magnitude dos altos volumes de produção das fábricas modernas (acima de 1.000.000 tSA/ano), a redução em 0,5 pontos percentuais no consumo de licor branco apresenta um resultado financeiro da ordem de centenas de milhares de dólares. O valor final apresenta alta variabilidade, considerando que o custo de produção do licor branco também é muito variável entre as fábricas, pois é fortemente dependente do tipo de combustível usado no forno de cal (que pode ser óleo combustível, gás natural ou outras fontes).

Estes métodos podem ser adaptados a outras unidades com reatores contínuos do processo Kraft, que possuam medidas corretivas com base nas análises da matéria prima, como por exemplo o forno de cal (que depende da análise da lama para aplicação dos parâmetros de temperatura e fluxo de alimentação). Outras aplicações em diferentes processos podem ser também aplicadas como na siderurgia em reatores de sinterização (que dependem da análise da matéria prima do sínter para determinação dos fundentes e temperatura), o alto-forno de gusa (que depende da análise do minério de ferro para aplicação dos parâmetros dos reagentes) etc.

No Capítulo 5 é desenvolvida uma abordagem de modelos preditivos aplicados no produto reagido do digestor. São apresentados os resultados da modelagem e da validação do número kappa (referência do teor de lignina resultante na polpa) em digestor contínuo, bem como um comparativo entre os modelos analisados.

Capítulo 6

Predição do Número Kappa

"But since all our measurements and observations are nothing more than approximations to the truth, the same must be true of all calculations resting upon them"
Theoria Motus, 1809



Carl Friedrich Gauss
(1777-1855)
Matemático Alemão

Capítulo 6

Predição do Número Kappa

O cozimento contínuo apresenta algumas dificuldades intrínsecas para sua modelagem. Os eventos físicos e químicos que ocorrem dentro do digestor são misturas de fenômenos de transporte e reações químicas complexas. O desenvolvimento de modelos fenomenológicos que representem o processo de cozimento da madeira é difícil devido aos seguintes fatores: natureza heterogênea do sistema no qual três fases (sólido/líquido/gás) estão presentes; medições difíceis (sistema pressurizado, sendo comum o uso de instrumentos radioativos); longo tempo de residência; complexidade da dinâmica no movimento da coluna de cavacos; não linearidade e interação entre as variáveis de processo. Por estas razões, a modelagem e identificação das equações do processo de cozimento contínuo são desafios permanentes. Tais desafios são mais presentes com a expansão das tecnologias de cozimentos modificados, que incluem alternativas de adição de licores ao longo do corpo do digestor e recuperação de sólidos.

Nos últimos anos, o aumento da capacidade de *software* e *hardware* tem proporcionado melhores ferramentas para tomada de decisões de processo. O desenvolvimento e aplicações de métodos de previsão é uma das formas de melhor uso destas ferramentas (MAKRIDAKIS, 1998).

Neste contexto, este capítulo apresenta alguns modelos preditivos do número kappa em um digestor contínuo de celulose Kraft. São apresentados os materiais e métodos, os resultados obtidos, bem como comparações entre eles por índices de desempenho.

6.1. Introdução

O número kappa é a principal referência de controle no digestor. Se for baixo afeta o rendimento e propriedades da polpa (HART e CONNELL 2006) e se for elevado pode causar perdas na produção pelo excesso de rejeitos que alimenta a planta de depuração. Visando antecipar o resultado desta variável na descarga do digestor, os analisadores *on line* hoje disponíveis dispõem de mecanismos de análise da polpa na fase intermediária do digestor (*mid kappa*). Infelizmente os resultados não têm sido

promissores, face às dificuldades de transporte da amostra em um ponto em que ainda não ocorreu formação completa da polpa. Para fibra curta, o ponto em que o cavaco perde as características de madeira e assume a característica de polpa, é em torno de número kappa 25 (vale lembrar que o resultado da análise de uma amostra apesar de ser apresentado como um valor discreto, trata-se de uma média de uma distribuição do mesmo), sendo possíveis valores ligeiramente superiores conforme a tecnologia de cozimento (LINDSTROM 2007).

O ponto de separação de fibras em madeiras de fibra longa tende a ocorrer em número kappa maiores devido à maior relação de grupos siringil:guaiacil comparados com madeiras de fibra curta (LINDSTROM 2011). Os grupos guaiacil reagem mais lentamente do que os grupos siringil (SANTOS *et al.* 2011). Os grupos siringil da lignina (em maior quantidade nas folhosas) reagem mais rapidamente do que os grupos guaiacil resultando em um menor conteúdo de lignina na polpa antes das fibras se tornarem quimicamente separadas, quando comparadas com madeiras de fibra longa.

No início da década de 1990, muitas pesquisas foram desenvolvidas com foco em ampliar a zona de cozimento, terminando o cozimento com um menor teor de lignina, usando a zona de cozimento estendido. A força motriz era a necessidade de reduzir os impactos ambientais do branqueamento, com menor carga orgânica ao efluente. Contudo, a deslignificação na fase final do digestor é muito lenta e com fraca seletividade, produzindo polpas degradadas, tornando-se um fator restritivo.

Já na década de 2000, maior atenção foi dedicada às reações da lignina, dos carboidratos e formação dos ácidos hexenurônicos (HexA), alterando o foco para os processos de maior rendimento da madeira, conduzindo ao término do cozimento com maior número kappa (KARLSTROM e LINDSTROM 2008; HART *et al.* 2011; WEDING 2012).

Com a tendência das fábricas buscarem número kappa em patamares mais elevados pelo maior rendimento, associado ao baixo índice do número kappa em que ocorre a desfibrilação das folhosas, a modelagem com foco em predição de número kappa neste tipo de madeira adquire uma importância particular. Várias são as pesquisas nesta área (sumarizadas no Capítulo 2), mas em sua maioria voltada para madeiras coníferas. Além disso, poucos autores reportam os desvios obtidos em seus

modelos de forma clara para uma análise estatística comparativa através de índices formais.

Assim, buscou-se formular modelos de inferência para o número kappa da celulose Kraft de eucalipto em digestor contínuo, usando os métodos de diferentes níveis de complexidade. Foram usados métodos simples como Alisamento Exponencial Simples (AES), métodos tradicionais como Regressão Linear Múltipla (RLM), passando a métodos mais complexos como Análise Box-Jenkins de Séries Temporais (ARMA) e Redes Neurais Artificiais (RNA). Os resultados dos quatro métodos foram discutidos e comparados.

6.2. Materiais e Métodos

Os dados usados neste estudo, foram oriundos de um digestor contínuo fase vapor, modelo Kamyr com capacidade de produção de 500.000 tSA/ano[23] de celulose Kraft de *eucalyptus spp* localizada na região sudeste do Brasil, conforme Figura 6.1.

Os dados foram coletados em uma frequência de 30 minutos, com análises do número kappa realizada em analisador em linha. Um total de 2.814 observações consecutivas foi dividido em dois conjuntos de dados tabulados em ordem cronológica.

O primeiro conjunto refere-se a um período de aproximadamente 1 mês de operação, com 1.471 observações, usado para elaboração dos modelos, doravante denominado [KAPPA1]. O segundo conjunto de dados refere-se a um período aproximado de 1 mês de operação com 1.343 observações, usado para validação dos modelos (doravante denominado [KAPPA2]). Em ambos os grupos foram excluídos os dados com valores dúbios e *outliers*. Para análise dos dados foi usado o *software eViews Econometric Views v.5* nos métodos AES, RLM e ARMA, e o *software MATLAB MATrix LABoratory v.7.9.0* no método RNA.

Para seleção dos modelos, foram considerados diferentes critérios estatísticos de decisão como MAD, MAPE, RMSE, AIC, BSC, DW, TIC. Conceitos destes índices estão sumarizados no *Anexo 3.2*.

---

[23] *tSA = tonelada seca ao ar : Por ser higroscópica, a celulose entra em equilíbrio* com *a umidade do ar, adquirindo valores próximos de 10%, independente da umidade original. É unidade padrão internacional para referência de produção de celulose (equivalente a 10% de umidade).*

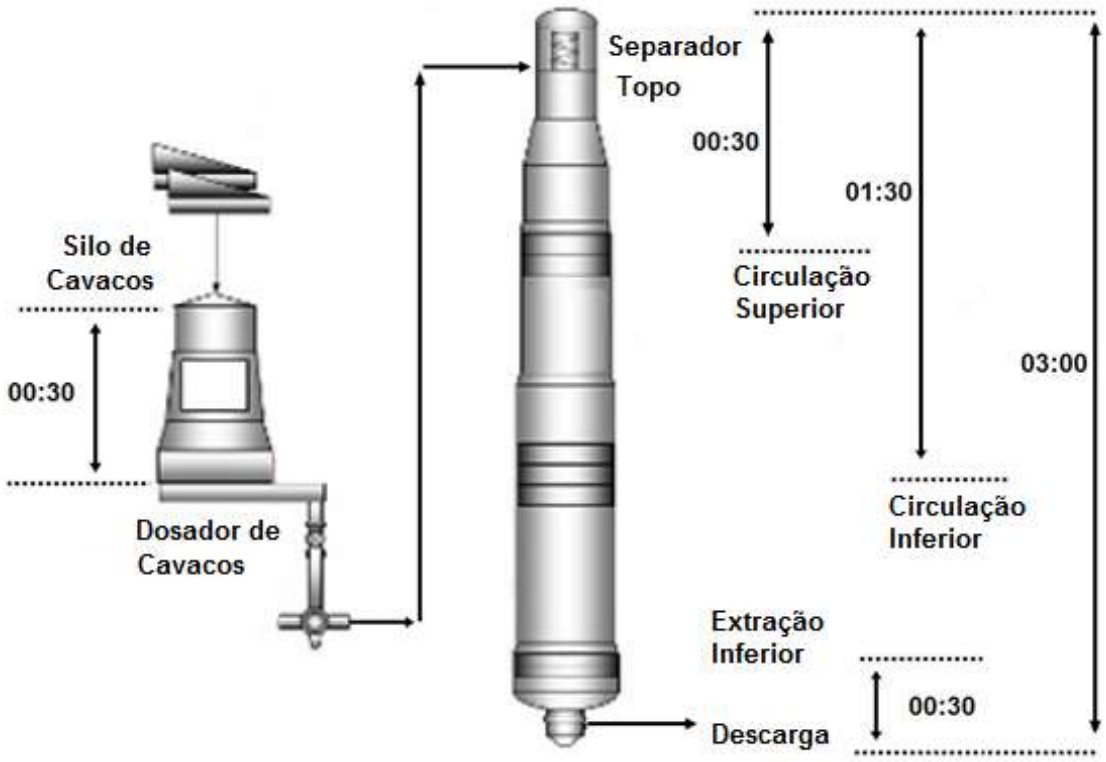


Figura 6.1 – Tempo de retenção das principais zonas do digestor contínuo

6.3. Resultados e Discussão

6.3.1 Análise Preliminar dos Dados

Os dados do primeiro conjunto [KAPPA1] foram tabulados em sua evolução cronológica, conforme indicado na Figura 6.2. Pela análise visual do gráfico, pode-se observar homocedasticidade dos dados e estacionariedade da série, não se fazendo necessária a diferenciação da mesma.

Por questões de confidencialidade, a escala dos valores reais do número kappa coletados na indústria foram intencionalmente normalizados para média um nas figuras 6.2, 6.3, 6.9 e 6.17.

Aspectos de normalidade podem ser identificados pelo grande volume de amostras e análise visual do gráfico da Figura 6.3, onde é apresentado o histograma dos dados.

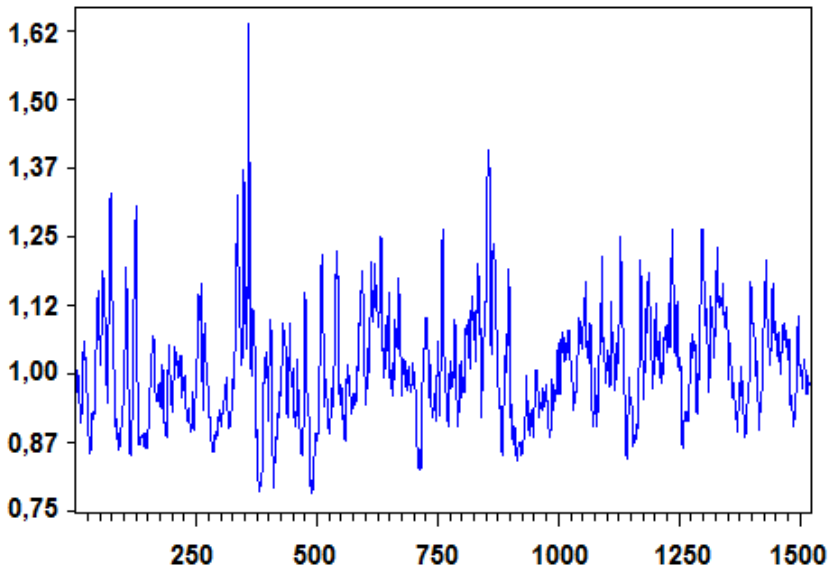


Figura 6.2 - Evolução cronológica número kappa [KAPPA1]

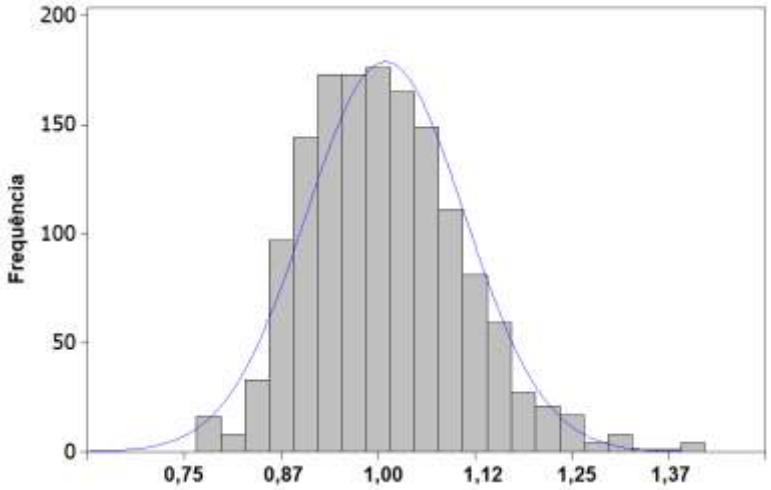


Figura 6.3 - Histograma número kappa [KAPPA1]

6.3.2 Método de Alisamento Exponencial Simples (AES)

De acordo com a Figura 6.2, o conjunto de dados para construção do modelo é uma série temporal não sazonal, sem tendência, viabilizando a aplicação do modelo AES.

Foi aplicada a Equação 4.2 para estimativa dos dados com diferentes valores do *índice de ponderação* α, foram obtidos iterativamente os índices de desvios MAD,

RMSE e MAPE conforme as equações 5.1, 5.2 e 5.3 que estão ilustrados nas Figuras 6.4 (a) e 6.4 (b) com o gráfico de superfície entre o índice α e os desvios citados.

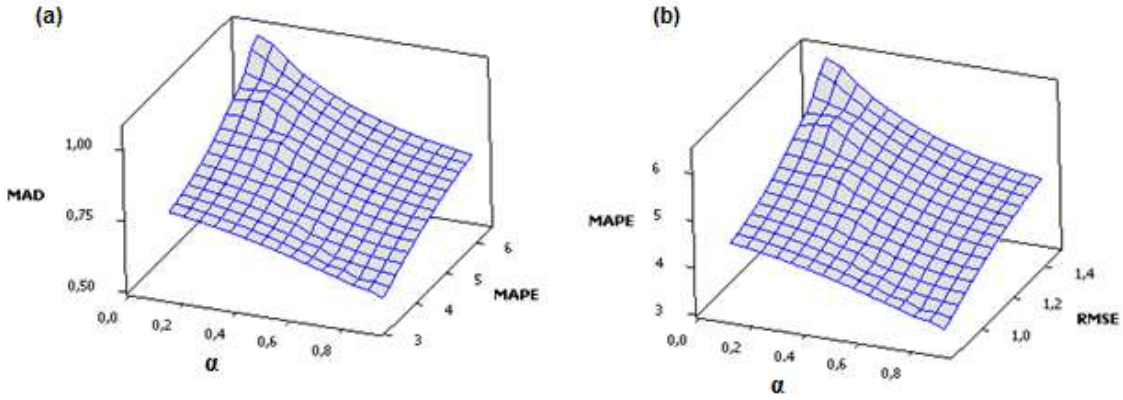


Figura 6.4 – Gráfico de Superfície : (a) Gráfico α x MAD x MAPE [KAPPA1]
(b) Gráfico α x MAPE x RMSE [KAPPA1]

Em complemento, foi analisado o valor do índice de ponderação α *versus* produto (MAD x RMSE x MAPE). O objetivo desta avaliação, foi analisar o índice α em relação aos três índices de erro associados. A Figura 6.5 mostra que α = 0,9 apresenta o menor valor dos erros em conjunto, sendo então este o valor selecionado para ser usado na etapa de validação. O índice α = 0,9 apresentou os valores de MAD = 0,57; MAPE = 3,39 e RMSE = 0,85. Tais índices estão sumarizados no *Apêndice3.2* - Tabela A3.1 , bem como os dados que geraram os gráficos das Figuras 6.4 e 6.5.

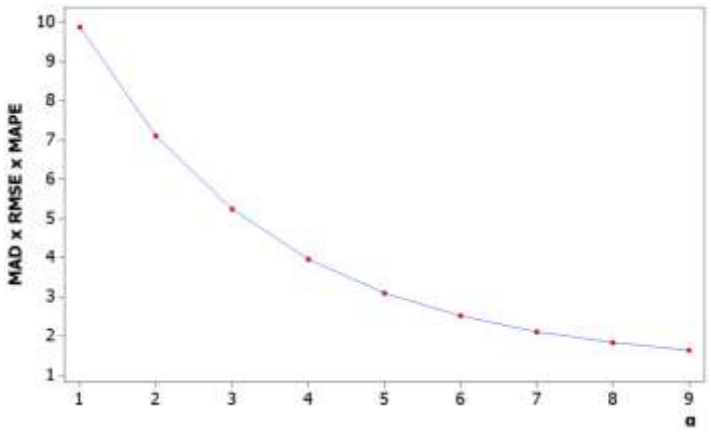


Figura 6.5 – Gráfico α x (MAD x MAPE x RMSE) [KAPPA1]

Aplicando o índice de ponderação α = 0,9 na Equação 4.2, foi obtida a Equação 6.1, para estimativa dos valores da série com o método AES:

$$\hat{Y}_t = 0{,}9Y_{t-1} + 0{,}1\hat{Y}_{t-1} \tag{6.1}$$

Para inicialização do modelo, foi aplicada a média das três primeiras observações. Tais dados foram comparados com o valor observado no segundo conjunto de dados [KAPPA2], sendo o histograma de seus resíduos indicado na Figura 6.6, que mostra normalidade em torno de média zero, com boa assimetria e curtose[24].

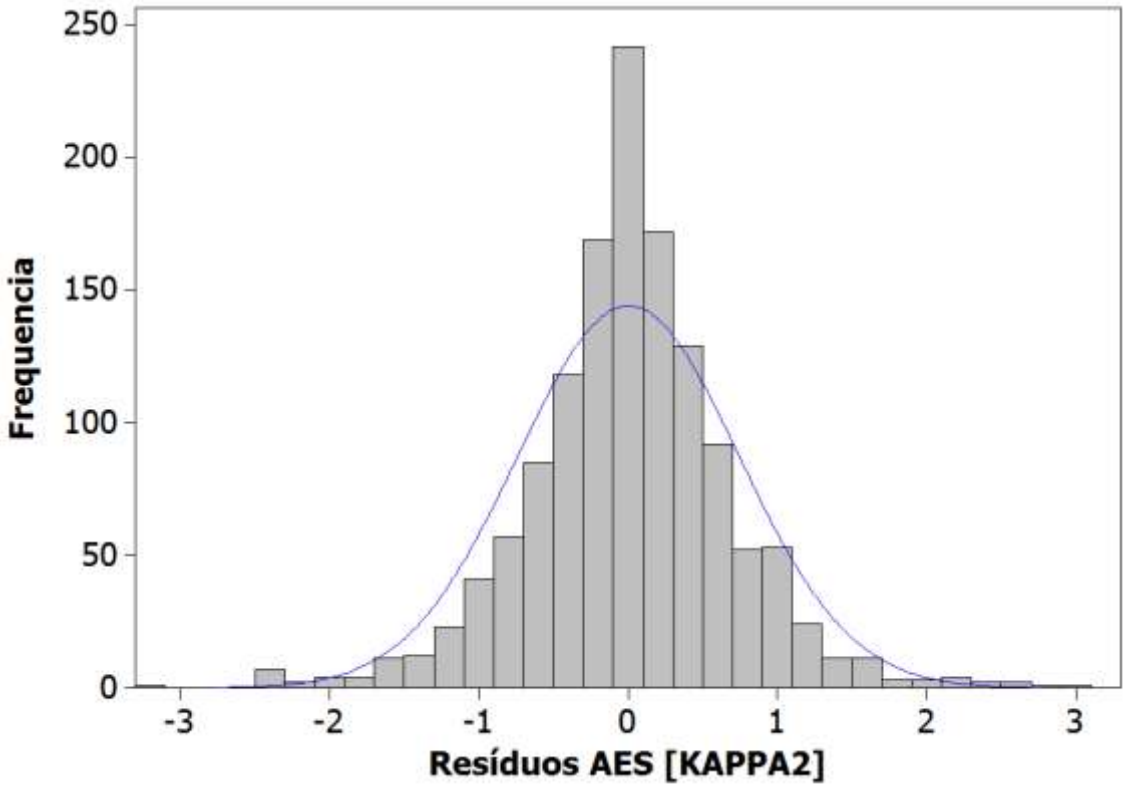


Figura 6.6 - Histograma dos resíduos modelo AES [KAPPA2]

O índice Durbin Watson (calculado conforme Equação A3.7), apresentou valor 1,26 , ficando fora do intervalo (DW < 1 ou DW > 3) conforme reportado no *Anexo 3.2*, mostrando que não há evidência de autocorrelação entre os resíduos.

A Tabela 6.1 apresenta os índices de desempenho de previsão estatística para este método.

[24] Curtose: *Grau de "achatamento" de uma distribuição de freqüências que indica o grau de concentração em torno do centro desta. Pode ser Mesocúrtica (igual), Platicúrtica (menor) ou Leptocúrtica (maior que a da distribuição normal).*

Tabela 6.1 - Índices de desempenho de previsão para o modelo AES [KAPPA2] :

Índice	**Valor**
R	0,85603
R^2	0,73279
MSE	0,73090
RMSE	0,85493
MAPE	0,03674
DW	1,26

Resultados comparativos dos índices estatísticos deste e dos demais métodos estão sumarizados na Tabela 6.12.

Comparativo de dados modelados *versus* observados deste e dos demais métodos estão sumarizados na Figura 6.21.

Informações complementares do desenvolvimento deste modelo encontram-se no *Apêndice 3.1*.

6.3.3. Método Regressão Linear Múltipla (RLM)

Seleção das variáveis:

Um problema relevante em muitos estudos exploratórios é a escolha das variáveis a serem avaliadas nos modelos de previsão. Uma consideração importante é a extensão em que uma variável escolhida contribui para reduzir a variação na resposta remanescente, em relação às contribuições das outras variáveis que tenham sido incluídas no modelo. Outras considerações incluem a importância da variável como um agente causador no processo em análise, o grau em que as observações sobre a variável podem ser obtidas adequadamente e o grau em que a variável pode ser controlada (KUTNER *et al*. 2005).

Foram selecionadas 17 variáveis de processo que influenciam as reações de deslignificação, indicadas na Tabela 6.2. Esta seleção foi baseada nos conceitos da literatura geral sobre o processo Kraft e pela experiência do autor em digestor contínuo nas avaliações das ocorrências de variação do número kappa. Nesta etapa, não foram identificadas variáveis categóricas que fossem pertinentes ao conjunto da análise, e por esta razão não foram incluídas.

Estas variáveis foram apropriadamente ajustadas conforme o fluxo de processo e tempo de retenção apresentados na Figura 6.1.

Tabela 6.2 - Variáveis de Cozimento Selecionadas na Análise Inicial RLM

Variável	**Descrição**	**Unidade**	**Retenção (h)**
1. DENS	Densidade a granel do cavaco	kg/m^3	3,5
2. CS	Consistência do cavaco	%	3,5
3. TRET	Tempo de retenção do silo de cavacos	min	3,5
4. TSILO	Temperatura do silo de cavacos	ºC	3,5
5. RPM	Rotação rosca dosadora de cavacos	RPM	3,5
6. RLM	Relação licor/madeira	m^3/t	3
7. CA	Carga alcalina	%AE	3
8. S	Sulfidez	%	3
9. TTOPO	Temperatura topo do digestor	ºC	3
10. P	Pressão no topo do digestor	kg/cm^2	3
11. ACSUP	Álcali efetivo circulação superior	g/L	2,5
12. TCSUP	Temperatura circulação superior	ºC	2,5
13. ACINF	Álcali efetivo circulação inferior	g/L	1,5
14. TCINF	Temperatura circulação inferior	ºC	1,5
15. EXTFUN	Percentual extração de licor inferior	%	0,5
16. LPDFUN	Fluxo Licor Preto Diluído aplicado ao fundo	m^3	0,5
17.LPD/RPM	Relação LPDFUN/RPM	m^3/RPM	0,5
18. KANT	Número kappa anterior	Un. kappa	0,5
19. KAPPA	Número kappa	Un. kappa	0

Os dados do número kappa foram tabulados e plotados em relação a todas as variáveis indicadas na Tabela 6.3. Conforme Figura 6.7, com exceção do "kappa anterior", todas variáveis são não (ou muito pouco) correlacionadas.

Foram tabuladas as 17 primeiras variáveis indicadas na Tabela 6.2, visando detectar os principais padrões de similaridade entre as variáveis com a menor perda de informação. Como se observa na Figura 6.8 através da FAC, esta variável é fortemente correlacionada com o número kappa anterior. Assim, foi incorporada esta variável na dinâmica de modelo da matriz do número kappa.

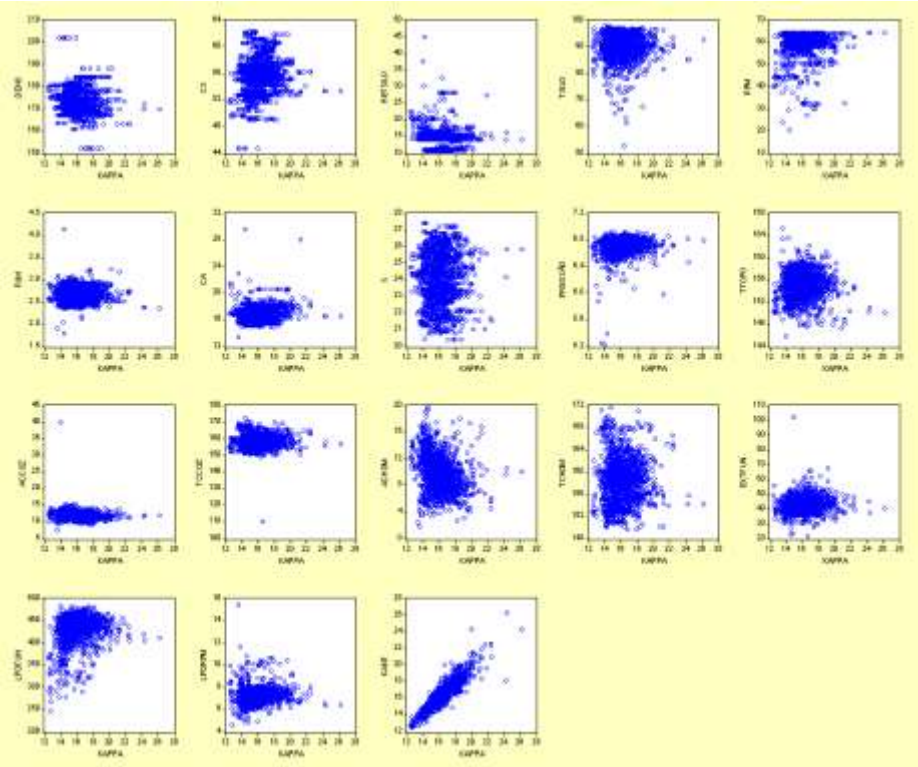


Figura 6.7: Correlação entre variáveis e número kappa

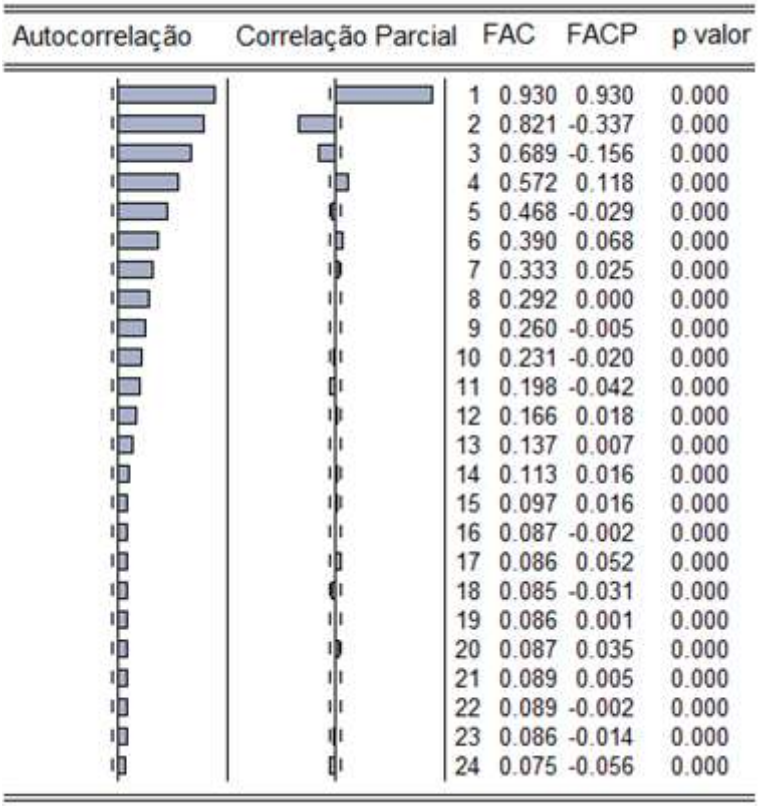


Figura 6.8 - Correlograma do número kappa

Ao conjunto das variáveis indicadas na Tabela 6.3, a Análise de Regressão Linear Múltipla (RLM) foi aplicada, visando obter uma relação entre a variável dependente (número kappa) e as demais variáveis regressoras, usando o método MQO.

A fim de eliminar as variáveis que não afetam significativamente a variável resposta, foi usado o método *step wise*[25], sendo testados o nível α de significância[26] 0,05; 0,10 e 0,15 .

Tabela 6.3 - Coeficientes do modelo RLM para estimativa do número kappa

Variável	Coeficiente	Desvio Padrão	p-valor
TTOPO	-0,030615	0,008194	0,000
TCINF	-0,040998	0,007724	0,000
TCSUP	-0,019371	0,007973	0,015
ACSUP	-0,052396	0,015349	0,000
ACINF	-0,093956	0,009374	0,000
CONSTANTE	15,723480	1,575070	0,000
CA	0,039818	0,016071	0,013
EXTFUN	0,009219	0,003186	0,003
KANT	0,883248	0,009784	0,000
LPDRPM	0,058975	0,025962	0,023
RETSILO	-0,017674	0,008349	0,034
RPM	0,012757	0,003851	0,000

Pela análise dos resíduos foi escolhido o nível α de significância 0,10 para inclusão e remoção. Como resultado, 11 variáveis foram selecionadas como variáveis de entrada para os modelos RLM e RNA, e aplicando MQO foram encontrados os coeficientes estimados indicados na Tabela 6.3 para a Equação 6.2.

$$\boldsymbol{KAPPA = 15,7235 - 0,0306\ TTOPO - 0,0410\ TCINF - 0,0194\ TCSUP - 0,0524\ ACSUP - 0,0940\ ACINF + 0,0398\ CA + 0,0092\ EXTFUN + 0,8832\ KANT + 0,0590\ LPDRPM - 0,0177\ RETSILO + 0,0128\ RPM} \quad (6.2)$$

[25] *stepwise : método para a seleção de variáveis por adição ou remoção destas no modelo, realizada com base em um teste estatístico de significância de cada variável (Anexo A3.10).*

[26] *nível α de significância : um resultado tem significância estatística se for improvável que tenha ocorrido por acaso. O nível α é a base para afirmar que um desvio é decorrente do acaso .*

Evolução iterativa da análise de regressão e seus dados complementares estão apresentados no *Apêndice 3.2*.

Resultados da evolução do kappa modelado e kappa observado da etapa de modelagem estão apresentados na Figura 6.9, onde pode se observar que as curvas praticamente se sobrepõem.

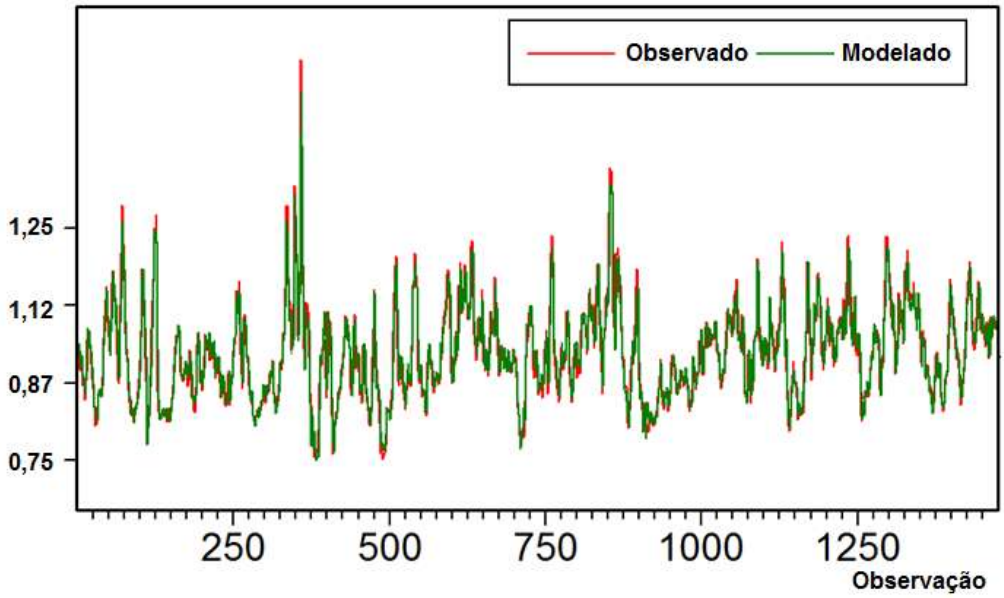


Figura 6.9 - Evolução predição do número kappa Modelo RLM [KAPPA1]

Resultados estatísticos do desempenho deste modelo são apresentados na Tabela 6.4, onde se observa bons resultados com o índice MAD < 0,5 unidades de número kappa. Isto é, a média dos desvios dos erros absolutos foram muito baixos, com um erro percentual médio de 2,4 %. Verifica-se ainda que o *Coeficiente de Desigualdade de Theil* TIC foi próximo de zero, com suas proporções em valores adequados. A Proporção Bias (do viés) foi zero (indicando que a média estimada da série teve o mesmo valor da média real). Da mesma forma a proporção da variância foi próximo de zero, indicando boa capacidade do modelo de repetir a variabilidade da variável de interesse. Em complemento, a proporção da covariância (que mede os erros de previsão não previstos no modelo) atingiu o desejável valor próximo de um. Ou seja, o modelo proposto atingiu a distribuição ideal das proporções $BP \approx VP \approx 0$ e $CV \approx 1$.

Quanto aos resíduos, são apresentados sua evolução na Figura 6.10, onde mostra a desejável homocedasticidade dos mesmos, com média próximo de zero ao longo do tempo e variância constante, com exceção de dois picos próximo à observação 300.

Tabela 6.4 - Desempenho do Modelo RLM [KAPPA1]

Índices	**Valores**
MAD	0,3891
MAPE	2,3530
RMSE	0,5572
TIC	0,0172
Proporção Bias	0,0000
Proporção Variância	0,0306
Proporção Covariância	0,9694

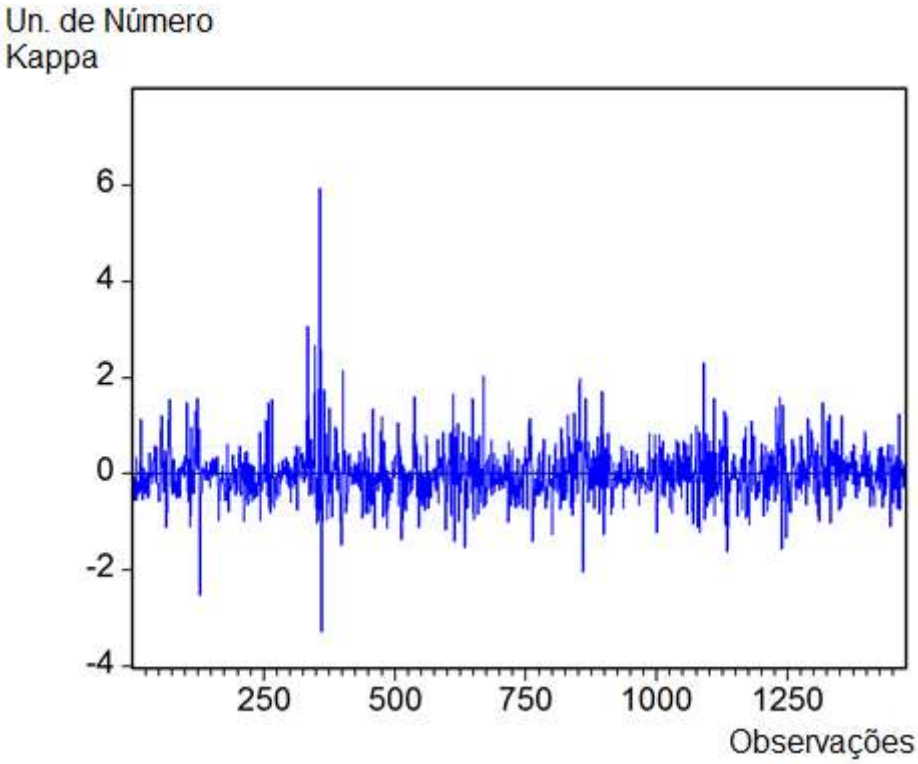


Figura 6.10 - Evolução dos resíduos modelo RLM [KAPPA1]

A Figura 6.11 mostra o histograma com distribuição normal e adequada simetria. O valor da curtose mais elevado, é justificado pelos dois pontos atípicos próximo à observação 300 da Figura 6.10.

Complementando o histograma, a Tabela 6.5 apresenta a estatística descritiva dos resíduos, mostrando os valores desejáveis próximos de zero para média e mediana, boa assimetria, porém com curtose elevada conforme explicado aos pontos próximos à observação 300.

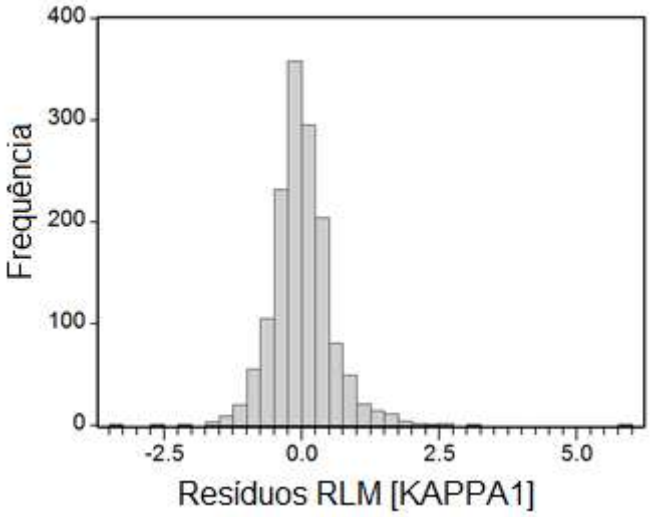


Figura 6.11 - Histograma dos resíduos RLM [KAPPA1]

Tabela 6.5 - Estatística descritiva dos resíduos RLM [KAPPA1]

Índices	**Valores**
Média	2,12E-15
Mediana	-0,0437
Máximo	5,9462
Mínimo	-3,2773
Desvio Padrão	0,5574
Assimetria	1,2352
Curtose	14,5366

O segundo conjunto de dados [KAPPA2], foi aplicado à equação obtida (Eq. 6.1) para validação do modelo. Os dados obtidos foram comparados com os valores reais do número kappa. A Figura 6.12 apresenta o histograma dos resíduos e a Tabela 6.6 apresenta alguns índices de desempenho de previsão estatística para este método.

O índice Durbin Watson foi calculado, com valor 1,32, mostrando que não há evidência de autocorrelação entre os resíduos.

Observa-se que a validação do modelo apresentou um erro percentual médio de aproximadamente 4 %, ficando ligeiramente superior ao apresentado pelo conjunto de dados de elaboração [KAPPA1] (2,4 %). Apesar das restrições já apontadas quanto ao uso do R^2, observa-se que o valor obtido ficou dentro das referências do Quadro 2.1 (0,56 ~ 0,82), próximo dos limites superiores. O valor RMSE ficou muito inferior ao da única referência que reportou este índice para fibra curta (1,4 ~ 3,3), apresentados nesta mesma tabela.

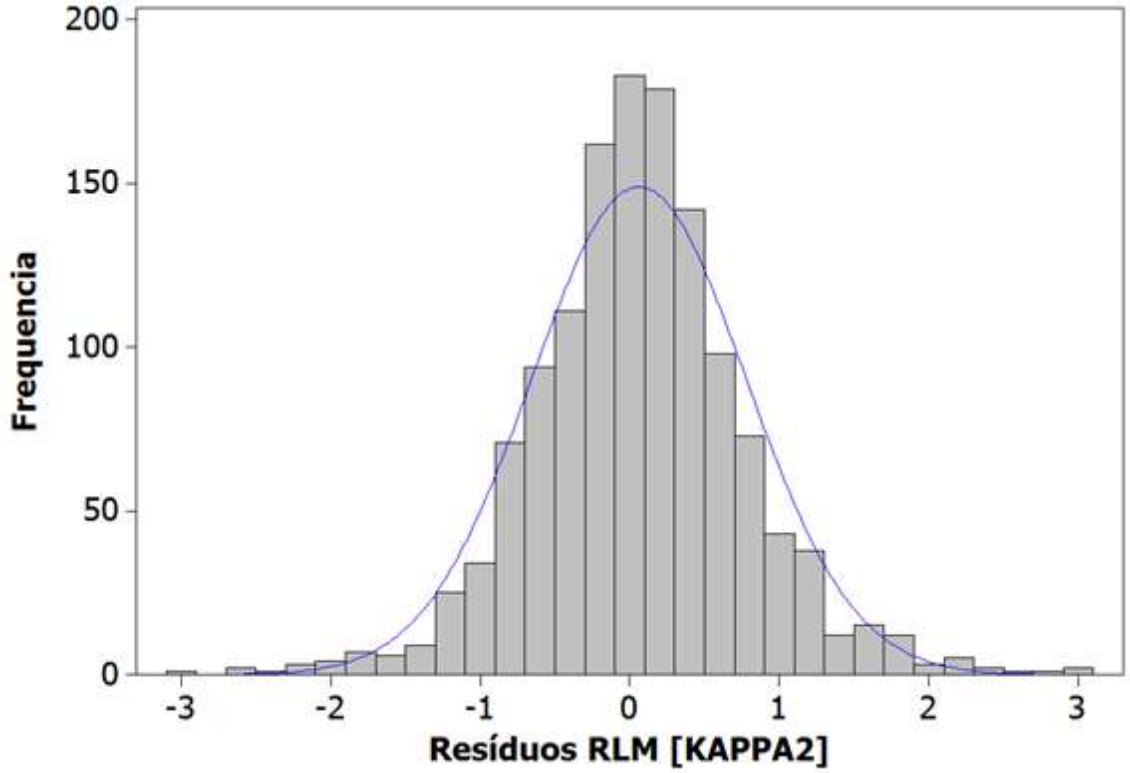


Figura 6.12 - Histograma Resíduos Modelo RLM [KAPPA2]

Tabela 6.6 - Índices de desempenho de previsão para o modelo RLM [KAPPA2]

Índice	**Valor**
MAD	0,6640
R^2	0,7752
MSE	0,7363
RMSE	0,8581
MAPE	0,0391
DW	1,32

Resultados comparativos dos índices estatísticos deste e dos demais métodos estão sumarizados na Tabela 6.12.

Comparativo de dados modelados *versus* observados deste e dos demais métodos estão sumarizados na Figura 6.21.

6.3.4. Método Redes Neurais Artificiais (RNA)

Para manter os critérios de comparação, foram usados como variáveis de entrada as 11 variáveis selecionadas no modelo RLM, apresentadas na Tabela 6.4 e como variável de saída o número kappa.

O modelo de redes neurais artificiais foi construído seguindo as etapas Especificação da Rede, Seleção e Validação do Modelos.

Etapa 1: Especificação da Rede

Foi selecionada a arquitetura MLP, função de transferência tangente hiperbólica por ser uma das mais usadas (HAYKIN 1994).

Foi selecionada uma camada oculta dentro dos critérios de parcimônia e resultados (MAYER e DANDY 2001).

Quanto ao número de épocas[27] foram testadas 500, 750 e 1000 épocas, sendo escolhido o valor intermediário, pela característica dos resultados conforme indicado na Figura 6.13 que ilustra um dos testes realizados. Como se pode observar, a curva atinge patamar de estabilidade por volta do número de 100 épocas. Foi escolhido então 750 épocas como uma referência conservadora.

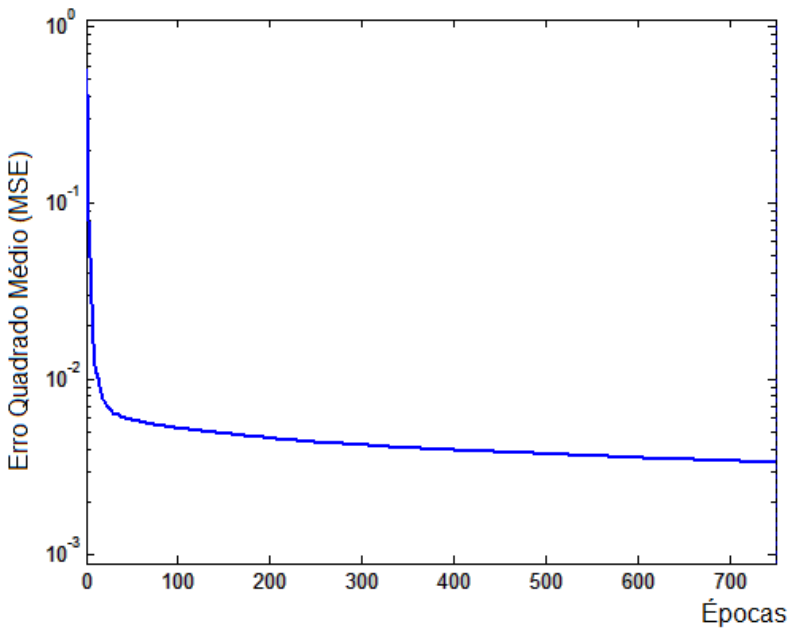


Figura 6.13 – Ilustração evolução número de épocas x MSE

As características de Especificação da Rede estão indicadas no Quadro 6.1 :

[27] *Época : Uma época é contada a cada apresentação à rede neural de todos os exemplos do conjunto de treinamento.*

Quadro 6.1 - Especificação da RNA - Etapa 1 :

1.1	Arquitetura	*Multi-Layer Perceptron* (MLP)
1.2	Entrada	11 variáveis (Tabela 6.4)
1.3	Saída	1 variável (número kappa)
1.4	Camada oculta	1
1.5	Função Transferência	Tangente Hiperbólica
1.6	Número de épocas	750 (após seleção)
1.7	Percentual de treinamento	75%
1.8	Percentual de validação	25%
1.9	Camada saída com função de transferência	Identidade

Etapa 2: Seleção do Modelo

Etapa 2A: Seleção do número de neurônios na camada oculta

A fim de selecionar o melhor modelo da RNA, foram usadas as equações 4.8 e 4.9 para determinação do número máximo de neurônios, sendo obtido respectivamente as Equações 6.3 e 6.4:

$$N_o \leq (2N_e + 1) \quad (4.8)$$

$$N_o \leq (2 \text{ x } 11 + 1) \leq 23 \quad (6.3)$$

$$N_o \leq N_{TR}/(N_e + 1) \quad (4.9)$$

$$N_o \leq (0{,}75 \text{ x } 1471)/\,(11 + 1) \leq 91{,}9 \quad (6.4)$$

Nas quais:

N_o = número de neurônios na camada oculta;
N_e = número de entradas ;
N_{TR} = número de dados para treinamento.

Foi escolhido o menor valor entre eles, sendo selecionado o número máximo de 23 neurônios na camada oculta, conforme calculado na Equação 6.3.

Para obtenção de dados com representatividade estatística, a rede foi processada em cada valor (1 a 23 neurônios) por 30 vezes. Para a escolha do número de neurônios foram considerados:

(i) Coeficiente de Correlação de Pearson (r);
(ii) Raiz do erro quadrado médio entre os valores estimados e observados (RMSE);
(iii) Coeficiente angular (α) da reta de associação entre os valores estimados pelo modelo e o valor real;

(iv) Coeficiente linear (intercepto β) da reta de associação entre os valores estimados pelo modelo e o valor real;

Tais índices estão apresentados nas Figuras 6.14 a 6.17, nas quais as barras verticais no gráfico representam intervalo de confiança da média ($\alpha = 0{,}95$).

A Figura 6.14 apresenta a evolução dos resultados obtidos do número de neurônios com o coeficiente *r* (quanto maior melhor). Pode se verificar que os índices de 1 e 3 neurônios apresentaram melhores valores.

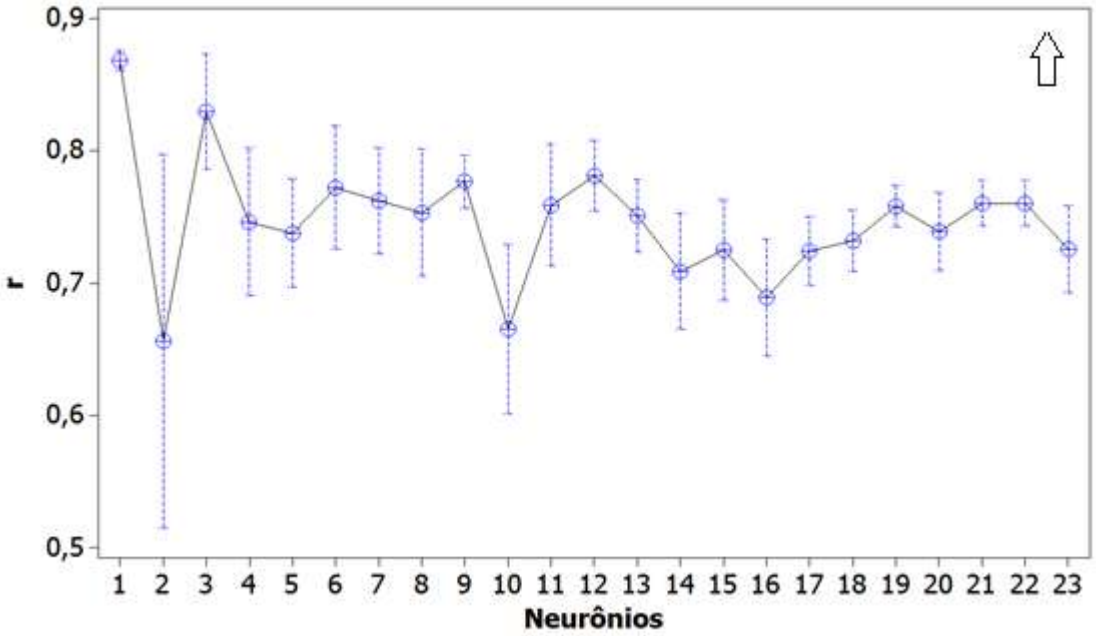


Figura 6.14 – Evolução número de neurônios x Coef. de Correlação de Pearson [KAPPA1]

A Figura 6.15 apresenta a evolução do RMSE (quanto menor melhor). Observam-se bons resultados para 1, 2 e 4 neurônios.

A Figura 6.16 apresenta a evolução do coeficiente angular (*a*) da reta de associação entre os valores estimados pelo modelo e o valor real (quanto mais próximo do valor 1, melhor). Observa-se que o índices 1, 2, 3, 5 e 7 neurônios apresentaram melhores resultados.

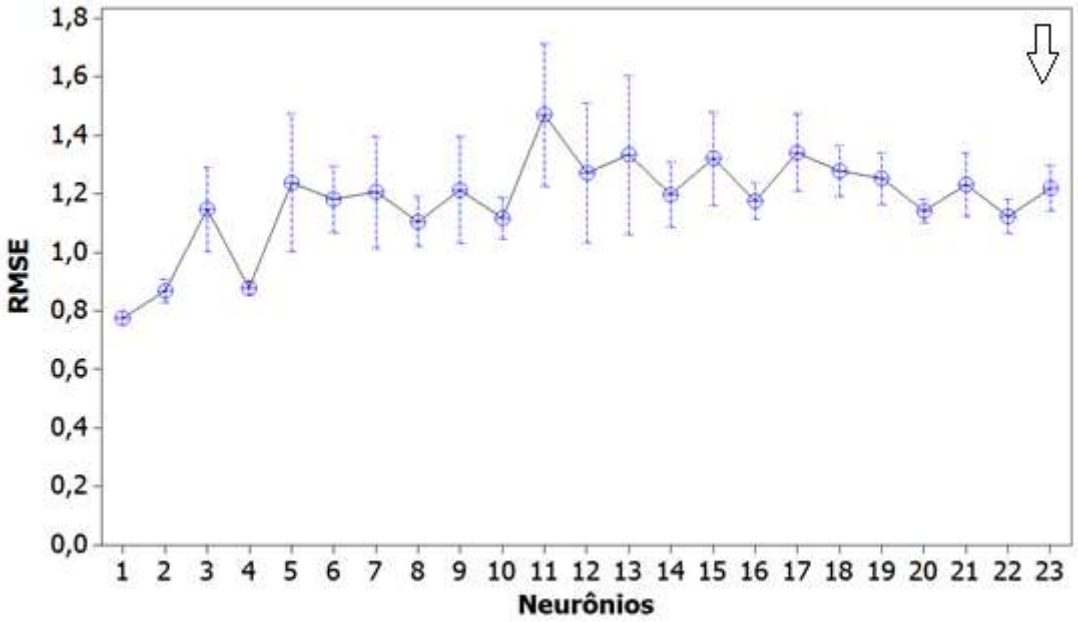


Figura 6.15 – Evolução número de neurônios x RMSE [KAPPA1]

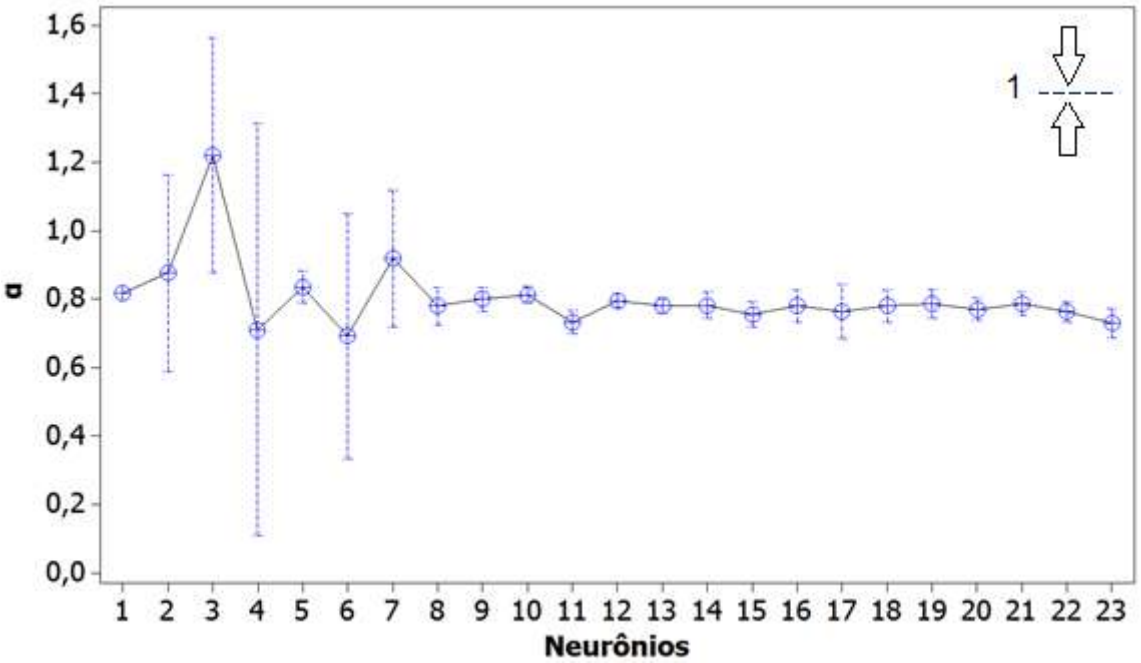


Figura 6.16 – Evolução número de neurônios x Coeficiente *a* [KAPPA1]

A Figura 6.17 apresenta a evolução do coeficiente linear (*b*) da reta de associação entre os valores estimados pelo modelo e o valor real (quanto mais próximo do valor 0, melhor). Observa-se que o índice de 3 neurônios apresentou o melhor resultado.

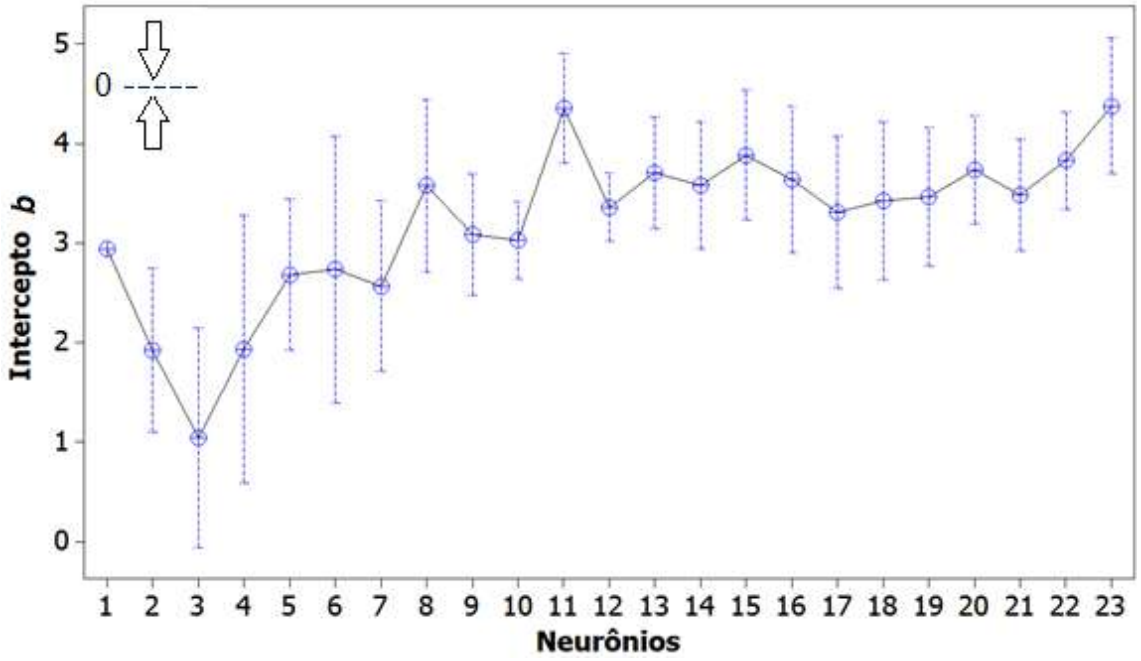


Figura 6.17 – Evolução número de neurônios x Intercepto *b* [KAPPA1]

Pela associação dos índices *r*, RMSE, *a* e *b* indicados, foi selecionado o valor de 3 neurônios para a camada oculta. Com a arquitetura da rede contemplando os parâmetros indicados, descarta-se a possibilidade de ter ocorrido sobre ajuste.

Outros dados complementares do modelo RNA encontram-se no *Apêndice 2.4.*

Etapa 2B: Estimação final do modelo

Uma re-estimação dos pesos da matriz para a RNA selecionada, usando três neurônios na camada oculta e o mesmo conjunto de dados de treinamento e validação [KAPPA1] foi elaborada, obtendo os resultados tabulados na Figura 6.18, cujos valores reais foram intencionalmente omitidos. A equação da reta não tracejada formulada pelo *software* foi indicada pela Equação 6.5:

Kappa Estimado = (0,84) Kappa observado + 2,6 (6.5)

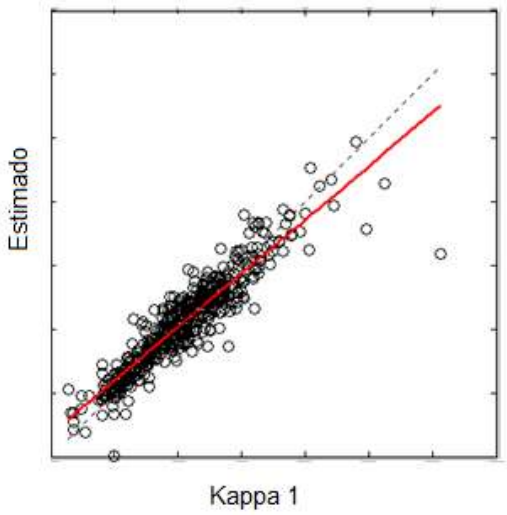


Figura 6.18 - Ilustração do treinamento com 3 neurônios na camada oculta

Foi construída a arquitetura da rede final conforme demonstrada na Figura 6.19, que ilustra as onze variáveis de entrada, três neurônios na camada oculta, e o número kappa como neurônio de saída, em rede MLP:

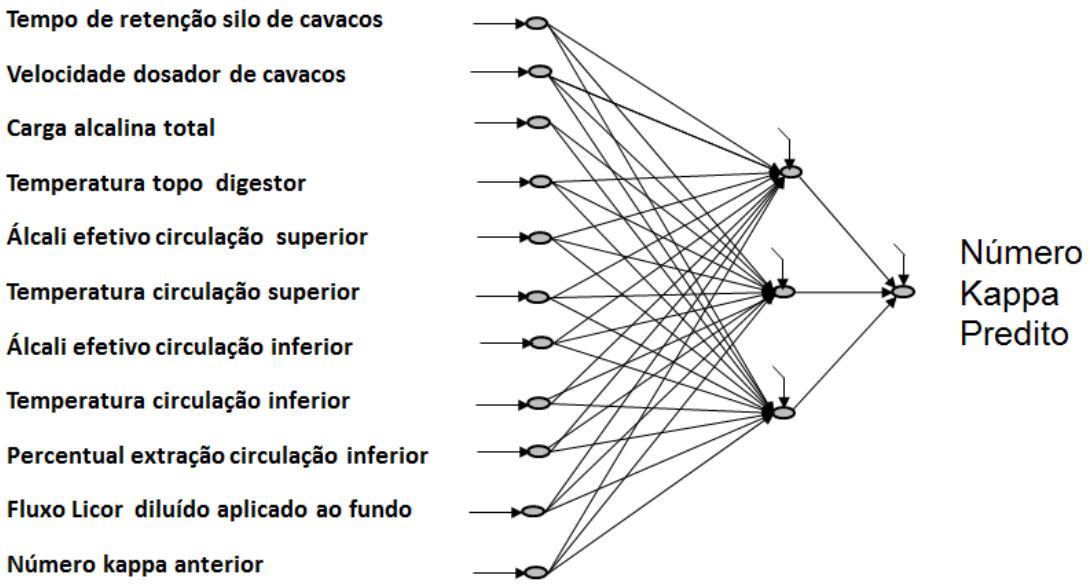


Figura 6.19 - Arquitetura final da RNA

Etapa 3: Validação do modelo

O segundo conjunto de dados [KAPPA2] foi usado para validação do modelo. Os dados obtidos foram comparados com os valores reais do número kappa. A Figura 6.20 apresenta o histograma dos resíduos, mostrando assimetria e média em torno de zero.

O índice Durbin Watson foi calculado, apresentando valor 1,44, mostrando que não há evidência de autocorrelação entre os resíduos.

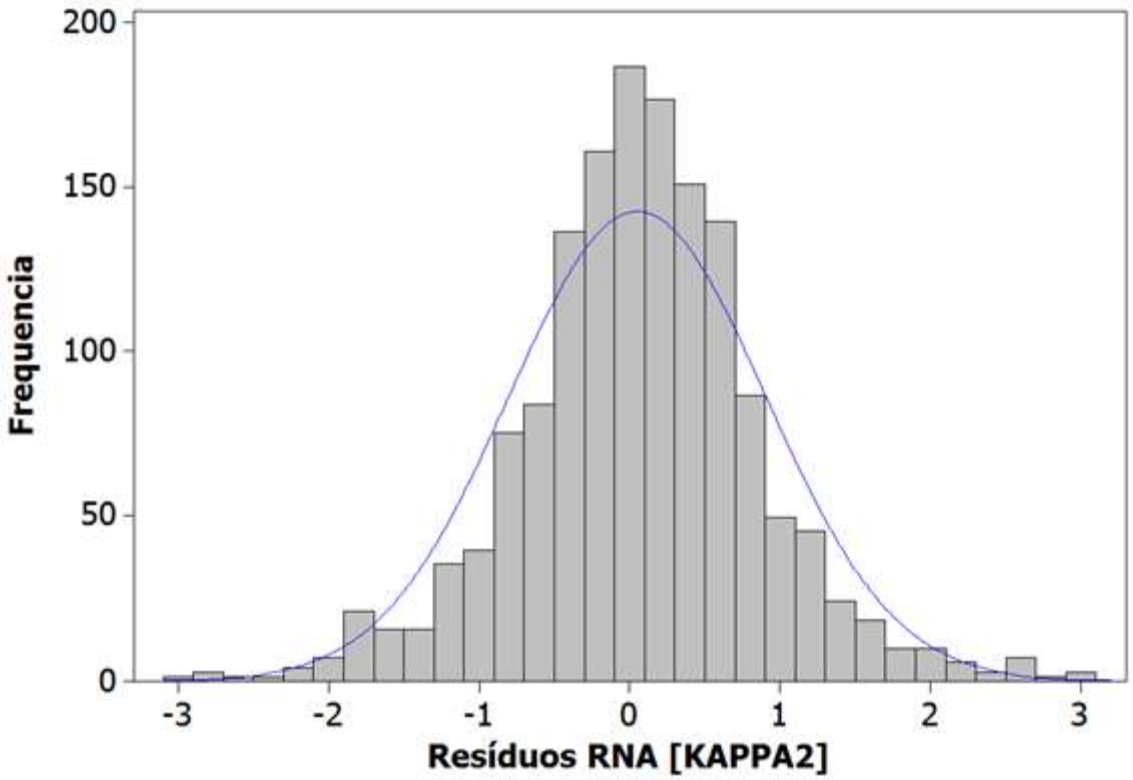


Figura 6.20 - Histograma dos Resíduos do Modelo de RNA [KAPPA2]

A Tabela 6.7 apresenta alguns índices de desempenho de previsão estatística para este método.

Tabela 6.7 - Índices de desempenho de previsão para o modelo RNA [KAPPA2]

Índice	**Valor**
MAD	0,6150
R^2	0,73279
MSE	0,73090
RMSE	0,85493
MAPE	0,03674
DW	1,44

Observa-se que o modelo RNA apresentou desempenho muito semelhante e ligeiramente superior ao modelo RLM. O erro percentual médio absoluto de aproximadamente 3,7 %, mostra seu bom resultado. Além disso, o índice MAD apresentado (0,62), ficou muito abaixo das referências que apresentam esta variável

para fibra curta (5 ~7) das referências do Quadro 2.1. O valor RMSE ficou inferior ao da única referência que reportou este índice (1,4 ~3,3).

Resultados comparativos dos índices estatísticos deste e dos demais métodos estão sumarizados na Tabela 6.12.

Comparativo de dados modelados *versus* observados deste e dos demais métodos estão sumarizados na Figura 6.21.

6.3.5. Método Box-Jenkins (ARMA)

Identificação do Modelo

De acordo com a Figura 6.2, o conjunto de dados para a construção do modelo é uma série temporal não sazonal, sem tendência, permitindo a aplicação do método sem diferenciação. Para estimação dos parâmetros do modelo, foi usado o primeiro conjunto de dados [KAPPA1]. Foram analisadas a Função de Auto Correlação (FAC) e Função de Auto Correlação Parcial (FACP), conforme indicado na Figura 6.8. Pela relevância de seus valores, foram analisados os modelos de primeira e segunda ordem para os componentes Autorregressivo (AR) e Média Móvel (MA). Os modelos ARMA (1,1); ARMA (2,1); ARMA (2,2) e ARMA (1,2), apresentaram ruído branco em seus resíduos, com bons resultados nos critérios MAD, MAPE, RMSE, AIC, BSC, DW e TIC, cujos resultados estão indicados na Tabela 6.8.

Tabela 6.8 - Índices estatísticos modelos ARMA [KAPPA1]

Modelo	**ARMA(1,1)**	**ARMA(2,1)**	**ARMA(2,2)**	**ARMA (1,2)**
MAD	0,4036	0,3890	0,3871	0,3868
MAPE	2,4314	2,3537	2,3412	2,3389
RMSE	0,5841	0,5553	0,5500	0,5500
AIC	1,7652	1,6665	1,6491	1,6473
BSC	1,7722	1,6806	1,6666	1,6614
DW	1,9052	2,0387	2,0042	1,9963

Em complemento à Tabela 6.8, a Tabela 6.9 apresenta o detalhamento do TIC *Coeficiente de Desigualdade de Theil* para o modelo ARMA (1,2). Verifica-se que o seu valor foi próximo de zero, com suas proporções em valores adequados. A proporção BIAS (do Viés) que informa o quão distante está a média da série estimada da média real foi zero. Da mesma forma a proporção da variância foi próximo de zero, indicando boa capacidade do modelo de repetir a variabilidade da variável de interesse.

Em complemento, a proporção da covariância (que mede os erros de previsão não previstos no modelo) atingiu o desejável valor próximo de um. Ou seja, o modelo proposto atingiu a distribuição ideal das proporções BP ≈VP ≈ 0 e CV ≈ 1.

Tabela 6.9 - Coeficiente de Desigualdade Theil Modelo ARMA (1,2) [KAPPA1]

Índice	**Valor**
TIC	0,0169
Proporção Bias	*0,0000*
Proporção Variância	*0,0305*
Proporção Covariância	*0,9695*

De uma forma geral todos os modelos podem ser considerados com bons resultados, com pequena desvantagem para o modelo ARMA (1,1). Índices estatísticos dos modelos ARMA (2,1), ARMA(2,2) e ARMA (1,2) ficaram muito próximos. O índice DW atingiu o desejável valor muito próximo de 2,00, demonstrando que os resíduos não estão correlacionados. Considerando as propriedades de acurácia e parcimônia, foi escolhido o modelo ARMA (1,2), cujos parâmetros estimados estão presentes na Tabela 6.10. Os parâmetros são significativos a 5% de significância, e atendem aos requisitos de estacionariedade e invertibilidade indicados na Tabela 4.1.

Tabela 6.10 - Parâmetros estimados para o modelo ARMA (1,2)

Parâmetro	**Coeficiente**	**Desvio Padrão**	**p Valor**
δ	16,14181	0,156000	0,0000
$\boldsymbol{\phi_1}$	0,851803	0,015525	0,0000
$\boldsymbol{\theta_1}$	0,361867	0,027421	0,0000
$\boldsymbol{\theta_2}$	0,273562	0,026999	0,0000

A Figura 6.21 apresenta o gráfico ilustrativo dos valores observados e modelados. Confirmando os índices estatísticos, o gráfico mostra a "quase sobreposição" das curvas, mostrando a adequada escolha do modelo.

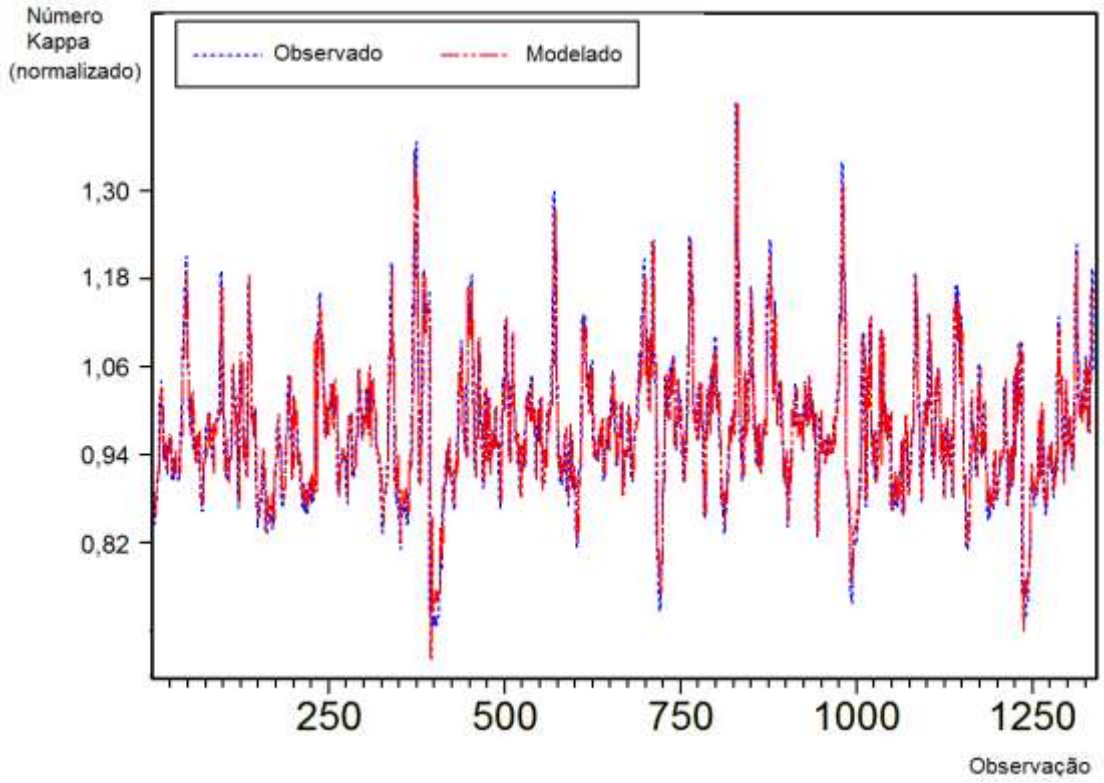


Figura 6.21 – Evolução valores observados e modelados Mod. ARMA (1,2) [KAPPA1]

A Figura 6.22 apresenta as curvas reais e teóricas das curvas FAC e FACP, mostrando o bom ajuste deste modelo nos 24 passos para a curva FAC e FACP dos valores reais e teóricos.

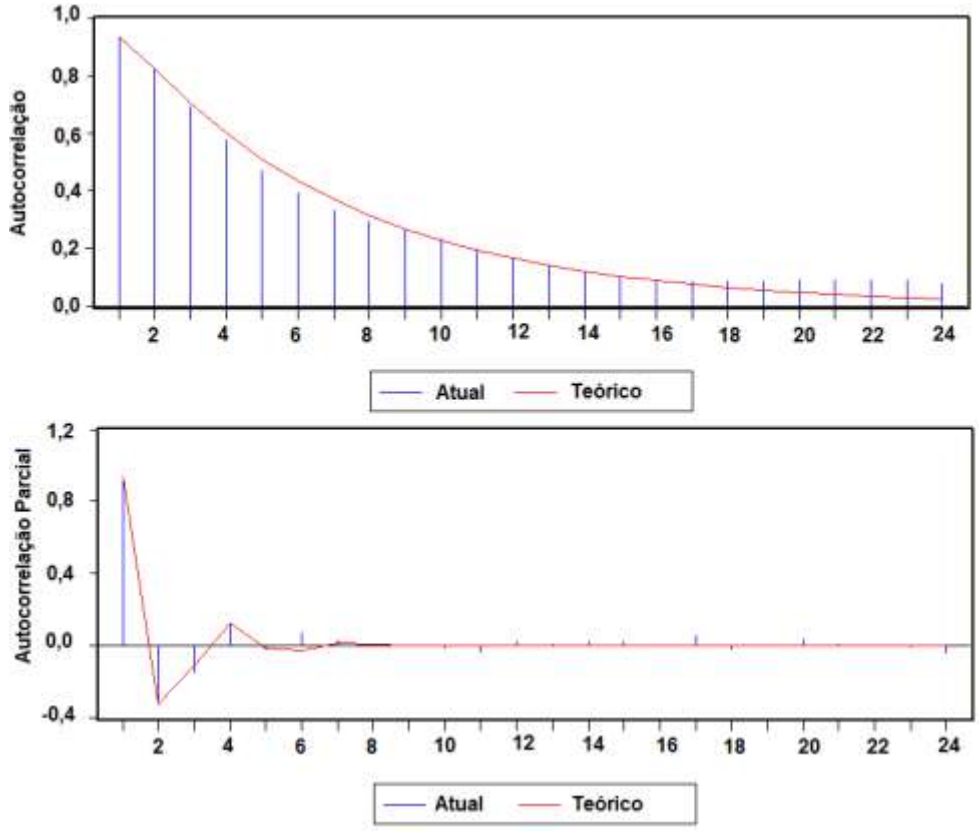
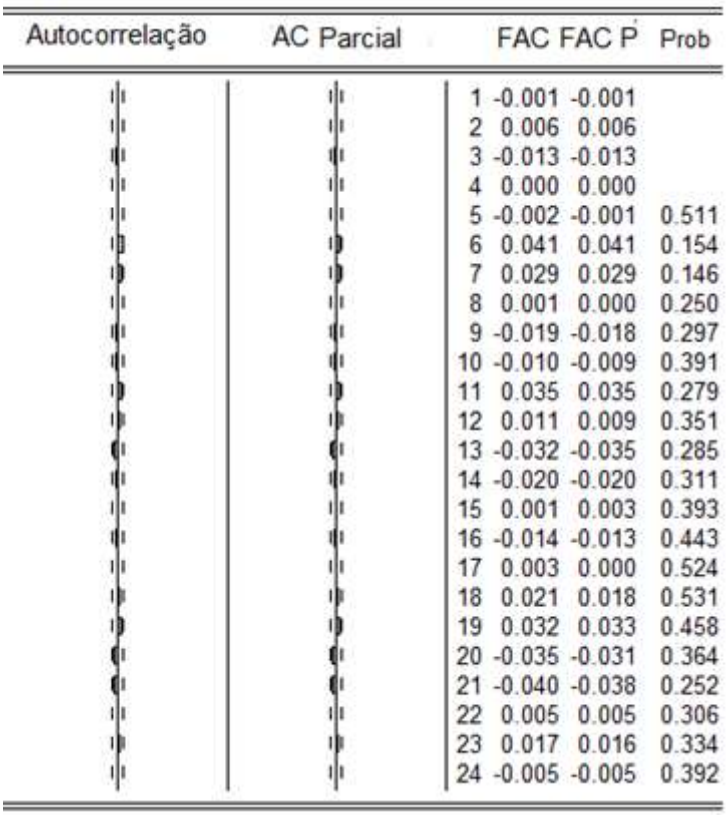


Figura 6.22 - Curvas reais e teóricas das FAC e FACP do Modelo ARMA (1,2) [KAPPA1]

Quanto a avaliação dos resíduos, a Figura 6.23 mostra que se obteve um ruído branco nas funções FAC e FACP, e a Figura 6.24 apresenta o histograma dos resíduos, que mostra a com média e media em torno de zero.



Autocorrelação	AC Parcial		FAC	FAC P	Prob
		1	-0.001	-0.001	
		2	0.006	0.006	
		3	-0.013	-0.013	
		4	0.000	0.000	
		5	-0.002	-0.001	0.511
		6	0.041	0.041	0.154
		7	0.029	0.029	0.146
		8	0.001	0.000	0.250
		9	-0.019	-0.018	0.297
		10	-0.010	-0.009	0.391
		11	0.035	0.035	0.279
		12	0.011	0.009	0.351
		13	-0.032	-0.035	0.285
		14	-0.020	-0.020	0.311
		15	0.001	0.003	0.393
		16	-0.014	-0.013	0.443
		17	0.003	0.000	0.524
		18	0.021	0.018	0.531
		19	0.032	0.033	0.458
		20	-0.035	-0.031	0.364
		21	-0.040	-0.038	0.252
		22	0.005	0.005	0.306
		23	0.017	0.016	0.334
		24	-0.005	-0.005	0.392

Figura 6.23 – Correlograma Ruído branco das FAC e FACP Modelo ARMA (1,2) [KAPPA1]

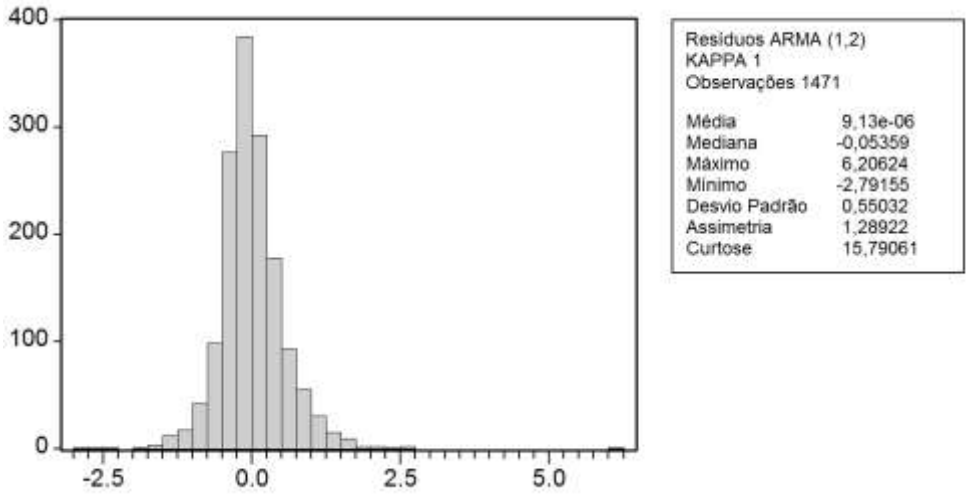


Figura 6.24 - Histograma dos resíduos Modelo ARMA (1,2) [KAPPA1]

Validação

Aplicando os coeficientes indicados da Tabela 6.9 na Equação 2.6, foi obtida a Equação 6.6 para validação do modelo ARMA (1,2) usando o segundo conjunto de dados, composto de 1358 observações [KAPPA2]:

$$\boldsymbol{Y_t = 2,3921 + \ 0,8518\, Y_{t-1} + 0,3619\, e_{t-1} + 0,2736\ e_{t-2}} \qquad (6.6)$$

na qual:
Y_t = número kappa observado ao tempo t;
e_t = Erro do número kappa ao tempo t (observado – estimado).

A validação com o novo conjunto de dados confirmou o bom desempenho dos três modelos selecionados. Observa-se ainda que os três modelos atingiram resultados muito bons e próximos, com índice MAPE da ordem de 2,7 %.

A Figura 6.25 apresenta o histograma dos resíduos do modelo ARMA(1,2) com os dados de validação.

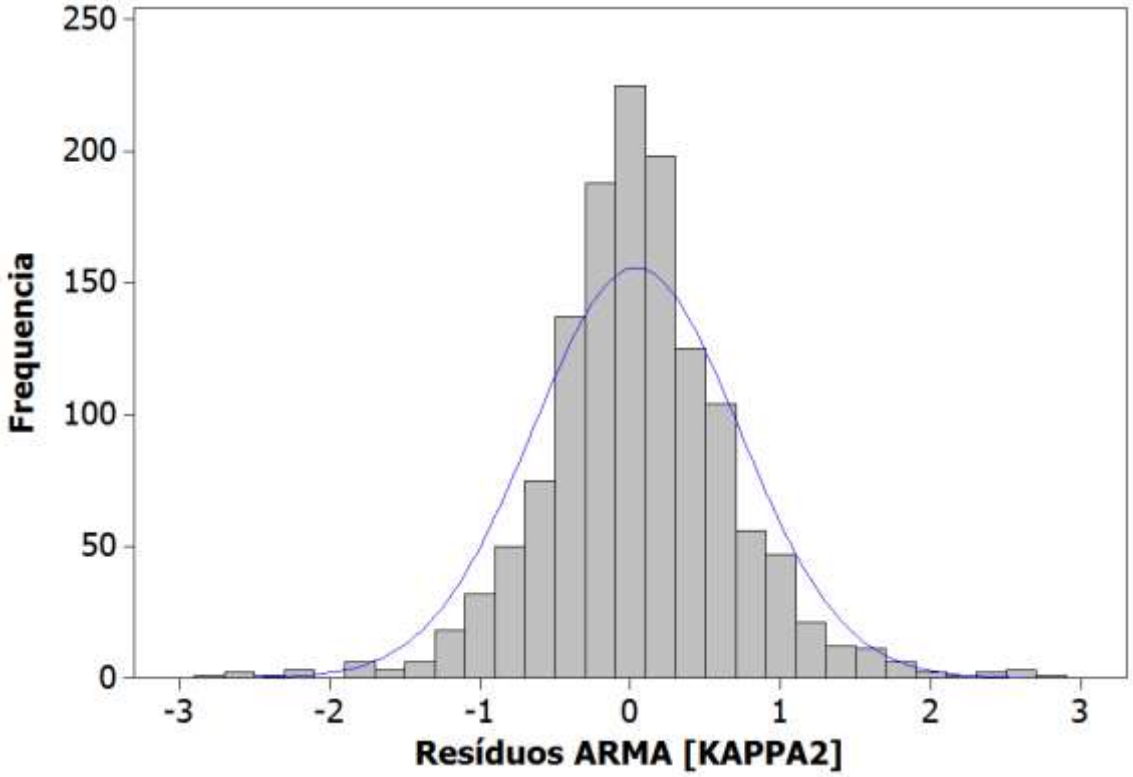


Figura 6.25 - Histograma dos Resíduos Modelo ARMA (1,2) [KAPPA2]

O índice Durbin Watson apresentou valor 2,22, mostrando que não há autocorrelação entre os resíduos.

São expressos na Tabela 6.11 resultados de desempenho de validação do modelo selecionado.

Tabela 6.11 - Índices de desempenho Modelo ARMA(1,2) [KAPPA2]

Modelo	**ARMA(1,2)**
Média	16,4722
MAD	0,4552
RMSE	0,413
MAPE	2,7327
DW	2,22

6.3.6. Comparativo entre os Métodos

É apresentado na Figura 6.26 o gráfico de dispersão entre o número kappa observado a partir do segundo conjunto de dados e os quatro modelos previstos. Importante registrar algumas particularidades entre os métodos e seus resultados:

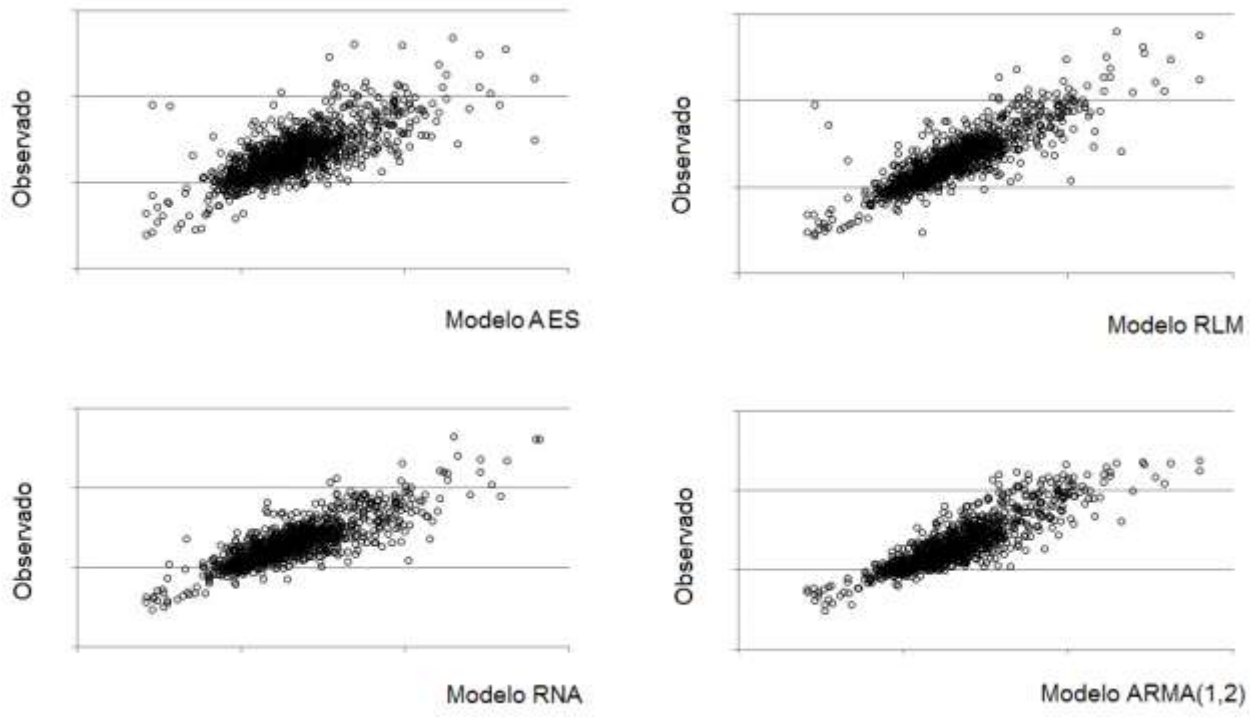


Figura 6.26 - Dispersão entre os modelos analisados 'modelados x observados' [KAPPA2]

O modelo RLM, apresentou resultados intermediários. Consideramos que sua avaliação pode ter sido influenciada negativamente pelas interferências da descontinuidade de alguns dados (por problemas de instrumentação e descontinuidade da produção, fez-se necessário a eliminação de alguns dados em ambos os conjuntos de dados).

O modelo RNA também apresentou resultados muito bons, e próximos ao modelo ARMA. Consideramos que sua avaliação pode ter sido influenciada negativamente pelas interferências da descontinuidade de alguns dados (nas mesmas condições do modelo RLM), e também pela seleção das variáveis de entrada. Para manter o mesmo padrão de comparação, as variáveis de entrada foram as mesmas do modelo RLM. É possível que o modelo obteria resultados melhores se a seleção das variáveis de entrada fosse realizada também por redes neurais.

Além destes itens, importante notar que o "número kappa" é uma variável controlada no processo. Isto é, de uma forma geral as perturbações nas onze variáveis de processo possuem uma fragilidade na aplicação em modelos pois são corrigidas naturalmente pelo operador ou pelo sistema de automação do digestor, visando corrigir a variável saída. A Tabela 6.12 resume alguns índices de previsão dos quatro métodos estudados. Além dos índices estatísticos, foi também incluído o valor percentual de "desvio absoluto menor do que 1 unidade de número kappa", como uma referência de um valor aceitável para aplicações industriais.

Tabela 6.12 - Resumo dos índices dos modelos avaliados [KAPPA2]

Modelo	**Validação**	**AES**	**RLM**	**RNA**	**ARMA**
MEDIA	16,5438	16,4722	16,4727	16,5383	16,4713
MAD	-	1,0261	0,6640	0,6150	0,4552
MAD < 1 (%)	-	64,1102	84,0883	84,3216	90,7713
MAPE	-	6,2220	3,9073	3,6740	2,7327
RMSE	-	1,4052	0,8581	0,8549	0,413
DW	-	1,26	1,32	1,44	2,22

O modelo ARMA(1,2) apresentou melhores valores em todos os índices de previsão, seguido por RNA, RLM e AES. De uma forma geral, todos os métodos apresentaram boa precisão e acurácia, com algumas restrições para o modelo AES, que considerando a simplicidade do método, apresentou resultados inferiores ao se comparar com os demais. Ainda assim, apresentou bons resultados quando comparados aos das referências.

O Quadro 6.2 mostra o comparativo entre os melhores resultados das referências indicadas no Quadro 2.1 com os modelos de menor (AES) e maior (ARMA) desempenho. Pode-se observar que os modelos aqui tratados tiveram bons desempenhos em predições quando comparados com os índices reportados na literatura. De uma

forma geral, consideramos que os modelos aqui avaliados foram favorecidos pela continuidade e frequência entre os dados, e principalmente pelo bom ajuste das séries temporais aos dados industriais analisados.

Quadro 6.2 - Comparativo entre as referências da literatura e modelos [KAPPA2]

	Saavedra (2011)	*AES*	*ARMA*
MAD	5,18	1,03	0,46
	Li e Zhu (2004)	*AES*	*ARMA*
MAD < 1 (%)	65	64	91
	Rantanen (2006)	*AES*	*ARMA*
RMSE	1,44 ~3,32	1,41	0,41

6.4. Conclusões

Foram analisados neste capítulo, quatro diferentes métodos para predição do número kappa em um processo de cozimento contínuo de celulose Kraft. Os dados de um digestor contínuo industrial foram usados para comparar o desempenho desses métodos, considerando a sua acurácia. Os modelos AES e ARMA foram desenvolvidos em modelos dinâmicos univariados, usando dados observados e modelados. Os modelos RLM e RNA foram analisados com 11 variáveis de processo de cozimento de entrada, selecionados por análise RLM de 18 variáveis de processo do cozimento.

Na análise dos resíduos, todos os modelos apresentaram bons resultados, seja pela análise dos histogramas ou pelo índice DW. Embora com algumas restrições para o modelo AES, tendo em conta que nenhum dos dados incluídos no subconjunto de elaboração do modelo foi utilizado na fase de validação, pode-se concluir que os quatro métodos são aceitáveis para aplicações práticas para predição do número kappa.

Os quatro modelos estudados apresentaram desempenhos superiores aos reportados na literatura. O modelo ARMA(1,2) apresentou melhores resultados, seguido por RNA, RLM e AES.

A informação do número kappa antes do final do cozimento permite à equipe operacional fazer correções em avanço aos resultados do laboratório ou ainda

permite ser usada como um sensor inferencial para parâmetros de calibração de instrumentos e agilizar ações corretivas. Tratam-se de ferramentas úteis para as fábricas de celulose, uma vez que podem ser aplicadas em uma planilha eletrônica, atualizados ao longo do tempo à medida que mais dados se tornam disponíveis.

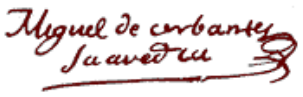
Os métodos AES, RLM, ARMA e RNA podem ser adaptados a outros processos com reatores contínuos, quando predições possam contribuir em medidas corretivas com base nas análises do produto reagido. Como exemplo desta aplicação dentro do processo Kraft, destacam-se áreas como as plantas do pré-branqueamento com oxigênio que depende dos resultados de viscosidade e número kappa na aplicação dos reagentes e parâmetros de temperatura e ainda o forno de cal (também mencionado no Capítulo 4), que depende da análise da cal útil para correção dos parâmetros de temperatura e fluxo de alimentação. Em outros ramos da indústria química, pode-se ilustrar na área de siderurgia o alto-forno, que depende da análise do gusa para correção nos parâmetros dos reagentes, reatores de fermentação, etc.

No Capítulo 7 são apresentadas as considerações finais, com conclusões e sugestões para pesquisas futuras, além da produção científica decorrente deste trabalho.

Capítulo 7

Considerações Finais

" digo que es grandísimo el riesgo a que se pone el que imprime un libro, siendo de toda imposibilidad imposible componerle tal que satisfaga y contente a todos los que le leyeren."
El Ingenioso Hidalgo Don Quijote de La Mancha (1615)





Miguel de Cervantes Saavedra (1547-1616)
Escritor e Poeta Espanhol

Capítulo 7

Considerações Finais

7.1. Conclusões

O digestor contínuo de celulose Kraft possui a particularidade das naturais variações da matéria prima, sujeitas não só às diferentes espécies, idade, tempo de estocagem, mas principalmente às variações climáticas e efeitos biológicos da árvore. Ademais, o longo tempo de retenção no equipamento influencia negativamente as ações de controle, tornando o foco na estabilidade do material produzido como um desafio permanente. Assim, este trabalho foi realizado buscando estudar predições de variáveis de processo em um digestor contínuo operando com matéria prima de fibra curta, aplicando métodos estatísticos e redes neurais artificiais em modelos preditivos de densidade de cavaco e número kappa. Com base nas pesquisas realizadas, pode-se concluir:

- ✓ Aplicação de métodos preditivos da densidade dos cavacos, como Média Móvel Simples, Alisamento Exponencial Simples e Box-Jenkins em um digestor contínuo industrial, apresentam erros menores quando comparados ao resultado da amostragem instantânea com o *delay* do tempo de análise, permitindo uma melhor acurácia da dosagem dos reagentes químicos de cozimento.

- ✓ O modelo ARMA (2,2) apresentou bom desempenho na série estudada na predição de dados de densidade de cavacos, resultando em uma redução de aproximadamente 25% no erro da densidade na aplicação do cálculo do fluxo de licor branco. A equação obtida do modelo pode ser aplicada em uma planilha eletrônica, sendo atualizada instantaneamente a cada nova obtenção de dados.

- ✓ Os modelos ARMA podem ser adaptados a outros processos com reatores contínuos, em que tenham predições que possibilitem contribuir em medidas corretivas com base nas análises da matéria prima.

- ✓ O método de Regressão Linear Múltipla é uma ferramenta aplicável para seleção de variáveis que influenciam as reações de deslignificação em um

digestor de celulose Kraft, permitindo um melhor entendimento das relações entre as variáveis de processo e o número kappa.

- ✓ Os métodos Alisamento Exponencial Simples, Regressão Linear Múltipla, Redes Neurais Artificiais e Box-Jenkins (nesta ordem progressiva), são alternativas viáveis para predição do número kappa de um digestor contínuo industrial. A inferência do grau de deslignificação contribui para tomada de ações corretivas operacionais em avanço aos resultados das análises.

- ✓ O modelo RNA apresentou o segundo melhor resultado na série estudada. Consideramos que seu desempenho pode ter sido influenciado negativamente pelas interferências da descontinuidade de alguns dados (causados pela parada de produção), e também pela seleção das variáveis de entrada (que foram selecionadas por RLM). É possível que o modelo obtivesse resultados melhores se a seleção das variáveis de entrada fosse realizada também por RNA.

- ✓ O modelo ARMA (1,2) apresentou o melhor resultado na série estudada para predições do número kappa, com erro absoluto percentual médio inferior a 3 %. A equação obtida do modelo pode ser aplicada em uma planilha eletrônica sendo atualizada instantaneamente a cada nova obtenção de dados.

- ✓ Os modelos ARMA podem ser adaptados a outros processos com reatores contínuos, em que tenham predições que possibilitem contribuir em medidas corretivas com base nas análises do produto reagido.

- ✓ Conforme pesquisa na literatura aberta, não foram encontradas referências que reportem modelos preditivos da densidade do cavaco ou de outras propriedades do mesmo para aplicações no digestor.

- ✓ No mesmo contexto, não foram encontrados em pesquisa na literatura aberta, referências quanto a metodologias para predição do número kappa com métodos univariados.

- ✓ As predições usando metodologias estatísticas e redes neurais possuem potencialidades para novas aplicações em outros campos da indústria química que possuam reator contínuo em seus processos.

7.2. Sugestões para Pesquisas Futuras

Considerando a importância da dinâmica do comportamento das variáveis de processo nas diferentes etapas de produção de celulose Kraft, sejam advindas da matéria prima ou das próprias reações químicas envolvidas, mais pesquisas com dados industriais podem contribuir para uma melhor compreensão do processo como um todo. Neste sentido, sugere-se como continuidade:

- Avaliação dos métodos com dados de digestores contínuos de outras plantas industriais.
- Avaliação do processo de deslignificação de oxigênio, visando antecipar variações do número kappa, alvura e viscosidade da polpa pré-branqueada.
- Avaliação do processo do forno de cal, visando identificar as variáveis relevantes no processo de calcinação bem como antecipar propriedades da cal produzida.

7.3. Contribuições Associadas à Tese

Esta tese tem como propósito o uso de modelos preditivos em digestor contínuo, conforme citado no item objetivos. Foram estimados parâmetros de modelos aplicados à matéria prima (densidade de cavacos) e ao produto reagido (número kappa).

Com relação ao processo de predição de densidade de cavacos, o modelo apresentado é inovador nesta aplicação, tendo sido publicado o artigo *A novel approach to white liquor control in a continuous digester using the Box-Jenkins methodology to predict chip bulk density* no periódico ***TAPPI Journal***. Este periódico é vinculado à Associação Técnica das Indústrias de Celulose e Papel dos Estados Unidos, que possui ampla inserção nas fábricas do setor em todos os países do mundo.

Da mesma forma, é também inovador o uso de métodos univariados na predição do número kappa em digestor de celulose Kraft. Além disso, os resultados obtidos foram superiores aos reportados na literatura aberta, relativos à predições e modelagem de número kappa de digestor contínuo. Abordando este assunto, foi publicado o artigo *Prediction of Kappa Number in Eucalyptus Kraft Pulp Continuous Digester Using the Box & Jenkins Methodology* no periódico ***Advances in Chemical Engineering and Science***.

Além dos artigos, alguns tópicos que compõem o desenvolvimento desta tese foram divulgados em dois congressos do setor. O trabalho *Predição do Número Kappa de um Digestor Contínuo de Celulose Kraft usando Análise de Regressão Múltipla*, foi apresentado no **XX COBEQ Congresso Brasileiro de Engenharia Química** 2014. Trata-se do maior evento da comunidade acadêmica da Engenharia Química do país, com participação de centenas de pesquisadores de todas as regiões do Brasil.

O trabalho *A Neural Network Approach for Kappa Number Prediction in Eucalyptus Kraft Pulp Continuous Digester*, foi divulgado no **7th International Colloquium on Eucalyptus Pulp** 2015. O *Colloquium* é um fórum de caráter internacional com presença acentuada de pesquisadores e profissionais da indústria de fibras de eucalipto de países como Chile, Uruguai, Portugal, Espanha, e naturalmente o Brasil. As inovações nele apresentadas e as discussões envolvidas com os participantes

têm caracterizado como um dos eventos técnicos mais seletivos na área de celulose atualmente.

Assim, considera-se que esta tese pôde contribuir para mostrar a viabilidade da aplicação de técnicas estatísticas e redes neurais na modelagem de processos em digestor contínuo de celulose kraft, cujo uso ainda não é tão abrangente em aplicações na indústria de celulose e papel, particularmente com matéria prima de fibra curta.

Relação das publicações citadas encontram-se no *Anexo 4.*

Referências Bibliográficas

Referências Bibliográficas

ACHEN, C. H. **Interpreting and Using Regression**, Sage Publications, Beverly Hills, EUA, 1982.

AHVENLAMPI, T.; KORTELA, U. Clustering algorithms in process monitoring and control application to continuous digesters. **Informatica,** v 29, 101-109, 2005.

AHVENLAMPI, T.; RANTANEN, R. Enhancing Kappa Number Control in Down flow Lo Solids™ Digester Using Diagnosis and Modelling, *In* **Proceedings** of the 4th International Conference on Informatics in Control, Automation and Robotics, 161-166, 2007.

ALEXANDRIDIS, A.; SARIMVEIS, H.; ANGELOU A.; RETSINA T.; BAFAS G. A model predictive control scheme for continuous pulp digesters based on the partial least square (PLS) modelling algorithm, *In* **Proceedings** of the 10th Control Systems conference, Stockholm, 253-257, 2002.

ANDERSON-SPRECHER, R.: Model comparisons and R2, **The American Statistician** 48, 113–117, 1994.

ARAÚJO, A.; FERREIRA, J.A.; FERNANDES, N.; OLIVEIRA, P. Using splitting methods in continuous digester modeling, **Applied Mathematical Modelling** , 32, 1869–1882, 2008.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14984** : Madeira - Determinação da densidade aparente de cavacos. Rio de Janeiro : 2003. 5p.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR ISO 302:** Pastas celulósicas - Determinação do número Kappa. : 2005. 11p.

BARRON, A. R. Statistical Properties of Artificial Neural Networks *In:* **Proceedings** of the 28th Conference on Decision and Control, 1989.

BARROS, M. Introdução às Séries Temporais e aos Modelos ARIMA, 2006
http://www.mbarros.com/documentos/upload/Livro_Processos_Cap_5_parte.pdf
Acesso em novembro 2015.

BERRY, W. D. **Understanding Regression Assumptions**, SAGE Publications, Beverly Hills, EUA, 1993.

BERRY, W.D. ; FELDMAN, S. **Multiple Regression in Practice**, SAGE Pub., Thousand Oaks, CA 1985.

BISHOP, C.M. Neural Networks and Their Applications, **Review of Scientific Instruments**, v 65 (6), 1803-1832, 1994. http://research.microsoft.com/en-us/um/people/cmbishop/downloads/BISHOP%20-%20NNA%20-%20RSI94.pdf Acesso em janeiro 2013.

BOGREN, J.; BRELID, H.; THELIANDER, J.: Towards a general Kraft delignification model. **Nordic Pulp and Paper Research Journal**, v 24 (1), 2009.

BOWERMAN, B.L.; O'CONNELL, R. T. ; KOEHLER, A.B. **Forecasting, time series, and regression: an applied approach,** 4th ed, Duxbury Press, Pacific Grove, EUA, 2005.

BOX, G. E. P.; JENKINS, G. **Time series analysis: Forecasting and control**, 2ª ed., Holden-Day, San Francisco, EUA, 1976.

BRAGA, A. P.; CARVALHO, A. C.; LUDERMIR, T. B. **Redes Neurais Artificiais: teoria e aplicações**. 2ª ed. São Carlos, LTC, 2007.

BULSARI, A. B. **Neural Networks for Chemical Engineers**, Elsevier, Amsterdam 1995.

CHAMBERS, J. C.; MULLICK, S. K. ; SMITH, D. D. How to choose the right forecasting technique, **Harvard Business Review,** v 49 (4), 45-74, 1971.

CHENG, B.; TITTERINGTON, D. M. Neural Networks: A Review from a Statistical Perspective, **Statistical Science**, v 9 (1), 2-54, 1994.

CHON, K. H.; COHEN, R. J. Linear and Nonlinear ARMA Model Parameter Estimation Using an Artificial Neural Network, IEEE Transatctions on Biomedical Engineering, v. 44, (3), 1997.

CLAYTON, D.; EASTY, D.; EINSPAHR, D.; LONSKY, W.; MALCOLM, E.; McDONOUGH, T.; SCHROEDER, L.; THOMPSON, N. **Alkaline Pulping**, vol 5 of Pulp and Paper Manufacture, chapter IV Kinetics and Modelling of Kraft Pulping, 45–73. Joint Textbook Committee of the Paper Industry, 3th ed, 1989.

CHIANG, L.H.; RUSSEL, E. L.; BRAATZ, R. D. **Fault Detection and Diagnosis in Industrial Systems.** Springer-Verlag, Londres, 2001.

COLODETTE, J. L. ; GOMES, F. J. B. **Branqueamento de Polpa Celulósica: da Produção da Polpa Marrom ao Produto Acabado**, 1ª ed., Viçosa, Ed. UFV, 2015

COLODETTE, J. L.; GOMIDE, J. L.; GIRARD, R; JAASKELAINEN, A.; ARGYROPOULOS, D.S.: Influence of Pulping Conditions on Eucalyptus Kraft Pulp Yield, Quality, and Bleachability. **Tappi Journal**, v 1, 14-20, 2002.

CONNOR, J. T. ; MARTIN, R. D. Martin ; ATLAS, L. E. Recurrent neural networks and robust time series prediction, **IEEE Transactions on Neural Networks**, v 5 (2), 240 – 254, 1994. DOI 10.1109/72.279188

DAHLQUIST, E., Process simulation for pulp and paper industries: Current practice and future trend. **Chemical Product and Process Modeling** , v 3 (1) 18 , Sweden, 2008. DOI 10.2202/1934-2659.1087

D'ALMEIDA, M.L.O. **Tecnologia de fabricação de pasta celulósica, 2ª** Ed., Vol 1, SP, SENAI-IPT, 2013.

DUFOUR, P.; BHARTIYA, S.; DHURJATI, P.S.; DOYLE III, F. J.: Neural network-based software sensor: Data set design and application to a continuous pulp digester. **Control Engineering Practice,** International Federation of Automatic Control, 2005, v 13 (2), .135-143. DOI 10.1016/j.conengprac.2004.02.013

ERIKSSON, L.; JOHANSSON, E.; KETTANEH-WOLD, N.; TRYGG, J.; WIKSTROM, C.; WOLD, S. **Multi- and Megavariate Data Analysis**, 2ª ed., Sweden, Umetrics AB, 2006.

ESPASA, A. Perspectiva histórica de los modelos ARIMA y su utilidad en el análisis económico. **Revista de Historia Económica,** v 3, 541-549, 1991.

FARAWAY, J. ; CHATFIELD, C. Time series forecasting with neural network A comparative study using the airline data**, Applied Statistic**, 47 (Part 2), 231-250, 1998.

FAUSETT, L. **Fundamentals of Neural Networks**, New York: Prentice Hall, EUA, 1994.

FENG, C-X. J.; YU, Z-G.; KING, U.; BAIG, M. P. Threefold vs. fivefold cross validation in one-hidden-layer and two-hidden-layer predictive neural network modeling of machining surface roughness data**. Journal of Manufacturing Systems**, v 24 (02), 93-107, 2005.

FENGEL, D., WEGENER, G. **Wood: Chemistry, Ultrastructure, Reactions**. 2ª ed. Walter de Gruyter, Berlim, 1984.

FERNANDES, N. C. P. **Modelização de um Digestor Contínuo de Cozimento Kraft**. Tese D.Sc. Universidade de Coimbra, Portugal, 2007.

FOELKEL, C.; MORA, E. ; MENOCHELLI, S. Densidade básica: sua verdadeira utilidade como índice de qualidade da madeira de eucalipto para produção de celulose, 6º Congresso Florestal Brasileiro, **Anais**, 719-728, 1990. Disponível em : http://www.celso-foelkel.com.br/artigos/outros/Db%20sua%20verdadeira%20utilidade.pdf Acesso em maio 2014.

FOELKEL, C. Qualidade da Madeira do Eucalipto Reflexões Acerca da Utilização da Densidade Básica como Indicador de Qualidade da Madeira no Setor de Base Florestal. EUCALYPTUS ONLINE BOOK ,Cap. 41, 2015. Disponível em : http://eucalyptus.com.br/eucaliptos/PT41_Densidade_Basica_Madeira.pdf Acesso em junho 2015.

_____(b): Qualidade da Madeira do Eucalipto Acerca dos Acertos e Erros na Utilização da Densidade Básica como Indicador de Qualidade de Madeiras EUCALYPTUS ONLINE BOOK ,Cap. 42. 2015. Disponível em : http://eucalyptus.com.br/eucaliptos/PT42_Densidade_Basica_Acertos&Erros.pdf Acesso em outubro 2015.

FORSSTRÖM, A. ; BASTA, J. ; BLOM, C. Kappa ótimo de cozimento -uma ferramenta versátil para a melhoria do desenvolvimento financeiro de uma planta de celulose de eucaliptos. **O Papel**, v. 67, n. 6, 96-100, 2006.

FOX, J. **Applied regression analysis, linear models, and related methods.** Thousand Oaks, Sage Publications, EUA, 1997.

GELLERSTEDT, G.; LI, J. ; SEVASTYANOVA, O. The relationship between kappa number and oxidizable structures in bleached Kraft pulps. *In :* International Pulp Bleaching Conference, **Proceedings,** Halifax, Canada 2000. pp 203-206.

GELPER, S., FRIED, R., and CROUX, C. Robust forecasting with exponential and Holt-Winters smoothing. **Journal of Forecasting**, v 29, 285–300, 2008. DOI: 10.2139/ssrn.108940

GOMES, F.J.B. ; GOMES, A. F. ; COLODETTE, J. L. ; GOMIDE, J. L. ; CARVALHO, A. M. M. L. ; TRUGILHO, P. F. ; GOMES, C.M. ; ROSADO, A.M. . Influência do Teor da Relação S/G da Lignina da Madeira no Desempenho da Polpação Kraft. **O Papel** , v 12, 95-105, 2008.

GOMIDE, J. L. ; FANTUZZI NETO, H. . Aspectos Fundamentais da Polpação Kraft de Madeira de Eucalyptus. **O Papel** , v 61 (3), 62-68, 2000.

GOMIDE, J.L. **Tecnologia e química da produção de celulose**. Notas de aula. Universidade Federal de Viçosa, Laboratório de Celulose e Papel, 2010.

GRANGER, C.; NEWBOLD P. R^2 and the transformation of regression variables. **Journal of Econometrics**, 4 (1), 205-210, 1976.

GUJARATI, D. N. **Basic Econometrics**, 4ª ed., The McGraw-Hill, NY, EUA, 2004.

GULLICHSEN, J.; PAULAPURO, H.; FOGELHOLM, C.J. **Chemical engineering principles of fiber line operations in Chemical Pulping**, Papermaking Science and Technology, Book 6A, Fapet Oy, Finland 2000.

GUSTAVSSON, C. **On the Interrelation Between Kraft Cooking Conditions and Pulp Composition**. Tese D.Sc, Instituto Real de Tecnologia, Estocolmo, Suécia, 2006. Disponível em http://www.diva-portal.org/smash/get/diva2:11377/FULLTEXT01.pdf Acesso em dezembro 2014.

HALMEVAARA, K. **Simulation assisted performance optimization of large-scale multiparameter technical systems**, Helsinki University of Technology, Finlandia, Tese D.Sc, 2009.

HALMEVAARA, K. ; HYOTYNIEMI, H. Performance Optimization of Large Control Systems - Case Study on a Continuous Pulp Digester, *In :* **Proceedings** of the 15th IFAC World Congress, Czech Republic, 2005.

HART, P. W.; COLSON, G. W.; ANTONSSON, S.; HJORT, A. High-kappa HW impregnation. **BioResources,** v 6 (4), 5139-5150, 2011.

HART, P.W.; CONNELL, D. The effect of digester kappa on the bleachability and yield of EMCC softwood Kraft pulp. **TAPPI Journal**, v 5 (4), 23-27, 2006.

HATTON, J. V. Development of yield prediction equations in Kraft pulping. **Tappi Journal**, 56 (7), 97-111, 1973.

HAYKIN, S. **Neural Networks: A Comprehensive Foundation**, Macmillan Pub. Comp., New York, EUA, 1994.

HAYKIN, S. **Redes Neurais – Princípios e Práticas**, 2ª ed. P. Alegre, Bookman, 2001.

HECHT-NIELSEN, R. Kolmogorov'a mapping neural network existence theorem. *In :* **Proceedings** of 1st IEEE Intemational Joint Conference on Neural Networks, 11-14, 1987.

HECHT-NIELSEN, R. **Theory of the backpropagation neural network.** Neural Networks, 1989. IJCNN, International Joint Conference on: IEEE, 1989:593-605. DOI: 10.1109/IJCNN.1989.118638

HILL, T.; MARQUEZ, L.; O'CONNOR, M.; REMUS, W.; Artificial neural network models for forecasting and decision making. **International Journal of Forecasting** 10, 5–15, 1994.

HIMMELBLAU, D. M. Applications of artificial neural networks in chemical engineering. **Korean Journal of Chemical Engineering,** 17 (4), 373-392, 2000. DOI: 10.1007/BF02706848

HOLT, C.C. Forecasting seasonals and trends by exponentially weighted moving averages. **International Journal of Forecasting**, 20 (1), 5–10, 2004. DOI 10.1016/j.ijforecast.2003.09.015.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. Multi-layer Feedforward Networks are Universal Approximators, **Neural Networks**, 2, 359, 1989. http://www.sciencedirect.com/science/article/pii/0893608089900208

JIANG, Z.; VAN LIEROP, B. V.; BERRY, R. Hexenuronic acid groups in pulping and bleaching chemistry.**Tappi Journal**, 83 (1) , 167-175, 2000.

KARLSTRÖM, K.; LINDSTRÖM, M. E. Moving the defibration point towards higher kappa numbers with a novel cooking technique. *In* : The Second Workshop on Chemical Pulping Processes, **Proceedings**, Karlstad, Sweden, 11–15, 2008.

KOKUREK, M.J.; GRACE, T.M.; MALCOLM, E.W. **Alkaline Pulping**, 3ª ed., Pulp and Paper Manufacture Series, Vol. 5, Joint Textbook Committee of the Paper Industry, TAPPI, Atlanta, GA, USA, 1989.

KUMAR, S. ; GUSTAFSON, R. Analysis of Kappa Variability in a Kamyr Digester and Oxygen Reactor. Process Control, Electrical & Information Conference: *In:* **Proceedings** TAPPI, 417-424 ,1998.

KUTNER, M. ; NACHTSHEIM, C. ; NETER, J. ; LI, W. **Applied Linear Statistical Models**. McGraw-Hill/Irwin. Chicago, EUA, 2005.

LAAKSO, S. **Modeling of Chip Bed Packing in a Continuous Kraft Cooking Digester**, Tese D. Sc. Faculty of Chemistry and Materials Sciences, Helsinki University of Technology, 2008.

LI, H.; ZHU, X. Application of support vector machine method in prediction of kappa number of Kraft pulping process. *In* **Proceedings** *of the 5th World Cong. on Intelligent Control and Automation*, Hangzhou, China, 3325-3330, 2004.

LI, J.; GELLERSTEDT, G. The contribution to kappa number from hexeneuronic acid groups in pulp xylan, **Carbohydrate Research** , v 302, 213-218, 1997.

LINDSTROM, M.E. Challenges in Kraft Cooking of Eucalyptus. *In :* International Colloquim on Eucalyptus Pulp, 3, 2007, 1-4. Belo Horizonte. **Anais**…, Belo Horizonte, UFV, 2007. Disponível em : http://www.eucalyptus.com.br/icep03/70Lindstrom.text.pdf Acesso em outubro 2014.

LINDSTROM, M.E From simple theory to industrial application – Extended impregnation Kraft cooking. *In :* 5 th International Colloquium on Eucalyptuys Pulp 5, 2007, Porto Seguro. **Anais**…, Porto Seguro, UFV, 2011, Brasil

MACLEOD, M. The top ten factors in Kraft pulp yield, **Paperi ja Puu – Paper and Timber** v 89 (4), 2007.

MAIER, H. R.; DANDY, G. C. Neural networks for the prediction and forecasting of water resources variables: A review of modelling issues and applications, **Environmental Modelling & Software**, v 15 (1), 101–124, 2000.

MAIER, H. R.; DANDY, G. C. Neural network based modeling of environmental variables: a systematic approach. **Mathematical and Computer Modelling**, v.33, 669-682, 2001.

MAKRIDAKIS S.G. A Survey of Time Series, **International Statistical Review**, v 44 (1), 29-70, 1976.

MAKRIDAKIS, S.G.; HIBON, M., Evaluating Accuracy (Or Error) Measures, **INSEAD Working Papers Series**, Fontainebleau, France, 1995. http://www.insead.edu/facultyresearch/research/details_papers.cfm?id=2265

MAKRIDAKIS, S.G.; ANDERSON, A.; CARBONE, R. ;FILDES, R. ; HIBON, M.; LEWANDOWSKI, R.; NEWTON, J.; PARZEN, E. ; WINKLER, R. The Accuracy of Extrapolation (Time Series) Methods: Results of a Forecasting Competition, **Journal of Forecasting**, 1, 111-153, 1982.

MAKRIDAKIS, S.G.; WHEELWRIGHT, S.C.; HYNDMAN, R.J. **Forecasting Methods and Applications**, 3ª., J. Wiley and Sons, Hoboken, NJ, USA, 1998.

MALKOV, S. **Studies on liquid penetration into softwood chips – Experiments, models and applications**, Helsinki University of Technology, Finlandia, Tese D.Sc, 2002.

MORETTIN, P. A. ; TOLOI, C. M. C. **Análise de Séries Temporais**. 2ª ed., ABE-Projeto Fisher e Editora Edgard Blucher, 2006.

PANKRATZ, A **Forecasting with Univariate Box-Jenkins Models: Concepts and Cases**. Inc., Hoboken, NJ, EUA, 2008. DOI: 10.1002/9780470316566

PASCOAL, C.; EVTUGUIN, D.; PINTO, P.; SILVESTRE, A.; FREIRE, C. Química da madeira de eucalyptus globulus: Especificidades e impacto nos processos de cozimento e de branqueamento. **Pasta e Papel** , v 7, 32-42, 2005.

PEÑA, D. George Box: An Interview for the International Journal of Forecasting. **International Journal of Forecasting** , v 17 , 1 – 9, 2001.

PIKKA, O., ANDRADE, M.A., New developments in pulping technology . *In :* **Proceedings** of the 7th International Colloquium on Eucalyptus Pulp, Vitoria, Brazil 2015.

QUEIROZ, S. C. S.; GOMIDE, J. L.; COLODETTE, J. L. ; OLIVEIRA, R. C. Influência da densidade básica da madeira na qualidade da polpa Kraft de clones híbridos de *Eucalyptus grandis* W. Hill ex Maiden x *Eucalyptus urophylla* S. T. Blake **. Árvore** , v 28 (6), 901-909, 2004.
DOI 10.1590/S0100-67622004000600016

RANTANEN, R. **Modelling and Control of Cooking Degree in Conventional and Modified Continuous Pulping Processes**, Tese Ph.D. Faculdade de Tecnologia, Universidade de Oslo, Finlandia, 2006.

RIPLEY, B.D. Statistical Aspects of Neural Networks, Cap. 2. *In* Barndorff-Nielsen, O.E., Jensen, J.L. and Kendall, W.S., eds., **Networks and Chaos: Statistical and Probabilistic Aspects**, London: Chapman& Hall, 1993.

RUDD, J. B. Using a neural network system for advanced process control. **Tappi Journal**, v. 74 (10), 153–159, 1991.

RYDHOLM, S.A. : **Pulping Processes** , Interscience Publishers, NY, EUA, 1969.

SAAVEDRA, A.D.M. **Implementacion y modelamiento predictive de coccion downflow lo-solid en digestor continuo**, Dissertação M.Sc., UFV, Viçosa, MG, 2011.

SANTOS, R.B.; CAPANEMA, E. A. ; BALAKSHIN, M. Y.; CHANG, H. M. ; JAMEEL, H. Effect of hardwoods characteristics on Kraft lignina structure, **BioResources**, v 6 (4), 3623-3637, 2011.

SATO, A.; ZUOLIANG S.; SEPPO, P. Neural Networks for Chemical Engineering Unit Operations, **Chemical Engineering Technology**, v 22 (9), 732-739, 1999. DOI: 10.1002/(SICI)1521-4125(199909)22:9<732::AID-CEAT732>3.0.CO;2-1

SARLE, W.S. Neural networks and statistical models. *In:* **Proceedings of the 19th Annual SAS Users Group International Conference**,1538–1550, 1994.

SCAN Method **CM 46-92**. Bulk density. Wood chips for pulp production. Scandinavian Pulp, Paper and Board Testing Committee, 1992, 04 p. Disponível em : http://www.pfi.no/Documents/Scan_test_methods/C_CM_M/CM_46-92.pdf Acesso em outubro 2014.

SHEELA, K. G.; DEEPA, S. N. Review on Methods to Fix Number of Hidden Neurons in Neural Networks, **Mathematical Problems in Engineering**, 2013. DOI 10.1155/2013/425740

SHIMOYAMA, V.R. de S.; BARRICHELO, L.E.G. Densidade Básica da Madeira, Melhoramento e Manejo Florestal, **Série Técnica**, IPEF, Piracicaba, 1989.

SIXTA, H. ; POTTHAST, A.; KROTSCHEK, A.W. **Chemical Pulping Processes**, 1ª ed., in: H. Sixta(Ed.), Handbook of Pulp, Wiley-VCH, Weinhein 2006.
SIXTA, H.; RUTKOWSKA, E.W. Estudo cinético abrangente da polpa Kraft de Eucalyptus globulus, **O Papel**, v 68 (2), 68-81, 2007.

SJÖSTRÖM, E. **Wood Chemistry : Fundamentals and Applications**. 2ª ed. Helsinki: Academic Press, 1992.

SMOOK, G., **Handbook for Pulp & Paper Technologist.** 3ª ed.; Tappi ,Vancouver, 2002.

TAPPI –Test methods **TAPPI T 236 OM-06 Kappa Number of Pulp**. Atlanta, EUA, 2001.

TETKO, I. V. ; LIVINGSTON, D.J.; LUIK, A. I. Neural network studies. 1. Comparison of overfitting and overtraining **J. Chem. Inf. Comput. Sci**., 35 (5), 826–833, 1995.
DOI: 10.1021/ci00027a006

THOMAS, A. J.; PETRIDIS, M.; WALTERS, S. D., GHEYTASSI, S. M.; MORGAN, R. E. On Predicting the Optimal Number of Hidden Nodes, *In :* **Proceedings** International Conference on Computational Science and Computational Intelligence, 565-570, 2015.
DOI 10.1109/CSCI.2015.33

TOMAZELLO, F. M. Formação e caracterização da estrutura anatômica da madeira de Eucalyptus. *In.* **Curso de processamento mecânico e secagem da madeira de Eucalyptus. Piracicaba**, IPEF, 1994.

VENTORIM, G. ; CARASCHI, J.C.; SANSIGOLO, C. A. A influência dos ácidos hexenurônicos no rendimento e na branqueabilidade da polpa Kraft. **Química Nova,** v. 32, n. 2, p. 373-377, 2009.

VUORINEN, T.; TELEMAN, A.; FAGERSTROM, P.; BUCHERT, J.; TENKANEN, M. Selective hydrolysis of hexenuronic acid groups and its application in ECF and TCF bleaching of Kraft pulps. **International Pulp Bleaching Conference**, Tappi Proceedings, 43-51, 1996.

VROOM, K. The H factor : A means of expressing cooking times and temperatures as a single variable. **Pulp and Paper Magazine of Canada,** v 58 (3), 228-231, 1957.

WALKUSH, K.; GUSTAFSON, R. R. Application of pulping models to investigate the performance of commercial continuous digesters, **Tappi Journal**, V. 1 (5), 13-19, 2002.

WEDING, H. **Aspects of extended impregnation Kraft cooking for high-yield pulping of hardwood**, Tese Ph.D. , KTH Royal Institute of Technology, Sweden, 2012.

WILLETT, JB., SINGER, J. D., 1988 , Another Cautionary Note about R2 : Its Use in Weighted Least-Squares Regression Analysis. **The American Statistician**, v 42, 236-238. DOI: 10.1080/00031305.1988.10475573

WINTERS, P.R. Forecasting Sales by Exponentially Weighted Moving Averages. **Management Science**, v 6, 324–342, 1960.

YANG, L. , LIU, S., Kinetic model for Kraft pulping process, **Industrial & Engineering Chemistry Research** , v 44 (18), 7078–7085, 2005.
DOI: 10.1021/ie050301n

Apêndices

Apêndice 1

Complementos dos Modelos de Predição da Densidade de Cavaco

Apêndice 1.1

Complementos Modelo Média Móvel Simples (MMS) na Predição do Densidade de Cavaco

Apêndice 1.2

Complementos Modelo Alisamento Exponencial Simples (AES) na Predição do Densidade de Cavaco

Apêndice 1.3

Complementos Modelo Box-Jenkins (ARMA) na Predição do Densidade de Cavaco

Apêndice 2

Complementos dos Modelos de Predição do Número Kappa

Apêndice 2.1

Dados Complementares Número Kappa

Apêndice 2.2

Complementos Modelos Alisamento Exponencial Simples (AES) na Predição do Número Kappa

Apêndice 2.3

Complementos Modelos Regressão Linear Múltipla (RLM) na Predição do Número Kappa

Apêndice 2.4

Complementos Modelos Redes Neurais Artificias (RNA) na Predição do Número Kappa

Apêndice 1

Complementos dos Modelos de Predição da Densidade de Cavaco

Apêndice 1.1 – Complementos Modelo MMS na Predição da Densidade de Cavaco

Tabela A1.1 : Comprimento de Média (m) e respectivos erros de previsão MAD, MAPE, RMSE [DENS1]

Comprimento Média (m)	MAD	MAPE	RMSE	MAPE x RMSE x MAD
2	3,68	2,11	5,06	39,34
3	3,61	2,07	4,95	36,99
4	3,56	2,05	4,84	35,28
5	3,52	2,03	4,78	34,10
6	3,45	1,99	4,72	32,31
7	3,42	1,97	4,68	31,44
8	3,41	1,96	4,66	31,23
9	3,42	1,96	4,66	31,30
10	3,42	1,97	4,66	31,31

Tabela A1.2 : Comprimento de Média (m) e respectivos erros de previsão MAD, MAPE, RMSE [DENS2]

Comprimento Média (m)	*MAD*	*MAPE*	*RMSE*	*MAPE x RMSE x MAD*
2	*1,96*	*3,42*	*4,83*	*32,43*
3	*1,91*	*3,33*	*4,68*	*29,69*
4	*1,91*	*3,33*	*4,59*	*29,08*
5	*1,87*	*3,26*	*4,60*	*28,06*
6	*1,84*	*3,22*	*4,53*	*26,83*
7	*1,82*	*3,17*	*4,54*	*26,15*
8	*1,80*	*3,16*	*4,49*	*25,61*
9	*1,81*	*3,16*	*4,50*	*25,70*
10	*1,81*	*3,16*	*4,51*	*25,78*

Apêndice 1.2 - Complementos Modelo AES na Predição da Densidade de Cavaco

Tabela A1.3 : Índice (**α**) e respectivos erros de previsão MAD, MAPE, RMSE [DENS1]

α	***MAD***	***MSE***	***RMSE***	***MAPE***	***MAD x MAPE x RMSE***
0,1	*3,28*	*20,42*	*4,52*	*1,89*	*28,02*
0,2	*3,28*	*20,60*	*4,54*	*1,89*	*28,06*
0,3	*3,31*	*21,10*	*4,59*	*1,90*	*28,99*
0,4	*3,36*	*21,80*	*4,67*	*1,93*	*30,29*
0,5	*3,42*	*22,68*	*4,76*	*1,97*	*32,10*
0,6	*3,51*	*23,74*	*4,87*	*2,02*	*34,46*
0,7	*3,60*	*25,02*	*5,00*	*2,07*	*37,24*
0,8	*3,71*	*26,56*	*5,15*	*2,13*	*40,71*
0,9	*3,84*	*28,44*	*5,33*	*2,21*	*45,21*

Tabela A1.4 : Índice (**α**) e respectivos erros de previsão MAD, MAPE, RMSE [DENS2]

α	**MAD**	**MSE**	**RMSE**	**MAPE**	**MAD x MAPE x RMSE**
0,1	2,96	18,46	4,30	1,70	21,60
0,2	3,00	18,94	4,35	1,72	22,49
0,3	3,06	19,55	4,42	1,76	23,79
0,4	3,13	20,35	4,51	1,79	25,25
0,5	3,19	21,36	4,62	1,83	27,01
0,6	3,27	22,61	4,76	1,88	29,17
0,7	3,36	24,15	4,91	1,93	31,89
0,8	3,48	26,02	5,10	2,00	35,44
0,9	3,62	28,31	5,32	2,01	38,68

Apêndice 1.3 - Complementos Modelo ARMA na Predição da Densidade de Complementos Resultados Modelo ARMA (2,2) :

Dependent Variable: DENS_1
Method: Least Squares
Date: 03/15/14 Time: 08:20
Sample (adjusted): 3 1948
Included observations: 1946 after adjustments
Convergence achieved after 18 iterations
Backcast: 1 2

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	173.9198	0.344822	504.3753	0.0000
AR(1)	1.404277	0.099330	14.13751	0.0000
AR(2)	-0.417042	0.095448	-4.369334	0.0000
MA(1)	-1.157647	0.104792	-11.04707	0.0000
MA(2)	0.201239	0.093597	2.150053	0.0317

R-squared	0.116660	Mean dependent var	173.9539
Adjusted R-squared	0.114840	S.D. dependent var	4.690204
S.E. of regression	4.412683	Akaike info criterion	5.809409
Sum squared resid	37794.71	Schwarz criterion	5.823729
Log likelihood	-5647.555	F-statistic	64.08541
Durbin-Watson stat	2.001810	Prob(F-statistic)	0.000000

Inverted AR Roots	.98	.43
Inverted MA Roots	.94	.21

Forecast: DENS_1_F
Actual: DENS_1
Forecast sample: 1 1948
Adjusted sample: 3 1948
Included observations: 1946

Root Mean Squared Error	4.407010
Mean Absolute Error	3.142288
Mean Abs. Percent Error	1.807168
Theil Inequality Coefficient	0.012664
Bias Proportion	0.000001
Variance Proportion	0.488907
Covariance Proportion	0.511091

Como ilustração, são indicados na Tabela A1.5, dados reais quando da aplicação *sem* os dados da predição. No exemplo a seguir, uma amostra de cavaco é coletada às 21:00 hs do dia 02/01. Como demanda um tempo para coleta, transporte da amostra e a própria análise, o resultado da análise desta amostra (175,0 kg/m^3) é disponibilizado ao operador às 01:00 hs do dia 03. Em não havendo predições, o valor a ser aplicado no cálculo do licor branco será este valor. Entretanto, às 01:00 h é coletado uma outra amostra de cavaco para análise (cujo valor após análise é de 172,1 kg/m^3). Isto é, o valor real que deveria ser aplicado ao cálculo de licor branco é 172,1, sendo que foi aplicado o valor de 175,0, resultando no momento instantâneo especificado em um MAD de 2,9; MAPE = 1,69; MSE = 8,4. Para as 20 amostras aqui ilustradas, possuem um valor médio de MAD= 3,2 ; MAPE = 1,84 ; MSE = 20,51.

Tabela A1.5 : Ilustração de dados reais de densidade sem aplicação de predição

Data	Resultado Conforme Coleta de Amostra	Resultado Disponibilizado pelo Laboratório	Valor Aplicado Sem Predição	MAD SEM Predição	MAPE SEM Predição	MSE Sem Predição
2014-01-02 21:00:00	175,0					
2014-01-03 01:00:00	172,1	175,0	175,0	2,9	1,69	8,4
2014-01-03 05:00:00	173,9	172,1	172,1	1,8	1,04	3,2
2014-01-03 09:00:00	171,2	173,9	173,9	2,7	1,58	7,3
2014-01-03 13:00:00	178,2	171,2	171,2	7,0	3,93	49,0
2014-01-03 17:00:00	176,8	178,2	178,2	1,4	0,79	2,0
2014-01-03 21:00:00	174,0	176,8	176,8	2,8	1,61	7,8
2014-01-04 01:00:00	174,5	174,0	174,0	0,5	0,29	0,3
2014-01-04 05:00:00	175,7	174,5	174,5	1,2	0,68	1,4
2014-01-04 09:00:00	174,3	175,7	175,7	1,4	0,80	2,0
2014-01-04 13:00:00	176,4	174,3	174,3	2,1	1,19	4,4
2014-01-04 17:00:00	162,2	176,4	176,4	14,2	8,75	201,6
2014-01-04 21:00:00	170,0	162,2	162,2	7,8	4,59	60,8
2014-01-05 01:00:00	174,6	170,0	170,0	4,6	2,63	21,2
2014-01-05 05:00:00	175,9	174,6	174,6	1,3	0,74	1,7
2014-01-05 09:00:00	176,4	175,9	175,9	0,5	0,28	0,3
2014-01-05 13:00:00	176,5	176,4	176,4	0,1	0,06	0,0
2014-01-05 17:00:00	171,7	176,5	176,5	4,8	2,80	23,0
2014-01-05 21:00:00	172,6	171,7	171,7	0,9	0,52	0,8
2014-01-06 01:00:00	174,7	172,6	172,6	2,1	1,20	4,4
2014-01-06 05:00:00	173,1	174,7	174,7	1,6	0,92	2,6
2014-01-06 09:00:00	177,6	173,1	173,1	4,5	2,53	20,3
MÉDIA	174,0	173,8	173,8	3,2	1,84	20,1

De modo análogo, são indicados na Tabela A2.6, ilustração com os mesmos dados reais, agora ***com*** aplicação das predições. No mesmo exemplo citado, o resultado da amostra de cavaco coletada às 21:00 hs do dia 02/01 é disponibilizado ao operador às 01:00 hs do dia 03. Entretanto, em vez da aplicação direta, faz-se a predição pelo

modelo ARMA, cujo valor calculado é de 174,9 kg/m^3. Este valor possui no momento instantâneo especificado o MAD = 2,80 ; MAPE = 1,64 ; MSE = 8,0. Para as 20 amostras aqui ilustradas, os índices apresentam um valor médio de MAD = 2,36 ; MAPE = 1,38 ; MSE = 12,37.

Tabela A1.6 : Ilustração de dados reais de densidade com aplicação de predição

Data	Resultado Conforme Coleta de Amostra	Resultado Disponibilizado pelo Laboratório	Valor Aplicado Sem Predição	MAD SEM Predição	MAPE SEM Predição	MSE Sem Predição	Predição ARMA(2,2)	MAD COM Predição	MAPE COM Predição	MSE COM Predição
2014-01-02 21:00:00	175,0									
2014-01-03 01:00:00	172,1	175,0	175,0	2,8	1,60	8,4	174,9	2,8	1,64	8,0
2014-01-03 05:00:00	173,9	172,1	172,1	1,8	1,04	3,2	174,3	0,4	0,26	0,2
2014-01-03 09:00:00	171,2	173,9	173,9	2,7	1,58	7,3	174,6	3,4	1,99	11,6
2014-01-03 13:00:00	178,2	171,2	171,2	7,0	3,93	49,0	174,0	4,2	2,38	18,0
2014-01-03 17:00:00	176,8	178,2	178,2	1,4	0,79	2,0	175,5	1,3	0,75	1,8
2014-01-03 21:00:00	174,0	176,8	176,8	2,8	1,61	7,8	175,5	1,5	0,86	2,2
2014-01-04 01:00:00	174,5	174,0	174,0	0,5	0,29	0,3	174,8	0,3	0,19	0,1
2014-01-04 05:00:00	175,7	174,5	174,5	1,2	0,68	1,4	174,8	0,9	0,53	0,9
2014-01-04 09:00:00	174,3	175,7	175,7	1,4	0,80	2,0	175,0	0,7	0,43	0,6
2014-01-04 13:00:00	176,4	174,3	174,3	2,1	1,19	4,4	174,8	1,6	0,93	2,7
2014-01-04 17:00:00	162,2	176,4	176,4	14,2	8,75	201,6	175,2	13,0	8,01	168,8
2014-01-04 21:00:00	170,0	162,2	162,2	7,8	4,59	60,8	171,8	1,8	1,06	3,2
2014-01-05 01:00:00	174,6	170,0	170,0	4,6	2,63	21,2	172,8	1,8	1,05	3,3
2014-01-05 05:00:00	175,9	174,6	174,6	1,3	0,74	1,7	174,0	1,9	1,06	3,5
2014-01-05 09:00:00	176,4	175,9	175,9	0,5	0,28	0,3	174,6	1,8	1,01	3,2
2014-01-05 13:00:00	176,5	176,4	176,4	0,1	0,06	0,0	174,9	1,6	0,91	2,6
2014-01-05 17:00:00	171,7	176,5	176,5	4,8	2,80	23,0	175,0	3,3	1,93	10,9
2014-01-05 21:00:00	172,6	171,7	171,7	0,9	0,52	0,8	173,9	1,3	0,74	1,6
2014-01-06 01:00:00	174,7	172,6	172,6	2,1	1,20	4,4	173,8	0,9	0,51	0,8
2014-01-06 05:00:00	173,1	174,7	174,7	1,6	0,92	2,6	174,3	1,2	0,68	1,4
2014-01-06 09:00:00	177,6	173,1	173,1	4,5	2,53	20,3	174,0	3,6	2,04	12,1
MÉDIA	174,0	173,8	173,8	3,2	1,84	20,1	174,4	2,36	1,38	12,3

A Figura A1.5 mostra o comparativo dos índices médios, para as 20 amostras aqui ilustradas, mostrando a redução dos mesmos quando é aplicado o modelo ARMA de previsão :

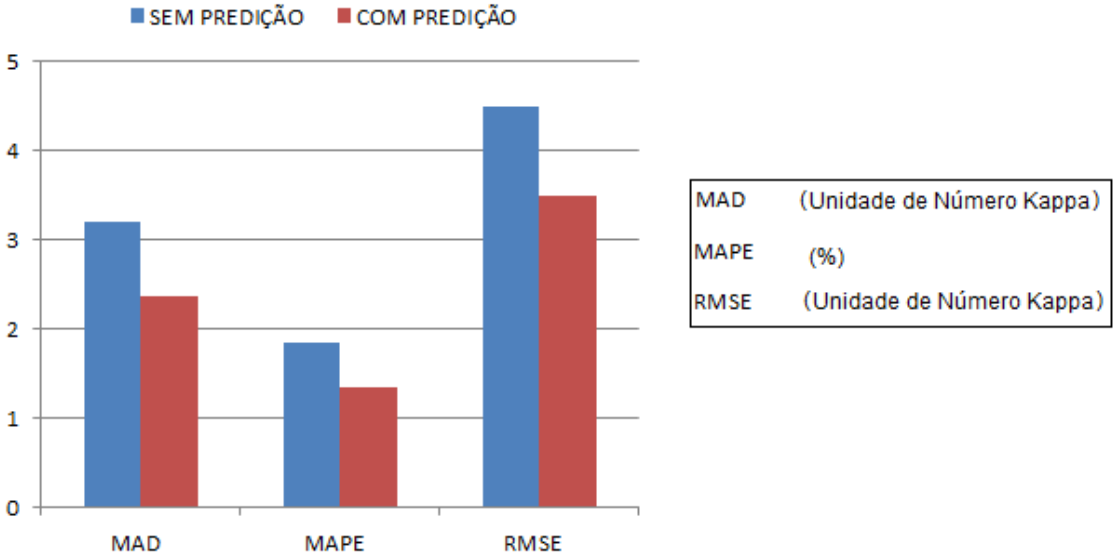


Figura A1.5 – Ilustração dos índices de Desvios *Sem* Predição e *Com* Predição

Apêndice 2

Complementos Modelos Predição do número kappa

Apêndice 2.1. - Complementos Modelo AES na Predição do número kappa

Tabela A2.1 : Índice (**α**) e respectivos erros de previsão MAD, MAPE, RMSE [KAPPA1]

α	MAD	MSE	RMSE	MAPE	MAD x MAPE x RMSE
0,1	1,06	2,16	6,36	1,47	9,88
0,2	0,95	1,75	5,68	1,32	7,10
0,3	0,85	1,44	5,11	1,20	5,23
0,4	0,77	1,22	4,64	1,10	3,97
0,5	0,71	1,05	4,26	1,02	3,10
0,6	0,66	0,93	3,95	0,96	2,51
0,7	0,62	0,84	3,71	0,92	2,11
0,8	0,59	0,77	3,53	0,88	1,83
0,9	0,57	0,73	3,39	0,85	1,64

Tabela A2.2 : Índice (**α**) e respectivos erros de previsão MAD, MAPE, RMSE [KAPPA2]

α	MAD	MSE	RMSE	MAPE	MAD x MAPE x RMSE
0,1	2,96	18,46	4,30	1,70	21,60
0,2	3,00	18,94	4,35	1,72	22,49
0,3	3,06	19,55	4,42	1,76	23,79
0,4	3,13	20,35	4,51	1,79	25,25
0,5	3,19	21,36	4,62	1,83	27,01
0,6	3,27	22,61	4,76	1,88	29,17
0,7	3,36	24,15	4,91	1,93	31,89
0,8	3,48	26,02	5,10	2,00	35,44
0,9	3,62	28,31	5,32	2,01	38,68

Apêndice 2.2. Complementos modelo RLN Predição número kappa [KAPPA2]

Etapas da Seleção de Variáveis pelo Método *Step Wise*

Stepwise Regression: KAPPA versus DENS; CS; ...

Alpha-to-Enter: 0,1 Alpha-to-Remove: 0,1

Response is KAPPA on 18 predictors, with N = 1471

Step	1	2	3	4	5	6
Constant	1,116	1,660	11,097	11,044	11,316	14,067
KANT	0,9310	0,9168	0,9019	0,8949	0,8942	0,8917
T-Value	97,62	93,69	94,87	93,81	93,98	93,44
P-Value	0,000	0,000	0,000	0,000	0,000	0,000
ACHOM		-0,0327	-0,0897	-0,1017	-0,0934	-0,0984
T-Value		-5,51	-11,63	-12,65	-11,03	-11,37
P-Value		0,000	0,000	0,000	0,000	0,000
TCHOM			-0,0545	-0,0576	-0,0570	-0,0538
T-Value			-10,99	-11,61	-11,51	-10,58
P-Value			0,000	0,000	0,000	0,000
RPM				0,0129	0,0147	0,0152
T-Value				4,90	5,46	5,66
P-Value				0,000	0,000	0,000
ACCOZ					-0,046	-0,054
T-Value					-3,06	-3,53
P-Value					0,002	0,000
TTOPO						-0,0200
T-Value						-2,66
P-Value						0,008
S	0,600	0,594	0,571	0,567	0,565	0,564
R-Sq	86,64	86,92	87,91	88,11	88,18	88,24
R-Sq(adj)	86,64	86,90	87,89	88,07	88,14	88,19
Mallows Cp	223,1	190,8	66,9	44,2	36,7	31,5

Step	7	8	9	10	11	12
Constant	13,72	14,84	16,26	16,31	16,80	16,26
KANT	0,8923	0,8886	0,8864	0,8834	0,8822	0,8821
T-Value	93,72	92,48	91,78	90,08	89,84	89,94
P-Value	0,000	0,000	0,000	0,000	0,000	0,000
ACHOM	-0,0924	-0,0914	-0,0923	-0,0939	-0,0977	-0,0932
T-Value	-10,40	-10,30	-10,40	-10,53	-10,69	-9,93
P-Value	0,000	0,000	0,000	0,000	0,000	0,000
TCHOM	-0,0518	-0,0515	-0,0512	-0,0545	-0,0448	-0,0408
T-Value	-10,13	-10,08	-10,02	-10,00	-5,97	-5,29
P-Value	0,000	0,000	0,000	0,000	0,000	0,000
RPM	0,0138	0,0174	0,0123	0,0131	0,0132	0,0147
T-Value	5,07	5,72	3,10	3,30	3,30	3,62

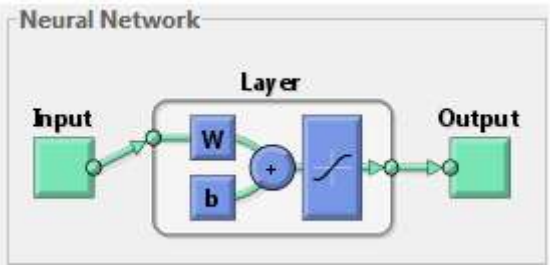
P-Value	0,000	0,000	0,002	0,001	0,001	0,000
ACCOZ	-0,055	-0,054	-0,056	-0,058	-0,057	-0,052
T-Value	-3,62	-3,59	-3,71	-3,80	-3,78	-3,40
P-Value	0,000	0,000	0,000	0,000	0,000	0,001
TTOPO	-0,0221	-0,0365	-0,0416	-0,0403	-0,0380	-0,0386
T-Value	-2,93	-3,93	-4,33	-4,19	-3,91	-3,98
P-Value	0,003	0,000	0,000	0,000	0,000	0,000
EXTFUN	0,0090	0,0091	0,0090	0,0087	0,0079	0,0093
T-Value	2,90	2,94	2,92	2,81	2,53	2,91
P-Value	0,004	0,003	0,004	0,005	0,011	0,004
RLM		0,33	0,31	0,25	0,23	0,20
T-Value		2,65	2,49	1,90	1,78	1,53
P-Value		0,008	0,013	0,058	0,076	0,126
RETSILO			-0,0170	-0,0178	-0,0169	-0,0167
T-Value			-2,04	-2,12	-2,02	-1,99
P-Value			0,042	0,034	0,043	0,047
CA				0,029	0,032	0,032
T-Value				1,73	1,94	1,94
P-Value				0,083	0,053	0,053
TCCOZ					-0,0148	-0,0183
T-Value					-1,89	-2,29
P-Value					0,060	0,022
LPDRPM						0,054
T-Value						2,08
P-Value						0,037
S	0,562	0,561	0,561	0,560	0,560	0,559
R-Sq	88,30	88,36	88,39	88,42	88,45	88,48
R-Sq(adj)	88,25	88,30	88,32	88,34	88,36	88,38
Mallows Cp	25,0	20,0	17,8	16,8	15,2	12,9

Step	13	14
Constant	15,72	15,72
KANT	0,8832	0,8832
T-Value	90,27	90,27
P-Value	0,000	0,000
ACHOM	-0,0940	-0,0939
T-Value	-10,02	-10,23
P-Value	0,000	0,000
TCHOM	-0,0410	-0,0409
T-Value	-5,31	-5,31
P-Value	0,000	0,000
RPM	0,0128	0,0127
T-Value	3,31	3,31
P-Value	0,001	0,000
ACCOZ	-0,052	-0,052
T-Value	-3,41	-3,41
P-Value	0,001	0,000
TTOPO	-0,0306	-0,0306

T-Value	-3,74	-3,74
P-Value	0,000	0,000
EXTFUN	0,0092	0,0092
T-Value	2,89	2,89
P-Value	0,004	0,004
RLM		
T-Value		
P-Value		
RETSILO	-0,0177	-0,0176
T-Value	-2,12	-2,17
P-Value	0,034	0,034
CA	0,040	0,040
T-Value	2,48	2,48
P-Value	0,013	0,013
TCCOZ	-0,0194	-0,0194
T-Value	-2,43	-2,43
P-Value	0,015	0,015
LPDRPM	0,059	0,059
T-Value	2,27	2,27
P-Value	0,023	0,023
P		
T-Value		
P-Value		

R-squared	0.884612	Mean dependent var	16.15180
Adjusted R-squared	0.883742	S.D. dependent var	1.640890
S.E. of regression	0.559487	Akaike info criterion	1.684532
Sum squared resid	456.7050	Schwarz criterion	1.727717
Log likelihood	-1226.974	F-statistic	1016.849
Durbin-Watson stat	1.594353	Prob(F-statistic)	0.000000

Apêndice 2.3. ***Complemento Modelos Redes Neurais Artificias (RNA) na Predição do número kappa***



A Figura A2.2 ilustra uma das repetições com 23 neurônios, para avaliação do coeficiente de correlação *r versus* número de neurônios na camada oculta. Foram realizadas 30 repetições para avaliação dos valores médios, e a figura abaixo ilustra uma delas.

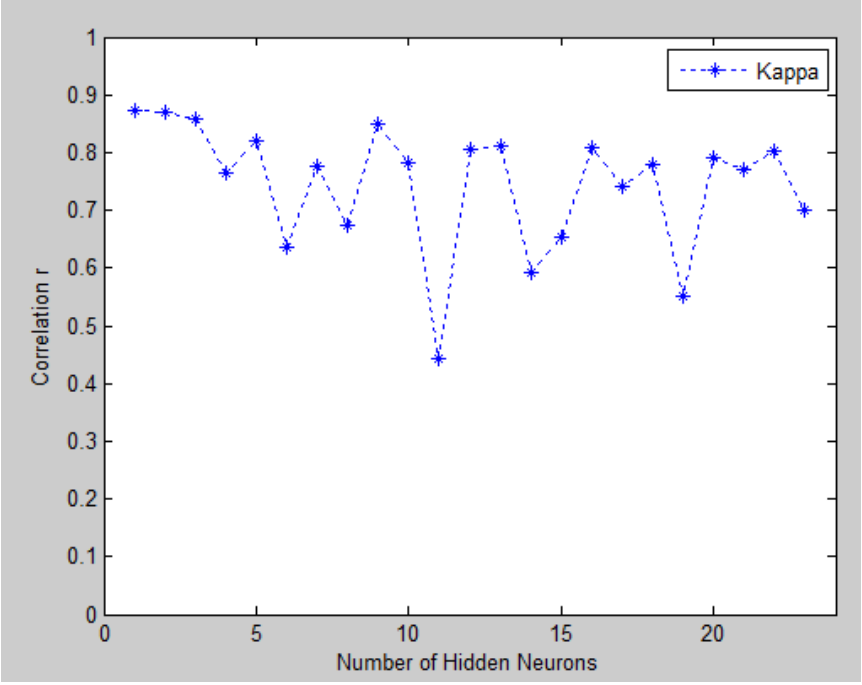


Figura A2.2 – Ilustração Evolução Número Neurônio x Coeficiente *r*.

A Figura A2.3 ilustra uma das repetições para avaliação do coeficiente angular (*a*) e Intercepto (*b*) quanto ao número de neurônios. Foram realizadas 30 repetições para avaliação dos valores médios, conforme indicado nas Figuras 6.15 e 6.16.

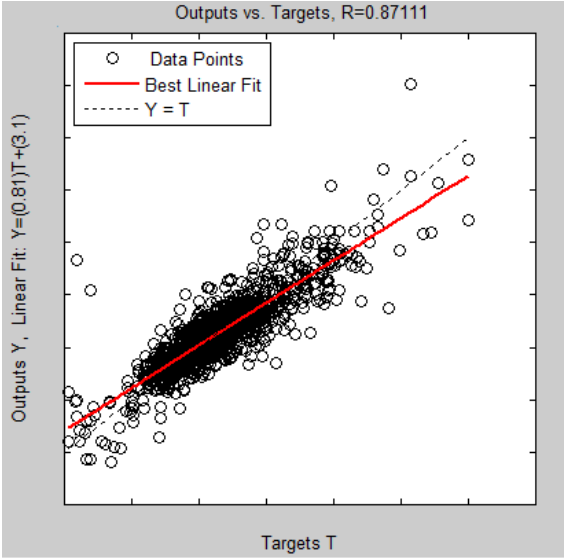


Figura A2.3 – Ilustração da avaliação do coeficiente angular e intercepto

As figuras A2.4 mostra a evolução dos dados do MAD após 30 repetições para avaliação dos valores médios *versus* número de neurônios na camada oculta. Conforme indicado no item 6.3.4 *Etapa 2A*, o índice MAD não foi considerado na escolha dos neurônios.

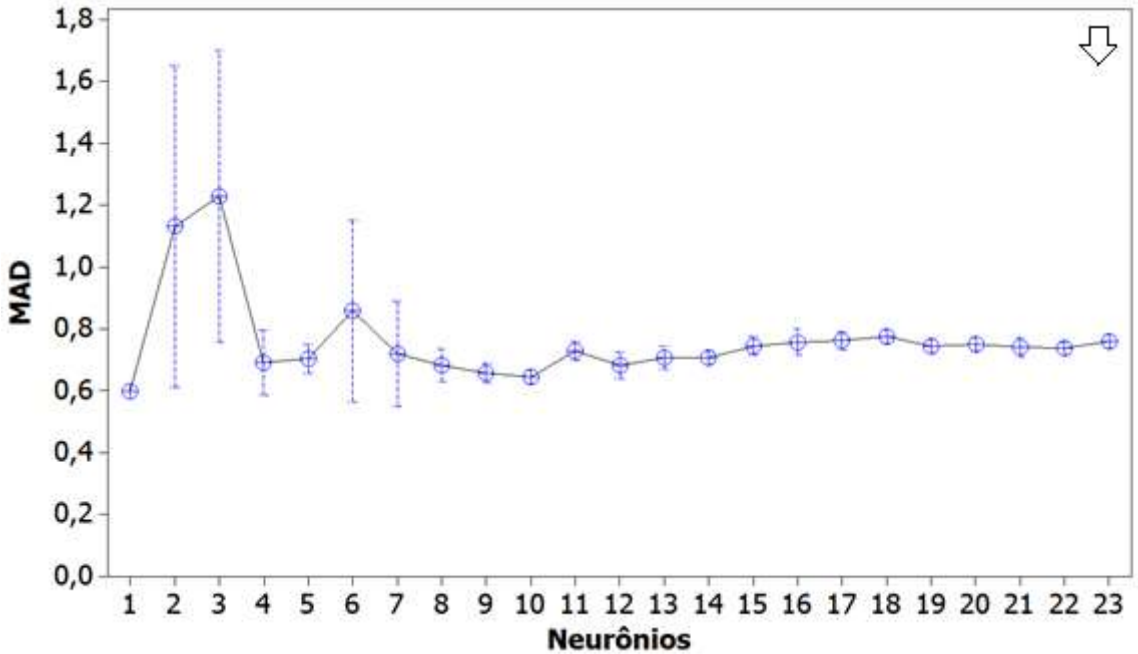


Figura A2.4 – Evolução Número de Neurônios x MAD

A evolução dos dados do MAPE após 30 repetições para avaliação dos valores médios *versus* número de neurônios na camada oculta é indicada na Figura

A2.5. Conforme indicado no item 6.3.4 *Etapa 2A*, o índice MAPE não foi considerado na escolha dos neurônios.

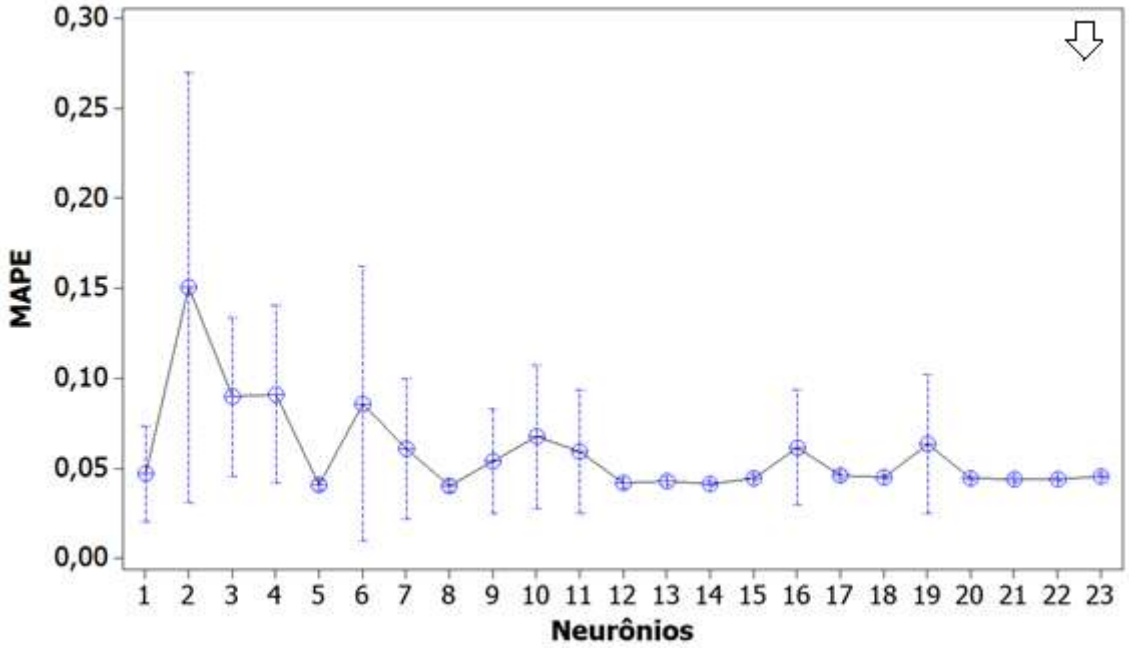


Figura A2.5 – Evolução Número de Neurônios x MAD

Visando identificar uma variável única que representasse a associação dos quatro índices (r, RMSE, α e β), foi elaborado o "Índice Global", considerando sua associação para "quanto maior melhor". O índice foi elaborado conforme equação abaixo, confirmando que o índice de "3 neurônios" foi o melhor considerando a associação dos quatro índices.

O Índice Global foi considerado como o produto dos índices a seguir compilados. As transformações foram necessárias para que os quatro índices apresentassem como resultado "quanto maior melhor" :

Coeficiente de Correlação de *Pearson* (*r*) : Aplicado como tal;
Raiz do Erro Quadrado Médio (RMSE) : Aplicado como (1/RMSE) ;
Coeficiente angular (*a*) da reta : Aplicado como 1/(ABS(1- *a*));
Intercepto (*b*) : Aplicado como 1/ *b*.

Índice Global = r x (1/RMSE) x [1/(ABS(1- *b*)] x 1/ *b*

Dados do índice estão indicados na Tabela A2.3 :

Tabela A2.3 : Número de Neurônios e Índice Global

Neurônios	r	1/RMSE	1/ABS(1-*a*)	1/*b*	Indice Global
1	0,88	1,27	5,00	0,33	1,86
2	0,65	1,14	8,33	0,53	3,24
3	0,82	0,88	4,76	1,00	3,43
4	0,75	1,11	3,57	0,53	1,57
5	0,74	0,80	5,00	0,36	1,06
6	0,77	0,83	3,13	0,36	0,72
7	0,76	0,83	10,00	0,37	2,33
8	0,75	0,91	4,76	0,28	0,90
9	0,78	0,82	5,00	0,31	1,00
10	0,67	0,89	5,26	0,32	1,02
11	0,76	0,68	4,35	0,23	0,51
12	0,78	0,78	4,76	0,30	0,87
13	0,75	0,75	4,76	0,27	0,73
14	0,70	0,83	4,76	0,28	0,77
15	0,73	0,76	4,55	0,26	0,66
16	0,68	0,85	4,76	0,27	0,74
17	0,72	0,75	4,76	0,30	0,78
18	0,73	0,78	4,76	0,29	0,80
19	0,76	0,79	4,76	0,29	0,84
20	0,69	0,85	4,76	0,27	0,75
21	0,76	0,81	4,76	0,29	0,83
22	0,76	0,79	4,55	0,26	0,72
23	0,72	0,75	4,35	0,23	0,53

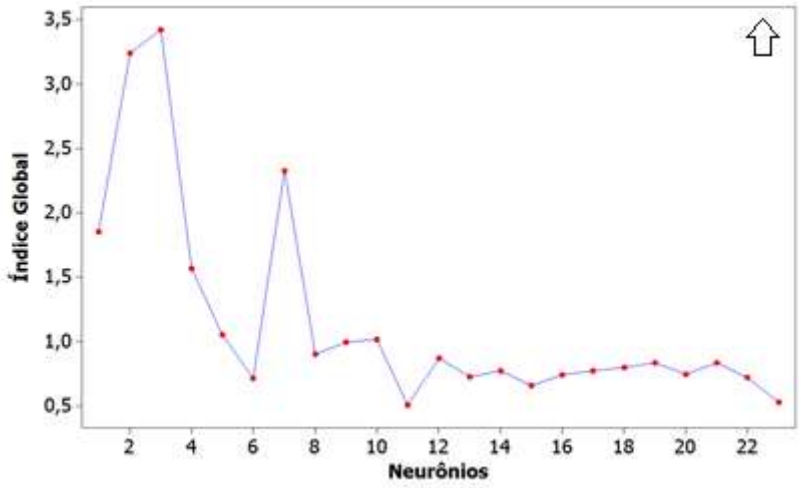


Figura A2.6 – Evolução Número de Neurônios x Índice Global

ANEXOS

Anexo 1

Patentes do Processo Kraft

Anexo 1.1. Patente A.K. Eaton (1870)

Anexo 1.2. Patente C.F. Dahl (1874)

Anexo 2

Terminologia do Processo Kraft

Anexo 3

Alguns Conceitos Estatísticos

Anexo 4

Publicações Associadas à Tese

Anexo 1.1. Patente A.K. Eaton

Patente US 106 143 de Asahel K. Eaton, referente ao processo de aplicação de compostos sulfurosos para deslignificação, do ano de 1870

United States Patent Office.

ASAHEL K. EATON, OF PIERMONT, NEW YORK.

Letters Patent No. 106,143, *dated August* 9, 1870.

IMPROVEMENT IN THE MANUFACTURE OF PAPER PULP.

To all whom it may concern:

Be it known that I, ASAHEL K. EATON, of Piermont, in the county of Rockland and State of New York, have invented certain new and useful Improvements in the Art of Manufacturing Paper Pulp from Straw, Wood, and other Vegetable Fiber; and I do hereby declare the following to be such a full, clear, and exact description thereof as will enable any one skilled in the art to which my invention appertains to work or practice the same.

In the manufacture of paper pulp after the process described in the patent heretofore granted to me, and dated the 22d of March, 1864, it is necessary to reproduce the caustic, soda, or potash to insure the desired profit as the commercial result of the process, but the expense of apparatus and labor necessary to the reproduction of the soda or potash makes it desirable to substitute in its place a solvent, the recovery whereof is unnecessary to insure at least as large a profit as can be obtained in the use of soda or potash as a solvent, even though the whole of it contained in the refuse water be recovered, which is scarcely possible in the practical manufacture of the pulp.

Now, I have discovered that the incrusting matter of the cellulose of the wood, straw, or other vegetable material suitable for paper pulp, can be dissolved readily, and with great economy, by the use of oxysulphide of calcium, a substance of such little cost that the refuse liquor can be thrown away without material loss to the manufacturer.

In the practice of this improvement, I first put the straw, wood, or other fibrous substance out of which the pulp is to be made, in the water-tank, and raise it to the boiling point. I then take, to a ton of straw or wood, from two to five hundred pounds of lime, which I first make into a milk of lime. To this I add about twenty pounds of sulphur. I then throw the mixture into the tank of boiling water containing the straw or wood, leaving the combination of the sulphur and lime to take place in the tank, thus saving the preparation of the sulphide beforehand, and continue the treatment as though a caustic soda were used.

The result is a pulp in all respects equal, if not superior, to that made by the use of caustic soda or potash, and in even a more favorable condition for bleaching.

The proportions given above may, of course, be somewhat varied, as will appear by those given, but the lime should always be in chemical excess of the sulphur, that is, more than is necessary for the sulphur to combine with to form the sulphide of calcium, the ordinary quantity of water being used in all cases.

The rationale of the process seems to be as follows:

The sulphide formed in the solution first dissolves the resinous and incrusting matter of the straw or wood, which it immediately gives up to the excess of lime, the sulphide being thus left in its original condition to act again and again.

In referring to the patent heretofore granted to me, I do not intend to limit this improvement to the method described there, as this sulphide can be substituted for the caustic alkali in all processes where the same is used as a solvent with beneficial and economical results; the cost of treating fiber with alkali after the old process being from two to three cents per pound of pulp produced for the alkaline treatment alone, while by the use of the sulphide the cost will be very much reduced, even by the old process; and, in connection with the process described in the patent above referred to, the cost is reduced to one-half cent or less per pound of pulp for this part of the process, which, itself, is a great advantage considered merely in the light of commerce.

Having now described the nature and extent of my improvement in the art of manufacturing paper pulp,

I claim as new herein, and desire to secure by Letters Patent—

The use of oxysulphide of calcium as a solvent in the manufacture of paper pulp from straw, wood, or other vegetable substance suitable for that purpose.

A. K. EATON.

Witnesses:

AMOS BROADNAX,

PETER D. KENNY.

Anexo 1.2. Patente C.F. Dahl

Patente US 296 935 de Carl Ferdinand Dahl, referente ao processo de aplicação de sulfato de sódio para deslignificação, do ano de 1884.

UNITED STATES PATENT OFFICE.

CARL FERDINAND DAHL, OF DANTZIC, PRUSSIA, GERMANY.

PROCESS OF MANUFACTURING CELLULOSE FROM WOOD, &c.

SPECIFICATION forming part of Letters Patent No. 296,935, dated April 15, 1884.

To all whom it may concern:

Be it known that I, CARL FERDINAND DAHL, a subject of the King of Prussia, residing at Dantzic, in the Kingdom of Prussia and German Empire, have invented new and useful Improvements in Process for the Manufacture of Cellulose from Wood and other Vegetable Substances, of which the following is a specification.

This invention consists in a process for the manufacture of cellulose from wood and other vegetable substances.

For the purpose of dissolving the cellular mass or fibrous mass out of the bodies incrusting the same, the comminuted wood, straw, esparto, and the like are boiled under pressure in wrought-iron vessels free from lead lining, containing a hydrated solution in which are contained sodium salts, partly in the form of sulphate of soda, carbonate of soda, soda hydrate, and sulphide of sodium. One hundred kilograms (about two hundred and twenty pounds avoirdupois) of half-dried pine wood require about twenty-six kilograms of the above-named salts in solution; straw or alfa, (esparto,) about ten to twelve kilograms. Pine or fir wood requires five to ten atmospheres overpressure, the strength of the sodium solution being 6° to 14° Baumé, the time of boiling thirty to four hours. Straw or alfa (esparto) requires two to five atmospheres overpressure, the strength of the sodium solution being 5° to 8° Baumé, and duration of boil-boiling eight to three hours. By the boiling process the incrustations combine with the sodium solutions; the cellular matter remains uninjured in a loose consistency. After the boiling is completed, the brownish-black lye is blown off into iron basins for the purpose of afterward recovering the sodium salts. The remaining cell matter is washed with warm water in the boiler or other suitable receptacle, and is then manufactured into paper-pulp, in the well-known way, by means of a Hollander or pulp engine, and bleached with a solution of chloride of lime. The color of the unbleached mass is yellowish gray; that of the bleached mass pure white or slightly but a clear yellowish, according to the degree of bleaching.

Sulphate of soda serves for the production of the sodium solution. The sulphate dissolved in water is boiled with about twenty to thirty per cent. of burnt lime. The lye thus prepared is already serviceable for boiling; but it receives its proper composition by the addition of the salts regained from the sulphate solution after the boiling process. The lye, after being used, is forced into an evaporating-oven for the purpose of regaining the salts, is strongly calcined, and after thus being deprived of gas is drawn from the oven as a cake-like mass, washed, and the resultant solution used for the preparation of fresh lye.

For obtaining pure salts without the admixture of carbon, the thickened lye is drawn from the evaporating-oven and is fused in a calcining-oven at a dark-red heat. The fused mass, after cooling, assumes a reddish-brown color, is readily soluble in water, and has approximately the following composition: sixteen per cent. sulphate of soda, fifty per cent. carbonate of soda, twenty per cent. sodium sulphide, four per cent diverse non-essential matters. This composition is very variable, according to the properties of the boiled matter, but without influencing the dissolving power of the solution afterward prepared therefrom. The salt which is regained should be dissolved as soon as possible, or guarded against the influence of atmospheric air. By the process of boiling and regaining, about ten to fifteen per cent. of the salts in the solution is lost. In general practice the losses are replaced in the preparation of the lye by sulphate of soda. For the solution are taken eighty-five to ninety per cent. of regained salt and fifteen to ten per cent. of sulphate, which mixture, boiled with twenty to twenty-three per cent. of burnt lime, yields the proper lye. With ten per cent. of loss a clear watery solution is taken for the lye, in which are contained ninety kilograms of regained salt; ten kilograms of sulphate are added, and the solution in which are contained one hundred kilograms (about two hundred and twenty pounds) of salts in the already-named proportion is boiled with twenty kilograms of burnt lime. If the loss amounts to fifteen per cent., then fifteen kilograms of sulphate are added to eighty-five kilograms of regained salt, the whole being boiled with twenty-three kilograms of lime. In the case of twenty per cent. loss, eighty kilograms of regained salts and twenty kilograms of sulphate are taken for the solution, and are boiled together with twenty-five kilograms of lime. If

twenty-five per cent. of sulphate is to be added, seventy-five kilogrames of regained salts, twenty-five kilograms of sulphate, and twenty-eight kilograms of burnt lime are taken for the solution. In regular operation the uttermost limit of sulphate addition should be thirty per cent., seventy kilograms of regained salts, thirty kilograms of sulphate, and thirty-two kilograms of burnt lime. The proportion of salts, contained in the boiling solution is, on an average, thirty-seven per cent. sulphate of soda, eight per cent. carbonate of soda, twenty-four per cent. soda hydrate, twenty-eight per cent. sodium sulphide, three per cent. diverse combinations. This composition is very varying according to the qualities of the materials to be boiled.

The transfer from the soda-hydrate treatment to the described treatment with sulphate is accomplished in the preparation of the lye by replacing the losses of soda hydrate by the sulphate instead of by soda, and then with the disappearing of the hydrate gradually reducing the addition of lime during the boiling of the solution from forty-five per cent. to from about twenty to twenty-three per cent.

What I claim as new, and desire to secure by Letters Patent, is—

1. The process of producing cellulose from wood or other vegetable matters by boiling the same under pressure in a watery or hydrated solution containing sulphate of soda, carbonate of soda, soda hydrate, and sodium sulphide, substantially as set forth.

2. The process of treating sulphate of lime and the salts regained from the resultant material in the production of cellulose by boiling the same with lime, substantially as and for the purpose set forth.

In testimony whereof I have signed my name to this specification in the presence of two subscribing witnesses.

CARL FERDINAND DAHL.

Witnesses:

EMIL BEHNKE,

CARL WM. LOAHN.

ANEXO 2

Terminologia do Processo Kraft

A2.1 AA – Álcali Ativo: Solução de NaOH e Na_2S (componentes químicos ativos do cozimento). Pode ser expresso em g/l de Na_2O ou NaOH (*).

A2.2 AE – Álcali Efetivo: Expressão dos componentes químicos efetivos da solução de cozimento Kraft. Expresso como as concentrações de(NaOH + ½ Na_2S) como resultado da reação de hidrólise do Sulfeto em solução aquosa :

$$Na_2S + H_2O \rightarrow NaOH + NaSH.$$

Isto é, apenas metade do quantitativo molar de sódio proveniente do Na_2S é convertido em NaOH. Por este motivo, o álcali efetivo é usado nos cálculos de carga alcalina do digestor. Pode ser expresso em g/l de Na_2O ou NaOH (*).

A2.3 AT - Álcali Total: Total dos compostos de sódio no sistema de cozimento e recuperação química. Constituído de NaOH + Na_2S + Na_2CO_3 + Na_2SO_4 + Na_2SO_3. Não inclui NaCl. Pode ser expresso em g/l de Na_2O ou NaOH (*).

A2.4 Carboidratos: São as substâncias sintetizadas pelos organismos vivos, de função mista poliálcool-aldeído ou poliálcool-cetona. Para a indústria de celulose e papel, são constituídos pela celulose e hemi-celulose.

A2.5 Carga alcalina: É o número percentual que expressa a quantidade de álcali adicionado ao digestor, em percentagem do peso de madeira. Pode ser expressa por AA ou AE. Em números amplos, tem um range de 15 a 20 % para folhosas (kappa ~17) e 20 a 25% para coníferas (kappa ~30), quando expresso como NaOH, em AE. Se a carga for insuficiente, o pH fica inadequado, gerando a reprecipitação da lignina, ficando muito difícil de ser removida no branqueamento. Por outro lado, se a carga for muito alta, ocorre elevação dos custos de químicos do cozimento, maior degradação da celulose (perda de viscosidade e rendimento).

A2.6 Celulose: Polissaricarídeo constituído por unidades monoméricas de β-D-glucose, que ligam entre si através dos carbonos 1 e 4, dando origem a um polímero linear. O prefixo β, refere-se formação de outro carbono quiral na molécula de glucose. Nos casos de monossacarídeos aldeídicos com 5 e 6 átomos de carbono, o grupo aldeídico do carbono 1, pode reagir com o grupo alcoólico do carbono 5, formando um anel estável de seis átomos. Este carbono 1 fica quiral e forma dois isômeros. A forma que contém o grupo glicosídico do mesmo lado do plano do anel que o grupo alcoólico do carbono 2 é denominada α**.** A que tem o grupo glicosídico do lado oposto, é chamado de forma β. Já

o prefixo D, refere-se à atividade óptica. Substâncias opticamente ativas são as que apresentam quirilidade (propriedade de girar o plano de vibração da luz polarizada).

A.2.7 Densidade Aparente: Em engenharia e na indústria química, designa o quociente entre a massa de determinado sólido granulado em relação ao volume total ocupado (incluindo os espaços “vazios" preenchidos por ar ou outro fluido). É também chamada massa específica aparente.

A.2.8 Densidade Básica: Razão entre a massa de um sólido e o volume ocupado por este sem espaços vazios.

A2.9 Hemiceluloses: Mistura de polissacarídeos ramificados. São apresentados exemplos dos constituintes monoméricos na Figura A2.1 (d’ALMEIDA, 2013):

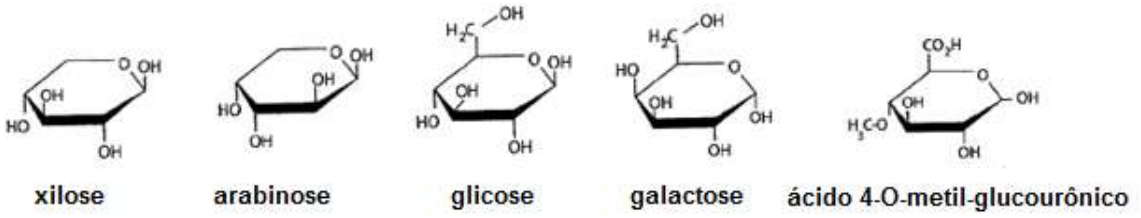


Figura A2.1 - Exemplos de unidades monoméricas das hemiceluloses

As hemiceluloses são degradadas mais facilmente que a celulose, devido à maior acessibilidade topo química (ramificação) e menor grau de polimerização, possuindo menor estabilidade química e térmica do que a celulose. Nas folhosas predominam as glicouranoxilanas, e nas coníferas predominam as galactoglicomananas, cujo segmento de estruturas estão apresentadas nas Figuras A2.2 e A2.3 respectivamente (d’ALMEIDA, 2013). :

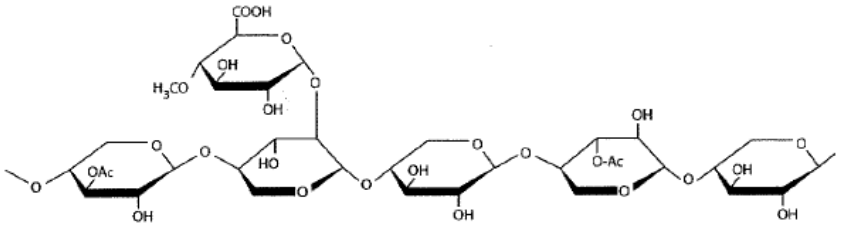


Figura A2.2 - Segmento da estrutura da hemicelulose o-acetil-4-o-metilglicouranoxilana

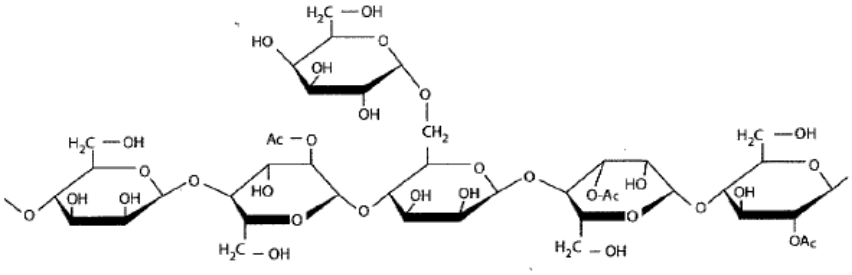


Figura A2.3 - Segmento da estrutura da hemicelulose o-acetil-galactoglicomanana

A2.10 Licor Branco: Licor de cozimento, constituído de solução química de NaOH e Na_2S.

A2.11 Licor Verde: Licor resultante das reações de redução da caldeira de recuperação química. Constituído de solução química de Na_2CO_3 e Na_2SO_4. É a matéria prima para processamento na caustificação visando gerar o Licor Branco.

A2.12 Licor Negro: Fase líquida resultante do processo de cozimento. Conforme sua concentração de sólidos é denominado licor negro diluído (<10%) resultante da lavagem UKP, licor negro fraco (< 20 %) antes de evaporado, licor negro forte (> 50 %) após evaporado.

A2.13 Lignina: Palavra originada do latim *"lignun"*, que significa madeira. É o segundo polímero mais abundante do reino vegetal, logo após a celulose. Substância química que confere rigidez à parede celular da madeira, gerando uma estrutura resistente ao impacto, compressão e dobra.

A2.14 Madeira *Softwood*: Termo genérico utilizado para as madeiras coníferas (de baixa densidade ou de fibra longa).

A2.15 Madeira *Hardwood*: Termo genérico utilizado para as madeiras de folhosas (de alta densidade ou de fibra curta). Biologicamente são as denominadas *angiospérmicas* (plantas que produzem sementes com algum tipo de cobertura).

A2.16 Número kappa: Termo utilizado para definir o grau de deslignificação de uma polpa. A medida é realizada através de uma reação de oxidação com permanganato de potássio ($KMnO_4$), que fornece a quantidade de material oxidável em uma amostra. Sabe-se que o número expressa o teor de lignina residual e também de compostos não cromóforos (ácidos hexenurônicos por exemplo).

A2.17 Smelt: Sais inorgânicos fundidos no processo de combustão da caldeira de recuperação química.

A2.18 Sulfidez: Razão entre as concentrações de Na_2S e Álcali Ativo (na grande maioria dos casos).

$$\% S = Na_2S / (AA)$$

Em algumas situações, expressa a razão entre as concentrações Na_2S e Álcali Total. Ainda em casos raros, é expressa em termos de álcali efetivo:

$$\% S = ½ Na_2S / (AE)$$

Em todas as situações, é expressa em percentual, como base em NaOH ou Na_2O. (*).

A2.19 Tonelada seca ao ar (tSA): Unidade comercial para produção de celulose. Massa de produto com equivalência a 10 % de água. Isto é, 1 tSA de celulose é equivalente a 900 kg de massa seca. A referência é indicada como tal, devido à higroscopia da celulose que adquire umidade natural quando exposta em ambiente atmosférica de aproximadamente 10 %. Naturalmente, o índice 10 % é de referência, visto que o valor efetivo em que ocorre o equilíbrio entre a umidade da celulose e a umidade atmosférica, depende da umidade relativa do ar.

(*) Terminologia NaOH , Na_2O : Os compostos inorgânicos de álcali e sulfidez, podem ser expressos como óxido de sódio ou hidróxido de sódio. De uma forma geral, as indústrias da América do Norte expressam em termos de Na_2O, e da Escandinávia em termos de NaOH. Já as fábricas da América do Sul, não possuem uma homogeneidade de expressão.

A seleção do Na_2O das fábricas norte americanas foi estabelecido de modo arbitrário e permanece em uso por longos anos de utilização. O Na_2O só existe em condições anidras muito rigorosas, e não está presente nas condições de polpação. Tem reação instantânea com água formando o hidróxido de sódio :

$$Na_2O + H_2O \rightarrow 2\ NaOH$$

Para os compostos de enxofre:

$$Na_2O + H_2S \leftrightarrows Na_2S + H_2O$$

Pelas equações químicas acima, pode-se fazer a conversão de Na_2O para NaOH, multiplicando pelo fator 1,290, e conversão para Na_2S multiplicando pelo fator 1,258. Importante cuidados especiais ao se comparar unidades em termos de qual álcali está expresso (ativo, efetivo, total) e a qual base do componente de sódio (Na_2O, NaOH), quanto à exatidão da expressão das unidades.

Anexo 3

Alguns Conceitos Estatísticos

A3.1. Correlograma

Ferramenta usada para identificar caracterítısticas da série temporal. É um gráfico com as informações da função de autocorrelação e autocorrelação parcial, com o *plot* de r (k) *versus* k. A análise das funções FAC e FACP no correlograma permite identificar a estacionariedade da série, bem como facilita a identificação do modelo ARMA.

Para o processo estacionário AR(p), a FAC empírica de uma série temporal amortece para zero. Já a FACP se anula para todas as defasagens maiores do que p, isto é, o seu gráfico apresenta um "corte" após a defasagem p. Já num processo estacionário MA(q), os q primeiros coeficientes da FAC são diferentes de zero, e os restantes iguais a zero. Os coeficientes da FACP são dominados por uma mistura de exponenciais e/ou senóides amortecidas. Por fim, a FACP de um processo ARMA(p,q) comporta-se de maneira similar à FACP de um processo MA puro. O quadro a seguir, apresenta um resumo das características das FAC e FACP para os modelos AR(p), MA(q) e ARMA(p,q) :

Quadro A3.1 : Padrões teóricos de FAC e FACP (GUJARATI,2004)

Tipo de Modelo	FAC : Padrão típico	FACP : Padrão típico
AR (p)	Decai exponencialmente para zero ou com padrão de onda senoidal amortecida, ou ambos.	Valores significativos (não nulos) até defasagem p
MA (q)	Valores significativos (não nulos) até defasagem q	Decai exponencialmente para zero
ARMA (p, q)	Decai exponencialmente para zero	Decai exponencialmente para zero

Tanto a FAC como FACP auxiliam na análise de séries temporais, como uma importante ferramenta para a investigação das propriedades empíricas da série, identificação da condição de estacionariedade e identificação de modelos potenciais a serem utilizados na modelagem e previsão.

A3.2. Critérios para Seleção dos Modelos de Previsão

São indicadas a seguir os principais índices estatísticos usados para avaliação dos erros de previsão, sendo todas as equações expressas como :

$Y_t =$ Valores observados (reais)no tempo t ;
$\hat{Y}_t =$ Valores estimados no tempo t ;
$n = número\ de\ dados$;

Em todos os critérios indicados, com exceção do índice Durbin Watson, os melhores modelos são os de menores índices. DW deve ser o mais próximo possível do número 2.

- **MAD (*Mean Absolute Deviation*): Desvio Absoluto Médio**

Este índice avalia o erro de previsão a partir do cálculo do erro absoluto médio. Uma das vantagens é que evita-se o problema de um erro negativo cancelar o positivo, pois são calculados em módulo. É calculado pela equação :

$$MAD = \frac{\sum_{t=1}^{n} |Y_t - \hat{Y}_t|}{n} \qquad \text{(A3.1)}$$

- **MAPE (*Mean Absolute Percentual Error*) : Erro Absoluto Percentual Médio**

Avalia a magnitude do módulo do erro percentual. É calculado pela equação :

$$MAPE = \frac{\sum_{t=1}^{n} \frac{|Y_t - \hat{Y}_t|}{Y_t}}{n} \qquad \text{(A3.2)}$$

- **MPE (*Mean Percentual Error*) : Erro Percentual Médio**

É um índice que mede se os valores estimados estão sistematicamente acima ou abaixo dos reais. Se positivo, os valores estimados estão freqüentemente abaixo do real, e se negativo, os valores estimados estão freqüentemente acima do real. É calculado pela equação :

$$MPE = \frac{\sum_{t=1}^{n} \frac{(Y_t - \hat{Y}_t)}{Y_t}}{n} \qquad \text{(A3.3)}$$

- **RMSE (*Rooted Mean Squared Error*) : Raiz do Erro quadrado médio**

É um índice complementar dos testes de avaliação estatística. Tem a propriedade de dar significância aos dados discrepantes (que se destacam devido ao cálculo da média ao quadrado), isto é, valores muito distantes da média (ainda que pouco freqüentes) elevam significativamente o índice. É expresso pela Equação A3.4:

$$RMSE = \sqrt{\frac{\sum_{t=1}^{n}(Y_t - \hat{Y}_t)^2}{n}} \quad \text{(A3.4)}$$

- **AIC (*Akaike Information Criterion*) : Critério de Informação de Akaike**

O Critério de Informação de Akaike é uma medida geral da qualidade de ajustamento de modelos. Esse índice avalia, em um grupo de possíveis modelos, a distância relativa entre o modelo proposto e o modelo "verdadeiro", ou seja, a discrepância no ajuste do modelo em relação aos dados. Para isso, são calculados os logaritmos das razões de verossimilhança entre os modelos, penalizando os modelos pelo número de parâmetros. O AIC avalia a qualidade da ligação entre as variáveis e o número de variáveis utilizadas. O modelo com menor AIC será o melhor, pois é capaz de explicar mais o fenômeno em estudo com um número menor de parâmetros. Por este critério, escolhe-se como melhor modelo, aquele cujas ordens p e q minimizam o Critério de Akaike normalizado. Na comparação de diversos modelos, com n fixo, o critério de Akaike é expresso conforme Equação A3.5:

$$AIC = N \log \hat{\sigma}_a^2 + 2(k + l + 1) \quad \text{(A3.5)}$$

Em que $\hat{\sigma}_a^2$ é o estimador de máxima verossimilhança de $\hat{\sigma}_a^2, 0 \leq k \leq p \; e \; 0 \leq l \leq q$.

k e l correspondem ao número de parâmetros que minizam o critério, independente do modelo ser completo ou incompleto. Entre os vários modelos propostos, deve-se escolher O AIC de menor valor.

- **BSC *(Bayesian Schwarz Criterion)* : Critério Bayesiano de Schwarz**

O critério bayesiano de de Schwarz (BSC) , é um critério para a comparação de modelos, proposto por Schwarz (1978). É definido conforme Equação A3.6:

$$BSC = -2 \log f\ (x_n \ \mathrm{I}\ \hat{\theta}\ ) + \mathrm{p} \log\ (n) \quad \text{(A3.6)}$$

Em que $f(x_n \,\mathrm{I}\, \ddot{\theta})$ é o modelo selecionado para o cálculo, p é o número de parâmetros a serem estimados e n é o número de observações da amostra.

A diferença principal entre AIC e BSC é o quanto severamente cada critério penaliza o modelo quanto ao aumento da ordem do mesmo. A penalização para o número de parâmetros no modelo é maior no BSC do que em AIC. De modo semelhante ao AIC, menores valores de BSC indicam os modelos a serem preferidos.

- **DW Índice Durbin Watson**

A estatística DW é usada para testar a presença de autocorrelação em resíduos. Autocorrelação significa que observações adjacentes são correlacionadas. Quando essas observações são correlacionadas, a regressão de MQO subestima o erro padrão dos coeficientes e os preditores podem parecer significantes quando na verdade não o são. A estatística Durbin-Watson determina se a correlação entre termos de erro adjacentes é zero. A estatística do teste de Durbin-Watson é dada pela fração entre diferença (ao quadrado) entre os resíduos em instantes sucessivos, e a soma do quadrado destes resíduos, conforme Equação A3.7:

$$DW = \frac{\sum_{t=2}^{n}(e_t - e_{t-1})^2}{\sum_{t=1}^{n} {e_t}^2} \tag{A3.7}$$

em que :

e_i = Erro estimado no instante t ; $0 \leq DW \leq 4$.

Como regra geral, a estatística DW é aproximadamente igual a $2(1-\hat{\rho})$, em que $\hat{\rho}$ é o coeficiente de correlação amostral entre os resíduos. Se DW=2, não há evidência de autocorrelação entre os resíduos. Como regra empírica, se DW < 1 ou DW > 3, é um indicador de problemas de autocorrelação positiva ou negativa dos resíduos respectivamente.

- **TIC (*Theil Inequality Coeficient*) : Coeficiente de Desigualdade de Theil**

É um índice complementar aos já indicados. Avalia o ajustamento da série prevista à série original. Este coeficiente está limitado ao intervalo [0,1]. Quanto mais próximo de zero, maior é o ajustamento da série prevista em relação a série original. Em contrapartida, valores mais próximos de um indicam que o modelo não conseguiu fazer boas previsões. O índice Theil é definido conforme Equação A3.8:

$$TIC = \frac{\sqrt{\frac{1}{n}\sum_{t=1}^{n}\left(\hat{Y}_t - Y_t\right)^2}}{\sqrt{\frac{1}{n}\sum_{t=1}^{n}\left(\hat{Y}_t\right)^2} + \sqrt{\frac{1}{n}\sum_{t=1}^{n}\left(Y_t\right)^2}} \tag{A3.8}$$

Pode ser decomposto em três proporções:

-BP : ***Bias Proportion*** ou Proporção do Viés , que informa o quão distante está a média da série estimada da média real. Esta proporção, BP, é um indicador do erro sistemático, sendo calculada por:

$$BP = \frac{(\overline{\hat{Y}_t} - \overline{Y})}{\frac{1}{n}\sum_{t=1}^{n}\left(\hat{Y}_n(t) - Y_n + t\right)^2} \quad \text{(A3.9)}$$

-VP : ***Variance Proportion*** ou Proporção da Variância que fornece a informação sobre a distância entre a variância da previsão e a variância real. Indica a capacidade do modelo de repetir a variabilidade da variável de interesse. É calculada por :

$$VP = \frac{(S_{\hat{Y}} - S_Y)^2}{\frac{1}{n}\sum_{t=1}^{n}(\hat{Y}_n^2(t) - Y_{n+t})^2} \quad \text{(A3.10)}$$

Em que $S_{\hat{Y}}$ e S_Y são os desvios padrões de $\hat{Y}$ e Y respectivamente.

-CP : ***Covariance Proportion*** ou Proporção da Covariância que mede os erros de previsão, restantes, não previstos no modelo, ou seja, o erro resultante depois de serem levados em consideração os desvios dos valores médios, sendo calculada por:

$$CP = \frac{2(1-r)S_{\hat{Y}}S_Y}{\frac{1}{n}\sum_{t=1}^{n}(\hat{Y}_n^2(t) - Y_{n+t})^2} \quad \text{(A3.11)}$$

Em que $S_{\hat{Y}}$ e S_Y são os desvios padrões de $\hat{Y}$ e Y respectivamente e ***r*** é o coeficiente de correlação entre de $\hat{Y}$ e Y. Nas situações onde as proporções BP e/ou VP são elevadas é um indício de que é necessário rever o modelo usado para a previsão.

Para qualquer valor de *TIC* > 0, a distribuição ideal das proporções deve ser

BP ≈VP ≈ 0 e CV ≈ 1. Nas situações em que BP e VP são pequenas, a proporção CV será a responsável pela grande parte da explicação do TIC.

A3.3. Método Stepwise

Qualquer procedimento para seleção ou exclusão de variáveis de um modelo é baseado em um algoritmo que checa a importância das mesmas, incluindo ou excluindo-as do modelo se baseando em uma regra de decisão. O critério para a adição ou remoção de variáveis é geralmente baseado na estatística F, comparando modelos com e sem as variáveis em questão para a decisão de inseri-las ou removê-las. Existem três métodos mais frequentes, f*orward*, *backward* e *stepwise*.

O método *forward* é um procedimento que parte da suposição de que não há variável no modelo, apenas o intercepto, sendo adicionado uma variável de cada vez. A variável

entra no modelo se a estatística F for maior do que o ponto crítico, chamado de F_{in} ou $F_{entrada}$. O processo é repetido recursivamente, até que não seja incluída mais nenhuma variável explicativa no modelo.

O método *backward* incorpora inicialmente todas as variáveis e depois, por etapas, cada uma pode ou não ser eliminada, conforme estatística F. O algoritmo de eliminação termina quando a menor estatística F parcial não for menor do que F_{out}.

Já o método *stepwise* é uma associação dos métodos *forward* e *backward*. Sua operacionalização ocorre através da sistemática adição ou remoção de variáveis no modelo de regressão, realizada com base em um teste estatístico de significância de cada variável. Inicia-se com uma variável (aquela que tiver maior correlação com a variável resposta) e a cada passo do *forward*, depois de incluir uma variável, aplica-se o *backward* para ver se alguma será descartada. Continua-se o processo até não incluir ou excluir nenhuma variável. Portanto, a regressão *stepwise* requer dois valores de corte, F_{in} e $F_{out.}$ É comum a escolha F_{in} e F_{out} com o mesmo valor, mas não é necessário.

A3.4. Ruído branco

Processo que ocorre quando a série não depende do seu passado, e todas autocorrelações são nulas. Caracteriza-se por variável aleatória independente e identicamente distribuída. Dá-se o nome de "ruído branco" a esse processo pelo fato de sua representação espectral ser bastante similar ao espectro físico da luz branca.

Considerando que a Esperança E [x] denota a média teórica do valor de *x*, a sequência ε_t é considerada um processo ruído branco se para cada período de tempo *t* tivermos:

(i) $E\left[\varepsilon_t\right] = E\left[\varepsilon_{t-1}\right] = \cdots = 0$, média zero;

(ii) $E\left[\varepsilon_t^2\right] = E\left[\varepsilon_{t-1}^2\right] = \cdots = \sigma^2$, variância constante;

(iii) $E\left[\varepsilon_t.\varepsilon_{t-s}\right] = \ = E\left[\varepsilon_{t-j}.\varepsilon_{t-j-s}\right] = \cdots = 0$, covariância nula para todo valor de *s*.

O processo estocástico ruído branco é o processo cujas variáveis aleatórias componentes são independentes e identicamente distribuídas.

Anexo 4

Publicações Associadas à Tese

Artigos :

- CORREIA, F.M.; d'ANGELO, J.V.H.; ZEMP, R.J. ; MINGOTI, S.A. (2014) **Prediction of Kappa Number in Eucalyptus Kraft Pulp Continuous Digester Using the Box & Jenkins Methodology**. *Advances in Chemical Engineering and Science*, 4, 539-547. http://dx.doi.org/10.4236/aces.2014.44055

- CORREIA, F.M.; d'ANGELO, J.V.H.; MINGOTI, S.A. (2015) **A novel approach to white liquor control in a continuous digester using the Box-Jenkins methodology to predict chip bulk density**. *TAPPI Journal*, V 14, 6, 395-402. http://www.tappi.org/Bookstore/Technical-Papers/Journal-Articles/TAPPI-JOURNAL/Archives/2015/June/Table-of-Contents/15jun395.aspx

Trabalhos Apresentados em Congressos:

- CORREIA, F.M.; d'ANGELO, J.V.H.; MINGOTI, S.A. (2014) **Predição do Número Kappa de um Digestor Contínuo de Celulose Kraft usando Análise de Regressão Múltipla.** *In:* Anais do XX Congresso Brasileiro de Engenharia Química - COBEQ 2014 , Blucher Chemical Engineering Proceedings, v.1, n.2, p. 11845-11852 . São Paulo: Blucher. ISSN 2359-1757 DOI: 10.5151/chemeng-cobeq2014-0928-22370-148607

- CORREIA, F.M.; ALMEIDA, G. M. ; d'ANGELO, J.V.H.; MINGOTI, S.A. (2015) **A Neural Network Approach for Kappa Number Prediction in Eucalyptus Kraft Pulp Continuous Digester.** *In:* 7th International Colloquium on Eucalyptus Pulp, Proceedings, Vitória, Brasil.