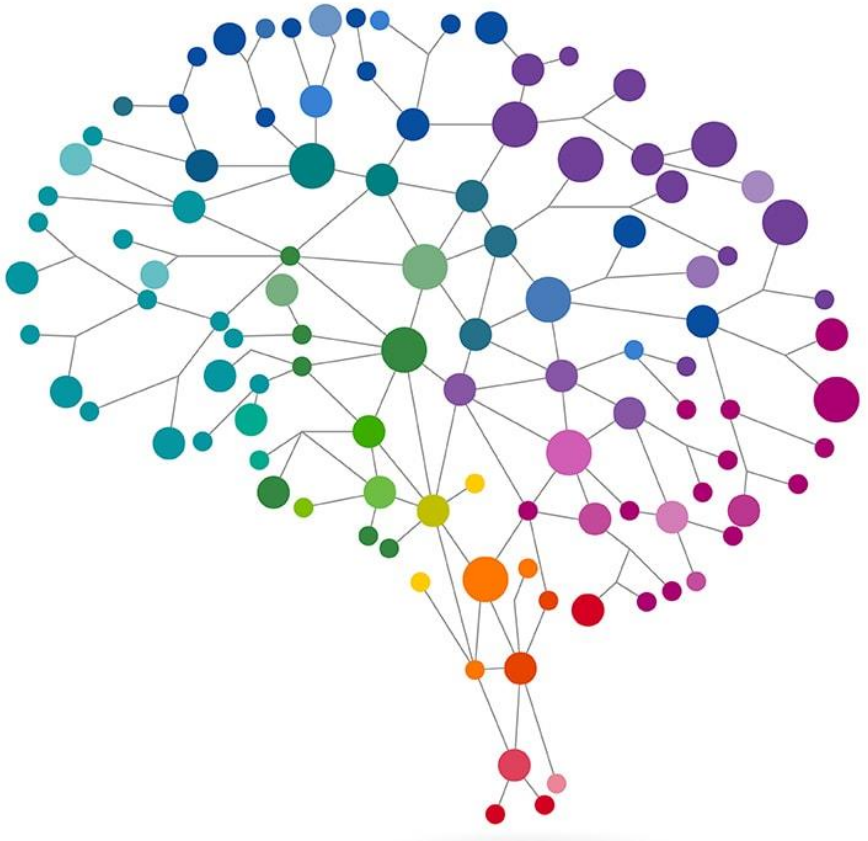
Aprendizado de Máquina





Classroom code tg44fjf

Prof. Rodrigo Caropreso
Nov/2018
rcaropreso at gmail

Conteúdo Programático – Aulas 1 e 2

Introdução

- Conceitos Gerais em Aprendizado de Máquina
- Tipos de Aprendizado: Supervisionado, Semi-Supervisionado, Não-Supervisionado;
- Aprendizado por Reforço.

Computação Evolutiva e Inteligência Coletiva

- Algoritmos Genéticos;
- Otimização por Enxame de Partículas (PSO).

Redes Neurais Artificiais – Parte 1

- Algoritmo de Descida de Gradiente
- Perceptron Simples, Adaline;
- Lei de Aprendizado de Hebb;
- Regra Delta.

Conteúdo Programático – Aulas 3 e 4

Redes Neurais Artificiais – Parte 2

- Clusterização e K-Means;
- Classificação e K-NN;
- Redes de Base Radial;

Análise Estatística

- Problemas de Classificação e Regressão;
- Regressão Linear e Logística;
- Parâmetros de Regularização;
- Naive Bayes.



Métodos de Clusterização e K-Means

Fonte: https://simonsfoundation.imgix.net/wp-content/uploads/2018/04/20113349/Protocluster-Illustration.png?auto=format&w=1020&q=90

Clusterização: Conceitos



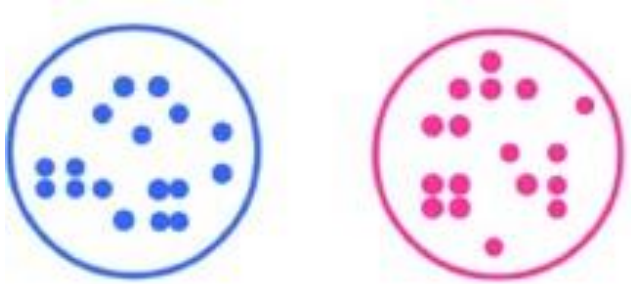
- são utilizados caracterizar os dados como membros de grupos.
- os grupos devem “fazer sentido”.
- em alguns casos “representantes” dos grupos passam a ser **arquétipos** dos dados.
- em processos automáticos: pertencer a um grupo é uma forma de classificar o dado e essa classe é usada nos processamentos seguintes.

Clusterização: Tipos de algoritmos



- **Baseado em centroides**: descobrir o “centro” de cada grupo**,** onde cada ponto pertence ao grupo (grupos) cujo centro é mais proximo(s).
- **Baseado em conectividade:** pontos e sub-grupos perto um dos outros devem pertencer ao mesmo super-grupo;
- **Baseado em densidade:** grupos são regiões de alta densidade de pontos separados por regiões de baixa densidade;
- **Baseado em distribuições probabilísticas:** modela-se os dados como sendo gerado por diferentes distribuições probabilísticas (cada uma compõe um grupo).

Clusterização: Tipos de clusters





- **Grupo Exclusivo (hard cluster)**: se refere a um tipo de agrupamento onde os registros são exclusivos ,ou seja, cada registro pertence a um único grupo.

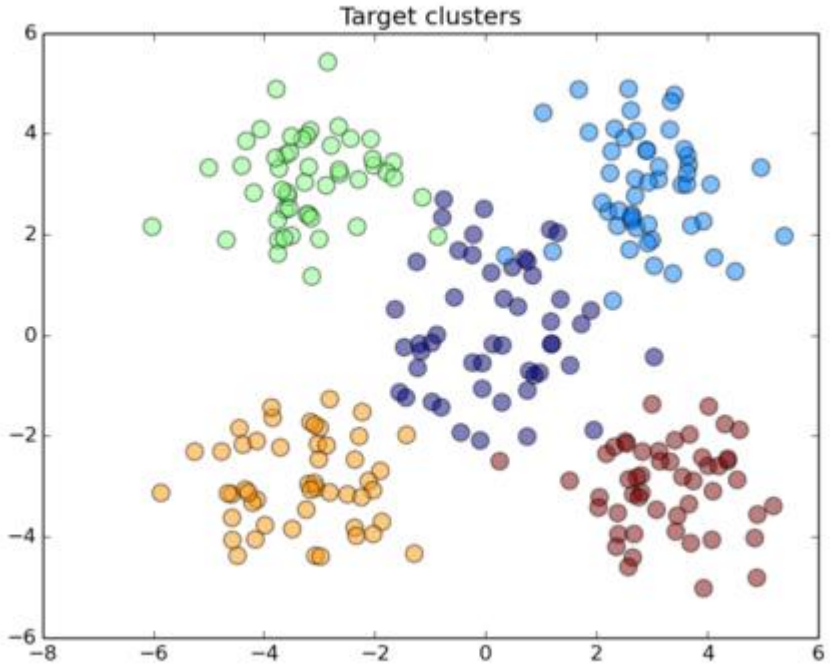
$$C_i \cap C_j = \emptyset, se\ i \neq j$$

- **Cluster Sobreposto (soft cluster):** pontos e sub-grupos perto um dos outros devem pertencer ao mesmo super-grupo.

$$C_i \cap C_j \neq \emptyset, se\ i \neq j$$

Fonte: https://www.sciencedirect.com/science/article/pii/S0957417416305097

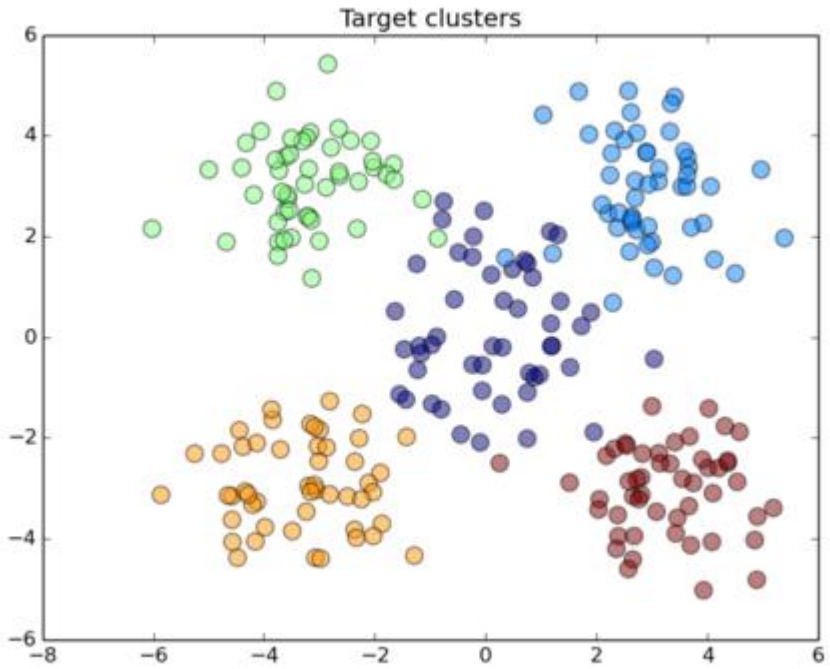
Clusterização: K-Means



Fonte: http://31.media.tumblr.com/b82e1520a5bb6390030cbdc1eda43b02/tumblr_inline_nhfsd93cWX1rnd3q0.png

- Algoritmo de clusterização bastante usado, baseado em cálculo de distância, para criação de grupos mais homogêneos.
- **k**: denota o número de clusters a serem criados em um intervalo $0 < k < N$, onde N é o número de amostras (ou observações).
- **Centróide**: é a base da criação do cluster, composta pela média das coordenadas dos pontos que pertencem ao cluster no espaço –N-dimensional.

Clusterização: K-Means



O algoritmo possui 2 etapas:

- **Atribuição**: definição dos k-centróides dos clusters, podendo ser realizada através da seleção aleatória de alguns pontos da amostra ou através da criação de pontos adicionais. Após a inicialização, cada fase de atribuição consiste em associar um ponto ao cluster cujo centróide for o mais próximo dentro do conceito de distância.

- **Atualização**: Nesta etapa, o centróide de cada cluster é recalculado a partir da média das coordenadas dos pontos que compõem o cluster.

Clusterização: K-Means

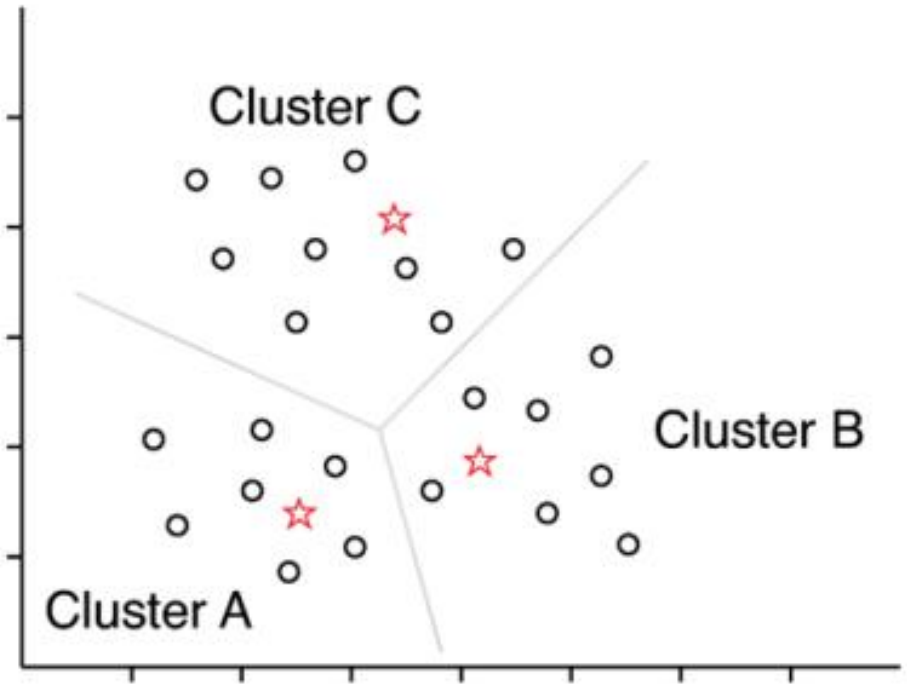
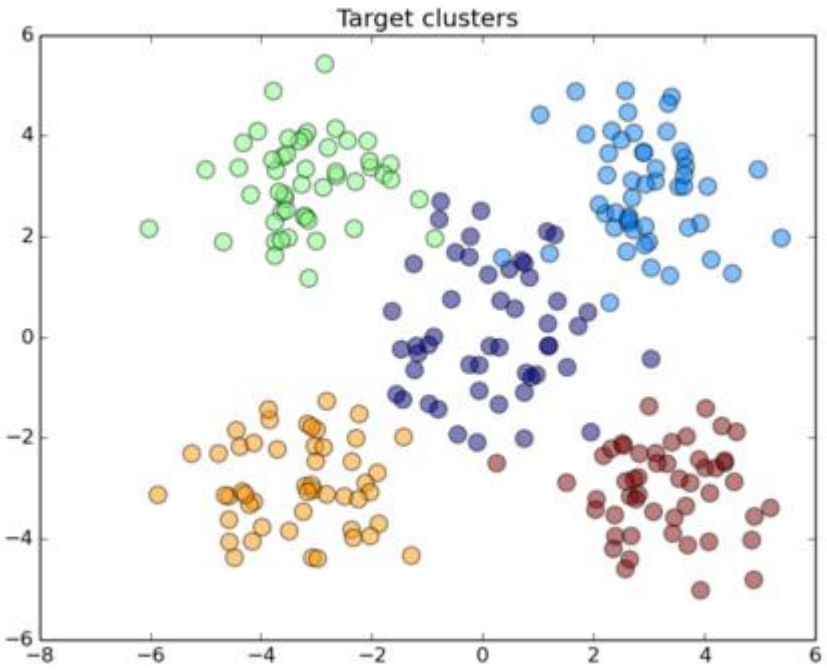


Diagrama de Voronoi: equidistâcia do ponto em relação aos centróides

- Todos os pontos devem ter o mesmo número de atributos (dimensões);
- A diferença de escala afeta o funcionamento do algoritmo, então recomenda-se a análise e normalização das dimensões dos dados.
- Pode ser utilizado z-score ou normalização max-min como ajuste de cada dimensão. Os clusters podem ser visualizados como **Diagramas de Voronoi**.

Clusterização: K-Means



Distorção de cluster:

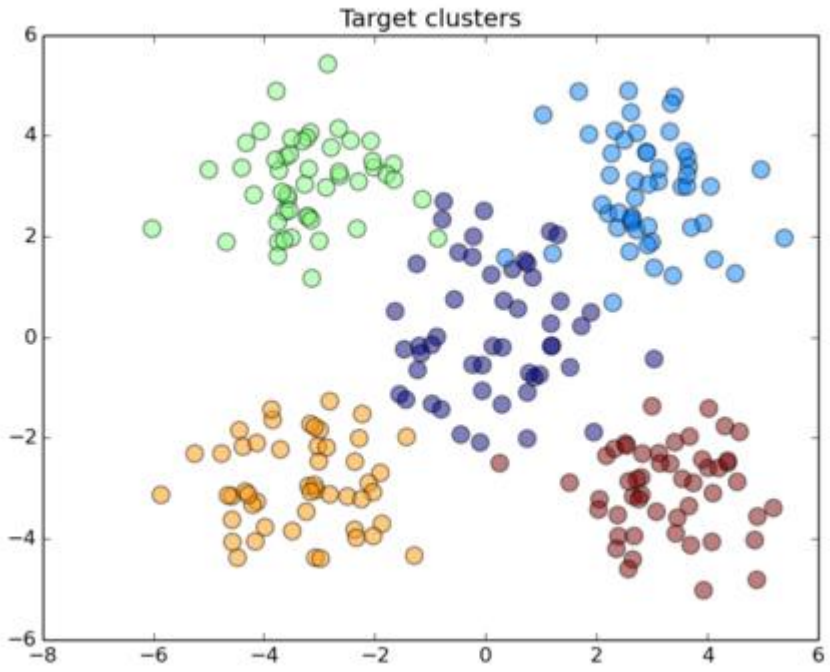
$$d = \sum_{i \in C_r} \|x_i - c_r\|^2$$

onde

- c_r é o centro de observações no cluster C_r
- $\|x_i - c_r\|^2$ é o quadrado da distância euclidiana entre x_i c_r.

- Este parâmetro mede o grau de homogeneidade de um cluster.

Clusterização: K-Means



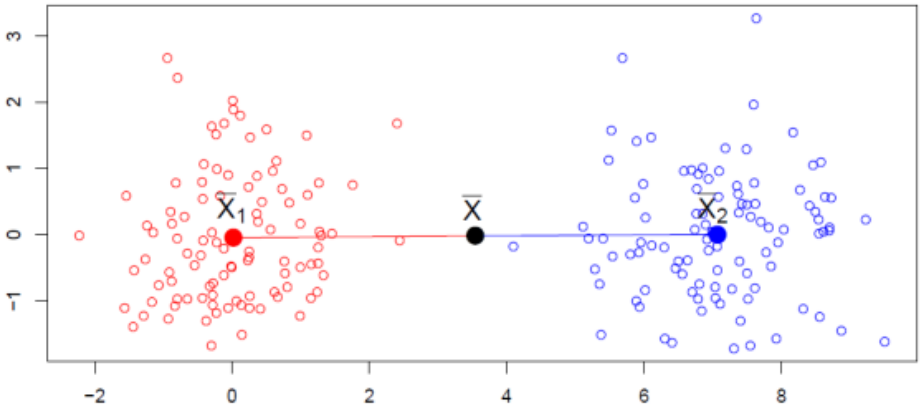
Dispersão intra-cluster:

$$W = \sum_{r=1}^{k} d_r$$

onde

- d_r é a distorção do cluster C_r
- De fato, o **k-means** fornece uma configuração de clusters que produz um mínimo local para W .
- Por este motivo, os praticantes executam o algoritmo diversas vezes com inicializações distintas para os c_r's.

Clusterização: K-Means



Exemplo com $x_i \in R^2$ n = 100 e k = 2

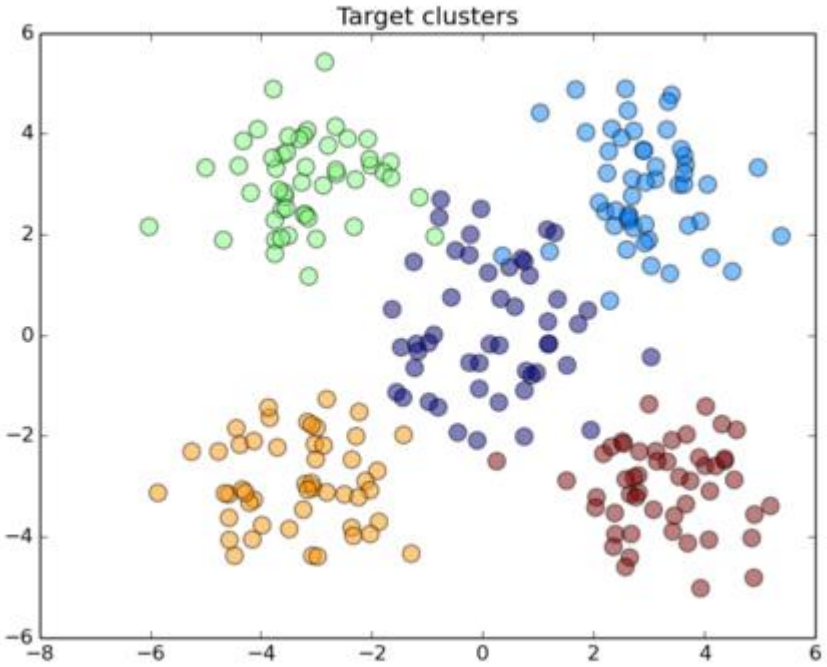
Dispersão inter-cluster:

$$B(k) = \sum_{r=1}^{k} n_r \cdot \|c_r - \bar{c}\|$$

- c_r é o centro do cluster C_r.
- $\bar{c}$ é a média de todos os pontos observados.
- n_r é o número de clusters utilizado

- Uma segunda alternativa seria escolher o k que maximiza $B(k)$.

Clusterização: K-Means



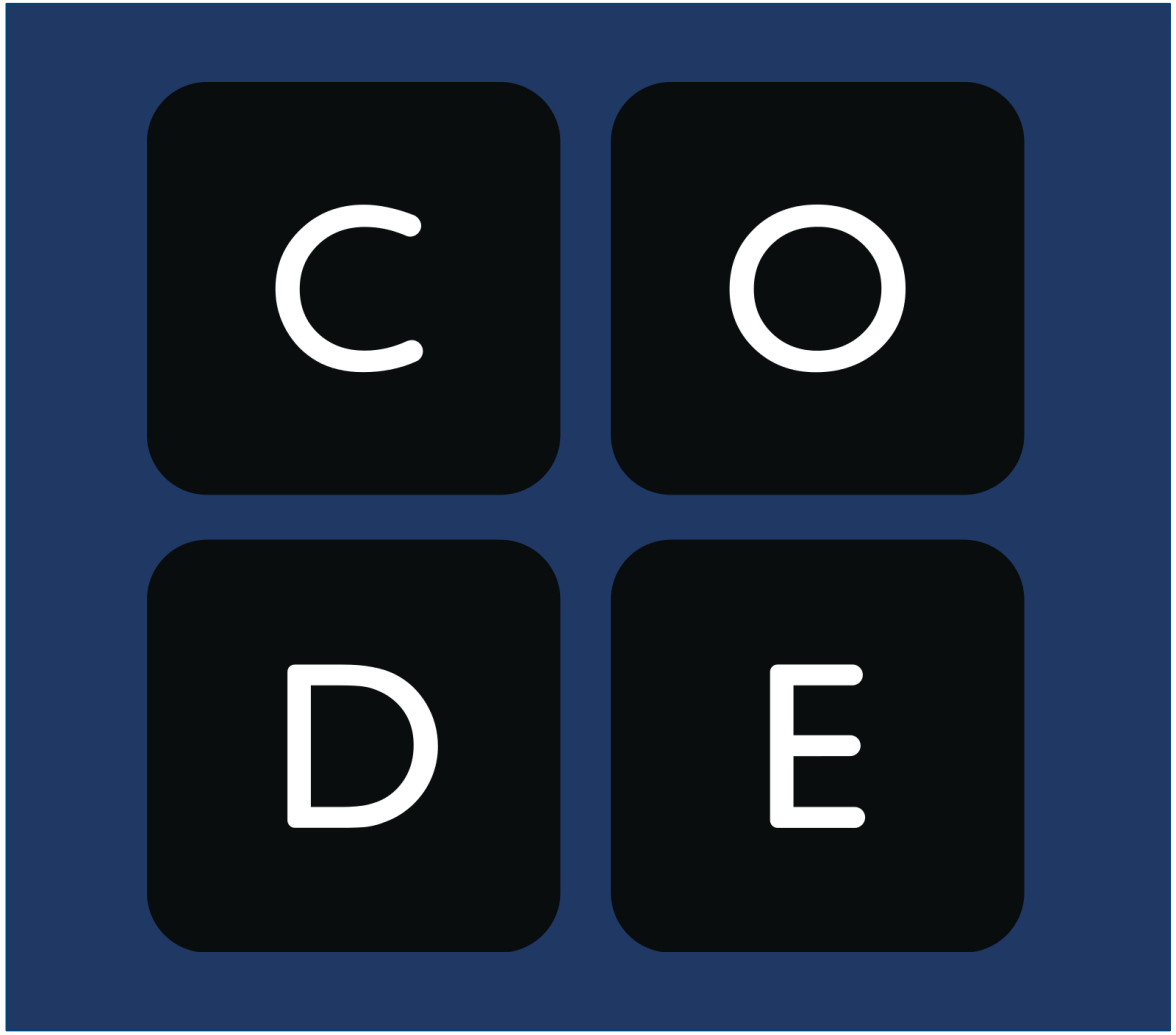
Pseudo-código do algorimo:

1. Inicializar os k-centróides do modelo
2. Enquanto (houver atribuições):
   - Efetuar fase de atribuição
   - Efetuar fase de atualização

- A medida de distância mais comum é a **Distância Euclidiana**:

$$\|x_i - x_j\| = \sqrt{\sum_{l=1}^{p} (x_{il} - x_{jl})^2}$$

Challenge Time



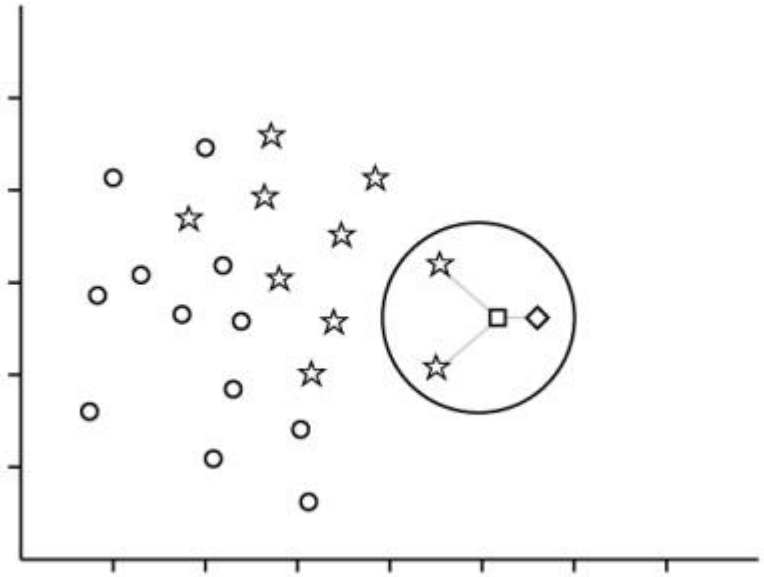


Exercício 1: Transformação de Domínios



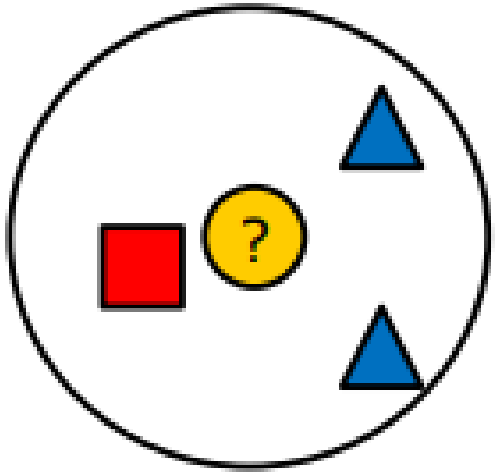
- **Utilizando Jupyter e NumPy**: Implemente, com o auxílio do professor, o algoritmo k-means.

kNN: Conceitos



- É utilizada para **Classificação**. O processo de treinamento é do tipo “Aprendizado Supervisionado”. É um processo de classificação estilo “caixa-preta”, onde um modelo não é criado pelo classificador
- As instâncias são classificadas de acordo com o seu grau de similaridade ou distância em relação a um conjunto k de exemplos, os vizinhos mais próximos
- É um dos algoritmos de classificação mais simples.
- Usado para classificar objetos com base em exemplos de treinamento que estão mais próximos no espaço de características.

kNN: Conceitos



Para utilizar o KNN é necessário:

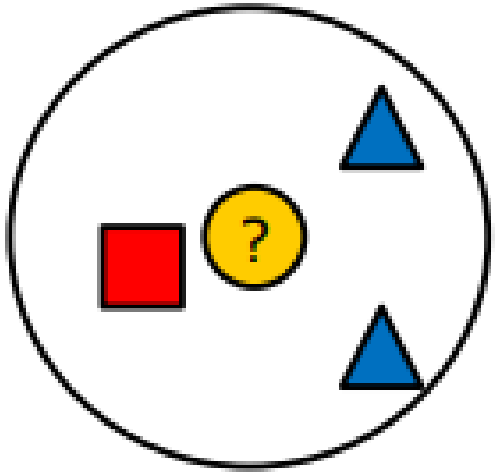
1. Um conjunto de exemplos de treinamento.

2. Definir uma métrica para calcular a distância entre os exemplos de treinamento.

3. Definir o valor de K (o número de vizinhos mais próximos que serão considerados pelo algoritmo).

Fonte: http://edirlei.3dgb.com.br/aulas/ia_2012_1/IA_Aula_16_KNN.pptx

kNN: Classificação



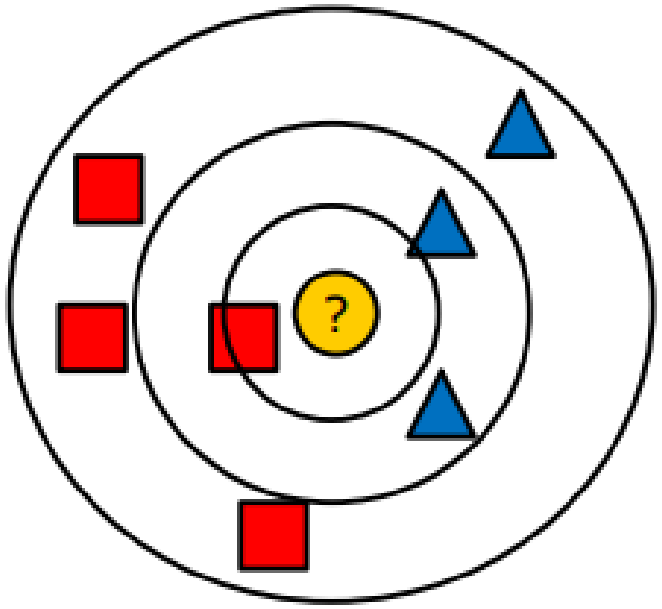
Classificar um exemplo desconhecido com o algoritmo KNN consiste em:

1. Calcular a distância entre o exemplo desconhecido e o outros exemplos do conjunto de treinamento.

2. Identificar os K vizinhos mais próximos.

3. Utilizar o rotulo da classe dos vizinhos mais próximos para determinar o rótulo de classe do exemplo desconhecido (votação majoritária).

kNN: Classificação



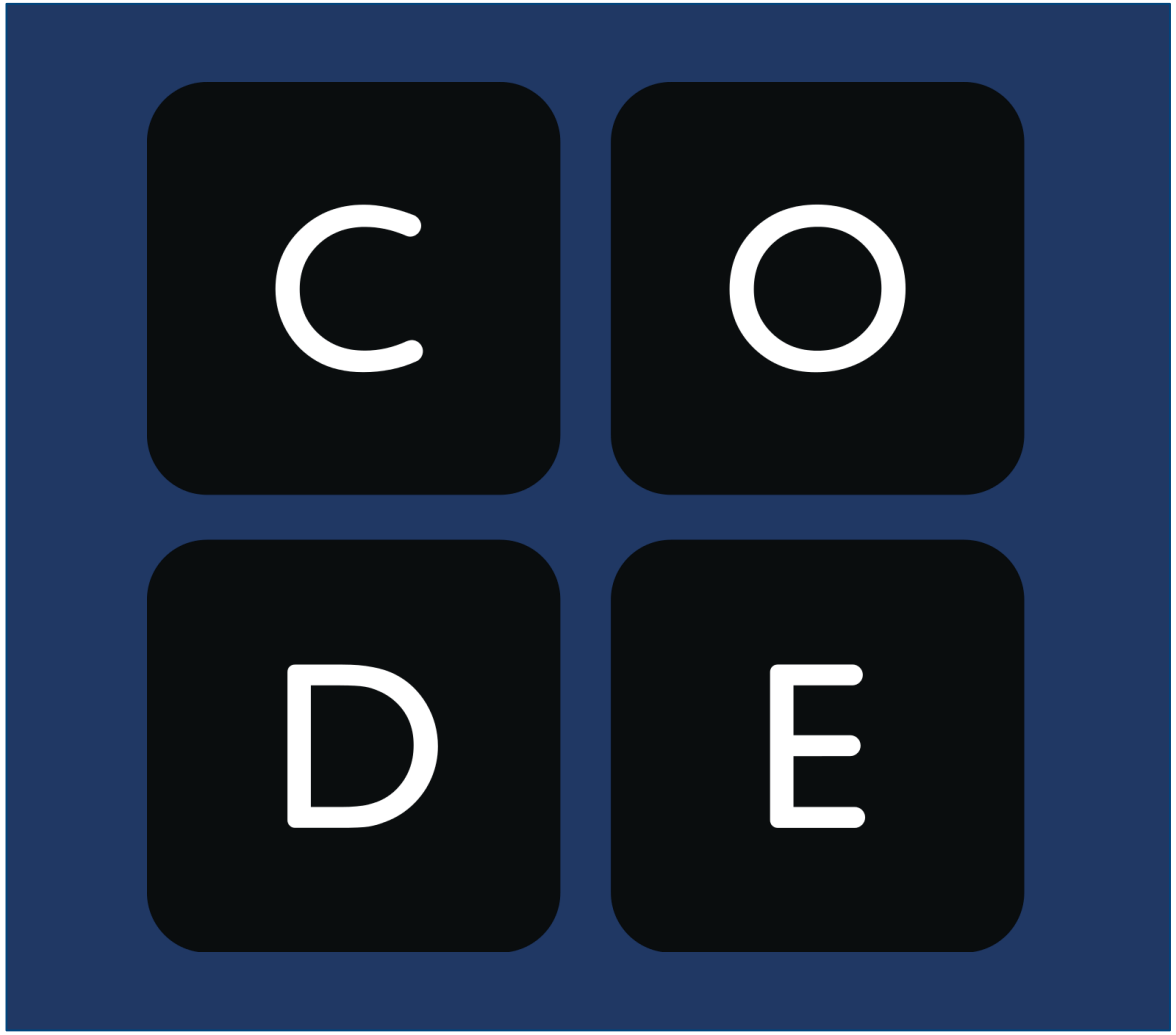
K = 1
Pertence a classe de quadrados.
K = 3
Pertence a classe de triângulos.
K = 7
Pertence a classe de quadrados.

Escolha de K:

1. O ideal é escolher um valor impar, evitando empates.
2. Valores baixos podem ser afetados por outliers.
3. Valores altos podem gerar muita interferência dos vizinhos.
4. O ideal é realizar alguns testes variando-se k.

Fonte: http://edirlei.3dgb.com.br/aulas/ia_2012_1/IA_Aula_16_KNN.pptx

Challenge Time





Exercício 1: Transformação de Domínios



- **Utilizando Jupyter e NumPy**: Implemente, com o auxílio do professor, o algoritmo k-NN.

Referências



- https://www.coursera.org/
- https://python.org.br/
- http://scikit-learn.org/stable/
- https://www.w3schools.com/python
- https://www.gnu.org/software/octave/
- https://octave-online.net/
- https://www.mathworks.com/products/matlab.html

Referências



- RUSSELL, STUART J.. Inteligência Artificial. 2ª ed. São Paulo: Campus - Elsevier, 2004.
- FERNANDES, Anita M. R.. Inteligência Artificial: noções gerais. 1ª ed. Florianópolis: Visual Books, 2008. Capítulo 1.
- SILVA, I.N. – Sistemas Inteligentes – Notas de Aula da disciplina de Sistemas Inteligentes – USP São Carlos, 2012.
- GOZALEZ, J.A.Q., ZAMPIROLLI, F.A. – Mineração de Dados e Regras de Associação. Notas de Aula da disciplina Sistemas Inteligentes. CMCC – UFABC, 2013.
- LIMA, E. S. – Material de aula da disciplina INF 1771 – Inteligência Artificial - PUC RJ Disponível em http://edirlei.3dgb.com.br/aulas/ia_2012_1/IA_Aula_16_KNN.pptx. Acesso em 29/11/2018



Facens

AQUI TEM ENGENHARIA