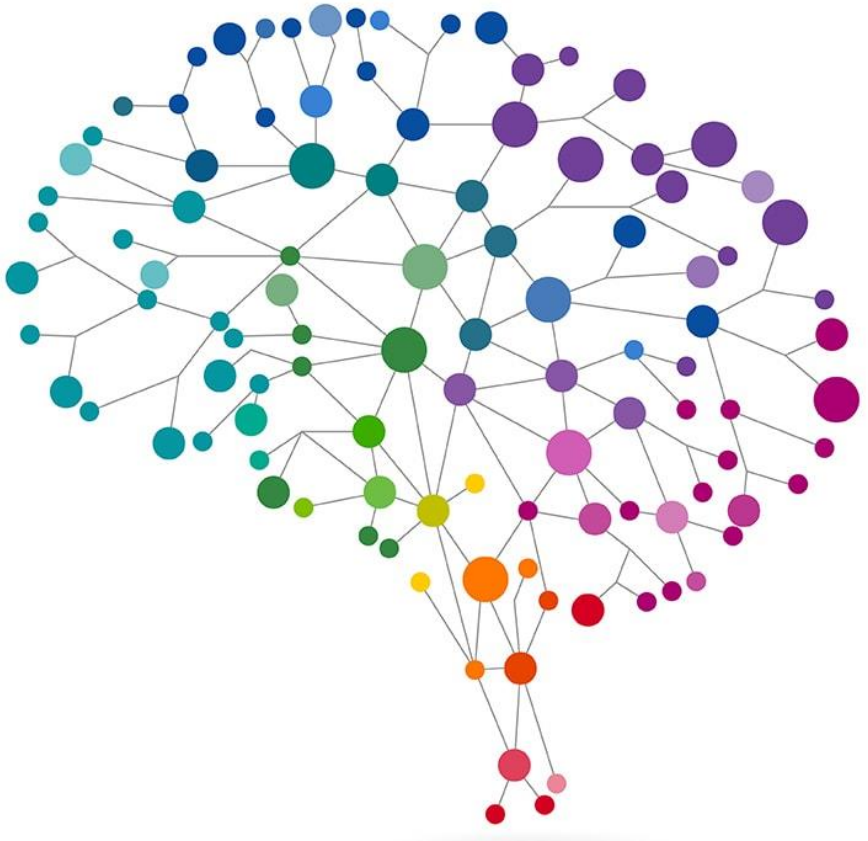
Aprendizado de Máquina





Classroom code tg44fjf

Prof. Rodrigo Caropreso
Nov/2018
rcaropreso at gmail

Conteúdo Programático – Aulas 1 e 2

Introdução

- Conceitos Gerais em Aprendizado de Máquina
- Tipos de Aprendizado: Supervisionado, Semi-Supervisionado, Não-Supervisionado;
- Aprendizado por Reforço.

Computação Evolutiva e Inteligência Coletiva

- Algoritmos Genéticos;
- Otimização por Enxame de Partículas (PSO).

Redes Neurais Artificiais – Parte 1

- Algoritmo de Descida de Gradiente
- Conceitos em Redes Neurais Artificiais (RNA);
- Perceptron Simples, Adaline;
- Lei de Aprendizado de Hebb;
- Regra Delta.

Conteúdo Programático – Aulas 3 e 4

Redes Neurais Artificiais – Parte 2

- Clusterização e K-Means;
- Classificação e K-NN;
- Redes de Base Radial;

Análise Estatística

- Problemas de Classificação e Regressão;
- Regressão Linear e Logística;
- Parâmetros de Regularização;
- Naive Bayes.



Redes de Base Radial (RBF)

Fonte: http://cdn.jornalgrandebahia.com.br/2018/01/Intelig%C3%AAncia-Artificial-IA-106-500x333.jpg

Redes de Base Radial (RBF): Conceitos



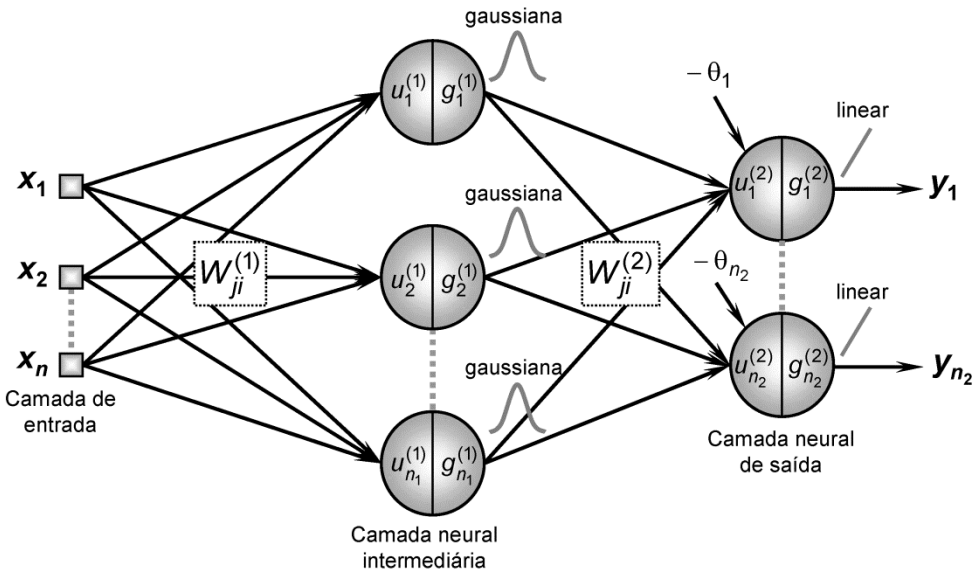
- As redes denominadas **Funções de Base Radial**, convencionalmente conhecidas como RBF (*Radial Basis Function*), são de arquitetura *feedforward* de camadas múltiplas.
- Diferentemente das redes Perceptron Multi-Camadas (PMC), as quais podem ser compostas de VÁRIAS camadas intermediárias, a estrutura típica da RBF é composta por apenas UMA dessas camadas:
  - As funções de ativação dos neurônios da camada intermediária são do tipo GAUSSIANA.
  - As funções de ativação dos neurônios da camada de saída são do tipo LINEAR.

Redes de Base Radial (RBF): Conceitos



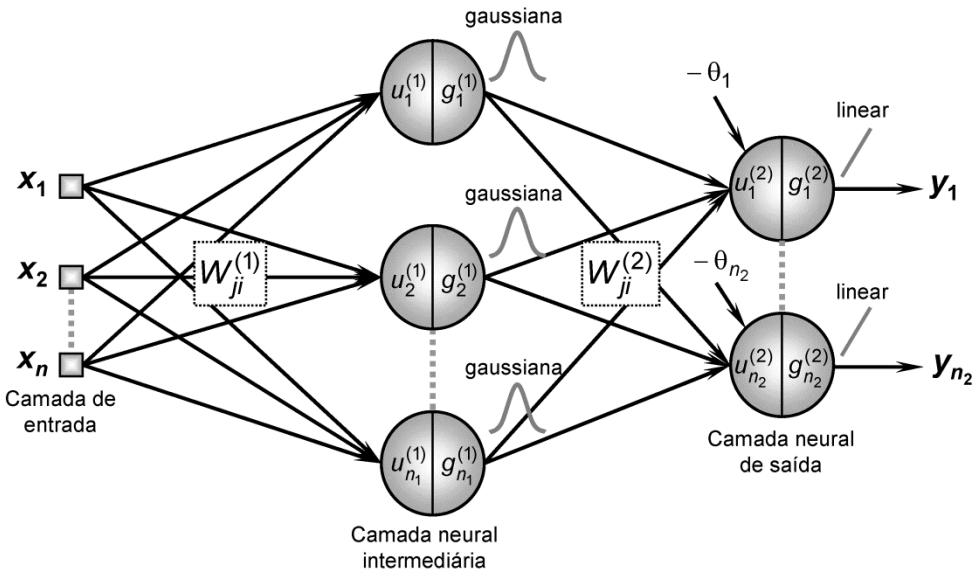
- As RBF’s podem ser também empregadas em quase todos os tipos de problemas tratados pelo PMC, ou sejam:
  - Problemas envolvendo aproximação funcional.
  - Problemas envolvendo classificação de padrões.
  - Problemas envolvendo sistemas variantes no tempo.
- O treinamento da RBF é também executada de forma SUPERVISIONADA.

Redes de Base Radial (RBF): Arquitetura



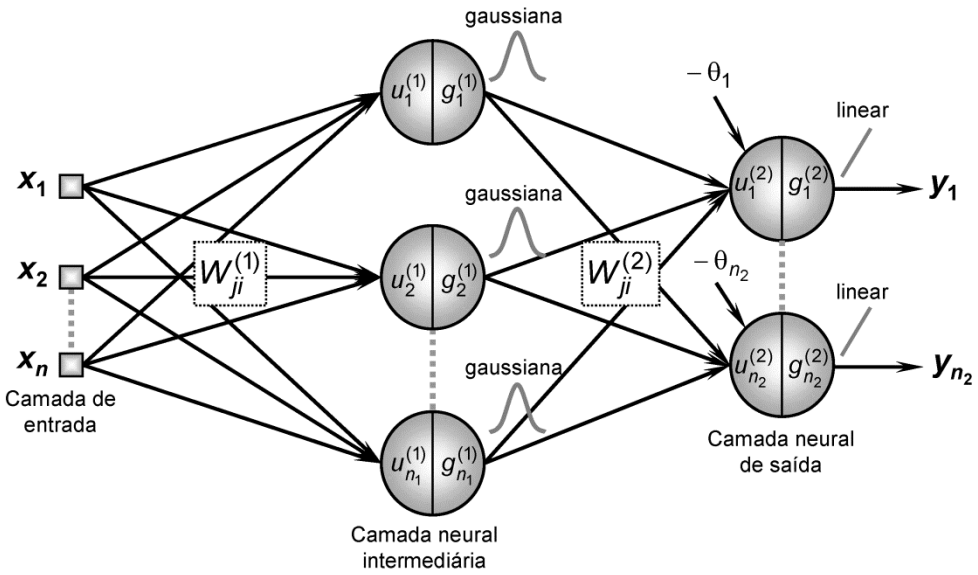
- Síntese do fluxo de informações na estrutura da rede RBF:
  1. Inicia-se na camada de entrada;
  2. Percorre, em seguida, a ÚNICA camada intermediária (neurônios com funções de ativação gaussiana);
  3. Finaliza-se na camada neural de saída (neurônios com funções de ativação linear).

Redes de Base Radial (RBF): Funcionamento



1. O princípio de funcionamento das redes RBF é também SIMILAR àquele do PMC, em que cada uma de suas entradas, representando os sinais advindos da aplicação, será então propagada pela referida camada intermediária, em direção à camada de saída.
2. Entretanto, diferentemente do PMC, a estratégia de treinamento da RBF é constituída de DUAS FASES ou estágios bem distintos entre si.

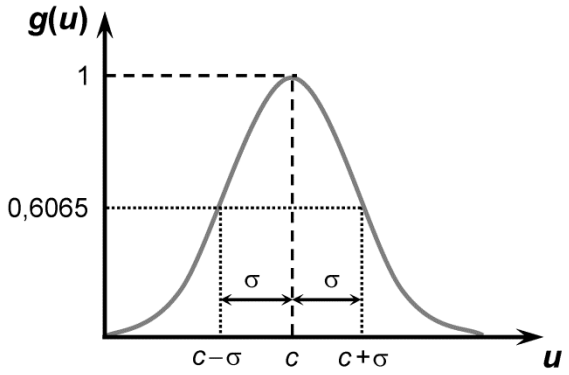
Redes de Base Radial (RBF): Funcionamento

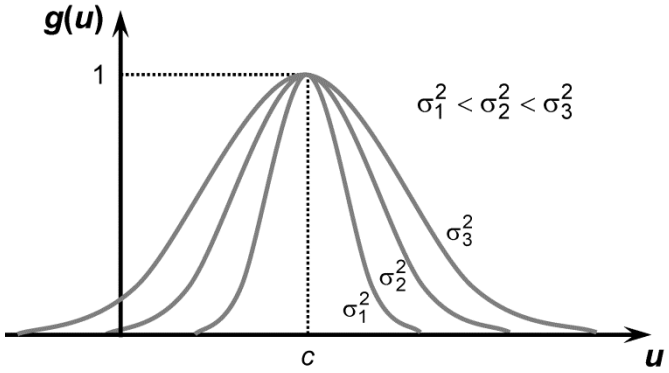


Fases de Treinamento:

1. **Primeiro Estágio -** Ajustes dos pesos dos neurônios da camada intermediária:
   - Adota um método de aprendizagem AUTO-ORGANIZADO (não-supervisionado), que é dependente apenas das características dos dados de entrada.
   - Este ajuste está diretamente relacionado com a ALOCAÇÃO das funções de ativação de base radial.
2. **Segundo Estágio -** Ajustes dos pesos dos neurônios da camada de saída:
   - Utiliza um critério de aprendizagem similar àquele usado na última camada do PMC, ou seja, a **REGRA DELTA GENERALIZADA**.

Redes de Base Radial (RBF): Funções de Ativação





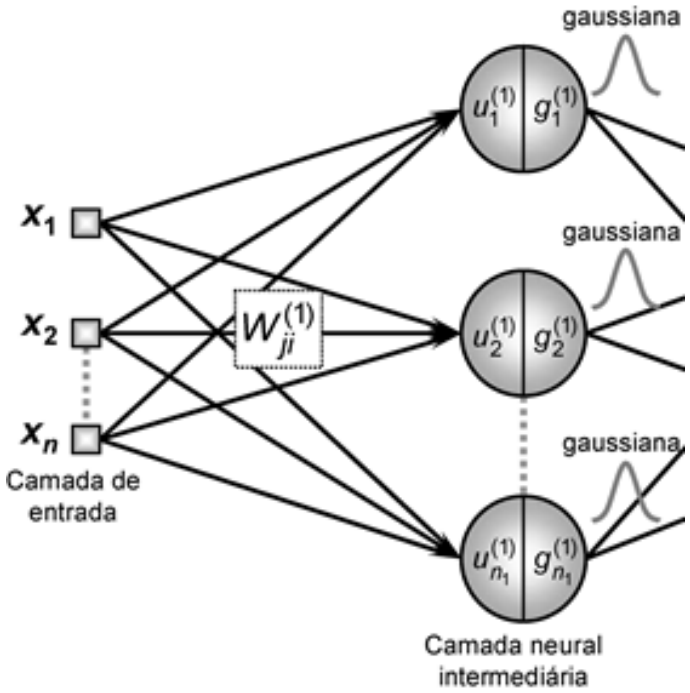
Camada Intermediária:

- Os neurônios pertencentes à camada intermediária da RBF possuem funções de ativação do tipo base radiais, sendo que a função GAUSSIANA é uma das mais usadas. A expressão que define uma função de ativação do tipo gaussiana é representada por:

$$g(u) = e^{-\frac{(u-c)^2}{2\sigma^2}}$$

onde c define o **CENTRO** da gaussiana e σ^2 denota a **VARIÂNCIA** (em que σ equivale ao desvio padrão), a qual indica o quão disperso está o potencial de ativação {u} em relação ao seu centro {c}.

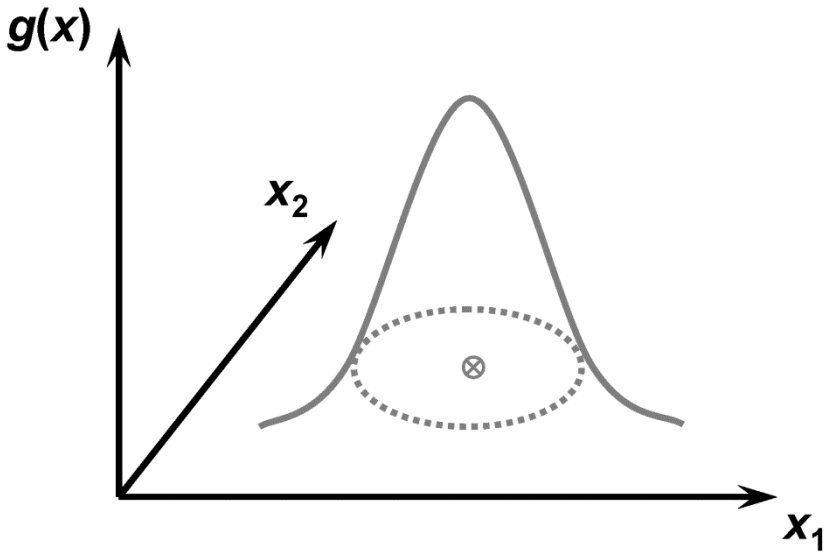
Redes de Base Radial (RBF): Ajuste da Camada Intermediária



- Considerando-se a expressão da gaussiana, os PARÂMETROS LIVRES a serem ajustados seriam então o centro c e a variância σ^2.
- Levando-se em conta o diagrama da RBF, juntamente com a configuração dos seus neurônios escondidos, o centro c está diretamente associado aos seus próprios PESOS.
- Nesta situação, a ENTRADA $u_j^{(1)}$ de cada um deles será o próprio vetor de entrada x, a qual representa os n sinais externos.
- Consequentemente, a SAÍDA de cada neurônio j desta camada é dada por:

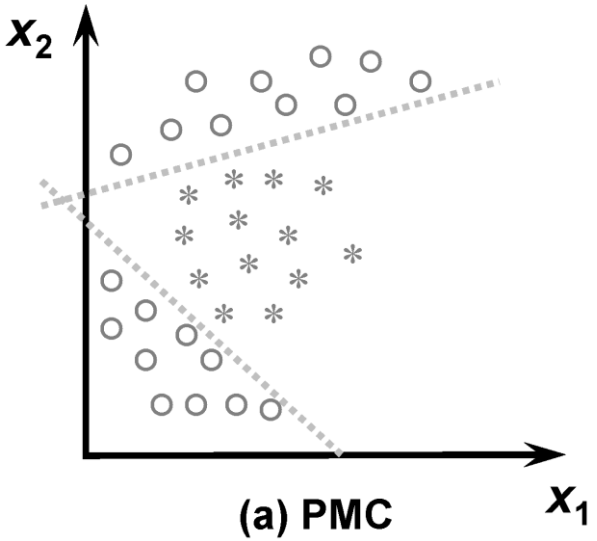
$$g_j^{(1)}\left(u_j^{(1)}\right) = g_j^{(1)}(x) = e^{-\frac{\sum_{i=1}^{n}\left(x_i - W_{ji}^{(1)}\right)^2}{2\sigma_j^2}}$$

Redes de Base Radial (RBF): Ajuste da Camada Intermediária

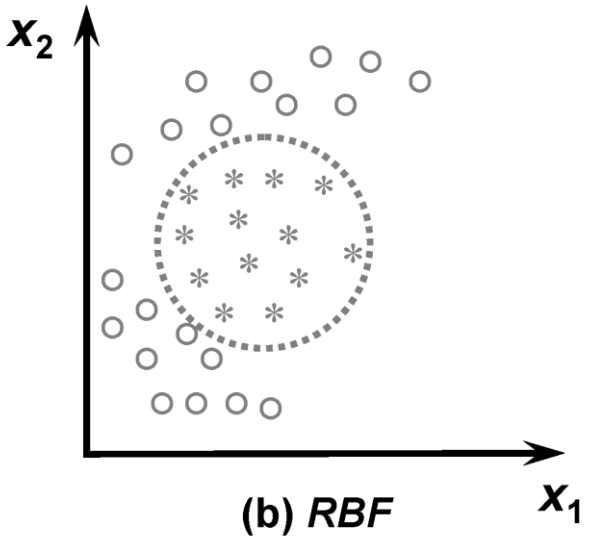


- **Campo Receptivo**: a figura mostra uma função de ativação gaussiana em relação a DOIS SINAIS de entrada x_1 e x_2, os quais compõem uma amostra x.
- Observa-se aqui que quanto mais próxima esteja uma determinada amostra (padrão) do CENTRO DA GAUSSIANA, mais significante será o valor produzido pelo campo receptivo radial da função de ativação, a qual tenderá para o valor 1.
- Em tal condição, o neurônio produzirá respostas similares para todos aqueles padrões que estejam a uma mesma DISTÂNCIA RADIAL do centro da gaussiana.
- Assim, para a RBF, as fronteiras delimitadoras são então definidas por **CAMPOS RECEPTIVOS HIPERESFÉRICOS**.

Redes de Base Radial (RBF): Ajuste da Camada Intermediária



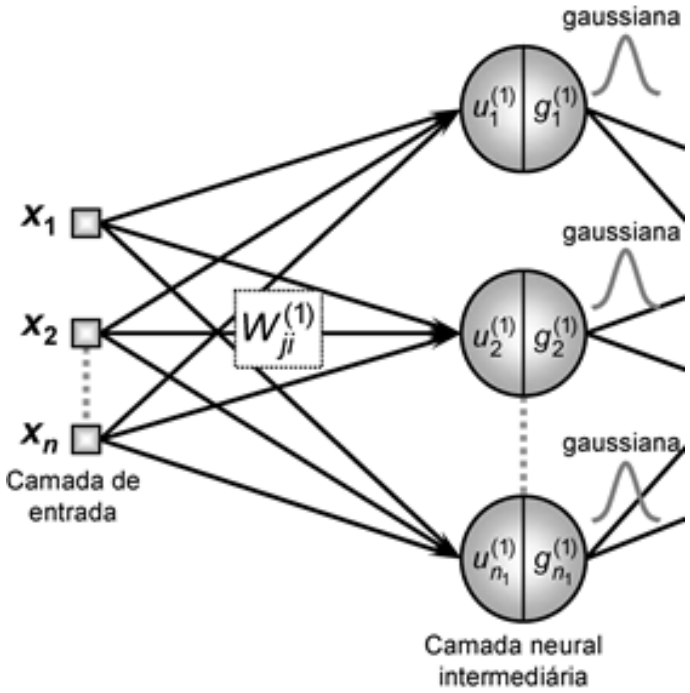
(a) PMC



(b) *RBF*

- Em se tratando de problemas de classificação de padrões, o PMC computa as fronteiras de delimitação de classes por intermédio de uma COMBINAÇÃO DE HIPERPLANOS.
- Já na RBF, com funções de ativação do tipo GAUSSIANA, as fronteiras delimitadoras são definidas por CAMPOS RECEPTIVOS HIPERESFÉRICOS.
- Neste caso, considerando somente duas entradas {x1 e x2}, a fronteira de separabilidade do PMC será formada de segmentos de RETA, ao passo que na RBF esta seria delimitada por um campo receptivo que pode ser representado por uma CIRCUNFERÊNCIA.

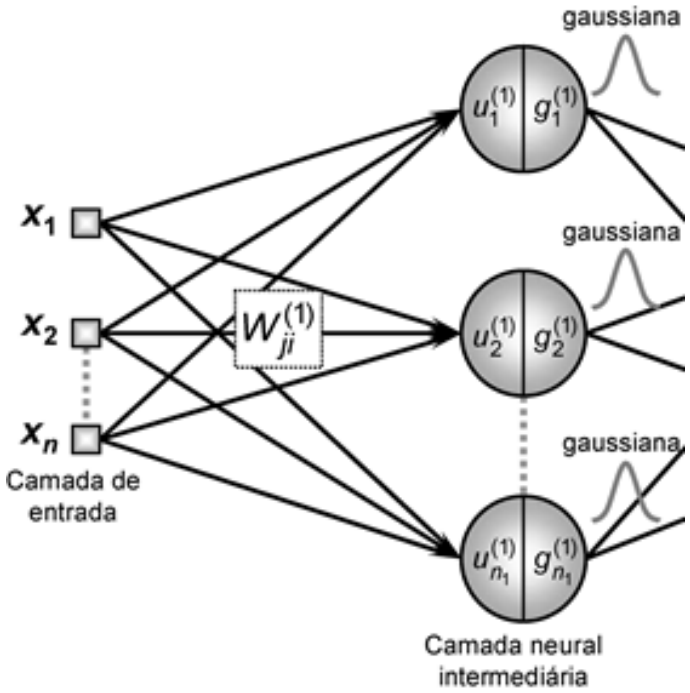
Redes de Base Radial (RBF): Treinamento – Estágio I



Ajustes dos neurônios da camada intermediária (K-MEANS):

- o principal objetivo dos neurônios da camada intermediária é POSICIONAR os centros de suas gaussianas de forma mais apropriada possível.
- um dos métodos mais bem utilizado para esta finalidade é denominado de K-MEANS (k-médias), cujo propósito é posicionar os centros de k-gaussianas em regiões que as amostras de entrada tenderão a se agrupar.
- Vale aqui ressaltar que o valor do parâmetro K é igual ao NÚMERO DE NEURÔNIOS da camada intermediária.
- De fato, a função de ativação de cada um deles é uma gaussiana, sendo que os centros delas serão representados pelos seus respectivos VETORES DE PESO.

Redes de Base Radial (RBF): Treinamento – Estágio I



Início {Algoritmo *RBF* – Primeiro Estágio de Treinamento}

<1> Obter o conjunto de amostras de treinamento $\{\boldsymbol{x}^{(k)}\}$;

<2> Iniciar o vetor de pesos de cada neurônio da camada intermediária com os valores das n_1 primeiras amostras de treinamento;

<3> Repetir as instruções:

<3.1> Para todas as amostras de treinamento $\{\boldsymbol{x}^{(k)}\}$, fazer:

<3.1.1> Calcular as distâncias euclidianas entre $\boldsymbol{x}^{(k)}$ e $W_{ji}^{(1)}$, considerando-se cada j-ésimo neurônio por vez;

<3.1.2> Selecionar o neurônio j, que contenha a menor distância, com o intuito de agrupar a referida amostra junto ao centro mais próximo;

<3.1.3> Atribuir a amostra $\boldsymbol{x}^{(k)}$ ao grupo $\Omega^{(j)}$;

<3.2> Para todos $W_{ji}^{(1)}$, onde $j = 1,\ldots,n_1$, fazer:

<3.2.1> Ajustar $W_{ji}^{(1)}$ de acordo com as amostras em $\Omega^{(j)}$:

$$W_{ji}^{(1)} = \frac{1}{m^{(j)}} \sum_{\boldsymbol{x}^{(k)} \in \Omega^{(j)}} \boldsymbol{x}^{(k)}$$

$\{m^{(j)}$ é o no. de amostras em $\Omega^{(j)}\}$

Até que: não haja mudanças nos grupos $\Omega^{(j)}$ entre as iterações;

<4> Para todos $W_{ji}^{(1)}$, onde $j = 1,\ldots,n_1$, fazer:

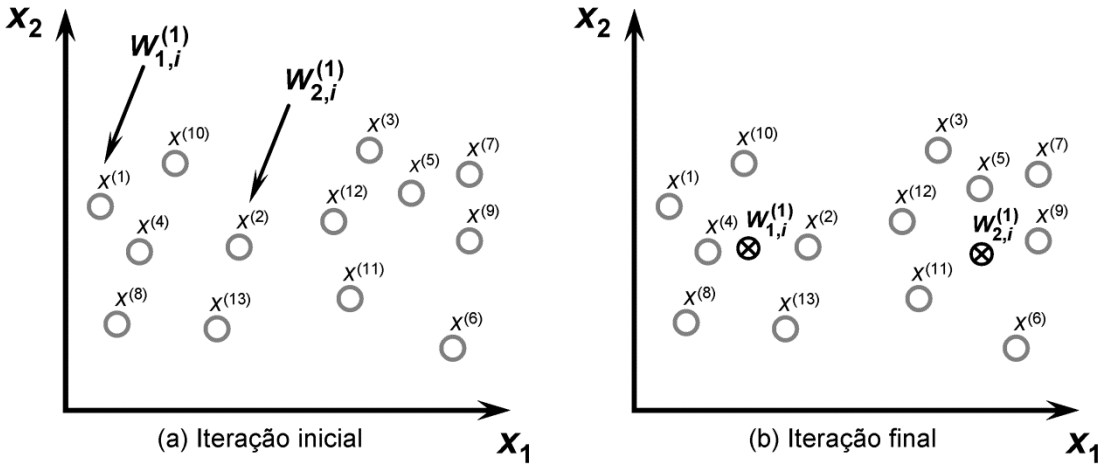
<4.1> Calcular a variância de cada uma das funções de ativação gaussianas pelo critério da distância quadrática média:

$$\sigma_j^2 = \frac{1}{m^{(j)}} \sum_{x^{(k)} \in \Omega^{(j)}} \sum_{i=1}^{n} (x_i^{(k)} - W_{ji}^{(1)})^2$$

Fim {Algoritmo *RBF* – Primeiro Estágio de Treinamento}

K-Means

Redes de Base Radial (RBF): Treinamento – Estágio I



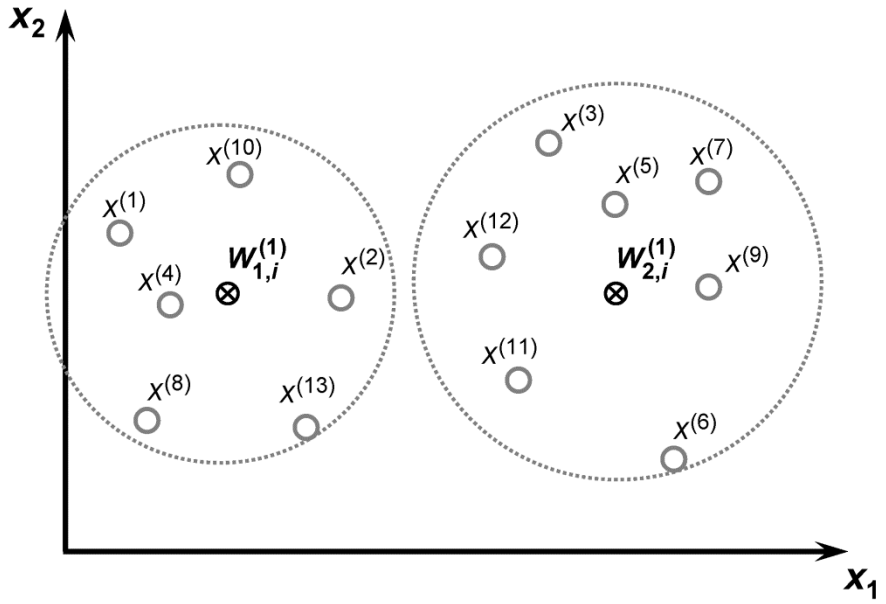
Configuração Inicial de $\Omega^{(1)}$ e $\Omega^{(2)}$

$$\Omega_{inicial}^{(1)} = \{x^{(1)}, x^{(4)}, x^{(8)}, x^{(10)}\}$$
$$\Omega_{inicial}^{(2)} = \{x^{(2)}, x^{(3)}, x^{(5)}, x^{(6)}x^{(7)}, x^{(9)}, x^{(11)}, x^{(12)}, x^{(13)}\}$$

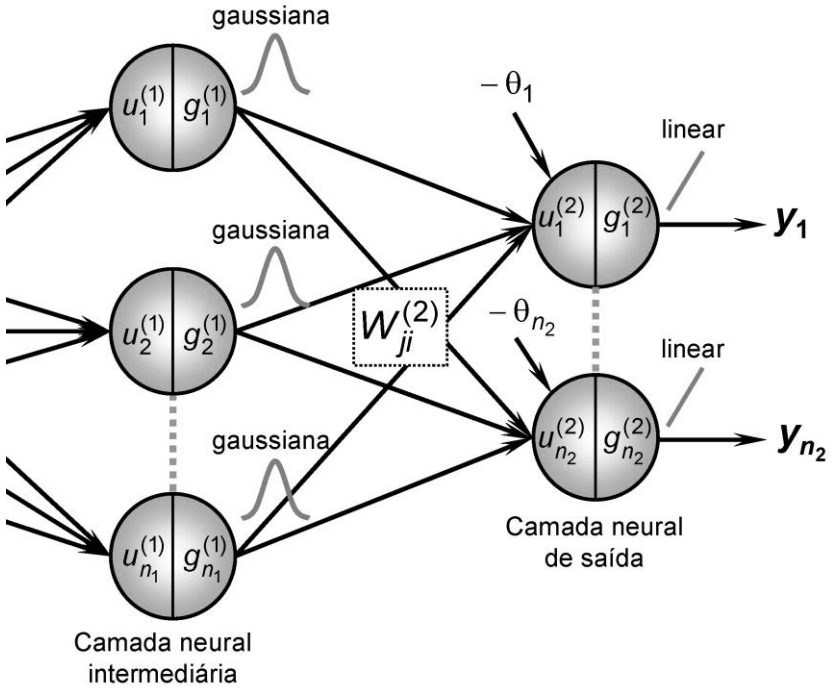
Configuração Final de $\Omega^{(1)}$ e $\Omega^{(2)}$

$$\Omega_{final}^{(1)} = \{x^{(1)}, x^{(2)}, x^{(4)}, x^{(8)}, x^{(10)}, x^{(13)}\}$$
$$\Omega_{final}^{(2)} = \{x^{(3)}, x^{(5)}, x^{(6)}, x^{(7)}, x^{(9)}, x^{(11)}, x^{(12)}\}$$

- **Exemplo**: considere um problema aplicativo constituído de duas entradas x_1 e x_2, com amostras de treinamento representadas na figura acima.
- Para este exemplo ilustrativo, a RBF será composta de apenas dois neurônios em sua camada intermediária (n_1= 2)



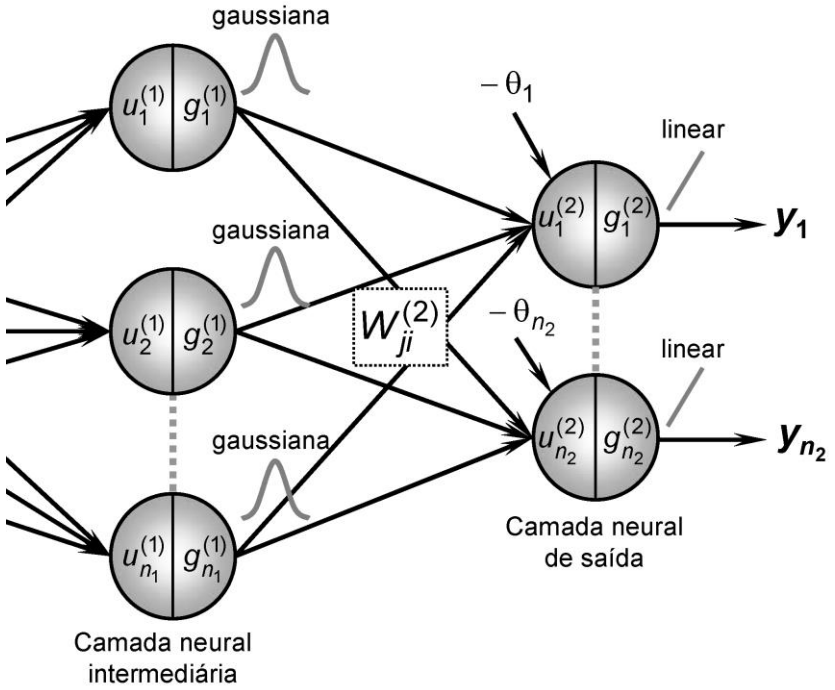
Redes de Base Radial (RBF): Treinamento – Estágio II



- A aplicação dos passos de ajuste referentes aos pesos dos neurônios da CAMADA DE SAÍDA deve ser executada, em sequência, somente após a finalização do primeiro estágio de treinamento.
- Diferentemente do primeiro estágio de treinamento da RBF, este 2º estágio utiliza um processo de aprendizado SUPERVISIONADO.
- O conjunto de treinamento para os neurônios de saída será então constituído por PARES de entrada e saída desejada.
- As entradas desta camada são as RESPOSTAS dadas pelas funções de ativação gaussianas dos neurônios da camada intermediária, ou seja:

$$u_j^{(2)} = \sum_{i=1}^{n_1} W_{ji}^{(2)} \cdot g_i^{(1)}\left(u_i^{(1)}\right) - \theta_j$$

Redes de Base Radial (RBF): Treinamento – Estágio II



Início {Algoritmo *RBF* – Segundo Estágio de Treinamento}

<1> Obter o conjunto original de amostras de treinamento $\{\boldsymbol{x}^{(k)}\}$;

<2> Obter o vetor de saída desejada $\{\boldsymbol{d}^{(k)}\}$ para cada amostra;

<3> Iniciar $W_{ji}^{(2)}$ com valores aleatórios pequenos;

<4> Especificar taxa de aprendizagem $\{\eta\}$ e precisão requerida $\{\varepsilon\}$;

<5> Para todas as amostras $\{\boldsymbol{x}^{(k)}\}$, fazer:

<5.1> Obter os valores de $g_j^{(1)}$ em relação à $\boldsymbol{x}^{(k)}$; {conforme (6.2)}

<5.2> Assumir $\boldsymbol{z}^{(k)} = [g_1^{(1)} \;\; g_2^{(1)} \ldots g_{n_1}^{(1)}]^T$; {*pseudo-amostras*}

<6> Iniciar o contador de número de épocas {*época* $\leftarrow$ 0};

<7> Repetir as instruções:

<7.1> $E_M^{anterior} \leftarrow E_M$; {conforme (5.8)}

<7.2> Para todos os pares de treinamento $\{\boldsymbol{z}^{(k)}, \boldsymbol{d}^{(k)}\}$, fazer:

Ajustar $W_{ji}^{(2)}$ e θ_j *aplicando os mesmos passos usados na camada de saída do PMC* (Subseção 5.3.1)

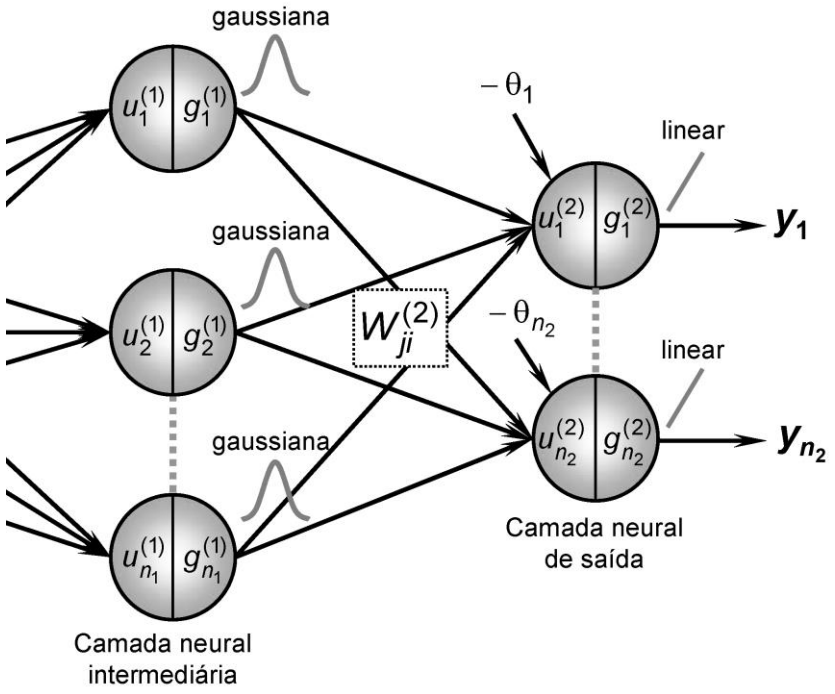
<7.3> $E_M^{atual} \leftarrow E_M$; {conforme (5.8)}

<7.4> *época* $\leftarrow$ *época* + 1;

Até que: $|E_M^{atual} - E_M^{anterior}| \leq \varepsilon$

Fim {Algoritmo *RBF* – Segundo Estágio de Treinamento}

Redes de Base Radial (RBF): Treinamento – Estágio II



- Após a finalização dos estágios de treinamento da RBF, esta estará então apta para estimar as saídas do processo que foi mapeado, frente agora às novas amostras que serão apresentadas.

Início {Algoritmo *RBF* – Fase de Operação}

<1> Apresentar uma amostra { $\boldsymbol{x}$ };

<2> Assumir os parâmetros $W_{ji}^{(1)}$, σ_j^2, $W_{ji}^{(2)}$ e θ_j já ajustados durante os estágios de treinamento;

<3> Executar as seguintes instruções:

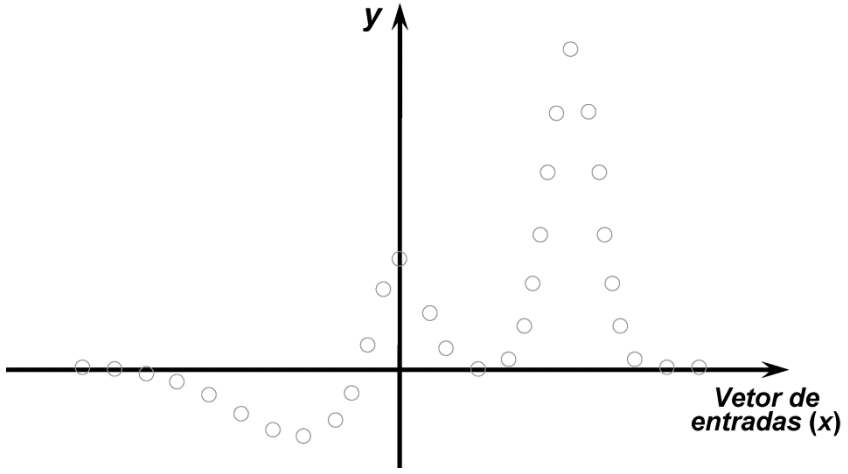
- <3.1> Obter $g_j^{(1)}$; {conforme (6.2)}
- <3.2> Obter $u_j^{(2)}$; {conforme (6.3)}
- <3.3> Obter y_j ; {conforme (6.4)}

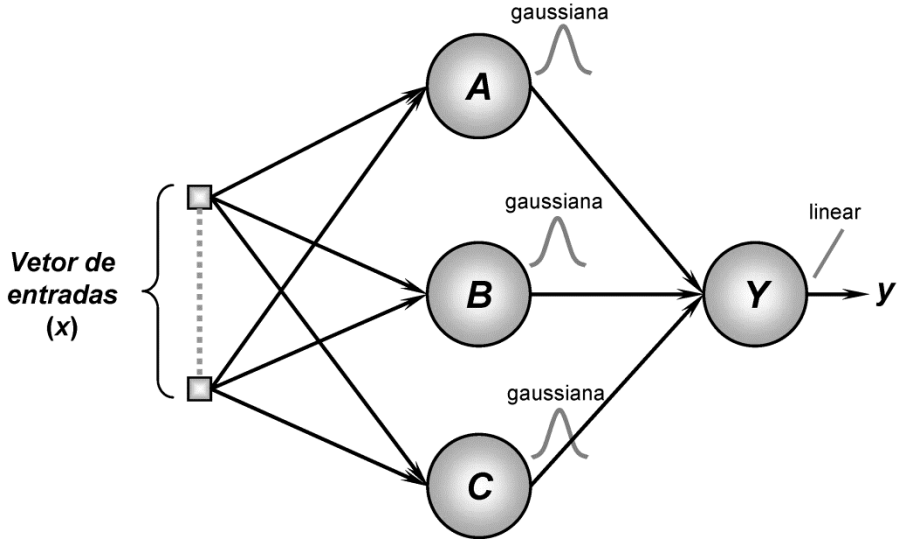
<4> Disponibilizar as saídas da rede mediante os valores contidos em y_j .

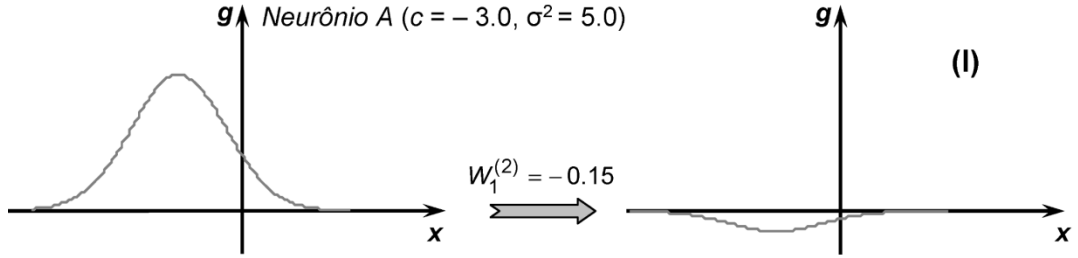
Fim {Algoritmo *RBF* – Fase de Operação}

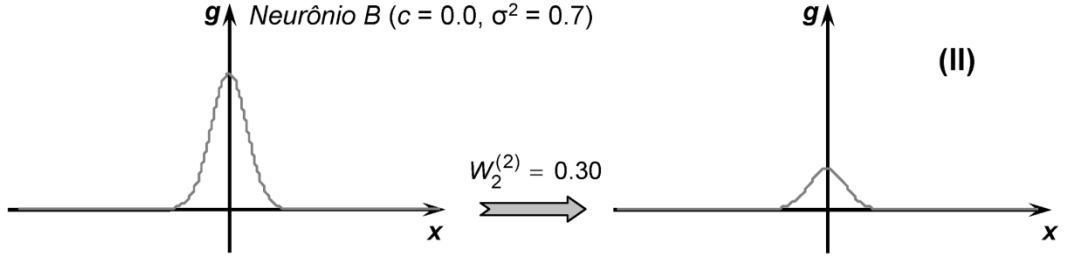
Redes de Base Radial (RBF): Aplicações em aproximação de funções

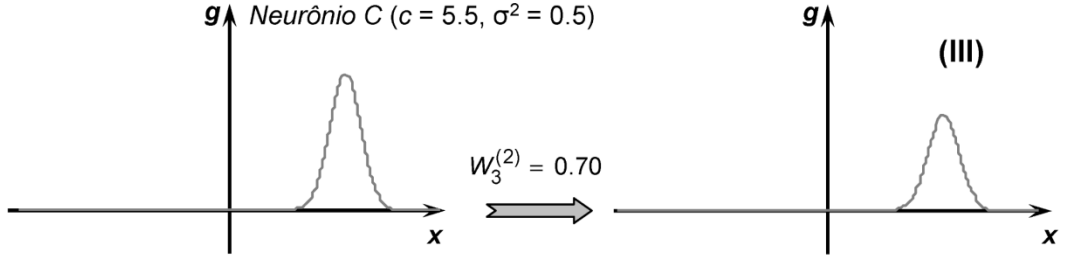
Conjunto de amostras relacionando entradas/saídas referente ao processo (função) a ser mapeado



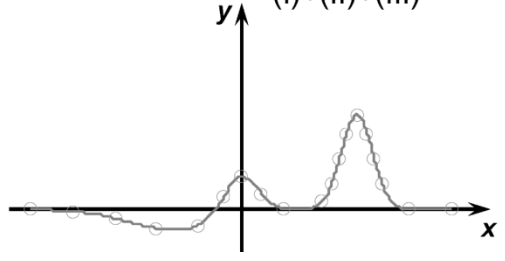




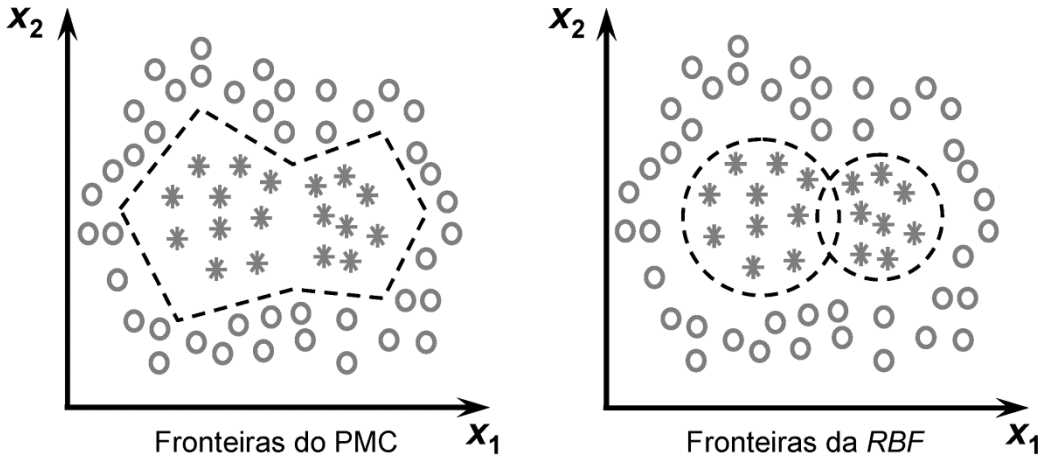




Resultado da soma ponto-a-ponto de (I)+(II)+(III)

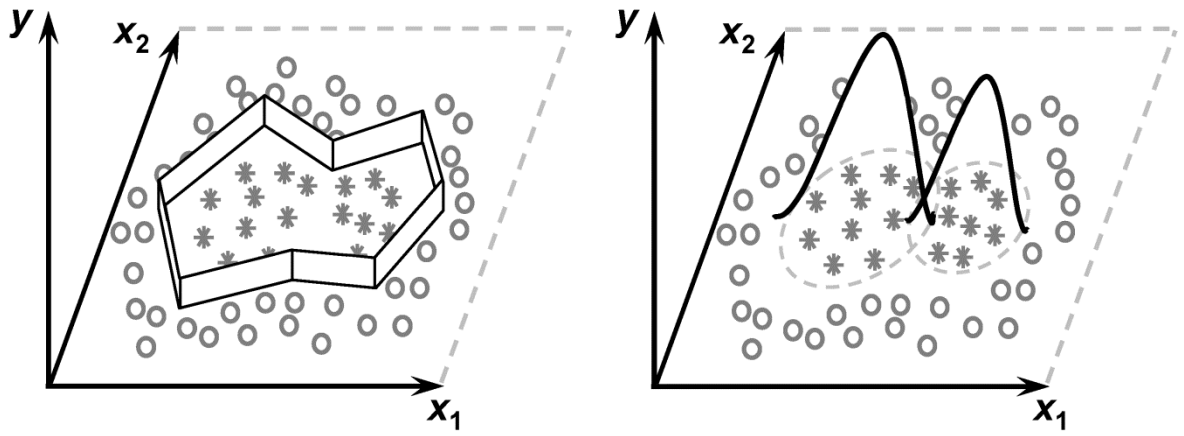


Redes de Base Radial (RBF): Aplicações em classificação de padrões

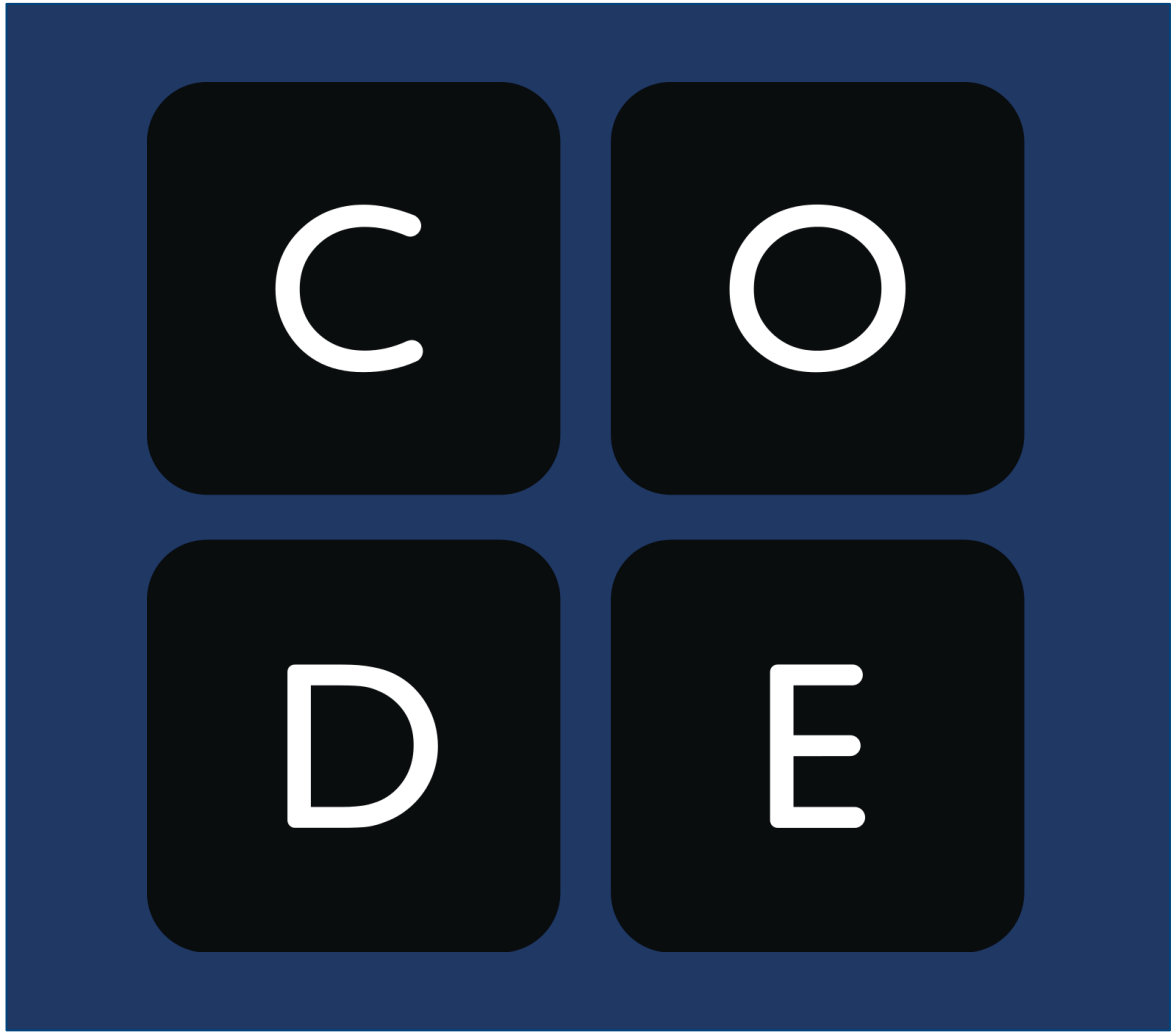


- Para o PMC, nota-se que a sua camada intermediária poderia ser constituída por 8 neurônios.
- Para a RBF, a sua camada intermediária seria composta por somente 2 neurônios, os quais são caracterizados pelas circunferências que delimitam as fronteiras.

A figura ao lado ilustra, de forma tridimensional, as possíveis regiões de separabilidade, baseadas nos resultados da figura dada acima.



Challenge Time





Laboratório 1: Treinamento e operação da RBF



- **Utilizando Jupyter e NumPy**: faça os laboratórios com o auxílio do professor.

Referências



- https://www.coursera.org/
- https://python.org.br/
- http://scikit-learn.org/stable/
- https://www.w3schools.com/python
- https://www.gnu.org/software/octave/
- https://octave-online.net/
- https://www.mathworks.com/products/matlab.html

Referências



- RUSSELL, STUART J.. Inteligência Artificial. 2ª ed. São Paulo: Campus - Elsevier, 2004.
- FERNANDES, Anita M. R.. Inteligência Artificial: noções gerais. 1ª ed. Florianópolis: Visual Books, 2008. Capítulo 1.
- SILVA, I.N. – Sistemas Inteligentes – Notas de Aula da disciplina de Sistemas Inteligentes – USP São Carlos, 2012.
- SILVA, I.N., SPATTI, D.H., FLAUZINO, R.A., Redes Neurais Artificiais para Engenharia e Ciências Aplicadas. 1ª ed. São Paulo: Editora Artiliber, 2010.
- NASCIMENTO JUNIOR, Cairo L., YONEYAMA, T. Inteligência Artificial em Controle e Automação. 1ª ed. São Paulo: Edgard Blücher, 2000.



Facens

AQUI TEM ENGENHARIA