

Universidade Federal
do Rio de Janeiro
Escola Politécnica

ANÁLISE DE PADRÕES DE CONSUMIDORES DE ENERGIA FOTOVOLTAICA POR MEIO DE APRENDIZADO NÃO SUPERVISIONADO

Jéssica Bezerra Claudio

Projeto de Graduação apresentado ao Curso de Engenharia Elétrica da Escola Politécnica, Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Engenheiro.

Orientador: Walter Issamu Suemitsu

Rio de Janeiro
Setembro de 2018

ANÁLISE DE PADRÕES DE CONSUMIDORES DE ENERGIA FOTOVOLTAICA POR MEIO DE APRENDIZADO NÃO SUPERVISIONADO

Jéssica Bezerra Claudio

PROJETO DE GRADUAÇÃO SUBMETIDO AO CORPO DOCENTE DO CURSO DE ENGENHARIA ELÉTRICA DA ESCOLA POLITÉCNICA DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE ENGENHEIRO ELETRICISTA.

Examinado por:

Prof. Walter Issamu Suemitsu, Dr.Ing.

Prof. José Luiz da Silva Neto, Ph.D.

Prof. Antonio Lopes de Souza, Ph.D.

RIO DE JANEIRO, RJ – BRASIL
SETEMBRO DE 2018

Bezerra Claudio, Jéssica

Análise de Padrões de Consumidores de Energia Fotovoltaica Por Meio de Aprendizado Não Supervisionado/Jéssica Bezerra Claudio. – Rio de Janeiro: UFRJ/ Escola Politécnica, 2018.

XI, 34 p.: il.; 29, 7cm.

Orientador: Walter Issamu Suemitsu

Projeto de Graduação – UFRJ/ Escola Politécnica/ Curso de Engenharia Elétrica, 2018.

Referências Bibliográficas: p. 34 – 34.

1. Medidores Inteligentes. 2. Clusterização. 3. Eficiência energética. I. Issamu Suemitsu, Walter. II. Universidade Federal do Rio de Janeiro, Escola Politécnica, Curso de Engenharia Elétrica. III. Título.

Agradecimentos

Gostaria de agradecer primeiramente aos meus pais, que me apoiaram, deram todo o suporte para que eu estivesse bem e, acima de tudo, acreditaram em mim, sempre demonstrando com muito amor que estavam ali torcendo e me observando, mesmo com os quilômetros que separam o Rio de Janeiro de São Paulo.

Agradeço aos meus amigos Fernanda e André por estarem ao meu lado quase todos os dias, me fazendo rir, sempre dispostos a conversar sobre a aleatoriedade da vida e me ajudaram a evoluir dia após dia.

Agradeço aos meu amigos Douglas, Érika, Lilian e Thiago por toda a ajuda e companheirismo. Vocês me mostram que eu não estava sozinha em momentos bons e, principalmente, nos momentos em que mais precisei.

Obrigada ao Marcello, Elisa, Stephanie e Fabio, por terem me ensinado de diferentes maneiras coisas que sempre guardarei comigo.

Os amigos que fiz durante o período da universidade me fizeram compreender o quão importante é ter pessoas que podemos confiar e contar, pois tornam tudo muito mais leve e divertido.

Por fim, agradeço ao professor Walter por ter se interessado pelo tema e dar apoio ao trabalho e aos professores Antonio Lopes e José Luís, por se mostrarem profissionais, com humildade e sempre dispostos à ajudar.

Resumo do Projeto de Graduação apresentado à Escola Politécnica/ UFRJ como parte dos requisitos necessários para a obtenção do grau de Engenheiro Eletricista.

ANÁLISE DE PADRÕES DE CONSUMIDORES DE ENERGIA FOTOVOLTAICA POR MEIO DE APRENDIZADO NÃO SUPERVISIONADO

Jéssica Bezerra Claudio

Setembro/2018

Orientador: Walter Issamu Suemitsu

Curso: Engenharia Elétrica

Apresenta-se, nesta trabalho uma metodologia que possibilita a realização de uma análise de padrões de consumidores de energia fotovoltaica por meio de aprendizado não supervisionado. Os perfis de consumo de energia são criados por meio de uma análise de agrupamentos, resultados do algoritmo *k-means*, por meio de um conjunto abrangente de dados contendo valores de carga residenciais medidos a cada meia hora, disponibilizados pela distribuidora australiana, *Ausgrid*.

Abstract of Undergraduate Project presented to POLI/UFRJ as a partial fulfillment of the requirements for the degree of Engineer.

ANALYSIS OF PATTERNS OF PHOTOVOLTAIC ENERGY CONSUMERS WITH UNSUPERVISED LEARNING

Jéssica Bezerra Claudio

September/2018

Advisor: Walter Issamu Suemitsu

Course: Electrical Engineering

This paper presents a methodology that makes it possible to carry out an analysis of the patterns of consumers of photovoltaic energy through unsupervised learning. The energy consumption profiles are created through a clustering analysis, results of the k-means algorithm, through a comprehensive set of data containing residential load values measured every half hour, made available by Australian electric power distributor, Ausgrid.

Sumário

Lista de Figuras **x**

Lista de Tabelas **xi**

1 Introdução **1**

1.1 Tema 1

1.2 Motivação 2

1.3 Objetivo 3

1.4 Estrutura do Trabalho 3

2 Fundamentos Teóricos **4**

2.1 Base de Dados: Medidores Inteligentes 5

2.1.1 Conceitos Básicos 5

2.2 Premissas: Estatística e Análise de Dados 6

2.3 Aprendizado de Máquina 6

2.3.1 Aprendizado supervisionado 7

2.3.2 Aprendizado não supervisionado 8

2.3.3 Aprendizado semi-supervisionado 11

2.3.4 Aprendizado por Reforço 11

2.4 Algoritmo K-Means para clusterização 12

3 Metodologia: Segmentação de Padrões de Consumo **15**

3.1 Base de Dados: Distribuidora *Ausgrid* 15

3.1.1 Carregar os dados para o ambiente *Python* 17

3.1.2 Tratamento dos dados 17

3.2 Premissas: Curvas Típicas de Consumidores Locais 18

3.3 Aplicação do Algoritmo K-Means para Segmentação de Perfis 22

4 Simulações e Resultados **24**

4.1 Segmentação de Perfis de Consumo de Energia Obtidos 24

4.2 Interpretação dos Resultados 28

4.3 Aplicação dos Resultados 29

5 Conclusões, Observações Finais e Trabalhos Futuros **32**
5.1 Conclusões 32
5.2 Observações Finais 32

Referências Bibliográficas **34**

Lista de Figuras

2.1 Diagrama de blocos da metodologia proposta neste projeto 4
2.2 Exemplo de funcionamento dos métodos aglomerativo e divisivo. . . . 10
2.3 Diagrama de blocos simplificado do algoritmo de aprendizado por reforço. 12
2.4 Diagrama de blocos do algoritmo *K-Means*. 13

3.1 Mapa da região de cobertura da distribuidora *Ausgrid*. 16
3.2 Conjunto de dados disponibilizado pela distribuidora *Ausgrid*, visualizado através da interface *Python*. 17
3.3 Perfil de famílias com filhos fora da idade escolar. Fonte:[1]. 19
3.4 Perfil de famílias com crianças no período escolar. Fonte:[1]. 19
3.5 Perfil de famílias com crianças pequenas no período de pré-escola. Fonte:[1]. 20
3.6 Perfil Diurno. Fonte:[1]. 21
3.7 Perfil Noturno Fonte:[1]. 22
3.8 Diagrama de blocos da síntese da metodologia proposta 23

4.1 Consumo médio diário durante o verão 25
4.2 Consumo médio diário durante o inverno 26
4.3 Consumo médio diário durante a primavera 27
4.4 Consumo médio diário durante o outono 28
4.5 Picos: Manhã e tarde 29
4.6 Picos: Final da tarde e noite 30
4.7 Picos: Manhã e tarde com consumo diário distribuído 30
4.8 Consumo durante o dia 30
4.9 onsumo durante a noite 31

Lista de Tabelas

4.1 Comparação entre os segmentos da referência de premissas e os resultados para o mês de inverno. 29

Capítulo 1

Introdução

1.1 Tema

A edição 2017 do relatório *New Energy Outlook* (NEO), produzido anualmente pela *Bloomberg New Energy Finance* (BNEF) mostra que as energias renováveis deverão receber quase três quartos dos US$ 10,2 trilhões que o mundo investirá em novas formas de tecnologia de geração até 2040. As fontes eólica e solar representarão 34% da geração de eletricidade até 2040, em comparação com os 5% atuais. De acordo com a reportagem "7 tendências globais em energia renovável para ficar de olho" da revista Online Exame, O custo da energia solar de painéis fotovoltaicos, que hoje é um quarto do que era em 2009, deverá baixar outros 66% até 2040. Até lá, um dólar comprará 2,3 vezes mais energia solar do que hoje, pelos cálculos da *BNEF*. Até 2040, os painéis solares fotovoltaicos residenciais representarão até 24% da eletricidade na Austrália, 20% no Brasil, 15% na Alemanha, 12% no Japão e 5% nos EUA e na Índia. Com isso, é essencial que pesquisas relacionados ao mercado de energia fotovoltaica e utilização da energia elétrica residencial sejam realizadas.

Dentre as maneiras para compreender a utilização de energia elétrica residencial, duas maneira podem ser citadas essencialmente. A primeira é dar ao consumidor um alto nível de detalhamento acerca de seu consumo, o que pode ser uma tarefa muitas vezes complicada, por necessitar de algoritmos mais complexos para detecção exata de quais aparelhos domésticos estão sendo utilizados em determinado momento, permitindo que o consumidor entenda exatamente seus gastos energéticos e podendo evitar eventuais desperdícios obtendo, consequentemente, uma maior eficiência energética. Outra maneira, mais simplificada, é observar através de curvas de padrões de consumo o comportamento do consumidor nos períodos diários de utilização da energia elétrica em sua residência e, partindo de premissas estatísticas, interpretá-las e então fazer recomendações e sugestões acerca da utilização de energia elétrica residencial e dimensionamento de sistemas fotovoltaicos de acordo com o grupo padrão

o qual o consumidor se encaixa, por exemplo.

Uma maneira para começar a compreender o mercado de energia de determinada região é observar e identificar diferentes padrões de consumo. Através do entendimento dos tipos majoritários de consumidores de energia, diversos setores podem ser favorecidos, tais como: fabricantes de sistemas fotovoltaicos, que podem fabricar sistemas otimizados para determinados, concessionárias, as quais podem se beneficiar com o melhor compreendimento da utilização da rede de energia e, até mesmo, os próprio consumidores, os quais podem receber sugestões para obter uma maior eficiência energética e recomendações para dimensionamento de sistemas fotovoltaicos para suas residências de acordo com o perfil de consumo o qual está enquadrado.

Uma segmentação adequada dos consumidores de energia contribui para a obtenção de soluções de eficiência energética, uma vez que permite o reconhecimento da influência de diferentes fatores no consumo de energia. Vários fatores podem influenciar o consumo de energia em uma residência tais como dimensão familiar, renda, períodos específicos do ano (tais como feriados e finais de semana), hábitos de consumo local e temperatura ambiente. As características de influência devem ser selecionadas de acordo com as premissas desejadas para a análise dos dados.

Este trabalho busca colaborar com a melhor compreensão do mercado de consumo de energia elétrica através do desenvolvimento de uma metodologia que utiliza aprendizado não supervisionado como algoritmo, resultando em uma segmentação de padrões de consumidores na região de Nova Gales do Sul, na Austrália. Os dados utilizados foram fornecidos pela distribuidora de energia elétrica australiana *Ausgrid* com a amostragem de dados em períodos de 30 em 30 minutos de 300 residências com sistemas fotovoltaicos instalados em sua localidade. Os consumidores foram segmentados de acordo com premissas retiradas por estudos realizados pela consultoria local *SunWiz* [1], pertence a região de coleta dos dados utilizados para este trabalho.

1.2 Motivação

Com a expansão das fontes de energia renováveis, novos estudos deverão surgir para dar suporte ao desenvolvimento das tecnologias para obter uma maior eficiência.

A motivação deste trabalho é colaborar com o setor elétrico através de estudos e desenvolvimento de uma metodologia de segmentação de consumidores de energia elétrica que possuem sistemas fotovoltaicos instalados em suas residencias para

melhor compreensão do comportamento do mercado de energia em crescimento.

1.3 Objetivo

O objetivo deste trabalho é encontrar uma metodologia que permite a compreensão dos consumidores de energia elétrica que possuem sistemas fotovoltaicos instalados em suas residências por meio de algoritmo de aprendizado de máquinas.

1.4 Estrutura do Trabalho

Este trabalho de conclusão de curso aborda o estudo e simulação de uma análise de padrões de consumidores de energia fotovoltaica por meio de aprendizado não supervisionado e é apresentado na seguinte estrutura:

O **capítulo 1** aborda a introdução, mostrando um panorama geral o qual o tema está inserido, motivação e o objetivo deste trabalho.

No **capítulo 2** são mostrados os fundamentos teóricos para melhor compreensão de algumas terminologias utilizadas na metodologia deste trabalho. Este capítulo é dividido por explicações objetivas acerca de medidores inteligentes, conceitos de premissa, aprendizado de máquinas e, por fim, uma explicação sobre o algoritmo de aprendizado não supervisionado utilizado, o algoritmo *k-means*. O algoritmo *k-means* tem sido considerado o mais conhecido e mais frequentemente usado para clusterização de dados de consumo [2].

O **capítulo 3** é apresentada a metodologia utilizada para a realização da segmentação dos padrões de consumo de energia, abordando em maiores detalhes a base de dados e as premissas utilizadas para este projeto para aplicação do algoritmo *k-means*.

No **capítulo 4**, a análise de agrupamento é aplicada e baseada no algoritmo *k-means* explicado em maiores detalhes no capítulo 4. Neste capítulo também é realizada a interpretação dos resultados com base em premissas realizadas por [1] e é dada um breve exemplo de aplicabilidade dos resultados obtidos.

Por fim, o **capítulo 5** são mostradas as conclusões, observações finais e trabalhos futuros.

Capítulo 2

Fundamentos Teóricos

De uma maneira simplificada, é possível observar através do diagrama de blocos mostrado na Figura 2.1 que a segmentação de padrões de consumo pode ser obtido inserindo-se uma base de dados juntamente com premissas, que darão um direcionamento às observações a serem feitas futuramente, no algoritmo de aprendizado de máquinas.

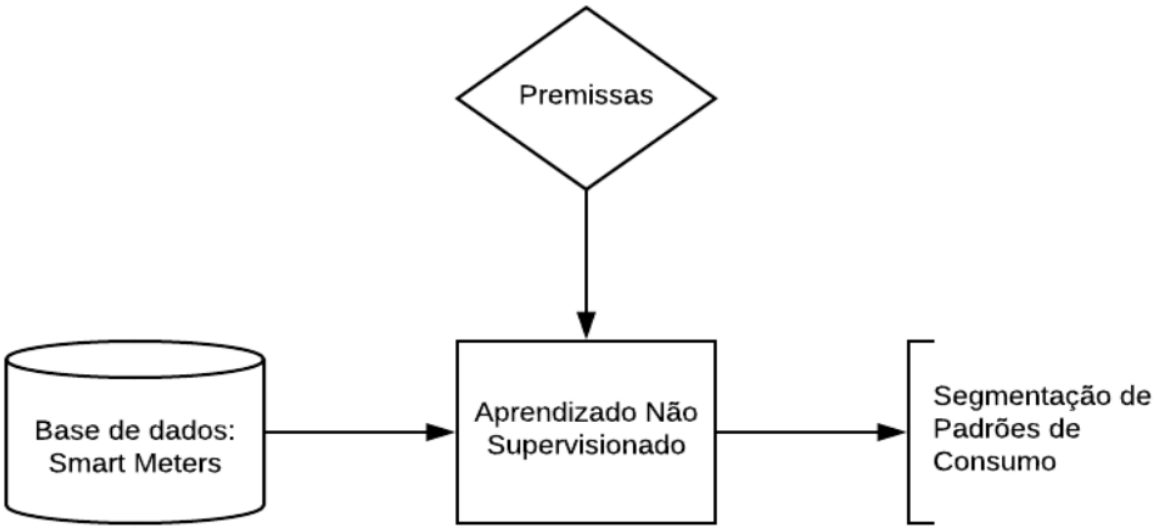


Figura 2.1: Diagrama de blocos da metodologia proposta neste projeto

A base de dados utilizada para este trabalho foi retirada de medidores inteligentes (ou, do inglês, *Smart Meters*), sendo que o funcionamento desses medidores será explicado em maiores detalhes na seção 2.1.

As premissas são variáveis de influência que e são baseadas nos conceitos de estatística e análise de dados, mostrados na seção 2.2.

A concepção de aprendizado não supervisionado esta inserido no conceito de aprendizado de máquinas, que será mostrado na seção 2.3.

Na seção 2.4 será mostrado com maior nível de detalhamento o algoritmo *K-Means*, que é o algoritmo de aprendizado não supervisionado utilizado neste trabalho para obter a segmentação de padrões de consumo, em que a metodologia será mostrada no Capítulo 3.

2.1 Base de Dados: Medidores Inteligentes

Nos últimos anos, redes inteligentes e medidores inteligentes têm sido amplamente implantados ao redor do mundo e estão colaborando para a realização de diversos tipos de pequisas voltadas para o mercado de energia em geral, entre elas, pesquisas relacionadas à observação de padrões de consumo de eletricidade em residências. A alta granularidade de informações que pode ser fornecida através dos medidores inteligentes permite que uma diversidade cada vez maior de pesquisas aconteçam, colaborando para que o desenvolvimento do setor energético tenha um direcionamento cada vez mais eficiente para seu crescimento.

2.1.1 Conceitos Básicos

Os medidores tradicionais medem apenas o consumo total e não fornecem informações de quando a energia foi consumida em cada local medido. Em contraste, os medidores inteligentes possuem a sensibilidade necessária para fornecer medições precisas de alta resolução na escala espacial, isto é, a nível doméstico, e a escala temporal, isto é, a cada hora ou 30 minutos, para partes da topologia de rede de distribuição de baixa voltagem para a qual anteriormente apenas medições com informações altamente agregadas eram fornecidas a partir de subestações e transformadores. A maioria dos medidores de eletricidade atuais podem medir a energia ativa e reativa consumida ou produzida, bem como níveis de tensão. Além de gravar dados elétricos, as novas gerações de medidores inteligentes são capazes de coletar informações sobre gás, calor ou utilização de água. Essa Infraestrutura de Medição Avançada (AMI, do inglês *Advanced Metering Infrastructure*) difere da tradicional Leitura Automática de Medidores (AMR, do inglês *Automatic Meter Reading*), na medida em que permite a comunicação bidirecional entre o contador e o centro de controle de um operador do sistema de distribuição [3].

2.2 Premissas: Estatística e Análise de Dados

Para realizar a aplicação de algoritmos de aprendizado de máquinas na grande quantidade de dados obtidos através de medidores inteligentes é necessário aplicar premissas, ou seja, são as variáveis escolhidas que irão influenciar os dados a serem analisados do conjunto de dados escolhidos, por exemplo, as curvas de consumo de energia poderão variar de acordo com temperatura local, o período do ano avaliado, ou hábitos de consumo local.

As premissas devem ser escolhidas com base em alguns conceitos, como a estatística e análise de dados, os quais serão explicados a seguir:

Estatística: É o estudo da coleta, análise, interpretação, apresentação e organização dos dados. Além disso, também pode ser definida como a matemática de estimar parâmetros de populações com base em dados de diferentes amostras representativas dessas populações. Na estatística, o procedimento padrão para estatísticos é começar com uma hipótese nula (uma posição padrão de que não há relação entre duas grandezas) que é comparada com uma hipótese alternativa (uma posição que afirma que há uma relação entre duas grandezas). A decisão de rejeitar uma hipótese é tomada com base em vários testes estatísticos que são realizados em diferentes amostras populacionais.

Análise de dados: é a descoberta e comunicação de padrões significativos em dados. A análise de dados é um processo (às vezes automatizado) usado para descobrir novos, válidos, úteis e potencialmente interessantes conhecimentos de grandes fontes de dados que, de outra forma, seriam difíceis de descobrir. Se a estatística deve ser considerada um ramo da matemática, a análise de dados está inclinada a executar a mesma funcionalidade para a ciência da computação. Ferramentas e técnicas visuais são os meios preferidos para comunicar os resultados da análise de dados.

2.3 Aprendizado de Máquina

O aprendizado de máquina (do inglês, *Machine Learning*) surgiu do campo da inteligência artificial e pode ser compreendido como o ramo da ciência da computação que permite que computadores aprendam a fazer previsões de dados, sem serem explicitamente programados.

As técnicas de aprendizado de máquina são utilizadas quando o objetivo é encontrar padrões, tendências ou aglomerados em um conjunto de dados. Estes atributos são informações que permitem melhor compreensão acerca dos dados.

O grande interesse em pesquisa sobre aprendizado de máquina deve-se aos mes-

mos fatores que tornaram a mineração de dados e a análise *bayesiana* mais populares do que nunca: o aumento do volume e da variedade de dados disponíveis, o processamento computacional mais barato e poderoso, o armazenamento de dados acessível etc.

Em geral, o aprendizado de máquina busca resolver problemas do mundo real, que apresentem relevância e possuam bases de dados contendo informações que possibilitem alcançar a solução. Embora muitos algoritmos de aprendizado de dados existam há bastante tempo, a habilidade de aplicar cálculos complexos automaticamente ao big data é um desenvolvimento relativamente recente.

De uma maneira geral, técnicas de aprendizado de máquina dependem da natureza dos dados que serão utilizados e podem ser divididas em 4 diferentes categorias, as quais serão mostradas nas seguintes subseções:

- 2.3.1 - Aprendizado supervisionado
- 2.3.2 - Aprendizado não supervisionado
- 2.3.3 - Aprendizado semi-supervisionado
- 2.3.4 - Aprendizado por reforço

2.3.1 Aprendizado supervisionado

Para este tipo de aprendizado, há variáveis de entrada (x) e variável de saída (Y) e o algoritmo de aprendizado faz o mapeamento da função que levará a entrada à saída.

$$Y = f(x)$$

Os problemas de aprendizado supervisionado podem ser divididos em problemas de regressão e classificação e, tanto na regressão quanto na classificação, o objetivo é encontrar relações ou estruturas específicas nos dados de entrada que nos permitam efetivamente produzir os dados de saída corretos.

Observe que a saída "correta"é determinada inteiramente pelos dados de treinamento, portanto, embora tenhamos uma verdade básica que nosso modelo assume como verdadeira, não é para dizer que os rótulos de dados estão sempre corretos em situações do mundo real. Dados incorretos ou com perturbação reduzirão a eficácia do modelo.

Overfiting e Generalização

Overfiting refere-se a aprender uma função que se ajusta muito bem aos dados de treinamento, mas não necessariamente se generalizar para outros pontos de dados,

em outras palavras, o modelo está aprendendo a produzir seus dados de treinamento sem aprender a tendência ou estrutura real dos dados que levam a isso saída. Imagine tentar encaixar uma curva entre dois pontos. Em teoria, você pode usar uma função de qualquer grau, mas, na prática, você adicionaria complexidade com parcimônia e seguiria com uma função linear.

O *tradeoff* de viés-variância também se relaciona com a generalização do modelo. Em qualquer modelo, há um equilíbrio entre o viés, que é o termo de erro constante, e a variância, que é o valor pelo qual o erro pode variar entre diferentes conjuntos de treinamento. Assim, um alto viés e baixa variância seria um modelo que está consistentemente errado 20% do tempo, enquanto um modelo de baixo viés e alta variância seria um modelo que pode estar errado entre 5% e 50% do tempo, dependendo os dados usados para treiná-lo. Observe que o viés e a variação geralmente se movem em direções opostas um do outro; o viés crescente geralmente leva a uma variância menor e vice-versa. Ao criar seu modelo, seu problema específico e a natureza de seus dados devem permitir que você tome uma decisão informada sobre onde cair no espectro de variância de viés. Geralmente, aumentar o viés (e diminuir a variação) resulta em modelos com níveis de desempenho da linha de base relativamente garantidos, o que pode ser crítico em determinadas tarefas. Além disso, para produzir modelos que generalizam bem, a variação de seu modelo deve ser dimensionada com o tamanho e a complexidade de seus dados de treinamento - conjuntos de dados pequenos e simples geralmente devem ser aprendidos com modelos de baixa variância e dados grandes e complexos. Os conjuntos geralmente exigem modelos de maior variação para aprender completamente a estrutura dos dados.

2.3.2 Aprendizado não supervisionado

O aprendizado não supervisionado pode ser dividido em duas partes:

- **(1)** Análise de Agrupamentos (ou *Clusterização*)
- **(2)** Redução de dimensionalidade

(1) Análise de Agrupamentos (ou Clusterização)

É o tipo de aprendizado não supervisionado em que dados não rotulados são utilizados e realiza o agrupamento de dados com perfis semelhantes e, em seguida, os dados agrupados são usados para criar *clusters*. O objetivo dessa técnica de aprendizado de máquina não supervisionada é encontrar semelhanças nos dados utilizados e agrupá-los e, por fim, determinar em qual *cluster* novos dados devem pertencer.

Há vários tipos de algoritmos de clusterização em aprendizado de máquinas, sendo os métodos mais tradicionais os denominados como métodos particionais e os

métodos Hierárquicos.

Método Hierárquico

O método hierárquico utiliza um algoritmo da técnica em que é construído uma hierarquia de *clusters*. Este algoritmo começa com todos os pontos de dados atribuídos a um grupo próprio. Os resultados de um algoritmo de clusterização hierárquica são normalmente mostrados como uma árvore binária ou *dendograma*, que é uma árvore que iterativamente divide a base de dados em subconjuntos menores. A raiz do *dendograma* representa o conjunto de dados inteiro e os nós folhas representam os indivíduos. O resultado da clusterização pode ser obtido cortando-se o *dendograma* em diferentes níveis de acordo com o número de *cluster* k desejado. Esta forma de representação fornece descrições informativas e visualização para as estruturas de grupos em potencial, especialmente quando há realmente relações hierárquicas nos dados como, por exemplo, dados de pesquisa sobre evolução de espécies. Em tais hierarquias, cada nó da árvore representa um *cluster* da base de dados. Existem dois métodos mais utilizados para clusterização hierárquica, o método divisivo e o método aglomerativo.

Método divisivo:No método de agrupamento divisivo ou de cima para baixo, atribuímos todas as observações a um único *cluster* e particionamos o cluster em dois *clusters* menos semelhantes. Finalmente, procedemos recursivamente em cada *cluster* até que haja um cluster para cada observação. Há evidências de que algoritmos divisivos produzem hierarquias mais precisas do que algoritmos aglomerativos em algumas circunstâncias, mas são conceitualmente mais complexas.

Método aglomerativo: No método de clusterização aglomerativa ou (bottom-up), atribuímos cada observação ao seu próprio *cluster*. Em seguida, calcule a similaridade (por exemplo, distância) entre cada um dos *clusters* e junte os dois clusters mais semelhantes. Por fim, repita as etapas 2 e 3 até restar apenas um *cluster*. O algoritmo relacionado é mostrado abaixo.

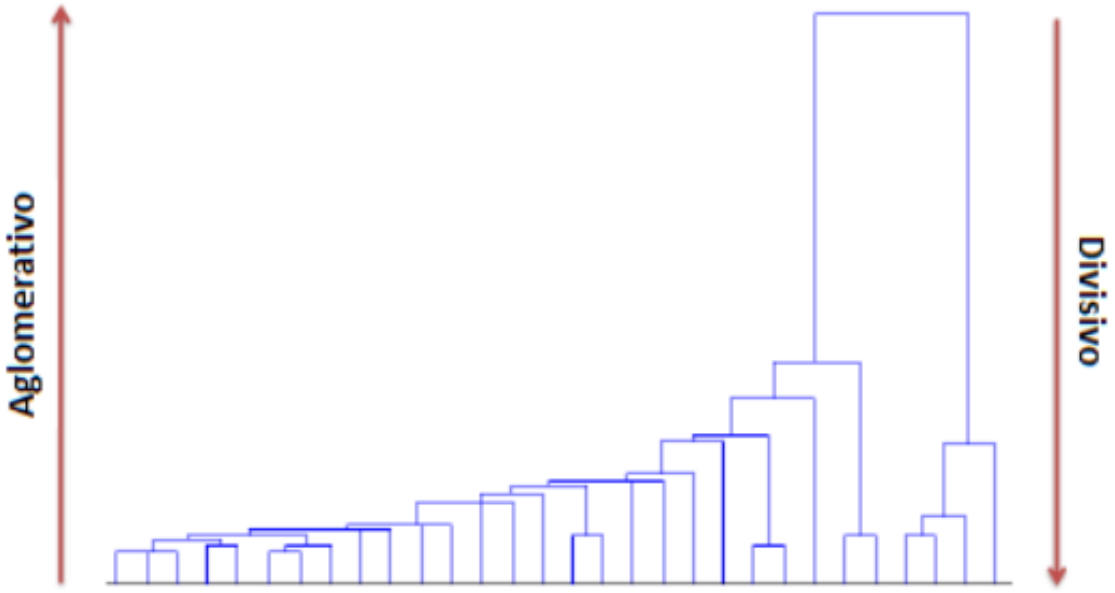


Figura 2.2: Exemplo de funcionamento dos métodos aglomerativo e divisivo.

Método Particional

Os algoritmos particionais dividem a base de dados em k-grupos, onde o número k é dado pelo usuário.

Inicialmente, o algoritmo escolhe k objetos como sendo os centros dos k *clusters*. Os objetos são divididos entre os k *clusters* de acordo com a medida de similaridade adotada, de modo que cada objeto fique no *cluster* que forneça o menor valor de distância entre o objeto e o centro do mesmo. Então, o algoritmo utiliza uma estratégia iterativa de controle para determinar que objetos devem mudar de *cluster*, de forma que a função objetivo usada seja otimizada.

Após a divisão inicial, há duas possibilidades na escolha do "elemento" que vai representar o centro do *cluster*. A primeira possibilidade utiliza a média dos objetos que pertencem ao *cluster* em questão, também chamada de centro de gravidade do *cluster* (esta é a abordagem conhecida como *k-means*) e, para a segunda possibilidade, escolhe-se como representante o objeto que se encontra mais próximo ao centro de gravidade do cluster (abordagem é conhecida como *k-medoids*), sendo o elemento mais próximo ao centro chamado de *medoid*.

O *k-means* é o mais popular e mais simples algoritmo particional e será o algoritmo utilizado para este trabalho, sendo abordado em maiores detalhes na Seção 2.4.

(2) Redução de Dimensionalidade

Redução de Dimensionalidade é o tipo de aprendizado não supervisionado, no qual as dimensões dos dados são reduzidas para remover os dados indesejados da entrada, removendo dados indesejáveis ou indesejáveis. Seu é baseado no processo de conversão de um conjunto de dados com grandes dimensões em conjuntos com dados e tamanhos reduzidos. Essa técnicas pode ser utilizada de maneira a otimizar processos de aprendizados de máquinas, reduzindo tempo de processamento e sua eficiência.

2.3.3 Aprendizado semi-supervisionado

A aprendizagem semi-supervisionada é um híbrido de aprendizado de máquina supervisionado e não supervisionado. O aprendizado semi-supervisionado é usado para os mesmos fins do aprendizado supervisionado, em que é empregado dados rotulados e não rotulados para treinamento, normalmente uma pequena quantidade de dados rotulados com uma quantidade significativa de dados não rotulados. Esse tipo de aprendizado pode ser usado com métodos como classificação, regressão e previsão.

Essa técnica é útil por alguns motivos, como por exemplo, otimizar o processo do aprendizado supervisionado, o qual é muitas vezes proibitivamente demorado e dispendioso com o processo de rotular grandes quantidades de dados. Além disso, incluir dados não rotulados durante o processo de treinamento tende a melhorar a precisão do modelo final de aprendizado.

2.3.4 Aprendizado por Reforço

Aprendizado por Reforço é o terceiro tipo de aprendizado de máquina no qual nenhum dado bruto é dado como entrada, porém, o algoritmo de aprendizado de reforço tem que descobrir a situação por conta própria. O aprendizado de reforço é usado com frequência para robótica, jogos e navegação. Com o aprendizado de reforço, o algoritmo descobre por tentativa e erro quais ações geram as recompensas mais significativas. Esse tipo de treinamento tem três componentes principais, que são: o agente, que pode descrever como aprendiz ou tomador de decisão, o ambiente que descreve como tudo com o qual o agente interage e ações que representam o que o agente pode fazer.

O objetivo é que o agente realize ações que maximizem a recompensa esperada em um determinado período de tempo. O agente alcançará a meta muito mais rapidamente seguindo um bom modelo algorítmico. Portanto, o propósito do aprendizado por reforço é aprender o melhor plano.

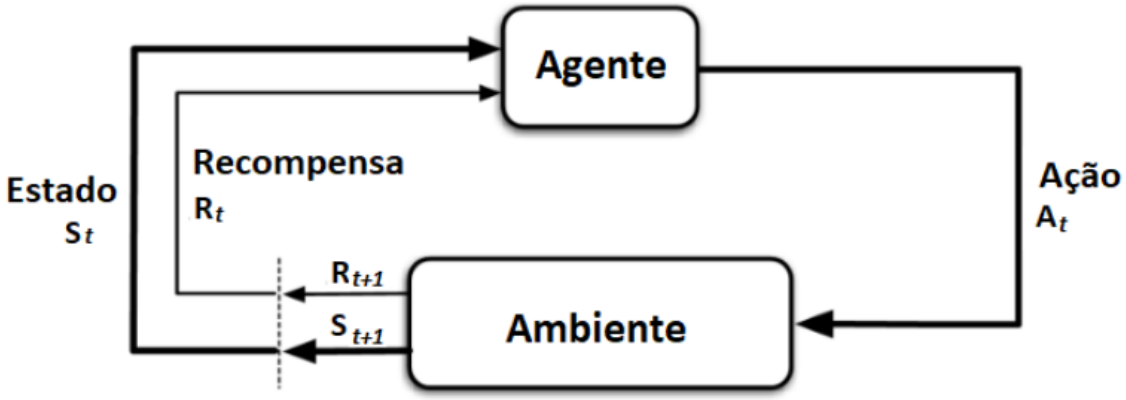


Figura 2.3: Diagrama de blocos simplificado do algoritmo de aprendizado por reforço.

2.4 Algoritmo K-Means para clusterização

O algoritmo *K-Means* agrupa dados tentando separar amostras em n grupos de variância igual, minimizando um critério conhecido como inércia ou soma de quadrados dentro do *cluster*. Esse algoritmo requer que o número de *clusters* seja especificado. Ele se adapta bem a um grande número de amostras e foi usado em uma grande variedade de áreas de aplicação em muitos campos diferentes.

O algoritmo atua minimizando a seguinte função objetivo [4.1]:

$$J = \sum_{c=1}^{k} \sum_{x_j \epsilon c_c}^{k} d(x_j, \bar{x}_c)^2 \tag{2.1}$$

onde, $d =$ simboliza a soma Euclidiana e $\bar{x}_c$ é o centróide do c-ésimo grupo:

$$\bar{x}_c = \frac{1}{|c_c|} \sum_{x_j \epsilon c_c} \tag{2.2}$$

A função objetivo também conhecida como inércia, ou o critério de soma dos quadrados dentro do *cluster*, pode ser reconhecida como uma medida de coerência entre os *clusters*. A inércia não é uma métrica normalizada - apenas sabemos que valores mais baixos são melhores e zero é o ideal. Em espaços de dimensões muito altas, as distâncias euclidianas tendem a se tornar infladas (este é um exemplo da chamada "maldição da dimensionalidade"). A execução de um algoritmo de redução de dimensionalidade, como o PCA antes do agrupamento *K-Means*, pode aliviar esse problema e acelerar os cálculos, mas este não foi o caso a ser abordado neste trabalho, devido ao pré-processamento do conjunto de dados utilizado, tornando-os concisos em relação à dimensionalidade.

O algoritmo primeiro passo escolhe os centróides iniciais, sendo o método mais básico escolher k amostras da base de dados X. Após a inicialização, o *K-Means* consiste em fazer um *loop* entre três etapas e, podendo ser observado na Figura 2.4:

- 1a etapa: Escolhe os centróides iniciais;
- 2a etapa: Determina a distância de cada objeto dos centróides estabelecidos na primeira etapa;
- 3a etapa: Agrupa os objetos com base na mínima distância.

Feitas as etapas acima, o algoritmo faz com que a diferença entre os antigos e os novos centróides seja calculada e o algoritmo repete as 3 etapas até que esse valor seja menor que um limite. Em outras palavras, repete até que os centróides não se movam significativamente.

Com tempo suficiente, o K-*Means* sempre irá convergir, no entanto, isso pode ser para um mínimo local. Isso é altamente dependente da inicialização dos centróides. Como resultado, o cálculo geralmente é feito várias vezes, com diferentes inicializações dos centróides.

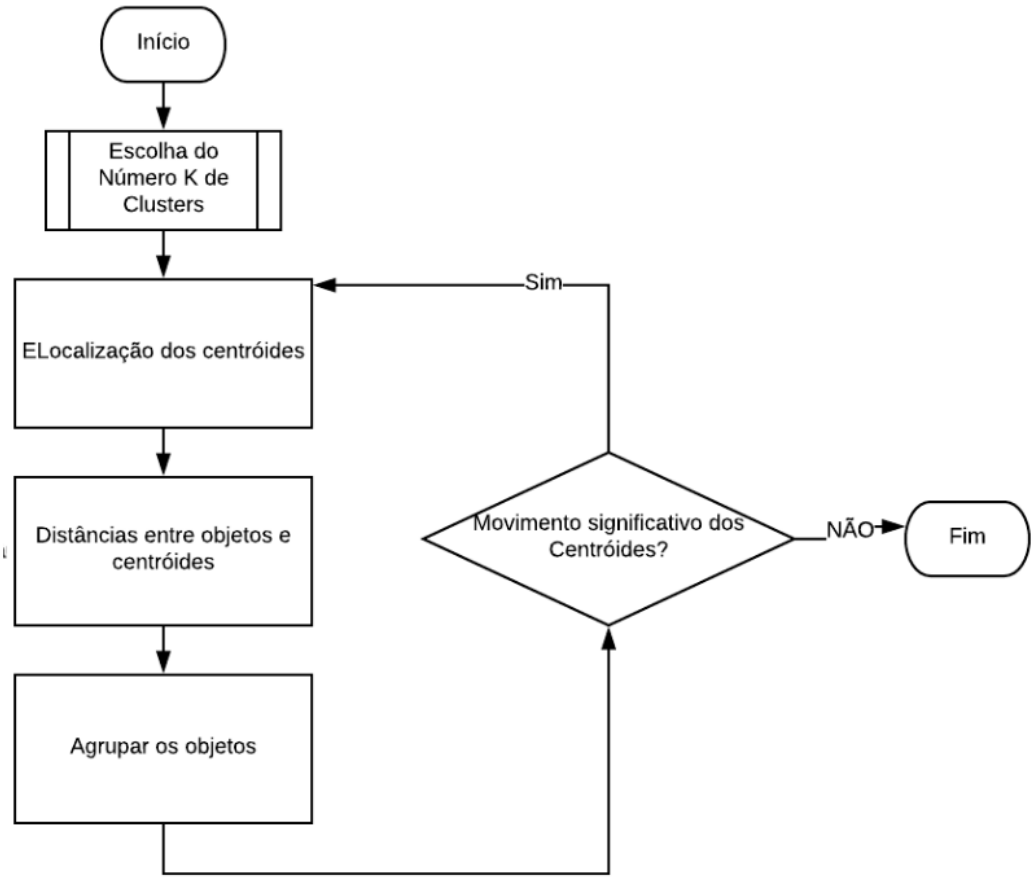


Figura 2.4: Diagrama de blocos do algoritmo *K-Means*.

Este algoritmo é vantajoso por ser simples e intuitivo, possuir complexidade computacional linear e é eficaz em muitos cenários em que as interpretação de resultados são mais simples, porém, possui a desvantagem da inserção de um k pelo indivíduo que o utiliza.

Capítulo 3

Metodologia: Segmentação de Padrões de Consumo

O processo de segmentação de padrões é explicado em maiores detalhes nas seções a seguir:

- 3.1 - Base de Dados: Distribuidora *Ausgrid*
- 3.2 - Premissas: Curvas Típicas de Consumidores Locais
- 3.3 - Aplicação do Algoritmo *K-Means* para Segmentação de Perfis

3.1 Base de Dados: Distribuidora *Ausgrid*

O conjunto de dados usado para este projeto é formado por gravações realizadas por medidores inteligentes em casas que utilizam energia solar em Sydney, Austrália, e foi disponibilizado por *Ausgrid*, empresa privada responsável por operar grande parte da rede de distribuição da região de *New South Wales* (Sidney, região de *Hunters* e Costa Central), como podemos observar no mapa da Figura 3.1.



Figura 3.1: Mapa da região de cobertura da distribuidora *Ausgrid*.

Os dados providos pela distribuidora *Ausgrid* foram escolhidos por serem disponibilizados publicamente, juntamente com informações completas acerca de suas características. A distribuidora permitiu a acessibilidade aos dados com o objetivo principal de incentivar a pesquisa acerca das informações. Além disso, foi de grande interesse trabalhar com dados reais para compreender e buscar os possíveis problemas que podem ser encontrados em dados obtidos por medidores inteligentes.

Os dados disponibilizados podem ser divididos por características dos consumidores (número de identificação do consumidor, capacidade de geração, CEP e a categoria do consumidor) e valores brutos de energia consumida, produzida ou controlada.

Foi utilizado do arquivo do formato *CSV* referente ao intervalo de 2011 à 2012 e, em uma visão geral dos dados, pode ser observado que as colunas estão organizadas por: "Consumidor", contendo uma numeração de identificação do consumidor, "Capacidade de geração", "Código postal", "Categoria de Consumo", "data" e "hora", contendo valores de consumo de energia elétrica.

Além dessas informações, há a diferenciação dos dados de consumo entre dados que foram efetivamente medidos pelo medidor no intervalo de meia hora ou marcado como "NA", do inglês Non-Actual, que identifica dados que foram estimados ou substituídos no processo de medição de consumo ou geração.

Entre os dados analisados, um total de 270.204 pontos de medições constam como efetivamente medidos e apenas 100 entre o total de dados foram marcados

como “NA”.

Entre as informações dadas nas colunas citadas acima, temos, 300 consumidores, identificados como números de 1 a 300.

Dentre as “Categorias de Consumo” (ou, canais de medições), temos as siglas: “GC”, “CL” e “GG”, com as seguintes descrições dadas pela *Ausgrid*:

- GC: Consumo Geral para eletricidade fornecida o tempo todo (tarifa primária, bloco de inclinação ou taxas de tempo de uso), excluindo geração solar e fornecimento de carga controlada
- CL : Consumo de Carga Controlada (tarifas diferenciadas fora do pico)
- GG : Geração Bruta de eletricidade através de um sistema fotovoltaico com configuração de medição bruta, medida separadamente para as cargas domésticas

3.1.1 Carregar os dados para o ambiente *Python*

Para este trabalho foi utilizada a plataforma *Jupyter*, uma plataforma específica para desenvolver software de código aberto, padrões abertos e serviços para computação interativa em dezenas de linguagens de programação e, o ambiente software utilizado foi o *Python 3*. A interface dos dados observados na plataforma e software utilizados é vista em 3.2.

	Customer	Generator Capacity	Postcode	Consumption Category	date	0:30	1:00	1:30	2:00	2:30	...	20:00	20:30	21:00	21:30	22:00	22:30	23:00	23:30
0	1	3.78	2076	CL	2011-07-01	1.250	1.250	1.250	0.625	0.219	...	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
1	1	3.78	2076	GC	2011-07-01	1.077	0.669	0.674	0.615	0.321	...	0.276	0.241	0.168	0.234	0.164	0.639	0.118	0.219
2	1	3.78	2076	GG	2011-07-01	0.000	0.000	0.000	0.000	0.000	...	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
3	1	3.78	2076	CL	2011-07-02	1.238	1.244	1.194	0.000	0.888	...	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
4	1	3.78	2076	GC	2011-07-02	0.476	0.130	0.044	0.094	0.032	...	0.234	0.306	0.183	0.240	0.170	0.506	0.224	0.088

Figura 3.2: Conjunto de dados disponibilizado pela distribuidora *Ausgrid*, visualizado através da interface *Python*.

3.1.2 Tratamento dos dados

Observando a ausência de dados, foi possível observar que quase todos os valores de “GG” E “GC” estão completos e cerca de 54% de CL estão ausentes. Há uma coerência nesta observação se for pensando em que nem todos os consumidores terão

dados de Consumo de Carga Controlada, pois este tipo de consumo somente ocorrerá com consumidores que recebem tarifas especiais nos períodos fora de pico.

Para a reformatação do conjunto de dados, o período de tempo e datas foram combinados em um único formato de dado para facilitar a manipulação dos dados, assim como a seleção das categorias de consumidores e valores de consumo como colunas com o mesmo objetivo de tornar mais fácil o manuseio do conteúdo do arquivo utilizado.

3.2 Premissas: Curvas Típicas de Consumidores Locais

Para analisar os padrões de curvas de cargas foi utilizado como referência a publicação da consultoria de mercado energético australiana *SunWinz*, a qual dividiu em 5 perfis principais o consumo para as regiões metropolitanas da Austrália. Uma descrição mais detalhada acerca destes perfis será discutida abaixo:

(1)Picos: Manhã e Começo da noite

Este perfil é caracterizado por dois picos distintos que denotam as atividade associadas às rotinas da manhã e da tarde. Ao longo do dia, a curva de carga permanece em um nível mais baixo devido à equipamentos que ficam ligados durante todo o dia (principalmente geladeira, aquecimento de água e outros dispositivos). Este perfil de curva de carga pode ser observado na figura 3.3

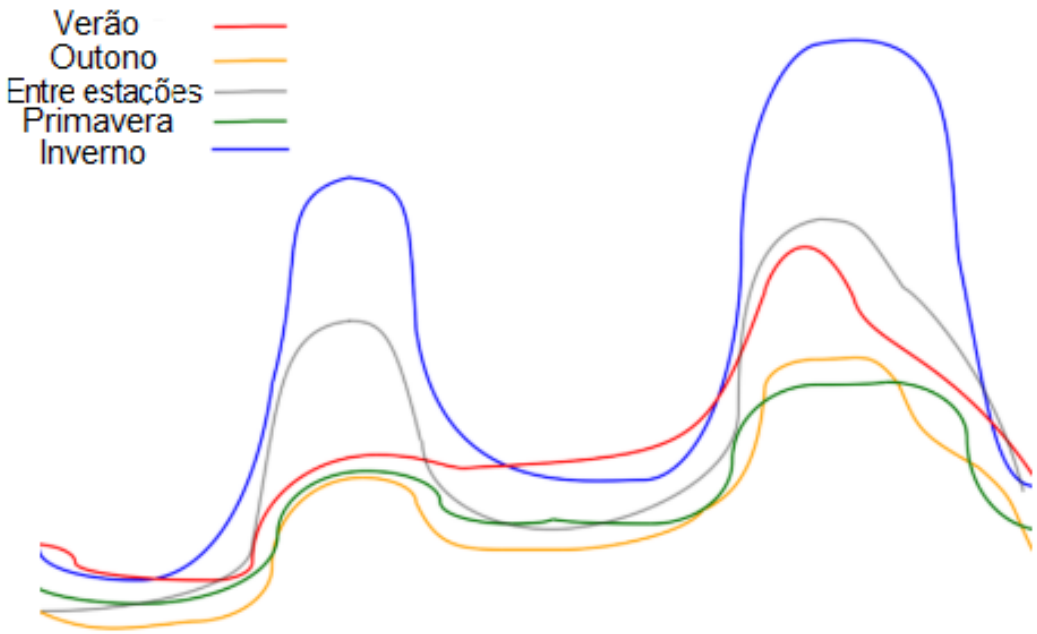


Figura 3.3: Perfil de famílias com filhos fora da idade escolar. Fonte:[1].

(2)Picos: Manhã e noite, com mais consumo à noite

Este perfil é caracterizado por um pico de consumo de energia elétrica quando os ocupantes chegam em casa do trabalho e começam a preparar-se para jantar, assistir televisão, tomar banho, etc. Este perfil de curva de carga pode ser observado na figura 3.4

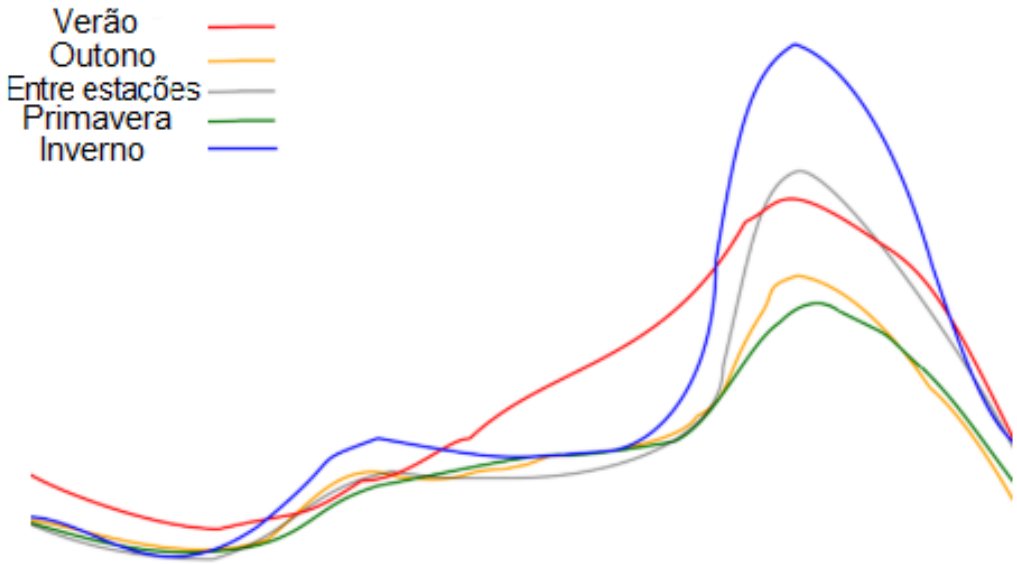


Figura 3.4: Perfil de famílias com crianças no período escolar. Fonte:[1].

(3)Picos: Manhã e começo da noite com consumo distribuído ao longo do dia

Este perfil se assemelha ao perfil (1), contendo os "dois picos"mencionado acima, porém, com uma maior demanda energética durante o período diurno. Este tipo de curva de carga pode ser observado na Figura 3.5.

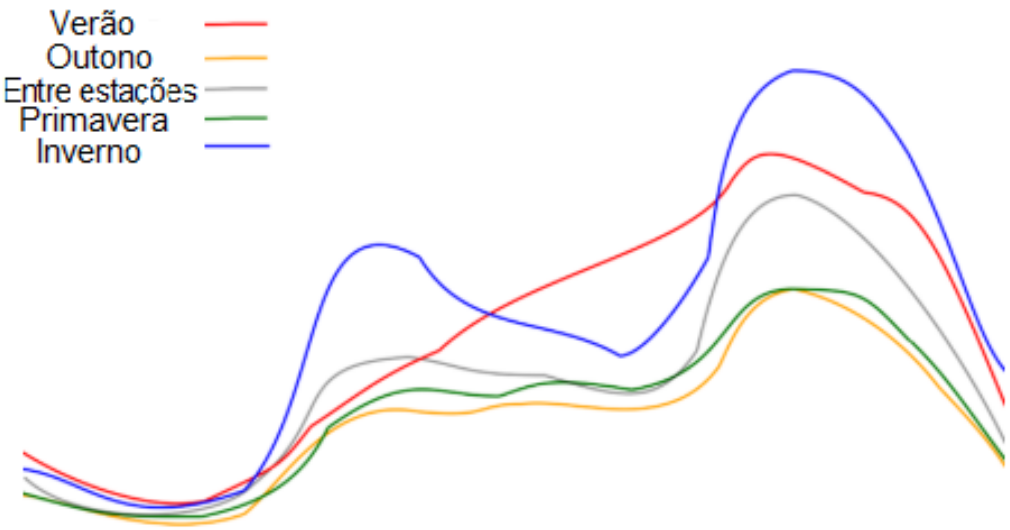


Figura 3.5: Perfil de famílias com crianças pequenas no período de pré-escola. Fonte:[1].

(4)Consumo durante o dia

Este perfil possui características de consumo de energia elétrica de aposentados e pessoas que trabalham em casa. As famílias (e empresas) de foco no dia usam uma quantidade de eletricidade relativamente constante ao longo do dia. Eles também têm mais flexibilidade quando se trata de escolher quando utilizar seus aparelhos. Este tipo de curva de carga pode ser observado na Figura 3.6.

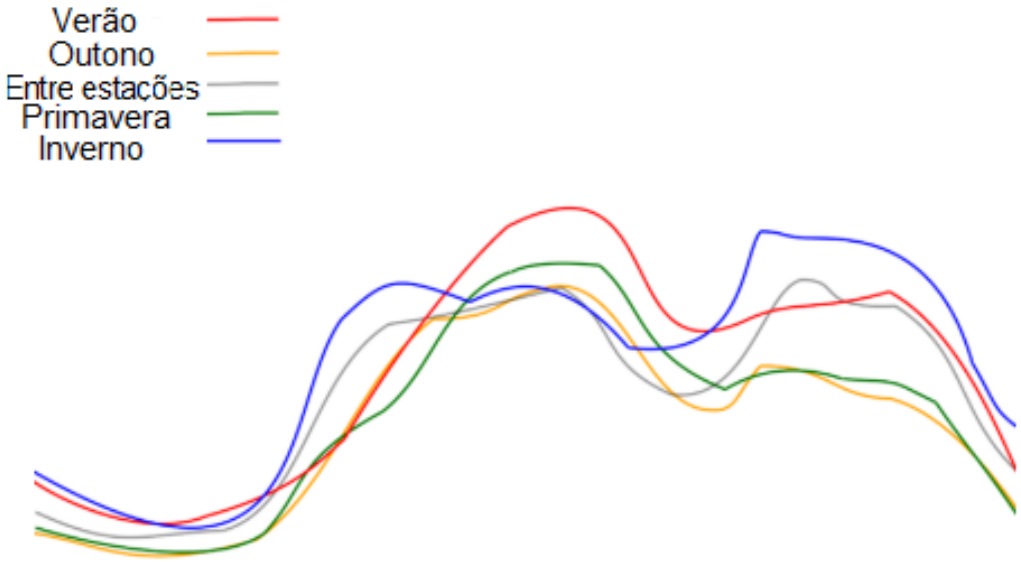


Figura 3.6: Perfil Diurno. Fonte:[1].

(5)Consumo durante a noite

Este perfil pertence principalmente à trabalhadores do turno noturno. As residências com foco noturno têm o inverso do padrão de uso de eletricidade das residências com foco no dia. A maior parte da atividade e consumo de eletricidade ocorre quando não há sol. Este tipo de curva de carga pode ser observado na Figura 3.7.

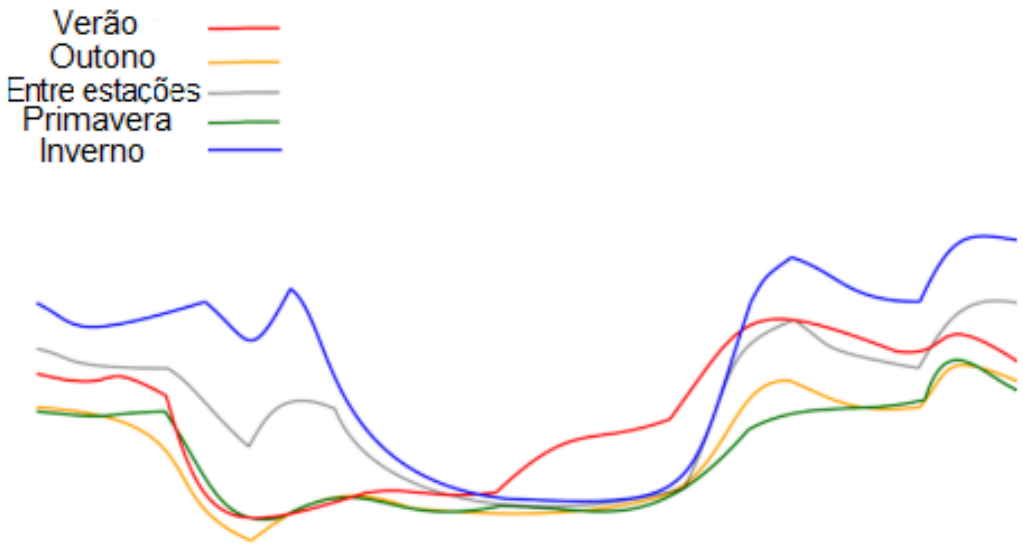


Figura 3.7: Perfil Noturno Fonte:[1].

É importante ressaltar que as características mostradas nestes perfis de carga certamente irão mudar com o passar do tempo à medida em que os comportamentos mudam, as crianças crescem e as pessoas mudam de localidade. Mas, tomá-los como uma referência é um primeiro passo importante para que o indivíduo gerador e consumidor de eletricidade tenha uma maior consciência e busque maiores informações para tornar-se mais eficiente.

3.3 Aplicação do Algoritmo K-Means para Segmentação de Perfis

Após carregar a base de dados para o ambiente *Python* e realizar o tratamento o tratamento de seu conteúdo, para este projeto, foi utilizado a biblioteca para aprendizado de máquina para *Python*, *scikit-learn*. Esta biblioteca além de possuir uma grande quantidade de ferramentas nos campos de análise de dados e *data mining*, disponibiliza textos explicativos e códigos fontes exemplificando cada uma delas.

O algoritmo *k-means* presente na biblioteca utilizada exige duas entradas, o número k, que representa o número de agrupamentos desejados e os dados, contendo as características específicas a serem analisadas. Para que seja obtidos os 5 tipos de curvas típicas de consumidores de energia mostrados na seção 3.2, será utilizado k=5, juntamente aos dados selecionados e tratados para períodos das 4 estações do

ano como as entradas para o algoritmo.

O diagrama de blocos da Figura 3.8 sintetiza a metodologia para obtenção do resultado deste trabalho, que será mostrado no capítulo 4.

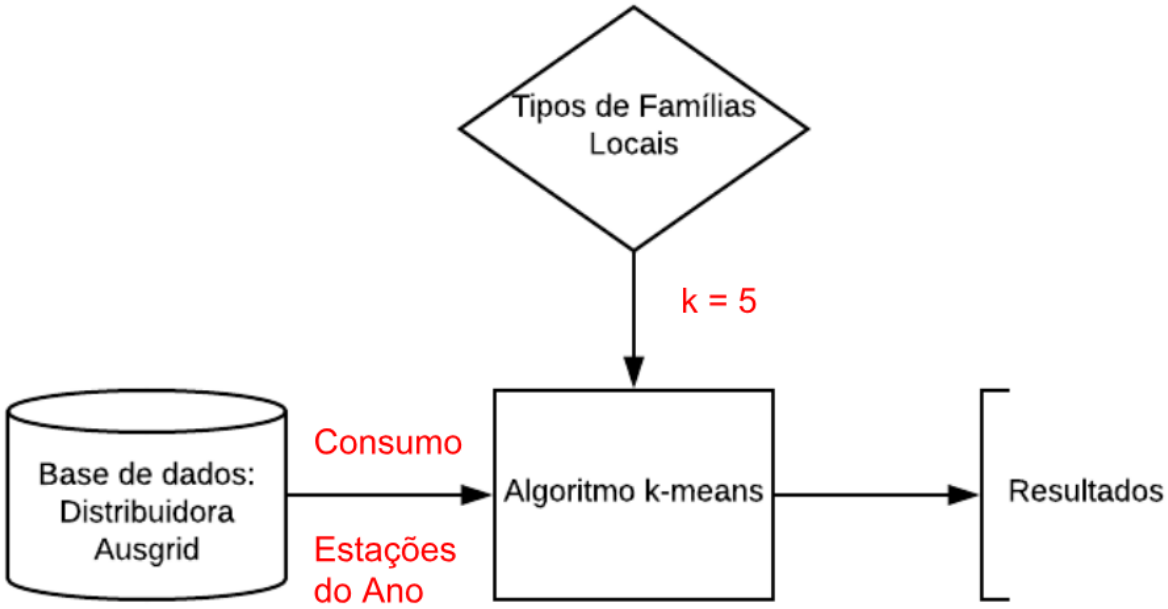


Figura 3.8: Diagrama de blocos da síntese da metodologia proposta

Capítulo 4

Simulações e Resultados

Neste capítulo, a análise de agrupamento é aplicada seguindo a metodologia mostrada no capítulo 3 e sintetizada no diagrama de blocos mostrado na Figura 3.8.

4.1 Segmentação de Perfis de Consumo de Energia Obtidos

O período de verão tem início no primeiro dia de dezembro e se finaliza no dia 28 de fevereiro. Neste período ocorre as férias coletivas de grande parte da população analisada e, portanto, as curvas terão um formato consideravelmente distinto das curvas que serão analisadas mais a frente que contém famílias com crianças em período escolar. É possível observar na Figura 4.1 que a média de consumo é inferior aos meses de inverno, possivelmente por motivos de viagens durante este período e menor uso de chuveiros elétricos e aquecedores, os quais possuem grande influência no consumo diário residenciais.

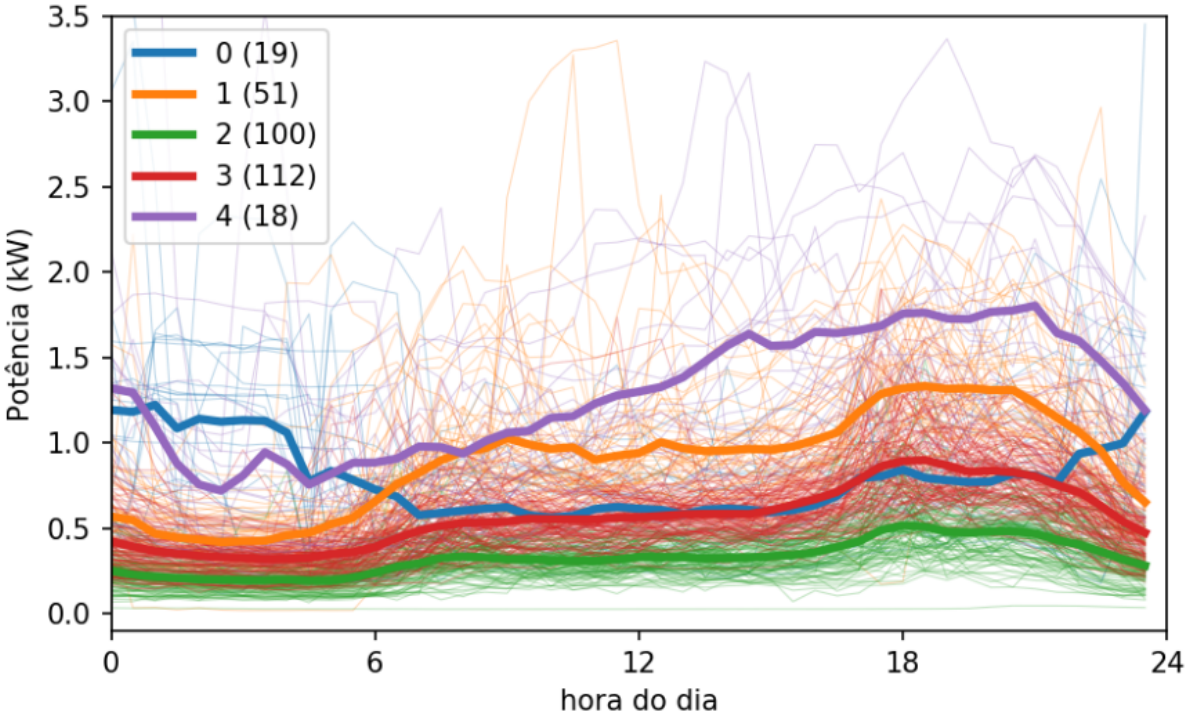


Figura 4.1: Consumo médio diário durante o verão

No período de inverno, o qual tem início do dia 1 de julho e vai até o dia 30 de agosto, pode ser observado o resultados de segmentação das curvas de consumo com maior semelhança em relação às curvas consideradas no Capítulo 5. O resultado da segmentação deste período pode ser observado na Figura 4.2.

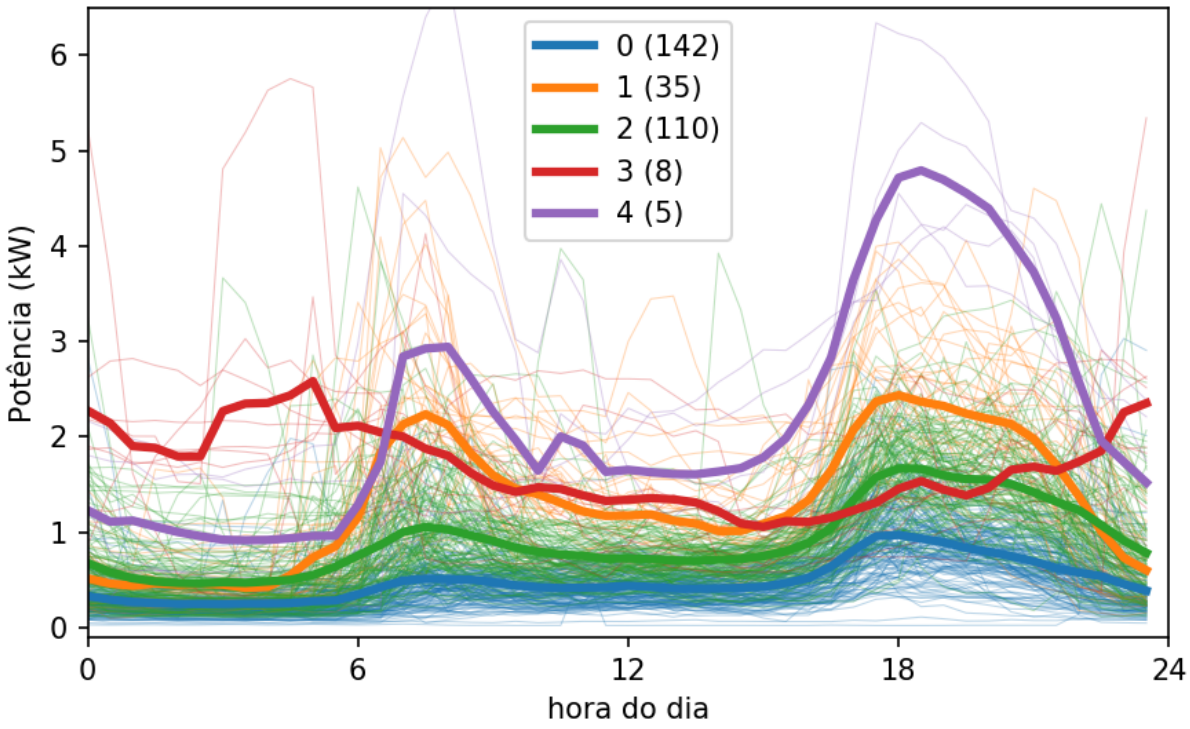


Figura 4.2: Consumo médio diário durante o inverno

Os período de primavera, que tem inícios em 1 de setembro e se finaliza em 30 de novembro, possui uma média de consumo de energia elétrica inferior à observada no período de inverno, assim como observado no período de verão. Durante esta estação, as curvas possuem picos mais acentuados quando comparados ao verão e menos evidentes quando comparadas ao inverno. Esse fato ocorre provavelmente pela temperatura mais amena, mas que necessita de aparelhos de grande influência na aparência destas curvas, como por exemplo, a utilização do chuveiro elétrico em temperaturas mais altas em dias um pouco mais frios.

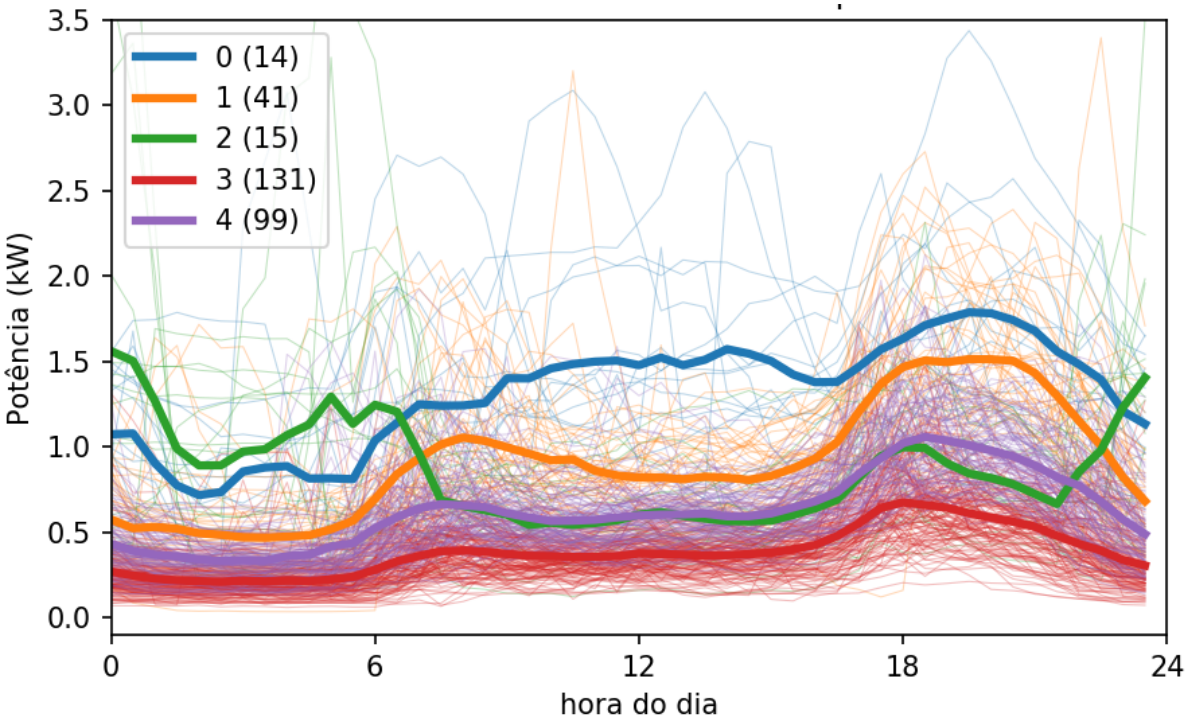


Figura 4.3: Consumo médio diário durante a primavera

No período do outono, , possuem picos de consumo mais acentuados, assim como no inverno, o que facilita a interpretação baseada nas referências mostradas no Capítulo 5. Durante o outono, a temperatura média é inferior às estações de verão e primavera e, portanto, o consumo residencial aumenta em relação a estas estações.

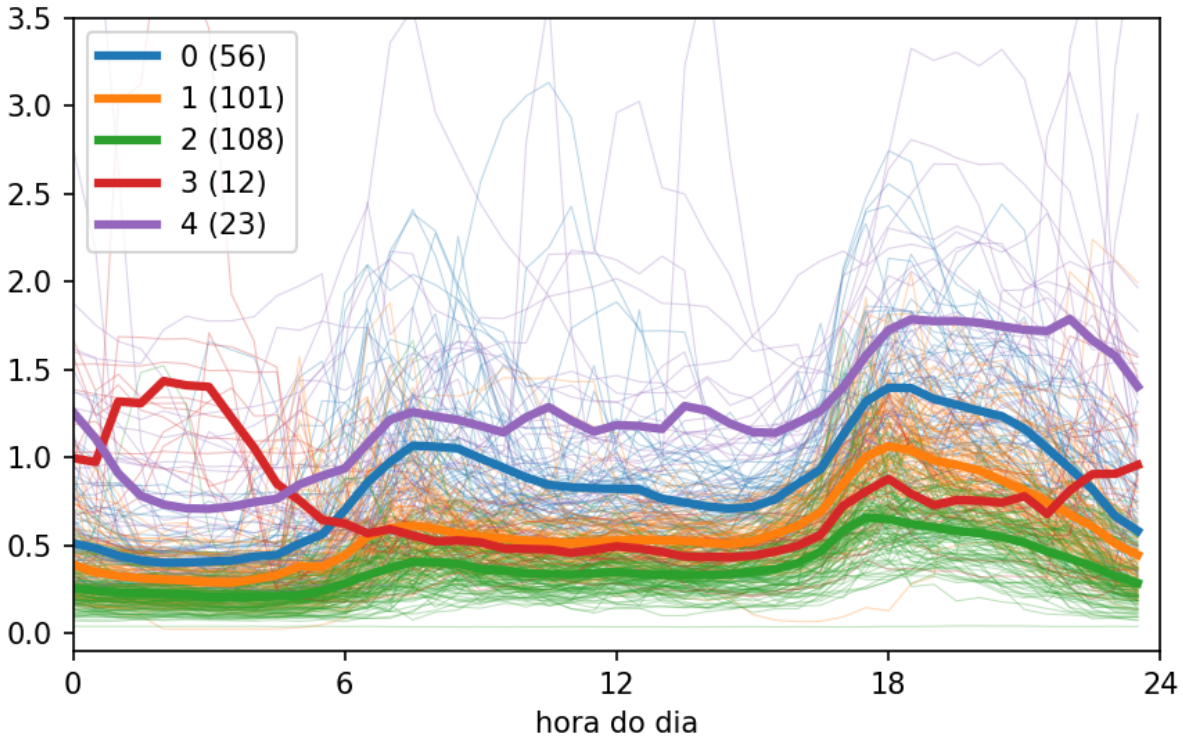
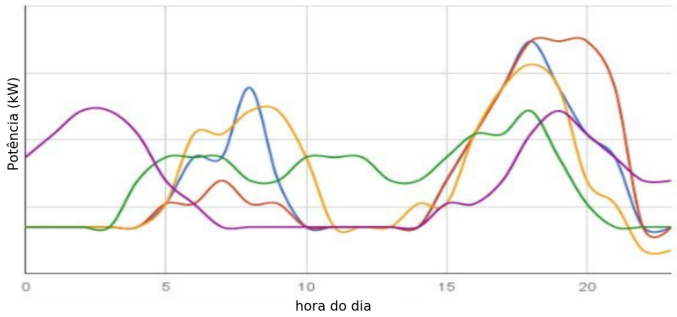


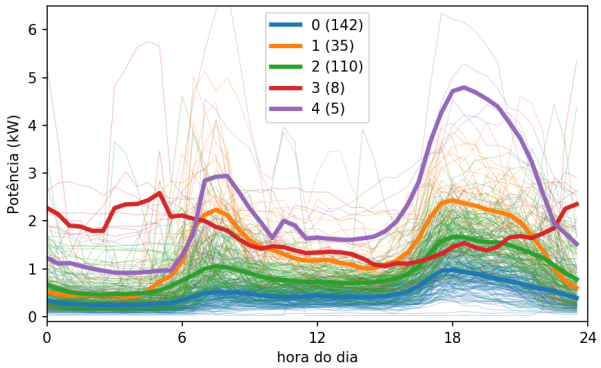
Figura 4.4: Consumo médio diário durante o outono

4.2 Interpretação dos Resultados

Realizando a comparação entre a curva de inverno obtida nos resultados da segmentação de perfis de consumo e as curvas de referências das premissas utilizadas de [1] através das figuras abaixo, podemos obter as interpretações mostradas na Tabela 4.1.



Referência de [1]



Curva Média Diária de Inverno

Tabela 4.1: Comparação entre os segmentos da referência de premissas e os resultados para o mês de inverno.

Segmento na curva de inverno	Tipo de Curva Típica	Quantidade de consumido
1	Picos: Manhã e tarde	35
4	Picos: Final de tarde e noite	5
2	Picos: Manhã e tarde com consumo diário distribuído	110
0	Consumo durante o dia	142
3	EConsumo durante a noite	8

4.3 Aplicação dos Resultados

Há diversas aplicações para a segmentação de padrões de perfis de consumidores residenciais de energia elétrica para o mercado de energia, entre elas, é possível observar é possível observar o comportamento das curvas de demanda de energia, juntamente com a geração fotovoltaica média estimada para a região de Sidney na Austrália e relacionar a uma breve análise de autoconsumo, para residencias sem sistemas de armazenamento instalados junto aos sistemas fotovoltaicos.

Através de aproximações dos perfis utilizados como referência dos 5 tipos de padrões de consumo em uma calculadora solar desenvolvida pela empresa *Solar Choice* [4] é possível observar os gráficos gerados, utilizando para o estimador: 20kWh de consumo de eletricidade com um sistema fotovoltaico instalado de 5kW - a única coisa que muda são os perfis de padrões de consumo para as Figuras 4.5, 4.6, 4.7, 4.8 e 4.9.



Figura 4.5: Picos: Manhã e tarde



Figura 4.6: Picos: Final da tarde e noite

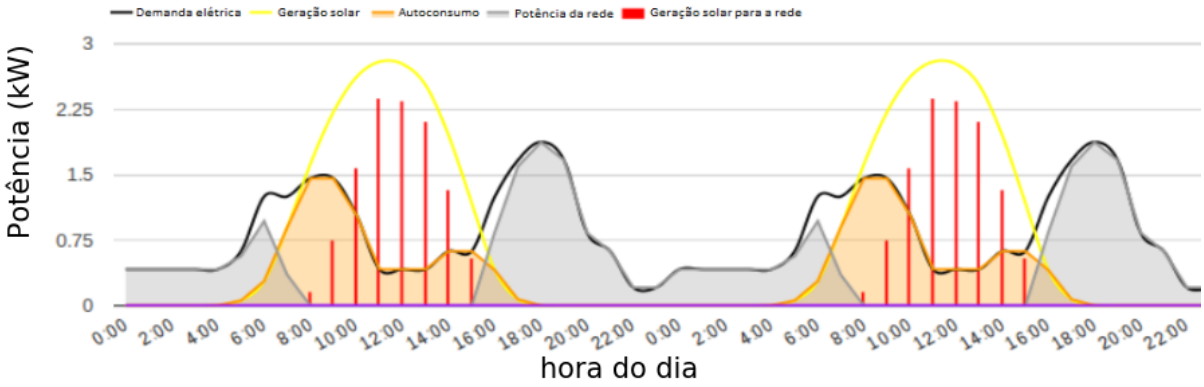


Figura 4.7: Picos: Manhã e tarde com consumo diário distribuído

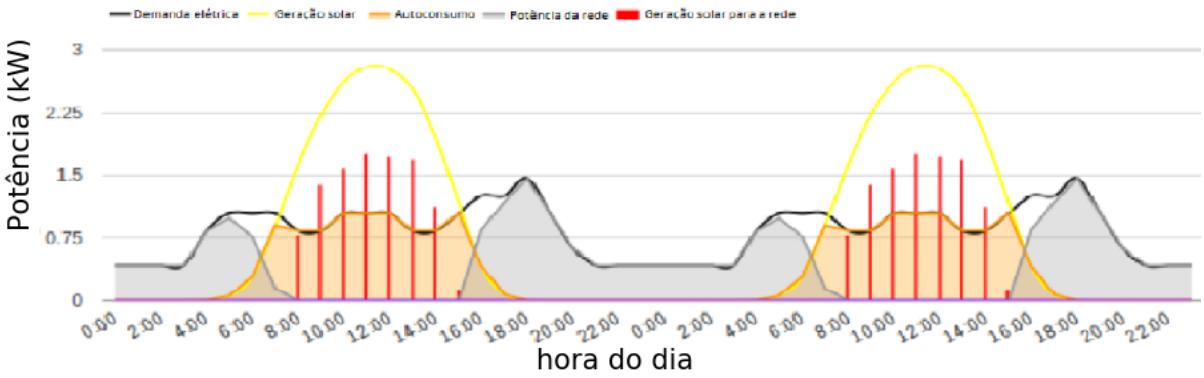


Figura 4.8: Consumo durante o dia

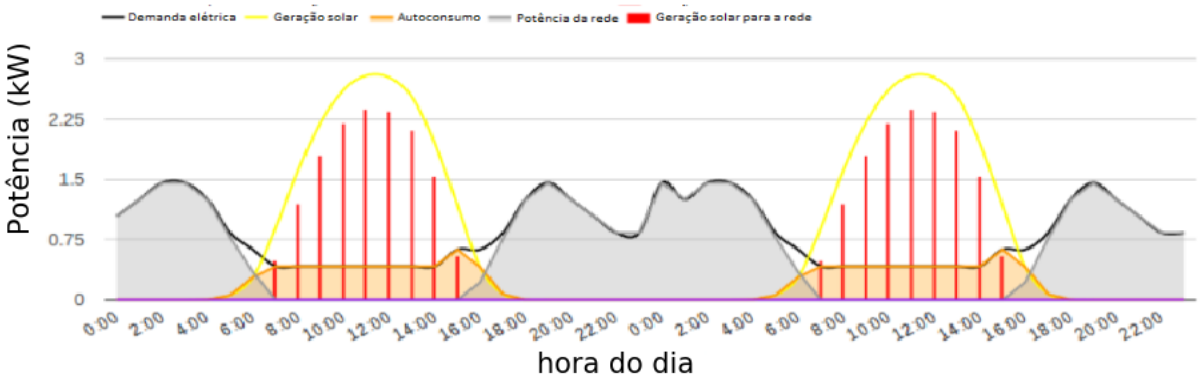


Figura 4.9: onsumo durante a noite

Capítulo 5

Conclusões, Observações Finais e Trabalhos Futuros

5.1 Conclusões

O objetivo inicial deste projeto final de graduação era de criar uma metodologia de segmentação de perfis de consumo de energia elétrica em residencias, sendo que a base de dados utilizada são de residencias com sistemas fotovoltaicos instalados. Através dos resultados da segmentação de perfis, foi possível observar que é a metodologia traz resultados plausíveis através da comparação com a premissa utilizada.

É interessante mencionar que as diferenças entre os grupos de *clusters* sempre podem ser explicados apenas até certo ponto, nunca inteiramente. E mesmo que uma residência tenha uma alta probabilidade, de acordo com suas características, de se enquadrar em um determinado grupo, isso dependerá do ponto de vista da análise que está sendo realizada. Como sempre neste campo de pesquisa, todas as conclusões são contestáveis e precisam ser questionadas e discutidas.

5.2 Observações Finais

É importante ressaltar que os gráficos destinam-se apenas a fornecer informações gerais sobre a utilização da eletricidade de uma casa ao longo do dia e, como tal, não incluem valores de utilização reais - apenas os padrões ao longo de um período de 24 horas.

Além disso, é interessante observar que nenhuma das análises leva em conta os possíveis benefícios da instalação de um sistema de armazenamento de energia. O armazenamento de energia permite uma maior flexibilidade quando a energia solar pode ser utilizada - permitindo consumir a sua própria energia mesmo depois de o

sol ter baixado.

No que diz respeito aos dados utilizados, é muito positivo o fato de existirem um abrangente banco de dados de cargas individuais disponíveis. No entanto, é uma desvantagem que os dados foram registrados em 2011 e 2012 e o possível efeito da substituição de lâmpadas convencionais por LEDs não pôde ser analisado. Além disso, todos os domicílios medidos estão situados em cidades de média ou grande população. Se houvesse uma localidade em área rural, por exemplo, talvez fosse possível a observação de uma nova segmentação.

De uma forma geral, este tema foi escolhido para compreender o funcionamento de um algoritmo não supervisionado muito popular no campo de aprendizado de máquinas para aplicação em um problema real e utilizar a criatividade juntamente com conhecimentos mais específicos em determinados temas para extrair ideias e observações acerca de eficiência energética e este objetivo foi concretizado de maneira concisa, mas deixando com que trabalhos futuros possam ocorrer para dar continuidade a esta ideia.

Algumas sugestões para trabalhos futuros são:

- Realizar uma análise econômica mais aprofundada
- Realizar um estudo com a aplicação conjunta a um sistema de armazenamento;
- Utilizar a metodologia deste trabalho para outros tipos de análises de agrupamentos tais como: Segmentação de consumo de energia anual, semanal, entre outros períodos.

Referências Bibliográficas

[1] JOHNSTON, W. "Solar pays its way on networks. It's no free rider". 2014. Disponível em: <https://reneweconomy.com.au/solar-pays-its-way-on-networks-its-no-free-rider-29167/>.

[2] F. RODRIGUES, J. DUARTE, V. F. Z. V. M. C. "A comparative analysis of clustering algorithms, applied to load profiling", *Proceedings of MLDM*, pp. 73–85, fev. 2003.

[3] SILIPO, R., WINTERS, P. *Big data, Smart Energy, and Predictive Analytics", type* =. Relatório técnico.

[4] CHOICE, S. "Solar PV Solar System Sizing Tool". 2017. Disponível em: <https://www.solarchoice.net.au/blog/solar-pv-solar-system-sizing-tool>.

Apêndice - Código realizado

August 28, 2018

1 Bibliotecas

```
In [92]: import numpy as np
         import pandas as pd

         import sklearn
         from sklearn.cluster import MeanShift, estimate_bandwidth, KMeans, DBSCAN

         import matplotlib as mpl
         import matplotlib.pyplot as plt

         %matplotlib inline

         pd.__version__
```

```
Out[92]: '0.22.0'
```

2 Download do dataset

```
In [93]: # Load the "Individual Household Consumption" dataset

         fname = "C:/Users/jessi/Desktop/solar_home_dataset/2011-2012.csv"

         data = pd.read_csv(fname, low_memory=False)

         #display (data)
```

Parse CSV

```
In [94]: d_raw = pd.read_csv(fname, skiprows=1,
                            parse_dates=['date'], dayfirst=True,
                            na_filter=False, dtype={'Row Quality': str})
```

3 Reformulando a base de dados

Objetivo:

- Reformular o tempo, para timestamp combinando dia e hora;
- pivotear as categorias de consumidores e o consumo como colunas

```
In [102]: from pandas.tseries.offsets import Day

In [103]: d1
          d1 + Day(1)

Out[103]: Timestamp('2012-07-01 00:00:00')
```

4 Criando o novo DataFrame

Começando por criar um DataFrame em branco

```
In [109]: empty_cols = pd.MultiIndex(
              levels=[customers, channels],
              labels=[[],[]],
              names=['Customer', 'Channel'])

In [110]: df = pd.DataFrame(index=index, columns=empty_cols)
          #df
```

Preenchendo as colunas

```
In [111]: missing_records = []

          for c in customers:
              d_c = d_raw[d_raw.Customer == c]

              # TODO: save the row quality
              #print(c, end=', ')

              for ch in channels:
                  d_c_ch = d_c[d_c['Consumption Category'] == ch]
                  ts = d_c_ch.iloc[:,5:-1].values.ravel()
                  if len(ts) != len(index):
                      missing_records.append((c,ch, len(ts)))
                  else:
                      df[c, ch] = ts
```

Analizando as gravações imcompletas e ausentes:

- 162 dados ausentes (de 900)
- 161 são de ausência de dados do canal CL
- 1 é proveniente de dados incompletos do canal CL (de 2011-07-01 à 2012-01-12)

```
In [112]: #len(columns)
          #len(missing_records)
```

```
In [113]: n_empty_CL = 0
          missing_records_others = []
          for (c, ch, len_ts) in missing_records:
              if ch=='CL' and len_ts==0:
                  n_empty_CL += 1
              else:
                  missing_records_others.append((c, ch, len_ts))
          n_empty_CL

Out[113]: 161

In [114]: missing_records_others

Out[115]: 24522   2011-07-01
          25107   2012-01-12
          Name: date, dtype: datetime64[ns]
```

Conversão de unidades: kWh para kW:

- As gravações originais do CSV estão em kWh para intervalos de 30 minutos

```
In [117]: #df[1].mean()
          df *= 2
          #df[1].mean()
```

5 Plotagens para Análises

Consumidor X contendo os 3 canais:

```
In [118]: df[1]['2011-07-01':'2011-07-03'].plot()
          plt.title('Customer 1 in July')
          plt.ylabel('kW')
          #plt.savefig('Customer 1 2012-07 01-03.png', dpi=150);

Out[118]: Text(0,0.5,'kW')
```

Selecionando um canal específico, entre todos os consumidores

```
In [128]: dfGC = df.xs('GC', level='Channel', axis=1)
          dfGCverao = dfGC['2011-12-30':'2012-02-28']
          dfGCinverno = dfGC['2011-07-01':'2011-08-31']
          dfGCprimavera = dfGC['2011-09-01':'2011-11-30']
          dfGCoutono = dfGC['2012-03-01':'2012-05-31']
          #dfGCverao.plot()
          #dfGC[[1]]

Out[129]: Text(0,0.5,'kW')
```

6 Análise para Padrões

Dividir o consumo em dois canais

- Consumo geral
- Carga controlada

```
In [130]: dfGC = df.xs('GC', level='Channel', axis=1)
          dfCL = df.xs('CL', level='Channel', axis=1)
```

** Padrões diários de consumo (não controlados) **

- Média de um ano para cada meia hora do dia

```
In [143]: def hod(tstamp):
              'hour of the day (fractional))'
              return tstamp.hour + tstamp.minute/60

          dfGCverao_dpat = dfGCverao.groupby(by=hod).mean()
          dfGCinverno_dpat = dfGCinverno.groupby(by=hod).mean()
          dfGCprimavera_dpat = dfGCprimavera.groupby(by=hod).mean()
          dfGCoutono_dpat = dfGCoutono.groupby(by=hod).mean()

In [133]: loc_6h = mpl.ticker.MultipleLocator(6)

In [161]: ax = dfGC_dpat.plot(color='g', alpha=0.15, lw=0.5)
          dfGC_dpat.mean(axis=1).plot(color='tab:orange', lw=3, alpha=0.7)

          ax.xaxis.set_major_locator(loc_6h)
          plt.legend(ax.lines[-1:], ['média'])
          ax.set(
              xlabel='Hora do dia',
              ylabel='Potência (kW)',
              ylim=(-0.1, 3.5),
              title='Média do consumo diário durante o verão de 2012'
              );

          plt.tight_layout()
          plt.savefig('GC_medio.png', dpi=150);

In [163]: #dfGC_dpat_norm

In [164]: ax = dfGCverao_dpat_norm.plot(color='g', alpha=0.15, lw=0.5)
          dfGCverao_dpat_norm.mean(axis=1).plot(color='tab:orange', lw=3, alpha=0.7)

          ax.xaxis.set_major_locator(loc_6h)
          plt.legend(ax.lines[-1:], ['média'])
          ax.set(
              xlabel='Hora do dia',
```

```
            ylabel='Potência / média por consumidor',
            title='Consumo médio diário normalizado verão de 2012'
            );

        plt.tight_layout()
        plt.savefig('GCverao_day_norm.png', dpi=150);
```

7 Clusterizando padrões diários de consumo

Objetivo: Mostrar diferentes tipos de consumidores, baseando-se nas diferenças de padrões diários de consumo

Os resultados da comparação das clusterizações são:

- Usando a forma normalizada e não normalizada
- Usando diferentes tipos de algorítimos de clusterização (Guia do scikit-learn)

Matriz de características:

Criar uma matriz contendo as características no formato padrão do scikit-learn (n_samples, n_features).

- n_samples: número de consumidores (300)
- n_features: é o número de períodos durante um dia (48 - já que temos intervalos de 30 minutos)

```
In [165]: Xverao = dfGCverao_dpat.transpose()
          Xnverao = dfGCverao_dpat_norm.transpose()
          Xinverno = dfGCinverno_dpat.transpose()
          Xninverno = dfGCinverno_dpat_norm.transpose()
          Xprimavera = dfGCprimavera_dpat.transpose()
          Xnprimavera = dfGCprimavera_dpat_norm.transpose()
          Xoutono = dfGCoutono_dpat.transpose()
          Xnoutono = dfGCoutono_dpat_norm.transpose()
```

K-means

- com 5 clusters

```
In [166]: km_5verao = KMeans(5).fit(Xverao)
          km_5inverno = KMeans(5).fit(Xinverno)
          km_5primavera = KMeans(5).fit(Xprimavera)
          km_5outono = KMeans(5).fit(Xoutono)
          pd.Series.value_counts(km_5verao.labels_)

Out[166]: 3    112
          2    100
          1     51
          0     19
          4     18
          dtype: int64
```

In [168]:
```
t_hod = dfGC_dpat.index

def plot_daily_cluster(cl, X, **ax_kwarg):
    '''plot clusters of classifier `cl` with data `X`'''
    labels = cl.labels_

    # samples, colored with their membership
    for k in np.unique(labels):
        color = 'C{}'.format(k) if k>=0 else 'black'
        plt.plot(t_hod, X.iloc[labels == k, :].T,
                 color=color, alpha=0.3, lw=0.5,
                 #drawstyle='steps-post',
                );

    # cluster centers
    for k in np.unique(labels):
        n_member = np.sum(labels == k)
        if k>=0:
            color = 'C{}'.format(k)
            plt.plot(t_hod, cl.cluster_centers_[k],
                     label='{} ({})'.format(k, n_member),
                     color=color, lw=3);

    ax = plt.gca()
    ax.set(
        xlim=(0, 24),
        xlabel='hora do dia'
    )
    ax.xaxis.set_major_locator(loc_6h);
    ax.set(**ax_kwarg)
    plt.tight_layout()
    plt.legend()
```

In [179]:
```
plot_daily_cluster(km_5inverno, Xinverno,
                   title='Consumo médio diário durante o inverno',
                   ylabel='Potência (kW)')
plt.ylim(-0.1, 6.5)
plt.savefig('inverno.png', dpi=150)
```