Projeto em Ciência de Dados

Trabalho 1 – Análise Exploratória

Prof. Fernando Vieira da Silva, M.Sc.

O objetivo deste trabalho é explorar e entender melhor as características dos dados que serão utilizados durante o Trabalho de Conclusão do Curso. Use os conhecimentos adquiridos nas disciplinas de Visualização de Dados, Estatística e Programação em Python para Ciência de Dados. Dica: aproveite essa oportunidade para tirar suas próprias dúvidas sobre os dados e conhecer melhor o problema que você escolheu estudar. Este trabalho deve ser entregue em forma de um notebook Jupyter.

1 – Observe os dados inconsistentes. Quais campos possuem registros faltantes? (Zero, vazio, negativo, NaN, etc). Quais possuem valores fora da faixa esperada? (ex: em um dataset com dados de pessoas, há registros de altura maior que 2,5m?). Qual a proporção em relação aos dados corretos? Para cada uma das campos com dados faltantes, qual sua proposta para tratar os dados? (ex: pretende preencher de alguma forma? Se sim, como?) (3 pontos)

2 – Liste as principais dúvidas sobre os dados (pelo menos 5). Seja específico e faça perguntas que possam te ajudar a escolher quais campos serão úteis e podem te ajudar a ter ideias de como montar sua solução no futuro. Também faça perguntas que te ajudem a identificar campos irrelevantes e que devem ser descartadas no futuro. Questões simples como "Qual a média/variância/desvio padrão do campo X?" não serão aceitas, mas perceba que pode ser interessante realizar esses cálculos para ter respostas de questões mais elaboradas. Você também pode elaborar uma questão como essa, desde faça esses cálculos para todos os campos, por exemplo: "Qual é a média, variância e desvio padrão de cada campo numérico do dataset?" (2 pontos).

Exemplos:

- Em um *dataset* com histórico de preços de ações, qual a correlação entre o volume comercializado e o preço?

- Em um *dataset* com tweets anotados com sentimentos positivo e negativo, quais palavras que estão entre as 10 mais frequentes em um *subset* que não estão entre as 10 mais frequentes de outro?

- Em um *dataset* de imagens, todas as imagens possuem a mesma resolução?

- Em um *dataset* com dados de temperatura por dia, a média, variância e desvio padrão mudam de mês a mês para máxima e mínima diárias? E de ano a ano?

- Em um *dataset* com dados de venda de um produto por dia, qual é a distribuição mensal da quantia e do valor total de produtos vendidas por mês para cada categoria de produto?

- Em um *dataset* de mensagens trocadas em chat, quais as 20 palavras mais frequentes que não existem no vocabulário do idioma estudado?

3 – Plote gráficos para responder às questões levantadas acima. Escolha os gráficos mais adequados para cada questão. Seja convincente e didático: pense que o observador pode não entender sobre o problema, como convencê-lo das suas afirmações? Capriche na apresentação! Faça uso de cores, legendas e outros recursos que deixem os gráficos visualmente agradáveis. (3 pontos)

4 – Para cada uma das questões que você elaborou no exercício 2, escreva uma breve conclusão após as observações feitas no exercício 3. Seja realista, tome suas conclusões com base nos dados e tome cuidado para não fazer afirmações difíceis de serem suportadas pelas suas análises (2 pontos).