Projeto em Ciência de Dados

Trabalho 02 – Revisão Bibliográfica

Faculdade de Engenharia de Sorocaba.

Prof. Fernando Vieira da Silva, M.Sc.

Alunos:
José Diniz Junior RA: 183134
Roberto Leonardo Rodrigues RA: 060235

1º. Artigo

O primeiro artigo analisado foi o ‘Assessing the Utility of Weather Data for Photovoltaic Power Prediction’ (Avaliando a utilidade de dados climáticos para previsão de energia fotovoltaica).

O objetivo desse artigo é através de informações meteorológicas, obter dados que possam ajudar a prever melhor a geração de energia fotovoltaica.

Tendo como dataset utilizado fornecido pela Greenview Energy Mangament Systems, que abrange o período de 29 de junho de 2016 a 25 de fevereiro de 2017 e que apresenta 100 parâmetros de painéis solares instalados na cidade de Syracuse, NY, sendo esses dados divididos em:

- Dados Meteorológicos;
- Dados do medidor;
- Dados de radiação solar;

Foram utilizados duas técnicas de regressão:

- LASSO - Least Absolute Shrinkage and Selection Operator;
- Regressão Linear;

Primeiramente, os autores começaram com a previsão de energia solar, utilizando LASSO tanto para seleção de variável como para regularização. Em seguida realizaram uma avaliação dos resultados utilizando a média dos valores atuais com os valores medidos (MSE - Mean Squared Error) e descobriram que quanto menor o MSE, mais preciso fica o algoritmo. Aplicaram o LASSO no dataset com valores padrões o obtiveram um valor de MSE de 5.5436, encontraram a constante α que afeta diretamente a precisão do modelo e treinaram o modelo variando o α, encontrando valores diferentes de MSE. Realizaram novamente o mesmo procedimento utilizando Regressão Linear e obtiveram um MSE de 5.4248, o que definiu a utilização de regressão linear para a previsão.

Foi utilizado o método de regressão linear para selecionar 25 campos com maiores valores de coeficientes, obtendo o valor de MSE para cada um deles, descobriu-se que o campo ‘input1A’ referente à irradiação solar instantânea e o campo ‘day1tempMaxF’ referente à mediação de temperatura em Fahrenheit apresentavam valores altos de MSE. A partir desse ponto, os autores partem para limitar a quantidade de dados meteorológicos a fim de determinar com quanto tempo de dados é possível obter previsões precisas, novamente com base nos valores de MSE, descobriu-se que a partir de dois meses, com amostras de 5000 valores, as flutuações dos valores de MSE eram consideravelmente pequenas.

Com esse estudo, os autores concluíram que a regressão linear tem um desempenho melhor que o LASSO e que dois meses de dados eram suficientes para treinar o modelo sem afetar a precisão.

2º. Artigo

O segundo artigo analisado foi o ‘A Predictive Model for Solar Photovoltaic Power using the Levenberg-Marquardt and Bayesian Regularization Algorithms and Real-Time Weather Data’ (Um Modelo Preditivo para Energia Solar Fotovoltaica usando os Algoritmos de Regularização Bayesiana e Levenberg-Marquardt e Dados Meteorológicos em Tempo Real).

O objetivo da pesquisa é propor um modelo de previsão eficiente para prever a geração da energia fotovoltaica do dia seguinte.

Para os dados, foi utilizado um dataset com dados de um painel fotovoltaico (PV ASU09) e dados meteorológicos coletados entre 16 de maio de 2015 a 15 de maio de 2016, totalizando 17.544 registros sucessivamente.

Basicamente, a ideia dos autores se resume em:

- Com os dados do painel fotovoltaico e os dados da estação meteorológica, realizar um filtro e gravar as associações - que consiste aplicar um filtro que garante a consistência dos dados, como dados meteorológicos sem valores de energia do painel fotovoltaico e vice versa. A associação foi encontrada com o comparativo dos dados;
- Normalizar os dados – visando a obtenção de dados homogêneos e resultados de aprendizado de máquina confiável, os dados foram normalizados entre 0 e 1;
- Utilizar uma rede neural – Os autores decidiram em utilizar as Redes Neurais artificiais (ANNs) pelo desempenho de aprendizado e classificação, optando pelo uso dos algoritmos Levenberg-Marquardt (LM) e pela Bayesian Regularization (BR), onde que para ambas é utilizado o peso dos erros quadráticos médios para se medir o desempenho;
- Aplicar regras de decisão – dois modelos foram criados com base nos algoritmos LM e BR, tendo como entradas os registros de data e hora e vetores de tempo e saída como potência média do painel fotovoltaico. Realizaram vários experimentos e avaliaram o desempenho calculando o RMSE médio;
- Com os resultados obtidos, prever as próximas 24 horas – Com o conjunto de dados associados, os autores utilizaram como fonte de aprendizado de rede neural, que utiliza dados climáticos em tempo real a fim de fornecer previsões de energia fotovoltaica para as próximas 24 horas.

3º. Artigo

O artigo analisado foi o “Predictive Models for Photovoltaic Electricity Production in Hot Weather Conditions” (Modelos preditivos para produção de eletricidade fotovoltaica em condições de clima quente).

Tendo como objetivo propor um modelo matemático para previsão de produção de energia em painéis fotovoltaicos baseado em um modelo de mapa de recurso auto-organizavel (SOFM), partindo da incerteza da saída do sistema fotovoltaico, que é afetada pela temperatura, umidade, radiação solar entre outros fatores.

O artigo apresenta também um comparativo do modelo proposto entre perceptron multicamadas (MLP) e máquina de vetores de suporte (SVM).

Para o desenvolvimento do artigo, foram instalados 24 painéis fotovoltaicos (140 W com eficiência de 13,9%) na universidade de Sohar em Oman, devido ao alto potencial de energia solar desta região. No período de julho de 2013 a agosto de 2014, foram monitorados e registrados parâmetros elétricos como tensão, correntes e potencia. Foi utilizado um sensor de radiação solar dedicado para a medição da irradiação solar no mesmo período e um sensor de temperatura para a obtenção de dados das regiões do Golfo, chegando a conclusões que as medições eram próximas de uma região á outra e que o resultado do trabalho pode ser utilizado para as mesmas, com alguns ajustes.

Para o treinamento foi utilizando SOFM que possui dois processamentos de saídas (PE) como camadas de entradas, sendo a radiação solar e a temperatura ambiente, uma camada de saída (corrente do painel fotovoltaico) e uma camada oculta. O espaço de saída não supervisionado foi de 5 x 5.

Os dados coletados foram divididos em 40% para treinamentos, 40% para dados de validação e 20% para dados de testes;

Os autores utilizaram o (MSE - Mean Squared Error) para o comparativo e treino do SOFM variando-se o número de épocas. Os modelos com SOFM alcançaram uma taxa de precisão de 99%, o MLP alcançou uma taxa de 92% e o SVM uma taxa de 62%. Com o uso de modelos de regressão, foi possível criar uma nova curva de ajuste para assegurar que os modelos propostos alcancem uma boa curva de ajuste para os resultados alcançados. O modelo de previsão alcançou a previsão de corrente por 60 dias. Foram realizados comparativos variando-se as épocas, utilizando-se diversos critérios entre eles a média absoluta dos erros (MAE), a fim de verificar os resultados dos modelos, como segue na **Tabela 1**.

Model No.	Neural Networks Type	*MSE* for Training	*MSE* for Cross Validation	*R*	*MAE*	Accuracy
1	MLP-1000	0.0058	0.010	0.9849	3.639	92%
2	SVM-1000	0.1018	0.1274	0.9820	4.537	61%
3	SOFM-1000	0.0005	0.0006	0.9915	0.456	93%
4	SOFM-2000	0.0001	0.0001	0.9996	0.531	99%
5	SOFM-5000	0.00006	0.0001	0.9996	0.435	99%
6	SOFM-10000	0.00003	0.0001	0.9997	0.3615	99%

Tabela 1: Comparativo entre os modelos com a variação das épocas.

O modelo com menor valor de MAE, foi considerado o de melhor performance.

Com o uso de técnicas de redes neurais artificiais, os autores conseguiram criar um modelo matemático para a produção de corrente elétrica a partir de painéis fotovoltaicos.

4º. Artigo

O terceiro artigo analisado foi o “Machine Learning in PV Fault Detection, Diagnostics and Prognostics: A Review” (Aprendizado de Máquina na Detecção de Falhas em PV, Diagnóstico e Prognóstico: Uma Revisão).

O objetivo deste artigo é usar dados em tempo real do sistema para manter proprietários e investidores informados sobre o retorno do investimento, e usar detecção de falhas para agendar facilmente as visitas de manutenção. É usada a classificação para detectar e identificar falhas, enquanto a regressão é usada no diagnóstico do sistema fotovoltaico para a previsão de geração de energia e performance do sistema.

Mais de 150 documentos de pesquisa de sistemas fotovoltaicos foram identificados e analisados para este trabalho, apenas 90 deles foram considerados, pois incluem os tópicos que são discutidos neste trabalho, como técnicas de machine learning, análise de performance, detecção de falhas e predição de energia.

Para as análises foram considerados radiação solar, temperatura ambiente, umidade, velocidade do vento, e ainda temperatura, corrente e tensão do módulo fotovoltaico.

Os algoritmos foram agrupados por tribos, na **Tabela 2** temos as tribos relecionadas, na **Tabela 3** são listados os algoritmos ligados às tribos e a quantidade de pesquisas que usaram os respectivos algoritmos (algumas pesquisas usaram combinações de algoritmos).

	Tribe	Master Algorithm
Tribe 1	Symbolists	Inverse deduction / Induction
Tribe 2	Connectionists	Backpropagation
Tribe 3	Evolutionaries	Genetic Programming
Tribe 4	Bayesians	Probabilistic Inference
Tribe 5	Analogizers	Kernel Machines

Tabela 2: Técnicas de machine learning com algoritmos.

Tribes	MLT	#
Tribe 1 # 15	Random Forests (RF)	4
	Regression Tree (RT)	2
	Classification and Regression Decision Tree (CART)	2
	Functional Tree	2
	C.45 Decision Tree	1
	Best First Decision Tree	1
	Gradient Boosting	1
	Binary Tree Bagging	1
	Fuzzy Logic (FL)	1
Tribe 2 # 58	Artificial Neural Network (ANN)	41
	Extreme Learning Machine (ELM)	4
	Extension Neural Network	2
	Recurrent Neural Network (RNN)	2
	Neural Network Ensemble (NNE) Bagging Or Bootstrap Based Neural Network (BNN)	2
	Group method of data handling neural network (GMDH-type NN)	1
	Dynamic Recurrent Neural Network (DRNN)	1
	Deep Belief Network (DBN)	1
	Long Short-Term Memory networks (LSTM) Based on Recurrent Neural Network (RNN)	1
	Auto-LSTM Long Short-Term Memory networks	1
	Entropy Extreme Learning Machine (EELM)	1
	Online Sequential Extreme Learning Machine	1
Tribe 3 #2	Genetic Programming (GP)	1
	Genetic Algorithm (GA)	1
Tribe 4 # 10	Gaussian Process	6
	Monte Carlo Method	1
	Graph-based Semi-Supervised Learning	1
	Naïve Bayes Classification	1
	Bayesian Belief Network	1
Tribe 5 # 15	K – Nearest Neighbor (K-NN)	9
	Support Vector Machine (SVM)	6
	Support Vector Regression (SVR)	5
	SVR with Radial kernel	4
	Radial Basis Function	3
	Polynomial SVM or SVR	2
	K-Means Algorithm	2
	Linear SVM	1
	Local Outlier Factor (LOF)	1
	Locally Weighted Learning	1
	Local Linear Fitting / Regression	1
	Clustering by fast search and find of density peaks	1

Tabela 3: Relação de pesquisas com determinados algoritmos.

Analisando a tabela vemos a grande quantidade de pesquisas que usaram redes neurais artificiais, 41 trabalhos, e obtiveram resultados muito precisos, o segundo algoritmo que mais obteve êxito foi o KNN, usado em 9 trabalhos, principalmente para classificação, usado na detecção de falhas.

Conclusão

Analisando os artigos, é possível identificar que a maioria utilizou redes neurais artificiais como base dos modelos propostos, sempre utilizando a junção de dados de painéis fotovoltaicos e de estações meteorológicas. Os quatro artigos analisados obtiveram dados satisfatórios de acordo com as suas respectivas propostas.

Devido aos resultados encontrados, adotaremos a utilização de redes neurais artificiais para o modelo inicial, visando um modelo que possa ser utilizado para uma melhor previsão de geração de energia e uma melhor estimativa para investimento inicial de um sistema de painéis fotovoltaicos.

REFERÊNCIAS

ZAFARANI, R.; EFTEKHARNEJAD, S.; PATEL, U.: **Assessing the Utility of Weather Data for Photovoltaic Power Prediction**. Disponível em: <https://arxiv.org/pdf/1802.03913.pdf>. Acessado em: 09 dez. 2018.

MOHAMMAD H, A.; OLA, Y.; SOFYAN M. A. H.: **A Predictive Model for Solar Photovoltaic Power using the Levenberg-Marquardt and Bayesian Regularization Algorithms and Real-Time Weather Data**. International Journal of Advanced Computer Science and Applications (IJACSA), 9(1), 2018.

YOUSIF, J.H.; KAZEM, H.A.; BOLAND, J.: **Predictive Models for Photovoltaic Electricity Production in Hot Weather Conditions.** Energies 2017, 10, 971.

RODRIGUES, S.; RAMOS, H.; DIAS, M.: **Machine Learning in PV Fault Detection, Diagnostics and Prognostics: A Review.** IEEE Photovoltaic Specialists Conference IEEE-PVSC, 2017.