Processo Seletivo Itaú-Unibanco

Observações:

A interpretação das questões é parte integrante da avaliação.

Sempre que julgar apropriado, você pode usar softwares (e.g., R, Python, Weka, etc.) para resolver as questões.

O tempo de realização da prova será usado em sua avaliação. Inicie a prova imediatamente após o recebimento e envie suas respostas o mais rapidamente possível. O tempo máximo de prova é de 3 horas e você poderá retornar a qualquer questão dentro deste período, desde que não tenha finalizado a prova.

Nas questões de Verdadeiro/Falso, cada questão errada anula uma certa. Em caso de dúvidas deixe em branco.

Todas as questões têm pesos iguais e valem 1 ponto, com exceção das V ou F que têm peso de 0,1/cada.

Coloque a resposta final de cada questão com dois dígitos após a vírgula.

INICIAR

Módulo 1 – Não Supervisionado - Questão 1

a) Considerando os dados do arquivo dados_Q5.csv, execute o algoritmo Complete-Linkage e corte o dendrograma na altura 2,3. Qual a posição do centroide de cada grupo formado?

Módulo 1 – Não Supervisionado - Questão 1

Voltar Avançar

Módulo 1 – Não Supervisionado - Questão 1

b) Considerando os dados do arquivo dados_Q5.csv, execute o algoritmo Kmeans (com 10 iterações no máximo). Utilize como posição inicial dos centroides a posição calculada na questão anterior. Qual a posição final dos centroides?

Módulo 1 – Não Supervisionado - Questão 1

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 2

Considerando os dados do arquivo dados_Q4.csv, aplique a técnica PCA (*Principal Component Analysis*).
a) Qual é a fração da variabilidade total explicada pelo segundo componente principal?

Módulo 1 – Não supervisionado - Questão 2

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 2

Considerando os dados do arquivo dados_Q4.csv, aplique a técnica PCA (*Principal Component Analysis*).
b) Qual é o número mínimo de componentes necessários para explicar 99% da variabilidade dos dados?

Módulo 1 – Não supervisionado - Questão 2

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 3

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

3 - É possível calcular eficientemente as distâncias entre as instâncias mais próximas utilizando KD-Trees, que funciona melhor quando a dimensão das instâncias é pequena.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 4

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

4 - Quando falamos de similaridade cosseno em variáveis independentes positivas (como TF-IDF, por exemplo) sabemos que deve estar no intervalo [0, 1], em que 0 significa a maior distância.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 5

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

5 - O objetivo do algoritmo k-means é minimizar a soma dos quadrados das distâncias dos pontos aos centroides.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 6

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

6 - Diferente do k-means com distância euclidiana, o GMM (Gaussian Mixture Models) pode encontrar grupos com formato elipsoidal.

Verdadeiro

Falso

Voltar Avançar

Módulo 1– Não supervisionado - Questão 7

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

7 - As técnicas PCA e T-SNE são amplamente utilizadas porque conseguem reduzir o número de dimensões de uma base de dados, sem que haja perda de informações.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 8

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

8 - Silhueta é um índice que mensura a qualidade do agrupamento a qual favorece uma menor distância intracluster e uma grande distância extracluster.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 9

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

9 - O dendrograma permite visualizar os grupos formados em diferentes granularidades, sem ser necessário executar novamente o algoritmo.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 10

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

10 - Há dois tipos principais de algoritmos para Agrupamento hierárquico: Divisivos (ou top-down) e Aglomerativos (ou botton-up).

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 11

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

11 - O método SGD (Stochastic Gradient Descendent) é utilizado para treinar diversos tipos de modelos, tais como redes neurais, regressão logística e SVM.

Verdadeiro

Falso

Voltar Avançar

Módulo 1 – Não supervisionado - Questão 12

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

12 - No paradigma Map/Reduce, remover caracteres especiais de cada documento de um corpus (coleção de documentos) é um exemplo de Reduce.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 1

Considerando os dados do arquivo dados_Q1.csv, treine o modelo "Árvore de Classificação" (função de custo: entropia, sem podas) e utilize como metodologia de reamostragem a técnica validação cruzada sequencial (com 10 folds).
a) Qual é a média da medida acurácia nas partições de treino?

Módulo 2 – Classificação - Questão 1

Voltar Avançar

Módulo 2 – Classificação - Questão 1

Considerando os dados do arquivo dados_Q1.csv, treine o modelo "Árvore de Classificação" (função de custo: entropia, sem podas) e utilize como metodologia de reamostragem a técnica validação cruzada sequencial (com 10 folds).
b) Qual é a média da medida acurácia nas partições de validação?

Módulo 2 – Classificação - Questão 1

Voltar Avançar

Módulo 2 – Classificação - Questão 2

Considerando os dados do arquivo dados_Q3.csv, treine o modelo Regressão Logística (tipo de regularização: L1, fator de regularização: 0.1) utilizando a metodologia de validação holdout. Use para treino a primeira metade da base de dados, e as demais linhas para validação. Para fins de aproximação, considere que números menores que 0.001 são iguais a zero.
a) Qual é o valor da medida F1 Score para a partição de validação?

Módulo 2 – Classificação - Questão 2

Voltar Avançar

Módulo 2 – Classificação - Questão 2

Considerando os dados do arquivo dados_Q3.csv, treine o modelo Regressão Logística (tipo de regularização: L1, fator de regularização: 0.1) utilizando a metodologia de validação holdout. Use para treino a primeira metade da base de dados, e as demais linhas para validação. Para fins de aproximação, considere que números menores que 0.001 são iguais a zero.
b) Quantas variáveis influenciam as predições geradas pelo modelo treinado?

Módulo 2 – Classificação - Questão 2

Voltar | Avançar

Módulo 2 – Classificação - Questão 3

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

3 - A regressão logística utiliza o método de Mínimos Quadrados Ordinários na estimação dos parâmetros.

Verdadeiro

Falso

Voltar | Avançar

Módulo 2 – Classificação - Questão 4

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

4 - Na regressão logística, a variável dependente é contínua no intervalo entre [0,1].

Verdadeiro

Falso

Voltar | Avançar

Módulo 2 – Classificação - Questão 5

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

5 - Na regressão logística as variáveis independentes podem ser numéricas ou categóricas. O coeficiente associado a cada variável representa a variação do valor estimado quando esta aumenta em 1 unidade.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 6

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

6 - Em uma árvore de decisão pode-se avaliar a taxa de crescimento do erro de classificação para paralisar a divisão dos ramos.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 7

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

7 - No classificador SVM, pode-se alterar a função objetivo para permitir que alguns pontos caiam dentro da margem durante o treinamento.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 8

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

8 - O precision é uma medida de qualidade calculada pela fração de quantas predições positivas estão corretas, podendo ser utilizada tanto para algoritmos de classificação quanto de regressão.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 9

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

9 - O KNN, com distância euclidiana, é sensível à escala dos atributos usado para treiná-lo.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 10

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

10 - No processo de criação de ensembles, quanto mais correlacionadas forem as predições individuais de cada classificador, o ganho de desempenho do modelo final combinado tende a ser menor.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 11

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

11 - O algoritmo Naive Bayes assume dependência entre cada par de característica.

Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 2 – Classificação - Questão 12

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

12 - Combinar diversas árvores de decisão usando a técnica Bagging é o mesmo que treinar uma Random Forest.

Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 2 – Classificação - Questão 13

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

13 - Os métodos de ensemble com boosting combinam vários classificadores para produzir um classificador mais robusto.

Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 2 – Classificação - Questão 14

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

14 - Uma das formas de tratar problemas de classes desbalanceadas é incluir a informação a priori do número de amostras na função de custo a ser otimizada.

Verdadeiro

Falso

Voltar Avançar

Módulo 2 – Classificação - Questão 15

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

15 - Não é aconselhado a utilização da acurácia para problemas com classes desbalanceadas.

Verdadeiro

Falso

Voltar Avançar

Módulo 3 – Regressão - Questão 1

Considerando os dados do arquivo dados_Q2.csv, treine o modelo SVM (kernel: linear, fator de regularização: 0.1) e utilize como metodologia de reamostragem a técnica Leave-One-Out.
a) Qual é a média da medida MAE nas partições de treino?

Módulo 3 – Regressão - Questão 1

Voltar Avançar

Módulo 3 – Regressão - Questão 1

Considerando os dados do arquivo dados_Q2.csv, treine o modelo SVM (kernel: linear, fator de regularização: 0.1) e utilize como metodologia de reamostragem a técnica Leave-One-Out.
b) Qual é a média da medida MAE nas partições de validação?

Módulo 3 – Regressão - Questão 1

Voltar Avançar

Módulo 3 – Regressão - Questão 2

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

2 - Para problemas de regressão com duas variáveis independentes altamente correlacionadas, enquanto o Lasso tem maior chance de escolher aleatoriamente uma delas, o método *Elastic Net* pode selecionar ambas.

Verdadeiro

Falso

Voltar Avançar

Módulo 3 – Regressão - Questão 3

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

3 - L1 e L2 são ambos componentes de regularização cujo objetivo é tratar o *overfitting* exclusivamente para problemas de regressão.

Verdadeiro

Falso

Voltar Avançar

Módulo 3 – Regressão - Questão 4

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

4 - Em um problema de regressão utilizando KNN, quanto maior for o número de vizinhos (K), menor a probabilidade de *overfitting*.

Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 3 – Regressão - Questão 5

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

5 - O bootstrap pode ser usado para estimar os erros dos coeficientes de uma regressão Linear.

Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 3 – Regressão - Questão 6

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

6 - Grid Search é uma técnica estocástica para encontrar os melhores hiperparâmetros para um modelo.

Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 4 – Estatística - Questão 1

a) Sob o contexto de inferência estatística e teste de hipóteses, calcule um intervalo de confiança para a média do vetor [4, 13, 9, 9, 8, 8, 11, 10, 12, 7, 20, 11, 7, 16, 13] utilizando 1.000 reamostras de bootstrap. Considere $z(1-\alpha\ 2/) = 1{,}96$.

Módulo 4 – Estatística - Questão 1

Voltar Avançar

Módulo 4 - Estatística - Questão 1

b) Uma gerente deve decidir sobre a concessão de empréstimos aos seus clientes. Para tal, ela deve analisar diversas informações para definir a chance do cliente ficar inadimplente. Com base em dados passados, ela estima em 15% a taxa de inadimplência. Dentre os inadimplentes, ela tem 90% de chance de tomar a decisão certa, enquanto essa chance aumenta para 95% entre os clientes adimplentes. Essa gerente acaba de recusar um empréstimo, qual é a probabilidade da decisão tomada estar correta?

Módulo 4 - Estatística - Questão 1

Voltar Avançar

Módulo 4 – Estatística - Questão 2

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

2 - Considerando três eventos quaisquer A, B e C, com probabilidade de ocorrência maior que zero, pode-se afirmar que se os eventos forem independentes então P (A ∩ B ∩ C) = P(A ∩ B) * P(C).

Verdadeiro

Falso

Voltar Avançar

Módulo 4 – Estatística - Questão 3

Assinale as alternativas com V ou F para Verdadeiro ou Falso respectivamente.
Atente para o fato que uma questão errada anula uma certa.
Em caso de dúvidas deixe em branco.

3 - Se dois eventos são disjuntos, então P(A ∩ B) = P(A) x P(B).

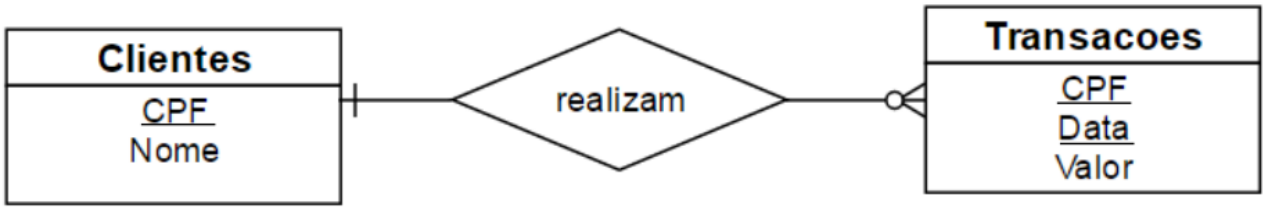
Verdadeiro

Falso

‹ Voltar Avançar ›

Módulo 5 – Banco de Dados - Questão 1

a) Suponha a existência de duas tabelas de dados conforme o Modelo Entidade Relacional (MER) abaixo:



Assinale a única alternativa correta que retorna os 100 clientes que transacionaram mais dinheiro.

SELECT SUM(Transacoes.Valor), clientes.CPF FROM Clientes INNER JOIN Transacoes ON Clientes.CPF=Transacoes.CPF GROUP BY clientes.CPF LIMIT 100;

SELECT a.* FROM (SELECT cpf, SUM(valor) as acumulado FROM transacoes GROUP BY cpf ORDER BY acumulado DESC) as a limit 100;

SELECT cpf, valor FROM transacoes order by cpf limit 100;

SELECT clientes.cpf, transacoes.valor FROM clientes LEFT JOIN transacoes ON clientes.cpf = transacoes.cpf ORDER BY transacoes.valor DESC LIMIT 100;

‹ Voltar Avançar ›

Módulo 5 – Banco de Dados - Questão 1

b) Assinale a única alternativa correta que retorna uma coluna que contenha a marcação 1 para as mulheres que transacionaram mais do que R$10.000,00 ao longo do tempo e 0 caso contrário.

SELECT c.CPF, CASE WHEN t.Valor > 10000 AND c.sexo = "F" then 1 else 0 end as resposta FROM clientes as c INNER JOIN Transacoes as t ON c.CPF=t.CPF

SELECT c.CPF, CASE WHEN t.Valor > 10000 AND c.sexo = "F" then 1 else 0 end as resposta FROM clientes as c INNER JOIN Transacoes as t ON c.CPF=t.CPF group by c.CPF, c.sexo;

SELECT c.CPF, CASE WHEN sum(t.Valor) > 10000 AND c.sexo = "F" then 1 else 0 end as resposta FROM clientes as c INNER JOIN Transacoes as t ON c.CPF=t.CPF group by c.CPF, c.sexo;

SELECT c.CPF, resposta FROM (SELECT CPF, 1 as resposta FROM Transacoes as t where sum(t.valor)>10000 group by t.CPF) as a INNER JOIN Clientes as c ON c.CPF=a.CPF where c.sexo = "F";

Voltar

Avançar