Baseado em Algoritmo

1. **Como uma ROC (Receiver Operating Characteristics) ajuda a avaliar um classificador? Você consegue interpretar efetivamente o gráfico assim obtido?**

   Descreve como o modelo é bom em prever a classe positiva quando o resultado real é positivo.
   Classificadores que dão curvas mais próximas do canto superior esquerdo indicam um melhor desempenho. Quanto mais próxima a curva chega à diagonal de 45 graus do espaço ROC, menos preciso é o teste. O ROC não depende da distribuição da classe, isso o torna útil para avaliar classificadores que predizem eventos raros, como doenças ou desastres

2. **Como o SVM usa "vetores de suporte" para definir o limite de decisão?**

   Ele encontra os pontos mais próximos da linha de ambas as classes, esses são os vetores de suporte, depois ele calcula a distância entre a linha de separação e os vetores de suporte que é chamado de margem, o hiperplano para qual a margem é máxima é o hiperplano ideal.

3. **Em que casos você usaria a Regressão de Ridge sobre a Regressão de Lasso?**

   Quando há muitos resíduos no conjunto de dados ou quando o número de atributos é maior que o número de amostras, a regressão fica sobreajustada (overfit) para os dados de treino, e não generaliza suficiente para o conjunto de teste.. Uma das formas de corrigir esse problema é aplicando regularização, forçando os coeficientes a residirem num espaço próximo. As duas normas mais comuns de regularização são LASSO e Ridge. Enquanto que Ridge favorece com coeficientes menores, LASSO favorece modelos que têm poucos coeficientes próximos de zero.

   Usaria o LASSO quando se deseja eliminar o maior número de atributos que não contribuem com o problema e o Ridge para limitar a magnitude dos coeficientes do modelo,para não ter um atributo que impacta demais.

4. **Qual é a diferença entre um modelo generativo e discriminativo?**

   O modelo discriminativo é um classificador, retorna se a saída é de uma classe ou de outra, o generativo é um preditor, ele prevê a saída, mas também pode ser usado como um classificador.

5. **Como você pode lidar eficientemente com um conjunto de dados desequilibrado e melhorar a pontuação de um recall?**

   Quando os dados estão muito desbalanceados fica difícil chegar em um resultado satisfatório, se após treinamento com vários algorítmos não funcionar e não for possível coletar mais dados, seria interessante realizar engenharia de atributos.

6. **Indique os métodos de imputação que você tentou ao lidar com valores ausentes em seus projetos.**

   Quando existem dados faltantes podem ser usadas algumas estratégias, como simplesmente remover o atributo ou tentar preenchê-lo de forma sintética. Preencher de forma sintética pode gerar uma falsa distribuição quando o número de atributos faltantes é muito alto. Quando este for o caso, é sempre seguro optar por remover o atributo inteiro. Também é importante lembrar que a estratégia de preenchimento deve ser coerente com o tipo de dado, por exemplo, dados ordinais não devem ser preenchidos com média, nem dados contínuos com moda. Em determinado projeto eu apaguei os dados faltantes, em outro preenchi com média ou moda dependendo do atributo, e em outro simplesmente completei com zeros, mas isso vai depender de cada caso.

7. **.Pegue um algoritmo como o XGBoost. Como isso bate facilmente outros algoritmos mais "clássicos" como KNN e Logistic Regression?**

   Porque ele tenta ajustar os dados usando vários modelos mais simples, se tornando um modelo eficiente.

8. **Por que o ReLU é melhor e mais usado do que a função Sigmoid no NN?**

   Porque o ReLU é mais simples computacionalmente e reduz bastante o custo computacional para treinamento da rede. Isso permite o treinamento de redes maiores com mais parâmetros com o mesmo custo computacional. Já a Sigmoid requer o cálculo de um expoente, quando se lida com grandes redes com muitos neurônios pode reduzir significativamente tanto o treinamento quanto os tempos de avaliação.

9. **Por que temos o pool máximo na classificação CNN?**

   O pool máximo é uma maneira de reduzir a dimensionalidade das representações intermediárias, o objetivo é reduzir a amostragem de uma representação de entrada e também reduzir o custo computacional por haver menos parâmetros para serem aprendidos.

10. **Mencione os casos de uso técnicas de redução de dimensionalidade PCA e TruncatedSVD? Como esses dois diferem no contexto da PNL?**

    A transformação do corpus em atributos contendo as frequências TF-IDF em geral resultará numa matriz bastante esparsa, ou seja, com muitas dimensões. Porém, além de isso tornar o treinamento de algoritmos mais demorado e custoso (computacionalmente falando), muitas dessas dimensões provavelmente são pouco representativas ou mesmo podem causar ruído durante o treinamento. Para resolver esse problema, podemos aplicar técnicas de redução de dimensionalidade como o PCA e o TruncatedSVD.

Baseado em programação geral

11. **Em que casos você mudaria para uma linguagem tipada dinamicamente de uma linguagem com tipagem estática?**

    Em casos que precise de mais flexibilidade e em pequenos desenvolvimentos.

12. **Como funciona uma tabela de hash?**

    Os registros armazenados em uma tabela são endereçados a partir de uma transformação aritmética sobre a chave de pesquisa.

13. **Existe uma diferença entre NoSQL e MySQL?**

    Os bancos de dados MySQL usam a linguagem de consulta estruturada para definir e manipular dados e exige que você use esquemas predefinidos para determinar a estrutura de seus dados antes de trabalhar com eles. Um banco de dados NoSQL, por outro lado, possui um esquema dinâmico para dados não estruturados e os dados são armazenados de várias maneiras: podem ser orientados por colunas, orientados a documentos, baseados em gráficos ou organizados como um armazenamento KeyValue.

14. **Como você implementaria um sistema de recomendação para os usuários de nossa empresa? Por que você escolheu seu método em detrimento dos outros métodos existentes?**

15. **Suponha que nossos clientes aumentem de 1.000 para 1100. Como você pode ter certeza de que isso não será aleatório, mas devido a alguma mudança real em nosso sistema?**

16. **Nossa startup de carros autônomos está passando por algumas dificuldades. Como você abordaria esse problema de aprendizado por reforço?**

17. **Um algoritmo de detecção facial projetado por nós está identificando incorretamente pessoas normais como ladrões? Alguma idéia para reduzir esses falsos positivos?**

    Na minha opinião seria necessário coletar mais dados e treinar novamente o modelo para evitar os erros.